Aula 10 — KNN e Árvores de Classificação

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §8.3–8.6; ISLP §4.7.6 e cap. 8

Objetivos da aula

Ao final desta aula o aluno deve ser capaz de:

- adaptar o KNN para classificação, pelo voto da maioria, e estimar $\mathbb{P}(Y = c \mid \boldsymbol{x})$ pelas proporções das classes entre os vizinhos;
- construir uma árvore de classificação e justificar a predição pela moda;
- definir as medidas de impureza de Gini e de entropia e justificar por que são preferidas à taxa de erro;
- usar florestas e *boosting* em classificação (voto, m, AdaBoost);
- comparar os classificadores vistos no curso quanto à fronteira, à interpretabilidade e ao desempenho.

Em sala

A aula fecha a classificação reaproveitando dois métodos não paramétricos vistos em regressão, o KNN (Aula 04) e as árvores (Aula 05). A estrutura dos dois não muda; muda o resumo de cada vizinhança ou folha, em que a média dá lugar à moda, e o critério de divisão das árvores, em que o EQM dá lugar à impureza.

1 KNN para classificação

Seja $\mathcal{N}_{\boldsymbol{x}}^{(k)} = \{i : d(\boldsymbol{X}_i, \boldsymbol{x}) \leq d_{\boldsymbol{x}}^k\}$ o conjunto dos índices das k observações de treino mais próximas de $\boldsymbol{x}$, como na Aula 04. O classificador dos k vizinhos mais próximos atribui a $\boldsymbol{x}$ a classe mais frequente entre os vizinhos, pelo voto da maioria:

$$\widehat{g}(\boldsymbol{x}) = \text{moda}\{Y_i : i \in \mathcal{N}_{\boldsymbol{x}}^{(k)}\}. \tag{1}$$

É um classificador *plug-in* (Aula 07). A estimativa

$$\widehat{\mathbb{P}}(Y = c \mid \boldsymbol{x}) = \frac{1}{k} \sum_{i \in \mathcal{N}_{\boldsymbol{x}}^{(k)}} \mathbf{1}\{Y_i = c\}\,,$$

a proporção de vizinhos da classe c, está em $[0, 1]$ e soma 1 sobre as classes; como $k\,\widehat{\mathbb{P}}(Y = c \mid \boldsymbol{x})$ é o número de votos da classe c, a classe de maior probabilidade estimada é a mais votada. E, como $\mathbb{P}(Y = c \mid \boldsymbol{X} = \boldsymbol{x}) = \mathbb{E}[\mathbf{1}\{Y = c\} \mid \boldsymbol{X} = \boldsymbol{x}]$, essa estimativa é o KNN de regressão da Aula 04 aplicado à indicadora $\mathbf{1}\{Y = c\}$.

Ideia central

k controla o balanço entre viés e variância, como na regressão: $k = 1$ dá uma fronteira muito recortada, com viés baixo e variância alta; k grande dá uma fronteira suave, com viés alto e variância baixa. Escolha k por validação cruzada (Aula 03).

Atenção

Valem os cuidados da Aula 04: *padronize* as covariáveis, porque o KNN se baseia numa distância, e lembre da *maldição da dimensionalidade*: o KNN não seleciona covariáveis e piora com muitas covariáveis irrelevantes. Em problemas binários, use k ímpar para evitar empates na votação.

2 Árvores de classificação

São o análogo das árvores de regressão (Aula 05): uma partição recursiva do espaço das covariáveis em regiões disjuntas $R_1, \ldots, R_J$. Para uma região R, sejam n_R o número de observações de treino em R e $\widehat{p}_{R,c}$ a proporção da classe c entre elas. Há duas adaptações.

2.1 Predição: a moda

Numa folha R_k, prediz-se a classe majoritária, em vez da média:

$$\widehat{g}(\boldsymbol{x}) = \text{moda}\{Y_i : \boldsymbol{X}_i \in R_k\}, \qquad \boldsymbol{x} \in R_k, \tag{2}$$

e $\widehat{\mathbb{P}}(Y = c \mid \boldsymbol{x}) = \widehat{p}_{R_k,c}$, a proporção da classe c na folha.

2.2 Critério de divisão: impureza

Em sala

Pergunta para a turma, antes das fórmulas: *"como uma árvore decide a melhor pergunta a fazer em cada nó quando o alvo é uma classe?"*

O EQM não faz sentido com Y qualitativo. Buscam-se divisões que tornem as regiões *puras*, idealmente com uma só classe, e mede-se a impureza de R por

$$\text{Índice de Gini:} \quad G(R) = \sum_{c \in \mathcal{C}} \widehat{p}_{R,c}\,(1 - \widehat{p}_{R,c}), \tag{3}$$

$$\text{Entropia:} \quad D(R) = -\sum_{c \in \mathcal{C}} \widehat{p}_{R,c}\,\log_2 \widehat{p}_{R,c}, \tag{4}$$

com a convenção $0 \log_2 0 = 0$. As duas se anulam se e somente se R é pura (algum $\widehat{p}_{R,c} = 1$) e são máximas quando as classes estão equilibradas, com $G(R) \leq 1 - 1/|\mathcal{C}|$ e $D(R) \leq \log_2 |\mathcal{C}|$. Com I igual a G ou a D, a divisão de R em R_1 e R_2, com n_1 e n_2 observações, é escolhida de modo a maximizar a redução de impureza

$$\Delta I = I(R) - \Big[\frac{n_1}{n_R}\, I(R_1) + \frac{n_2}{n_R}\, I(R_2)\Big],$$

o que equivale a minimizar a impureza ponderada $n_1 I(R_1) + n_2 I(R_2)$.

Observação 2.1 (Por que não usar a taxa de erro?)**.** A taxa de erro de classificação $E(R) = 1 - \max_c \widehat{p}_{R,c}$ também mede impureza, mas é insensível a mudanças nas proporções que não alterem a classe majoritária: no caso binário, ela é linear em cada metade de $[0, 1]$, e, se os dois filhos têm a mesma classe majoritária, a média ponderada dos erros deles é igual ao erro do pai. Gini e entropia são estritamente côncavas e respondem a qualquer melhora na pureza; por isso fazem divisões melhores. A taxa de erro é boa para a *poda* final.

Exemplo 2.2 (Escolha de divisão pelo Gini)**.** Para predizer se um hospital tem tomógrafo, o [AME] compara, em dez hospitais, a divisão por especialidade em cardiologia com a divisão por mais de 100 leitos. O Gini ponderado da divisão por cardiologia é $\frac{4}{10} \cdot \frac{1}{2} + \frac{6}{10} \cdot \frac{4}{9} = \frac{7}{15} \approx 0{,}467$, e o da divisão por leitos é $\frac{6}{10} \cdot \frac{5}{18} + \frac{4}{10} \cdot \frac{3}{8} = \frac{19}{60} \approx 0{,}317$; a de *menor* valor, a mais pura, é a divisão por leitos. O [AME] dá 0,472 e 0,326, porque soma $\widehat{p}(1 - \widehat{p})$ nas duas regiões sem ponderar pelo tamanho delas; a escolha é a mesma.

A construção segue as duas etapas da Aula 05: *cresce-se* uma árvore grande e depois ela é *podada* por custo–complexidade, com α escolhido por validação cruzada. Valem as mesmas vantagens: interpretabilidade, tratamento direto de covariáveis categóricas, seleção automática de covariáveis e captura de interações.

3 *Ensembles* para classificação

As formas de agregar árvores valem também em classificação, agora com árvores de classificação:

Bagging / Florestas
: B árvores ajustadas em amostras *bootstrap*, agregadas pelo voto da maioria ou pela média das probabilidades estimadas. As florestas diminuem a correlação entre as árvores sorteando m covariáveis candidatas em cada nó; em classificação, a regra empírica é $m \approx \sqrt{p}$. Aumentar B não leva a superajuste, e a estimativa OOB do risco e a importância das covariáveis saem sem custo adicional.

Boosting
: árvores ajustadas em sequência. A variante clássica em classificação é o AdaBoost: a cada rodada, as observações são reponderadas, com mais peso para as mal classificadas, e o classificador final é um voto ponderado dos aprendizes fracos. Um B grande pode levar a superajuste (use parada antecipada, *early stopping*); o XGBoost é a implementação de referência.

4 Comparando os classificadores do curso

Método	**Fronteira**	**Interpretab.**	**Observações**
Logística	linear (no *log-odds*)	alta (coefs.)	dá probabilidades; robusta
LDA / QDA	linear / quadrática	média	ótimos sob gaussianidade
Bayes ingênuo	depende	média	forte com texto; indep. condicional
KNN	muito flexível, local	baixa	sensível a escala e dimensão
Árvore	"escada" (eixos)	**altíssima**	instável sozinha
Florestas / Boosting	muito flexível	baixa	topo de desempenho em dados tabulares
SVM (kernel)	linear ou não linear	baixa	ótima com classes separadas

Ideia central

Nenhum método é melhor que os outros em todos os problemas ("não existe almoço grátis"). A escolha depende da estrutura dos dados e do objetivo: são necessárias probabilidades calibradas? interpretabilidade? há muitas covariáveis irrelevantes? a fronteira é não linear? Compare alguns candidatos por validação cruzada, com as métricas adequadas (Aula 08).

Em sala

Use os notebooks `Aula prática 10`, `Comparação entre classificadores paramétricos` e `Exemplo - KNN e árvores em dados artificiais` para mostrar as fronteiras de decisão lado a lado. É o melhor jeito de fixar a oposição entre métodos flexíveis e rígidos, que percorreu o curso inteiro.

Em sala: o item "probabilidades calibradas" não é preferência

A §7 da `Aula prática 10` refaz a tabela numa base em que a classe positiva é rara (10% das observações). Vale mostrar as duas medições:

- a acurácia varia de 0,8989 a 0,9072 entre os sete métodos, e quatro deles empatam exatamente com quem responde "não" para todos, porque nunca preveem a classe positiva; na mesma tabela, a AP varia de 0,119 a 0,453;
- com o corte de custo 1:20 da Aula 08, $1/21 \approx 0{,}0476$, a árvore podada e o AdaBoost mandam investigar todos os clientes, porque as probabilidades deles quase nunca ficam abaixo de 0,05; a cada mil clientes, entre os quais há 101 positivos, a logística manda investigar 410 e encontra 82, e a SVM manda 493 e encontra 89.

O ponto a registrar no quadro: o corte ótimo é ótimo para probabilidades calibradas. Pergunte à turma o que fazer com um modelo que ordena bem e calibra mal; a resposta vem da Aula 08, e é calibrar, não trocar de modelo.

Resumo

- KNN para classificação (1): voto da maioria; estima $\mathbb{P}(Y = c \mid \boldsymbol{x})$ pelas proporções entre os vizinhos; k por validação cruzada; padronize as covariáveis.
- Árvore de classificação: prediz a moda (2); divide pelo Gini (3) ou pela entropia (4), melhores que a taxa de erro; cresce e é podada como na Aula 05.
- Florestas ($m \approx \sqrt{p}$) e *boosting* (AdaBoost) agregam árvores por voto e estão entre os métodos de melhor desempenho em dados tabulares.
- Nenhum classificador é melhor em todos os problemas: escolha pela estrutura dos dados e pelo objetivo, e compare por validação cruzada com as métricas da Aula 08.

Leitura recomendada. [AME] §8.3 (árvores de classificação, índice de Gini), §8.4 e §8.5 (*bagging*, florestas, *boosting*), §8.6 (KNN); [ISLP] §4.7.6 (KNN) e Capítulo 8 (árvores e *ensembles*, incluindo critérios de impureza e *boosting*).