Lista Teórica 10 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 10 — KNN e Árvores de Classificação

Exercício 1. Uma engenheira de qualidade de uma fábrica de cerâmica usa uma árvore de classificação para prever se um lote de peças será reprovado ($Y = 1$) ou aprovado ($Y = 0$) na inspeção final, a partir de medidas do processo de produção. Para uma região R do espaço das covariáveis, sejam n_R o número de lotes de treino em R, $n_{R,c}$ o número deles na classe $c \in \{0, 1\}$ e $\widehat{p}_{R,c} = n_{R,c}/n_R$. O erro de classificação, o índice de Gini e a entropia de R são

$$E(R) = 1 - \max_c \widehat{p}_{R,c}, \qquad G(R) = \sum_c \widehat{p}_{R,c}\,(1 - \widehat{p}_{R,c}), \qquad D(R) = -\sum_c \widehat{p}_{R,c} \log_2 \widehat{p}_{R,c},$$

com a convenção $0 \log_2 0 = 0$. Se I é uma das três medidas e R é dividida em R_1 e R_2, com n_1 e n_2 lotes, a impureza ponderada do corte é $n_1 I(R_1) + n_2 I(R_2)$, e a redução de impureza é $n_R I(R) - \big[n_1 I(R_1) + n_2 I(R_2)\big]$. Como $n_R I(R)$ não depende do corte, o corte de menor impureza ponderada é o de maior redução.

Durante o crescimento da árvore, a engenheira examina uma região R com 180 lotes e um corte pela umidade da argila, que divide R em R_1 e R_2:

região	lotes	reprovados	aprovados
R	180	30	150
R_1	90	0	90
R_2	90	30	60

(a) Com duas classes, escreva $p = \widehat{p}_{R,1}$ e mostre que $E(R) = \min\{p, 1-p\}$, $G(R) = 2p(1-p)$ e $D(R) = -p \log_2 p - (1-p)\log_2(1-p)$. Mostre também que $n_R E(R)$ é o número de lotes de treino de R que a moda de R classifica errado.

(b) Calcule, para cada uma das três medidas, $n_R I(R)$, a impureza ponderada $n_1 I(R_1) + n_2 I(R_2)$ e a redução de impureza do corte da engenheira. Use $\log_2 3 \approx 1{,}585$ e $\log_2 5 \approx 2{,}322$.

(c) O corte é bom? Qual das três medidas não registra isso? Explique o valor que ela dá contando os erros de treino da moda em R, em R_1 e em R_2.

(d) Considere também um segundo corte, por outra covariável, que divide R em duas regiões de 90 lotes, cada uma com 15 reprovados. Calcule as três reduções desse corte e compare os dois cortes por cada uma das medidas. O que aconteceria se o algoritmo que cresce a árvore usasse o erro de classificação?

Solução

(a) Com duas classes, $\widehat{p}_{R,1} = p$ e $\widehat{p}_{R,0} = 1 - p$, porque cada lote de R pertence a exatamente uma delas. Como $1 - \max\{a, b\} = \min\{1 - a, 1 - b\}$,

$$E(R) = 1 - \max\{p, 1-p\} = \min\{1-p,\, p\},$$

e, somando as parcelas das duas classes,

$$G(R) = p\,(1-p) + (1-p)\,(1-(1-p)) = 2p(1-p).$$

A expressão de $D(R)$ é a própria definição, escrita com as suas duas parcelas.
Se R for uma folha, a árvore prediz para todos os lotes de R a sua moda, uma classe c^* com $n_{R,c^*} = \max_c n_{R,c}$. Ela acerta os n_{R,c^*} lotes dessa classe e erra todos os outros, que são

$$n_R - \max_c n_{R,c} = n_R\Big(1 - \max_c \widehat{p}_{R,c}\Big) = n_R E(R).$$

Se houver empate entre as classes, o número de erros é o mesmo qualquer que seja a classe escolhida. Assim, $E(R)$ é a taxa de erro de treino da moda de R, e $n_R E(R)$ é o número desses erros.

(b) A proporção de reprovados é $30/180 = 1/6$ em R, 0 em R_1 e $30/90 = 1/3$ em R_2. A região R_1 é pura, e as suas três impurezas são nulas: o item (a) dá $E(R_1) = G(R_1) = 0$ e, com a convenção $0 \log_2 0 = 0$, $D(R_1) = 0$. Nas outras duas regiões,

$$G(R) = 2 \cdot \tfrac{1}{6} \cdot \tfrac{5}{6} = \tfrac{5}{18}, \qquad G(R_2) = 2 \cdot \tfrac{1}{3} \cdot \tfrac{2}{3} = \tfrac{4}{9},$$

e, como $-\log_2 p = \log_2(1/p)$,

$$D(R) = \tfrac{1}{6}\log_2 6 + \tfrac{5}{6}\log_2 \tfrac{6}{5} = \log_2 6 - \tfrac{5}{6}\log_2 5 = 1 + \log_2 3 - \tfrac{5}{6}\log_2 5 \approx 0{,}650,$$

$$D(R_2) = \tfrac{1}{3}\log_2 3 + \tfrac{2}{3}\log_2 \tfrac{3}{2} = \log_2 3 - \tfrac{2}{3} \approx 0{,}918.$$

Multiplicando cada impureza pelo número de lotes da região:

medida	$n_R I(R)$	$n_1 I(R_1) + n_2 I(R_2)$	redução
E	$180 \cdot \frac{1}{6} = 30$	$90 \cdot 0 + 90 \cdot \frac{1}{3} = 30$	0
G	$180 \cdot \frac{5}{18} = 50$	$90 \cdot 0 + 90 \cdot \frac{4}{9} = 40$	10
D	$180 \cdot 0{,}650 \approx 117{,}0$	$90 \cdot 0 + 90 \cdot 0{,}918 \approx 82{,}6$	$\approx 34{,}4$

Em forma exata, a redução da entropia é $240 + 90\log_2 3 - 150\log_2 5 \approx 34{,}36$.
As reduções de medidas diferentes não se comparam entre si, porque cada medida tem a sua escala: com duas classes, E e G valem no máximo $1/2$, e D, no máximo 1. O que se compara são cortes diferentes pela mesma medida, como no item (d).

(c) O corte é bom. A região R_1 é pura: os 90 lotes que ela contém, metade dos lotes de R, foram todos aprovados. Para um lote novo com umidade abaixo do corte, os dados de treino não registram nenhuma reprovação; antes do corte, a mesma pergunta tinha como resposta a proporção de R, um lote reprovado em cada seis. As 30 reprovações ficam concentradas em R_2.
A medida que não registra isso é o erro de classificação, cuja redução é exatamente zero. Pelo item (a), $n_R E(R)$, $n_1 E(R_1)$ e $n_2 E(R_2)$ são os números de erros de treino das modas das três regiões. A moda é "aprovado" em todas elas: 150 contra 30 em R, 90 contra 0 em R_1 e 60 contra 30 em R_2. Antes do corte, a moda de R erra os 30 lotes reprovados; depois, a de R_1 não erra nenhum lote, e a de R_2 erra os mesmos 30. O corte não muda a classe prevista para nenhum lote de treino, e por isso não pode mudar o número de erros, que é tudo o que E mede.
O Gini e a entropia, ao contrário, registram o ganho. Para ver de onde ele vem, use $n_R = n_1 + n_2$ e escreva a redução região por região:

$$n_R I(R) - \big[n_1 I(R_1) + n_2 I(R_2)\big] = n_1\big[I(R) - I(R_1)\big] - n_2\big[I(R_2) - I(R)\big].$$

O primeiro termo é o ganho de pureza dos lotes que foram para R_1, e o segundo, a perda dos que foram para R_2, onde a proporção de reprovados subiu de $1/6$ para $1/3$. As três

medidas concordam que R_1 melhorou e R_2 piorou; o que muda é o peso de cada parte. Para o erro de classificação, $90(\frac{1}{6}-0)-90(\frac{1}{3}-\frac{1}{6})=15-15=0$, e o ganho e a perda se cancelam. Para o Gini, $90(\frac{5}{18}-0)-90(\frac{4}{9}-\frac{5}{18})=25-15=10$, e, para a entropia, $90\,(0{,}650-0)-90\,(0{,}918-0{,}650)\approx 58{,}5-24{,}1=34{,}4$: o ganho supera a perda.
É a mesma situação do exemplo dos dados `Heart` no [ISLP] §8.1.2: um corte cujas duas folhas preveem a mesma classe não reduz o erro de classificação e, ainda assim, é feito, porque aumenta a pureza.

(d) No segundo corte, as duas regiões têm a mesma proporção de reprovados que R, $15/90=1/6$. Como as três medidas dependem da região só pelas proporções das classes, cada região tem a mesma impureza que R, e

$$n_1 I(R_1)+n_2 I(R_2)=90\,I(R)+90\,I(R)=n_R I(R)\,:$$

as três reduções são nulas. O corte não separa nada, e as duas regiões reproduzem, em proporção, a região original.
Pelo Gini e pela entropia, os dois cortes ficam bem distintos, com reduções 10 contra 0 e 34,4 contra 0. Pelo erro de classificação, os dois têm redução zero e ficam empatados. Se o algoritmo que cresce a árvore usasse o erro de classificação, ele não teria como preferir o corte da engenheira, que isola 90 lotes sem nenhuma reprovação, a um corte que não muda nada. O argumento do item (c) mostra mais: sempre que as duas partes de um corte mantêm a classe prevista em R, nenhuma previsão de treino muda, e a redução do erro de classificação é zero. Numa região em que todos os cortes candidatos fossem desse tipo, esse critério não distinguiria corte nenhum. É por isso que a árvore cresce com o Gini ou com a entropia.

Exercício 2. Um estudante quer entender o papel de k no KNN de classificação e começa pelos dois valores extremos, $k=1$ e $k=n$. Ele tem $n=301$ observações de treino de duas classes, 181 da classe 1 e 120 da classe 0, com vetores de covariáveis $\boldsymbol{X}_1,\dots,\boldsymbol{X}_n$ distintos dois a dois, e usa a distância euclidiana d. Lembre-se que o classificador é

$$\widehat{g}(\boldsymbol{x})=\text{moda}\{Y_i : i\in\mathcal{N}_{\boldsymbol{x}}^{(k)}\},\qquad\text{com}\qquad \mathcal{N}_{\boldsymbol{x}}^{(k)}=\{i : d(\boldsymbol{X}_i,\boldsymbol{x})\le d_{\boldsymbol{x}}^{k}\},$$

em que $d_{\boldsymbol{x}}^{k}$ é a distância de $\boldsymbol{x}$ à k-ésima observação de treino mais próxima.

(a) Mostre que, com $k=1$, o classificador acerta todas as observações de treino. Mostre que, com $k=n$, ele atribui a mesma classe a todo $\boldsymbol{x}$. Calcule o erro de treino para cada um desses casos.

(b) Descreva a fronteira de decisão nos dois casos. Suponha, em seguida, que o estudante descubra que alguns rótulos foram registrados errado e os corrija, trocando 1 por 0. Qual é o menor número de rótulos trocados que muda o classificador com $k=1$? E com $k=n$? Relacione as respostas com o viés e a variância de cada caso.

(c) Pelo item (a), o estudante conclui que $k=1$ é a melhor escolha, porque com ela o classificador não erra nenhuma observação de treino. O argumento está certo? Como k deve ser escolhido, e por que esse procedimento não teria o mesmo problema de $k=1$?

Solução

(a) Com $k=1$, tome uma observação de treino $\boldsymbol{X}_i$. Como d é uma distância, $d(\boldsymbol{X}_i,\boldsymbol{X}_i)=0$, e $d(\boldsymbol{X}_j,\boldsymbol{X}_i)>0$ para todo $j\neq i$, porque os vetores são distintos. Logo $d_{\boldsymbol{X}_i}^{1}=0$, $\mathcal{N}_{\boldsymbol{X}_i}^{(1)}=\{i\}$ e $\widehat{g}(\boldsymbol{X}_i)=\text{moda}\{Y_i\}=Y_i$: cada observação de treino é a sua própria vizinha mais próxima,

e a taxa de erro de treino é zero. A hipótese de vetores distintos é necessária. Se $\boldsymbol{X}_i = \boldsymbol{X}_j$ com $Y_i \neq Y_j$, o classificador atribui uma única classe a esse ponto e erra ao menos uma das duas observações, qualquer que seja a regra de desempate.

Com $k = n$, $d_{\boldsymbol{x}}^n$ é a distância de $\boldsymbol{x}$ à observação de treino mais distante, e todas as observações satisfazem $d(\boldsymbol{X}_i, \boldsymbol{x}) \leq d_{\boldsymbol{x}}^n$. Então $\mathcal{N}_{\boldsymbol{x}}^{(n)} = \{1, \ldots, n\}$ para todo $\boldsymbol{x}$, e $\widehat{g}(\boldsymbol{x})$ é a moda de todos os rótulos de treino: a classe 1, com 181 observações contra 120. O classificador não depende de $\boldsymbol{x}$; é o classificador constante que prediz a classe majoritária. Ele erra exatamente as 120 observações da classe 0, e a taxa de erro de treino é $120/301 \approx 0{,}399$, a proporção da classe minoritária.

(b) Com $k = 1$, cada $\boldsymbol{x}$ recebe a classe da observação de treino mais próxima. O espaço fica dividido em regiões, uma para cada $\boldsymbol{X}_i$, formadas pelos pontos mais próximos de $\boldsymbol{X}_i$ do que de qualquer outra observação de treino, e a fronteira de decisão é formada pelas bordas comuns a regiões de observações de classes diferentes. Ela acompanha cada observação: é muito recortada, e uma observação isolada no meio da outra classe cria uma ilha em torno de si, como na Figura 1 da Aula 10. Com $k = n$, não há fronteira: todo $\boldsymbol{x}$ é atribuído à classe 1.

Com $k = 1$, um único rótulo trocado já muda o classificador. Se Y_i passa de 1 a 0, o item (a) dá $\widehat{g}(\boldsymbol{X}_i) = 0$, onde antes era 1. A mudança não se restringe ao ponto $\boldsymbol{X}_i$. Seja $\delta = \min_{j \neq i} d(\boldsymbol{X}_i, \boldsymbol{X}_j)$, que é positivo porque os vetores são distintos. Se $d(\boldsymbol{x}, \boldsymbol{X}_i) < \delta/2$, a desigualdade triangular dá, para todo $j \neq i$,

$$d(\boldsymbol{x}, \boldsymbol{X}_j) \;\geq\; d(\boldsymbol{X}_i, \boldsymbol{X}_j) - d(\boldsymbol{x}, \boldsymbol{X}_i) \;>\; \delta - \frac{\delta}{2} \;=\; \frac{\delta}{2} \;>\; d(\boldsymbol{x}, \boldsymbol{X}_i),$$

de modo que $\boldsymbol{X}_i$ é a vizinha mais próxima de $\boldsymbol{x}$, e a previsão muda em toda a bola de raio $\delta/2$ centrada em $\boldsymbol{X}_i$.

Com $k = n$, o classificador só muda se mudar a classe majoritária. Com m rótulos trocados, as classes passam a ter $181 - m$ e $120 + m$ observações, e a classe 0 se torna majoritária se e somente se $120 + m > 181 - m$, isto é, $m > 30{,}5$. Com até 30 trocas, o classificador não muda em ponto nenhum; com 31, quaisquer que sejam, muda em todos.

Em classificação, a aula usa viés e variância no mesmo sentido da regressão: a variância diz o quanto o classificador ajustado muda quando a amostra de treino muda, e o viés, o quanto ele erra de forma sistemática, mesmo com muitos dados. As contagens acima medem a variância de forma direta. Com $k = 1$, o classificador depende de cada observação individualmente, e um rótulo diferente basta para mudá-lo numa região inteira: a variância é alta. Com $k = n$, ele depende da amostra só pela classe majoritária, que resiste a 30 trocas em 301: a variância é baixa. O viés vai no sentido oposto. Com $k = n$, o classificador ignora $\boldsymbol{x}$; se a proporção de cada classe varia ao longo do espaço das covariáveis, ele erra sistematicamente onde a classe 0 predomina, por maior que seja n, e o viés é alto. Com $k = 1$, a decisão em $\boldsymbol{x}$ vem da observação de treino mais próxima, e, quando há observações perto de $\boldsymbol{x}$, ela acompanha essa variação: o viés é baixo.

(c) O argumento não está certo. O item (a) mostrou que o erro de treino do 1-NN é zero em qualquer conjunto de treino com vetores distintos, qualquer que seja a relação entre $\boldsymbol{X}$ e Y. Ele seria zero mesmo que Y fosse independente de $\boldsymbol{X}$. Nesse caso, as covariáveis não trazem informação nenhuma sobre a classe, o classificador de Bayes da Aula 07 prediz sempre a classe mais provável, e nenhum classificador erra menos do que ele em observações novas. Um número que vale zero em qualquer situação não informa nada sobre o desempenho em observações novas, que é o que o risco mede. O erro de treino do 1-NN é zero porque cada observação de treino é usada para prever a si mesma. Como a aula indica, k deve ser escolhido por validação cruzada. Nela, cada observação é prevista por um classificador ajustado sem ela. No LOOCV com $k = 1$, por exemplo, a

observação i é prevista pelo rótulo da mais próxima entre as outras $n-1$, e há erro sempre que esse rótulo é diferente de Y_i. Como a observação deixada de fora não é mais vizinha de si mesma, todos os valores de k passam a ser comparados pelo erro em observações que não participaram do ajuste, que estima o risco (Aula 03). Na Figura 1 da Aula 10, com $n = 300$, o 1-NN tem acurácia de treino 1,000 e a pior acurácia de teste das três, 0,826, contra 0,888 com $k = 15$ e 0,889 com $k = 120$.