Lista Teórica 10

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 10 — KNN e Árvores de Classificação

Exercício 1. Uma engenheira de qualidade de uma fábrica de cerâmica usa uma árvore de classificação para prever se um lote de peças será reprovado ($Y = 1$) ou aprovado ($Y = 0$) na inspeção final, a partir de medidas do processo de produção. Para uma região R do espaço das covariáveis, sejam n_R o número de lotes de treino em R, $n_{R,c}$ o número deles na classe $c \in \{0, 1\}$ e $\widehat{p}_{R,c} = n_{R,c}/n_R$. O erro de classificação, o índice de Gini e a entropia de R são

$$E(R) = 1 - \max_c \widehat{p}_{R,c}, \qquad G(R) = \sum_c \widehat{p}_{R,c}\,(1 - \widehat{p}_{R,c}), \qquad D(R) = -\sum_c \widehat{p}_{R,c} \log_2 \widehat{p}_{R,c},$$

com a convenção $0 \log_2 0 = 0$. Se I é uma das três medidas e R é dividida em R_1 e R_2, com n_1 e n_2 lotes, a impureza ponderada do corte é $n_1 I(R_1) + n_2 I(R_2)$, e a redução de impureza é $n_R I(R) - \big[n_1 I(R_1) + n_2 I(R_2)\big]$. Como $n_R I(R)$ não depende do corte, o corte de menor impureza ponderada é o de maior redução.

Durante o crescimento da árvore, a engenheira examina uma região R com 180 lotes e um corte pela umidade da argila, que divide R em R_1 e R_2:

região	lotes	reprovados	aprovados
R	180	30	150
R_1	90	0	90
R_2	90	30	60

(a) Com duas classes, escreva $p = \widehat{p}_{R,1}$ e mostre que $E(R) = \min\{p, 1 - p\}$, $G(R) = 2p(1 - p)$ e $D(R) = -p \log_2 p - (1 - p) \log_2(1 - p)$. Mostre também que $n_R E(R)$ é o número de lotes de treino de R que a moda de R classifica errado.

(b) Calcule, para cada uma das três medidas, $n_R I(R)$, a impureza ponderada $n_1 I(R_1) + n_2 I(R_2)$ e a redução de impureza do corte da engenheira. Use $\log_2 3 \approx 1{,}585$ e $\log_2 5 \approx 2{,}322$.

(c) O corte é bom? Qual das três medidas não registra isso? Explique o valor que ela dá contando os erros de treino da moda em R, em R_1 e em R_2.

(d) Considere também um segundo corte, por outra covariável, que divide R em duas regiões de 90 lotes, cada uma com 15 reprovados. Calcule as três reduções desse corte e compare os dois cortes por cada uma das medidas. O que aconteceria se o algoritmo que cresce a árvore usasse o erro de classificação?

Exercício 2. Um estudante quer entender o papel de k no KNN de classificação e começa pelos dois valores extremos, $k = 1$ e $k = n$. Ele tem $n = 301$ observações de treino de duas classes, 181 da classe 1 e 120 da classe 0, com vetores de covariáveis $\boldsymbol{X}_1, \ldots, \boldsymbol{X}_n$ distintos dois a dois, e usa a distância euclidiana d. Lembre-se que o classificador é

$$\widehat{g}(\boldsymbol{x}) = \text{moda}\{Y_i : i \in \mathcal{N}_{\boldsymbol{x}}^{(k)}\}, \qquad \text{com} \qquad \mathcal{N}_{\boldsymbol{x}}^{(k)} = \{i : d(\boldsymbol{X}_i, \boldsymbol{x}) \le d_{\boldsymbol{x}}^{k}\},$$

em que $d_{\boldsymbol{x}}^{k}$ é a distância de $\boldsymbol{x}$ à k-ésima observação de treino mais próxima.

(a) Mostre que, com $k = 1$, o classificador acerta todas as observações de treino. Mostre que, com $k = n$, ele atribui a mesma classe a todo $\boldsymbol{x}$. Calcule o erro de treino para cada um desses casos.

(b) Descreva a fronteira de decisão nos dois casos. Suponha, em seguida, que o estudante descubra que alguns rótulos foram registrados errado e os corrija, trocando 1 por 0. Qual é o menor número de rótulos trocados que muda o classificador com $k = 1$? E com $k = n$? Relacione as respostas com o viés e a variância de cada caso.

(c) Pelo item (a), o estudante conclui que $k = 1$ é a melhor escolha, porque com ela o classificador não erra nenhuma observação de treino. O argumento está certo? Como k deve ser escolhido, e por que esse procedimento não teria o mesmo problema de $k = 1$?