

Aula 10 — Máquinas de Vetores de Suporte (SVM)

Curso de Aprendizado de Máquina — UFRJ

Leitura recomendada: AME §8.2 e §4.6; ISLP cap. 9

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- definir hiperplano separador e o **classificador de margem máxima**;
- identificar os **vetores de suporte** e o papel da margem;
- generalizar para dados não separáveis com o **classificador de vetor de suporte** (*soft margin*) e o hiperparâmetro C ;
- explicar o **truque do kernel** a partir da forma dual;
- usar *kernels* (polinomial, gaussiano/RBF) para fronteiras não lineares e entender γ ;
- reconhecer a SVM como minimização da *perda* hinge regularizada e sua relação com a regressão logística; tratar o caso multiclasse.

Mudança de perspectiva em relação à Aula 08. Lá, todo método passava por modelar $\mathbb{P}(Y | \mathbf{x})$ e depois aplicar o Teorema de Bayes. A SVM ignora probabilidades e ataca a fronteira *geometricamente*, procurando a separação mais folgada possível. É um dos métodos mais elegantes do curso — liga geometria, otimização e os RKHS da Aula 04. Comece pela pergunta:

se há infinitos hiperplanos que separam as classes, qual é o melhor?

1 Hiperplanos e o classificador de margem máxima

Codifique as classes como $y \in \{-1, +1\}$. Um **hiperplano** em $\mathbb{R}^d$ é o conjunto $\{\mathbf{x} : f(\mathbf{x}) = 0\}$ com $f(\mathbf{x}) = \beta_0 + \beta^\top \mathbf{x}$. Ele separa o espaço em dois lados conforme o sinal de f . Dizemos que os dados são *linearmente separáveis* se existe f tal que

$$y_i f(\mathbf{X}_i) > 0 \quad \text{para todo } i. \quad (1)$$

A magnitude $|f(\mathbf{x})|$ (com $\|\beta\| = 1$) é a *distância* de $\mathbf{x}$ ao hiperplano.

Ideia central: por que a codificação ± 1

Não é capricho de notação. Com $y \in \{-1, +1\}$, o produto $y_i f(\mathbf{X}_i)$ é positivo exatamente quando a classificação está certa, e seu *valor* mede o quanto ela está certa. Essa única quantidade — a **margem** da observação i — vai organizar a aula inteira, inclusive a função de perda da Seção 4.

Definição 1.1 (Classificador de margem máxima). Procura-se o hiperplano que maximiza a margem M :

$$\max_{\beta_0, \beta} M \quad \text{s.a.} \quad \sum_{j=1}^d \beta_j^2 = 1, \quad y_i f(\mathbf{X}_i) \geq M \quad \forall i.$$

A restrição $\|\beta\| = 1$ torna os hiperplanos comparáveis (assim $y_i f(\mathbf{X}_i)$ é a distância com sinal). As observações que *atingem* a margem ($y_i f(\mathbf{X}_i) = M$) são os **vetores de suporte**.

Atenção

Apenas os vetores de suporte determinam o hiperplano: mover um ponto longe da margem não muda *nada*. Isso é bom e ruim ao mesmo tempo. Bom: o modelo é econômico, definido por um punhado de observações. Ruim: a formulação *exige* separabilidade perfeita e é **muito sensível** — mover um único vetor de suporte pode girar a fronteira inteira. Precisamos relaxá-la.

2 O classificador de vetor de suporte (*soft margin*)

Para lidar com dados não separáveis (e ganhar robustez), permitimos que algumas observações violem a margem, introduzindo *folgas* $e_i \geq 0$:

$$\max_{\beta_0, \beta, e} M \quad \text{s.a.} \quad \|\beta\| = 1, \quad y_i f(\mathbf{X}_i) \geq M(1 - e_i) \quad \forall i, \quad e_i \geq 0, \quad \sum_{i=1}^n e_i \leq C. \quad (2)$$

A folga e_i mede o quanto a i -ésima observação viola a margem: $e_i > 0$ significa dentro da margem; $e_i > 1$ significa do *lado errado* do hiperplano (erro de classificação).




Figura 1: O mesmo conjunto de 40 pontos com três orçamentos de violação. A linha cheia é a fronteira; as tracejadas delimitam a margem; os pontos circulosados em verde são os **vetores de suporte**. Aumentar a tolerância a violações alarga a margem e traz mais pontos para dentro dela: de 3 vetores de suporte e margem 0,50 até 18 vetores de suporte e margem 2,80. Quanto mais pontos sustentam a solução, menos ela depende de cada um — daí a robustez. **Atenção ao rótulo:** este é o C do `scikit-learn`, cuja convenção é a inversa da de (2).

Ideia central

C é o **tuning parameter**, escolhido por validação cruzada (Aula 03). Na convenção de (2) — a do [AME] e do [ISLP] — C é o *orçamento de violações*:

- C *grande*: tolera muitas violações $\Rightarrow$ margem larga, mais vetores de suporte, modelo mais *rígido* (alto viés, baixa variância);
- C *pequeno*: poucas violações $\Rightarrow$ margem estreita, modelo mais *flexível* (baixo viés, alta variância).

É o balanço viés-variância da Aula 01 outra vez.

Atenção: a inversão que já derrubou muita gente

No `scikit-learn`, o C é o *peso da penalidade* sobre as violações, não o orçamento delas. Portanto tudo se inverte: C grande penaliza mais, tolera menos, e dá margem *estreita*. É o que a Figura 1 mostra. Ao ler qualquer texto sobre SVM, confira qual convenção está em uso antes de interpretar “ C grande”.

3 O truque do *kernel*

A chave que torna a SVM poderosa: a solução depende dos dados *apenas através de produtos internos*. Pode-se mostrar que a função ótima se escreve

$$f(\mathbf{x}) = \beta_0 + \sum_{k=1}^n \alpha_k \langle \mathbf{x}, \mathbf{X}_k \rangle, \quad \langle \mathbf{x}, \mathbf{X}_k \rangle = \sum_{j=1}^d x_j x_{k,j}, \quad (3)$$

e que o cálculo dos α_k também só requer os produtos internos $\langle \mathbf{X}_i, \mathbf{X}_k \rangle$ entre as observações. Crucialmente, $\alpha_k = 0$ para todos os pontos que *não* são vetores de suporte; logo

$$f(\mathbf{x}) = \beta_0 + \sum_{k \in S} \alpha_k \langle \mathbf{x}, \mathbf{X}_k \rangle,$$

onde S é o conjunto de vetores de suporte.

Ideia central

Como tudo depende só de produtos internos, podemos **substituir** $\langle \mathbf{x}, \mathbf{X}_k \rangle$ por um *kernel* $K(\mathbf{x}, \mathbf{X}_k)$ — que corresponde a um produto interno num espaço de *features* de dimensão muito maior (ou infinita), sem *nunca* computar esse espaço explicitamente. Isso é o **truque do kernel**: fronteiras não lineares no espaço original a custo de fronteiras lineares num espaço ampliado.

Exemplo 3.1 (o truque em duas dimensões). Tome $K(\mathbf{x}, \mathbf{x}') = (\langle \mathbf{x}, \mathbf{x}' \rangle)^2$ em $\mathbb{R}^2$. Expandindo,

$$(x_1 x'_1 + x_2 x'_2)^2 = (x_1^2)(x_1'^2) + 2(x_1 x_2)(x_1' x_2') + (x_2^2)(x_2'^2) = \langle \phi(\mathbf{x}), \phi(\mathbf{x}') \rangle,$$

com $\phi(\mathbf{x}) = (x_1^2, \sqrt{2} x_1 x_2, x_2^2)$. Ou seja: calcular *um* produto e elevá-lo ao quadrado equivale a mapear os pontos para $\mathbb{R}^3$ e fazer o produto interno lá. Com o kernel polinomial de grau p em $\mathbb{R}^d$ o espaço tem dimensão $\binom{d+p}{p}$, e com o RBF ele é *de dimensão infinita* — e o custo continua sendo uma conta com d termos. É esse o negócio.

Kernels de Mercer comuns (cf. Aula 04, §4.6):

Kernel	$K(\mathbf{x}, \mathbf{x}')$
Linear	$\langle \mathbf{x}, \mathbf{x}' \rangle$
Polinomial	$(1 + \langle \mathbf{x}, \mathbf{x}' \rangle)^p$
Gaussiano (RBF)	$\exp(-\gamma \ \mathbf{x} - \mathbf{x}'\ ^2)$

No kernel gaussiano, $\gamma > 0$ é um *tuning parameter*: γ grande $\Rightarrow$ influência local, fronteiras muito flexíveis (risco de superajuste); γ pequeno $\Rightarrow$ fronteiras suaves. Escolhem-se C e γ juntos por validação cruzada.




Figura 2: Duas classes dispostas em anéis concêntricos — o exemplo canônico do que uma reta não resolve. O kernel linear acerta 60%, pouco acima do palpite. O polinomial de grau 2 encontra a circunferência exata e sobe para 99,4%, e o RBF com $\gamma = 0,5$ faz o mesmo. Já o RBF com $\gamma = 50$ produz uma fronteira rendilhada que persegue observações individuais: γ é um botão de flexibilidade e, como todos os outros do curso, superajusta se você o girar demais.

4 SVM como perda *hinge* regularizada

Há uma leitura que conecta a SVM a tudo o que vimos. Dado um kernel de Mercer K com RKHS $\mathcal{H}_K$ (Aula 04), o classificador da SVM minimiza

$$\min_{g \in \mathcal{H}_K} \sum_{k=1}^n \underbrace{(1 - y_k g(\mathbf{X}_k))_+}_{\text{perda hinge}} + \lambda \|g\|_{\mathcal{H}_K}^2, \quad (4)$$

onde $(u)_+ = \max(u, 0)$. Ou seja, a SVM é *ajuste de perda + regularização* (Aula 02), com a **perda *hinge*** $L(y, g) = (1 - yg)_+$.

Observação 4.1. A perda *hinge* é **zero** quando $yg(\mathbf{x}) \geq 1$, isto é, quando o ponto está do lado certo e *folgadoamente* longe da margem. Só os pontos próximos ou violando a margem contribuem — e são exatamente os *vetores de suporte*. No caso separável, (4) reencontra a margem máxima $(1/\|g\|)$.




Figura 3: As três perdas como função da margem $yg(x)$. A 0-1 é o que gostaríamos de minimizar, mas ela é descontínua e constante por partes — otimizar sobre ela é NP-difícil. A *hinge* e a logística são substitutas convexas: ambas majoram a 0-1 e são tratáveis. A diferença decisiva está na faixa sombreada: a *hinge* **zera** a partir da margem 1, e todos os pontos ali param de influenciar a solução — é daí que vem a esparsidade em vetores de suporte. A logística nunca chega a zero, e por isso *todo* ponto pesa um pouco.

4.1 Relação com a regressão logística

A SVM (*hinge*) e a regressão logística (perda logística $\log(1 + e^{-y\theta})$) são ambas “perda de margem + regularização ℓ_2 ”:

- a *hinge* é exatamente zero longe da margem $\Rightarrow$ solução *esparsa* em vetores de suporte; a logística nunca é zero;
- a logística entrega **probabilidades** calibradas (Aula 09); a SVM entrega só a fronteira. As “probabilidades” do SVC vêm de um ajuste *a posteriori* (escala de Platt), não do método.

Regra prática: classes bem separadas $\rightarrow$ SVM costuma ir muito bem; quando se quer $\mathbb{P}(Y | \mathbf{x})$, prefira a logística.

5 Mais de duas classes

A SVM é intrinsecamente binária — não há como escrever “ $y_i f(\mathbf{X}_i) > 0$ ” com três classes. Para $|\mathcal{C}| > 2$, contorna-se com vários classificadores binários:

Um-contra-um (OvO)

treina uma SVM para cada par de classes ($\binom{K}{2}$ classificadores) e classifica por votação. Cada ajuste usa só os dados de duas classes, então são muitos problemas pequenos. Padrão do `scikit-learn`.

Um-contra-todos (OvA)

treina K SVMs (cada classe vs. o resto) e escolhe a de maior $f(\mathbf{x})$. São K problemas grandes, e cada um deles fica desbalanceado — com a ressalva da Aula 09.

6 Prática em Python

```

1 from sklearn.svm import SVC
2 from sklearn.preprocessing import StandardScaler
3 from sklearn.pipeline import make_pipeline
4 from sklearn.model_selection import GridSearchCV
5
6 # SVM com kernel RBF; padronizar e ESSENCIAL (metodo baseado em distancia)
7 pipe = make_pipeline(StandardScaler(), SVC(kernel="rbf"))
8 grade = {"svc__C": [0.1, 1, 10, 100],
9          "svc__gamma": [0.001, 0.01, 0.1, 1]}
10 busca = GridSearchCV(pipe, grade, cv=5, scoring="accuracy")
11 busca.fit(X_tr, y_tr)
12 print("melhores parametros:", busca.best_params_)
13
14 # Para probabilidades: SVC(probability=True) (usa Platt scaling, mais lento)

```

Atenção

Três observações práticas. (i) SVM com RBF é **sensível à escala** — a distância $\|\mathbf{x} - \mathbf{x}'\|^2$ do kernel soma todas as coordenadas, então *sempre* padronize dentro do *pipeline* (Aula 07). (ii) C e γ interagem, e por isso a busca é numa *grade bidimensional*, não em dois passos separados. (iii) O custo de treino do SVC cresce entre $O(n^2)$ e $O(n^3)$: com centenas de milhares de observações ele fica inviável, e a saída é o `LinearSVC` ou aproximações de kernel (`Nystroem`).

O notebook `Exemplo - SVM em dados artificiais` ilustra o efeito de C , γ e da escolha do kernel sobre a fronteira de decisão.

Resumo

- **Margem máxima:** hiperplano separador de maior folga; definido pelos *vetores de suporte*; exige separabilidade e é frágil.
- **Soft margin** (2): folgas e_i e orçamento C controlam o balanço viés-variância (Fig. 1). Cuidado com a convenção invertida de C no `scikit-learn`.
- **Truque do kernel:** a solução só depende de produtos internos (3); trocá-los por K dá fronteiras não lineares (Fig. 2), e γ do RBF é mais um botão de flexibilidade.
- SVM = **perda hinge** + regularização (4) (RKHS, Aula 04); a hinge zera longe da margem, e é daí que vem a esparsidade (Fig. 3).
- Relação com a logística (perda de margem + ℓ_2); SVM não dá probabilidades de imediato.
- Multiclasse por OvO/OvA; *padronize* sempre.

Leitura recomendada. [AME] §8.2 (SVM) e §4.6 (RKHS e o truque do kernel, onde o mesmo maquinário aparece em regressão). [ISLP] Capítulo 9 inteiro: §9.1 (margem máxima), §9.2 (vetor de suporte e o papel de C — a Figura 9.7 deles é a nossa Figura 1), §9.3 (kernels, com a versão deles da nossa Figura 2), §9.4 (multiclasse) e §9.5 (relação com a logística, de onde vem a nossa Figura 3).

Para praticar. `recursos/listas/Lista de exercícios 08.pdf`.