

Lista Teórica 10

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 10 — Máquinas de Vetores de Suporte (SVM)

Exercício 1 — a margem, na mão. Quatro observações em $\mathbb{R}^2$, linearmente separáveis:

	<i>A</i>	<i>B</i>	<i>C</i>	<i>D</i>
$\mathbf{x}_i$	(3, 1)	(3, 3)	(1, 1)	(1, 3)
y_i	+1	+1	-1	-1

Lembre que o hiperplano de margem máxima é escrito na forma canônica $\mathbf{w}^\top \mathbf{x} + b = 0$ com $y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1$ para todo i , e que a margem de cada lado vale $1/\|\mathbf{w}\|$.

- Desenhe os quatro pontos e determine, por inspeção, o hiperplano de margem máxima. Escreva $\mathbf{w}$ e b na forma canônica e calcule a margem.
- Quais pontos são vetores de suporte?
- Acrescente $E = (5, 2)$ com $y_E = +1$. O hiperplano muda? Justifique sem refazer a conta.
- Agora mova A de (3, 1) para (2, 5; 1), mantendo os demais. Qual é o novo hiperplano e a nova margem? Quais são agora os vetores de suporte?

Exercício 2 — o que C faz, e por que ele é invertido. A SVM de margem suave resolve

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \quad \text{sujeito a} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

- Descreva o que acontece quando $C \rightarrow \infty$. Existe sempre solução?
- Descreva o que acontece quando $C \rightarrow 0$. O que ocorre com $\mathbf{w}$, com a margem e com o número de vetores de suporte?
- Portanto: C grande corresponde a um modelo mais *flexível* ou mais *rígido*? Compare com o papel de λ na Ridge (Aula 02) e explique por que essa comparação confunde tanta gente.
- Ao montar uma grade de busca para C , por que se usa `np.logspace(-3, 3, 7)` e não `np.linspace(0.001, 1000, 7)`?

Exercício 3 — o truque do kernel, explicitamente. Em $\mathbb{R}^2$, considere o kernel polinomial de grau 2

$$K(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^\top \mathbf{z} + 1)^2.$$

- Expandir K e exibir um mapa $\varphi: \mathbb{R}^2 \rightarrow \mathbb{R}^m$ tal que $K(\mathbf{x}, \mathbf{z}) = \varphi(\mathbf{x})^\top \varphi(\mathbf{z})$. Qual é m ?
- Conte as operações necessárias para calcular $K(\mathbf{x}, \mathbf{z})$ pelos dois caminhos: pela fórmula fechada e via φ .
- Em $\mathbb{R}^d$, o espaço de atributos do kernel polinomial de grau p tem $\binom{d+p}{p}$ dimensões. Calcule para $d = 100$, $p = 3$ e para $d = 1000$, $p = 3$.
- Enuncie em uma frase o que é o “truque do kernel”, usando os números do item (c).

Exercício 4 — a perda *hinge* e a esparsidade. A SVM de margem suave é equivalente a minimizar

$$\sum_{i=1}^n \underbrace{\max(0, 1 - y_i f(\mathbf{x}_i))}_{\text{perda } hinge} + \lambda \|\mathbf{w}\|^2, \quad f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b.$$

- (a) Complete a tabela abaixo com o valor das três perdas, em função da *margem funcional* $m = yf(\mathbf{x})$.

$m = yf(\mathbf{x})$	-1	0	0,5	1	2
0-1: $\mathbb{K}\{m < 0\}$					
<i>hinge</i> : $\max(0, 1 - m)$					
logística: $\ln(1 + e^{-m})$					

- (b) Para quais valores de m a perda *hinge* vale exatamente zero? Relacione com o conceito de vetor de suporte.
- (c) A perda logística vale zero para algum m finito? Que consequência isso tem sobre *quais* observações influenciam o ajuste de uma regressão logística?
- (d) Por que não se minimiza diretamente a perda 0-1, que é a que realmente interessa?