

Lista Teórica 11

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 11 — KNN e Árvores de Classificação

Exercício 1 — o corte que o erro de classificação não enxerga. Um nó tem 400 observações, das quais 300 são da classe 1 — logo $p = 0,75$. Um corte candidato o divide em dois filhos de 200 observações cada:

	n	classe 1	classe 0
pai	400	300	100
esquerda	200	100	100
direita	200	200	0

As três medidas de impureza de um nó com proporção p são

$$\text{erro} = \min(p, 1 - p), \quad \text{Gini} = 2p(1 - p), \quad \text{entropia} = -p \log_2 p - (1 - p) \log_2 (1 - p).$$

- Calcule a impureza do pai e a impureza ponderada dos filhos, pelas três medidas, e obtenha as três reduções.
- O corte é bom? (Olhe o filho da direita.) Qual das três medidas *não percebe* isso, e qual é exatamente a redução que ela indica?
- Que consequência isso tem para o algoritmo que **cresce** a árvore?
- Ainda assim, o erro de classificação é a medida recomendada para **podar**. Por quê?

Exercício 2 — KNN nos extremos, em classificação.

- Qual é o erro de *treino* do KNN com $k = 1$, num conjunto sem pontos repetidos? E com $k = n$ (supondo n ímpar)?
- Descreva a fronteira de decisão nos dois extremos, em termos de viés e variância.
- Um resultado clássico (Cover e Hart, 1967) diz que, quando $n \rightarrow \infty$, o erro do classificador de 1 vizinho mais próximo, R_{1NN} , satisfaz

$$R^* \leq R_{1NN} \leq 2 R^*,$$

onde R^* é o erro de Bayes. Se $R^* = 0,10$, em que intervalo está o erro assintótico do 1-NN? Comente: isso é uma boa ou uma má notícia sobre o 1-NN?

- Por que, na prática, o KNN com k escolhido por validação cruzada costuma bater o 1-NN, se o teorema já garante um fator 2?

Exercício 3 — o que cada classificador supõe. Complete a tabela abaixo para os classificadores vistos no curso.

classificador	suposição principal	forma da fronteira	gera./discr.
regressão logística			
LDA			
QDA			
naive Bayes gaussiano			
KNN			
árvore			
SVM linear			
SVM com RBF			

- (a) Preencha as três colunas.
- (b) Quais desses métodos produzem estimativas de $\mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$ diretamente? Quais delas você usaria numa conta de custo esperado, à luz da Aula 09?
- (c) Dois deles são *invariantes* a transformações monótonas de cada covariável separadamente (trocar x_j por $\log x_j$, por exemplo). Quais são, e por quê? Que consequência prática isso tem?

Exercício 4 — concavidade: por que Gini sempre ganha algo. Seja $\phi : [0, 1] \rightarrow \mathbb{R}$ uma medida de impureza e considere um nó com proporção p dividido em dois filhos de pesos w e $1 - w$ e proporções p_E e p_D , com

$$p = w p_E + (1 - w) p_D$$

- (a proporção do pai é sempre a média ponderada das dos filhos — confira isso no Exercício 1).
- (a) Mostre que, se ϕ é **côncava**, a redução de impureza $\phi(p) - [w \phi(p_E) + (1 - w) \phi(p_D)]$ é sempre ≥ 0 .
- (b) Mostre que, se ϕ é **estritamente** côncava, a redução é > 0 sempre que $p_E \neq p_D$.
- (c) Verifique que $\phi(p) = \min(p, 1 - p)$ é côncava mas **não** estritamente. Use isso para explicar, em uma linha, o resultado do Exercício 1.
- (d) Mostre que o Gini $2p(1 - p)$ é a **variância** de uma Bernoulli(p). Que interpretação isso dá à “redução de impureza de Gini”?