Aula Extra E1 — Análise de Agrupamento: k-Médias

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME cap. 11; ISLP §12.4

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- distinguir aprendizado supervisionado de *não supervisionado* e dizer por que a avaliação fica mais difícil;
- escolher uma medida de *dissimilaridade* e entender que essa escolha define o que é um "grupo";
- enunciar o objetivo do **k-médias** (WCSS) e executar o **algoritmo de Lloyd**;
- explicar por que Lloyd converge, e para o quê;
- escolher K pelo *cotovelo* e pela *silhueta*, sabendo dos limites de ambos;
- descrever o **agrupamento hierárquico** e o papel do *linkage*.

Viramos a chave para o aprendizado não supervisionado: aqui **não há rótulos** Y. O objetivo deixa de ser "prever" e passa a ser "descobrir estrutura". Isso muda tudo, a começar pela pergunta:

sem uma resposta certa, como sabemos se um agrupamento é bom?

Guarde a pergunta: ela é genuinamente mais difícil do que qualquer coisa que vimos em regressão ou em classificação, e a resposta honesta — Seção 3.2 — é que não há critério definitivo.

1 Aprendizado não supervisionado

Até aqui observávamos pares $(\boldsymbol{X}_i, Y_i)$. No **aprendizado não supervisionado** observamos apenas as covariáveis $\boldsymbol{X}_1, \ldots, \boldsymbol{X}_n$, *sem* rótulos, e buscamos estrutura nos dados. Duas grandes tarefas: *agrupamento* (esta aula) e *redução de dimensionalidade* (Aula E2).

Atenção

Sem rótulos, não há "risco" nem "erro de teste" no sentido das aulas anteriores. Toda a maquinaria das Aulas 01 e 03 — que existia para estimar $\mathbb{E}[L(Y, g(\boldsymbol{X}))]$ — simplesmente não se aplica, porque não há Y. A avaliação passa a ser mais sutil e frequentemente subjetiva: o agrupamento é "bom" se for *útil* e *interpretável* no problema. Volte a esta caixa ao ler a Seção 3.2.

2 O problema de agrupamento

Agrupar (*clustering*) é particionar os índices $\{1, \ldots, n\}$ em grupos $C_1, \ldots, C_K$ disjuntos cuja união é o todo, de modo que elementos do *mesmo* grupo sejam *parecidos* e elementos de grupos *diferentes* sejam *distintos*. "Parecido" exige uma medida de **dissimilaridade** $d(\boldsymbol{x}_i, \boldsymbol{x}_j)$. Exemplos:

Medida	$d(\boldsymbol{x}_i, \boldsymbol{x}_j)$
Euclidiana	$\sqrt{\sum_{k=1}^{p}(x_{i,k} - x_{j,k})^2}$
Manhattan	$\sum_{k=1}^{p} \lvert x_{i,k} - x_{j,k}\rvert$
Cosseno	$1 - \dfrac{\boldsymbol{x}_i \cdot \boldsymbol{x}_j}{\lVert\boldsymbol{x}_i\rVert \, \lVert\boldsymbol{x}_j\rVert}$
Jaccard	adequada a dados binários (presença/ausência)

Ideia central

A escolha da medida *define* o que significa "grupo". Um exemplo esclarece: dois textos, um com 50 palavras e outro com 5000, sobre exatamente o mesmo assunto, ficam *longe* na distância euclidiana (as contagens têm magnitudes diferentes) e *perto* na distância cosseno (que só olha a direção, isto é, as proporções relativas de palavras). Por isso o cosseno é padrão em texto (Aula E3), e por isso **escolher a dissimilaridade é a primeira decisão de modelagem** — ela vem antes de qualquer algoritmo.

3 k-Médias

O k-médias usa a distância **euclidiana** e exige fixar K de antemão. Busca a partição que minimiza a **soma de quadrados dentro dos grupos** (WCSS):

$$\min_{C_1,\ldots,C_K} \sum_{k=1}^{K} \frac{1}{2\,|C_k|} \sum_{i,j \in C_k} d^2(\boldsymbol{x}_i, \boldsymbol{x}_j) \;=\; \min_{C_1,\ldots,C_K} \sum_{k=1}^{K} \sum_{i \in C_k} \lVert \boldsymbol{x}_i - \boldsymbol{c}_k \rVert^2 , \tag{1}$$

onde $\boldsymbol{c}_k = \frac{1}{|C_k|} \sum_{i \in C_k} \boldsymbol{x}_i$ é o **centroide** do grupo k. A igualdade acima não é óbvia e vale reter: minimizar a dispersão *par-a-par* dentro do grupo equivale a minimizar a soma das distâncias ao *centroide*. É ela que transforma um problema sobre $\binom{|C_k|}{2}$ pares num problema sobre um único ponto por grupo — e é por isso que o algoritmo abaixo é tão simples.

Atenção

Há K^n atribuições possíveis: otimizar (1) exatamente é inviável (o problema é NP-difícil). Usamos uma heurística iterativa — o algoritmo de Lloyd — que encontra um *mínimo local*. É o mesmo tipo de concessão que fizemos ao crescer árvores de forma gananciosa na Aula 05.

3.1 Algoritmo de Lloyd

Algoritmo de Lloyd (k-médias)

1. **Inicialização:** escolha K centroides $\boldsymbol{c}_1, \ldots, \boldsymbol{c}_K$ (ex. aleatoriamente entre os dados). Itere até convergir:
2. **Atribuição:** associe cada ponto ao centroide mais próximo, $C_k = \{\boldsymbol{x}_i : \arg\min_r \lVert \boldsymbol{x}_i - \boldsymbol{c}_r \rVert = k\}$.
3. **Atualização:** recalcule cada centroide como a média do seu grupo, $\boldsymbol{c}_k \leftarrow \frac{1}{|C_k|} \sum_{i \in C_k} \boldsymbol{x}_i$.

Proposição 3.1 (Lloyd não aumenta a WCSS)**.** *Cada iteração do algoritmo de Lloyd não aumenta o objetivo* (1)*; como há finitas partições, o algoritmo converge em número finito de passos.*

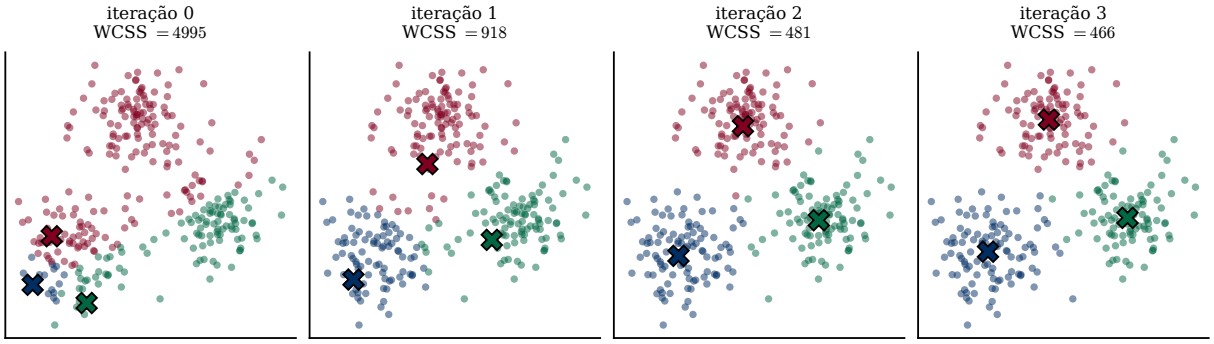


Figura 1: Lloyd em ação sobre 300 pontos, partindo de uma inicialização deliberadamente ruim (os três centroides amontoados no canto inferior esquerdo). Os "X" são os centroides. Em três iterações eles se espalham e encontram os três grupos, e a WCSS cai de 4995 para 918, depois 481 e 466 — decrescendo a cada passo, como a Proposição 3.1 garante, e com ganhos cada vez menores.

Esboço. O passo de *atribuição* reduz (ou mantém) a soma das distâncias ao centroide, pois cada ponto vai ao centroide mais próximo. O passo de *atualização* também reduz (ou mantém), pois a média é o ponto que minimiza $\sum_{i \in C_k} \|\boldsymbol{x}_i - \boldsymbol{c}\|^2$. Como o objetivo decresce monotonicamente e só há finitas partições, há convergência.

Atenção

Preste atenção no que a proposição **não** diz. Ela garante que o algoritmo *para*, e que para num ponto onde nenhum dos dois passos melhora nada. Não garante que esse ponto seja o mínimo global de (1) — e em geral não é.

Atenção: Mínimos locais e inicialização

Lloyd converge para um mínimo *local* que **depende da inicialização**: sementes ruins levam a agrupamentos ruins. Soluções:

- rodar várias vezes com inícios diferentes e ficar com a menor WCSS (`n_init` no `scikit-learn`) — barato e eficaz;
- usar ***k*-médias++**: escolhe os centroides iniciais *espalhados* — o primeiro ao acaso e cada seguinte com probabilidade proporcional ao quadrado da distância ao centroide mais próximo já escolhido, $p_i \propto D^2(\boldsymbol{x}_i)$. Aumenta muito a chance de bom resultado, e é o padrão do `scikit-learn`.

3.2 Escolhendo o número de grupos K

K é o "*tuning parameter*", mas — e aqui está a diferença fundamental em relação ao resto do curso — **sem um erro de teste para minimizar**. Não dá para usar validação cruzada, porque não há nada contra o que validar. Restam heurísticas:

Cotovelo plote a WCSS contra K. Ela *sempre* cai com K (com $K = n$, WCSS $= 0$), então minimizá-la é inútil; procure o "cotovelo", onde o ganho marginal despenca.

Silhueta mede, para cada ponto, quão melhor ele se encaixa no seu grupo do que no grupo vizinho mais próximo. Ao contrário da WCSS, ela *tem* máximo interior — e por isso pode ser otimizada de fato.

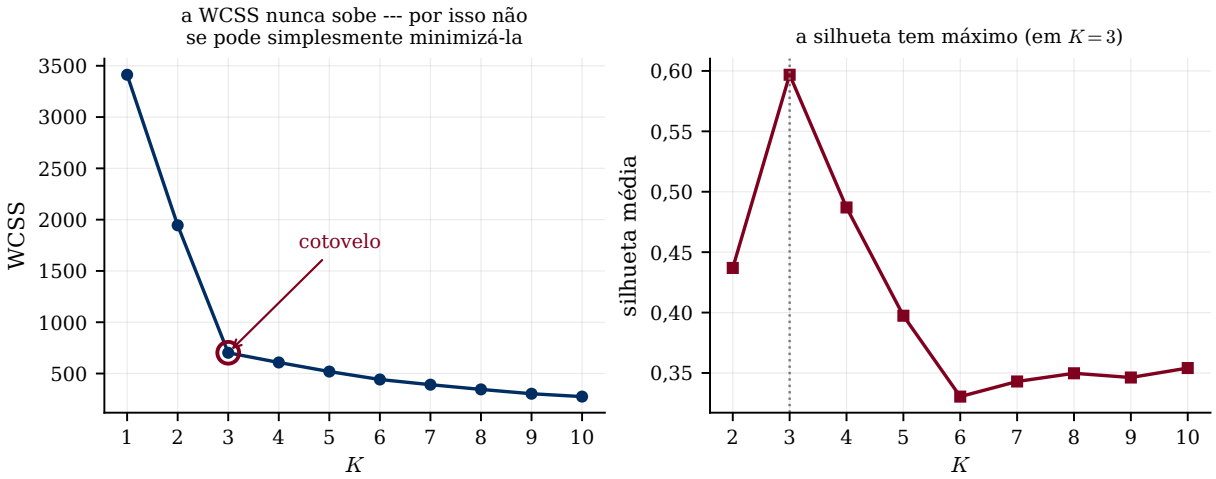


Figura 2: As duas heurísticas nos mesmos dados, que *de fato* têm três grupos. À esquerda a WCSS: ela desaba de $K = 1$ a $K = 3$ e depois cai devagar — o cotovelo em $K = 3$. À direita a silhueta média, que tem um máximo bem definido, também em $K = 3$. Note a assimetria: o cotovelo é um julgamento visual (e nem sempre há um cotovelo), enquanto a silhueta dá um número.

Ideia central

Aqui está a resposta honesta à pergunta de abertura: **não existe critério definitivo**. As duas heurísticas concordaram nesta figura porque os dados foram gerados com três grupos bem separados. Em dados reais elas frequentemente discordam, e nenhum dos dois números tem o *status* que um erro de teste tem. O critério final é o que a caixa lá do começo dizia: o agrupamento é bom se for útil e interpretável no seu problema. Isso não é um defeito da técnica — é o que significa não ter rótulos.

Exemplo 3.2 (Compressão de imagens)**.** Trate cada *pixel* como um ponto em $\mathbb{R}^3$ (cores R, G, B) e rode k-médias com K pequeno. Substituindo cada pixel pela cor do seu centroide, a imagem passa a usar só K cores — uma **compressão** (quantização de cor). K controla a qualidade. (É o exemplo do [AME]; compare com a compressão por SVD da Aula E2, que ataca o mesmo problema por outro caminho.)

Atenção: a silhueta não escolhe o K da compressão — e não deveria

Vale juntar as duas coisas acima, porque elas discordam por um fator de dez. A §8 da `Aula prática E1` comprime a `flower.jpg` e mede os dois critérios nos mesmos pixels:

- a **silhueta** tem máximo em $K = 2$ (+0,766) e cai monotonamente daí em diante: +0,71 em $K = 3$, +0,50 em $K = 4$, +0,44 em $K = 6$;
- o **olho** só deixa de distinguir o resultado do original entre 16 e 32 cores — e $K = 32$ ocupa 21% do arquivo original.

Não é a silhueta errando. Ela responde *"existem grupos bem separados?"*, e a nuvem de cores de uma fotografia não tem grupos: é um contínuo, com no máximo duas regiões densas. A resposta $K = 2$ está certa para a pergunta que ela faz.

A compressão faz outra pergunta — *"quantos representantes bastam para o erro de reconstrução ficar imperceptível?"* — e essa não exige grupo nenhum, só pontos bem espalhados pela nuvem. É *quantização vetorial*, não análise de agrupamento; o algoritmo é o mesmo e o critério de sucesso não.

A regra que sobra vale além de imagens: **antes de escolher K por uma métrica, saiba para que o K serve.** Silhueta, cotovelo e afins medem separação. Se o seu uso é

resumir, comprimir ou pré-processar, o critério certo é o erro da tarefa que vem depois.

4 Agrupamento hierárquico

Ao contrário do k-médias, o agrupamento hierárquico (*aglomerativo*) **não exige fixar** K e produz uma hierarquia de grupos:

1. comece com cada ponto em seu próprio grupo;
2. repetidamente *funda* os dois grupos mais próximos;
3. pare quando restar um único grupo.

O resultado é um **dendrograma** (árvore), que se "corta" a uma altura para obter o número desejado de grupos. A noção de "distância entre grupos" é o *linkage*:

Linkage	**Distância entre grupos A e B**
Completo (*complete*)	$\max_{i\in A, j\in B} d(\boldsymbol{x}_i, \boldsymbol{x}_j)$ — grupos compactos
Simples (*single*)	$\min_{i\in A, j\in B} d(\boldsymbol{x}_i, \boldsymbol{x}_j)$ — tende a "encadear"
Médio (*average*)	média das distâncias entre pares
Ward	minimiza o aumento da WCSS na fusão

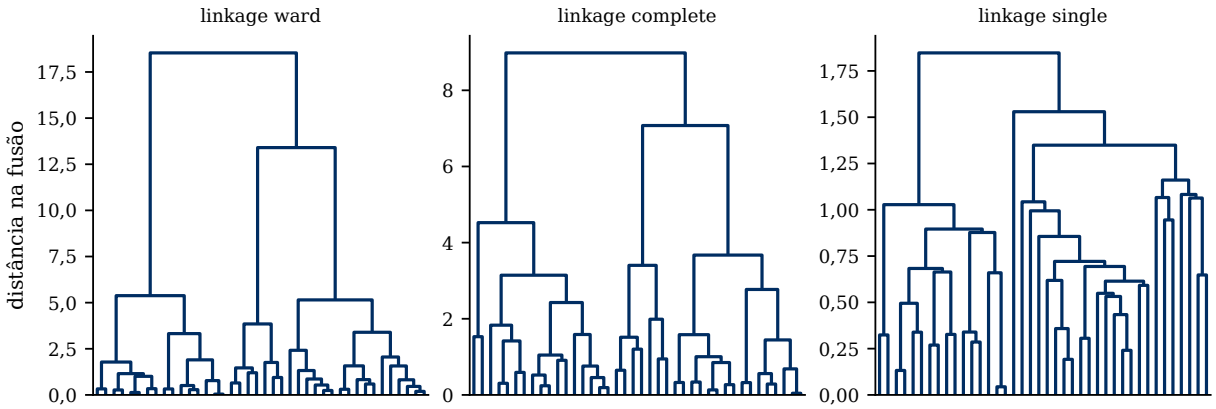


Figura 3: O mesmo conjunto de 40 pontos, três *linkages*. A altura de cada fusão é a distância entre os grupos fundidos, e cortar o dendrograma numa altura dá os grupos correspondentes. Ward e completo produzem árvores equilibradas, com fusões altas e bem separadas — fácil escolher onde cortar. O *single* exibe o *encadeamento* característico: ele funde repetidamente um ponto de cada vez ao mesmo grupo grande, porque basta *um* par próximo para aproximar dois grupos inteiros.

Ideia central

A vantagem do hierárquico é entregar *todas* as partições de uma vez: você decide K *depois* de olhar a estrutura, em vez de antes. A desvantagem é o custo — $O(n^2)$ de memória só para guardar as distâncias, o que o inviabiliza com centenas de milhares de pontos, onde o k-médias vai bem.

5 Prática em Python

```
from sklearn.cluster import KMeans, AgglomerativeClustering
from sklearn.metrics import silhouette_score
from sklearn.preprocessing import StandardScaler
```

```
X = StandardScaler().fit_transform(X) # PADRONIZE: k-medias usa distancia

for K in range(2, 11):
    km = KMeans(n_clusters=K, n_init=10, random_state=0).fit(X)
    print(K, "WCSS:", km.inertia_, "silhueta:", silhouette_score(X, km.labels_))

# hierarquico: o dendrograma vem do scipy
from scipy.cluster.hierarchy import dendrogram, linkage
dendrogram(linkage(X, method="ward"))
```

Atenção

O `StandardScaler` não é opcional aqui, pelo mesmo motivo do KNN (Aula 04): a distância euclidiana soma as coordenadas, e uma variável em unidades grandes domina o agrupamento inteiro. E note que *não há* `predict` honesto para avaliar — a diferença entre este trecho e todos os anteriores do curso é a ausência de `y`.

Os notebooks `Aula prática E1` e `EXTRA K-medias (exemplo)` exploram o k-médias, a escolha de K e o efeito da inicialização.

Resumo

- Sem rótulos não há risco a estimar: a avaliação é parcialmente subjetiva.
- A *dissimilaridade* escolhida define o que é um grupo — é a primeira decisão de modelagem, não um detalhe.
- **k-médias** minimiza a WCSS (1); o problema exato é NP-difícil e usamos o algoritmo de **Lloyd**, que converge (Prop. 3.1) para um mínimo *local* (Fig. 1).
- Inicialização importa: use `n_init` alto e k-médias++.
- K por *cotovelo* (a WCSS nunca sobe, então não se minimiza) ou por *silhueta* (tem máximo) — e nenhum dos dois é definitivo (Fig. 2).
- **Hierárquico**: dendrograma, sem fixar K; o *linkage* muda radicalmente o resultado (Fig. 3); custo $O(n^2)$.
- *Padronize* sempre.

Leitura recomendada. [AME] Capítulo 11: §11.1 (k-médias, com o exemplo da compressão de imagens), §11.2 (agrupamento espectral, que não vimos aqui e resolve casos em que o k-médias falha por causa da geometria dos grupos) e §11.3 (métodos hierárquicos). [ISLP] §12.4 — §12.4.1 (k-médias, com uma figura das iterações de Lloyd equivalente à nossa Figura 1), §12.4.2 (hierárquico e *linkage*) e, muito recomendável, §12.4.3 (*Practical Issues in Clustering*), que discute em detalhe a fragilidade das escolhas desta aula.

Para praticar. `Lista teorica E1.pdf` (teórica, com gabarito) e `Lista prática E1.ipynb` (prática, para completar as lacunas), nesta mesma pasta.