

# Aula Extra E1 — Análise de Agrupamento: $k$ -Médias

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME cap. 11; ISLP §12.4

## Objetivos da aula

Ao final desta aula o aluno deve ser capaz de:

- situar o **aprendizado não supervisionado** e o problema de *agrupamento*;
- escolher uma medida de **dissimilaridade** adequada ao contexto;
- formular o objetivo do  $k$ -**médias** (soma de quadrados intra-grupo) e executar o **algoritmo de Lloyd**;
- explicar por que o  $k$ -médias cai em mínimos locais e como o  $k$ -**médias++** ajuda;
- escolher o número de grupos  $K$  (cotovelo, silhueta);
- descrever o **agrupamento hierárquico** e o dendrograma.

### Em sala

Viramos a chave para o Bloco III: aqui *não há rótulos*  $Y$ . O objetivo deixa de ser “prever” e passa a ser “descobrir estrutura”. Pergunta de abertura: “*sem uma resposta certa, como sabemos se um agrupamento é bom?*” — pergunta genuinamente mais difícil que em aprendizado supervisionado.

## 1 Aprendizado não supervisionado

Até aqui observávamos pares  $(\mathbf{X}_i, Y_i)$ . No **aprendizado não supervisionado** observamos apenas as covariáveis  $\mathbf{X}_1, \dots, \mathbf{X}_n$ , *sem* rótulos, e buscamos estrutura nos dados. Duas grandes tarefas: *agrupamento* (esta aula) e *redução de dimensionalidade* (Aula E2).

### Atenção

Sem rótulos, não há “risco” nem “erro de teste” no sentido das aulas anteriores. A avaliação é mais sutil e frequentemente subjetiva: o agrupamento é “bom” se for *útil* e *interpretável* no problema. Isso torna a validação um ponto delicado — volte a esta caixa ao discutir a escolha de  $K$ .

## 2 O problema de agrupamento

*Agrupar (clustering)* é particionar os índices  $\{1, \dots, n\}$  em grupos  $C_1, \dots, C_K$  disjuntos cuja união é o todo, de modo que elementos do *mesmo* grupo sejam *parecidos* e elementos de grupos *diferentes* sejam *distintos*. “Parecido” exige uma medida de **dissimilaridade**  $d(\mathbf{x}_i, \mathbf{x}_j)$ . Exemplos:

| Medida     | $d(\mathbf{x}_i, \mathbf{x}_j)$                                                 |
|------------|---------------------------------------------------------------------------------|
| Euclidiana | $\sum_{k=1}^p (x_{i,k} - x_{j,k})^2$                                            |
| Manhattan  | $\sum_{k=1}^p  x_{i,k} - x_{j,k} $                                              |
| Cosseno    | $1 - \frac{\mathbf{x}_i \cdot \mathbf{x}_j}{\ \mathbf{x}_i\  \ \mathbf{x}_j\ }$ |
| Jaccard    | adequada a dados binários (presença/ausência)                                   |

### Ideia central

A escolha da medida *define* o que significa “grupo”. A distância cosseno é padrão em texto (Aula E3); a euclidiana é a hipótese embutida no  $k$ -médias; Jaccard serve a dados de presença/ausência. **Escolher a dissimilaridade é a primeira decisão de modelagem.**

## 3 $k$ -Médias

O  $k$ -médias usa a distância **euclidiana** e exige fixar  $K$  de antemão. Busca a partição que minimiza a **soma de quadrados dentro dos grupos** (WCSS):

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \frac{1}{|C_k|} \sum_{i,j \in C_k} d^2(\mathbf{x}_i, \mathbf{x}_j) = \min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{c}_k\|^2, \quad (1)$$

onde  $\mathbf{c}_k = \frac{1}{|C_k|} \sum_{i \in C_k} \mathbf{x}_i$  é o **centroide** do grupo  $k$  (a igualdade acima é um fato útil: minimizar a dispersão par-a-par equivale a minimizar a soma das distâncias aos centroides).

### Atenção

Há  $K^n$  partições possíveis: otimizar (1) exatamente é inviável. Usamos uma heurística iterativa — o algoritmo de Lloyd — que encontra um *mínimo local*.

### 3.1 Algoritmo de Lloyd

#### Algoritmo de Lloyd ( $k$ -médias)

1. **Inicialização:** escolha  $K$  centroides  $\mathbf{c}_1, \dots, \mathbf{c}_K$  (ex. aleatoriamente entre os dados). Itere até convergir:
2. **Atribuição:** associe cada ponto ao centroide mais próximo,  $C_k = \{\mathbf{x}_i : \arg \min_r \|\mathbf{x}_i - \mathbf{c}_r\| = k\}$ .
3. **Atualização:** recalcule cada centroide como a média do seu grupo,  $\mathbf{c}_k \leftarrow \frac{1}{|C_k|} \sum_{i \in C_k} \mathbf{x}_i$ .

**Proposição 3.1** (Lloyd não aumenta a WCSS). *Cada iteração do algoritmo de Lloyd não aumenta o objetivo (1); como há finitas partições, o algoritmo converge em número finito de passos.*

*Esboço.* O passo de *atribuição* reduz (ou mantém) a soma das distâncias ao centroide, pois cada ponto vai ao centroide mais próximo. O passo de *atualização* também reduz (ou mantém), pois a média é o ponto que minimiza  $\sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{c}\|^2$  (Proposição análoga à da Aula 01). Como o objetivo decresce monotonicamente e só há finitas partições, há convergência.

**Atenção: Mínimos locais e inicialização**

Lloyd converge para um mínimo *local* que **depende da inicialização**: sementes ruins levam a agrupamentos ruins. Soluções:

- rodar várias vezes com inícios diferentes e ficar com a menor WCSS (`n_init` no `scikit-learn`);
- usar *k-médias++*: escolhe os centroides iniciais *espalhados* — o primeiro ao acaso e cada seguinte com probabilidade proporcional ao quadrado da distância ao centroide mais próximo já escolhido,  $p_i \propto D^2(\mathbf{x}_i)$ . Aumenta muito a chance de bom resultado.

**3.2 Escolhendo o número de grupos  $K$** 

$K$  é o “*tuning parameter*”, mas *sem* um erro de teste para minimizar. Heurísticas:

**Cotovelo** plote a WCSS contra  $K$ . Ela sempre cai com  $K$  (com  $K = n$ , WCSS = 0); procure o “cotovelo”, onde o ganho marginal despenca.

**Silhueta** mede, para cada ponto, quão melhor ele se encaixa no seu grupo do que no vizinho mais próximo. Escolha  $K$  que maximiza a silhueta média.

**Exemplo 3.2** (Compressão de imagens). Trate cada *pixel* como um ponto em  $\mathbb{R}^3$  (cores R, G, B) e rode *k-médias* com  $K$  pequeno. Substituindo cada pixel pela cor do seu centroide, a imagem passa a usar só  $K$  cores — uma **compressão** (quantização de cor).  $K$  controla a qualidade. (É o exemplo do [AME].)

**Em sala: juntar as duas coisas acima, que discordam por um fator de dez**

Pergunte: “qual  $K$  a silhueta escolheria para comprimir uma foto?” A §8 da Aula prática E1 mede na `flower.jpg`: a silhueta tem máximo em  $K = 2$  (+0,766) e cai daí em diante, enquanto o olho só deixa de distinguir o resultado do original entre 16 e 32 cores.

O ponto a extrair: a silhueta pergunta “*existem grupos bem separados?*”, e a nuvem de cores de uma foto é um contínuo —  $K = 2$  é a resposta *correta* para essa pergunta. Compressão é quantização vetorial, não análise de agrupamento: mesmo algoritmo, outro critério de sucesso. Antes de escolher  $K$  por uma métrica, saiba para que o  $K$  serve.

**4 Agrupamento hierárquico**

Ao contrário do *k-médias*, o agrupamento hierárquico (*aglomerativo*) **não exige fixar  $K$**  e produz uma hierarquia de grupos:

1. comece com cada ponto em seu próprio grupo;
2. repetidamente *funda* os dois grupos mais próximos;
3. pare quando restar um único grupo.

O resultado é um **dendrograma** (árvore), que se “corta” a uma altura para obter o número desejado de grupos. A noção de “distância entre grupos” é o *linkage*:

| Linkage                      | Distância entre grupos $A$ e $B$                                             |
|------------------------------|------------------------------------------------------------------------------|
| Completo ( <i>complete</i> ) | $\max_{i \in A, j \in B} d(\mathbf{x}_i, \mathbf{x}_j)$ — grupos compactos   |
| Simples ( <i>single</i> )    | $\min_{i \in A, j \in B} d(\mathbf{x}_i, \mathbf{x}_j)$ — tende a “encadear” |
| Médio ( <i>average</i> )     | média das distâncias entre pares                                             |
| Ward                         | minimiza o aumento da WCSS na fusão                                          |

**Ideia central**

$k$ -médias vs. hierárquico: o primeiro exige  $K$  e supõe grupos “esféricos” (euclidianos), mas é rápido e escala bem; o segundo dispensa  $K$ , dá uma visão multiescala (dendrograma) e aceita qualquer dissimilaridade, mas é mais caro ( $O(n^2)$  ou pior).

**Atenção**

Ambos são sensíveis à **escala** das covariáveis (usam distâncias) — *padronize* antes (Aula 06). E lembre: o  $k$ -médias *sempre* devolve  $K$  grupos, mesmo que não haja estrutura de grupos nenhuma nos dados. Interprete com ceticismo.

## 5 Prática em Python

```

1 from sklearn.cluster import KMeans, AgglomerativeClustering
2 from sklearn.preprocessing import StandardScaler
3 from sklearn.metrics import silhouette_score
4 import numpy as np
5
6 Xs = StandardScaler().fit_transform(X) # padronizar e essencial
7
8 # k-medias com k-medias++ e varios inicios; metodo do cotovelo
9 wcss = []
10 for k in range(2, 11):
11     km = KMeans(n_clusters=k, init="k-means++", n_init=10, random_state=0).fit(Xs)
12     wcss.append(km.inertia_) # inertia_ = WCSS
13     print(k, "silhueta:", silhouette_score(Xs, km.labels_))
14
15 # hierarquico (Ward), cortando em 3 grupos
16 rotulos = AgglomerativeClustering(n_clusters=3, linkage="ward").fit_predict(Xs)

```

O notebook Aula prática E1 e o material extra EXTRA K-medias (exemplo) exploram o  $k$ -médias, incluindo o exemplo de compressão de imagem.

## Resumo

- Aprendizado **não supervisionado**: sem rótulos; busca-se estrutura. Avaliação é subjetiva.
- *Agrupamento*: partição com grupos internos homogêneos; a **dissimilaridade** é a primeira decisão.
- $k$ -**médias**: minimiza a WCSS (1) via **Lloyd**; converge a um mínimo *local*  $\Rightarrow$  use  $k$ -**médias++** e vários inícios.
- Escolha de  $K$ : *cotovelo* (WCSS) e *silhueta*.
- **Hierárquico**: dendrograma, *linkages*; dispensa  $K$ .
- Sempre *padronize*;  $k$ -médias supõe grupos esféricos e sempre devolve  $K$  grupos.

**Leitura recomendada.** [AME] Capítulo 11 (§11.1  $k$ -médias, §11.2 espectral, §11.3 hierárquico); [ISLP] §12.4 (*Clustering Methods: k-médias e hierárquico*).