

Lista Teórica E1 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula E1 — Análise de Agrupamento: k -Médias

Exercício 1 — o algoritmo de Lloyd, na mão. Quatro pontos em $\mathbb{R}^2$:

$$A = (1, 1), \quad B = (1, 2), \quad C = (5, 4), \quad D = (5, 5),$$

e $K = 2$. Inicialize os centroides de propósito mal, em $\mu_1 = (1, 1)$ e $\mu_2 = (1, 2)$.

- Rode a **primeira** iteração: calcule as distâncias de cada ponto a cada centroide, atribua cada ponto ao mais próximo e atualize os centroides. Calcule a inércia resultante.
- Rode a **segunda** iteração e calcule a nova inércia.
- Mostre que uma terceira iteração não muda nada, isto é, que o algoritmo convergiu.
- A solução encontrada é o mínimo global? Justifique. E se os centroides tivessem sido inicializados em $\mu_1 = (1, 1)$ e $\mu_2 = (1, 2)$ — ou seja, os *mesmos* de agora?

Sugestões: $\sqrt{20} \approx 4,4721$, $\sqrt{32} \approx 5,6569$.

Solução

(a) Distâncias a $\mu_1 = (1, 1)$ e $\mu_2 = (1, 2)$:

ponto	$d(\cdot, \mu_1)$	$d(\cdot, \mu_2)$	grupo
$A = (1, 1)$	0	1	1
$B = (1, 2)$	1	0	2
$C = (5, 4)$	$\sqrt{16+9} = 5$	$\sqrt{16+4} = 4,4721$	2
$D = (5, 5)$	$\sqrt{16+16} = 5,6569$	$\sqrt{16+9} = 5$	2

Atualização: $\mu_1 = A = (1, 1)$ e

$$\mu_2 = \frac{1}{3}[(1, 2) + (5, 4) + (5, 5)] = \left(\frac{11}{3}, \frac{11}{3}\right) \approx (3,6667; 3,6667).$$

Inércia (soma dos quadrados de cada ponto ao centroide do seu grupo):

$$\underbrace{0}_A + \underbrace{7,1111 + 2,7778}_B + \underbrace{1,7778 + 0,1111}_C + \underbrace{1,7778 + 1,7778}_D = \mathbf{15,3333}.$$

(b) Novas distâncias, agora a $(1, 1)$ e $(3,6667; 3,6667)$:

ponto	$d(\cdot, \mu_1)$	$d(\cdot, \mu_2)$	grupo
A	0	3,7712	1
B	1	3,1447	1
C	5	1,3744	2
D	5,6569	1,8856	2

Agora B mudou de grupo. Atualizando: $\mu_1 = \frac{1}{2}[(1, 1) + (1, 2)] = (1; 1,5)$ e $\mu_2 = \frac{1}{2}[(5, 4) + (5, 5)] = (5; 4,5)$. Inércia:

$$4 \times 0,25 = \mathbf{1,0000},$$

já que cada ponto está a 0,5 do seu centroide.

(c) Com $\mu_1 = (1; 1,5)$ e $\mu_2 = (5; 4,5)$, as distâncias são 0,5 ao centroide do próprio grupo e mais de 4,7 ao outro, para os quatro pontos. Nenhuma atribuição muda; logo os centroides não mudam. O algoritmo convergiu em **2 iterações efetivas**.

(d) **Sim, é o mínimo global** — neste caso dá para verificar por força bruta: com $n = 4$ e $K = 2$ há apenas $2^{4-1} - 1 = 7$ partições não vazias distintas, e a que separa $\{A, B\}$ de $\{C, D\}$ tem inércia 1,0, menor que todas as outras (a segunda melhor, $\{A\}$ contra $\{B, C, D\}$, dá 15,33).

O item embutido na pergunta é uma pegadinha: a inicialização proposta é a que usamos, e ela era ruim — μ_1 e μ_2 começaram nos dois pontos mais próximos entre si, do mesmo lado da nuvem. Ainda assim o algoritmo se recuperou em duas iterações.

Isso **não** é garantido em geral. O algoritmo de Lloyd converge sempre (Exercício 2), mas para um mínimo *local*, e há inicializações a partir das quais ele fica preso numa solução ruim. É por isso que o KMeans do `scikit-learn` roda o algoritmo `n_init` vezes com sementes diferentes e devolve a melhor — e por isso o padrão de `init` é o `k-means++`, que sorteia centroides iniciais afastados entre si em vez de uniformemente.

Exercício 2 — por que o algoritmo sempre termina. A inércia de uma configuração (atribuição c e centroides μ) é

$$J(c, \mu) = \sum_{i=1}^n \left\| \mathbf{x}_i - \mu_{c(i)} \right\|^2.$$

Cada iteração de Lloyd faz duas coisas: (i) atualiza c mantendo μ fixo, e (ii) atualiza μ mantendo c fixo.

- Mostre que o passo (i) não aumenta J .
- Mostre que o passo (ii) não aumenta J . *Sugestão:* para cada grupo k separadamente, qual μ minimiza $\sum_{i: c(i)=k} \|\mathbf{x}_i - \mu\|^2$? Você já provou isso no Exercício 2(a) da Lista Teórica 01.
- Conclua que o algoritmo termina em um número **finito** de iterações. *Sugestão:* quantas atribuições c diferentes existem?
- O algoritmo termina no mínimo global? Se não, o que a garantia dos itens anteriores realmente dá?

Solução

(a) Com μ fixo, J é uma soma de n termos, e o termo i depende só de $c(i)$:

$$J(c, \mu) = \sum_{i=1}^n \left\| \mathbf{x}_i - \mu_{c(i)} \right\|^2.$$

Cada termo é minimizado, independentemente dos outros, escolhendo $c(i) = \arg \min_k \|\mathbf{x}_i - \mu_k\|^2$ — que é exatamente o que o passo de atribuição faz. Minimizar cada parcela separadamente minimiza a soma, então o novo c dá J menor ou igual.

(b) Com c fixo, J se separa por grupo:

$$J(c, \mu) = \sum_{k=1}^K \sum_{i: c(i)=k} \left\| \mathbf{x}_i - \mu_k \right\|^2,$$

e cada parcela depende de um μ_k diferente. Pelo Exercício 2(a) da Lista Teórica 01 — a conta de que $\mathbb{E}[(Y - c)^2]$ é minimizada em $c = \mathbb{E}[Y]$, aqui na versão amostral e coordenada a coordenada — o minimizador é a média do grupo:

$$\mu_k^* = \frac{1}{n_k} \sum_{i: c(i)=k} x_i.$$

É exatamente o passo de atualização. Logo J não aumenta.

(Vale notar o que isso revela: o “**médias**” do nome **não é uma escolha de projeto, é a consequência de usar distância euclidiana ao quadrado**. Com a distância ℓ_1 , o minimizador seria a *mediana* — é o k -medianas.)

(c) Pelos itens (a) e (b), J é não-crescente ao longo das iterações. E J é determinado pela atribuição c : dado c , os centroides ótimos são as médias, e portanto o valor de J ao final de cada iteração é uma função de c apenas.

Ora, existem no máximo K^n atribuições possíveis — um número grande, mas **finito**. Como J nunca aumenta e cada iteração que muda alguma coisa produz uma atribuição *estritamente* melhor (se não melhorasse, nada teria mudado e o algoritmo teria parado), nenhuma atribuição pode se repetir. Com um número finito de candidatas e nenhuma repetição, o algoritmo para.

(d) **Não**, o algoritmo não encontra o mínimo global. Encontrar a partição ótima de n pontos em K grupos é NP-difícil, e Lloyd é uma heurística gulosa.

O que a garantia dá é: *o algoritmo termina, e termina num ponto em que nenhum dos dois passos consegue melhorar*. Isso é um mínimo local no sentido forte de que nem realocar um ponto sozinho, nem mover um centroide, reduz J . Nada impede que exista uma partição bem melhor, alcançável apenas movendo *vários* pontos ao mesmo tempo.

A consequência prática é `n_init`: rodar de vários pontos de partida e ficar com o melhor resultado é a maneira barata de reduzir a chance de terminar num mínimo local ruim.

Exercício 3 — o cotovelo não é um critério. Considere de novo os quatro pontos do Exercício 1.

- Calcule a inércia da melhor solução para $K = 1$, $K = 2$, $K = 3$ e $K = 4$.
- Prove, em geral, que a inércia ótima é **não-crescente** em K , e que vale exatamente zero quando $K = n$. Por que isso impede que “minimize a inércia” seja um critério para escolher K ?
- A silhueta de um ponto i é $s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$, onde $a(i)$ é a distância média de i aos pontos do *seu* grupo e $b(i)$ a menor distância média de i aos pontos de *outro* grupo. Calcule $s(A)$ para a solução com $K = 2$ e interprete o valor.
- Por que a silhueta média *pode* servir como critério, e a inércia não?

Solução

(a)

- $K = 1$: o centroide é a média geral $(3, 3)$, e a inércia é $8 + 5 + 5 + 8 = \mathbf{26}$.
- $K = 2$: a solução do Exercício 1, **1,0**.
- $K = 3$: por exemplo $\{A\}, \{B\}, \{C, D\}$, com inércia $0 + 0 + 0,5 = \mathbf{0,5}$.

- $K = 4$: cada ponto é seu próprio grupo, inércia $\mathbf{0}$.

(b) Seja J_K^* a inércia ótima com K grupos. Dada qualquer solução ótima com K grupos, construa uma com $K + 1$ assim: tome um grupo com ao menos dois pontos, separe um ponto dele e faça-o um grupo sozinho. O ponto separado passa a contribuir com 0; os demais do grupo original passam a ter como centroide a média dos que sobraram, que (pelo Exercício 2(b)) minimiza a soma de quadrados deles — em particular, não é pior do que manter o centroide antigo. Logo a inércia dessa solução com $K + 1$ grupos é $\leq J_K^*$, e portanto $J_{K+1}^* \leq J_K^*$.

Com $K = n$, cada ponto é seu próprio centroide e $J_n^* = 0$.

Isso impede “minimize a inércia” de ser critério porque o mínimo é sempre atingido em $K = n$: um agrupamento com um grupo por observação, que não agrupa nada. É o mesmo defeito do erro de treino da Aula 01 — um critério que premia a complexidade sem penalizá-la escolhe sempre o modelo mais complexo.

O “cotovelo” tenta contornar isso procurando o ponto em que a curva deixa de cair rápido. É uma heurística visual, sem definição formal, e em dados reais a curva costuma ser suave demais para haver cotovelo algum.

(c) Para $A = (1, 1)$, com grupos $\{A, B\}$ e $\{C, D\}$:

- $a(A) = d(A, B) = 1$;
- $b(A) = \frac{1}{2}[d(A, C) + d(A, D)] = \frac{1}{2}[5 + 5,6569] = 5,3284$.

$$s(A) = \frac{5,3284 - 1}{5,3284} = \mathbf{0,8123}.$$

A silhueta varia em $[-1, 1]$: perto de 1 significa que o ponto está muito mais perto do seu grupo do que do vizinho mais próximo; perto de 0, que está na fronteira entre dois grupos; negativa, que ele estaria melhor em outro grupo. Um valor de 0,81 indica um ponto **confortavelmente** no grupo certo. (As silhuetas dos quatro pontos são 0,8123, 0,7889, 0,7889 e 0,8123, com média 0,8006.)

(d) Porque a silhueta **compara duas quantidades que se movem em direções opostas** quando K cresce: aumentar K diminui $a(i)$ (grupos menores e mais compactos) mas também diminui $b(i)$ (o grupo vizinho mais próximo fica mais perto). Não há um lado para o qual empurrar K que melhore os dois termos, e por isso a silhueta média tem um **máximo interior**.

Nestes dados, a silhueta média vale 0,8006 em $K = 2$ e cai para 0,3941 em $K = 3$ — ela escolhe $K = 2$ sozinha, sem precisar de inspeção visual. Em $K = 4$ ela nem está definida (com um ponto por grupo, $a(i)$ é média de um conjunto vazio).

A inércia não tem essa propriedade porque só olha o *primeiro* termo: mede compacidade dentro dos grupos e ignora completamente a separação entre eles.

Exercício 4 — dentro e entre. Seja $\bar{x}$ a média de todas as n observações e, para uma atribuição c em K grupos de tamanhos n_k e médias μ_k , defina

$$SQ_{\text{total}} = \sum_{i=1}^n \|x_i - \bar{x}\|^2, \quad SQ_{\text{dentro}} = \sum_{k=1}^K \sum_{i: c(i)=k} \|x_i - \mu_k\|^2, \quad SQ_{\text{entre}} = \sum_{k=1}^K n_k \|\mu_k - \bar{x}\|^2.$$

- Mostre que $SQ_{\text{total}} = SQ_{\text{dentro}} + SQ_{\text{entre}}$.
- Verifique numericamente nos quatro pontos do Exercício 1, com a solução de $K = 2$.
- Conclua que minimizar SQ_{dentro} (que é a inércia) equivale a **maximizar** SQ_{entre} . Que leitura isso dá ao k -médias?

- (d) Compare com a decomposição do risco da Aula 01. Que papel joga aqui a quantidade que lá era o erro irreduzível?

Solução

(a) Some e subtraia $\mu_{c(i)}$ dentro da norma:

$$\|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 = \|(\mathbf{x}_i - \mu_{c(i)}) + (\mu_{c(i)} - \bar{\mathbf{x}})\|^2 = \|\mathbf{x}_i - \mu_{c(i)}\|^2 + 2(\mathbf{x}_i - \mu_{c(i)})^\top (\mu_{c(i)} - \bar{\mathbf{x}}) + \|\mu_{c(i)} - \bar{\mathbf{x}}\|^2.$$

Somando sobre i e agrupando por grupo, o termo cruzado do grupo k é

$$2 \left(\underbrace{\sum_{i: c(i)=k} (\mathbf{x}_i - \mu_k)}_{=0} \right)^\top (\mu_k - \bar{\mathbf{x}}) = 0,$$

porque μ_k é justamente a média do grupo k e os desvios em torno da média somam zero.

Sobram $\sum_i \|\mathbf{x}_i - \mu_{c(i)}\|^2 = \text{SQ}_{\text{dentro}}$ e $\sum_k n_k \|\mu_k - \bar{\mathbf{x}}\|^2 = \text{SQ}_{\text{entre}}$.

Note onde a hipótese entrou: o termo cruzado só se anula porque os centroides são as *médias* dos grupos. Com centroides arbitrários a identidade é falsa.

(b) Média geral: $\bar{\mathbf{x}} = (3, 3)$. Então

$$\text{SQ}_{\text{total}} = 8 + 5 + 5 + 8 = 26.$$

Com $\mu_1 = (1; 1,5)$, $\mu_2 = (5; 4,5)$ e $n_1 = n_2 = 2$:

$$\text{SQ}_{\text{dentro}} = 4 \times 0,25 = 1, \quad \text{SQ}_{\text{entre}} = 2[(1-3)^2 + (1,5-3)^2] + 2[(5-3)^2 + (4,5-3)^2] = 2(6,25) + 2(6,25) = 25.$$

E $1 + 25 = 26$. ✓

(c) SQ_{total} **não depende da atribuição** — é uma propriedade dos dados. Logo $\text{SQ}_{\text{entre}} = \text{SQ}_{\text{total}} - \text{SQ}_{\text{dentro}}$, e minimizar a inércia é literalmente a mesma coisa que maximizar a dispersão *entre* os centroides.

A leitura: o k -médias pode ser descrito de dois jeitos equivalentes — “deixe os grupos o mais compactos possível” ou “deixe os centroides o mais espalhados possível”. A segunda formulação explica por que ele tende a produzir grupos de tamanho parecido e de forma aproximadamente esférica: essa é a configuração que mais afasta as médias, dada a dispersão total.

(d) O papel é análogo, mas em posição invertida. Na Aula 01,

$$R = \text{viés}^2 + \text{variância} + \sigma^2,$$

com σ^2 fixo, fora do controle do modelo, e os outros dois disputando o que sobra. Aqui,

$$\text{SQ}_{\text{total}} = \text{SQ}_{\text{dentro}} + \text{SQ}_{\text{entre}},$$

com SQ_{total} fixo e os outros dois disputando o que sobra.

A diferença é qual parcela é o alvo: lá, *duas* parcelas são controláveis e existe um balanço entre elas; aqui há um jogo de soma zero entre apenas duas, e o algoritmo simplesmente empurra tudo para um lado. É por isso que o k -médias não tem um “balanço” interno que sugira o K certo — e por isso K precisa vir de fora, pela silhueta ou pelo problema.