

## Lista Teórica E1 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula E1 — Análise de Agrupamento:  $k$ -Médias

**Exercício 1 — o algoritmo de Lloyd, na mão.** Quatro pontos em  $\mathbb{R}^2$ :

$$A = (1, 1), \quad B = (1, 2), \quad C = (5, 4), \quad D = (5, 5),$$

e  $K = 2$ . Inicialize os centroides de propósito mal, em  $\mu_1 = (1, 1)$  e  $\mu_2 = (1, 2)$ .

- Rode a **primeira** iteração: calcule as distâncias de cada ponto a cada centroide, atribua cada ponto ao mais próximo e atualize os centroides. Calcule a inércia resultante.
- Rode a **segunda** iteração e calcule a nova inércia.
- Mostre que uma terceira iteração não muda nada, isto é, que o algoritmo convergiu.
- A solução encontrada é o mínimo global? Justifique. E se os centroides tivessem sido inicializados em  $\mu_1 = (1, 1)$  e  $\mu_2 = (1, 2)$  — ou seja, os *mesmos* de agora?

Sugestões:  $\sqrt{20} \approx 4,4721$ ,  $\sqrt{32} \approx 5,6569$ .

### Solução

(a) Distâncias a  $\mu_1 = (1, 1)$  e  $\mu_2 = (1, 2)$ :

| ponto        | $d(\cdot, \mu_1)$       | $d(\cdot, \mu_2)$      | grupo |
|--------------|-------------------------|------------------------|-------|
| $A = (1, 1)$ | 0                       | 1                      | 1     |
| $B = (1, 2)$ | 1                       | 0                      | 2     |
| $C = (5, 4)$ | $\sqrt{16+9} = 5$       | $\sqrt{16+4} = 4,4721$ | 2     |
| $D = (5, 5)$ | $\sqrt{16+16} = 5,6569$ | $\sqrt{16+9} = 5$      | 2     |

Atualização:  $\mu_1 = A = (1, 1)$  e

$$\mu_2 = \frac{1}{3}[(1, 2) + (5, 4) + (5, 5)] = \left(\frac{11}{3}, \frac{11}{3}\right) \approx (3,6667; 3,6667).$$

Inércia (soma dos quadrados de cada ponto ao centroide do seu grupo):

$$\underbrace{0}_A + \underbrace{7,1111 + 2,7778}_B + \underbrace{1,7778 + 0,1111}_C + \underbrace{1,7778 + 1,7778}_D = \mathbf{15,3333}.$$

(b) Novas distâncias, agora a  $(1, 1)$  e  $(3,6667; 3,6667)$ :

| ponto | $d(\cdot, \mu_1)$ | $d(\cdot, \mu_2)$ | grupo |
|-------|-------------------|-------------------|-------|
| $A$   | 0                 | 3,7712            | 1     |
| $B$   | 1                 | 3,1447            | 1     |
| $C$   | 5                 | 1,3744            | 2     |
| $D$   | 5,6569            | 1,8856            | 2     |

Agora  $B$  mudou de grupo. Atualizando:  $\mu_1 = \frac{1}{2}[(1, 1) + (1, 2)] = (1; 1,5)$  e  $\mu_2 = \frac{1}{2}[(5, 4) + (5, 5)] = (5; 4,5)$ . Inércia:

$$4 \times 0,25 = \mathbf{1,0000},$$

já que cada ponto está a 0,5 do seu centroide.

(c) Com  $\mu_1 = (1; 1,5)$  e  $\mu_2 = (5; 4,5)$ , as distâncias são 0,5 ao centroide do próprio grupo e mais de 4,7 ao outro, para os quatro pontos. Nenhuma atribuição muda; logo os centroides não mudam. O algoritmo convergiu em **2 iterações efetivas**.

(d) **Sim, é o mínimo global** — neste caso dá para verificar por força bruta: com  $n = 4$  e  $K = 2$  há apenas  $2^{4-1} - 1 = 7$  partições não vazias distintas, e a que separa  $\{A, B\}$  de  $\{C, D\}$  tem inércia 1,0, menor que todas as outras (a segunda melhor,  $\{A\}$  contra  $\{B, C, D\}$ , dá 15,33).

O item embutido na pergunta é uma pegadinha: a inicialização proposta é a que usamos, e ela era ruim —  $\mu_1$  e  $\mu_2$  começaram nos dois pontos mais próximos entre si, do mesmo lado da nuvem. Ainda assim o algoritmo se recuperou em duas iterações.

Isso **não** é garantido em geral. O algoritmo de Lloyd converge sempre (Exercício 2), mas para um mínimo *local*, e há inicializações a partir das quais ele fica preso numa solução ruim. É por isso que o KMeans do `scikit-learn` roda o algoritmo `n_init` vezes com sementes diferentes e devolve a melhor — e por isso o padrão de `init` é o `k-means++`, que sorteia centroides iniciais afastados entre si em vez de uniformemente.

**Exercício 2 — por que o algoritmo sempre termina.** A inércia de uma configuração (atribuição  $c$  e centroides  $\mu$ ) é

$$J(c, \mu) = \sum_{i=1}^n \left\| \mathbf{x}_i - \mu_{c(i)} \right\|^2.$$

Cada iteração de Lloyd faz duas coisas: (i) atualiza  $c$  mantendo  $\mu$  fixo, e (ii) atualiza  $\mu$  mantendo  $c$  fixo.

- Mostre que o passo (i) não aumenta  $J$ .
- Mostre que o passo (ii) não aumenta  $J$ . *Sugestão:* para cada grupo  $k$  separadamente, qual  $\mu$  minimiza  $\sum_{i: c(i)=k} \left\| \mathbf{x}_i - \mu \right\|^2$ ? Você já provou isso no Exercício 2(a) da Lista Teórica 01.
- Conclua que o algoritmo termina em um número **finito** de iterações. *Sugestão:* quantas atribuições  $c$  diferentes existem?
- O algoritmo termina no mínimo global? Se não, o que a garantia dos itens anteriores realmente dá?

### Solução

(a) Com  $\mu$  fixo,  $J$  é uma soma de  $n$  termos, e o termo  $i$  depende só de  $c(i)$ :

$$J(c, \mu) = \sum_{i=1}^n \left\| \mathbf{x}_i - \mu_{c(i)} \right\|^2.$$

Cada termo é minimizado, independentemente dos outros, escolhendo  $c(i) = \arg \min_k \left\| \mathbf{x}_i - \mu_k \right\|^2$  — que é exatamente o que o passo de atribuição faz. Minimizar cada parcela separadamente minimiza a soma, então o novo  $c$  dá  $J$  menor ou igual.

(b) Com  $c$  fixo,  $J$  se separa por grupo:

$$J(c, \mu) = \sum_{k=1}^K \sum_{i: c(i)=k} \left\| \mathbf{x}_i - \mu_k \right\|^2,$$

e cada parcela depende de um  $\mu_k$  diferente. Pelo Exercício 2(a) da Lista Teórica 01 — a conta de que  $\mathbb{E}[(Y - c)^2]$  é minimizada em  $c = \mathbb{E}[Y]$ , aqui na versão amostral e coordenada a coordenada — o minimizador é a média do grupo:

$$\mu_k^* = \frac{1}{n_k} \sum_{i: c(i)=k} x_i.$$

É exatamente o passo de atualização. Logo  $J$  não aumenta.

(Vale notar o que isso revela: o “**médias**” do nome **não é uma escolha de projeto, é a consequência de usar distância euclidiana ao quadrado**. Com a distância  $\ell_1$ , o minimizador seria a *mediana* — é o  $k$ -medianas.)

(c) Pelos itens (a) e (b),  $J$  é não-crescente ao longo das iterações. E  $J$  é determinado pela atribuição  $c$ : dado  $c$ , os centroides ótimos são as médias, e portanto o valor de  $J$  ao final de cada iteração é uma função de  $c$  apenas.

Ora, existem no máximo  $K^n$  atribuições possíveis — um número grande, mas **finito**. Como  $J$  nunca aumenta e cada iteração que muda alguma coisa produz uma atribuição *estritamente* melhor (se não melhorasse, nada teria mudado e o algoritmo teria parado), nenhuma atribuição pode se repetir. Com um número finito de candidatas e nenhuma repetição, o algoritmo para.

(d) **Não**, o algoritmo não encontra o mínimo global. Encontrar a partição ótima de  $n$  pontos em  $K$  grupos é NP-difícil, e Lloyd é uma heurística gulosa.

O que a garantia dá é: *o algoritmo termina, e termina num ponto em que nenhum dos dois passos consegue melhorar*. Isso é um mínimo local no sentido forte de que nem realocar um ponto sozinho, nem mover um centroide, reduz  $J$ . Nada impede que exista uma partição bem melhor, alcançável apenas movendo *vários* pontos ao mesmo tempo.

A consequência prática é `n_init`: rodar de vários pontos de partida e ficar com o melhor resultado é a maneira barata de reduzir a chance de terminar num mínimo local ruim.

**Exercício 3 — o cotovelo não é um critério.** Considere de novo os quatro pontos do Exercício 1.

- Calcule a inércia da melhor solução para  $K = 1$ ,  $K = 2$ ,  $K = 3$  e  $K = 4$ .
- Prove, em geral, que a inércia ótima é **não-crescente** em  $K$ , e que vale exatamente zero quando  $K = n$ . Por que isso impede que “minimize a inércia” seja um critério para escolher  $K$ ?
- A silhueta de um ponto  $i$  é  $s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$ , onde  $a(i)$  é a distância média de  $i$  aos pontos do *seu* grupo e  $b(i)$  a menor distância média de  $i$  aos pontos de *outro* grupo. Calcule  $s(A)$  para a solução com  $K = 2$  e interprete o valor.
- Por que a silhueta média *pode* servir como critério, e a inércia não?

### Solução

(a)

- $K = 1$ : o centroide é a média geral  $(3, 3)$ , e a inércia é  $8 + 5 + 5 + 8 = \mathbf{26}$ .
- $K = 2$ : a solução do Exercício 1, **1,0**.
- $K = 3$ : por exemplo  $\{A\}, \{B\}, \{C, D\}$ , com inércia  $0 + 0 + 0,5 = \mathbf{0,5}$ .

- $K = 4$ : cada ponto é seu próprio grupo, inércia  $\mathbf{0}$ .

(b) Seja  $J_K^*$  a inércia ótima com  $K$  grupos. Dada qualquer solução ótima com  $K$  grupos, construa uma com  $K + 1$  assim: tome um grupo com ao menos dois pontos, separe um ponto dele e faça-o um grupo sozinho. O ponto separado passa a contribuir com 0; os demais do grupo original passam a ter como centroide a média dos que sobraram, que (pelo Exercício 2(b)) minimiza a soma de quadrados deles — em particular, não é pior do que manter o centroide antigo. Logo a inércia dessa solução com  $K + 1$  grupos é  $\leq J_K^*$ , e portanto  $J_{K+1}^* \leq J_K^*$ .

Com  $K = n$ , cada ponto é seu próprio centroide e  $J_n^* = 0$ .

Isso impede “minimize a inércia” de ser critério porque o mínimo é sempre atingido em  $K = n$ : um agrupamento com um grupo por observação, que não agrupa nada. É o mesmo defeito do erro de treino da Aula 01 — um critério que premia a complexidade sem penalizá-la escolhe sempre o modelo mais complexo.

O “cotovelo” tenta contornar isso procurando o ponto em que a curva deixa de cair rápido. É uma heurística visual, sem definição formal, e em dados reais a curva costuma ser suave demais para haver cotovelo algum.

(c) Para  $A = (1, 1)$ , com grupos  $\{A, B\}$  e  $\{C, D\}$ :

- $a(A) = p(A, B) = 1$ ;
- $b(A) = \frac{1}{2}[p(A, C) + p(A, D)] = \frac{1}{2}[5 + 5,6569] = 5,3284$ .

$$s(A) = \frac{5,3284 - 1}{5,3284} = \mathbf{0,8123}.$$

A silhueta varia em  $[-1, 1]$ : perto de 1 significa que o ponto está muito mais perto do seu grupo do que do vizinho mais próximo; perto de 0, que está na fronteira entre dois grupos; negativa, que ele estaria melhor em outro grupo. Um valor de 0,81 indica um ponto **confortavelmente** no grupo certo. (As silhuetas dos quatro pontos são 0,8123, 0,7889, 0,7889 e 0,8123, com média 0,8006.)

(d) Porque a silhueta **compara duas quantidades que se movem em direções opostas** quando  $K$  cresce: aumentar  $K$  diminui  $a(i)$  (grupos menores e mais compactos) mas também diminui  $b(i)$  (o grupo vizinho mais próximo fica mais perto). Não há um lado para o qual empurrar  $K$  que melhore os dois termos, e por isso a silhueta média tem um **máximo interior**.

Nestes dados, a silhueta média vale 0,8006 em  $K = 2$  e cai para 0,3941 em  $K = 3$  — ela escolhe  $K = 2$  sozinha, sem precisar de inspeção visual. Em  $K = 4$  ela nem está definida (com um ponto por grupo,  $a(i)$  é média de um conjunto vazio).

A inércia não tem essa propriedade porque só olha o *primeiro* termo: mede compacidade dentro dos grupos e ignora completamente a separação entre eles.

**Exercício 4 — dentro e entre.** Seja  $\bar{x}$  a média de todas as  $n$  observações e, para uma atribuição  $c$  em  $K$  grupos de tamanhos  $n_k$  e médias  $\mu_k$ , defina

$$SQ_{\text{total}} = \sum_{i=1}^n \|x_i - \bar{x}\|^2, \quad SQ_{\text{dentro}} = \sum_{k=1}^K \sum_{i: c(i)=k} \|x_i - \mu_k\|^2, \quad SQ_{\text{entre}} = \sum_{k=1}^K n_k \|\mu_k - \bar{x}\|^2.$$

- Mostre que  $SQ_{\text{total}} = SQ_{\text{dentro}} + SQ_{\text{entre}}$ .
- Verifique numericamente nos quatro pontos do Exercício 1, com a solução de  $K = 2$ .
- Conclua que minimizar  $SQ_{\text{dentro}}$  (que é a inércia) equivale a **maximizar**  $SQ_{\text{entre}}$ . Que leitura isso dá ao  $k$ -médias?

- (d) Compare com a decomposição do risco da Aula 01. Que papel joga aqui a quantidade que lá era o erro irreduzível?

### Solução

(a) Some e subtraia  $\mu_{c(i)}$  dentro da norma:

$$\|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 = \|(\mathbf{x}_i - \mu_{c(i)}) + (\mu_{c(i)} - \bar{\mathbf{x}})\|^2 = \|\mathbf{x}_i - \mu_{c(i)}\|^2 + 2(\mathbf{x}_i - \mu_{c(i)})^\top (\mu_{c(i)} - \bar{\mathbf{x}}) + \|\mu_{c(i)} - \bar{\mathbf{x}}\|^2.$$

Somando sobre  $i$  e agrupando por grupo, o termo cruzado do grupo  $k$  é

$$2 \left( \underbrace{\sum_{i: c(i)=k} (\mathbf{x}_i - \mu_k)}_{=0} \right)^\top (\mu_k - \bar{\mathbf{x}}) = 0,$$

porque  $\mu_k$  é justamente a média do grupo  $k$  e os desvios em torno da média somam zero.

Sobram  $\sum_i \|\mathbf{x}_i - \mu_{c(i)}\|^2 = \text{SQ}_{\text{dentro}}$  e  $\sum_k n_k \|\mu_k - \bar{\mathbf{x}}\|^2 = \text{SQ}_{\text{entre}}$ .

Note onde a hipótese entrou: o termo cruzado só se anula porque os centroides são as *médias* dos grupos. Com centroides arbitrários a identidade é falsa.

(b) Média geral:  $\bar{\mathbf{x}} = (3, 3)$ . Então

$$\text{SQ}_{\text{total}} = 8 + 5 + 5 + 8 = 26.$$

Com  $\mu_1 = (1; 1,5)$ ,  $\mu_2 = (5; 4,5)$  e  $n_1 = n_2 = 2$ :

$$\text{SQ}_{\text{dentro}} = 4 \times 0,25 = 1, \quad \text{SQ}_{\text{entre}} = 2[(1-3)^2 + (1,5-3)^2] + 2[(5-3)^2 + (4,5-3)^2] = 2(6,25) + 2(6,25) = 25.$$

E  $1 + 25 = 26$ . ✓

(c)  $\text{SQ}_{\text{total}}$  **não depende da atribuição** — é uma propriedade dos dados. Logo  $\text{SQ}_{\text{entre}} = \text{SQ}_{\text{total}} - \text{SQ}_{\text{dentro}}$ , e minimizar a inércia é literalmente a mesma coisa que maximizar a dispersão *entre* os centroides.

A leitura: o  $k$ -médias pode ser descrito de dois jeitos equivalentes — “deixe os grupos o mais compactos possível” ou “deixe os centroides o mais espalhados possível”. A segunda formulação explica por que ele tende a produzir grupos de tamanho parecido e de forma aproximadamente esférica: essa é a configuração que mais afasta as médias, dada a dispersão total.

(d) O papel é análogo, mas em posição invertida. Na Aula 01,

$$R = \text{viés}^2 + \text{variância} + \sigma^2,$$

com  $\sigma^2$  fixo, fora do controle do modelo, e os outros dois disputando o que sobra. Aqui,

$$\text{SQ}_{\text{total}} = \text{SQ}_{\text{dentro}} + \text{SQ}_{\text{entre}},$$

com  $\text{SQ}_{\text{total}}$  fixo e os outros dois disputando o que sobra.

A diferença é qual parcela é o alvo: lá, *duas* parcelas são controláveis e existe um balanço entre elas; aqui há um jogo de soma zero entre apenas duas, e o algoritmo simplesmente empurra tudo para um lado. É por isso que o  $k$ -médias não tem um “balanço” interno que sugira o  $K$  certo — e por isso  $K$  precisa vir de fora, pela silhueta ou pelo problema.