

Aula Extra E2 — Redução de Dimensionalidade (PCA e t-SNE)

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME cap. 10; ISLP §12.2

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- listar as razões para reduzir a dimensionalidade;
- definir os **componentes principais** como direções de variância máxima e resolvê-los via autovetores;
- usar a *proporção de variância explicada* para escolher quantos componentes manter;
- interpretar o PCA geometricamente e usá-lo para **compressão**;
- reconhecer as extensões não lineares — **Kernel PCA** e **t-SNE** — e os cuidados com este último.

Esta aula ataca de frente a maldição da dimensionalidade da Aula 05, mas pelo lado da *redundância*: se as covariáveis são correlacionadas, os dados ocupam apenas uma fatia fina do espaço $\mathbb{R}^p$, e talvez baste descrevê-la. A pergunta:

como resumir p covariáveis em bem menos, sem perder o essencial?

1 Por que reduzir a dimensionalidade?

- **Visualização**: projetar dados em 2D/3D para enxergar estrutura.
- **Compressão**: armazenar/transmitir com menos espaço (imagens).
- **Pré-processamento**: combater a *maldição da dimensionalidade* (Aula 05) e o ruído antes de um método supervisionado.
- **Redundância**: muitas covariáveis correlacionadas vivem perto de uma subvariedade de dimensão menor — queremos recuperá-la.

Ideia central

O último item é o mais importante conceitualmente, e liga esta aula ao Bloco I. Na Aula 05 vimos que o KNN *se adapta sozinho* à dimensão intrínseca u , mas que métodos que somam todas as coordenadas sofrem com p grande. O PCA faz esse trabalho *explicitamente*: ele encontra a subvariedade — desde que ela seja aproximadamente um subespaço linear.

2 Componentes principais (PCA)

Suponha as covariáveis *centradas* (média zero). O **primeiro componente principal** é a combinação linear

$$Z_1 = \phi_{11}X_1 + \cdots + \phi_{p1}X_p = \phi_1^\top \mathbf{X}$$

de **variância máxima**, sob a restrição $\|\phi_1\|^2 = \sum_k \phi_{k1}^2 = 1$ (sem ela, bastaria inflar os coeficientes). O i -ésimo componente Z_i tem variância máxima entre as combinações lineares unitárias *não correlacionadas* com $Z_1, \dots, Z_{i-1}$.

Ideia central

Procuramos novos eixos (ortogonais) ao longo dos quais os dados *mais variam*. O 1º eixo capta o máximo de variabilidade; o 2º, o máximo do que resta sendo ortogonal ao 1º; e assim por diante. Concentrar a variância em poucos eixos é o que permite descartar os demais com pouca perda.




Figura 1: PCA em duas dimensões. À esquerda, a nuvem original e as duas direções principais, com comprimento proporcional ao desvio-padrão ao longo delas: a primeira acompanha o alongamento da nuvem e responde por 94,4% da variância. À direita, os mesmos pontos escritos nas novas coordenadas — é literalmente uma *rotação*. É aí que a redução fica óbvia: descartar a segunda coordenada custa 5,6% da variância e transforma dois números em um.

2.1 Solução: autovetores da covariância

Seja $\mathbf{C} = \mathbf{X}^\top \mathbf{X}$ (proporcional à matriz de covariância, pois os dados têm média zero). O problema é

$$\max_{\phi} \text{Var}(\phi^\top \mathbf{X}) = \max_{\phi} \phi^\top \mathbf{C} \phi \quad \text{s.a.} \quad \|\phi\|^2 = 1.$$

Proposição 2.1 (O 1º componente é o autovetor principal). *O maximizador de $\phi^\top \mathbf{C} \phi$ sob $\|\phi\| = 1$ é o autovetor de $\mathbf{C}$ associado ao maior autovalor, e o valor máximo da variância é esse autovalor.*

Demonstração. Lagrangiano: $\mathcal{L}(\phi, \nu) = \phi^\top \mathbf{C} \phi - \nu(\phi^\top \phi - 1)$. Anulando o gradiente em ϕ : $2\mathbf{C}\phi - 2\nu\phi = 0$, isto é, $\mathbf{C}\phi = \nu\phi$ — ϕ é autovetor de $\mathbf{C}$ com autovalor ν . Para um autovetor unitário, a variância é $\phi^\top \mathbf{C} \phi = \nu$. Logo o máximo é atingido no autovetor de *maior* autovalor. Os componentes seguintes saem do mesmo argumento restrito ao complemento ortogonal, gerando os demais autovetores em ordem decrescente de autovalor. $\square$

Ideia central

Vale apreciar quanto essa proposição entrega. O problema original — “ache a melhor direção, depois a melhor entre as ortogonais a ela, e assim por diante” — parece uma sequência de p otimizações encadeadas. A proposição diz que **uma única** decomposição espectral de $\mathbf{C}$ resolve todas de uma vez, e ainda ordena o resultado. É por isso que o PCA é barato mesmo com p grande.

Empilhando os autovetores (ordenados por autovalor decrescente) nas colunas de $\mathbf{U}$ (a **matriz de cargas**), os *scores* são

$$\mathbf{Z} = \mathbf{X}\mathbf{U} \quad (n \times p),$$

e a i -ésima nova coordenada da observação $\mathbf{x}$ é $z_i = \mathbf{u}_i^\top \mathbf{x}$. Como os autovetores são ortogonais, os componentes são *não correlacionados* — sem informação redundante.

2.2 Quantos componentes? Variância explicada

Cada autovalor λ_i é a variância capturada pelo i -ésimo componente. A **proporção de variância explicada** pelos p primeiros é

$$\text{PVE}(p) = \frac{\sum_{i=1}^p \lambda_i}{\sum_{i=1}^p \lambda_i}. \quad (1)$$

Escolhe-se p olhando o *scree plot* (λ_i vs. i , procurando o “cotovelo”) ou exigindo PVE acima de um limiar (ex.: 90%).




Figura 2: PCA nas 81 covariáveis padronizadas do `superconductivity.csv`, a mesma base das aulas práticas. O primeiro componente sozinho explica 38,9% da variância, e **12 componentes** chegam a 90%. Em outras palavras: as 81 colunas carregam cerca de uma dúzia de dimensões de informação, e as demais 69 são, em boa medida, repetição. É a *redundância* da Aula 05, medida.

3 Interpretação geométrica e compressão

3.1 PCA como escalonamento multidimensional

O PCA também resolve: encontrar a projeção linear $\mathbf{Z}$ em $m < p$ dimensões que melhor *preserva as distâncias* entre pares,

$$\min_{\mathbf{Z}} \sum_{i,j} (\|\mathbf{x}_i - \mathbf{x}_j\|^2 - \|\mathbf{z}_i - \mathbf{z}_j\|^2).$$

A solução são os m primeiros componentes principais. Ou seja, PCA é a melhor aproximação linear de baixa dimensão no sentido de distâncias — daí ser tão útil para visualização. Note que são *dois* problemas aparentemente diferentes (maximizar variância, preservar distâncias) com a *mesma* solução; guarde isso, porque o t-SNE vai atacar o segundo problema por outro caminho.

3.2 Compressão (SVD truncada)

Da decomposição $\mathbf{X}^\top \mathbf{X} = \mathbf{U} \mathbf{\Sigma} \mathbf{U}^\top$, reconstrói-se $\mathbf{X} \approx \mathbf{Z}_p \mathbf{U}_p^\top$, usando só as p primeiras colunas. Se os autovalores decaem rápido, a reconstrução é quase perfeita guardando apenas $(z_{i,1}, \dots, z_{i,p})$ e as p cargas $\mathbf{u}_1, \dots, \mathbf{u}_p$ — uma **compressão**.




Figura 3: Uma imagem em tons de cinza 600×512 (307 mil números) reconstruída a partir de k componentes. Com $k = 5$ guardamos 2% dos números e já temos 89% da variância — e a imagem, embora borrada, tem a silhueta certa. Com $k = 20$ (7% dos números) o rosto é reconhecível; com $k = 60$ (22%), a diferença para o original quase não se vê. A queda rápida dos autovalores é a razão de tudo isso funcionar.

Atenção

PCA usa variância e produtos internos $\Rightarrow$ é **sensível à escala**. *Padronize* as covariáveis antes (Aula 07), senão variáveis de maior magnitude dominam os componentes artificialmente — trocar metros por milímetros numa coluna muda o resultado. E PCA é *não supervisionado*: a direção de maior variância *não* é necessariamente a mais útil para prever um Y . É perfeitamente possível que o sinal preditivo esteja justamente no componente de menor variância, que você acabou de descartar.

4 Além do linear: Kernel PCA e t-SNE

4.1 Kernel PCA

PCA só captura estrutura *linear*. Como o PCA pode ser escrito em termos de produtos internos, aplica-se o **truque do kernel** (Aulas 04 e 10): substituem-se os produtos internos por um kernel K , fazendo PCA num espaço de *features* de alta dimensão. Resultado: componentes **não lineares**, que capturam subvariedades curvas. É literalmente o mesmo truque da Aula 10, aplicado a outro problema — e essa recorrência não é coincidência: qualquer método que só dependa de produtos internos admite a mesma generalização.

4.2 t-SNE

O **t-SNE** (*t-distributed Stochastic Neighbor Embedding*) é uma técnica *não linear* feita para **visualização** (2D/3D). A ideia:

- converte distâncias em **probabilidades de vizinhança** no espaço original (kernel gaussiano) e no espaço reduzido (distribuição t de Student, de caudas pesadas);
- ajusta as posições no espaço reduzido minimizando a divergência de **Kullback–Leibler** entre as duas distribuições;
- assim, *preserva a estrutura local* (vizinhos próximos continuam próximos), revelando agrupamentos.

O principal hiperparâmetro é a **perplexidade** (ordem de grandeza do número de vizinhos considerados).

Ideia central: por que a distribuição t

O detalhe do nome tem uma razão precisa. Ao espremer dados de $\mathbb{R}^p$ em $\mathbb{R}^2$, não há espaço para manter todo mundo afastado — pontos moderadamente distantes seriam esmagados uns sobre os outros. A distribuição t , com caudas pesadas, atribui probabilidade razoável a distâncias grandes no espaço reduzido, o que permite ao algoritmo *espalhar* os grupos em vez de amontoá-los. É uma solução para um problema de espaço, não de estatística.

Atenção: Cuidados com o t-SNE

- é só para **visualização** — não use os eixos como *features* para um modelo supervisionado (e note que, ao contrário do PCA, ele nem tem um **transform** para aplicar a dados novos);
- **distâncias e tamanhos** entre grupos no gráfico *não* têm significado — só a vizinhança local é confiável. Dois grupos afastados na figura não são necessariamente mais diferentes que dois próximos;
- é **estocástico** e sensível à perplexidade: rode mais de uma vez e compare. Se os agrupamentos mudam de uma rodada para outra, eles não estão nos dados. Para grandes bases, UMAP é uma alternativa mais rápida.

Em resumo: PCA para *compressão e pré-processamento* (linear, interpretável, com **transform** aplicável a dados novos); t-SNE para *olhar* os dados, e só.

5 Prática em Python

```

1 from sklearn.decomposition import PCA
2 from sklearn.manifold import TSNE
3 from sklearn.preprocessing import StandardScaler
4 from sklearn.pipeline import make_pipeline
5
6 # PCA como etapa de um pipeline (Aula 07): ajustado SO no treino
7 pipe = make_pipeline(StandardScaler(), PCA(n_components=0.90), Ridge())
8
9 # quanta variância cada componente explica
10 pca = PCA().fit(StandardScaler().fit_transform(X))
11 print(pca.explained_variance_ratio_.cumsum())
12
13 # t-SNE: apenas para visualizar. O init explícito importa -- com "pca" o
14 # resultado é reprodutível; com "random", cada semente da outra figura
15 Z = TSNE(n_components=2, perplexity=30, init="pca",
16         random_state=0).fit_transform(X)

```

O truque do `n_components=0.90` é útil: em vez de um número de componentes, passa-se a *proporção de variância* desejada, e o `scikit-learn` escolhe p sozinho.

Atenção: qual é, afinal, a gravidade desse vazamento

O PCA aprende direções a partir dos dados, então pela regra da Aula 07 ele é etapa do modelo e tem de entrar no *pipeline*. Mas vale ser preciso sobre a *gravidade*, porque a intuição engana aqui.

O que torna grave o vazamento por seleção de variáveis (Aula 07) é que a seleção **olha o Y** : ela escolhe as colunas que, por acaso, se parecem com a resposta naquela amostra, e é assim que fabrica $R^2 = 0,40$ a partir de ruído puro. O PCA **não olha o Y** . Sem a resposta, não há como escolher direções que finjam explicar ruído.

E a medição confirma: o notebook desta aula repete o experimento cruel da Aula 07 — y de ruído puro — em quatro configurações de (n, p, k) , e em *nenhuma* delas calcular o PCA fora da dobra inflou o R^2 . Ele o *piorou*, porque componentes calculados sobre o conjunto todo não são os componentes ótimos de nenhuma dobra de treino. Na hierarquia da Aula 07, portanto, o PCA fica na categoria **leve**, ao lado da padronização — e a conduta continua a mesma, porque corrigir custa uma linha.

Os notebooks Aula **prática E2** e **Exemplo - PCA** ilustram os componentes principais e a variância explicada em dados reais.

Resumo

- Reduzir dimensão serve para visualizar, comprimir, pré-processar e explorar *redundância* (Aula 05).
- **PCA**: direções ortogonais de variância máxima; são os autovetores de $\mathbf{X}^\top \mathbf{X}$ em ordem de autovalor (Prop. 2.1), obtidos de uma única decomposição (Fig. 1).
- *Proporção de variância explicada* (1) guia a escolha de p : no **superconductivity**, 12 dos 81 componentes dão 90% (Fig. 2).
- PCA = melhor projeção linear no sentido de distâncias; a truncagem da SVD é compressão (Fig. 3).
- *Padronize* antes; e lembre que PCA é não supervisionado — a direção de maior variância pode não ser a mais preditiva.
- **Kernel PCA** e **t-SNE** estendem para o não linear; o t-SNE é *só* para visualização, e distâncias entre grupos nele não significam nada.

Leitura recomendada. [AME] Capítulo 10: §10.1 (PCA e a interpretação como escalonamento multidimensional), §10.1.2 (compressão de imagens, que é a nossa Figura 3), §10.2 (Kernel PCA) e §10.4 (*autoencoders*, a generalização não linear via redes neurais). [ISLP] §12.2 — §12.2.1–12.2.2 (o que são os componentes e a interpretação alternativa), §12.2.3 (proporção de variância explicada, a nossa Figura 2) e §12.2.4, que discute honestamente quantos componentes usar e por que não há resposta objetiva.

Para praticar. **Lista teorica E2.pdf** (teórica, com gabarito) e **Lista prática E2.ipynb** (prática, para completar as lacunas), nesta mesma pasta.