

Aula Extra E2 — Redução de Dimensionalidade: PCA e t-SNE

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME cap. 10; ISLP §12.2

Objetivos da aula

Ao final desta aula o aluno deve ser capaz de:

- motivar a **redução de dimensionalidade** (visualização, compressão, ruído, maldição da dimensionalidade);
- definir os **componentes principais** (PCA) como combinações lineares de variância máxima;
- resolver o PCA via **autovetores** da matriz de covariância e interpretar cargas e *scores*;
- escolher o número de componentes pela **proporção de variância explicada**;
- reconhecer o PCA como *escalonamento multidimensional* e usá-lo para compressão;
- descrever **Kernel PCA** e **t-SNE**, e os cuidados ao usar t-SNE.

Em sala

Segunda face do não supervisionado (após o agrupamento, Aula E1). Conexão direta com a Aula 05: a *redundância* das covariáveis (dimensão intrínseca baixa) é exatamente o que a redução de dimensionalidade explora. Pergunta de abertura: “*como resumir centenas de variáveis correlacionadas em duas ou três, sem perder o essencial?*”

1 Por que reduzir a dimensionalidade?

- **Visualização**: projetar dados em 2D/3D para enxergar estrutura.
- **Compressão**: armazenar/transmitir com menos espaço (imagens).
- **Pré-processamento**: combater a *maldição da dimensionalidade* (Aula 05) e o ruído antes de um método supervisionado.
- **Redundância**: muitas covariáveis correlacionadas vivem perto de uma subvariedade de dimensão menor — queremos recuperá-la.

2 Componentes principais (PCA)

Suponha as covariáveis *centradas* (média zero). O **primeiro componente principal** é a combinação linear

$$Z_1 = \phi_{11}X_1 + \dots + \phi_{p1}X_p = \phi_1^\top \mathbf{X}$$

de **variância máxima**, sob a restrição $\|\phi_1\|^2 = \sum_k \phi_{k1}^2 = 1$ (sem ela, bastaria inflar os coeficientes). O *i*-ésimo componente Z_i tem variância máxima entre as combinações lineares unitárias *não correlacionadas* com $Z_1, \dots, Z_{i-1}$.

Ideia central

Procuramos novos eixos (ortogonais) ao longo dos quais os dados *mais variam*. O 1º eixo capta o máximo de variabilidade; o 2º, o máximo do que resta sendo ortogonal ao 1º; e assim por diante. Concentrar a variância em poucos eixos é o que permite descartar os demais com pouca perda.

2.1 Solução: autovetores da covariância

Seja $\mathbf{C} = \mathbf{X}^\top \mathbf{X}$ (proporcional à matriz de covariância, pois os dados têm média zero). O problema é

$$\max_{\phi} \text{Var}(\phi^\top \mathbf{X}) = \max_{\phi} \phi^\top \mathbf{C} \phi \quad \text{s.a.} \quad \|\phi\|^2 = 1.$$

Proposição 2.1 (O 1º componente é o autovetor principal). *O maximizador de $\phi^\top \mathbf{C} \phi$ sob $\|\phi\| = 1$ é o autovetor de $\mathbf{C}$ associado ao maior autovalor, e o valor máximo da variância é esse autovalor.*

Demonstração. Lagrangiano: $\mathcal{L}(\phi, \nu) = \phi^\top \mathbf{C} \phi - \nu(\phi^\top \phi - 1)$. Anulando o gradiente em ϕ : $2\mathbf{C}\phi - 2\nu\phi = 0$, isto é, $\mathbf{C}\phi = \nu\phi$ — ϕ é autovetor de $\mathbf{C}$ com autovalor ν . Para um autovetor unitário, a variância é $\phi^\top \mathbf{C} \phi = \nu$. Logo o máximo é atingido no autovetor de maior autovalor. Os componentes seguintes saem do mesmo argumento restrito ao complemento ortogonal, gerando os demais autovetores em ordem decrescente de autovalor. $\square$

Empilhando os autovetores (ordenados por autovalor decrescente) nas colunas de $\mathbf{U}$ (a **matriz de cargas**), os *scores* são

$$\mathbf{Z} = \mathbf{X}\mathbf{U} \quad (n \times p),$$

e a i -ésima nova coordenada da observação $\mathbf{x}$ é $z_i = \mathbf{u}_i^\top \mathbf{x}$. Como os autovetores são ortogonais, os componentes são *não correlacionados* — sem informação redundante.

2.2 Quantos componentes? Variância explicada

Cada autovalor λ_i é a variância capturada pelo i -ésimo componente. A **proporção de variância explicada** pelos p primeiros é

$$\text{PVE}(p) = \frac{\sum_{i=1}^p \lambda_i}{\sum_{i=1}^p \lambda_i}. \quad (1)$$

Escolhe-se p olhando o *scree plot* (λ_i vs. i , procurando o “cotovelo”) ou exigindo PVE acima de um limiar (ex.: 90%).

3 Interpretação geométrica e compressão**3.1 PCA como escalonamento multidimensional**

O PCA também resolve: encontrar a projeção linear $\mathbf{Z}$ em $m < p$ dimensões que melhor *preserva as distâncias* entre pares,

$$\min_{\mathbf{Z}} \sum_{i,j} (\|\mathbf{x}_i - \mathbf{x}_j\|^2 - \|\mathbf{z}_i - \mathbf{z}_j\|^2).$$

A solução são os m primeiros componentes principais. Ou seja, PCA é a melhor aproximação linear de baixa dimensão no sentido de distâncias — daí ser tão útil para visualização.

3.2 Compressão (SVD truncada)

Da decomposição $\mathbf{X}^\top \mathbf{X} = \mathbf{U} \mathbf{\Sigma} \mathbf{U}^\top$, reconstrói-se $\mathbf{X} \approx \mathbf{Z}_p \mathbf{U}_p^\top$, usando só as p primeiras colunas. Se os autovalores decaem rápido, a reconstrução é quase perfeita guardando apenas $(z_{i,1}, \dots, z_{i,p})$ e as p cargas $\mathbf{u}_1, \dots, \mathbf{u}_p$ — uma **compressão**. Aplicação clássica: comprimir imagens tratando cada canal de cor (R, G, B) como uma matriz.

Atenção

PCA usa variância e produtos internos $\Rightarrow$ é **sensível à escala**. *Padronize* as covariáveis antes (Aula 07), senão variáveis de maior magnitude dominam os componentes artificialmente. E PCA é *não supervisionado*: a direção de maior variância *não* é necessariamente a mais útil para prever um Y .

4 Além do linear: Kernel PCA e t-SNE

4.1 Kernel PCA

PCA só captura estrutura *linear*. Como o PCA pode ser escrito em termos de produtos internos, aplica-se o **truque do kernel** (Aulas 04 e 10): substituem-se os produtos internos por um kernel K , fazendo PCA num espaço de *features* de alta dimensão. Resultado: componentes **não lineares**, que capturam subvariedades curvas.

4.2 t-SNE

O **t-SNE** (*t-distributed Stochastic Neighbor Embedding*) é uma técnica *não linear* feita para **visualização** (2D/3D). A ideia:

- converte distâncias em **probabilidades de vizinhança** no espaço original (kernel gaussiano) e no espaço reduzido (distribuição t de Student, de caudas pesadas);
- ajusta as posições no espaço reduzido minimizando a divergência de **Kullback–Leibler** entre as duas distribuições;
- assim, *preserva a estrutura local* (vizinhos próximos continuam próximos), revelando agrupamentos.

O principal hiperparâmetro é a **perplexidade** (ordem de grandeza do número de vizinhos considerados).

Atenção: Cuidados com o t-SNE

- é **só para visualização** — não use os eixos como *features* para um modelo supervisionado;
- **distâncias e tamanhos** entre grupos no gráfico *não* têm significado — só a vizinhança local é confiável;
- é **estocástico** e sensível à perplexidade: rode mais de uma vez e compare. Para grandes bases, UMAP é uma alternativa mais rápida.

Em resumo: PCA para *compressão/pré-processamento* (linear, interpretável, determinístico); t-SNE para *enxergar* agrupamentos.

5 Prática em Python

```
1 from sklearn.decomposition import PCA, KernelPCA
2 from sklearn.manifold import TSNE
3 from sklearn.preprocessing import StandardScaler
```

```
4 Xs = StandardScaler().fit_transform(X) # padronizar e essencial
5
6
7 pca = PCA().fit(Xs)
8 print("variancia explicada acumulada:", pca.explained_variance_ratio_.cumsum())
9 Z = PCA(n_components=2).fit_transform(Xs) # scores nos 2 primeiros PCs
10
11 # Kernel PCA (nao linear) e t-SNE (visualizacao)
12 Zk = KernelPCA(n_components=2, kernel="rbf", gamma=0.1).fit_transform(Xs)
13 Zt = TSNE(n_components=2, perplexity=30, init="pca", # init explicito:
14           random_state=0).fit_transform(Xs) # o padrao ja mudou uma vez
```

Os notebooks Aula prática E2 e Exemplo - PCA ilustram os componentes principais e comparam com o t-SNE na mesma base.

Resumo

- Reduzir dimensão: visualizar, comprimir, remover ruído, explorar *redundância* (Aula 05).
- **PCA**: componentes = combinações lineares de variância máxima = autovetores da covariância (Prop. 2.1); *scores* $\mathbf{Z} = \mathbf{XU}$, não correlacionados.
- Número de componentes pela **PVE** (1) / *scree plot*.
- PCA = melhor projeção linear que preserva distâncias (MDS); base da **compressão** por SVD truncada. *Padronize*.
- **Kernel PCA**: PCA não linear via *kernel*. **t-SNE**: visualização que preserva vizinhança local — com cuidados (estocástico, só visual, distâncias entre grupos sem sentido).

Leitura recomendada. [AME] Capítulo 10 (§10.1 PCA e MDS, §10.1.2 compressão de imagens, §10.2 Kernel PCA); [ISLP] §12.2 (*Principal Components Analysis*).