

Lista Teórica E2

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula E2 — Redução de Dimensionalidade (PCA e t-SNE)

Exercício 1 — PCA na mão. Quatro pontos em $\mathbb{R}^2$:

$$(3, 1), \quad (1, 3), \quad (-3, -1), \quad (-1, -3).$$

- (a) Verifique que a média é a origem e calcule a matriz de covariância amostral $\mathbf{S} = \frac{1}{n} \mathbf{X}^\top \mathbf{X}$.
- (b) Encontre os autovalores e autovetores de $\mathbf{S}$. Escreva as duas componentes principais como vetores unitários.
- (c) Qual a proporção da variância explicada pela primeira componente?
- (d) Calcule as coordenadas dos quatro pontos no novo sistema (isto é, projete cada um sobre as duas componentes). Que estrutura geométrica isso revela?

Exercício 2 — quantas componentes guardar. Uma matriz de dados com $p = 8$ covariáveis tem autovalores da matriz de covariância

$$\lambda = (12,5; 6,2; 3,1; 1,4; 0,9; 0,5; 0,3; 0,1).$$

- (a) Calcule a proporção de variância explicada por cada componente e a proporção acumulada.
- (b) Quantas componentes são necessárias para reter ao menos 90% da variância? E 99%?
- (c) O que significa `PCA(n_components=0.90)` no `scikit-learn`, e por que é uma forma mais conveniente de especificar a redução do que dar o número de componentes?
- (d) A soma dos autovalores vale 25. A que quantidade dos dados originais esse número corresponde? O que isso diz sobre a necessidade de **padronizar** antes da PCA?

Exercício 3 — o que o t-SNE preserva, e o que não preserva. O t-SNE constrói, no espaço original, probabilidades p_{ij} de que i escolha j como vizinho, e procura pontos $\mathbf{z}_i$ em $\mathbb{R}^2$ cujas probabilidades q_{ij} minimizem $\text{KL}(p \parallel q)$.

- (a) A divergência de Kullback–Leibler $\sum_{ij} p_{ij} \log(p_{ij}/q_{ij})$ não é simétrica. Que tipo de erro ela pune muito, e que tipo ela quase não pune? *Sugestão:* olhe o que acontece com o somando quando p_{ij} é grande e q_{ij} pequeno, e vice-versa.
- (b) Conclua o que se pode e o que não se pode ler num diagrama de t-SNE sobre: (i) pontos que aparecem próximos; (ii) a distância entre dois grupos distantes; (iii) o tamanho relativo de dois grupos.
- (c) O parâmetro **perplexity** controla, grosso modo, quantos vizinhos cada ponto considera. O que se espera do diagrama com **perplexity** muito pequena? E muito grande?
- (d) Por que não se usa t-SNE como etapa de um Pipeline de predição, do jeito que se usa PCA?

Exercício 4 — PCA e SVD são a mesma coisa. Seja $\mathbf{X}$ a matriz $n \times p$ dos dados **centrados**, com decomposição em valores singulares $\mathbf{X} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$, em que $\mathbf{U}$ é $n \times r$ com colunas ortonormais, $\mathbf{D}$ é diagonal $r \times r$ com $d_1 \geq d_2 \geq \dots \geq d_r > 0$, e $\mathbf{V}$ é $p \times r$ com colunas ortonormais.

- (a) Mostre que as colunas de $\mathbf{V}$ são autovetores de $\mathbf{S} = \frac{1}{n}\mathbf{X}^\top\mathbf{X}$ e que o autovalor associado a $\mathbf{v}_j$ é $\lambda_j = d_j^2/n$.
- (b) Conclua que as componentes principais podem ser calculadas por SVD, sem formar $\mathbf{X}^\top\mathbf{X}$. Por que isso importa numericamente?
- (c) As coordenadas dos dados nas k primeiras componentes são as k primeiras colunas de $\mathbf{U}\mathbf{D}$. Verifique isso a partir de $\mathbf{Z} = \mathbf{X}\mathbf{V}$.
- (d) O teorema de Eckart–Young diz que $\mathbf{X}_k = \mathbf{U}_k\mathbf{D}_k\mathbf{V}_k^\top$ é a melhor aproximação de posto k de $\mathbf{X}$, no sentido de minimizar $\|\mathbf{X} - \mathbf{A}\|_F$ entre todas as $\mathbf{A}$ de posto $\leq k$. Que interpretação isso dá à PCA?