

Lista Teórica E3 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula E3 — NLP + Classificação (Aplicação)

Exercício 1 — do texto à matriz. Considere três documentos:

d_1 = “o gato dorme”, d_2 = “o cachorro dorme”, d_3 = “o gato corre e o cachorro corre”.

- Monte o vocabulário em ordem alfabética e escreva a matriz documento–termo de **contagens** ($3 \times V$).
- O **scikit-learn** calcula $\text{idf}(t) = \ln\left(\frac{1+n}{1+\text{df}(t)}\right) + 1$, onde $\text{df}(t)$ é o número de documentos que contêm t . Calcule o idf de *gato* e de *o*.
- Calcule o vetor TF-IDF de d_1 , normalizado em norma ℓ_2 . *Dados:* $\ln(4/3) \approx 0,2877$.
- Por que o termo *o* recebe o menor peso possível? E por que ainda assim ele não é zerado por essa fórmula?

Solução

(a) Vocabulário: *cachorro, corre, dorme, e, gato, o* — $V = 6$.

	cachorro	corre	dorme	e	gato	o
d_1	0	0	1	0	1	1
d_2	1	0	1	0	0	1
d_3	1	2	0	1	1	2

Repare no que se perdeu: a **ordem** das palavras. “o gato corre” e “corre o gato” dão exatamente a mesma linha. É o que o nome *bag of words* — saco de palavras — quer dizer.

(b) Com $n = 3$:

- gato* aparece em d_1 e d_3 , então $\text{df} = 2$ e $\text{idf} = \ln\left(\frac{4}{2}\right) + 1 \approx \mathbf{1,2877}$;
- o* aparece nos três, $\text{df} = 3$ e $\text{idf} = \ln\left(\frac{4}{3}\right) + 1 = \ln 1 + 1 = \mathbf{1}$.

(c) O vetor bruto de d_1 é $\text{tf} \times \text{idf}$, componente a componente. Só três entradas são não nulas:

$$\text{dorme} : 1 \times 1,2877, \quad \text{gato} : 1 \times 1,2877, \quad \text{o} : 1 \times 1.$$

A norma é $\sqrt{1,2877^2 + 1,2877^2 + 1^2} = \sqrt{1,6582 + 1,6582 + 1} = \sqrt{4,3164} \approx 2,0776$, e o vetor normalizado fica

$$\left(0, 0, \underbrace{0,6198}_{\text{dorme}}, 0, \underbrace{0,6198}_{\text{gato}}, \underbrace{0,4813}_{\text{o}}\right).$$

(d) Porque *o* aparece em **todos** os documentos, e um termo que aparece em todo lugar não distingue nada — é exatamente isso que o idf mede. Com $\text{df}(t) = n$, o argumento do logaritmo é $\frac{1+n}{1+n} = 1$ e o idf cai ao seu valor mínimo.

Mas ele não é *zero*: é 1, por causa do “+1” na fórmula. Sem esse termo, todo vocábulo presente em todos os documentos seria multiplicado por zero e sumiria da matriz. O “+1”

é uma decisão de projeto do `scikit-learn` (o parâmetro `smooth_idf` controla o outro “+1”, o de dentro do logaritmo) para que nenhum termo seja descartado *pela fórmula* — descartar é papel do `min_df` e da lista de *stop words*, que são decisões explícitas de quem modela.

Exercício 2 — naive Bayes multinomial e a suavização de Laplace. Um filtro de spam foi treinado sobre um vocabulário de $V = 5$ palavras, com as contagens totais abaixo (soma sobre todas as mensagens de cada classe):

	grátis	clique	oferta	reunião	amanhã	total
spam	8	5	4	0	1	18
não-spam	1	0	1	6	7	15

As priors estimadas são $\mathbb{P}(\text{spam}) = 0,4$ e $\mathbb{P}(\text{não-spam}) = 0,6$. O modelo multinomial estima

$$\mathbb{P}(w | c) = \frac{N_{wc} + \alpha}{N_c + \alpha V},$$

com $\alpha = 1$ (suavização de Laplace).

- Classifique a mensagem “clique oferta grátis”, comparando as log-posterioris das duas classes. *Dados:* $\ln 0,4 = -0,9163$, $\ln 0,6 = -0,5108$.
- O que aconteceria com a log-posteriori de não-spam se $\alpha = 0$ (sem suavização)? Isso é razoável?
- Por que se trabalha com *logaritmos* das probabilidades, e não com as probabilidades diretamente?
- O modelo supõe que as palavras são independentes dentro de cada classe. Cite duas maneiras óbvias pelas quais isso é falso em texto. Por que o método funciona mesmo assim?

Solução

(a) Com $\alpha = 1$ e $V = 5$, o denominador é $18 + 5 = 23$ no spam e $15 + 5 = 20$ no não-spam.

	$\mathbb{P}(w \text{spam})$	$\mathbb{P}(w \text{não-spam})$
clique	$(5 + 1)/23 = 0,2609$	$(0 + 1)/20 = 0,0500$
oferta	$(4 + 1)/23 = 0,2174$	$(1 + 1)/20 = 0,1000$
grátis	$(8 + 1)/23 = 0,3913$	$(1 + 1)/20 = 0,1000$

Somando os logaritmos:

$$\ln \mathbb{P}(\text{spam} | \text{msg}) \propto -0,9163 - 1,3437 - 1,5261 - 0,9383 = -4,7244,$$

$$\ln \mathbb{P}(\text{não-spam} | \text{msg}) \propto -0,5108 - 2,9957 - 2,3026 - 2,3026 = -8,1117.$$

Como $-4,7244 > -8,1117$, a mensagem é classificada como **spam**. (A diferença de 3,39 em log corresponde a uma razão de chances de $e^{3,39} \approx 30$ a favor de spam.)

(b) Sem suavização, $\mathbb{P}(\text{clique} | \text{não-spam}) = 0/15 = 0$, e o produto inteiro zera: $\mathbb{P}(\text{não-spam} | \text{msg}) = 0$ *exatamente*, ou $-\infty$ em log.

Não é razoável. Uma única palavra nunca vista naquela classe no treino **veta** a classe inteira, por mais que todas as outras palavras apontem para ela. E “nunca vista no treino” é banal em texto: o Exercício 3 mostra que a maioria dos termos aparece em pouquíssimos documentos. A suavização substitui a afirmação “é impossível” por “é raro”, que é o que os dados de fato sustentam.

(c) Por **estabilidade numérica**. A posteriori é um produto de tantos fatores quanto palavras na mensagem, cada um bem menor que 1. Numa mensagem de 100 palavras com probabilidades típicas de 10^{-4} , o produto é da ordem de 10^{-400} — abaixo do menor *float* de precisão dupla representável ($\approx 10^{-308}$), e portanto arredondado para zero. As duas classes dariam zero, e a comparação seria impossível.

Em log, o produto vira soma e os valores ficam na casa das centenas negativas, perfeitamente representáveis. Como o logaritmo é estritamente crescente, comparar log-posterioris é equivalente a comparar posterioris.

(d) Duas maneiras óbvias:

- **colocações**: “São” e “Paulo” aparecem juntos muito mais do que o produto das frequências individuais previria; o mesmo para “cartão de crédito”;
- **tema**: numa mensagem sobre futebol, ver “gol” aumenta muito a chance de ver “time” — as palavras de um mesmo campo semântico se atraem, dentro da própria classe.

Funciona mesmo assim pela razão do Exercício 4 da Lista Teórica 08: para **classificar** basta acertar qual log-posteriori é maior, e contar a mesma evidência duas vezes tende a deslocar as duas na mesma direção, preservando a ordem. Some-se a isso a economia de parâmetros — o multinomial estima V probabilidades por classe, e modelar dependências exigiria V^2 ou mais, o que é inviável com V na casa dos milhares.

O preço é a **calibração**, e é o mesmo medido na Lista prática 09: as probabilidades saem empurradas para 0 e 1. Para decidir spam ou não, tanto faz; para dizer “esta mensagem tem 73% de chance de ser spam”, não serve.

Exercício 3 — esparsidade, e o que fazer com ela. Numa coleção de 5 572 mensagens de SMS, o `CountVectorizer` produz um vocabulário de 8 672 termos, e a matriz resultante tem 73 916 entradas não nulas.

- Calcule a densidade da matriz. Se ela fosse guardada densamente, em *float* de 8 bytes, quanto ocuparia? E num formato esparsa que guarda, para cada não-zero, o valor (8 bytes) e o índice da coluna (4 bytes)?
- Por que a matriz é tão esparsa? A mediana de palavras distintas por mensagem é 11; use isso para prever a densidade e compare com o valor do item (a).
- O que faz `CountVectorizer(min_df=5)`? Que efeito isso tem sobre o tamanho do vocabulário, e por que costuma *ajudar* o classificador?
- Cite um método do curso que **não** funcionaria bem sobre uma matriz esparsa desse tipo, e explique por quê.

Solução

(a) A densidade é $73\,916 / (5\,572 \times 8\,672) = 0,153\%$ — menos de duas entradas em cada mil.

Densa: $5\,572 \times 8\,672 \times 8 \text{ bytes} \approx 3,87 \times 10^8 \text{ bytes} \approx \mathbf{387 \text{ MB}}$. Esparsa: $73\,916 \times 12 \text{ bytes} \approx \mathbf{0,89 \text{ MB}}$ (mais um vetor de ponteiros de linha, desprezível). Uma redução de **436 vezes**.

É o que torna o problema tratável num computador comum — e é por isso que todos os vetorizadores do `scikit-learn` devolvem matrizes `scipy.sparse`, não `numpy`.

(b) Porque cada mensagem usa uma fração ínfima do vocabulário. Com mediana de 11 palavras distintas, a linha típica tem 11 entradas não nulas em 8 672 colunas, o que prevê densidade $11/8\,672 \approx 0,127\%$ — próximo dos 0,153% medidos. (A diferença vem da cauda: algumas mensagens são bem mais longas que a mediana, e a densidade é governada pela *média*, não pela mediana.)

O vocabulário é a união do que *todas* as mensagens usam, e cada uma usa quase nada dele. Isso é uma propriedade estrutural de texto, não um acidente deste conjunto: o vocabulário cresce com o tamanho do corpus enquanto o comprimento de cada documento não.

(c) `min_df=5` descarta todo termo que apareça em menos de 5 documentos. O vocabulário encolhe muito — neste corpus, de 7 168 termos (no conjunto de treino) para 1 418 — um quinto. A razão é que 53,9% dos termos aparecem em *um único* documento: nomes próprios, erros de digitação, números.

Costuma ajudar por duas razões. Primeiro, **variância**: um termo que aparece em 2 documentos, ambos spam, recebe um coeficiente enorme e confiante baseado em duas observações — é ruído que o modelo trata como sinal. Segundo, **custo**: menos colunas, menos parâmetros, ajuste mais rápido.

O `min_df` é, portanto, um hiperparâmetro de **regularização** disfarçado de parâmetro de pré-processamento — e, como tal, pertence ao Pipeline e à grade de busca da Aula 07, não a uma decisão tomada uma vez no começo.

(d) O **KNN** (ou qualquer método baseado em distância euclidiana). Duas razões que se somam:

- é a **maldição da dimensionalidade** da Aula 05 na sua forma mais extrema: com $p \approx 8\,700$, a taxa $n^{-2/(2+p)}$ é indistinguível de n^0 , e todos os pontos ficam praticamente equidistantes;
- pior, com esparsidade alta, duas mensagens quaisquer quase não compartilham palavras, então a distância entre elas é essencialmente $\sqrt{\|x_i\|^2 + \|x_j\|^2}$ — determinada pelo *comprimento* das mensagens, não pelo conteúdo delas.

Os métodos que funcionam bem aqui são os **lineares** — naïve Bayes, logística, SVM linear — justamente porque um modelo linear em 8 700 dimensões esparsas tem, na prática, pouquíssimos parâmetros ativos por observação, e porque a penalização ℓ_2 ou ℓ_1 controla a variância sem precisar de nenhuma noção de vizinhança.

Exercício 4 — n -gramas e a explosão do vocabulário. O `CountVectorizer` aceita `ngram_range=(1,2)`, que acrescenta ao vocabulário todos os **pares de palavras consecutivas** além das palavras isoladas.

- Para os três documentos do Exercício 1, liste os bigramas de cada um. Quantos bigramas distintos existem ao todo?
- Que informação os bigramas recuperam, que o saco de palavras havia jogado fora? Dê um exemplo em que isso muda a classificação.
- Um corpus com V palavras distintas tem no máximo V^2 bigramas possíveis, mas na prática o número observado é muito menor. Por quê?

- (d) Acrescentar bigramas aumenta muito o número de colunas. Isso agrava o problema do Exercício 3(d)? E o risco de superajuste?

Solução

(a)

- d_1 : *o gato, gato dorme*;
- d_2 : *o cachorro, cachorro dorme*;
- d_3 : *o gato, gato corre, corre e, e o, o cachorro, cachorro corre*.

Distintos: *o gato, gato dorme, o cachorro, cachorro dorme, gato corre, corre e, e o, cachorro corre* — **8 bigramas**. Com `ngram_range=(1,2)` o vocabulário passaria de 6 para $6 + 8 = 14$ colunas, mais que o dobro, num corpus de três frases.

(b) Os bigramas recuperam, parcialmente, a **ordem** das palavras — a informação que o saco de palavras descartou.

O exemplo canônico em classificação de texto é a **negação**. As frases “não é bom” e “é bom” têm sacos de palavras quase idênticos (a segunda é um subconjunto da primeira), e um modelo unigrama vê “bom” nas duas e tende a classificar as duas como positivas. Com bigramas, “não é” e “é bom” são colunas distintas, e o modelo pode aprender que “não é” carrega peso negativo.

Em detecção de spam, o mesmo vale para expressões: “clique aqui” é muito mais informativo que “clique” e “aqui” separados.

(c) Porque a linguagem é fortemente restrita: a esmagadora maioria dos pares de palavras **nunca ocorre**. Sintaxe (“o” não é seguido de verbo), semântica (“verde” não modifica “segunda-feira”) e simples convenção de uso eliminam quase todas as V^2 combinações.

Empiricamente, o número de bigramas distintos num corpus cresce aproximadamente com o número de *tokens*, e não com V^2 : é a lei de Heaps, e a razão de fundo é a lei de Zipf — a distribuição de frequências das palavras tem cauda muito pesada, e a maioria delas aparece pouquíssimas vezes, logo tem pouquíssimos vizinhos possíveis observados.

(d) **Para o KNN, agrava**. Mais colunas com a mesma quantidade de informação por documento significa esparsidade ainda maior e distâncias ainda menos informativas.

Para o superajuste, o quadro é mais sutil, e a resposta é “depende do que se faz com as colunas”. Sim, o número de parâmetros cresce, e um bigrama que aparece em duas mensagens de spam vira um preditor perfeito no treino e ruído fora dele — exatamente o mecanismo do Exercício 3(c). Mas:

- `min_df` corta justamente esses bigramas raríssimos, que são a maioria esmagadora dos novos;
- a penalização (ℓ_2 da logística, ou o C da SVM) controla os coeficientes das colunas que sobram;
- modelos lineares em alta dimensão esparsa toleram bem colunas extras inúteis, desde que regularizados — é a observação de Greenshtein e Ritov citada na Aula 02, em que p aparece só dentro de um logaritmo.

Na prática, `ngram_range` e `min_df` são escolhidos *juntos*, por validação cruzada, dentro do mesmo Pipeline — e é comum que a combinação vencedora inclua bigramas com um `min_df` mais alto do que o usado só com unigramas.