

Avaliação Teórica 01 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Atenção

Documento do professor. As resoluções indicam o *esperado*; argumentos equivalentes e corretos devem ser aceitos integralmente. Os pesos por item somam o valor da questão.

Questão 1 — A Regressão Ridge como moda a posteriori (4,0 pontos)

Já mencionamos que o Ridge tem uma leitura bayesiana: ele é a moda a posteriori sob uma priori gaussiana. A afirmação é mais do que curiosidade — ela dá um significado concreto ao λ , que até aqui era só um hiperparâmetro.

Considere o modelo

$$\mathbf{y} \mid \boldsymbol{\beta} \sim N(\mathbb{X}\boldsymbol{\beta}, \sigma^2 \mathbb{I}), \quad \boldsymbol{\beta} \sim N(\mathbf{0}, \sigma_{\boldsymbol{\beta}}^2 \mathbb{I}),$$

com σ^2 e $\sigma_{\boldsymbol{\beta}}^2$ conhecidos.

- (a) (1,6) Escreva a densidade a posteriori de $\boldsymbol{\beta}$ a menos de constante multiplicativa e mostre que maximizá-la equivale a minimizar

$$\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \frac{1}{2\sigma_{\boldsymbol{\beta}}^2} \|\boldsymbol{\beta}\|^2.$$

O caminho é o de sempre: passar ao logaritmo transforma produto em soma, e trocar o sinal transforma maximizar em minimizar.

- (b) (1,0) Compare o que você obteve com a definição do Ridge da aula e identifique λ em função de σ^2 e $\sigma_{\boldsymbol{\beta}}^2$. Cuidado com o fator que precisa ser eliminado antes da comparação.
- (c) (1,4) Agora a parte interessante: o que a priori está *afirmando* quando $\sigma_{\boldsymbol{\beta}}^2 \rightarrow \infty$, e quando $\sigma_{\boldsymbol{\beta}}^2 \rightarrow 0$? Ligue cada resposta ao comportamento do Ridge em $\lambda \rightarrow 0$ e $\lambda \rightarrow \infty$.

Solução

(a) Pelo teorema de Bayes, a densidade a posteriori é proporcional ao produto da verossimilhança pela priori. Com as duas densidades normais do modelo,

$$f(\mathbf{y} \mid \boldsymbol{\beta}) = (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2\right\}, \quad \pi(\boldsymbol{\beta}) = (2\pi\sigma_{\boldsymbol{\beta}}^2)^{-q/2} \exp\left\{-\frac{1}{2\sigma_{\boldsymbol{\beta}}^2} \|\boldsymbol{\beta}\|^2\right\},$$

em que q é a dimensão de $\boldsymbol{\beta}$, vem

$$\pi(\boldsymbol{\beta} \mid \mathbf{y}) \propto f(\mathbf{y} \mid \boldsymbol{\beta}) \pi(\boldsymbol{\beta}) \propto \exp\left\{-\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 - \frac{1}{2\sigma_{\boldsymbol{\beta}}^2} \|\boldsymbol{\beta}\|^2\right\}.$$

O " $\propto$ " é em $\boldsymbol{\beta}$: as constantes de normalização e a densidade marginal de $\mathbf{y}$ não dependem de $\boldsymbol{\beta}$, e por isso não mudam *onde* a posteriori é máxima.

A moda a posteriori é o ponto de máximo dessa densidade. Como o logaritmo é estritamente crescente, maximizar uma função positiva é o mesmo que maximizar o seu logaritmo, que aqui é

$$\log \pi(\boldsymbol{\beta} \mid \mathbf{y}) = \text{const} - \frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 - \frac{1}{2\sigma_{\boldsymbol{\beta}}^2} \|\boldsymbol{\beta}\|^2;$$

e maximizar $-F$ é o mesmo que minimizar F . Logo a moda é o minimizador de

$$\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \frac{1}{2\sigma_\beta^2} \|\boldsymbol{\beta}\|^2.$$

Esse objetivo é estritamente convexo (a segunda parcela já é), então o mínimo existe e é único: a moda está bem definida.

(b) Multiplicar o objetivo por $2\sigma^2 > 0$ não muda o minimizador, e elimina o fator que está na frente do RSS:

$$\|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \frac{\sigma^2}{\sigma_\beta^2} \|\boldsymbol{\beta}\|^2.$$

Agora é o objetivo do Ridge, com

$$\lambda = \frac{\sigma^2}{\sigma_\beta^2}$$

O cuidado do enunciado era esse: comparar antes de eliminar o fator leva a ler $\lambda = 1/(2\sigma_\beta^2)$, ou a inverter a razão.

Um detalhe de rigor. Se $\mathbb{X}$ tem a coluna de uns, a priori acima encolhe também o intercepto — e a Ridge da aula não o penaliza. A correspondência exata pede a priori normal só para $\beta_1, \dots, \beta_p$, com uma priori plana para β_0 ($\pi(\beta_0) \propto 1$); ou dados centrados, em que o intercepto sai de cena. Nos dois casos a conta é a mesma, e o λ também.

De quebra: completando o quadrado no expoente, vê-se que a posteriori é normal,

$$\boldsymbol{\beta} \mid \mathbf{y} \sim N\left((\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I})^{-1} \mathbb{X}^\top \mathbf{y}, \sigma^2 (\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I})^{-1}\right),$$

e a média é exatamente o minimizador acima. Numa normal, moda e média coincidem — é por isso que, no Ridge, a solução é a moda e a média a posteriori.

(c) A ponte é $\lambda = \sigma^2/\sigma_\beta^2$: cada afirmação sobre a priori vira uma afirmação sobre a penalização.

Quando $\sigma_\beta^2 \rightarrow \infty$, a priori se espalha. Para dois valores quaisquer de $\boldsymbol{\beta}$, a razão das densidades, $\pi(\boldsymbol{\beta})/\pi(\boldsymbol{\beta}') = \exp\{(\|\boldsymbol{\beta}'\|^2 - \|\boldsymbol{\beta}\|^2)/(2\sigma_\beta^2)\}$, tende a 1: ela deixa de preferir um valor a outro — não afirma nada —, e a posteriori passa a ser ditada pela verossimilhança. Do lado do Ridge, $\lambda \rightarrow 0$, e

$$\hat{\boldsymbol{\beta}}_\lambda = (\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I})^{-1} \mathbb{X}^\top \mathbf{y} \longrightarrow (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{y}$$

quando $\mathbb{X}^\top \mathbb{X}$ é invertível, porque a inversão de matrizes é contínua: o Ridge vira o MQO, com viés pequeno e variância alta.

Quando $\sigma_\beta^2 \rightarrow 0$, a priori se concentra em zero: $\mathbb{P}(\|\boldsymbol{\beta}\| > \varepsilon) \rightarrow 0$ para todo $\varepsilon > 0$. Ela afirma, antes de ver dado algum e com certeza cada vez maior, que os coeficientes são praticamente nulos. Do lado do Ridge, $\lambda \rightarrow \infty$ e $\hat{\boldsymbol{\beta}}_\lambda \rightarrow \mathbf{0}$: como todos os autovalores de $\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I}$ são pelo menos λ , vale $\|\hat{\boldsymbol{\beta}}_\lambda\| \leq \|\mathbb{X}^\top \mathbf{y}\|/\lambda \rightarrow 0$. Variância nula e viés máximo: a estimativa ignora os dados.

Entre os extremos, a fórmula diz uma coisa sensata: regulariza-se mais quando os dados são ruidosos (σ^2 grande) ou quando a crença prévia é firme (σ_β^2 pequeno). O λ é a razão entre duas incertezas, a do ruído e a da priori; e escolhê-lo por validação cruzada é, nessa leitura, deixar os dados escolherem a priori que melhor prediz.

Critério de correção (sugestão)

- (a) 0,8 pelo produto verossimilhança $\times$ priori; 0,8 por passar ao logaritmo e trocar máximo por mínimo corretamente. Ignorar as constantes de normalização não desconta, desde que o aluno justifique que não dependem de β .
- (b) 0,4 por eliminar o fator $1/(2\sigma^2)$ sem alterar o argmin; 0,6 pelo valor de λ . Chegar a λ invertido (σ_β^2/σ^2) vale 0,3 dos 0,6. A observação de que a priori também encolhe o intercepto, que a Ridge da aula não penaliza, não é exigida.
- (c) 0,7 por extremo. Exige ligar priori e λ , não apenas descrever o comportamento do Ridge. Mencionar o par viés-variância é esperado, mas não obrigatório para a nota cheia.

Questão 2 — Duas fórmulas da validação cruzada**(4,0 pontos)**

Quem estuda validação cruzada pelas notas de aula e pelo livro encontra duas fórmulas diferentes para a mesma quantia, e é natural desconfiar de que uma delas esteja errada. Não está: elas só diferem na unidade que cada uma pondera igualmente.

As notas de aula definem

$$\hat{R}_{k-CV} = \frac{1}{n} \sum_{j=1}^k \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2,$$

e o livro define $CV_{(k)} = \frac{1}{k} \sum_{j=1}^k EQM_j$, com $EQM_j = \frac{1}{|L_j|} \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2$.

- (a) **(1,2)** Reescreva a fórmula das notas de modo a fazer os EQM_j aparecerem, mostrando que

$$\hat{R}_{k-CV} = \sum_{j=1}^k \frac{|L_j|}{n} EQM_j.$$

- (b) **(0,8)** Olhando para os pesos que você obteve, diga em que condição as duas definições coincidem — e se coincidem exatamente ou apenas aproximadamente. Em seguida, nomeie a unidade que cada fórmula pondera igualmente.
- (c) **(0,7)** Com $n = 50$ e $k = 7$, as dobras não podem ter todas o mesmo tamanho; suponha que tenham tamanhos 8, 8, 7, 7, 7, 7, 6. Confirme que somam 50 e explique por que, neste caso, os dois números diferem.
- (d) **(1,3)** Suponha que a dobra de 6 observações tenha $EQM = 10$ e todas as outras tenham $EQM = 1$. Calcule os dois estimadores, diga qual deles dá mais peso à dobra atípica, e qual você reportaria. Justifique a escolha.

Solução

- (a) A chave é reconhecer a soma interna. Pela definição de EQM_j , basta multiplicar dos dois lados por $|L_j|$:

$$\sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2 = |L_j| EQM_j.$$

Substituindo na fórmula das notas,

$$\hat{R}_{k-CV} = \frac{1}{n} \sum_{j=1}^k |L_j| EQM_j = \sum_{j=1}^k \frac{|L_j|}{n} EQM_j.$$

São os *mesmos* EQM_j do livro, combinados com pesos $w_j = |L_j|/n$. E esses pesos somam 1, porque as dobras particionam as n observações: $\sum_j |L_j| = n$. As duas fórmulas são,

portanto, médias ponderadas dos mesmos k números, e só diferem nos pesos: $|L_j|/n$ numa, $1/k$ na outra.

(b) Os pesos coincidem em todas as dobras se e só se $|L_j|/n = 1/k$ para todo j , isto é, se todas as dobras têm tamanho n/k — o que só é possível quando k divide n . Nesse caso as duas fórmulas são a mesma soma dos mesmos números com os mesmos pesos: coincidem **exatamente**, e não aproximadamente.

A unidade que cada uma pondera igualmente: as notas dão o mesmo peso a cada **observação** — todo resíduo de validação entra com peso $1/n$ —; o livro dá o mesmo peso a cada **dobra**. Visto do lado das observações, o livro dá a cada resíduo da dobra j o peso $1/(k|L_j|)$.

(c) $8 + 8 + 7 + 7 + 7 + 7 + 6 = 50$.

Os pesos das notas são $8/50$ (duas vezes), $7/50$ (quatro vezes) e $6/50$; os do livro, $1/7$ para cada dobra. Como os tamanhos diferem, os pesos diferem, e as duas médias só coincidem por acaso — quando os EQM_j são todos iguais, por exemplo.

Olhando por observação fica mais claro. No livro, cada resíduo recebe

$$\frac{1}{7 \cdot 8} = \frac{1}{56}, \quad \frac{1}{7 \cdot 7} = \frac{1}{49} \quad \text{ou} \quad \frac{1}{7 \cdot 6} = \frac{1}{42},$$

conforme a dobra em que caiu, contra $1/50$ para todos nas notas. Uma observação da dobra de 6 pesa $4/3$ de uma da dobra de 8, só porque divide a sua dobra com menos gente.

(d) Pelas notas, a dobra atípica entra com peso $6/50$ e as outras 44 observações com $44/50$:

$$\hat{R}_{k\text{-CV}} = \frac{6}{50} \times 10 + \frac{44}{50} \times 1 = \frac{104}{50} = \mathbf{2,08}.$$

Pelo livro, a dobra atípica é uma das sete, e só:

$$\text{CV}_{(7)} = \frac{1}{7}(10 + 6 \times 1) = \frac{16}{7} \approx \mathbf{2,286}.$$

O livro dá mais peso à dobra atípica: $1/7 \approx 0,143$ contra $6/50 = 0,12$. Ela é a menor dobra e, ainda assim, vale um sétimo do total.

Qual reportar? Para *estimar o risco*, a das notas tem a seu favor um argumento limpo. O risco é a esperança da perda numa observação nova, e cada resíduo de validação ℓ_i é uma medida dessa perda. Se essas medidas tivessem a mesma média e a mesma variância s^2 , e fossem não correlacionadas — uma idealização, mas é ela que orienta —, toda combinação $\sum_i w_i \ell_i$ com pesos somando 1 teria a mesma média, e variância $s^2 \sum_i w_i^2$. Pela desigualdade de Cauchy–Schwarz,

$$1 = \left(\sum_{i=1}^n w_i \right)^2 \leq n \sum_{i=1}^n w_i^2,$$

com igualdade só nos pesos iguais, $w_i = 1/n$. Pesar as observações igualmente é o que menos desperdiça informação; dar mais peso a quem caiu numa dobra pequena é deixar o acaso do corte decidir.

A do livro também se defende. Ela trata cada dobra como uma repetição do experimento "treinar e validar", e é a escala natural quando o que se quer é comparar as dobras entre si: é dos k números EQM_j que sai o erro-padrão da regra de um erro-padrão. E é a que o `scikit-learn` calcula — `cross_val_score(...).mean()` é média não ponderada —, então o essencial é *saber qual das duas o seu código calcula* antes de comparar o seu número com o de outra pessoa.

E a recomendação das notas encerra a discussão pela raiz: com n pequeno, escolha um k que divida n . Aí as duas coincidem, e a pergunta não se coloca.

Critério de correção (sugestão)

- (a) 0,6 por reconhecer que $\sum_{i \in L_j} (\cdot)^2 = |L_j| \text{EQM}_j$; 0,6 pela substituição e pela forma final. Observar que os pesos somam 1 é bônus.
- (b) 0,5 pela igualdade dos pesos quando k divide n ; 0,3 por nomear as duas unidades (observação $\times$ dobra). Responder "aproximadamente iguais" perde 0,2 — a igualdade é exata.
- (c) 0,2 pela soma; 0,5 pela explicação dos pesos desiguais. Basta o argumento; não é preciso calcular os sete pesos.
- (d) 0,45 por cada valor correto (2,08 e $\approx 2,286$); 0,1 por dizer que a do livro dá mais peso à dobra atípica; 0,3 pela justificativa da escolha. Aceitar tanto a defesa da fórmula ponderada quanto a da não ponderada, desde que argumentada; **não** aceitar resposta que ignore a existência das duas.

Questão 3**(4,0 pontos)**

Um colega recebeu um banco de dados em que a coluna **renda** está em reais e a coluna **altura** em metros, e pergunta se precisa padronizar antes de ajustar. A resposta honesta é "depende do método" — e o critério que decide cabe numa pergunta: **o método soma coisas vindas de colunas diferentes?**

Se soma, as unidades precisam ser comparáveis, e trocar uma delas estraga a comparação. Se não soma, a unidade é irrelevante.

- (a) **(2,0 — 0,4 cada)** Para cada método abaixo, diga se multiplicar uma única coluna por 1000 **muda** ou **não muda** a predição, justificando em uma linha onde está — ou onde não está — a soma sobre colunas.
- (i) Mínimos quadrados ordinários.
 - (ii) Regressão Ridge com $\lambda > 0$ fixo.
 - (iii) Árvore de regressão.
 - (iv) Floresta aleatória.
 - (v) KNN com k fixo.
- (b) **(0,9)** Entre os que mudam, qual você espera que seja o mais afetado, e por quê? Compare o *modo* como a escala entra em cada um.
- (c) **(1,1)** Outro colega ajustou o Lasso a dados padronizados, com λ escolhido por validação cruzada. Em seguida multiplicou por 1000 a coluna de maior efeito sobre Y , reajustou com o *mesmo* λ , e o erro quadrático médio no conjunto de teste *diminuiu*. Ele conclui que é melhor não padronizar. Explique por que a reescala pode ter ajudado e por que a conclusão não se sustenta.

Solução

Uma única mudança de variáveis resolve de uma vez os três métodos lineares. Seja $c = 1000$, e suponha que a coluna reescalada é a primeira: os dados novos são $\tilde{\mathbb{X}} = \mathbb{X}D$, com $D = \text{diag}(c, 1, \dots, 1)$. Para um vetor γ de coeficientes nos dados novos, escreva $\beta = D\gamma$, isto é, $\beta_1 = c\gamma_1$ e $\beta_j = \gamma_j$ para $j \geq 2$. Então $\tilde{\mathbb{X}}\gamma = \mathbb{X}\beta$: é o *mesmo ajuste*, escrito em outra unidade, e o RSS não muda. Já as penalidades mudam:

$$\sum_j \gamma_j^2 = \frac{\beta_1^2}{c^2} + \sum_{j \geq 2} \beta_j^2, \quad \sum_j |\gamma_j| = \frac{|\beta_1|}{c} + \sum_{j \geq 2} |\beta_j|.$$

Ou seja: **reescalar a coluna 1 equivale a trocar o peso dela na penalidade** — por $1/c^2 = 10^{-6}$ no Ridge, por $1/c = 10^{-3}$ no Lasso — e deixar todo o resto igual. Onde não há penalidade, não há o que mudar.

- (a) Só dois mudam: o Ridge e o KNN.

- (i) **MQO: não muda.** Sem penalidade, o problema reescalado é o mesmo problema: o coeficiente da coluna vira $\beta_1/1000$, o produto $\beta_1 x_1$ fica igual, e as previsões também. A previsão *soma* sobre as colunas, $\sum_j \beta_j x_j$, mas cada parcela é um número na unidade de Y , que o coeficiente ajusta livremente; nada na função-objetivo compara grandezas de colunas diferentes com pesos fixos.
- (ii) **Ridge ($\lambda > 0$): muda.** A penalidade $\lambda \sum_j \beta_j^2$ soma, com o mesmo peso, coeficientes de colunas diferentes, e cada coeficiente carrega a unidade da sua coluna. Pela conta acima, a coluna reescalada passa a ser penalizada com peso $\lambda \cdot 10^{-6}$.
- (iii) **Árvore: não muda.** Ela só pergunta " $x_j \leq t$ ", e $\{x_1 \leq t\} = \{1000 x_1 \leq 1000 t\}$: as partições que se consegue formar são as mesmas, com o mesmo RSS cada uma, e o corte escolhido é o mesmo, com o limiar multiplicado por 1000.
- (iv) **Floresta aleatória: não muda.** Cada árvore é indiferente à escala, e os sorteios — das amostras bootstrap e das covariáveis candidatas — não olham os valores. Com os mesmos sorteios, cada árvore sai idêntica, e a média também.
- (v) **KNN com k fixo: muda.** A distância $\sum_j (x_{ij} - x_{\ell j})^2$ soma, com o mesmo peso, diferenças medidas em unidades diferentes; a parcela da coluna reescalada fica multiplicada por 10^6 .

(b) O KNN. O tamanho do fator não distingue os dois — nos dois ele chega a 10^6 —; o que distingue é *o que a escala controla* em cada um.

No Ridge, a escala controla *quanto um coeficiente é penalizado*. Pela conta do início, o novo ajuste é o de um Ridge em que a coluna reescalada está praticamente isenta de encolhimento. Todas as colunas continuam sendo usadas, e a mudança é limitada: o pior que pode acontecer é aquele coeficiente deixar de ser encolhido — e a diferença some quando $\lambda \rightarrow 0$, porque aí o Ridge vira o MQO, que não muda.

No KNN, a escala controla *quem entra na média*. A distância passa a ser

$$10^6 (x_{i1} - x_{\ell 1})^2 + \sum_{j \geq 2} (x_{ij} - x_{\ell j})^2,$$

e basta que duas observações difiram um pouco em x_1 para essa parcela dominar todas as outras. Os vizinhos passam a ser, na prática, os de um KNN que só enxerga a coluna reescalada: as outras colunas não ficam só menos importantes — saem da conta, e a informação que carregavam se perde. Nenhum k a recupera.

(c) *Por que a reescala pode ter ajudado.* Pela conta do início, o Lasso nos dados reescalados é o Lasso original com a penalidade da coluna reescalada multiplicada por 10^{-3} : justamente a coluna que mais importa ficou quase isenta de encolhimento. E encolher um coeficiente grande é quase só viés. No caso ortonormal, em que o Lasso tem fórmula fechada, um coeficiente com $|\hat{\beta}_j|$ bem acima de $\lambda/2$ é deslocado de exatamente $\lambda/2$: um deslocamento fixo, que não reduz variância nenhuma e acrescenta $\lambda^2/4$ ao erro quadrático daquele coeficiente. Tirar esse viés pode baixar o erro de teste — pode, não precisa.

Por que a conclusão não se sustenta. O resultado dependeu de *qual* coluna foi reescalada. Faça o mesmo com uma coluna *irrelevante* e o efeito tende a se inverter: quase isenta da penalidade, ela deixa de ser zerada, recebe um coeficiente ajustado ao ruído, e o erro de teste piora. Além disso, a comparação usou o mesmo λ , escolhido por validação cruzada para os dados padronizados; nos dados reescalados, nem é esse o λ que a validação cruzada escolheria.

O ponto de fundo é que, nos dois casos, quem decidiu quanto regularizar cada coluna não foi o analista: foi a **unidade de medida** em que o dado chegou. Um procedimento cujo

resultado depende de a coluna ter sido anotada em metros ou em milímetros não está bem definido, e ter dado certo desta vez não muda isso. Se a conclusão é que aquela coluna merece menos penalidade, essa é uma decisão a tomar com os dados — por validação cruzada —, e não a deixar por conta da unidade.

Critério de correção (sugestão)

- (a) 0,2 pelo veredito e 0,2 pela justificativa, em cada um dos cinco itens. Veredito certo com justificativa ausente ou errada vale 0,2. Aceitar "equivariante" sem demonstração em (i); ali, também está certo dizer que a predição soma $\beta_j x_j$ sobre as colunas, desde que se note que cada parcela não depende da unidade.
- (b) 0,3 por apontar o KNN; 0,6 por comparar o que a escala controla em cada um: no Ridge, quanto um coeficiente é penalizado; no KNN, quem são os vizinhos, com as outras colunas saindo da conta. Dizer apenas que a escala entra ao quadrado na distância vale 0,2 desses 0,6, porque ela também entra ao quadrado na penalidade do Ridge. Responder "Ridge" com bom argumento vale 0,4.
- (c) 0,5 pelo mecanismo: o coeficiente da coluna reescalada fica 1000 vezes menor e escapa quase inteiramente da penalidade, de modo que a coluna mais importante deixa de ser encolhida. 0,6 por explicar por que a conclusão não se sustenta: numa coluna irrelevante o efeito tende a se inverter. A observação de que foi a unidade de medida que tomou a decisão é o ponto alto da resposta e deve ser premiada dentro dos 0,6; aceitar também, como parte deles, o argumento de que um resultado favorável isolado não valida o procedimento, ou o de que a comparação usou o mesmo λ , escolhido para os dados padronizados.

Boa prova!