

Avaliação Teórica 01 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Conteúdo: Aulas 01 a 06 — Fundamentos, Regressão, Validação Cruzada, KNN, Árvores e Pipelines

Atenção

Documento do professor. As resoluções indicam o *esperado*; argumentos equivalentes e corretos devem ser aceitos integralmente. Os pesos por item somam o valor da questão.

Questão 1 — a Ridge como moda a posteriori

(4,0 pontos)

[Aula 02]

A Aula 02 menciona que o Ridge tem uma leitura bayesiana: ele é a moda a posteriori sob uma priori gaussiana. A afirmação é mais do que curiosidade — ela dá um significado concreto ao λ , que até aqui era só um botão a girar.

Suponha o modelo

$$\mathbf{y} | \boldsymbol{\beta} \sim N(\mathbb{X}\boldsymbol{\beta}, \sigma^2 \mathbb{I}), \quad \boldsymbol{\beta} \sim N(\mathbf{0}, \sigma_{\boldsymbol{\beta}}^2 \mathbb{I}),$$

com σ^2 e $\sigma_{\boldsymbol{\beta}}^2$ conhecidos.

- (a) (1,2) Escreva a densidade a posteriori de $\boldsymbol{\beta}$ a menos de constante multiplicativa e mostre que maximizá-la equivale a minimizar

$$\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \frac{1}{2\sigma_{\boldsymbol{\beta}}^2} \|\boldsymbol{\beta}\|^2.$$

O caminho é o de sempre: passar ao logaritmo transforma produto em soma, e maximizar em minimizar.

- (b) (0,8) Compare o que você obteve com a definição do Ridge da aula e identifique λ em função de σ^2 e $\sigma_{\boldsymbol{\beta}}^2$. Cuidado com o fator que precisa ser eliminado antes da comparação.
- (c) (0,8) Agora a parte interessante: o que a priori está *afirmando* quando $\sigma_{\boldsymbol{\beta}}^2 \rightarrow \infty$, e quando $\sigma_{\boldsymbol{\beta}}^2 \rightarrow 0$? Ligue cada resposta ao comportamento do Ridge em $\lambda \rightarrow 0$ e $\lambda \rightarrow \infty$.
- (d) (1,2) Neste modelo a moda e a média a posteriori coincidem. Para o Lasso a priori correspondente é a de Laplace, e essa coincidência **falha**. Explique por que isso importa na prática — em particular, por que a média a posteriori do Lasso não produz coeficientes exatamente nulos.

Solução

- (a) Pelo teorema de Bayes, a posteriori é proporcional ao produto da verossimilhança pela priori:

$$\pi(\boldsymbol{\beta} | \mathbf{y}) \propto f(\mathbf{y} | \boldsymbol{\beta}) \pi(\boldsymbol{\beta}) \propto \exp \left\{ -\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 \right\} \cdot \exp \left\{ -\frac{1}{2\sigma_{\boldsymbol{\beta}}^2} \|\boldsymbol{\beta}\|^2 \right\}.$$

As constantes de normalização das duas gaussianas não dependem de $\boldsymbol{\beta}$ e por isso podem ser absorvidas no $\propto$.

Maximizar uma função positiva é o mesmo que maximizar seu logaritmo, e o logaritmo de

um produto de exponenciais é a soma dos expoentes:

$$\log \pi(\boldsymbol{\beta} \mid \mathbf{y}) = \text{const} - \frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 - \frac{1}{2\sigma_{\beta}^2} \|\boldsymbol{\beta}\|^2.$$

Maximizar isso é minimizar o simétrico dos dois termos que dependem de $\boldsymbol{\beta}$, que é exatamente o objetivo do enunciado.

(b) O objetivo de (a) tem um $1/(2\sigma^2)$ na frente do primeiro termo, e a definição do Ridge não tem fator nenhum ali. Multiplique tudo por $2\sigma^2 > 0$ — o que não altera o minimizador, por ser constante positiva:

$$\|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \frac{\sigma^2}{\sigma_{\beta}^2} \|\boldsymbol{\beta}\|^2.$$

Agora a comparação é imediata, e

$$\lambda = \frac{\sigma^2}{\sigma_{\beta}^2}$$

(c) Quando $\sigma_{\beta}^2 \rightarrow \infty$, a priori fica **difusa**: ela espalha massa por toda parte e não expressa preferência alguma por coeficientes pequenos. Em outras palavras, ela não afirma nada. Correspondentemente $\lambda \rightarrow 0$ e o Ridge degenera no MQO: os dados decidem sozinhos, com viés baixo e variância alta.

Quando $\sigma_{\beta}^2 \rightarrow 0$, a priori fica **concentrada em zero**: ela afirma, antes de ver dado nenhum, que os coeficientes são praticamente nulos. Correspondentemente $\lambda \rightarrow \infty$ e $\hat{\boldsymbol{\beta}} \rightarrow \mathbf{0}$: viés máximo, variância mínima.

Entre os dois extremos, a fórmula $\lambda = \sigma^2/\sigma_{\beta}^2$ diz uma coisa bem razoável: regulariza-se mais quando os *dados* são ruidosos (σ^2 grande) ou quando a *crença prévia* é firme (σ_{β}^2 pequeno). O λ é a razão entre duas incertezas, e escolhê-lo por validação cruzada é, nessa leitura, deixar os dados escolherem a priori que melhor prediz.

(d) Importa porque o que torna o Lasso atraente é a **esparsidade** — coeficientes exatamente nulos, que equivalem a descartar covariáveis — e a esparsidade é propriedade da *moda*, não da média.

Veja por quê. A posteriori do Lasso é uma densidade contínua em $\mathbb{R}^p$, e a massa que uma densidade contínua atribui a um ponto isolado é zero: $\mathbb{P}(\beta_j = 0) = 0$ sob a posteriori. Isso não impede que a *moda* caia exatamente sobre $\beta_j = 0$ — a priori de Laplace tem um bico ali, e o ponto de máximo pode perfeitamente ser um ponto angular. É isso que o algoritmo de otimização encontra.

A *média*, porém, integra sobre toda a densidade. E não há razão para uma integral de função contínua dar exatamente zero: ela dá um número pequeno, muito pequeno talvez, mas não nulo.

A consequência prática é direta: se você quer seleção de variáveis, tem de reportar a moda — que é o que o Lasso do `scikit-learn` devolve, porque ele resolve um problema de otimização. Quem rodar um amostrador bayesiano e tomar a média das amostras vai obter encolhimento, e nenhum zero, e pode concluir erradamente que "o Lasso não zerou nada".

Critério de correção (sugestão)

(a) 0,6 pelo produto verossimilhança $\times$ priori; 0,6 por passar ao logaritmo e trocar máximo por mínimo corretamente. Ignorar as constantes de normalização não desconta, desde que o aluno justifique que não dependem de $\boldsymbol{\beta}$.

- (b) 0,4 por eliminar o fator $1/(2\sigma^2)$ sem alterar o argmin; 0,4 pelo valor de λ . Chegar a λ invertido (σ_β^2/σ^2) vale 0,2.
- (c) 0,4 por extremo. Exige ligar priori e λ , não apenas descrever o comportamento do Ridge. Mencionar o par viés–variância é esperado, mas não obrigatório para a nota cheia.
- (d) 0,6 por identificar que a esparsidade é propriedade da moda; 0,6 por explicar que a posteriori é contínua e a média inteira. Aceitar qualquer formulação correta do argumento de continuidade.

Questão 2 — a mesma validação cruzada, escrita de dois jeitos (4,0 pontos)

[Aula 03]

Quem estuda validação cruzada pela Aula 03 e pelo [ISLP] encontra duas fórmulas diferentes para a mesma coisa, e é natural desconfiar de que uma delas esteja errada. Não está: elas são a mesma conta, escrita com outra unidade.

A Aula 03 define

$$\hat{R}_{k\text{-CV}} = \frac{1}{n} \sum_{j=1}^k \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2,$$

e o [ISLP] define $\text{CV}_{(k)} = \frac{1}{k} \sum_{j=1}^k \text{EQM}_j$, com $\text{EQM}_j = \frac{1}{|L_j|} \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2$.

- (a) (1,2) Reescreva a fórmula da aula de modo a fazer os EQM_j aparecerem, mostrando que

$$\hat{R}_{k\text{-CV}} = \sum_{j=1}^k \frac{|L_j|}{n} \text{EQM}_j.$$

- (b) (0,8) Olhando para os pesos que você obteve, diga em que condição as duas definições coincidem — e se coincidem exatamente ou apenas aproximadamente. Em seguida, nomeie a unidade que cada fórmula pondera igualmente.
- (c) (0,7) Com $n = 50$ e $k = 7$, o `KFold` produz dobras de tamanhos 8, 8, 7, 7, 7, 7, 6. Confirme que somam 50 e explique por que, neste caso, os dois números diferem.
- (d) (1,3) Suponha que a dobra de 6 observações tenha $\text{EQM} = 10$ e todas as outras tenham $\text{EQM} = 1$. Calcule os dois estimadores, diga qual deles dá mais peso à dobra atípica, e qual você reportaria. Justifique a escolha.

Solução

- (a) A chave é reconhecer a soma interna. Pela definição de EQM_j , basta multiplicar dos dois lados por $|L_j|$:

$$\sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2 = |L_j| \text{EQM}_j.$$

Substituindo na fórmula da aula,

$$\hat{R}_{k\text{-CV}} = \frac{1}{n} \sum_{j=1}^k |L_j| \text{EQM}_j = \sum_{j=1}^k \frac{|L_j|}{n} \text{EQM}_j.$$

São os *mesmos* EQM_j do [ISLP], numa média ponderada. E os pesos somam 1, porque as dobras particionam as n observações: $\sum_j |L_j| = n$.

- (b) Se k divide n , todas as dobras têm o mesmo tamanho $|L_j| = n/k$, e cada peso vale $(n/k)/n = 1/k$. A média ponderada vira média simples — que é exatamente a definição do [ISLP].

E coincidem **exatamente**, não aproximadamente: é a mesma soma dos mesmos números com os mesmos pesos.

Quanto à unidade, a diferença é essa: a fórmula da aula pondera igualmente cada **observação**, e a do [ISLP] pondera igualmente cada **dobra**.

(c) $8 + 8 + 7 + 7 + 7 + 7 + 6 = 50$.

Diferem porque os tamanhos não são todos iguais. Os pesos da fórmula da aula valem $8/50$, $8/50$, $7/50$ (quatro vezes) e $6/50$, enquanto a do [ISLP] usa $1/7$ para todas as sete. O efeito concreto é sobre as observações individuais: uma que caiu na dobra de 6 recebe, na conta do [ISLP], peso maior do que uma que caiu na dobra de 8 — porque ela divide a responsabilidade da sua dobra com menos gente.

(d) Pela fórmula da aula, a dobra atípica entra com peso $6/50$ e as outras 44 observações com $44/50$:

$$\hat{R}_{k-CV} = \frac{6}{50} \times 10 + \frac{44}{50} \times 1 = \frac{60 + 44}{50} = \frac{104}{50} = \mathbf{2,08}.$$

Pela do [ISLP], a dobra atípica é uma das sete, e só:

$$CV_{(7)} = \frac{1}{7}(10 + 6 \times 1) = \frac{16}{7} \approx \mathbf{2,286}.$$

A do [ISLP] dá mais peso à dobra atípica — e é fácil ver por quê: ela é a *menor* dobra e ainda assim vale $1/7 \approx 0,143$ do total, contra $6/50 = 0,12$ na outra conta. Justamente por ter menos observações, cada uma delas pesa mais.

Qual reportar? Para *estimar o risco*, a fórmula da aula é a mais defensável: a unidade amostral é a observação, não a dobra, e não há razão para uma observação valer mais por acaso de agrupamento. Na prática, porém, o `scikit-learn` segue o [ISLP] — `cross_val_score(...).mean()` é média não ponderada — então o essencial é *saber qual das duas o seu código está calculando* antes de comparar com o de outra pessoa.

E a recomendação da aula encerra a discussão pela raiz: com n pequeno, escolha um k que divida n . Aí as duas coincidem e a pergunta não se coloca.

Critério de correção (sugestão)

- (a) 0,6 por reconhecer que $\sum_{i \in L_j} (\cdot)^2 = |L_j| \text{EQM}_j$; 0,6 pela substituição e pela forma final. Observar que os pesos somam 1 é bônus.
- (b) 0,5 pela igualdade dos pesos quando k divide n ; 0,3 por nomear as duas unidades (observação $\times$ dobra). Responder "aproximadamente iguais" perde 0,2 — a igualdade é exata.
- (c) 0,2 pela soma; 0,5 pela explicação dos pesos desiguais. Basta o argumento; não é preciso calcular os sete pesos.
- (d) 0,45 por cada valor correto (2,08 e $\approx 2,286$); 0,4 pela justificativa da escolha. Aceitar tanto a defesa da fórmula ponderada quanto a da não ponderada, desde que argumentada; **não** aceitar resposta que ignore a existência das duas.

Questão 3 — para quem a régua importa

(4,0 pontos)

[Aula 06]

Um colega recebeu um banco em que a coluna **renda** está em reais e a coluna **altura** em metros, e pergunta se precisa padronizar antes de ajustar. A resposta honesta é "depende do método" — e o critério que decide cabe numa pergunta: **o método soma coisas vindas de colunas diferentes?**

Se soma, as unidades precisam ser comparáveis, e trocar uma delas estraga a comparação. Se não soma, a unidade é irrelevante.

- (a) **(2,4 — 0,4 cada)** Para cada método abaixo, diga se multiplicar uma única coluna por 1000 **muda** ou **não muda** a predição, justificando em uma linha onde está — ou onde não está — a soma sobre colunas.

- (i) Mínimos quadrados ordinários.
 - (ii) Regressão Ridge com $\lambda > 0$ fixo.
 - (iii) Árvore de regressão.
 - (iv) Floresta aleatória.
 - (v) KNN com k fixo.
 - (vi) *Spline* de base truncada, ajustado por mínimos quadrados.
- (b) (0,7) Entre os que mudam, qual você espera que seja o mais afetado, e por quê? Compare o *modo* como a escala entra em cada um.
- (c) (0,9) Um colega observa que, ao reescalar uma coluna, o risco do Lasso *melhorou*, e conclui que não padronizar foi uma boa ideia. Explique o erro do raciocínio.

Solução

(a)

	muda?	onde está (ou não) a soma sobre colunas
(i)	não	O MQO é equivariante: o coeficiente da coluna se divide por 1000 e o produto $\beta_j x_j$ fica igual. Nada na função-objetivo compara coeficientes entre si.
(ii)	sim	A penalidade $\lambda \sum_j \beta_j^2$ soma coeficientes de colunas diferentes; mudar a unidade de uma delas muda quanto ela pesa nessa soma.
(iii)	não	A árvore só pergunta " $x_j \leq t$ ". O corte t é multiplicado junto, e a pergunta separa exatamente as mesmas observações.
(iv)	não	É uma média de árvores, e cada uma é indiferente; a indiferença atravessa a agregação.
(v)	sim	A distância euclidiana $\sum_j (x_{ij} - x_{\ell j})^2$ é uma soma sobre colunas.
(vi)	não	É um MQO sobre uma base fixa de funções de uma coluna; vale o mesmo argumento de (i).

(b) O KNN, e a diferença é de ordem, não de grau.

Nos métodos penalizados a escala entra *uma vez*, de forma linear, na comparação entre coeficientes. Na distância euclidiana ela entra **ao quadrado**: multiplicar a coluna por 1000 multiplica as diferenças naquela coordenada por 1000, e a contribuição delas para a distância por 10^6 .

O efeito é que a coluna reescalada passa a decidir sozinha quem é vizinho de quem. As demais não são apenas menos importantes — elas somem da conta, e o método deixa de usar a informação que carregavam.

(c) O erro é confundir um resultado com um argumento.

A melhora aconteceu porque a coluna reescalada era, naquele problema, a de maior efeito verdadeiro. Deixá-la 1000 vezes maior tornou o coeficiente dela 1000 vezes menor, e um coeficiente minúsculo quase não pesa em $\sum_j |\beta_j|$ — a coluna ficou praticamente isenta da penalidade. Isentar de penalidade justamente a coluna que mais importa calhou de ajudar. Calhou: é sorte, não método. Aplique a mesma reescala a uma coluna *irrelevante* e o efeito se inverte — ela ganharia liberdade para receber um coeficiente grande sem pagar por isso, e o ajuste pioraria.

O ponto de fundo é que, nos dois casos, quem decidiu quanto regularizar cada coluna não foi o analista: foi a **unidade de medida** em que o dado chegou. E é por isso que o

argumento do colega não se salva nem quando o resultado o favorece — um procedimento cujo desempenho depende de a coluna ter sido anotada em metros ou em milímetros está fora de controle, e ter dado certo desta vez não muda isso.

Critério de correção (sugestão)

- (a) 0,2 pelo veredito e 0,2 pela justificativa, em cada um dos seis itens. Veredito certo com justificativa ausente ou errada vale 0,2. Aceitar "equivariante" sem demonstração em (i) e (vi).
- (b) 0,3 por apontar o KNN; 0,4 pelo argumento do quadrado na distância. Responder "Ridge" com bom argumento vale 0,3.
- (c) 0,4 por identificar que a coluna reescalada era a de maior efeito; 0,5 por explicar que o efeito se inverteria numa coluna irrelevante. A observação de que foi a unidade de medida que tomou a decisão é o ponto alto da resposta e deve ser premiada dentro dos 0,5.

Boa prova!