

Avaliação Teórica 01 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Atenção

Documento do professor. As resoluções indicam o *esperado*; argumentos equivalentes e corretos devem ser aceitos integralmente. Os pesos por item somam o valor da questão.

Questão 1 — A Regressão Ridge como moda a posteriori (4,0 pontos)

Já mencionamos que o Ridge tem uma leitura bayesiana: ele é a moda a posteriori sob uma priori gaussiana. A afirmação é mais do que curiosidade — ela dá um significado concreto ao λ , que até aqui era só um hiperparâmetro.

Considere o modelo

$$\mathbf{y} \mid \boldsymbol{\beta} \sim N(\mathbb{X}\boldsymbol{\beta}, \sigma^2 \mathbb{I}), \quad \boldsymbol{\beta} \sim N(\mathbf{0}, \sigma_{\boldsymbol{\beta}}^2 \mathbb{I}),$$

com σ^2 e $\sigma_{\boldsymbol{\beta}}^2$ conhecidos.

- (a) (1,6) Escreva a densidade a posteriori de $\boldsymbol{\beta}$ a menos de constante multiplicativa e mostre que maximizá-la equivale a minimizar

$$\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \frac{1}{2\sigma_{\boldsymbol{\beta}}^2} \|\boldsymbol{\beta}\|^2.$$

O caminho é o de sempre: passar ao logaritmo transforma produto em soma, e trocar o sinal transforma maximizar em minimizar.

- (b) (1,0) Compare o que você obteve com a definição do Ridge da aula e identifique λ em função de σ^2 e $\sigma_{\boldsymbol{\beta}}^2$. Cuidado com o fator que precisa ser eliminado antes da comparação.
- (c) (1,4) Agora a parte interessante: o que a priori está *afirmando* quando $\sigma_{\boldsymbol{\beta}}^2 \rightarrow \infty$, e quando $\sigma_{\boldsymbol{\beta}}^2 \rightarrow 0$? Ligue cada resposta ao comportamento do Ridge em $\lambda \rightarrow 0$ e $\lambda \rightarrow \infty$.

Solução

(a) Pelo teorema de Bayes, a posteriori é proporcional ao produto da verossimilhança pela priori:

$$\pi(\boldsymbol{\beta} \mid \mathbf{y}) \propto f(\mathbf{y} \mid \boldsymbol{\beta}) \pi(\boldsymbol{\beta}) \propto \exp \left\{ -\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 \right\} \cdot \exp \left\{ -\frac{1}{2\sigma_{\boldsymbol{\beta}}^2} \|\boldsymbol{\beta}\|^2 \right\}.$$

As constantes de normalização das duas gaussianas não dependem de $\boldsymbol{\beta}$ e por isso podem ser absorvidas no $\propto$.

Maximizar uma função positiva é o mesmo que maximizar seu logaritmo, e o logaritmo de um produto de exponenciais é a soma dos expoentes:

$$\log \pi(\boldsymbol{\beta} \mid \mathbf{y}) = \text{const} - \frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 - \frac{1}{2\sigma_{\boldsymbol{\beta}}^2} \|\boldsymbol{\beta}\|^2.$$

Maximizar isso é minimizar o simétrico dos dois termos que dependem de $\boldsymbol{\beta}$, que é exatamente o objetivo do enunciado.

(b) O objetivo de (a) tem um $1/(2\sigma^2)$ na frente do primeiro termo, e a definição do Ridge não tem fator nenhum ali. Multiplique tudo por $2\sigma^2 > 0$ — o que não altera o minimizador, por ser constante positiva:

$$\|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \frac{\sigma^2}{\sigma_\beta^2} \|\boldsymbol{\beta}\|^2.$$

Agora a comparação é imediata, e

$$\lambda = \frac{\sigma^2}{\sigma_\beta^2}$$

(c) Quando $\sigma_\beta^2 \rightarrow \infty$, a priori fica **difusa**: ela espalha massa por toda parte e não expressa preferência alguma por coeficientes pequenos. Em outras palavras, ela não afirma nada. Correspondentemente $\lambda \rightarrow 0$ e o Ridge degenera no MQO: os dados decidem sozinhos, com viés baixo e variância alta.

Quando $\sigma_\beta^2 \rightarrow 0$, a priori fica **concentrada em zero**: ela afirma, antes de ver dado nenhum, que os coeficientes são praticamente nulos. Correspondentemente $\lambda \rightarrow \infty$ e $\hat{\boldsymbol{\beta}} \rightarrow \mathbf{0}$: viés máximo, variância mínima.

Entre os dois extremos, a fórmula $\lambda = \sigma^2/\sigma_\beta^2$ diz uma coisa bem razoável: regulariza-se mais quando os *dados* são ruidosos (σ^2 grande) ou quando a *crença prévia* é firme (σ_β^2 pequeno). O λ é a razão entre duas incertezas, e escolhê-lo por validação cruzada é, nessa leitura, deixar os dados escolherem a priori que melhor prediz.

Critério de correção (sugestão)

(a) 0,8 pelo produto verossimilhança $\times$ priori; 0,8 por passar ao logaritmo e trocar máximo por mínimo corretamente. Ignorar as constantes de normalização não desconta, desde que o aluno justifique que não dependem de $\boldsymbol{\beta}$.

(b) 0,4 por eliminar o fator $1/(2\sigma^2)$ sem alterar o argmin; 0,6 pelo valor de λ . Chegar a λ invertido (σ_β^2/σ^2) vale 0,3 dos 0,6.

(c) 0,7 por extremo. Exige ligar priori e λ , não apenas descrever o comportamento do Ridge. Mencionar o par viés-variância é esperado, mas não obrigatório para a nota cheia.

Questão 2 — Duas fórmulas da validação cruzada

(4,0 pontos)

Quem estuda validação cruzada pelas notas de aula e pelo ISLP encontra duas fórmulas diferentes para a mesma quantia, e é natural desconfiar de que uma delas esteja errada. Não está: elas só diferem na unidade que cada uma pondera igualmente.

As notas de aula definem

$$\hat{R}_{k-CV} = \frac{1}{n} \sum_{j=1}^k \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2,$$

e o ISLP define $CV_{(k)} = \frac{1}{k} \sum_{j=1}^k \text{EQM}_j$, com $\text{EQM}_j = \frac{1}{|L_j|} \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2$.

(a) (1,2) Reescreva a fórmula da aula de modo a fazer os EQM_j aparecerem, mostrando que

$$\hat{R}_{k-CV} = \sum_{j=1}^k \frac{|L_j|}{n} \text{EQM}_j.$$

(b) (0,8) Olhando para os pesos que você obteve, diga em que condição as duas definições coincidem — e se coincidem exatamente ou apenas aproximadamente. Em seguida, nomeie a unidade que cada fórmula pondera igualmente.

- (c) **(0,7)** Com $n = 50$ e $k = 7$, as dobras não podem ter todas o mesmo tamanho; suponha que tenham tamanhos 8, 8, 7, 7, 7, 7, 6. Confirme que somam 50 e explique por que, neste caso, os dois números diferem.
- (d) **(1,3)** Suponha que a dobra de 6 observações tenha $EQM = 10$ e todas as outras tenham $EQM = 1$. Calcule os dois estimadores, diga qual deles dá mais peso à dobra atípica, e qual você reportaria. Justifique a escolha.

Solução

(a) A chave é reconhecer a soma interna. Pela definição de EQM_j , basta multiplicar dos dois lados por $|L_j|$:

$$\sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2 = |L_j| EQM_j.$$

Substituindo na fórmula da aula,

$$\hat{R}_{k-CV} = \frac{1}{n} \sum_{j=1}^k |L_j| EQM_j = \sum_{j=1}^k \frac{|L_j|}{n} EQM_j.$$

São os *mesmos* EQM_j do ISLP, numa média ponderada. E os pesos somam 1, porque as dobras particionam as n observações: $\sum_j |L_j| = n$.

(b) Se k divide n , todas as dobras têm o mesmo tamanho $|L_j| = n/k$, e cada peso vale $(n/k)/n = 1/k$. A média ponderada vira média simples — que é exatamente a definição do ISLP.

E coincidem **exatamente**, não aproximadamente: é a mesma soma dos mesmos números com os mesmos pesos.

Quanto à unidade, a diferença é essa: a fórmula da aula pondera igualmente cada **observação**, e a do ISLP pondera igualmente cada **dobra**.

(c) $8 + 8 + 7 + 7 + 7 + 7 + 6 = 50$.

Diferem porque os tamanhos não são todos iguais. Os pesos da fórmula da aula valem $8/50$, $8/50$, $7/50$ (quatro vezes) e $6/50$, enquanto a do ISLP usa $1/7$ para todas as sete. O efeito concreto é sobre as observações individuais: uma que caiu na dobra de 6 recebe, na conta do ISLP, peso maior do que uma que caiu na dobra de 8 — porque ela divide a responsabilidade da sua dobra com menos gente.

(d) Pela fórmula da aula, a dobra atípica entra com peso $6/50$ e as outras 44 observações com $44/50$:

$$\hat{R}_{k-CV} = \frac{6}{50} \times 10 + \frac{44}{50} \times 1 = \frac{60 + 44}{50} = \frac{104}{50} = \mathbf{2,08}.$$

Pela do ISLP, a dobra atípica é uma das sete, e só:

$$CV_{(7)} = \frac{1}{7}(10 + 6 \times 1) = \frac{16}{7} \approx \mathbf{2,286}.$$

A do ISLP dá mais peso à dobra atípica — e é fácil ver por quê: ela é a *menor* dobra e ainda assim vale $1/7 \approx 0,143$ do total, contra $6/50 = 0,12$ na outra conta. Justamente por ter menos observações, cada uma delas pesa mais.

Qual reportar? Para *estimar o risco*, a fórmula da aula é a mais defensável: a unidade amostral é a observação, não a dobra, e não há razão para uma observação valer mais por acaso de agrupamento. Na prática, porém, o `scikit-learn` segue o ISLP — `cross_val_score(...).mean()` é média não ponderada — então o essencial é *saber qual das duas o seu código está calculando* antes de comparar com o de outra pessoa.

E a recomendação da aula encerra a discussão pela raiz: com n pequeno, escolha um k que divida n . Aí as duas coincidem e a pergunta não se coloca.

Critério de correção (sugestão)

- (a) 0,6 por reconhecer que $\sum_{i \in L_j} (\cdot)^2 = |L_j| \text{EQM}_j$; 0,6 pela substituição e pela forma final. Observar que os pesos somam 1 é bônus.
- (b) 0,5 pela igualdade dos pesos quando k divide n ; 0,3 por nomear as duas unidades (observação $\times$ dobra). Responder "aproximadamente iguais" perde 0,2 — a igualdade é exata.
- (c) 0,2 pela soma; 0,5 pela explicação dos pesos desiguais. Basta o argumento; não é preciso calcular os sete pesos.
- (d) 0,45 por cada valor correto (2,08 e $\approx 2,286$); 0,1 por dizer que a do ISLP dá mais peso à dobra atípica; 0,3 pela justificativa da escolha. Aceitar tanto a defesa da fórmula ponderada quanto a da não ponderada, desde que argumentada; **não** aceitar resposta que ignore a existência das duas.

Questão 3**(4,0 pontos)**

Um colega recebeu um banco de dados em que a coluna **renda** está em reais e a coluna **altura** em metros, e pergunta se precisa padronizar antes de ajustar. A resposta honesta é "depende do método" — e o critério que decide cabe numa pergunta: **o método soma coisas vindas de colunas diferentes?**

Se soma, as unidades precisam ser comparáveis, e trocar uma delas estraga a comparação. Se não soma, a unidade é irrelevante.

- (a) **(2,0 — 0,4 cada)** Para cada método abaixo, diga se multiplicar uma única coluna por 1000 **muda** ou **não muda** a predição, justificando em uma linha onde está — ou onde não está — a soma sobre colunas.
- (i) Mínimos quadrados ordinários.
 - (ii) Regressão Ridge com $\lambda > 0$ fixo.
 - (iii) Árvore de regressão.
 - (iv) Floresta aleatória.
 - (v) KNN com k fixo.
- (b) **(0,9)** Entre os que mudam, qual você espera que seja o mais afetado, e por quê? Compare o *modo* como a escala entra em cada um.
- (c) **(1,1)** Outro colega ajustou o Lasso a dados padronizados, com λ escolhido por validação cruzada. Em seguida multiplicou por 1000 a coluna de maior efeito sobre Y , reajustou com o *mesmo* λ , e o erro quadrático médio no conjunto de teste *diminuiu*. Ele conclui que é melhor não padronizar. Explique por que a reescala pode ter ajudado e por que a conclusão não se sustenta.

Solução

- (a) Só dois mudam, o Ridge e o KNN: os dois que somam coisas vindas de colunas diferentes.
- (i) **Não muda.** O MQO é equivariante: o coeficiente da coluna se divide por 1000 e o produto $\beta_j x_j$ fica igual. Nada na função-objetivo compara coeficientes entre si.
 - (ii) **Muda.** A penalidade $\lambda \sum_j \beta_j^2$ soma coeficientes de colunas diferentes; mudar a unidade de uma delas muda quanto ela pesa nessa soma.
 - (iii) **Não muda.** A árvore só pergunta " $x_j \leq t$ ". O corte t é multiplicado junto, e a pergunta separa exatamente as mesmas observações.
 - (iv) **Não muda.** É uma média de árvores, e cada uma é indiferente; a indiferença atravessa a agregação.
 - (v) **Muda.** A distância euclidiana $\sum_j (x_{ij} - x_{\ell j})^2$ é uma soma sobre colunas.
- (b) O KNN. A diferença não está no tamanho do fator — nos dois métodos ele chega a 10^6 —, e sim no que a escala controla em cada um.

No Ridge, a escala mexe só no *quanto* um coeficiente é penalizado. O coeficiente que produz o mesmo ajuste fica 1000 vezes menor, e o termo dele na penalidade $\lambda \sum_j \beta_j^2$, 10^6 vezes menor: a coluna fica praticamente livre do encolhimento. Mas o ajuste continua usando todas as colunas, e o pior que pode acontecer é aquele coeficiente deixar de ser encolhido — uma mudança limitada, que desaparece quando $\lambda \rightarrow 0$, porque aí o Ridge vira o MQO, que não muda.

No KNN, a escala mexe em *quem* entra na média. As diferenças na coluna reescalada são multiplicadas por 1000, e a contribuição delas para $\sum_j (x_{ij} - x_{\ell j})^2$, por 10^6 . A coluna passa a decidir sozinha quem é vizinho de quem, e as demais não ficam apenas menos importantes — somem da conta, e o método deixa de usar a informação que carregavam.

(c) Primeiro, por que a reescala pode ter ajudado. Multiplicar a coluna por 1000 faz o coeficiente que produz o mesmo ajuste ficar 1000 vezes menor, e um coeficiente minúsculo quase não pesa em $\lambda \sum_j |\beta_j|$: a coluna ficou praticamente isenta da penalidade. Como era a de maior efeito, o Lasso deixou de encolher justamente o coeficiente que mais importa. E encolher um coeficiente grande é quase só viés. No caso ortonormal, o Lasso subtrai $\lambda/2$ de todo coeficiente que sobrevive, um deslocamento que não reduz variância nenhuma. Tirar esse viés pode baixar o erro de teste — pode, não precisa: nem nesse caso favorável a melhora é garantida.

A conclusão, porém, não se sustenta, porque o resultado dependeu de *qual* coluna foi reescalada. Aplique a mesma reescala a uma coluna *irrelevante* e o efeito tende a se inverter: ela ganha liberdade para receber um coeficiente grande sem pagar por isso, e o ajuste passa a acompanhar ruído.

O ponto de fundo é que, nos dois casos, quem decidiu quanto regularizar cada coluna não foi o analista: foi a **unidade de medida** em que o dado chegou. E é por isso que o argumento do colega não se salva nem quando o resultado o favorece — um procedimento cujo desempenho depende de a coluna ter sido anotada em metros ou em milímetros está fora de controle, e ter dado certo desta vez não muda isso.

Critério de correção (sugestão)

- (a) 0,2 pelo veredito e 0,2 pela justificativa, em cada um dos cinco itens. Veredito certo com justificativa ausente ou errada vale 0,2. Aceitar "equivariante" sem demonstração em (i).
- (b) 0,3 por apontar o KNN; 0,6 por comparar o que a escala controla em cada um: no Ridge, quanto um coeficiente é penalizado; no KNN, quem são os vizinhos, com as outras colunas saindo da conta. Dizer apenas que a escala entra ao quadrado na distância vale 0,2 desses 0,6, porque ela também entra ao quadrado na penalidade do Ridge. Responder "Ridge" com bom argumento vale 0,4.
- (c) 0,5 pelo mecanismo: o coeficiente da coluna reescalada fica 1000 vezes menor e escapa quase inteiramente da penalidade, de modo que a coluna mais importante deixa de ser encolhida. 0,6 por explicar por que a conclusão não se sustenta: numa coluna irrelevante o efeito tende a se inverter. A observação de que foi a unidade de medida que tomou a decisão é o ponto alto da resposta e deve ser premiada dentro dos 0,6; aceitar também, como parte deles, o argumento de que um resultado favorável isolado não valida o procedimento.

Boa prova!