Avaliação Teórica 02 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Atenção

Documento do professor. As resoluções indicam o *esperado*; argumentos equivalentes e corretos devem ser aceitos integralmente. Os pesos por item somam o valor da questão.

Questão 1 **(4,0 pontos)**

Diego é analista antifraude num banco e tem dois sistemas que já foram avaliados, A e B. Tome a fraude como a classe positiva, $Y = 1$. As taxas de falsos positivos e de verdadeiros positivos são $(\mathrm{FPR}, \mathrm{TPR}) = (0{,}02;\ 0{,}50)$ para A e $(0{,}08;\ 0{,}80)$ para B. O banco aceita mandar para revisão manual no máximo 5% das transações legítimas, e nenhum dos dois sistemas aproveita esse limite: A fica abaixo dele e B o ultrapassa. Diego então propõe sortear: para cada transação, uma moeda com probabilidade λ de dar cara, lançada independentemente de tudo o mais, escolhe se a decisão será a de A (cara) ou a de B (coroa). Seja g_λ esse classificador.

(a) **(1,6)** Mostre que $\mathrm{FPR}(g_\lambda) = \lambda\,\mathrm{FPR}(A) + (1-\lambda)\,\mathrm{FPR}(B)$ e que o mesmo vale para a TPR, isto é, que o ponto de g_λ no plano (FPR, TPR) está no segmento que liga os pontos de A e de B. Determine λ para que a taxa de falsos positivos seja exatamente 0,05 e calcule a taxa de verdadeiros positivos obtida. Que classificadores sorteados dão os pontos da diagonal?

(b) **(1,2)** Um terceiro sistema, C, tem $(\mathrm{FPR}, \mathrm{TPR}) = (0{,}70;\ 0{,}40)$. Mostre que o classificador que inverte todas as decisões de C tem o ponto $(0{,}30;\ 0{,}60)$ e, em geral, que inverter as decisões leva $(\mathrm{FPR}, \mathrm{TPR})$ a $(1-\mathrm{FPR}, 1-\mathrm{TPR})$. Se um escore tem curva ROC abaixo da diagonal, com área $\mathrm{AUC} < 1/2$, qual é a curva e qual é a área do escore com o sinal trocado?

(c) **(1,2)** Com custos ℓ_0 por falso negativo e ℓ_1 por falso positivo, o custo esperado de um classificador g é $R_\ell(g) = \ell_1 \mathbb{P}(g(\boldsymbol{X}) = 1, Y = 0) + \ell_0 \mathbb{P}(g(\boldsymbol{X}) = 0, Y = 1)$. Mostre que $R_\ell(g_\lambda) = \lambda R_\ell(A) + (1-\lambda) R_\ell(B)$ e conclua que, sem a restrição do banco, sortear nunca custa menos que o melhor dos dois sistemas. Para que serve, então, o sorteio?

Solução

(a) Seja Z a moeda, com $\mathbb{P}(Z = 1) = \lambda$, independente de $(\boldsymbol{X}, Y)$. Pela lei da probabilidade total, condicionando em Z,

$$\begin{aligned}\mathbb{P}(g_\lambda(\boldsymbol{X}) = 1 \mid Y = 0) = \lambda\,&\mathbb{P}(g_A(\boldsymbol{X}) = 1 \mid Y = 0,\, Z = 1) \\ &+ (1-\lambda)\,\mathbb{P}(g_B(\boldsymbol{X}) = 1 \mid Y = 0,\, Z = 0),\end{aligned}$$

em que se usou $\mathbb{P}(Z = 1 \mid Y = 0) = \mathbb{P}(Z = 1) = \lambda$, pela independência. Também pela independência, condicionar em Z não altera a distribuição de $\boldsymbol{X}$ dado Y, e as duas probabilidades condicionais são as taxas de falsos positivos de A e de B. Assim, $\mathrm{FPR}(g_\lambda) = \lambda\,\mathrm{FPR}(A) + (1-\lambda)\,\mathrm{FPR}(B)$, e a mesma conta, condicionando em $Y = 1$, dá a TPR. O ponto de g_λ é a combinação convexa dos pontos de A e de B com pesos λ e $1-\lambda$, e percorre o segmento entre eles quando λ vai de 0 a 1.
Para a taxa de falsos positivos valer 0,05,

$$0{,}02\,\lambda + 0{,}08\,(1-\lambda) = 0{,}05 \iff 0{,}06\,\lambda = 0{,}03 \iff \lambda = \tfrac{1}{2},$$

e a taxa de verdadeiros positivos é $\frac{1}{2}\cdot 0{,}50 + \frac{1}{2}\cdot 0{,}80 = 0{,}65$: Diego usa o limite do banco inteiro e detecta 65% das fraudes, contra 50% de A. A diagonal vem do sorteio entre os dois classificadores triviais, $g \equiv 0$, no ponto $(0,0)$, e $g \equiv 1$, no ponto $(1,1)$: sortear $g = 1$ com probabilidade q dá o ponto (q,q).

(b) Se $g' = 1 - g$, então $g'(\boldsymbol{X}) = 1$ exatamente quando $g(\boldsymbol{X}) = 0$, e

$$\mathrm{TPR}(g') = \mathbb{P}(g(\boldsymbol{X}) = 0 \mid Y = 1) = 1 - \mathrm{TPR}(g), \qquad \mathrm{FPR}(g') = 1 - \mathrm{FPR}(g).$$

Para C, o ponto invertido é $(1 - 0{,}70;\ 1 - 0{,}40) = (0{,}30;\ 0{,}60)$, acima da diagonal: um sistema que erra sistematicamente carrega informação, desde que se faça o contrário do que ele diz. A aplicação $(a,b) \mapsto (1-a, 1-b)$ é a simetria em relação ao ponto $(\frac{1}{2}, \frac{1}{2})$. Trocar o sinal do escore troca "escore acima do corte" por "escore abaixo do corte", o que inverte as decisões em cada corte; a curva do escore com o sinal trocado é, portanto, a simétrica da original em relação a $(\frac{1}{2}, \frac{1}{2})$. Essa simetria leva a região do quadrado unitário abaixo de uma curva na região acima da curva simétrica e preserva áreas. A área sob a curva nova é, então, a área acima da curva antiga, $1 - \mathrm{AUC} > 1/2$.

(c) Condicionando de novo na moeda, e usando a independência,

$$\mathbb{P}(g_\lambda(\boldsymbol{X}) = 1,\, Y = 0) = \lambda\,\mathbb{P}(g_A(\boldsymbol{X}) = 1,\, Y = 0) + (1-\lambda)\,\mathbb{P}(g_B(\boldsymbol{X}) = 1,\, Y = 0),$$

e o mesmo para $\mathbb{P}(g_\lambda(\boldsymbol{X}) = 0,\, Y = 1)$. Multiplicando a primeira igualdade por ℓ_1, a segunda por ℓ_0 e somando, $R_\ell(g_\lambda) = \lambda R_\ell(A) + (1-\lambda) R_\ell(B)$. Uma média ponderada de dois números nunca é menor que o menor deles, e o sorteio nunca custa menos que o melhor dos dois sistemas: sem restrição, basta escolher um deles. O sorteio serve para atingir um ponto que nenhum dos dois atinge, como a taxa de falsos positivos de exatamente 0,05 permitida pelo banco: respeitando esse limite, $g_{1/2}$ detecta 65% das fraudes, e A, só 50%.

Critério de correção (sugestão)

(a) 0,8 pela fórmula da FPR: 0,4 por condicionar na moeda, com $\mathbb{P}(Z = 1 \mid Y = 0) = \lambda$, e 0,4 por justificar, pela independência, que as duas probabilidades condicionais são as taxas de falsos positivos de A e de B. Afirmar a combinação convexa sem usar a independência vale 0,3 desses 0,8, e a TPR, que sai da mesma conta, não precisa ser refeita. 0,5 pelos números: 0,3 por $\lambda = 1/2$ e 0,2 pela TPR de 0,65. 0,3 pela diagonal: sortear entre $g \equiv 0$ e $g \equiv 1$, isto é, declarar positivo com probabilidade q sem olhar $\boldsymbol{x}$, dá o ponto (q,q).
(b) 0,3 pelo ponto $(0{,}30;\ 0{,}60)$; 0,4 pelo caso geral, $\mathrm{TPR}(1-g) = 1 - \mathrm{TPR}(g)$ e o mesmo para a FPR; 0,5 pelo escore com o sinal trocado, 0,25 pela curva, a simétrica da original em relação a $(\frac{1}{2}, \frac{1}{2})$, e 0,25 pela área, $1 - \mathrm{AUC} > 1/2$. Aceitar a área justificada pela simetria ou pela área acima da curva original; não é exigido tratar empates entre escores.
(c) 0,5 pela linearidade do custo esperado, que repete a conta do item (a) com as probabilidades conjuntas; remeter ao item (a) vale integralmente se ficar claro que a conta se faz para os dois tipos de erro e que os custos entram como constantes. 0,3 por concluir que uma média ponderada nunca é menor que o menor dos dois custos. 0,4 pela utilidade do sorteio: atingir uma taxa de falsos positivos que nenhum dos dois sistemas atinge, como os 0,05 permitidos pelo banco, com 65% das fraudes detectadas contra 50% de A. Dizer apenas que o sorteio combina os dois sistemas, sem a restrição do banco, vale 0,1 desses 0,4.

Questão 2 **(4,0 pontos)**

Júlia estuda matemática aplicada e lê nas notas que o *kernel* radial $k(\boldsymbol{x}, \boldsymbol{x}') = e^{-\gamma\|\boldsymbol{x}-\boldsymbol{x}'\|^2}$, com $\gamma > 0$, é um *kernel* em $\mathbb{R}^p$; e decide tentar demonstrar o resultado. Lembre que $k : \mathbb{R}^p \times \mathbb{R}^p \to \mathbb{R}$ é um *kernel* se existem um espaço de Hilbert $\mathcal{H}$ e uma função $\varphi : \mathbb{R}^p \to \mathcal{H}$ com $k(\boldsymbol{x}, \boldsymbol{x}') = \langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle_{\mathcal{H}}$ para todos $\boldsymbol{x}, \boldsymbol{x}'$, e que, pelo teorema visto em aula, isso acontece se e somente se

k é simétrica e, para todo $n \geq 1$ e quaisquer $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n \in \mathbb{R}^p$, a matriz $\left[k(\boldsymbol{x}_i, \boldsymbol{x}_j)\right]_{i,j=1}^n$ é positiva semidefinida. Use à vontade que o produto interno $\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$ e as funções constantes iguais a $c \geq 0$ são *kernels*, e que a soma de dois *kernels* e o produto de um *kernel* por uma constante $c \geq 0$ também são.

(a) **(1,6)** Mostre que, se k_1 e k_2 são *kernels*, o produto $k(\boldsymbol{x}, \boldsymbol{x}') = k_1(\boldsymbol{x}, \boldsymbol{x}')\, k_2(\boldsymbol{x}, \boldsymbol{x}')$ também é. (Escreva uma das duas matrizes pela decomposição espectral.)

(b) **(1,3)** Mostre que, se k é um *kernel* e $h : \mathbb{R}^p \to \mathbb{R}$ é uma função qualquer, então $h(\boldsymbol{x})\, h(\boldsymbol{x}')\, k(\boldsymbol{x}, \boldsymbol{x}')$ é um *kernel*. Mostre também que $e^{k(\boldsymbol{x}, \boldsymbol{x}')}$ é um *kernel*, usando a série da exponencial e o fato de que um limite de matrizes positivas semidefinidas é positivo semidefinido.

(c) **(1,1)** Conclua que o *kernel* radial é um *kernel* em $\mathbb{R}^p$, para todo p e todo $\gamma > 0$. (Escreva $\|\boldsymbol{x} - \boldsymbol{x}'\|^2$ em termos de $\|\boldsymbol{x}\|^2$, $\|\boldsymbol{x}'\|^2$ e $\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$.)

Solução

(a) Sejam $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n \in \mathbb{R}^p$, $A = \left[k_1(\boldsymbol{x}_i, \boldsymbol{x}_j)\right]$ e $B = \left[k_2(\boldsymbol{x}_i, \boldsymbol{x}_j)\right]$, simétricas e positivas semidefinidas pelo teorema. A matriz de k nesses pontos é o produto entrada a entrada, $(A \circ B)_{ij} = A_{ij} B_{ij}$, que é simétrica. Pelo teorema espectral, $B = \sum_{m=1}^n \lambda_m \boldsymbol{v}_m \boldsymbol{v}_m^\top$, com autovalores $\lambda_m \geq 0$, porque B é positiva semidefinida, e autovetores ortonormais $\boldsymbol{v}_m \in \mathbb{R}^n$; em coordenadas, $B_{ij} = \sum_m \lambda_m v_{mi} v_{mj}$. Para $\boldsymbol{a} \in \mathbb{R}^n$,

$$\begin{aligned} \boldsymbol{a}^\top (A \circ B)\, \boldsymbol{a} &= \sum_{i,j} a_i a_j A_{ij} \sum_m \lambda_m v_{mi} v_{mj} = \sum_m \lambda_m \sum_{i,j} (a_i v_{mi})\, A_{ij}\, (a_j v_{mj}) \\ &= \sum_m \lambda_m\, \boldsymbol{u}_m^\top A\, \boldsymbol{u}_m \;\geq\; 0, \end{aligned}$$

em que $\boldsymbol{u}_m = (a_1 v_{m1}, \ldots, a_n v_{mn})$, e cada parcela é não negativa porque $\lambda_m \geq 0$ e A é positiva semidefinida. Como isso vale para todo n e quaisquer pontos, o teorema dá que $k_1 k_2$ é um *kernel*.

(b) A função $h(\boldsymbol{x}) h(\boldsymbol{x}') k(\boldsymbol{x}, \boldsymbol{x}')$ é simétrica, e a sua matriz nos pontos $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n$ é DKD, com $K = \left[k(\boldsymbol{x}_i, \boldsymbol{x}_j)\right]$ e $D = \operatorname{diag}\left(h(\boldsymbol{x}_1), \ldots, h(\boldsymbol{x}_n)\right)$. Para $\boldsymbol{a} \in \mathbb{R}^n$, $\boldsymbol{a}^\top DKD\, \boldsymbol{a} = (D\boldsymbol{a})^\top K (D\boldsymbol{a}) \geq 0$. (Pela definição, é o mesmo que tomar a função $h\varphi$ no lugar de φ.)
Para a exponencial, $e^{k(\boldsymbol{x}, \boldsymbol{x}')} = \sum_{m \geq 0} k(\boldsymbol{x}, \boldsymbol{x}')^m / m!$. A potência k^0 é a constante 1, que é um *kernel*, e, se k^m é um *kernel*, $k^{m+1} = k^m \cdot k$ também é, pelo item (a); por indução, todas as potências são *kernels*. As somas parciais $S_M = \sum_{m=0}^M k^m / m!$ são, então, *kernels*, como somas de *kernels* multiplicados por constantes positivas. Fixados os pontos e $\boldsymbol{a} \in \mathbb{R}^n$, cada número $\boldsymbol{a}^\top \left[S_M(\boldsymbol{x}_i, \boldsymbol{x}_j)\right] \boldsymbol{a}$ é não negativo, e, quando $M \to \infty$, converge para $\boldsymbol{a}^\top \left[e^{k(\boldsymbol{x}_i, \boldsymbol{x}_j)}\right] \boldsymbol{a}$, porque é uma soma finita de termos que convergem. Um limite de números não negativos é não negativo. A matriz de e^k é, portanto, positiva semidefinida, e e^k, que é simétrica, é um *kernel*.

(c) Como $\|\boldsymbol{x} - \boldsymbol{x}'\|^2 = \|\boldsymbol{x}\|^2 - 2\langle \boldsymbol{x}, \boldsymbol{x}' \rangle + \|\boldsymbol{x}'\|^2$,

$$e^{-\gamma \|\boldsymbol{x} - \boldsymbol{x}'\|^2} = e^{-\gamma \|\boldsymbol{x}\|^2}\, e^{-\gamma \|\boldsymbol{x}'\|^2}\, e^{2\gamma \langle \boldsymbol{x}, \boldsymbol{x}' \rangle}.$$

O produto interno é um *kernel*, e $2\gamma \langle \boldsymbol{x}, \boldsymbol{x}' \rangle$ também, porque $2\gamma > 0$. Pelo item (b), $e^{2\gamma \langle \boldsymbol{x}, \boldsymbol{x}' \rangle}$ é um *kernel*, e, ainda pelo item (b), com $h(\boldsymbol{x}) = e^{-\gamma \|\boldsymbol{x}\|^2}$, o produto acima é um *kernel*. O argumento vale para todo p e todo $\gamma > 0$, e não precisa exibir φ; com $p = 1$, expandir $e^{2\gamma x x'}$ em série reproduz a função φ do exemplo das notas.

Critério de correção (sugestão)

(a) 0,2 pela simetria de $A \circ B$; 0,4 pela decomposição espectral de B, com autovalores não negativos porque B é positiva semidefinida; 0,6 por reescrever $\boldsymbol{a}^\top (A \circ B)\, \boldsymbol{a}$ como $\sum_m \lambda_m \, \boldsymbol{u}_m^\top A \, \boldsymbol{u}_m$; 0,4 pela conclusão, parcela a parcela, e pelo teorema, porque a conta vale para todo n e quaisquer pontos. Aceitar integralmente uma prova correta por outro caminho, como a construção de uma função φ para o produto. Citar o teorema do produto de Schur sem demonstrá-lo vale 0,4 do item.
(b) 0,5 por $h(\boldsymbol{x})h(\boldsymbol{x}')k(\boldsymbol{x}, \boldsymbol{x}')$: a simetria e a matriz DKD, com $\boldsymbol{a}^\top DKD\, \boldsymbol{a} = (D\boldsymbol{a})^\top K (D\boldsymbol{a}) \geq 0$, ou a função $h\varphi$ no lugar de φ. 0,8 pela exponencial: 0,3 pelas potências, por indução e pelo item (a); 0,2 pelas somas parciais, combinações de *kernels* com coeficientes positivos; 0,3 pela passagem ao limite, com os pontos e $\boldsymbol{a}$ fixados. Afirmar que um limite de *kernels* é um *kernel* sem dizer em que sentido vale 0,1 desses 0,3.
(c) 0,3 pela fatoração $e^{-\gamma \|\boldsymbol{x}-\boldsymbol{x}'\|^2} = e^{-\gamma\|\boldsymbol{x}\|^2} e^{-\gamma\|\boldsymbol{x}'\|^2} e^{2\gamma\langle \boldsymbol{x}, \boldsymbol{x}'\rangle}$; 0,4 por $e^{2\gamma\langle \boldsymbol{x}, \boldsymbol{x}'\rangle}$ ser um *kernel*, porque $2\gamma\,\langle \boldsymbol{x}, \boldsymbol{x}'\rangle$ é um múltiplo positivo do produto interno e pelo item (b); 0,4 pelo item (b) com $h(\boldsymbol{x}) = e^{-\gamma\|\boldsymbol{x}\|^2}$ e pela observação de que o argumento não depende de p nem do valor de $\gamma > 0$. Usar os itens (a) e (b) sem tê-los demonstrado não desconta neste item.

Questão 3 **(4,0 pontos)**

Ana é bióloga e usa uma árvore de classificação para distinguir mudas de duas espécies, a espécie 1 e a espécie 0, a partir de características medidas no viveiro. Num nó com 12 mudas, 6 de cada espécie, a árvore compara duas divisões:

A pela altura, separa dois grupos de 6 mudas, um com 2 da espécie 1 e 4 da espécie 0 e outro com 4 da espécie 1 e 2 da espécie 0;

B por uma mancha rara na folha, isola uma única muda, da espécie 0, das outras 11, que têm 6 da espécie 1 e 5 da espécie 0.

Numa região com proporção p de mudas da espécie 1, o índice de Gini é $G(p) = 2p(1-p)$, a entropia é $D(p) = -p \log_2 p - (1-p)\log_2(1-p)$, com $0 \log_2 0 = 0$, e o erro de classificação é $E(p) = \min(p, 1-p)$. Uma divisão em regiões com n_1 e n_2 mudas e proporções p_1 e p_2 tem impureza ponderada $[n_1 I(p_1) + n_2 I(p_2)]/(n_1 + n_2)$, para cada medida I, e a árvore escolhe a divisão de menor impureza ponderada.

(a) **(2,0)** Calcule a impureza ponderada das divisões A e B pelas três medidas e diga qual divisão cada medida escolhe. *Dados:* $\log_2 3 \approx 1{,}5850$, $\log_2 5 \approx 2{,}3219$ e $\log_2 11 \approx 3{,}4594$.

(b) **(2,0)** Seja I uma medida de impureza qualquer para duas classes, com $I(p) = I(1-p)$, $I(0) = 0$ e $I(6/11) > 0$. Mostre que A tem impureza ponderada menor que B se e somente se $I(1/3)/I(6/11) < 11/12$. Calcule essa razão para as três medidas e explique que propriedade da curva da entropia a leva a escolher B.

Solução

(a) Na divisão A, as proporções da espécie 1 são 1/3 e 2/3, cada uma num filho com metade das mudas. Na divisão B, são 0, numa muda, e 6/11, nas outras 11. Pelo Gini,

A: $\frac{1}{2}\cdot 2 \cdot \frac{1}{3}\cdot\frac{2}{3} + \frac{1}{2}\cdot 2 \cdot \frac{2}{3}\cdot\frac{1}{3} = \frac{4}{9} \approx 0{,}444$, B: $\frac{1}{12}\cdot 0 + \frac{11}{12}\cdot 2 \cdot \frac{6}{11}\cdot\frac{5}{11} = \frac{5}{11} \approx 0{,}455$.

Pela entropia, como $D(1/3) = D(2/3) = \frac{1}{3}\log_2 3 + \frac{2}{3}\log_2 \frac{3}{2} = \log_2 3 - \frac{2}{3}$,

A: $\log_2 3 - \frac{2}{3} \approx 0{,}918$,

B: $\frac{11}{12} D\left(\frac{6}{11}\right) = \frac{1}{12}\left(6 \log_2 \frac{11}{6} + 5 \log_2 \frac{11}{5}\right) = \frac{1}{12}(11 \log_2 11 - 6\log_2 6 - 5 \log_2 5) \approx 0{,}911$,

com $\log_2 6 = 1 + \log_2 3$. Pelo erro de classificação, A erra 2 mudas em cada filho, $4/12 = 1/3$, e B erra as 5 mudas da espécie 0 no filho grande, $5/12 \approx 0{,}417$. O Gini e o erro escolhem

A; a entropia escolhe B. O nó tem $G = 0{,}5$ e $D = 1$, e as reduções correspondentes são 0,056 (A) e 0,045 (B) no Gini, e 0,082 (A) e 0,089 (B) na entropia.

(b) Pela simetria, a impureza ponderada de A é $\frac{1}{2}I(1/3) + \frac{1}{2}I(2/3) = I(1/3)$, e a de B é $\frac{1}{12}I(0) + \frac{11}{12}I(6/11) = \frac{11}{12}I(6/11)$. Como $I(6/11) > 0$,

$$I\left(\tfrac{1}{3}\right) < \tfrac{11}{12}\, I\left(\tfrac{6}{11}\right) \iff \frac{I(1/3)}{I(6/11)} < \frac{11}{12} \approx 0{,}917.$$

As razões são $(4/9)/(60/121) = 121/135 \approx 0{,}896$ para o Gini, $0{,}918/0{,}994 \approx 0{,}924$ para a entropia e $(1/3)/(5/11) = 11/15 \approx 0{,}733$ para o erro: só a entropia passa de 11/12.

A comparação tem uma leitura simples. A divisão A leva os dois filhos da proporção 1/2 à proporção 1/3; a divisão B torna pura 1/12 das mudas e deixa as outras numa região quase tão misturada quanto o nó, porque $6/11 \approx 0{,}545$ está perto de 1/2. Com $I(6/11) \approx I(1/2)$, a pergunta é, em essência, se $I(1/3)$ fica abaixo de 11/12 do máximo: $G(1/3)/G(1/2) = 8/9 \approx 0{,}889$, mas $D(1/3)/D(1/2) \approx 0{,}918$. A entropia é mais achatada perto do máximo: trata uma região com um terço de uma espécie como quase tão impura quanto uma equilibrada, e por isso dá pouco valor à purificação parcial de A e, em comparação, mais valor à purificação completa de um pedaço pequeno, que é o que B faz.

Critério de correção (sugestão)

(a) 0,5 pelo Gini, $4/9 \approx 0{,}444$ em A e $5/11 \approx 0{,}455$ em B; 0,8 pela entropia, 0,4 por divisão, $\log_2 3 - 2/3 \approx 0{,}918$ em A e cerca de 0,911 em B; 0,4 pelo erro de classificação, 1/3 em A e 5/12 em B; 0,3 pelas escolhas: o Gini e o erro escolhem A, e a entropia escolhe B. Aceitar desvios de até 0,002 nos valores da entropia, que dependem dos logaritmos dados, e impurezas sem a divisão por 12, que não mudam a comparação. Uma conta errada que inverta a escolha da entropia perde os pontos dessa conta e dessa escolha, mas não os das outras medidas.

(b) 0,5 por escrever as impurezas ponderadas como $I(1/3)$ e $\frac{11}{12}I(6/11)$, usando a simetria e $I(0) = 0$; 0,3 pela equivalência, dividindo por $I(6/11) > 0$; 0,6 pelas três razões, 0,2 cada ($121/135 \approx 0{,}896$ no Gini, cerca de 0,924 na entropia e $11/15 \approx 0{,}733$ no erro), com a conclusão de que só a da entropia passa de 11/12; 0,6 pela explicação: perto de $p = 1/2$ a entropia é mais achatada que o Gini ($D(1/3)/D(1/2) \approx 0{,}918$, contra $G(1/3)/G(1/2) = 8/9$), e por isso dá pouco valor à purificação parcial de A diante da purificação completa de uma única muda em B. Dizer apenas que as curvas têm formas diferentes, sem ligar a forma aos valores em 1/3 e perto de 1/2, vale 0,2 desses 0,6.

Boa prova!