Avaliação Teórica 02

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Instruções.

- Duração: **2 horas**. Prova individual e sem consulta.
- A prova vale **12,0 pontos**; o valor de cada item está indicado ao lado.
- **Justifique todas as respostas.**
- Notação: $(\boldsymbol{X}, Y)$ é um vetor aleatório com $\boldsymbol{X} \in \mathbb{R}^p$ e Y num conjunto finito $\mathcal{C}$ de classes; no caso binário, $\mathcal{C} = \{0, 1\}$, a classe $Y = 1$ é a positiva e $\eta(\boldsymbol{x}) = \mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x})$; $\mathcal{D} = \{(\boldsymbol{X}_i, Y_i)\}_{i=1}^n$ é a amostra de treino, i.i.d.; a perda é a 0–1, com risco $R(g) = \mathbb{P}\big(Y \neq g(\boldsymbol{X})\big)$, salvo indicação em contrário.

Questão 1 (4,0 pontos)

Diego é analista antifraude num banco e tem dois sistemas que já foram avaliados, A e B. Tome a fraude como a classe positiva, $Y = 1$. As taxas de falsos positivos e de verdadeiros positivos são $(\mathrm{FPR}, \mathrm{TPR}) = (0{,}02;\ 0{,}50)$ para A e $(0{,}08;\ 0{,}80)$ para B. O banco aceita mandar para revisão manual no máximo 5% das transações legítimas, e nenhum dos dois sistemas aproveita esse limite: A fica abaixo dele e B o ultrapassa. Diego então propõe sortear: para cada transação, uma moeda com probabilidade λ de dar cara, lançada independentemente de tudo o mais, escolhe se a decisão será a de A (cara) ou a de B (coroa). Seja g_λ esse classificador.

(a) **(1,6)** Mostre que $\mathrm{FPR}(g_\lambda) = \lambda\,\mathrm{FPR}(A) + (1-\lambda)\,\mathrm{FPR}(B)$ e que o mesmo vale para a TPR, isto é, que o ponto de g_λ no plano (FPR, TPR) está no segmento que liga os pontos de A e de B. Determine λ para que a taxa de falsos positivos seja exatamente 0,05 e calcule a taxa de verdadeiros positivos obtida. Que classificadores sorteados dão os pontos da diagonal?

(b) **(1,2)** Um terceiro sistema, C, tem $(\mathrm{FPR}, \mathrm{TPR}) = (0{,}70;\ 0{,}40)$. Mostre que o classificador que inverte todas as decisões de C tem o ponto $(0{,}30;\ 0{,}60)$ e, em geral, que inverter as decisões leva $(\mathrm{FPR}, \mathrm{TPR})$ a $(1 - \mathrm{FPR}, 1 - \mathrm{TPR})$. Se um escore tem curva ROC abaixo da diagonal, com área $\mathrm{AUC} < 1/2$, qual é a curva e qual é a área do escore com o sinal trocado?

(c) **(1,2)** Com custos ℓ_0 por falso negativo e ℓ_1 por falso positivo, o custo esperado de um classificador g é $R_\ell(g) = \ell_1 \mathbb{P}(g(\boldsymbol{X}) = 1, Y = 0) + \ell_0 \mathbb{P}(g(\boldsymbol{X}) = 0, Y = 1)$. Mostre que $R_\ell(g_\lambda) = \lambda R_\ell(A) + (1-\lambda) R_\ell(B)$ e conclua que, sem a restrição do banco, sortear nunca custa menos que o melhor dos dois sistemas. Para que serve, então, o sorteio?

Questão 2 (4,0 pontos)

Júlia estuda matemática aplicada e lê nas notas que o *kernel* radial $k(\boldsymbol{x}, \boldsymbol{x}') = e^{-\gamma \|\boldsymbol{x} - \boldsymbol{x}'\|^2}$, com $\gamma > 0$, é um *kernel* em $\mathbb{R}^p$; e decide tentar demonstrar o resultado. Lembre que $k : \mathbb{R}^p \times \mathbb{R}^p \to \mathbb{R}$ é um *kernel* se existem um espaço de Hilbert $\mathcal{H}$ e uma função $\varphi : \mathbb{R}^p \to \mathcal{H}$ com $k(\boldsymbol{x}, \boldsymbol{x}') = \langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle_{\mathcal{H}}$ para todos $\boldsymbol{x}, \boldsymbol{x}'$, e que, pelo teorema visto em aula, isso acontece se e somente se k é simétrica e, para todo $n \geq 1$ e quaisquer $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n \in \mathbb{R}^p$, a matriz $\big[k(\boldsymbol{x}_i, \boldsymbol{x}_j)\big]_{i,j=1}^n$ é positiva semidefinida. Use à vontade que o produto interno $\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$ e as funções constantes iguais a $c \geq 0$ são *kernels*, e que a soma de dois *kernels* e o produto de um *kernel* por uma constante $c \geq 0$ também são.

(a) **(1,6)** Mostre que, se k_1 e k_2 são *kernels*, o produto $k(\boldsymbol{x}, \boldsymbol{x}') = k_1(\boldsymbol{x}, \boldsymbol{x}')\, k_2(\boldsymbol{x}, \boldsymbol{x}')$ também é. (Escreva uma das duas matrizes pela decomposição espectral.)

(b) **(1,3)** Mostre que, se k é um *kernel* e $h : \mathbb{R}^p \to \mathbb{R}$ é uma função qualquer, então $h(\boldsymbol{x})\, h(\boldsymbol{x}')\, k(\boldsymbol{x}, \boldsymbol{x}')$ é um *kernel*. Mostre também que $e^{k(\boldsymbol{x},\boldsymbol{x}')}$ é um *kernel*, usando a série da exponencial e o fato de que um limite de matrizes positivas semidefinidas é positivo semidefinido.

(c) **(1,1)** Conclua que o *kernel* radial é um *kernel* em $\mathbb{R}^p$, para todo p e todo $\gamma > 0$. (Escreva $\|\boldsymbol{x} - \boldsymbol{x}'\|^2$ em termos de $\|\boldsymbol{x}\|^2$, $\|\boldsymbol{x}'\|^2$ e $\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$.)

Questão 3 **(4,0 pontos)**

Ana é bióloga e usa uma árvore de classificação para distinguir mudas de duas espécies, a espécie 1 e a espécie 0, a partir de características medidas no viveiro. Num nó com 12 mudas, 6 de cada espécie, a árvore compara duas divisões:

A pela altura, separa dois grupos de 6 mudas, um com 2 da espécie 1 e 4 da espécie 0 e outro com 4 da espécie 1 e 2 da espécie 0;

B por uma mancha rara na folha, isola uma única muda, da espécie 0, das outras 11, que têm 6 da espécie 1 e 5 da espécie 0.

Numa região com proporção p de mudas da espécie 1, o índice de Gini é $G(p) = 2p(1-p)$, a entropia é $D(p) = -p \log_2 p - (1-p)\log_2(1-p)$, com $0 \log_2 0 = 0$, e o erro de classificação é $E(p) = \min(p, 1-p)$. Uma divisão em regiões com n_1 e n_2 mudas e proporções p_1 e p_2 tem impureza ponderada $[n_1 I(p_1) + n_2 I(p_2)]/(n_1 + n_2)$, para cada medida I, e a árvore escolhe a divisão de menor impureza ponderada.

(a) **(2,0)** Calcule a impureza ponderada das divisões A e B pelas três medidas e diga qual divisão cada medida escolhe. *Dados:* $\log_2 3 \approx 1{,}5850$, $\log_2 5 \approx 2{,}3219$ e $\log_2 11 \approx 3{,}4594$.

(b) **(2,0)** Seja I uma medida de impureza qualquer para duas classes, com $I(p) = I(1-p)$, $I(0) = 0$ e $I(6/11) > 0$. Mostre que A tem impureza ponderada menor que B se e somente se $I(1/3)/I(6/11) < 11/12$. Calcule essa razão para as três medidas e explique que propriedade da curva da entropia a leva a escolher B.

Boa prova!