

Lista de Revisão — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aulas 01 a 06 — Fundamentos, Regressão, Validação Cruzada, KNN, Árvores e Pipelines

Não há ordem obrigatória para a resolução, mas os exercícios de uma mesma aula se apoiam uns nos outros, ou em exercícios de listas anteriores.

Salvo indicação em contrário, $(\mathbf{X}, Y)$ é um vetor aleatório com distribuição P , $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ é a função de regressão, $\mathcal{D} = \{(\mathbf{X}_i, Y_i)\}_{i=1}^n$ é a amostra de treino (i.i.d.), p é o número de covariáveis e a perda é a quadrática.

Aula 01 — Introdução

Exercício 1 — O melhor preditor. No início do curso, vimos uma afirmação forte: de todas as funções que você poderia usar para prever Y a partir de $\mathbf{X}$, a melhor é a função de regressão $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$. Não a melhor entre as lineares, nem a melhor entre as que o seu método consegue produzir — a melhor, ponto.

Uma afirmação dessas pede demonstração, e ela é mais curta do que parece. Todo o trabalho está num truque que você vai reencontrar várias vezes no curso: somar e subtrair a quantidade certa dentro de um quadrado.

- (a) Seja $g : \mathbb{R}^p \rightarrow \mathbb{R}$ uma função qualquer com $\mathbb{E}[g(\mathbf{X})^2] < \infty$. Some e subtraia $r(\mathbf{X})$ dentro do quadrado e mostre que

$$\mathbb{E}[(Y - g(\mathbf{X}))^2] = \mathbb{E}[(Y - r(\mathbf{X}))^2] + \mathbb{E}[(r(\mathbf{X}) - g(\mathbf{X}))^2].$$

O trabalho está em mostrar que o termo cruzado desaparece; condicione em $\mathbf{X}$ e pergunte-se o que $\mathbb{E}[Y - r(\mathbf{X}) \mid \mathbf{X}]$ vale.

- (b) Olhe para a identidade que você acabou de provar e responda: por que ela mostra que r é o minimizador? Em seguida, mostre que o valor mínimo é $R(r) = \mathbb{E}[\text{Var}(Y \mid \mathbf{X})]$.
- (c) Esse mínimo tem nome: **erro irreduzível**. O nome sugere que não há como baixá-lo, e é verdade — mas a razão não é que os métodos atuais sejam ruins. Explique de onde vem essa impossibilidade, e diga o que teria de mudar *no problema* para o número diminuir.
- (d) Na Lista Teórica 01, mostramos que o melhor preditor *constante* tem risco $\text{Var}(Y)$. Use a identidade de (a) para escrever a diferença $\text{Var}(Y) - R(r)$ como uma esperança, e interprete: que pergunta prática essa quantidade responde?

Solução

Suponha, ao longo de todo o exercício, que $\mathbb{E}[Y^2] < \infty$: é o que garante que todas as esperanças abaixo existam. Em particular $r(\mathbf{X})$ também tem segundo momento finito, porque $\mathbb{E}[r(\mathbf{X})^2] = \mathbb{E}[(\mathbb{E}[Y \mid \mathbf{X}])^2] \leq \mathbb{E}[\mathbb{E}[Y^2 \mid \mathbf{X}]] = \mathbb{E}[Y^2]$ (desigualdade de Jensen, aplicada condicionalmente a $\mathbf{X}$).

- (a) Some e subtraia $r(\mathbf{X})$ e expanda o quadrado:

$$(Y - g(\mathbf{X}))^2 = (Y - r(\mathbf{X}))^2 + 2(Y - r(\mathbf{X}))(r(\mathbf{X}) - g(\mathbf{X})) + (r(\mathbf{X}) - g(\mathbf{X}))^2.$$

As três parcelas são integráveis: as duas quadráticas porque Y , $r(\mathbf{X})$ e $g(\mathbf{X})$ têm segundo

momento finito, e o termo cruzado pela desigualdade de Cauchy–Schwarz, $\mathbb{E}|UV| \leq \sqrt{\mathbb{E}[U^2]\mathbb{E}[V^2]}$. Podemos, então, tomar esperança termo a termo, e tudo se resume a mostrar que o termo cruzado tem esperança zero.

Condicione em $\mathbf{X}$ e use a lei da esperança total:

$$\begin{aligned}\mathbb{E}[(Y - r(\mathbf{X}))(r(\mathbf{X}) - g(\mathbf{X}))] &= \mathbb{E}\left[\mathbb{E}[(Y - r(\mathbf{X}))(r(\mathbf{X}) - g(\mathbf{X})) \mid \mathbf{X}]\right] \\ &= \mathbb{E}\left[(r(\mathbf{X}) - g(\mathbf{X})) \underbrace{\mathbb{E}[Y - r(\mathbf{X}) \mid \mathbf{X}]}_{= r(\mathbf{X}) - r(\mathbf{X}) = 0}\right] = 0.\end{aligned}$$

O passo do meio é a regra "o que é função de $\mathbf{X}$ sai da esperança condicional em $\mathbf{X}$ ": $r(\mathbf{X}) - g(\mathbf{X})$ depende só de $\mathbf{X}$, e condicionar em $\mathbf{X}$ é tratá-lo como conhecido. O zero vem da *definição* de r : $\mathbb{E}[Y \mid \mathbf{X}] = r(\mathbf{X})$.

Em palavras: o erro $Y - r(\mathbf{X})$ que sobra depois de acertar a média condicional é **ortogonal a toda função de $\mathbf{X}$** — nenhuma informação contida em $\mathbf{X}$ ajuda a prevê-lo. Guarde a frase: o Exercício 4 tem uma versão dela para as funções lineares.

(b) A identidade de (a) diz que

$$R(g) = \underbrace{R(r)}_{\text{não depende de } g} + \underbrace{\mathbb{E}[(r(\mathbf{X}) - g(\mathbf{X}))^2]}_{\geq 0}.$$

Logo $R(g) \geq R(r)$ para toda g : r é minimizadora. E é a única, a menos de probabilidade zero: a igualdade vale se e só se $\mathbb{E}[(r(\mathbf{X}) - g(\mathbf{X}))^2] = 0$, isto é, se $g(\mathbf{X}) = r(\mathbf{X})$ com probabilidade 1. (Alterar g num conjunto de valores de $\mathbf{x}$ que nunca ocorrem não muda risco nenhum.)

O valor mínimo sai de novo pela esperança total. Dado $\mathbf{X}$, $Y - r(\mathbf{X})$ é o desvio de Y em torno da sua própria média condicional, e a esperança condicional do seu quadrado é, por definição, a variância condicional:

$$R(r) = \mathbb{E}[(Y - \mathbb{E}[Y \mid \mathbf{X}])^2] = \mathbb{E}\left[\mathbb{E}[(Y - \mathbb{E}[Y \mid \mathbf{X}])^2 \mid \mathbf{X}]\right] = \mathbb{E}[\text{Var}(Y \mid \mathbf{X})].$$

(c) A impossibilidade é matemática, e não tecnológica. O item (b) mostrou que **nenhuma** função de $\mathbf{X}$ tem risco menor que $\mathbb{E}[\text{Var}(Y \mid \mathbf{X})]$ — nem mesmo r , conhecida exatamente, com $n = \infty$ e erro de estimação zero. E essa quantidade não menciona método nenhum: é uma propriedade da distribuição conjunta de $(\mathbf{X}, Y)$. Ela mede quanto Y ainda varia entre indivíduos com o mesmo $\mathbf{x}$. Dois pacientes com idade, peso e exames idênticos, mas desfechos diferentes, recebem forçosamente a mesma previsão, porque o preditor recebeu a mesma entrada nos dois casos.

Para baixar o número é preciso mudar o problema: **medir mais**. Se Z é uma covariável nova, a lei da variância total, aplicada condicionalmente a $\mathbf{X}$, dá

$$\mathbb{E}[\text{Var}(Y \mid \mathbf{X})] = \mathbb{E}[\text{Var}(Y \mid \mathbf{X}, Z)] + \mathbb{E}[\text{Var}(\mathbb{E}[Y \mid \mathbf{X}, Z] \mid \mathbf{X})] \geq \mathbb{E}[\text{Var}(Y \mid \mathbf{X}, Z)],$$

com igualdade só quando Z não muda a média condicional, $\mathbb{E}[Y \mid \mathbf{X}, Z] = \mathbb{E}[Y \mid \mathbf{X}]$. Acrescentar informação nunca aumenta o erro irreduzível, e o diminui sempre que a informação for relevante. Isso vale na população; com n finito, cada covariável nova também custa variância de estimação (Aula 02), de modo que medir mais é necessário, mas não suficiente, para prever melhor.

(d) Aplique a identidade de (a) com $g \equiv \mathbb{E}[Y]$. O lado esquerdo é o risco do melhor preditor constante, $\text{Var}(Y)$. E como $\mathbb{E}[r(\mathbf{X})] = \mathbb{E}[\mathbb{E}[Y \mid \mathbf{X}]] = \mathbb{E}[Y]$, pela esperança total, a última parcela é uma variância:

$$\text{Var}(Y) = R(r) + \mathbb{E}[(r(\mathbf{X}) - \mathbb{E}[r(\mathbf{X})])^2] \implies \boxed{\text{Var}(Y) - R(r) = \text{Var}(r(\mathbf{X}))}$$

É a lei da variância total, $\text{Var}(Y) = \mathbb{E}[\text{Var}(Y | \mathbf{X})] + \text{Var}(\mathbb{E}[Y | \mathbf{X}])$, obtida por outro caminho.

A pergunta que isso responde é: **vale a pena usar as covariáveis?** O lado esquerdo é o máximo que se pode ganhar trocando o preditor constante pelo melhor preditor possível; o direito diz que esse ganho é exatamente o quanto a resposta *esperada* muda de um perfil de covariáveis para outro. Dividido por $\text{Var}(Y)$, vira a fração da variância de Y que as covariáveis conseguem explicar no melhor dos casos: um R^2 populacional, teto para o R^2 de qualquer modelo.

Os dois extremos ajudam a fixar. Se $\text{Var}(r(\mathbf{X})) = 0$, a função de regressão é constante: as covariáveis não carregam informação sobre a média de Y , e prever pela média é o melhor que existe — não há modelo a construir. Se $R(r) = 0$, Y é função de $\mathbf{X}$, e toda a sua variância é explicável.

Exercício 2. A palavra "risco" apareceu durante o nosso curso com dois sentidos, e a diferença entre eles não é preciosismo: ela decide qual pergunta o seu número está respondendo.

Quando g é tratada como uma função *fixa*, a esperança em $\mathbb{E}[(Y - g(\mathbf{X}))^2]$ percorre só a observação nova $(\mathbf{X}, Y)$. Chamamos isso de **risco condicional**. Quando $g = \hat{g}$ é tratada como aleatória — e ela é, porque foi construída a partir de $\mathcal{D}$ —, a esperança percorre também as amostras de treino possíveis, e temos o **risco esperado**.

- (a) Cada um dos dois oferece uma garantia diferente. Descreva as duas, e diga qual interessa a quem já ajustou um modelo e vai colocá-lo em produção, e qual interessa a quem ainda está escolhendo entre diversos métodos.
- (b) Você separou um conjunto de teste de m observações que não participou de nenhum treinamento, e calculou $\hat{R}(\hat{g}) = \frac{1}{m} \sum_{k=1}^m W_k$, com $W_k = (Y_k - \hat{g}(\mathbf{X}_k))^2$. Qual dos dois riscos esse número estima? Para responder, pergunte-se o que está fixo e o que varia no momento em que você faz a conta.
- (c) Um conjunto de teste permite algo que a validação cruzada não permite: uma barra de erro honesta. Explique por que os W_k são i.i.d. e escreva o intervalo de confiança aproximado de 95% que o Teorema Central do Limite fornece.

Solução

Vale escrever os dois objetos antes de compará-los. Seja $\hat{g}$ o ajuste obtido a partir de $\mathcal{D}$, e $(\mathbf{X}, Y)$ uma observação nova, independente de $\mathcal{D}$. O **risco condicional** é

$$R(\hat{g}) = \mathbb{E}[(Y - \hat{g}(\mathbf{X}))^2 | \mathcal{D}] :$$

a esperança percorre só a observação nova, com o treino fixo. Repare que ele é uma *variável aleatória* — cada amostra de treino produz o seu $\hat{g}$ e, portanto, o seu $R(\hat{g})$. O **risco esperado** é a média desse número sobre as amostras de treino possíveis, $\mathbb{E}_{\mathcal{D}}[R(\hat{g})] = \mathbb{E}[(Y - \hat{g}(\mathbf{X}))^2]$: um número só, que depende do método e de n , mas não da amostra que você tem.

(a) As duas garantias são sobre objetos diferentes.

O **risco condicional** é uma garantia sobre *a função que você tem nas mãos*: este $\hat{g}$, já ajustado, usado em observações novas, erra tanto em média.

O **risco esperado** é uma garantia sobre o *procedimento*: sortear uma amostra de tamanho n , rodar este método e usar o que sair erra tanto em média. Ele mistura as amostras de treino boas com as ruins.

Quem vai pôr em produção um modelo já ajustado quer o **condicional**: o modelo dele é

um só, não será reajustado, e o desempenho médio dos modelos que o método *costuma* produzir não diz quanto *este* vai errar. Quem ainda escolhe entre métodos quer o **esperado**: a pergunta ali é qual método tende a produzir bons modelos com dados como os seus, e uma amostra de sorte não deveria decidir a escolha.

(b) No momento da conta, $\mathcal{D}$ já foi sorteado e $\hat{g}$ está fixo; o que varia de uma parcela para outra é só o par de teste $(\mathbf{X}_k, Y_k)$, independente do treino. Condicionamente a $\mathcal{D}$, cada W_k tem média $R(\hat{g})$, e

$$\mathbb{E}[\hat{R}(\hat{g}) | \mathcal{D}] = R(\hat{g}), \quad \text{Var}(\hat{R}(\hat{g}) | \mathcal{D}) = \frac{\text{Var}(W_1 | \mathcal{D})}{m} \xrightarrow{m \rightarrow \infty} 0.$$

O número estima o **risco condicional**: pela lei dos grandes números, com um teste grande ele converge para $R(\hat{g})$ — o risco *daquele* ajuste.

Há uma sutileza que vale registrar, porque a pergunta a esconde. Tomando esperança também sobre o treino, $\mathbb{E}[\hat{R}(\hat{g})] = \mathbb{E}[R(\hat{g})]$: o erro de teste é não viesado *também* para o risco esperado. Mas não converge para ele. A diferença $R(\hat{g}) - \mathbb{E}[R(\hat{g})]$ é aleatoriedade do treino, que já aconteceu e não é repetida; nenhum m a elimina. Estimar bem o risco esperado exigiria repetir o procedimento inteiro com vários treinos.

(c) Condicione em $\mathcal{D}$. Então $\hat{g}$ é uma função fixa, e $W_k = (Y_k - \hat{g}(\mathbf{X}_k))^2$ é a mesma função fixa, $(\mathbf{x}, y) \mapsto (y - \hat{g}(\mathbf{x}))^2$, aplicada a pares $(\mathbf{X}_k, Y_k)$ i.i.d. e independentes do treino. Funções fixas de variáveis i.i.d. são i.i.d.: os W_k são i.i.d., com média $R(\hat{g})$ e variância $\tau^2 = \text{Var}(W_1 | \mathcal{D})$, que supomos finita.

O Teorema Central do Limite, junto com a consistência de $\hat{\sigma}^2$ para τ^2 , dá

$$\frac{\sqrt{m}(\hat{R}(\hat{g}) - R(\hat{g}))}{\hat{\sigma}} \xrightarrow{d} N(0, 1), \quad \hat{\sigma}^2 = \frac{1}{m} \sum_{k=1}^m (W_k - \bar{W})^2,$$

e daí o intervalo de confiança aproximado de 95% para $R(\hat{g})$, com 2 no lugar de 1,96, como nas notas:

$$\hat{R}(\hat{g}) \pm 2\sqrt{\hat{\sigma}^2/m}.$$

Duas ressalvas. A aproximação normal pede m razoável: cada W_k é um quadrado, e distribuições de quadrados são assimétricas à direita. E a hipótese que faz todo o trabalho é a independência entre teste e treino: se o teste tiver sido usado para escolher qualquer coisa, $\hat{g}$ passa a depender dele e o argumento desaba.

E por que a validação cruzada não oferece o mesmo? Porque nela as parcelas $(Y_i - g_{-j}(\mathbf{X}_i))^2$ não são independentes: os k ajustes compartilham boa parte das observações de treino, e cada observação ajuda a treinar os modelos que avaliam as outras. Um erro-padrão calculado como se fossem independentes — como o da regra de um erro-padrão — serve de guia para comparar modelos, mas não entrega a cobertura anunciada: tende a sair estreito demais.

Aula 02 — Regressão Linear e Regularização

Exercício 3 — Regressão no caso ortonormal. As notas da aula de Regressão Linear apresentam duas fórmulas prontas para o caso ortonormal, $\mathbb{X}^\top \mathbb{X} = \mathbb{I}$, e não as derivam. São elas que explicam a frase "o Ridge encolhe e o Lasso zera", e o exercício é preencher essa lacuna.

Use as definições da aula, **sem** fator $\frac{1}{2}$ no RSS:

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \sum_j \beta_j^2 \right\}, \quad \hat{\beta}^{\text{lasso}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \sum_j |\beta_j| \right\}.$$

Aqui $\mathbb{X} \in \mathbb{R}^{n \times p}$ não tem a coluna de uns: não há intercepto, e as duas penalidades somam sobre os p coeficientes.

- (a) Comece pelo passo que torna tudo possível. Supondo $\mathbb{X}^\top \mathbb{X} = \mathbb{I}$, mostre que o estimador de mínimos quadrados é $\hat{\beta} = \mathbb{X}^\top \mathbf{y}$ e que

$$\|\mathbf{y} - \mathbb{X}\beta\|^2 = \|\mathbf{y}\|^2 - \|\hat{\beta}\|^2 + \sum_{j=1}^p (\beta_j - \hat{\beta}_j)^2.$$

Explique por que essa identidade faz o problema **se separar** em p problemas de uma variável — e por que é justamente isso que falha quando as colunas não são ortonormais.

- (b) Com a separação em mãos, derive $\hat{\beta}_j^{\text{ridge}} = \hat{\beta}_j / (1 + \lambda)$.
- (c) Agora o Lasso. A dificuldade nova é que $|\beta_j|$ não é derivável em zero, então não dá para igualar a derivada a zero e pronto: trate separadamente as regiões $\beta_j > 0$, $\beta_j < 0$ e o ponto $\beta_j = 0$. Derive $\hat{\beta}_j^{\text{lasso}} = \text{sign}(\hat{\beta}_j)(|\hat{\beta}_j| - \lambda/2)_+$ e diga qual é a condição exata que leva um coeficiente a zero.
- (d) O limiar deu $\lambda/2$, e não λ . De onde veio esse 2? Diga o que mudaria nas duas fórmulas se a aula tivesse definido o RSS com um $\frac{1}{2}$ na frente, e que lição prática isso deixa.

Solução

(a) Com $\mathbb{X}^\top \mathbb{X} = \mathbb{I}$ a matriz é invertível, e as equações normais $\mathbb{X}^\top \mathbb{X} \beta = \mathbb{X}^\top \mathbf{y}$ dão diretamente $\hat{\beta} = \mathbb{X}^\top \mathbf{y}$.

Para a identidade, o caminho mais curto é o teorema de Pitágoras. Escreva

$$\mathbf{y} - \mathbb{X}\beta = (\mathbf{y} - \mathbb{X}\hat{\beta}) + \mathbb{X}(\hat{\beta} - \beta).$$

As duas parcelas são ortogonais, porque as equações normais dizem exatamente que o resíduo do MQO é ortogonal às colunas de $\mathbb{X}$: $\mathbb{X}^\top (\mathbf{y} - \mathbb{X}\hat{\beta}) = \mathbf{0}$. Logo, para *qualquer* $\mathbb{X}$ de posto cheio,

$$\|\mathbf{y} - \mathbb{X}\beta\|^2 = \|\mathbf{y} - \mathbb{X}\hat{\beta}\|^2 + (\beta - \hat{\beta})^\top \mathbb{X}^\top \mathbb{X} (\beta - \hat{\beta}). \quad (*)$$

No caso ortonormal a forma quadrática é $\sum_j (\beta_j - \hat{\beta}_j)^2$, e

$$\|\mathbf{y} - \mathbb{X}\hat{\beta}\|^2 = \|\mathbf{y}\|^2 - 2 \hat{\beta}^\top \underbrace{\mathbb{X}^\top \mathbf{y}}_{=\hat{\beta}} + \hat{\beta}^\top \underbrace{\mathbb{X}^\top \mathbb{X}}_{=\mathbb{I}} \hat{\beta} = \|\mathbf{y}\|^2 - \|\hat{\beta}\|^2,$$

o que dá a identidade do enunciado.

Por que ela separa o problema. Somando a penalidade, os dois objetivos ficam

$$\|\mathbf{y}\|^2 - \|\hat{\beta}\|^2 + \sum_{j=1}^p h_j(\beta_j), \quad h_j(\beta) = (\beta - \hat{\beta}_j)^2 + \lambda \text{pen}(\beta),$$

com $\text{pen}(\beta) = \beta^2$ no Ridge e $\text{pen}(\beta) = |\beta|$ no Lasso. A constante não muda o minimizador, e o resto é uma soma de funções de *uma coordenada cada*. Para somas assim vale um fato simples: β^* minimiza $\sum_j h_j(\beta_j)$ se e só se cada β_j^* minimiza a sua h_j . (Se cada parcela está no seu mínimo, a soma está; e se alguma não estivesse, trocar só aquela coordenada baixaria a soma.) Um problema em $\mathbb{R}^p$ virou p problemas na reta.

Por que isso falha sem ortonormalidade. Em (*), a forma quadrática tem os termos cruzados $2(\mathbb{X}^\top \mathbb{X})_{j\ell}(\beta_j - \hat{\beta}_j)(\beta_\ell - \hat{\beta}_\ell)$, e o melhor valor de uma coordenada passa a depender

das outras. É por isso que o Lasso não tem fórmula fechada no caso geral, e as fórmulas deste exercício pedem uma hipótese forte. (É também por isso que o enunciado tira o intercepto: a coluna de uns tem norma $\sqrt{n}$ e não caberia numa matriz com $\mathbb{X}^\top \mathbb{X} = \mathbb{I}$. Com dados centrados o intercepto sai de cena, e é nesse cenário que o caso ortonormal faz sentido.)

(b) Para o Ridge, $h(\beta) = (\beta - \hat{\beta}_j)^2 + \lambda\beta^2$ é uma parábola com $h'' = 2(1 + \lambda) > 0$: estritamente convexa, com mínimo único onde a derivada se anula,

$$h'(\beta) = 2(\beta - \hat{\beta}_j) + 2\lambda\beta = 0 \iff \hat{\beta}_j^{\text{ridge}} = \frac{\hat{\beta}_j}{1 + \lambda}.$$

O Ridge **multiplica** todo coeficiente pelo mesmo fator $1/(1+\lambda)$: encolhe proporcionalmente — quem é grande perde mais em valor absoluto — e nunca zera um coeficiente não nulo, para λ finito.

(c) Agora $h(\beta) = (\beta - b)^2 + \lambda|\beta|$, com $b = \hat{\beta}_j$ e $\lambda > 0$. A função é contínua em toda a reta e derivável fora do zero:

$$h'(\beta) = 2(\beta - b) + \lambda \quad (\beta > 0), \quad h'(\beta) = 2(\beta - b) - \lambda \quad (\beta < 0).$$

A estratégia é ver onde h cresce e onde decresce, dos dois lados do zero.

Caso $b > \lambda/2$. Para $\beta < 0$, $h'(\beta) = 2\beta - (2b + \lambda) < 0$: h decresce em toda a semirreta negativa. Para $\beta > 0$, h' troca de sinal uma única vez, em $\beta = b - \lambda/2 > 0$: h decresce até ali e cresce depois. Como h é contínua no zero, o mínimo global é $\beta = b - \lambda/2$.

Caso $b < -\lambda/2$. Simétrico: o mínimo é $\beta = b + \lambda/2 < 0$.

Caso $|b| \leq \lambda/2$. Para $\beta > 0$, $h'(\beta) = 2\beta + (\lambda - 2b) > 0$, porque $\lambda - 2b \geq 0$; para $\beta < 0$, $h'(\beta) = 2\beta - (\lambda + 2b) < 0$, porque $\lambda + 2b \geq 0$. A função decresce até o zero e cresce depois dele: o mínimo é $\beta = 0$ — justamente o ponto em que ela não é derivável, e que nenhuma equação " $h' = 0$ " encontraria.

Os três casos cabem numa fórmula só,

$$\hat{\beta}_j^{\text{lasso}} = \text{sin}(\hat{\beta}_j)(|\hat{\beta}_j| - \lambda/2)_+, \quad \text{e o coeficiente zera} \iff |\hat{\beta}_j| \leq \lambda/2.$$

(Para quem conhece subgradientes: 0 minimiza a função convexa h quando $0 \in \partial h(0) = -2b + \lambda[-1, 1]$, que é a mesma condição.)

Compare com (b): o Lasso **subtrai** a mesma quantidade, $\lambda/2$, de todo coeficiente, em vez de multiplicar por um fator. Quem tinha módulo menor que isso não sobrevive ao deslocamento e vira exatamente zero. É o *soft thresholding*, e é a razão algébrica de o Lasso fazer seleção de variáveis.

(d) O 2 vem de derivar o quadrado. A derivada de $(\beta - \hat{\beta}_j)^2$ traz um fator 2 que a de $\lambda|\beta|$ não traz; ao isolar β , dividimos tudo por 2, e o λ vira $\lambda/2$.

Com o RSS definido com $\frac{1}{2}$ na frente (e a penalidade sem), o problema seria minimizar $\frac{1}{2} \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \text{Pen}(\beta)$. Multiplicar um objetivo por uma constante positiva não muda o minimizador, e multiplicando este por 2 ele vira o problema da aula com 2λ no lugar de λ . Basta fazer essa troca nas fórmulas:

$$\hat{\beta}_j^{\text{ridge}} = \frac{\hat{\beta}_j}{1 + 2\lambda}, \quad \hat{\beta}_j^{\text{lasso}} = \text{sin}(\hat{\beta}_j)(|\hat{\beta}_j| - \lambda)_+.$$

(Pôr o $\frac{1}{2}$ também na penalidade não mudaria nada: seria multiplicar o objetivo inteiro por uma constante.)

A lição prática: o **valor numérico de λ depende da convenção**, não só dos dados. Antes de comparar o λ das notas com o de um livro, de um artigo ou de uma biblioteca, confira qual

objetivo cada um minimiza. O Lasso do `scikit-learn` minimiza $\frac{1}{2n} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \alpha \|\boldsymbol{\beta}\|_1$; multiplicando por $2n$ vê-se que o seu α corresponde a $\lambda = 2n\alpha$ na convenção da aula. O n vem de usar a média em vez da soma; o 2 é o deste item.

Exercício 4 — O que o MQO estima quando a linearidade é falsa. Circula por aí a ideia de que a regressão linear "só vale se o modelo estiver correto". Vimos durante o curso que isso é impreciso: o MQO converge para uma função bem definida mesmo quando r não é linear.

Essa função é o **melhor preditor linear**,

$$\boldsymbol{\beta}^* = \arg \min_{\boldsymbol{\beta}} \mathbb{E}[(Y - \boldsymbol{\beta}^\top \mathbf{X})^2],$$

que existe sempre que $\Sigma = \mathbb{E}[\mathbf{X}\mathbf{X}^\top]$ é bem definida e invertível — *sem* supor nada sobre a forma de r .

- Derive $\boldsymbol{\beta}^* = \Sigma^{-1}\boldsymbol{\alpha}$, onde $\boldsymbol{\alpha} = \mathbb{E}[Y\mathbf{X}]$. É o mesmo cálculo das equações normais, com esperanças no lugar de somas.
- O estimador de mínimos quadrados pode ser escrito como $\hat{\boldsymbol{\beta}} = \hat{\Sigma}^{-1}\hat{\boldsymbol{\alpha}}$, com $\hat{\Sigma} = \frac{1}{n} \sum_i \mathbf{X}_i \mathbf{X}_i^\top$ e $\hat{\boldsymbol{\alpha}} = \frac{1}{n} \sum_i Y_i \mathbf{X}_i$. Olhe para essas duas expressões e diga o que elas são, estatisticamente. Em seguida, explique por que $\hat{\boldsymbol{\beta}} \rightarrow \boldsymbol{\beta}^*$ em probabilidade sem que se precise supor linearidade em lugar nenhum.
- Todo teorema garante uma coisa e deixa de garantir outra. Enuncie as duas, com cuidado. Em particular: o resultado diz que o risco de $\hat{\boldsymbol{\beta}}$ é pequeno?
- Um colega ajusta uma regressão linear a dados em que r é visivelmente curva e conclui: "o coeficiente deu 2,3, logo aumentar x_1 em uma unidade aumenta Y em 2,3". Separe o que é leitura legítima de $\boldsymbol{\beta}^*$ do que não é.

Solução

Hipóteses em uso: $\mathbb{E}[Y^2] < \infty$ e $\mathbb{E}\|\mathbf{X}\|^2 < \infty$, para que Σ e $\boldsymbol{\alpha}$ existam (a existência de $\boldsymbol{\alpha}$ sai por Cauchy–Schwarz), e Σ invertível. Como $\mathbf{v}^\top \Sigma \mathbf{v} = \mathbb{E}[(\mathbf{v}^\top \mathbf{X})^2] \geq 0$ para todo $\mathbf{v}$, Σ é semidefinida positiva; sendo invertível, é definida positiva.

(a) Expanda o objetivo; as esperanças são números fixos:

$$Q(\boldsymbol{\beta}) = \mathbb{E}[(Y - \boldsymbol{\beta}^\top \mathbf{X})^2] = \mathbb{E}[Y^2] - 2 \underbrace{\boldsymbol{\beta}^\top \mathbb{E}[Y\mathbf{X}]}_{\boldsymbol{\alpha}} + \underbrace{\boldsymbol{\beta}^\top \mathbb{E}[\mathbf{X}\mathbf{X}^\top]}_{\Sigma} \boldsymbol{\beta}.$$

É uma função quadrática de $\boldsymbol{\beta}$, com gradiente $\nabla Q(\boldsymbol{\beta}) = -2\boldsymbol{\alpha} + 2\Sigma\boldsymbol{\beta}$ e Hessiana 2Σ , definida positiva. Logo Q é estritamente convexa, e seu único ponto crítico é o mínimo global:

$$\Sigma\boldsymbol{\beta} = \boldsymbol{\alpha} \iff \boldsymbol{\beta}^* = \Sigma^{-1}\boldsymbol{\alpha}.$$

São as equações normais da aula com $\mathbb{E}[\mathbf{X}\mathbf{X}^\top]$ no lugar de $\frac{1}{n}\mathbb{X}^\top\mathbb{X}$ e $\mathbb{E}[Y\mathbf{X}]$ no lugar de $\frac{1}{n}\mathbb{X}^\top\mathbf{y}$: o mesmo problema, escrito na população em vez de na amostra.

Vale conhecer uma segunda demonstração, sem derivadas, porque ela rende uma identidade que usaremos em (c). Some e subtraia $\boldsymbol{\beta}^{*\top}\mathbf{X}$ dentro do quadrado:

$$\begin{aligned} Q(\boldsymbol{\beta}) &= \mathbb{E}\left[\left((Y - \boldsymbol{\beta}^{*\top}\mathbf{X}) - (\boldsymbol{\beta} - \boldsymbol{\beta}^*)^\top \mathbf{X}\right)^2\right] \\ &= Q(\boldsymbol{\beta}^*) - 2(\boldsymbol{\beta} - \boldsymbol{\beta}^*)^\top \underbrace{\mathbb{E}[\mathbf{X}(Y - \mathbf{X}^\top \boldsymbol{\beta}^*)]}_{=\boldsymbol{\alpha} - \Sigma\boldsymbol{\beta}^* = \mathbf{0}} + (\boldsymbol{\beta} - \boldsymbol{\beta}^*)^\top \Sigma (\boldsymbol{\beta} - \boldsymbol{\beta}^*), \end{aligned}$$

ou seja,

$$Q(\beta) = Q(\beta^*) + (\beta - \beta^*)^\top \Sigma (\beta - \beta^*). \quad (\dagger)$$

O último termo é estritamente positivo para $\beta \neq \beta^*$, o que prova de uma vez que β^* é o mínimo e que é o único. É o mesmo "some e subtraia" do Exercício 1, e funciona pela mesma razão. Lá, o resíduo $Y - r(\mathbf{X})$ era ortogonal a toda função de $\mathbf{X}$; aqui, $\mathbb{E}[\mathbf{X}(Y - \mathbf{X}^\top \beta^*)] = \mathbf{0}$ diz que o resíduo do melhor preditor linear é ortogonal a cada covariável. $r(\mathbf{X})$ é a projeção de Y sobre todas as funções de $\mathbf{X}$; $\beta^{*\top} \mathbf{X}$, a projeção sobre as lineares.

(b) $\hat{\Sigma}$ e $\hat{\alpha}$ são **médias amostrais** de variáveis i.i.d.: a primeira, das matrizes $\mathbf{X}_i \mathbf{X}_i^\top$, cuja esperança é Σ ; a segunda, dos vetores $Y_i \mathbf{X}_i$, cuja esperança é α . É essa observação que resolve o item.

Pela lei dos grandes números, aplicada coordenada a coordenada (as esperanças existem pelas hipóteses acima), $\hat{\Sigma} \rightarrow \Sigma$ e $\hat{\alpha} \rightarrow \alpha$ em probabilidade. A função $(A, \mathbf{a}) \mapsto A^{-1} \mathbf{a}$ é contínua no conjunto aberto das matrizes invertíveis, que contém Σ ; por isso $\hat{\Sigma}$ é invertível com probabilidade tendendo a 1, e o teorema de Mann–Wald (da aplicação contínua) transporta a convergência:

$$\hat{\beta} = \hat{\Sigma}^{-1} \hat{\alpha} \xrightarrow{P} \Sigma^{-1} \alpha = \beta^*.$$

Em nenhum passo apareceu a forma de r . O alvo β^* é definido por um problema de minimização que faz sentido para qualquer distribuição com segundos momentos finitos; o que a linearidade de r acrescentaria seria só a coincidência $\beta^{*\top} \mathbf{x} = r(\mathbf{x})$ — agradável, mas dispensável para a convergência.

(c) Duas identidades do curso dizem tudo. Aplique a do Exercício 1(a) com $g(\mathbf{x}) = \beta^{*\top} \mathbf{x}$, e depois $(\dagger)$ com $\beta = \hat{\beta}$ (fixado o treino, o risco do ajuste é $R(\hat{g}) = Q(\hat{\beta})$):

$$R(\hat{g}) = \underbrace{\mathbb{E}[\text{Var}(Y | \mathbf{X})]}_{\text{irreduzível}} + \underbrace{\mathbb{E}[(r(\mathbf{X}) - \beta^{*\top} \mathbf{X})^2]}_{\text{erro de aproximação}} + \underbrace{(\hat{\beta} - \beta^*)^\top \Sigma (\hat{\beta} - \beta^*)}_{\text{erro de estimação}}.$$

Com a decomposição à vista, as duas coisas se enunciam sem ambiguidade.

O que o teorema garante: a terceira parcela vai a zero, porque $\hat{\beta} \rightarrow \beta^*$ e a forma quadrática é contínua. Com n grande, o MQO chega tão perto quanto se queira do melhor que a classe das funções lineares tem a oferecer, e $R(\hat{g}) \rightarrow R(g_{\beta^*})$.

O que ele não garante: que esse melhor seja bom. A segunda parcela não depende de n , e o teorema não diz nada sobre ela; se r é muito curva, ela é grande, e convergir para uma aproximação ruim continua sendo ruim. Então não: o resultado *não* diz que o risco de $\hat{\beta}$ é pequeno, só que ele se aproxima do risco do oráculo. Tampouco diz *com que rapidez*: é um resultado de convergência, sem taxa.

Na linguagem da Aula 01, o teorema cuida do erro de estimação — a variância, e a parte do viés que vem de n ser finito — e deixa intacto o viés de aproximação, que é o preço fixo de ter escolhido uma classe rígida.

(d) *A leitura legítima.* 2,3 é o coeficiente de x_1 no hiperplano que *melhor aproxima* r em erro quadrático médio, sob a distribuição de $\mathbf{X}$ em que os dados foram colhidos. É um resumo global, e útil como tal.

O que não se pode ler nele, em três sentidos.

- *Não é a inclinação de r .* Com r curva, $\partial r / \partial x_1$ muda de ponto para ponto, e 2,3 não é o valor dela em lugar nenhum em particular. Com várias covariáveis, pode nem ter relação com ela. Tome $X_2 \sim N(0, 1)$, $X_1 = X_2^2 + \varepsilon$, com $\varepsilon \sim N(0, s^2)$

independente, e $r(\mathbf{x}) = x_2^2$: r nem depende de x_1 , e ainda assim, regredindo em $(1, x_1, x_2)$,

$$\beta_1^* = \frac{\text{Cov}(X_1, X_2^2)}{\text{Var}(X_1)} = \frac{2}{2 + s^2} \neq 0.$$

A reta usa x_1 como *procurador* da parte curva de r que ela não consegue representar em x_2 . (A conta: X_2 não é correlacionada nem com X_2^2 nem com X_1 , pois $\mathbb{E}[X_2^3] = 0$; então o coeficiente de x_2 é zero, o de x_1 é o da regressão simples, e $\text{Var}(X_2^2) = \mathbb{E}[X_2^4] - 1 = 2$.)

- *Depende de onde os dados caíram.* Mesmo com uma covariável só: para $r(x) = x^2$ e $X \sim \text{Unif}(0, a)$, a inclinação ótima é $\text{Cov}(X, X^2) / \text{Var}(X) = (a^3/12) / (a^2/12) = a$. Colhendo dados em $[0, 1]$ o colega veria 1; em $[0, 2]$, veria 2 — com r exatamente a mesma. Um número que muda com a faixa amostrada não descreve um mecanismo.
- *"Aumentar x_1 aumenta Y " é uma frase causal*, sobre intervir no sistema. Nenhuma regressão a autoriza sozinha, nem com r linear: comparar indivíduos que *diferem* em x_1 não é o mesmo que *mudar* o x_1 de alguém.

Exercício 5 — A Regressão Ridge como moda a posteriori. Já mencionamos que o Ridge tem uma leitura bayesiana: ele é a moda a posteriori sob uma priori gaussiana. A afirmação é mais do que curiosidade — ela dá um significado concreto ao λ , que até aqui era só um hiperparâmetro.

Considere o modelo

$$\mathbf{y} \mid \boldsymbol{\beta} \sim N(\mathbb{X}\boldsymbol{\beta}, \sigma^2\mathbb{I}), \quad \boldsymbol{\beta} \sim N(\mathbf{0}, \sigma_\beta^2\mathbb{I}),$$

com σ^2 e σ_β^2 conhecidos.

- (a) Escreva a densidade a posteriori de $\boldsymbol{\beta}$ a menos de constante multiplicativa e mostre que maximizá-la equivale a minimizar

$$\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \frac{1}{2\sigma_\beta^2} \|\boldsymbol{\beta}\|^2.$$

O caminho é o de sempre: passar ao logaritmo transforma produto em soma, e trocar o sinal transforma maximizar em minimizar.

- (b) Compare o que você obteve com a definição do Ridge da aula e identifique λ em função de σ^2 e σ_β^2 . Cuidado com o fator que precisa ser eliminado antes da comparação.
- (c) Agora a parte interessante: o que a priori está *afirmando* quando $\sigma_\beta^2 \rightarrow \infty$, e quando $\sigma_\beta^2 \rightarrow 0$? Ligue cada resposta ao comportamento do Ridge em $\lambda \rightarrow 0$ e $\lambda \rightarrow \infty$.

Solução

(a) Pelo teorema de Bayes, a densidade a posteriori é proporcional ao produto da verossimilhança pela priori. Com as duas densidades normais do modelo,

$$f(\mathbf{y} \mid \boldsymbol{\beta}) = (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2\right\}, \quad \pi(\boldsymbol{\beta}) = (2\pi\sigma_\beta^2)^{-q/2} \exp\left\{-\frac{1}{2\sigma_\beta^2} \|\boldsymbol{\beta}\|^2\right\},$$

em que q é a dimensão de β , vem

$$\pi(\beta | \mathbf{y}) \propto f(\mathbf{y} | \beta) \pi(\beta) \propto \exp \left\{ -\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\beta\|^2 - \frac{1}{2\sigma_\beta^2} \|\beta\|^2 \right\}.$$

O " $\propto$ " é em β : as constantes de normalização e a densidade marginal de $\mathbf{y}$ não dependem de β , e por isso não mudam *onde* a posteriori é máxima.

A moda a posteriori é o ponto de máximo dessa densidade. Como o logaritmo é estritamente crescente, maximizar uma função positiva é o mesmo que maximizar o seu logaritmo, que aqui é

$$\log \pi(\beta | \mathbf{y}) = \text{const} - \frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\beta\|^2 - \frac{1}{2\sigma_\beta^2} \|\beta\|^2;$$

e maximizar $-F$ é o mesmo que minimizar F . Logo a moda é o minimizador de

$$\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\beta\|^2 + \frac{1}{2\sigma_\beta^2} \|\beta\|^2.$$

Esse objetivo é estritamente convexo (a segunda parcela já é), então o mínimo existe e é único: a moda está bem definida.

(b) Multiplicar o objetivo por $2\sigma^2 > 0$ não muda o minimizador, e elimina o fator que está na frente do RSS:

$$\|\mathbf{y} - \mathbb{X}\beta\|^2 + \frac{\sigma^2}{\sigma_\beta^2} \|\beta\|^2.$$

Agora é o objetivo do Ridge, com

$$\lambda = \frac{\sigma^2}{\sigma_\beta^2}$$

O cuidado do enunciado era esse: comparar antes de eliminar o fator leva a ler $\lambda = 1/(2\sigma_\beta^2)$, ou a inverter a razão.

Um detalhe de rigor. Se $\mathbb{X}$ tem a coluna de uns, a priori acima encolhe também o intercepto — e a Ridge da aula não o penaliza. A correspondência exata pede a priori normal só para $\beta_1, \dots, \beta_p$, com uma priori plana para β_0 ($\pi(\beta_0) \propto 1$); ou dados centrados, em que o intercepto sai de cena. Nos dois casos a conta é a mesma, e o λ também.

De quebra: completando o quadrado no expoente, vê-se que a posteriori é normal,

$$\beta | \mathbf{y} \sim N\left((\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I})^{-1} \mathbb{X}^\top \mathbf{y}, \sigma^2 (\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I})^{-1}\right),$$

e a média é exatamente o minimizador acima. Numa normal, moda e média coincidem — é por isso que, no Ridge, a solução é a moda e a média a posteriori.

(c) A ponte é $\lambda = \sigma^2/\sigma_\beta^2$: cada afirmação sobre a priori vira uma afirmação sobre a penalização.

Quando $\sigma_\beta^2 \rightarrow \infty$, a priori se espalha. Para dois valores quaisquer de β , a razão das densidades, $\pi(\beta)/\pi(\beta') = \exp\{(\|\beta'\|^2 - \|\beta\|^2)/(2\sigma_\beta^2)\}$, tende a 1: ela deixa de preferir um valor a outro — não afirma nada —, e a posteriori passa a ser ditada pela verossimilhança. Do lado do Ridge, $\lambda \rightarrow 0$, e

$$\hat{\beta}_\lambda = (\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I})^{-1} \mathbb{X}^\top \mathbf{y} \rightarrow (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{y}$$

quando $\mathbb{X}^\top \mathbb{X}$ é invertível, porque a inversão de matrizes é contínua: o Ridge vira o MQO, com viés pequeno e variância alta.

Quando $\sigma_\beta^2 \rightarrow 0$, a priori se concentra em zero: $\mathbb{P}(\|\beta\| > \varepsilon) \rightarrow 0$ para todo $\varepsilon > 0$. Ela afirma, antes de ver dado algum e com certeza cada vez maior, que os coeficientes são praticamente nulos. Do lado do Ridge, $\lambda \rightarrow \infty$ e $\hat{\beta}_\lambda \rightarrow \mathbf{0}$: como todos os autovalores de $\mathbb{X}^\top \mathbb{X} + \lambda \mathbf{I}$ são pelo menos λ , vale $\|\hat{\beta}_\lambda\| \leq \|\mathbb{X}^\top \mathbf{y}\| / \lambda \rightarrow 0$. Variância nula e viés máximo: a estimativa ignora os dados.

Entre os extremos, a fórmula diz uma coisa sensata: regulariza-se mais quando os dados são ruidosos (σ^2 grande) ou quando a crença prévia é firme (σ_β^2 pequeno). O λ é a razão entre duas incertezas, a do ruído e a da priori; e escolhê-lo por validação cruzada é, nessa leitura, deixar os dados escolherem a priori que melhor prediz.

Aula 03 — Seleção de Modelos e Validação Cruzada

Exercício 6 — A fórmula de regressão linear para LOOCV. O LOOCV (*Leave-One-Out Cross Validation*) parece caro: n ajustes, um para cada observação deixada de fora. Já comentamos que, para ajustes lineares, um único ajuste basta — mas não demonstramos.

Vamos demonstrar no caso da regressão linear por mínimos quadrados. A matriz de design $\mathbb{X}$ tem linha i igual a $\mathbf{X}_i^\top$, e o ajuste com *todos* os dados é $\hat{g}(\mathbf{x}) = \mathbf{x}^\top \hat{\beta}$, com $\hat{\beta} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{y}$. Chame de $\hat{g}_{-i}$ o ajuste feito sem a i -ésima observação. A fórmula a demonstrar é

$$\hat{R}_{\text{LOO}} = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{g}(\mathbf{X}_i)}{1 - h_{ii}} \right)^2,$$

em que h_{ii} é o i -ésimo elemento da diagonal da matriz $\mathbf{H} = \mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top$.

Suponha que $\mathbb{X}$ tenha posto cheio, e que continue tendo quando se tira qualquer uma de suas linhas. Assim todos os ajustes são únicos, e $h_{ii} \neq 1$: dividir por $1 - h_{ii}$ nunca é problema.

A demonstração vem em etapas. O item (a) mostra o que são os números $h_{i\ell}$; os itens (b) e (c) usam um truque para escrever $\hat{g}_{-i}(\mathbf{X}_i)$ em termos de $\hat{g}$; o (d) faz a conta; e o (e) interpreta o resultado.

- (a) *De onde vêm os pesos.* Mostre que o vetor de valores ajustados, $\hat{\mathbf{y}} = (\hat{g}(\mathbf{X}_1), \dots, \hat{g}(\mathbf{X}_n))^\top$, é igual a $\mathbf{H}\mathbf{y}$, e conclua, olhando a coordenada i , que

$$\hat{g}(\mathbf{X}_i) = \sum_{\ell=1}^n h_{i\ell} Y_\ell,$$

em que $h_{i\ell}$ é a entrada (i, ℓ) de $\mathbf{H}$. Dica: como a linha i de $\mathbb{X}$ é $\mathbf{X}_i^\top$, vale $\hat{\mathbf{y}} = \mathbb{X}\hat{\beta}$.

Em palavras: a predição no ponto $\mathbf{X}_i$ é uma combinação de todas as respostas, inclusive da própria Y_i , que entra com peso h_{ii} . De que esses pesos dependem? E de que eles *não* dependem?

- (b) *O truque.* Imagine o conjunto de dados em que a resposta Y_i foi trocada por $\tilde{Y}_i = \hat{g}_{-i}(\mathbf{X}_i)$ — o valor que o ajuste sem a observação i prevê ali —, com as covariáveis e as demais respostas intactas. Mostre que o ajuste de mínimos quadrados nesse conjunto modificado é exatamente $\hat{g}_{-i}$.

Antes do caso geral, veja o truque funcionar no modelo só com intercepto, em que o ajuste é a média: troque Y_i pela média das outras $n - 1$ respostas e confira que a média das n passa a ser justamente a média das outras. Para o caso geral, um caminho: escreva o RSS do conjunto modificado como a soma das $n - 1$ parcelas de sempre com a parcela da observação i ; veja o que $\hat{g}_{-i}$ faz com cada uma das duas partes; e conclua que nenhuma função linear consegue um RSS menor, o que basta, porque o ajuste é único.

- (c) *A mesma matriz, duas vezes.* O conjunto modificado tem as mesmas covariáveis que o original, e portanto a mesma matriz $\mathbf{H}$. Aplique (a) a ele e use (b) para mostrar que

$$\hat{g}_{-i}(\mathbf{X}_i) = \sum_{\ell \neq i} h_{i\ell} Y_\ell + h_{ii} \tilde{Y}_i.$$

Depois some e subtraia $h_{ii}Y_i$ para chegar a

$$\hat{g}_{-i}(\mathbf{X}_i) = \hat{g}(\mathbf{X}_i) + h_{ii}(\tilde{Y}_i - Y_i).$$

- (d) *A conta.* Na igualdade de (c), $\tilde{Y}_i$ aparece dos dois lados, porque o lado esquerdo é o próprio $\tilde{Y}_i$. Subtraia Y_i dos dois lados, junte os termos com $\tilde{Y}_i - Y_i$ e isole o resíduo de validação $Y_i - \hat{g}_{-i}(\mathbf{X}_i)$. Conclua a fórmula do enunciado.
- (e) *Lendo o resultado.* A matriz $\mathbf{H}$ tem duas propriedades. É simétrica, porque $\mathbb{X}^\top \mathbb{X}$ é simétrica e sua inversa também. E vale $\mathbf{H}\mathbf{H} = \mathbf{H}$, o que se confere multiplicando:

$$\mathbf{H}\mathbf{H} = \mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1} \underbrace{\mathbb{X}^\top \mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1}}_{=\mathbf{I}} \mathbb{X}^\top = \mathbf{H}.$$

Em palavras: $\mathbf{H}$ projeta $\mathbf{y}$ no espaço gerado pelas colunas de $\mathbb{X}$, e projetar de novo o que já foi projetado não muda nada. Usando as duas propriedades, a entrada (i, i) de $\mathbf{H}\mathbf{H} = \mathbf{H}$ dá

$$h_{ii} = \sum_{\ell=1}^n h_{i\ell}^2 = h_{ii}^2 + \sum_{\ell \neq i} h_{i\ell}^2.$$

Conclua que $0 \leq h_{ii} \leq 1$ e que, portanto, o resíduo de validação nunca é menor, em módulo, que o de treino. O que isso confirma sobre o erro de treino como estimativa do risco? E o que significa uma observação com h_{ii} próximo de 1?

Solução

(a) Como a linha i de $\mathbb{X}$ é $\mathbf{X}_i^\top$, a coordenada i de $\mathbb{X}\hat{\boldsymbol{\beta}}$ é $\mathbf{X}_i^\top \hat{\boldsymbol{\beta}} = \hat{g}(\mathbf{X}_i)$; logo $\hat{\mathbf{y}} = \mathbb{X}\hat{\boldsymbol{\beta}}$, substituindo $\hat{\boldsymbol{\beta}}$,

$$\hat{\mathbf{y}} = \underbrace{\mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top}_{=\mathbf{H}} \mathbf{y} = \mathbf{H}\mathbf{y}.$$

A coordenada i de $\mathbf{H}\mathbf{y}$ é a linha i de $\mathbf{H}$ vezes $\mathbf{y}$; igualando as coordenadas i dos dois lados, $\hat{g}(\mathbf{X}_i) = \sum_{\ell} h_{i\ell} Y_\ell$.

Os pesos são entradas de $\mathbf{H}$, que é construída só com $\mathbb{X}$: eles **dependem das covariáveis e não dependem das respostas**. Troque o vetor $\mathbf{y}$ mantendo as covariáveis, e a predição em $\mathbf{X}_i$ continua sendo a mesma combinação, agora das respostas novas. É essa propriedade — o ajuste é uma função *linear* de $\mathbf{y}$ — que o item (c) usa. (No modelo só com intercepto, $\mathbb{X} = \mathbf{1}$, todas as entradas de $\mathbf{H}$ valem $1/n$, e a combinação é a média.)

(b) *O caso da média.* Seja $\bar{Y}_{-i}$ a média das outras $n - 1$ respostas. Trocando Y_i por $\tilde{Y}_i = \bar{Y}_{-i}$, a soma das n respostas vira $(n - 1)\bar{Y}_{-i} + \bar{Y}_{-i} = n\bar{Y}_{-i}$, e a nova média é $\bar{Y}_{-i}$. A observação trocada foi posta exatamente onde o ajuste sem ela já estava, e por isso não puxa o ajuste para lado nenhum.

O caso geral é o mesmo argumento, escrito com o RSS. Para uma função linear $g(\mathbf{x}) = \mathbf{x}^\top \boldsymbol{\beta}$ qualquer, o RSS do conjunto modificado se parte em duas:

$$\widetilde{\text{RSS}}(g) = \underbrace{\sum_{\ell \neq i} (Y_\ell - g(\mathbf{X}_\ell))^2}_{A(g)} + \underbrace{(\tilde{Y}_i - g(\mathbf{X}_i))^2}_{B(g) \geq 0}.$$

Por definição, $\hat{g}_{-i}$ minimiza A entre as funções lineares — e está bem definido, porque $\mathbb{X}$ sem a linha i tem posto cheio. E $B(\hat{g}_{-i}) = 0$, porque $\tilde{Y}_i$ foi escolhido como $\hat{g}_{-i}(\mathbf{X}_i)$. Logo, para toda g linear,

$$\widetilde{\text{RSS}}(g) = A(g) + B(g) \geq A(\hat{g}_{-i}) + 0 = \widetilde{\text{RSS}}(\hat{g}_{-i}) :$$

$\hat{g}_{-i}$ minimiza o RSS modificado. Como o conjunto modificado tem a mesma matriz $\mathbb{X}$, de posto cheio, esse minimizador é único; é, portanto, o ajuste de mínimos quadrados do conjunto modificado.

(c) Aplique (a) ao conjunto modificado. As covariáveis são as mesmas, então $\mathbf{H}$ é a mesma, e a predição em $\mathbf{X}_i$ é a mesma combinação de antes, com $\tilde{Y}_i$ no lugar de Y_i . Por (b), essa predição é $\hat{g}_{-i}(\mathbf{X}_i)$:

$$\hat{g}_{-i}(\mathbf{X}_i) = \sum_{\ell \neq i} h_{i\ell} Y_\ell + h_{ii} \tilde{Y}_i.$$

Somando e subtraindo $h_{ii} Y_i$, a soma se completa e aparece $\hat{g}(\mathbf{X}_i)$:

$$\hat{g}_{-i}(\mathbf{X}_i) = \underbrace{\sum_{\ell} h_{i\ell} Y_\ell}_{=\hat{g}(\mathbf{X}_i)} + h_{ii} (\tilde{Y}_i - Y_i).$$

(d) O lado esquerdo de (c) é o próprio $\tilde{Y}_i$. Subtraindo Y_i dos dois lados, a diferença $\tilde{Y}_i - Y_i$ aparece nos dois:

$$\tilde{Y}_i - Y_i = (\hat{g}(\mathbf{X}_i) - Y_i) + h_{ii} (\tilde{Y}_i - Y_i) \iff (1 - h_{ii})(\tilde{Y}_i - Y_i) = \hat{g}(\mathbf{X}_i) - Y_i.$$

Como $h_{ii} \neq 1$ (o item (e) confere), podemos dividir; trocando os sinais,

$$Y_i - \hat{g}_{-i}(\mathbf{X}_i) = \frac{Y_i - \hat{g}(\mathbf{X}_i)}{1 - h_{ii}}$$

Elevando ao quadrado e tirando a média em i , sai a fórmula do enunciado. O ganho está no lado direito: só entra $\hat{g}$, ajustado *uma* vez, com todos os dados. Os n ajustes do LOOCV viraram um.

(e) Pela simetria, a entrada (i, i) de $\mathbf{H}\mathbf{H}$ é $\sum_{\ell} h_{i\ell} h_{\ell i} = \sum_{\ell} h_{i\ell}^2$; pela idempotência, ela vale h_{ii} . Daí saem as duas desigualdades:

$$h_{ii} = \sum_{\ell} h_{i\ell}^2 \geq 0, \quad h_{ii} = h_{ii}^2 + \sum_{\ell \neq i} h_{i\ell}^2 \geq h_{ii}^2 \implies h_{ii}(1 - h_{ii}) \geq 0 \implies h_{ii} \leq 1.$$

E a hipótese exclui $h_{ii} = 1$. Suponha $h_{ii} = \mathbf{X}_i^\top (\mathbb{X}^\top \mathbb{X})^{-1} \mathbf{X}_i = 1$ e tome $\mathbf{v} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbf{X}_i$, que não é nulo (senão h_{ii} seria 0). Sem a linha i , a matriz de delineamento $\mathbb{X}_{-i}$ satisfaz $\mathbb{X}_{-i}^\top \mathbb{X}_{-i} = \mathbb{X}^\top \mathbb{X} - \mathbf{X}_i \mathbf{X}_i^\top$, e então

$$\mathbb{X}_{-i}^\top \mathbb{X}_{-i} \mathbf{v} = \mathbf{X}_i - \mathbf{X}_i (\mathbf{X}_i^\top \mathbf{v}) = \mathbf{X}_i - \mathbf{X}_i h_{ii} = \mathbf{0} :$$

$\mathbb{X}_{-i}$ perderia o posto, contra a hipótese. (A recíproca também vale, e o exemplo típico é uma coluna indicadora que só a observação i tem: sem ela, a coluna zera.)

Com $0 \leq h_{ii} < 1$, o fator $1/(1 - h_{ii})$ é pelo menos 1, e (d) dá

$$|Y_i - \hat{g}_{-i}(\mathbf{X}_i)| \geq |Y_i - \hat{g}(\mathbf{X}_i)| \quad \text{para toda observação } i.$$

Tirando a média dos quadrados, $\hat{R}_{\text{LOO}}$ nunca fica abaixo do erro quadrático médio de treino. Isso confirma, de um jeito bem concreto, que o erro de treino é **otimista** — e não

só em média: em toda amostra, observação por observação, e com o tamanho da correção escrito.

O h_{ii} mede a **alavancagem**: o peso da própria Y_i na predição feita em $\mathbf{X}_i$. Perto de 1, essa predição é quase só Y_i — o ajuste passa colado no ponto, e o resíduo de treino sai pequeno e engana. O fator $1/(1 - h_{ii})$ fica grande justamente para desfazer o engano: sem a observação i , as outras quase não informam o que acontece em $\mathbf{X}_i$. Para ter uma escala, $\sum_i h_{ii} = \text{tr}(\mathbf{H}) = \text{tr}((\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbb{X})$ é o número de colunas de $\mathbb{X}$; a alavancagem *média* é, portanto, o número de parâmetros dividido por n , e "alta" quer dizer muito acima disso. Um último comentário, de método: repare onde cada hipótese trabalhou. A linearidade do ajuste nas respostas entrou em (a) e (c); o fato de $\hat{g}_{-i}$ ser um ajuste de mínimos quadrados *na mesma classe de funções*, em (b); o posto cheio, na unicidade de (b) e em $h_{ii} \neq 1$; a simetria e a idempotência de $\mathbf{H}$, só em (e). Um método que não tenha alguma dessas propriedades não herda a fórmula automaticamente.

Exercício 7 — Duas fórmulas da validação cruzada. Quem estuda validação cruzada pelas notas de aula e pelo livro encontra duas fórmulas diferentes para a mesma quantia, e é natural desconfiar de que uma delas esteja errada. Não está: elas só diferem na unidade que cada uma pondera igualmente.

As notas de aula definem

$$\hat{R}_{k\text{-CV}} = \frac{1}{n} \sum_{j=1}^k \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2,$$

e o livro define $\text{CV}_{(k)} = \frac{1}{k} \sum_{j=1}^k \text{EQM}_j$, com $\text{EQM}_j = \frac{1}{|L_j|} \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2$.

(a) Reescreva a fórmula das notas de modo a fazer os EQM_j aparecerem, mostrando que

$$\hat{R}_{k\text{-CV}} = \sum_{j=1}^k \frac{|L_j|}{n} \text{EQM}_j.$$

- (b) Olhando para os pesos que você obteve, diga em que condição as duas definições coincidem — e se coincidem exatamente ou apenas aproximadamente. Em seguida, nomeie a unidade que cada fórmula pondera igualmente.
- (c) Com $n = 50$ e $k = 7$, as dobras não podem ter todas o mesmo tamanho; suponha que tenham tamanhos 8, 8, 7, 7, 7, 7, 6. Confirme que somam 50 e explique por que, neste caso, os dois números diferem.
- (d) Suponha que a dobra de 6 observações tenha $\text{EQM} = 10$ e todas as outras tenham $\text{EQM} = 1$. Calcule os dois estimadores, diga qual deles dá mais peso à dobra atípica, e qual você reportaria. Justifique a escolha.

Solução

(a) A chave é reconhecer a soma interna. Pela definição de EQM_j , basta multiplicar dos dois lados por $|L_j|$:

$$\sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2 = |L_j| \text{EQM}_j.$$

Substituindo na fórmula das notas,

$$\hat{R}_{k\text{-CV}} = \frac{1}{n} \sum_{j=1}^k |L_j| \text{EQM}_j = \sum_{j=1}^k \frac{|L_j|}{n} \text{EQM}_j.$$

São os *mesmos* EQM_j do livro, combinados com pesos $w_j = |L_j|/n$. E esses pesos somam 1, porque as dobras particionam as n observações: $\sum_j |L_j| = n$. As duas fórmulas são, portanto, médias ponderadas dos mesmos k números, e só diferem nos pesos: $|L_j|/n$ numa, $1/k$ na outra.

(b) Os pesos coincidem em todas as dobras se e só se $|L_j|/n = 1/k$ para todo j , isto é, se todas as dobras têm tamanho n/k — o que só é possível quando k divide n . Nesse caso as duas fórmulas são a mesma soma dos mesmos números com os mesmos pesos: coincidem **exatamente**, e não aproximadamente.

A unidade que cada uma pondera igualmente: as notas dão o mesmo peso a cada **observação** — todo resíduo de validação entra com peso $1/n$ —; o livro dá o mesmo peso a cada **dobra**. Visto do lado das observações, o livro dá a cada resíduo da dobra j o peso $1/(k|L_j|)$.

(c) $8 + 8 + 7 + 7 + 7 + 7 + 6 = 50$.

Os pesos das notas são $8/50$ (duas vezes), $7/50$ (quatro vezes) e $6/50$; os do livro, $1/7$ para cada dobra. Como os tamanhos diferem, os pesos diferem, e as duas médias só coincidem por acaso — quando os EQM_j são todos iguais, por exemplo.

Olhando por observação fica mais claro. No livro, cada resíduo recebe

$$\frac{1}{7 \cdot 8} = \frac{1}{56}, \quad \frac{1}{7 \cdot 7} = \frac{1}{49} \quad \text{ou} \quad \frac{1}{7 \cdot 6} = \frac{1}{42},$$

conforme a dobra em que caiu, contra $1/50$ para todos nas notas. Uma observação da dobra de 6 pesa $4/3$ de uma da dobra de 8, só porque divide a sua dobra com menos gente.

(d) Pelas notas, a dobra atípica entra com peso $6/50$ e as outras 44 observações com $44/50$:

$$\hat{R}_{k\text{-CV}} = \frac{6}{50} \times 10 + \frac{44}{50} \times 1 = \frac{104}{50} = \mathbf{2,08}.$$

Pelo livro, a dobra atípica é uma das sete, e só:

$$\text{CV}_{(7)} = \frac{1}{7}(10 + 6 \times 1) = \frac{16}{7} \approx \mathbf{2,286}.$$

O livro dá mais peso à dobra atípica: $1/7 \approx 0,143$ contra $6/50 = 0,12$. Ela é a menor dobra e, ainda assim, vale um sétimo do total.

Qual reportar? Para *estimar o risco*, a das notas tem a seu favor um argumento limpo. O risco é a esperança da perda numa observação nova, e cada resíduo de validação ℓ_i é uma medida dessa perda. Se essas medidas tivessem a mesma média e a mesma variância s^2 , e fossem não correlacionadas — uma idealização, mas é ela que orienta —, toda combinação $\sum_i w_i \ell_i$ com pesos somando 1 teria a mesma média, e variância $s^2 \sum_i w_i^2$. Pela desigualdade de Cauchy–Schwarz,

$$1 = \left(\sum_{i=1}^n w_i \right)^2 \leq n \sum_{i=1}^n w_i^2,$$

com igualdade só nos pesos iguais, $w_i = 1/n$. Pesar as observações igualmente é o que menos desperdiça informação; dar mais peso a quem caiu numa dobra pequena é deixar o acaso do corte decidir.

A do livro também se defende. Ela trata cada dobra como uma repetição do experimento "treinar e validar", e é a escala natural quando o que se quer é comparar as dobras entre si: é dos k números EQM_j que sai o erro-padrão da regra de um erro-padrão. E é a que o `scikit-learn` calcula — `cross_val_score(...).mean()` é média não ponderada —, então o essencial é *saber qual das duas o seu código calcula* antes de comparar o seu número com o de outra pessoa.

E a recomendação das notas encerra a discussão pela raiz: com n pequeno, escolha um k que divida n . Aí as duas coincidem, e a pergunta não se coloca.

Aula 04 — Métodos Não Paramétricos (KNN)

Exercício 8 — Duas doenças, dois remédios. Durante o curso, apresentamos ferramentas que, à primeira vista, andam em sentidos opostos. A regularização *restringe* o modelo: o Ridge, por exemplo, soma ao RSS do MQO uma penalidade sobre o tamanho dos coeficientes,

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}.$$

Os métodos não paramétricos o *soltam*: o KNN, por exemplo, não supõe forma nenhuma para r e prevê pela média das respostas dos k vizinhos mais próximos de $\mathbf{x}$, cujos índices formam o conjunto $\mathcal{N}_{\mathbf{x}}$,

$$\hat{r}(\mathbf{x}) = \frac{1}{k} \sum_{i \in \mathcal{N}_{\mathbf{x}}} Y_i.$$

Parece contradição, e não é: são ferramentas para serem usadas em dois contextos diferentes.

Para ver quais, a referência é a decomposição do erro de previsão num ponto fixo $\mathbf{x}_0$. Para um estimador $\hat{r}$ construído com a amostra $\mathcal{D}$,

$$\mathbb{E}_{\mathcal{D}}[(Y_0 - \hat{r}(\mathbf{x}_0))^2] = \underbrace{(\mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0)] - r(\mathbf{x}_0))^2}_{\text{viés}^2} + \underbrace{\text{Var}_{\mathcal{D}}(\hat{r}(\mathbf{x}_0))}_{\text{variância}} + \underbrace{\sigma^2(\mathbf{x}_0)}_{\text{irreduzível}},$$

em que Y_0 é uma resposta nova em $\mathbf{x}_0$, $\sigma^2(\mathbf{x}_0) = \text{Var}(Y \mid \mathbf{X} = \mathbf{x}_0)$, e $\mathbb{E}_{\mathcal{D}}$ e $\text{Var}_{\mathcal{D}}$ percorrem as amostras de treino possíveis. O último termo não depende do método; a disputa é entre os dois primeiros.

- (a) Explique, em palavras, o que o viés e a variância medem. Depois diga qual dos dois termos a regularização ataca e qual os métodos não paramétricos atacam, e o que cada família aceita pagar no outro.
- (b) Descreva, em uma frase cada, a situação que motiva cada família: o que está errado com o modelo *antes* de aplicarmos Ridge, e o que está errado *antes* de aplicarmos um spline?
- (c) O KNN com $k = 1$ e o MQO com p grande erram por motivos que, na decomposição, caem no mesmo lugar. Explique. Em seguida diga qual é o remédio de cada um e por que os dois remédios se parecem.

Dica para o KNN: trate as covariáveis da amostra como fixas — assim os vizinhos de $\mathbf{x}_0$ também ficam fixos — e suponha que Y tenha variância constante σ^2 em torno de r . Nesse caso a decomposição fica

$$\mathbb{E}[(Y_0 - \hat{r}(\mathbf{x}_0))^2] = \left(\frac{1}{k} \sum_{i \in \mathcal{N}_{\mathbf{x}_0}} r(\mathbf{X}_i) - r(\mathbf{x}_0) \right)^2 + \frac{\sigma^2}{k} + \sigma^2.$$

O que acontece com cada termo quando k cresce?

- (d) As duas ideias podem ser combinadas? Dê um exemplo concreto, visto no curso, de método que seja ao mesmo tempo não paramétrico e regularizado, e diga qual botão controla cada coisa nele.

Solução

(a) Fixe $\mathbf{x}_0$ e pense em $\hat{r}(\mathbf{x}_0)$ como uma variável aleatória: ele muda com a amostra $\mathcal{D}$. O **viés**, $\mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0)] - r(\mathbf{x}_0)$, compara a *média* das estimativas, sobre todas as amostras de treino possíveis, com o alvo. É o erro sistemático, o que sobra depois que o acaso da amostra se cancela na média — e, quando a classe de funções do método não contém r , ele não some com mais dados. A **variância**, $\text{Var}_{\mathcal{D}}(\hat{r}(\mathbf{x}_0))$, mede a instabilidade: o quanto a estimativa mudaria se a amostra de treino fosse outra, do mesmo tamanho.

A **regularização ataca a variância**: ela restringe o espaço de soluções — no Ridge, encolhendo os coeficientes — e aceita pagar viés por isso. Os **métodos não paramétricos atacam o viés**: ampliam a classe de funções representáveis, até que r caiba nela, e aceitam pagar variância. O terceiro termo, $\sigma^2(\mathbf{x}_0)$, fica fora da disputa: é o erro irreduzível do Exercício 1, e nenhuma das duas famílias mexe nele.

(b) Antes do Ridge, o modelo é **flexível demais para a amostra**: covariáveis demais, ou colineares, para o n disponível. A matriz $\text{Var}(\hat{\beta}) = \sigma^2(\mathbb{X}^\top \mathbb{X})^{-1}$ tem entradas enormes, e os coeficientes mudam muito de uma amostra para outra. Excesso de variância.

Antes do spline, o modelo é **rígido demais para a verdade**: r é curva, e a reta não a acompanha. O erro que sobra é o erro de aproximação $\mathbb{E}[(r(\mathbf{X}) - \beta^{*\top} \mathbf{X})^2]$ do Exercício 4, que não depende de n — nenhum volume de dados conserta uma reta. Excesso de viés.

"Para a amostra" contra "para a verdade" é o coração da distinção: uma é falta de dados, a outra é falta de classe.

(c) Os dois erram por **variância**. Vale ver as contas, porque elas mostram também por que os remédios se parecem.

O *KNN*. Na situação da dica, os vizinhos de $\mathbf{x}_0$ estão fixos e as respostas são $Y_i = r(\mathbf{X}_i) + \varepsilon_i$, com ruídos independentes, de média zero e variância σ^2 . Então $\mathbb{E}[\hat{r}(\mathbf{x}_0)] = \frac{1}{k} \sum_{i \in \mathcal{N}_{\mathbf{x}_0}} r(\mathbf{X}_i)$ e $\text{Var}(\hat{r}(\mathbf{x}_0)) = \frac{1}{k^2} \cdot k\sigma^2 = \sigma^2/k$; como Y_0 é independente da amostra, a decomposição da dica sai direto. Com $k = 1$, a variância vale σ^2 — tanto quanto o próprio ruído —, enquanto o viés, $(r(\mathbf{X}_{(1)}) - r(\mathbf{x}_0))^2$, é pequeno se r é contínua e o vizinho mais próximo, $\mathbf{X}_{(1)}$, está perto de $\mathbf{x}_0$. Nos pontos de treino, o ajuste reproduz cada Y_i : resíduo nulo e nenhuma estabilidade.

O *MQO*. No mesmo regime (covariáveis fixas, ruído de variância σ^2), $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ tem matriz de covariância $\sigma^2 \mathbf{H}\mathbf{H}^\top = \sigma^2 \mathbf{H}$, porque $\mathbf{H}$ é simétrica e idempotente. A variância média dos valores ajustados é

$$\frac{1}{n} \sum_{i=1}^n \text{Var}(\hat{g}(\mathbf{X}_i)) = \frac{\sigma^2}{n} \text{tr}(\mathbf{H}) = \sigma^2 \frac{p+1}{n}.$$

Ela cresce linearmente com o número de parâmetros e chega a σ^2 quando $p+1 = n$ — a interpolação, exatamente como no KNN com $k = 1$. Com $p+1 > n$, a solução nem é única.

Por que caem no mesmo lugar. O KNN também é um suavizador linear: cada linha da sua matriz $\mathbf{H}$ tem k entradas iguais a $1/k$, de modo que $\text{tr}(\mathbf{H}) = n/k$ (Lista Teórica 04) e $\text{Var}(\hat{r}(\mathbf{X}_i)) = \sigma^2 \cdot k \cdot (1/k)^2 = \sigma^2 \text{tr}(\mathbf{H})/n$ — a mesma expressão do MQO. Nos dois métodos, quem governa a variância é o *número efetivo de parâmetros* $\text{tr}(\mathbf{H})$: n/k num, $p+1$ no outro. E $k = 1$ e $p+1 = n$ são o mesmo desastre — um parâmetro por observação. *Os remédios.* O do KNN é **aumentar** k : pela dica, a variância cai como σ^2/k , e o preço aparece no primeiro termo, porque vizinhos mais distantes entram na média e $\frac{1}{k} \sum r(\mathbf{X}_i)$

se afasta de $r(\mathbf{x}_0)$. O do MQO é **regularizar**. No caso ortonormal do Exercício 3 a troca é explícita: o Ridge divide cada coeficiente por $1 + \lambda$, o que divide sua variância por $(1 + \lambda)^2$ e cria um viés de $-\lambda\beta_j/(1 + \lambda)$.

Os dois se parecem porque fazem a mesma coisa: **reduzem** $\text{tr}(\mathbf{H})$, trocando variância por viés. No KNN, $\text{tr}(\mathbf{H}) = n/k$; no Ridge ortonormal, $\mathbf{H}_\lambda = \mathbb{X}(\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I})^{-1} \mathbb{X}^\top = \mathbb{X}\mathbb{X}^\top/(1 + \lambda)$, e $\text{tr}(\mathbf{H}_\lambda) = p/(1 + \lambda)$. Nos dois há um botão — k , que é inteiro, e λ , que é contínuo —, e nos dois ele se escolhe por validação cruzada, nunca no olho.

E os dois botões correm **no mesmo sentido**: k grande e λ grande dão modelos mais simples, e na ponta de cima dos dois está o modelo constante — a média global quando $k = n$, só o intercepto quando $\lambda \rightarrow \infty$. O que corre ao contrário é o grau do polinômio, ou o número de nós de um spline: ali, grande quer dizer flexível. O teste seguro, quando a memória falha, é perguntar de que lado está o modelo constante.

(d) Podem, e o curso tem pelo menos dois exemplos.

A *árvore podada* (Aula 05). O crescimento a torna não paramétrica: o número de folhas não é fixado de antemão, e cresce com n . E a poda por custo-complexidade a regulariza:

$$\sum_{m=1}^{|T|} \sum_{i: \mathbf{X}_i \in R_m} (Y_i - \hat{y}_{R_m})^2 + \alpha |T|$$

é "ajuste mais preço vezes complexidade", a mesma estrutura do Ridge, com o número de folhas no lugar da soma dos quadrados dos coeficientes. A flexibilidade disponível vem do crescimento; quanto dela é usado, decide o α .

As *smoothing splines* (Aula 04), que põem um nó em cada observação — não paramétricas ao extremo, com n parâmetros nominais — e controlam a flexibilidade penalizando a curvatura:

$$\sum_{i=1}^n (y_i - g(x_i))^2 + \gamma \int (g''(x))^2 dx.$$

A base cresce com n (o lado não paramétrico), e γ regula quanta daquela liberdade é de fato usada (o lado regularizado). Os nós deixaram de ser o botão — são todos —, e quem manda é γ : quando ele vai de 0 a ∞ , os graus de liberdade efetivos caem de n para 2, os da reta de mínimos quadrados.

(Vale também, no mesmo espírito, aplicar Ridge ou Lasso a uma base grande — muitos monômios, ou um spline com muitos nós.)

Aula 05 — Árvores de Regressão e *Ensembles*

Exercício 9 — O problema da poda. Construir uma árvore tem duas etapas, e elas usam objetivos diferentes de propósito. O crescimento escolhe cortes que mais reduzem o RSS; a poda escolhe uma subárvore $T \subseteq T_0$ minimizando

$$C_\alpha(T) = \sum_{k=1}^{|T|} \sum_{i: \mathbf{X}_i \in R_k} (Y_i - \hat{y}_{R_k})^2 + \alpha |T|,$$

onde $|T|$ é o número de folhas e $\hat{y}_{R_k}$ é a média das respostas na folha R_k . Se a forma lembra a regularização, não é coincidência.

- (a) O que se obtém nos dois extremos, $\alpha = 0$ e $\alpha \rightarrow \infty$? Diga em cada caso quantas folhas tem a subárvore vencedora.

- (b) Considere uma folha com RSS igual a S , que pode ser dividida em duas com RSS S_a e S_b . Escreva a condição sobre $S - (S_a + S_b)$ para que a divisão valha a pena segundo C_α , e interprete: em que unidade o α está cobrando?
- (c) Uma árvore tem RSS total 120 com 6 folhas; podando-a para 4 folhas, o RSS sobe para 140. Para quais valores de α a podada é preferível?
- (d) Por que a poda usa um critério diferente do crescimento, em vez de simplesmente parar de crescer quando o ganho fica pequeno? Dê um exemplo de estrutura nos dados que um critério de parada perderia e a poda recupera.

Solução

Um fato prepara o exercício todo: **dividir uma região nunca aumenta o RSS**. Se a região R se divide em R_a e R_b , então

$$\begin{aligned} S = \sum_{i \in R} (Y_i - \bar{Y}_R)^2 &= \sum_{i \in R_a} (Y_i - \bar{Y}_R)^2 + \sum_{i \in R_b} (Y_i - \bar{Y}_R)^2 \\ &\geq \sum_{i \in R_a} (Y_i - \bar{Y}_{R_a})^2 + \sum_{i \in R_b} (Y_i - \bar{Y}_{R_b})^2 = S_a + S_b, \end{aligned}$$

porque, dentro de cada parte, a média é a constante que minimiza a soma de quadrados — é o melhor preditor constante da Lista Teórica 01, na versão amostral.

(a) Com $\alpha = 0$, $C_0(T)$ é só o RSS. Toda subárvore $T \subseteq T_0$ se obtém de T_0 juntando folhas, e pelo fato acima isso nunca diminui o RSS; logo a árvore inteira T_0 minimiza C_0 , com todas as suas $|T_0|$ folhas — no limite do crescimento, uma observação por folha e RSS zero. (Uma subárvore com o mesmo RSS de T_0 empataria com ela.)

Quando $\alpha \rightarrow \infty$, seja S_{raiz} o RSS da raiz sozinha, isto é, a soma de quadrados total. A raiz custa $S_{\text{raiz}} + \alpha$, e qualquer árvore com $|T| \geq 2$ folhas custa pelo menos 2α . Assim que $\alpha > S_{\text{raiz}}$, a raiz vence: **uma folha só**, que prediz a média de todas as respostas. Não é preciso α infinito; basta passar da soma de quadrados total.

Entre os dois extremos, as subárvores vencedoras formam uma sequência finita e encaixada, de T_0 até a raiz, podando um ramo de cada vez — e é essa sequência que a validação cruzada percorre para escolher o α .

(b) Dividir a folha troca 1 folha por 2: o RSS cai de S para $S_a + S_b$, e o custo de complexidade sobe α . A divisão reduz C_α se, e só se,

$$(S_a + S_b) + \alpha(|T| + 1) < S + \alpha|T| \iff S - (S_a + S_b) > \alpha$$

(na igualdade, é indiferente). **A divisão precisa reduzir o RSS em mais de α** . O α é literalmente o *preço de uma folha*, cobrado na mesma unidade do RSS: se Y está em reais, α está em reais ao quadrado — o que explica, de passagem, por que um valor de α não se transporta de um problema para outro de escala diferente.

(c) A árvore grande custa $120 + 6\alpha$; a podada, $140 + 4\alpha$. A podada é preferível quando

$$140 + 4\alpha < 120 + 6\alpha \iff 20 < 2\alpha \iff \alpha > 10,$$

com empate em $\alpha = 10$ e as seis folhas mantidas abaixo disso.

O 10 é $20/2$: o aumento de RSS *por folha removida*. E a conta é sempre essa. Se uma árvore tem L folhas a menos que outra e RSS maior em Δ , a menor vence exatamente quando

$$\alpha > \frac{\Delta}{L}.$$

O item (b) é o caso $L = 1$. A regra dá um jeito rápido de estimar de cabeça qual α separa duas subárvores — e, mais importante, mostra que a poda julga *grupos* de cortes pelo que eles rendem juntos, por folha.

(d) Porque o critério de parada é **míope**: julga cada corte pelo que ele rende sozinho, e um corte que rende pouco pode ser indispensável por *viabilizar* os seguintes. A poda julga ramos inteiros — é o critério de (c) — e por isso enxerga o que só aparece depois de dois ou mais cortes.

O exemplo clássico é a **interação**. Tome X_1 e X_2 independentes e uniformes em $[-1, 1]$, e $Y = \text{sinal}(X_1 X_2)$, sem ruído, com n observações. A média de Y é zero, e $S_{\text{raiz}} = \sum_i Y_i^2 = n$.

- *Um corte sozinho não rende nada.* Depois de um corte $X_1 \leq t$, os dois lados continuam com média zero, porque, pela independência, $\mathbb{E}[\text{sinal}(X_1 X_2) \mid X_1 \in A] = \mathbb{E}[\text{sinal}(X_1) \mid X_1 \in A] \cdot \mathbb{E}[\text{sinal}(X_2)] = 0$; o mesmo vale para cortes em X_2 . Na população, o ganho de qualquer primeiro corte é exatamente zero; na amostra, é só flutuação. Um critério de parada com qualquer limiar positivo devolve a raiz sozinha.
- *Dois níveis de cortes resolvem tudo.* Cortando X_1 em 0 e depois X_2 em 0 dos dois lados, as quatro folhas são os quadrantes, cada uma com Y constante: RSS zero. Pelo critério de (c), essa subárvore de 4 folhas vence a raiz sempre que $\alpha < n/3$ (ganho n por três folhas a mais) e a de 2 folhas sempre que $\alpha < n/2$.

Quem cresce primeiro e poda depois chega aos quadrantes e os mantém para qualquer α razoável; quem para cedo nunca chega lá. (Se o primeiro corte da árvore gananciosa cair fora do zero — todos empatam, afinal —, ela gasta mais folhas para separar os quadrantes, mas a conclusão não muda: o ramo inteiro rende uma fração fixa de n por folha, e o primeiro corte, sozinho, zero.)

É por isso que crescer e podar usam critérios diferentes de propósito, e por que não se deve confundir o α da poda com um limite de profundidade: limitar a profundidade é, ele próprio, um critério de parada.

Exercício 10. Justificamos o *bagging* com uma proposição de enunciado curto: se $g_1, \dots, g_B$ são não-viesados para $r(\mathbf{x})$, têm a mesma variância $v(\mathbf{x})$ e são **não-correlacionados**, então a média $\bar{g} = \frac{1}{B} \sum_b g_b$ tem risco $\text{Var}(Y \mid \mathbf{x}) + v(\mathbf{x})/B$, que nunca passa do risco $\text{Var}(Y \mid \mathbf{x}) + v(\mathbf{x})$ de cada g_b .

Proposições com hipóteses só ficam úteis quando se sabe o que acontece ao violá-las — e, no caso do *bagging*, uma delas é violada o tempo todo.

- Identifique as duas condições e explique, para cada uma, o que acontece com a conclusão se ela falhar.
- O *bagging* usa árvores **profundas e não podadas**. Qual das duas condições essa escolha atende? E por que podar as árvores seria contraproducente aqui?
- Na prática as árvores do *bagging* são correlacionadas. Explique a razão — o que elas têm em comum que as faz parecidas — e por que aumentar B não resolve esse problema específico.
- A floresta aleatória sorteia $m < p$ covariáveis candidatas em cada nó. Explique como isso ataca a condição comprometida, qual é o preço pago na outra, e por que essa troca costuma compensar.

Solução

Uma conta prepara o exercício todo. Fixe $\mathbf{x}$ e suponha que os $g_b(\mathbf{x})$ tenham a mesma esperança $r(\mathbf{x}) + b(\mathbf{x})$ — um viés comum $b(\mathbf{x})$ —, a mesma variância v e correlação ρ dois a dois, e que a resposta nova Y seja independente deles. A decomposição viés-variância da Aula 01 e a variância de uma soma dão

$$\begin{aligned}\mathbb{E}[(Y - \bar{g}(\mathbf{x}))^2] &= \text{Var}(Y \mid \mathbf{x}) + b(\mathbf{x})^2 + \underbrace{\frac{1}{B^2} (Bv + B(B-1)\rho v)}_{\text{Var}(\bar{g}(\mathbf{x}))} \\ &= \text{Var}(Y \mid \mathbf{x}) + b(\mathbf{x})^2 + \rho v + \frac{1-\rho}{B} v.\end{aligned}$$

A proposição é o caso $b = 0$ e $\rho = 0$. Cada hipótese que falha deixa uma marca nessa fórmula.

(a) As duas condições são (i) **não viesamento** e (ii) **não correlação**. (A de variância comum é técnica: sem ela a conta muda de forma, não de conclusão.)

Se (i) falha, a média herda o viés inteiro: $\mathbb{E}[\bar{g}(\mathbf{x})] = r(\mathbf{x}) + b(\mathbf{x})$. Promediar reduz variância, mas **não corrige viés** — a média de mil estimadores enviesados é igualmente enviesada. A comparação com cada g_b sobrevive, porque o $b(\mathbf{x})^2$ aparece dos dois lados; o que se perde é o piso: com $B \rightarrow \infty$, o risco desce até $\text{Var}(Y \mid \mathbf{x}) + b(\mathbf{x})^2$, e não até $\text{Var}(Y \mid \mathbf{x})$. Se (ii) falha, com $\rho > 0$, a variância da média passa a ser $\rho v + (1-\rho)v/B$. Ela continua não passando de v , mas **estaciona num piso** ρv em vez de ir a zero: B só mata o segundo termo.

(b) Atende a condição (i). Árvores profundas são muito flexíveis: acompanham r de perto e têm viés baixo, ao custo de variância alta. E variância é justamente o que a média sabe reduzir.

Sob as hipóteses da proposição, podar seria contraproducente pela própria fórmula acima. A poda introduz viés para reduzir variância; mas, no risco da média, o viés entra inteiro, como $b(\mathbf{x})^2$, enquanto a variância que a poda economizaria entra dividida por B — e, com B grande, a média já a elimina sem custo nenhum. Seria pagar viés por um benefício que se tem de graça. Daí a regra: deixe cada árvore ser instável, e deixe a média estabilizar.

(c) As árvores do *bagging* são ajustadas em amostras bootstrap do **mesmo** conjunto de dados, e todas enxergam **todas** as p covariáveis em todos os nós. Se há uma covariável fortemente preditiva, quase todas a escolhem no primeiro corte; e, como tudo o que vem abaixo depende do primeiro corte, árvores que começam igual continuam parecidas. Elas erram juntas — e errar junto é exatamente o que $\rho > 0$ significa.

Aumentar B não resolve porque o piso ρv **não depende de B** . Acrescentar árvores só encolhe $(1-\rho)v/B$, que depois de algumas dezenas delas já é pequeno: passado certo ponto, cada árvore nova custa tempo de computação e não compra quase nada.

(d) A floresta ataca o ρ . Sorteando $m < p$ candidatas por nó, ela impede que a covariável dominante seja usada sempre: numa fração $1 - m/p$ dos nós, ela nem está disponível, e a árvore é obrigada a olhar para outra coisa. As árvores passam a divergir na estrutura, ρ cai, e o piso ρv cai junto.

O preço é pago na **outra condição, a (i)**. Uma árvore proibida de usar a melhor covariável em parte dos nós aproxima r pior: o **viés** de cada árvore sobe — e, pelo item (a), a floresta o herda inteiro, porque média nenhuma corrige viés. (Cada árvore também fica um pouco mais instável, e v sobe; mas esse aumento, a queda de ρ absorve com folga.)

A troca compensa enquanto o piso cair mais do que o viés² subir. Com B grande, o que sobra da fórmula é $\text{Var}(Y \mid \mathbf{x}) + b(\mathbf{x})^2 + \rho v$: diminuir m desce o terceiro termo e sobe o segundo. No começo, o terceiro cai depressa; com m pequeno demais, o viés passa a

dominar. É o que o Exercício 2 da Lista prática 05 mede: de $m = p/3$ para $m = 0,15p$ o ρ continua caindo, e o erro piora. Por isso m é um hiperparâmetro, a escolher por validação cruzada, e $m \approx p/3$ em regressão é um ponto de partida — não uma verdade.

Aula 06 — Pré-processamento e *Pipelines*

Exercício 11. Um colega recebeu um banco de dados em que a coluna **renda** está em reais e a coluna **altura** em metros, e pergunta se precisa padronizar antes de ajustar. A resposta honesta é "depende do método" — e o critério que decide cabe numa pergunta: **o método soma coisas vindas de colunas diferentes?**

Se soma, as unidades precisam ser comparáveis, e trocar uma delas estraga a comparação. Se não soma, a unidade é irrelevante.

- (a) Para cada método abaixo, diga se multiplicar uma única coluna por 1000 **muda** ou **não muda** a predição, justificando em uma linha onde está — ou onde não está — a soma sobre colunas.
- (i) Mínimos quadrados ordinários.
 - (ii) Regressão Ridge com $\lambda > 0$ fixo.
 - (iii) Árvore de regressão.
 - (iv) Floresta aleatória.
 - (v) KNN com k fixo.
- (b) Entre os que mudam, qual você espera que seja o mais afetado, e por quê? Compare o *modo* como a escala entra em cada um.
- (c) Outro colega ajustou o Lasso a dados padronizados, com λ escolhido por validação cruzada. Em seguida multiplicou por 1000 a coluna de maior efeito sobre Y , reajustou com o *mesmo* λ , e o erro quadrático médio no conjunto de teste *diminuiu*. Ele conclui que é melhor não padronizar. Explique por que a reescala pode ter ajudado e por que a conclusão não se sustenta.

Solução

Uma única mudança de variáveis resolve de uma vez os três métodos lineares. Seja $c = 1000$, e suponha que a coluna reescalada é a primeira: os dados novos são $\tilde{\mathbf{X}} = \mathbf{X}D$, com $D = \text{diag}(c, 1, \dots, 1)$. Para um vetor γ de coeficientes nos dados novos, escreva $\beta = D\gamma$, isto é, $\beta_1 = c\gamma_1$ e $\beta_j = \gamma_j$ para $j \geq 2$. Então $\tilde{\mathbf{X}}\gamma = \mathbf{X}\beta$: é o *mesmo ajuste*, escrito em outra unidade, e o RSS não muda. Já as penalidades mudam:

$$\sum_j \gamma_j^2 = \frac{\beta_1^2}{c^2} + \sum_{j \geq 2} \beta_j^2, \quad \sum_j |\gamma_j| = \frac{|\beta_1|}{c} + \sum_{j \geq 2} |\beta_j|.$$

Ou seja: **reescalar a coluna 1 equivale a trocar o peso dela na penalidade** — por $1/c^2 = 10^{-6}$ no Ridge, por $1/c = 10^{-3}$ no Lasso — e deixar todo o resto igual. Onde não há penalidade, não há o que mudar.

(a) Só dois mudam: o Ridge e o KNN.

- (i) **MQO: não muda.** Sem penalidade, o problema reescalado é o mesmo problema: o coeficiente da coluna vira $\beta_1/1000$, o produto $\beta_1 x_1$ fica igual, e as predições também. A predição *soma* sobre as colunas, $\sum_j \beta_j x_j$, mas cada parcela é um número na

unidade de Y , que o coeficiente ajusta livremente; nada na função-objetivo compara grandezas de colunas diferentes com pesos fixos.

- (ii) **Ridge ($\lambda > 0$): muda.** A penalidade $\lambda \sum_j \beta_j^2$ soma, com o mesmo peso, coeficientes de colunas diferentes, e cada coeficiente carrega a unidade da sua coluna. Pela conta acima, a coluna reescalada passa a ser penalizada com peso $\lambda \cdot 10^{-6}$.
- (iii) **Árvore: não muda.** Ela só pergunta " $x_j \leq t$ ", e $\{x_1 \leq t\} = \{1000 x_1 \leq 1000 t\}$: as partições que se consegue formar são as mesmas, com o mesmo RSS cada uma, e o corte escolhido é o mesmo, com o limiar multiplicado por 1000.
- (iv) **Floresta aleatória: não muda.** Cada árvore é indiferente à escala, e os sorteios — das amostras bootstrap e das covariáveis candidatas — não olham os valores. Com os mesmos sorteios, cada árvore sai idêntica, e a média também.
- (v) **KNN com k fixo: muda.** A distância $\sum_j (x_{ij} - x_{lj})^2$ soma, com o mesmo peso, diferenças medidas em unidades diferentes; a parcela da coluna reescalada fica multiplicada por 10^6 .

(b) O KNN. O tamanho do fator não distingue os dois — nos dois ele chega a 10^6 —; o que distingue é *o que a escala controla* em cada um.

No Ridge, a escala controla *quanto um coeficiente é penalizado*. Pela conta do início, o novo ajuste é o de um Ridge em que a coluna reescalada está praticamente isenta de encolhimento. Todas as colunas continuam sendo usadas, e a mudança é limitada: o pior que pode acontecer é aquele coeficiente deixar de ser encolhido — e a diferença some quando $\lambda \rightarrow 0$, porque aí o Ridge vira o MQO, que não muda.

No KNN, a escala controla *quem entra na média*. A distância passa a ser

$$10^6 (x_{i1} - x_{l1})^2 + \sum_{j \geq 2} (x_{ij} - x_{lj})^2,$$

e basta que duas observações difiram um pouco em x_1 para essa parcela dominar todas as outras. Os vizinhos passam a ser, na prática, os de um KNN que só enxerga a coluna reescalada: as outras colunas não ficam só menos importantes — saem da conta, e a informação que carregavam se perde. Nenhum k a recupera.

(c) *Por que a reescala pode ter ajudado.* Pela conta do início, o Lasso nos dados reescalados é o Lasso original com a penalidade da coluna reescalada multiplicada por 10^{-3} : justamente a coluna que mais importa ficou quase isenta de encolhimento. E encolher um coeficiente grande é quase só viés. No caso ortonormal, em que o Lasso tem fórmula fechada, um coeficiente com $|\hat{\beta}_j|$ bem acima de $\lambda/2$ é deslocado de exatamente $\lambda/2$: um deslocamento fixo, que não reduz variância nenhuma e acrescenta $\lambda^2/4$ ao erro quadrático daquele coeficiente. Tirar esse viés pode baixar o erro de teste — pode, não precisa.

Por que a conclusão não se sustenta. O resultado dependeu de *qual* coluna foi reescalada. Faça o mesmo com uma coluna *irrelevante* e o efeito tende a se inverter: quase isenta da penalidade, ela deixa de ser zerada, recebe um coeficiente ajustado ao ruído, e o erro de teste piora. Além disso, a comparação usou o mesmo λ , escolhido por validação cruzada para os dados padronizados; nos dados reescalados, nem é esse o λ que a validação cruzada escolheria.

O ponto de fundo é que, nos dois casos, quem decidiu quanto regularizar cada coluna não foi o analista: foi a **unidade de medida** em que o dado chegou. Um procedimento cujo resultado depende de a coluna ter sido anotada em metros ou em milímetros não está bem definido, e ter dado certo desta vez não muda isso. Se a conclusão é que aquela coluna merece menos penalidade, essa é uma decisão a tomar com os dados — por validação cruzada —, e não a deixar por conta da unidade.