

Lista de Revisão — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aulas 01 a 06 — Fundamentos, Regressão, Validação Cruzada, KNN, Árvores e Pipelines

Treze exercícios para revisar o Bloco I antes da avaliação. Eles não repetem os das listas de cada aula — a maior parte pede que você *demonstre* resultados que as notas usaram sem demonstrar, ou que ligue duas aulas vistas separadamente.

Não há ordem obrigatória, mas os exercícios de uma mesma aula se apoiam uns nos outros, e vários apontam para exercícios das listas anteriores — quando isso acontece, o enunciado avisa.

Salvo indicação em contrário, $(\mathbf{X}, Y)$ é um par aleatório com distribuição P , $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ é a função de regressão, $\mathcal{D} = \{(\mathbf{X}_i, Y_i)\}_{i=1}^n$ é a amostra de treino (i.i.d.), p é o número de covariáveis e a perda é a quadrática.

Aula 01 — Introdução

Exercício 1 — o melhor preditor de todos, e o que sobra depois dele. A Aula 01 abriu com uma afirmação forte: de todas as funções que você poderia usar para prever Y a partir de $\mathbf{X}$, a melhor é a função de regressão $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$. Não a melhor entre as lineares, nem a melhor entre as que o seu método consegue produzir — a melhor, ponto.

Uma afirmação dessas pede demonstração, e ela é mais curta do que parece. Todo o trabalho está num truque que você vai reencontrar várias vezes no curso: somar e subtrair a quantidade certa dentro de um quadrado.

- (a) Seja $g : \mathbb{R}^p \rightarrow \mathbb{R}$ uma função qualquer com $\mathbb{E}[g(\mathbf{X})^2] < \infty$. Some e subtraia $r(\mathbf{X})$ dentro do quadrado e mostre que

$$\mathbb{E}[(Y - g(\mathbf{X}))^2] = \mathbb{E}[(Y - r(\mathbf{X}))^2] + \mathbb{E}[(r(\mathbf{X}) - g(\mathbf{X}))^2].$$

O trabalho está em mostrar que o termo cruzado desaparece; condicione em $\mathbf{X}$ e pergunte-se o que $\mathbb{E}[Y - r(\mathbf{X}) \mid \mathbf{X}]$ vale.

- (b) Olhe para a identidade que você acabou de provar e responda: por que ela mostra que r é o minimizador? Em seguida, mostre que o valor mínimo é $R(r) = \mathbb{E}[\text{Var}(Y \mid \mathbf{X})]$.
- (c) Esse mínimo tem nome: **erro irreduzível**. O nome sugere que não há como baixá-lo, e é verdade — mas a razão não é que os métodos atuais sejam ruins. Explique de onde vem essa impossibilidade, e diga o que teria de mudar *no problema* para o número diminuir.
- (d) Na Lista Teórica 01 você mostrou que o melhor preditor *constante* tem risco $\text{Var}(Y)$. Use a identidade de (a) para escrever a diferença $\text{Var}(Y) - R(r)$ como uma esperança, e interprete: que pergunta prática essa quantidade responde?

Solução

- (a) Escreva a diferença em duas partes,

$$Y - g(\mathbf{X}) = \underbrace{(Y - r(\mathbf{X}))}_{\text{o que ninguém prevê}} + \underbrace{(r(\mathbf{X}) - g(\mathbf{X}))}_{\text{o quanto } g \text{ erra o alvo}},$$

e eleve ao quadrado:

$$(Y - g(\mathbf{X}))^2 = (Y - r(\mathbf{X}))^2 + 2(Y - r(\mathbf{X}))(r(\mathbf{X}) - g(\mathbf{X})) + (r(\mathbf{X}) - g(\mathbf{X}))^2.$$

Tomando esperança, o que precisa ser mostrado é que o termo do meio some.

Condicione em $\mathbf{X}$. Feito isso, $r(\mathbf{X}) - g(\mathbf{X})$ vira uma constante — as duas são funções de $\mathbf{X}$, e $\mathbf{X}$ está fixo — e portanto sai de dentro da esperança condicional:

$$\mathbb{E}[(Y - r(\mathbf{X}))(r(\mathbf{X}) - g(\mathbf{X}))] = \mathbb{E}[(r(\mathbf{X}) - g(\mathbf{X})) \underbrace{\mathbb{E}[Y - r(\mathbf{X}) \mid \mathbf{X}]}_{=0}].$$

E a esperança que sobrou é zero, porque $\mathbb{E}[Y \mid \mathbf{X}] = r(\mathbf{X})$ é exatamente a definição de r . Sobram os dois quadrados.

(b) A identidade separa o risco de g em duas parcelas, e só a segunda depende de g :

$$R(g) = \underbrace{\mathbb{E}[(Y - r(\mathbf{X}))^2]}_{\text{fixo, não depende de } g} + \underbrace{\mathbb{E}[(r(\mathbf{X}) - g(\mathbf{X}))^2]}_{\geq 0}.$$

Como a segunda é uma esperança de algo não negativo, ela nunca ajuda: o melhor que g pode fazer é anulá-la, e isso acontece exatamente quando $g(\mathbf{X}) = r(\mathbf{X})$ com probabilidade 1. Logo r minimiza, e o mínimo é a primeira parcela.

Para identificá-la, olhe para o que está dentro do quadrado: $Y - r(\mathbf{X}) = Y - \mathbb{E}[Y \mid \mathbf{X}]$ é o desvio de Y em relação à sua própria média condicional. A lei da esperança total dá

$$R(r) = \mathbb{E}[(Y - \mathbb{E}[Y \mid \mathbf{X}])^2] = \mathbb{E}[\mathbb{E}[(Y - \mathbb{E}[Y \mid \mathbf{X}])^2 \mid \mathbf{X}]] = \mathbb{E}[\text{Var}(Y \mid \mathbf{X})].$$

(c) A expressão $\mathbb{E}[\text{Var}(Y \mid \mathbf{X})]$ não menciona g nenhuma. Ela é uma propriedade da **distribuição conjunta de** $(\mathbf{X}, Y)$ — do problema, não do método.

O que ela mede é isto: fixe um valor $\mathbf{x}$ das covariáveis; entre todos os indivíduos que têm exatamente esse $\mathbf{x}$, quanto Y ainda varia? Se dois pacientes com idade, peso e exames idênticos ainda assim têm desfechos diferentes, nenhum algoritmo pode distinguir um do outro — ele recebeu a mesma entrada nos dois casos. Mesmo conhecendo r exatamente, com $n = \infty$ e zero erro de estimação, esse termo permanece.

E é isso que diz o que fazer para baixá-lo: não trocar de modelo, e sim **trocar de $\mathbf{X}$** . Medir uma covariável nova, que explique parte do que hoje é indistinguível. Isso muda o problema, e só mudar o problema resolve.

(d) Aplique a identidade de (a) com $g \equiv \mathbb{E}[Y]$, que é o melhor preditor constante:

$$\underbrace{R(\mathbb{E}[Y])}_{= \text{Var}(Y)} = R(r) + \mathbb{E}[(r(\mathbf{X}) - \mathbb{E}[Y])^2].$$

A esperança que sobrou é a variância de $r(\mathbf{X})$, porque $\mathbb{E}[r(\mathbf{X})] = \mathbb{E}[Y]$ pela lei da esperança total. Logo

$$\text{Var}(Y) - R(r) = \text{Var}(r(\mathbf{X})).$$

A pergunta que isso responde é: **vale a pena usar as covariáveis?** O lado esquerdo é quanto se ganha ao trocar o preditor constante pelo melhor preditor possível. O lado direito diz que esse ganho é exatamente o quanto $r(\mathbf{X})$ varia, isto é, o quanto a resposta esperada muda de um perfil de covariáveis para outro.

Nos dois extremos: se $\text{Var}(r(\mathbf{X})) = 0$, a função de regressão é constante, as covariáveis não carregam informação nenhuma sobre Y , e prever pela média é o melhor que existe — não há modelo a construir. Quanto maior essa variância, maior o prêmio por acertar r .

Exercício 2 — dois riscos com o mesmo nome, e uma barra de erro. A palavra "risco" aparece na Aula 01 com dois sentidos, e a diferença entre eles não é preciosismo: ela decide qual pergunta o seu número está respondendo.

Quando g é tratada como uma função *fixa*, a esperança em $\mathbb{E}[(Y - g(\mathbf{X}))^2]$ percorre só a observação nova $(\mathbf{X}, Y)$. Chamamos isso de **risco condicional**. Quando $g = \hat{g}$ é tratada como aleatória — e ela é, porque foi construída a partir de $\mathcal{D}$ —, a esperança percorre também as amostras de treino possíveis, e temos o **risco esperado**.

- Cada um dos dois oferece uma garantia diferente. Descreva as duas, e diga qual interessa a quem já ajustou um modelo e vai colocá-lo em produção, e qual interessa a quem ainda está escolhendo entre dois métodos.
- Você separou um conjunto de teste de m observações que não participou de nada, e calculou $\hat{R}(\hat{g}) = \frac{1}{m} \sum_{k=1}^m W_k$, com $W_k = (Y_k - \hat{g}(\mathbf{X}_k))^2$. Qual dos dois riscos esse número estima? Para responder, pergunte-se o que está fixo e o que varia no momento em que você faz a conta.
- Um conjunto de teste permite algo que a validação cruzada não permite: uma barra de erro honesta. Explique por que os W_k são i.i.d. e escreva o intervalo de confiança aproximado de 95% que o Teorema Central do Limite fornece.
- Num teste com $m = 400$ você obteve $\hat{R} = 2,50$ e $\hat{\sigma}^2 = 16,0$. Calcule o intervalo. Um colega, no mesmo conjunto, obteve 2,20 com outro método e anuncia que o dele é melhor. Ele pode? Justifique.

Solução

(a) O **risco condicional** é uma garantia sobre *aquela função específica*: se eu usar este $\hat{g}$, já ajustado, em observações novas, meu erro quadrático médio esperado é tanto.

O **risco esperado** é uma garantia sobre o *procedimento*: se eu sortear uma amostra de treino, rodar este método e usar o que sair, meu erro esperado é tanto. A esperança percorre também os treinos possíveis.

Quem vai pôr o modelo em produção quer o **condicional**. O modelo dele é um só, já existe, não vai ser reajustado — saber como se comportam os modelos que aquele método *costuma* produzir não paga as contas.

Quem está comparando métodos quer o **esperado**. A pergunta ali é "qual deles tende a produzir bons modelos", e uma rodada de sorte com um método ruim não deveria decidir a escolha.

(b) Estima o **risco condicional**.

No momento da conta, $\hat{g}$ já foi ajustado e não muda: é uma função fixa. O que varia de uma parcela para outra é apenas o par $(\mathbf{X}_k, Y_k)$ sorteado para o teste. A aleatoriedade do treino — que outra amostra teria dado outro $\hat{g}$ — não entra na conta em momento nenhum, porque o treino aconteceu antes e não é repetido.

Dito de outro modo: para estimar o risco *esperado* você teria de repetir o processo inteiro, sorteando vários treinos, e não é o que um único conjunto de teste faz.

(c) Condicionalmente a $\hat{g}$ — que é a situação, por (b) — cada $W_k = (Y_k - \hat{g}(\mathbf{X}_k))^2$ é função de um único par $(\mathbf{X}_k, Y_k)$. Esses pares são i.i.d. entre si e independentes do treino, e a mesma função $\hat{g}$ é aplicada a todos. Logo os W_k são i.i.d., com média $R(\hat{g})$.

Como $\hat{R}$ é média de i.i.d., o Teorema Central do Limite se aplica e dá

$$\hat{R}(\hat{g}) \pm 2\sqrt{\hat{\sigma}^2/m}, \quad \hat{\sigma}^2 = \frac{1}{m} \sum_{k=1}^m (W_k - \bar{W})^2.$$

Há uma hipótese fazendo todo o trabalho aqui: o teste não participou de nada. Se ele

tivesse sido usado para escolher qualquer coisa, os W_k deixariam de ser independentes do $\hat{g}$ e o intervalo perderia o sentido.

(d) A margem é

$$2\sqrt{16,0/400} = 2\sqrt{0,04} = 2 \times 0,2 = 0,4,$$

e o intervalo é

$$2,50 \pm 0,40 = [2,10; 2,90].$$

Ele não pode. O valor dele, 2,20, cai **dentro** do intervalo: a diferença de 0,30 é menor que a incerteza da própria medição, e um outro conjunto de teste do mesmo tamanho poderia perfeitamente inverter a ordem.

O que se pode afirmar é mais modesto, e a formulação importa: *este conjunto de teste não distinguiu os dois métodos*. Isso não é o mesmo que dizer que eles são equivalentes — talvez sejam diferentes e o teste seja pequeno demais para perceber.

Daí sai também uma decisão de projeto. A margem encolhe com $\sqrt{m}$: para cortá-la pela metade é preciso quadruplicar o teste. Como estimar risco é uma tarefa muito mais barata do que construir um bom preditor, com n grande vale reservar bem menos que os 30% de praxe — e com n pequeno vale desconfiar de qualquer ranking apertado.

Aula 02 — Regressão Linear e Regularização

Exercício 3 — de onde saem as fórmulas do caso ortonormal. As notas da Aula 02 apresentam duas fórmulas prontas para o caso ortonormal, $\mathbb{X}^\top \mathbb{X} = \mathbb{I}$, e não as derivam. São elas que explicam a frase "o Ridge encolhe e o Lasso zera", e o exercício é preencher essa lacuna.

Use as definições da aula, **sem** fator $\frac{1}{2}$ no RSS:

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \sum_j \beta_j^2 \right\}, \quad \hat{\beta}^{\text{lasso}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \sum_j |\beta_j| \right\}.$$

(a) Comece pelo passo que torna tudo possível. Supondo $\mathbb{X}^\top \mathbb{X} = \mathbb{I}$, mostre que o estimador de mínimos quadrados é $\hat{\beta} = \mathbb{X}^\top \mathbf{y}$ e que

$$\|\mathbf{y} - \mathbb{X}\beta\|^2 = \|\mathbf{y}\|^2 - \|\hat{\beta}\|^2 + \sum_{j=1}^p (\beta_j - \hat{\beta}_j)^2.$$

Explique por que essa identidade faz o problema **se separar** em p problemas de uma variável — e por que é justamente isso que falha quando as colunas não são ortonormais.

(b) Com a separação em mãos, derive $\hat{\beta}_j^{\text{ridge}} = \hat{\beta}_j / (1 + \lambda)$.

(c) Agora o Lasso. A dificuldade nova é que $|\beta_j|$ não é derivável em zero, então não dá para igualar a derivada a zero e pronto: trate separadamente as regiões $\beta_j > 0$, $\beta_j < 0$ e o ponto $\beta_j = 0$. Derive $\hat{\beta}_j^{\text{lasso}} = \text{sin}(\hat{\beta}_j)(|\hat{\beta}_j| - \lambda/2)_+$ e diga qual é a condição exata que leva um coeficiente a zero.

(d) O limiar deu $\lambda/2$, e não λ . De onde veio esse 2? Diga o que mudaria nas duas fórmulas se a aula tivesse definido o RSS com um $\frac{1}{2}$ na frente, e que lição prática isso deixa.

Solução

(a) Com $\mathbb{X}^\top \mathbb{X} = \mathbb{I}$, as equações normais dão diretamente $\hat{\beta} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{y} = \mathbb{X}^\top \mathbf{y}$. Agora expanda o RSS, usando essa igualdade e a ortonormalidade:

$$\|\mathbf{y} - \mathbb{X}\beta\|^2 = \mathbf{y}^\top \mathbf{y} - 2\beta^\top \underbrace{\mathbb{X}^\top \mathbf{y}}_{=\hat{\beta}} + \beta^\top \underbrace{\mathbb{X}^\top \mathbb{X}}_{=\mathbb{I}} \beta = \|\mathbf{y}\|^2 - 2\beta^\top \hat{\beta} + \|\beta\|^2.$$

Os dois últimos termos pedem um completar quadrados:

$$-2\beta^\top \hat{\beta} + \|\beta\|^2 = \|\beta - \hat{\beta}\|^2 - \|\hat{\beta}\|^2,$$

o que dá a identidade do enunciado.

O que ela tem de especial: o único termo que depende de β é $\sum_j (\beta_j - \hat{\beta}_j)^2$, e nessa soma a j -ésima parcela envolve *apenas* β_j . Como as penalidades $\sum_j \beta_j^2$ e $\sum_j |\beta_j|$ também são somas coordenada a coordenada, o problema inteiro vira p problemas escalares que não conversam entre si — e problema escalar a gente resolve derivando.

Quando as colunas *não* são ortonormais, $\mathbb{X}^\top \mathbb{X}$ tem termos fora da diagonal, aparecem produtos $\beta_j \beta_\ell$ com $j \neq \ell$, e a separação morre. É exatamente por isso que o Lasso não tem solução fechada no caso geral: a ortonormalidade é uma hipótese muito forte, não uma simplificação inocente.

(b) O problema escalar é minimizar $h(\beta) = (\beta - \hat{\beta}_j)^2 + \lambda\beta^2$, que é derivável em toda a reta:

$$h'(\beta) = 2(\beta - \hat{\beta}_j) + 2\lambda\beta = 0 \implies \beta(1 + \lambda) = \hat{\beta}_j \implies \beta = \frac{\hat{\beta}_j}{1 + \lambda}.$$

Como $h'' = 2(1 + \lambda) > 0$, é mínimo.

Leia o resultado: o Ridge **multiplica** por um fator $1/(1 + \lambda) < 1$. Isso encolhe proporcionalmente — quem era grande perde mais em valor absoluto — e nunca zera, porque o fator só alcança zero no limite $\lambda \rightarrow \infty$.

(c) Agora $h(\beta) = (\beta - \hat{\beta}_j)^2 + \lambda|\beta|$. Analise por regiões.

Onde $\beta > 0$, temos $|\beta| = \beta$ e $h'(\beta) = 2(\beta - \hat{\beta}_j) + \lambda$, que zera em $\beta = \hat{\beta}_j - \lambda/2$. Só que essa raiz precisa cair na região em que a conta vale, isto é, precisa ser positiva — o que exige $\hat{\beta}_j > \lambda/2$.

Onde $\beta < 0$, temos $|\beta| = -\beta$ e $h'(\beta) = 2(\beta - \hat{\beta}_j) - \lambda$, que zera em $\beta = \hat{\beta}_j + \lambda/2$, admissível se $\hat{\beta}_j < -\lambda/2$.

E se $|\hat{\beta}_j| \leq \lambda/2$? Aí nenhuma das duas raízes cai na sua própria região: a candidata positiva sai negativa e vice-versa. Como h é convexa e contínua, o mínimo existe, e só pode estar no único ponto que sobrou — $\beta = 0$, justamente onde a função não é derivável. (Em linguagem de subgradiente: 0 é mínimo quando $0 \in -2\hat{\beta}_j + \lambda[-1, 1]$, que é exatamente a condição $|\hat{\beta}_j| \leq \lambda/2$.)

Juntando os três casos,

$$\hat{\beta}_j^{\text{lasso}} = \text{sinal}(\hat{\beta}_j)(|\hat{\beta}_j| - \lambda/2)_+,$$

e a condição exata para zerar é $|\hat{\beta}_j| \leq \lambda/2$.

Compare com (b) e a diferença salta: o Lasso **subtrai** uma constante em vez de multiplicar por um fator. Todo mundo encolhe pela mesma quantidade, $\lambda/2$, e quem era menor que isso em módulo não sobrevive ao deslocamento. É o *soft thresholding*, e é a razão algébrica de o Lasso fazer seleção de variáveis.

(d) O 2 vem da derivada do quadrado. Derivando $(\beta - \hat{\beta}_j)^2$ aparece um fator 2; derivando $\lambda|\beta|$ aparece só $\pm\lambda$. Ao isolar β dividimos tudo por 2, e o λ vira $\lambda/2$.

Se o RSS levasse um $\frac{1}{2}$ na frente — e a penalidade também, como é comum em outros textos —, o fator 2 sumiria das duas derivadas e o limiar do Lasso viraria λ , com o Ridge continuando em $\hat{\beta}_j/(1 + \lambda)$.

A lição prática é que o **limiar depende da convenção**, não da matemática. Antes de comparar um λ do seu caderno com um λ de um artigo ou de uma biblioteca, confira qual RSS cada um está minimizando. É o mesmo tipo de cuidado que a Aula 02 pede ao lembrar que o Ridge e o Lasso do `scikit-learn` diferem entre si por um fator n .

Exercício 4 — o que o MQO estima quando a linearidade é falsa. Circula por aí a ideia de que a regressão linear "só vale se o modelo estiver correto". A Aula 02 mostra que isso é impreciso: o MQO converge para alguma coisa bem definida mesmo quando r não é linear coisa nenhuma.

Essa coisa é o **melhor preditor linear**,

$$\beta^* = \arg \min_{\beta} \mathbb{E}[(Y - \beta^\top \mathbf{X})^2],$$

que existe sempre que $\Sigma = \mathbb{E}[\mathbf{X}\mathbf{X}^\top]$ é bem definida e invertível — *sem* supor nada sobre a forma de r .

- Derive $\beta^* = \Sigma^{-1}\alpha$, onde $\alpha = \mathbb{E}[Y\mathbf{X}]$. É o mesmo cálculo das equações normais, com esperanças no lugar de somas.
- O estimador de mínimos quadrados pode ser escrito como $\hat{\beta} = \hat{\Sigma}^{-1}\hat{\alpha}$, com $\hat{\Sigma} = \frac{1}{n} \sum_i \mathbf{X}_i \mathbf{X}_i^\top$ e $\hat{\alpha} = \frac{1}{n} \sum_i Y_i \mathbf{X}_i$. Olhe para essas duas expressões e diga o que elas são, estatisticamente. Em seguida, explique por que $\hat{\beta} \rightarrow \beta^*$ em probabilidade sem que se precise supor linearidade em lugar nenhum.
- Todo teorema garante uma coisa e deixa de garantir outra. Enuncie as duas, com cuidado. Em particular: o resultado diz que o risco de $\hat{\beta}$ é pequeno?
- Um colega ajusta uma regressão linear a dados em que r é visivelmente curva e conclui: "o coeficiente deu 2,3, logo aumentar x_1 em uma unidade aumenta Y em 2,3". Separe o que é leitura legítima de β^* do que não é.

Solução

- Expanda o objetivo, tratando as esperanças como constantes:

$$Q(\beta) = \mathbb{E}[(Y - \beta^\top \mathbf{X})^2] = \mathbb{E}[Y^2] - 2\beta^\top \underbrace{\mathbb{E}[Y\mathbf{X}]}_{\alpha} + \beta^\top \underbrace{\mathbb{E}[\mathbf{X}\mathbf{X}^\top]}_{\Sigma} \beta.$$

O gradiente é $\nabla Q = -2\alpha + 2\Sigma\beta$, que se anula quando $\Sigma\beta = \alpha$, ou seja, $\beta^* = \Sigma^{-1}\alpha$. A Hessiana é 2Σ , definida positiva por hipótese: é mínimo, e é único.

A conta é a mesma das equações normais da aula, com $\mathbb{E}[\mathbf{X}\mathbf{X}^\top]$ no lugar de $\frac{1}{n}\mathbb{X}^\top\mathbb{X}$ e $\mathbb{E}[Y\mathbf{X}]$ no lugar de $\frac{1}{n}\mathbb{X}^\top\mathbf{y}$. É o mesmo problema, escrito na população em vez de na amostra.

- Tanto $\hat{\Sigma}$ quanto $\hat{\alpha}$ são **médias amostrais** de variáveis i.i.d.: a primeira das matrizes $\mathbf{X}_i \mathbf{X}_i^\top$, a segunda dos vetores $Y_i \mathbf{X}_i$. Essa é a observação que resolve o item.

Pela lei dos grandes números, médias amostrais convergem para as esperanças correspondentes: $\hat{\Sigma} \rightarrow \Sigma$ e $\hat{\alpha} \rightarrow \alpha$ em probabilidade. Como inverter matriz e multiplicar são operações contínuas onde Σ é invertível, o teorema de Mann–Wald (continuous mapping)

transporta a convergência:

$$\hat{\beta} = \hat{\Sigma}^{-1} \hat{\alpha} \rightarrow \Sigma^{-1} \alpha = \beta^*.$$

Em nenhum passo foi preciso supor $r(\mathbf{x}) = \beta^\top \mathbf{x}$. A definição de β^* é um problema de minimização que faz sentido para qualquer distribuição P ; o que a linearidade de r acrescentaria seria a coincidência $\beta^{*\top} \mathbf{x} = r(\mathbf{x})$ — uma coincidência agradável, mas dispensável para a convergência.

(c) Garante: com n grande, o MQO acerta a melhor aproximação linear disponível. Ele não fica vagando nem depende de sorte da amostra; converge para um alvo bem definido, e esse alvo é o melhor que a classe das funções lineares tem a oferecer.

Não garante: que esse alvo seja bom. Se r for muito curva, o melhor preditor linear pode ter risco alto, e o teorema apenas assegura que chegaremos perto dele — perto de uma aproximação ruim continua sendo ruim.

Na linguagem da Aula 01: o teorema controla a **variância**, porque o erro de estimação some com n , e não diz absolutamente nada sobre o **viés de aproximação** $\mathbb{E}[(r(\mathbf{X}) - \beta^{*\top} \mathbf{X})^2]$, que é o preço fixo de ter escolhido uma classe rígida. "Convergir para o alvo certo" e "o alvo certo ser bom" são afirmações independentes, e só a primeira foi demonstrada.

(d) O erro é ler β^* como efeito causal — ou mesmo como descrição local de r .

O que se pode dizer é que 2,3 é a inclinação da reta que *melhor aproxima* r no sentido de erro quadrático médio, ponderada pela distribuição de $\mathbf{X}$. É um resumo global, e nada além disso.

Duas consequências mostram por que a frase do colega não se sustenta. Primeira: com r curva, a inclinação verdadeira $\partial r / \partial x_1$ muda de ponto para ponto, e 2,3 é uma espécie de média dela — podendo não coincidir com a inclinação em ponto nenhum. Segunda, e mais desconfortável: se ele coletar a mesma medida noutra população, com outra faixa de x_1 , o β^* muda, porque a ponderação mudou — ainda que r seja exatamente a mesma função do mundo. Um número que depende de onde você coletou não descreve um mecanismo.

Exercício 5 — a Ridge como moda a posteriori. A Aula 02 menciona que o Ridge tem uma leitura bayesiana: ele é a moda a posteriori sob uma priori gaussiana. A afirmação é mais do que curiosidade — ela dá um significado concreto ao λ , que até aqui era só um botão a girar. Suponha o modelo

$$\mathbf{y} | \beta \sim N(\mathbb{X}\beta, \sigma^2 \mathbb{I}), \quad \beta \sim N(\mathbf{0}, \sigma_\beta^2 \mathbb{I}),$$

com σ^2 e σ_β^2 conhecidos.

- (a)** Escreva a densidade a posteriori de β a menos de constante multiplicativa e mostre que maximizá-la equivale a minimizar

$$\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\beta\|^2 + \frac{1}{2\sigma_\beta^2} \|\beta\|^2.$$

O caminho é o de sempre: passar ao logaritmo transforma produto em soma, e maximizar em minimizar.

- (b)** Compare o que você obteve com a definição do Ridge da aula e identifique λ em função de σ^2 e σ_β^2 . Cuidado com o fator que precisa ser eliminado antes da comparação.
- (c)** Agora a parte interessante: o que a priori está *afirmando* quando $\sigma_\beta^2 \rightarrow \infty$, e quando $\sigma_\beta^2 \rightarrow 0$? Ligue cada resposta ao comportamento do Ridge em $\lambda \rightarrow 0$ e $\lambda \rightarrow \infty$.

- (d) Neste modelo a moda e a média a posteriori coincidem. Para o Lasso a priori correspondente é a de Laplace, e essa coincidência **falha**. Explique por que isso importa na prática — em particular, por que a média a posteriori do Lasso não produz coeficientes exatamente nulos.

Solução

(a) Pelo teorema de Bayes, a posteriori é proporcional ao produto da verossimilhança pela priori:

$$\pi(\boldsymbol{\beta} \mid \mathbf{y}) \propto f(\mathbf{y} \mid \boldsymbol{\beta}) \pi(\boldsymbol{\beta}) \propto \exp \left\{ -\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 \right\} \cdot \exp \left\{ -\frac{1}{2\sigma_\beta^2} \|\boldsymbol{\beta}\|^2 \right\}.$$

As constantes de normalização das duas gaussianas não dependem de $\boldsymbol{\beta}$ e por isso podem ser absorvidas no $\propto$.

Maximizar uma função positiva é o mesmo que maximizar seu logaritmo, e o logaritmo de um produto de exponenciais é a soma dos expoentes:

$$\log \pi(\boldsymbol{\beta} \mid \mathbf{y}) = \text{const} - \frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 - \frac{1}{2\sigma_\beta^2} \|\boldsymbol{\beta}\|^2.$$

Maximizar isso é minimizar o simétrico dos dois termos que dependem de $\boldsymbol{\beta}$, que é exatamente o objetivo do enunciado.

(b) O objetivo de (a) tem um $1/(2\sigma^2)$ na frente do primeiro termo, e a definição do Ridge não tem fator nenhum ali. Multiplique tudo por $2\sigma^2 > 0$ — o que não altera o minimizador, por ser constante positiva:

$$\|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \frac{\sigma^2}{\sigma_\beta^2} \|\boldsymbol{\beta}\|^2.$$

Agora a comparação é imediata, e

$$\lambda = \frac{\sigma^2}{\sigma_\beta^2}$$

(c) Quando $\sigma_\beta^2 \rightarrow \infty$, a priori fica **difusa**: ela espalha massa por toda parte e não expressa preferência alguma por coeficientes pequenos. Em outras palavras, ela não afirma nada. Correspondentemente $\lambda \rightarrow 0$ e o Ridge degenera no MQO: os dados decidem sozinhos, com viés baixo e variância alta.

Quando $\sigma_\beta^2 \rightarrow 0$, a priori fica **concentrada em zero**: ela afirma, antes de ver dado nenhum, que os coeficientes são praticamente nulos. Correspondentemente $\lambda \rightarrow \infty$ e $\hat{\boldsymbol{\beta}} \rightarrow \mathbf{0}$: viés máximo, variância mínima.

Entre os dois extremos, a fórmula $\lambda = \sigma^2/\sigma_\beta^2$ diz uma coisa bem razoável: regulariza-se mais quando os *dados* são ruidosos (σ^2 grande) ou quando a *crença prévia* é firme (σ_β^2 pequeno). O λ é a razão entre duas incertezas, e escolhê-lo por validação cruzada é, nessa leitura, deixar os dados escolherem a priori que melhor prediz.

(d) Importa porque o que torna o Lasso atraente é a **esparsidade** — coeficientes exatamente nulos, que equivalem a descartar covariáveis — e a esparsidade é propriedade da *moda*, não da média.

Veja por quê. A posteriori do Lasso é uma densidade contínua em $\mathbb{R}^p$, e a massa que uma densidade contínua atribui a um ponto isolado é zero: $\mathbb{P}(\beta_j = 0) = 0$ sob a posteriori. Isso não impede que a *moda* caia exatamente sobre $\beta_j = 0$ — a priori de Laplace tem um bico ali, e o ponto de máximo pode perfeitamente ser um ponto anguloso. É isso que o algoritmo de otimização encontra.

A *média*, porém, integra sobre toda a densidade. E não há razão para uma integral de função contínua dar exatamente zero: ela dá um número pequeno, muito pequeno talvez, mas não nulo.

A consequência prática é direta: se você quer seleção de variáveis, tem de reportar a moda — que é o que o `Lasso` do `scikit-learn` devolve, porque ele resolve um problema de otimização. Quem rodar um amostrador bayesiano e tomar a média das amostras vai obter encolhimento, e nenhum zero, e pode concluir erradamente que "o Lasso não zerou nada".

Aula 03 — Seleção de Modelos e Validação Cruzada

Exercício 6 — o atalho do LOOCV, demonstrado. O LOOCV parece caro: n ajustes, um para cada observação deixada de fora. A Aula 03 enuncia que, para ajustes lineares, um único ajuste basta — e não demonstra. É uma das fórmulas mais bonitas da área, e o exercício é prová-la.

Para um ajuste com matriz de projeção $\mathbf{H} = \mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top$, vale

$$\hat{R}_{\text{LOO}} = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{g}(\mathbf{X}_i)}{1 - h_{ii}} \right)^2,$$

com $\hat{g}$ ajustado em *todos* os dados.

Escreva $\hat{g}(\mathbf{X}_i) = \sum_{\ell} h_{i\ell} Y_{\ell}$ — é isso que "ajuste linear" quer dizer: a predição é combinação linear das respostas, com pesos que dependem só de $\mathbb{X}$. Denote por $\hat{g}_{-i}$ o ajuste feito sem a i -ésima observação.

- (a) *O truque.* Imagine o conjunto de dados em que a resposta Y_i foi trocada por $\tilde{Y}_i = \hat{g}_{-i}(\mathbf{X}_i)$ — isto é, pelo valor que o ajuste sem ela teria previsto ali — mantendo as demais. Argumente que o ajuste linear nesse conjunto modificado devolve exatamente a mesma função $\hat{g}_{-i}$.

A ideia é que $\hat{g}_{-i}$ já minimiza o RSS nas outras $n - 1$ observações, e a parcela nova contribui com zero.

- (b) Use (a) e a linearidade do ajuste para mostrar que

$$\hat{g}_{-i}(\mathbf{X}_i) = \hat{g}(\mathbf{X}_i) + h_{ii}(\tilde{Y}_i - Y_i).$$

- (c) O item (b) é uma equação em que $\tilde{Y}_i$ aparece dos dois lados. Resolva-a para o resíduo de validação $Y_i - \hat{g}_{-i}(\mathbf{X}_i)$ e conclua a fórmula do enunciado.
- (d) Agora leia o que você provou. Por que o fator $1/(1 - h_{ii})$ é sempre ≥ 1 , e que afirmação da Aula 03 isso torna exata? O que significa uma observação com h_{ii} próximo de 1?

Solução

(a) O ajuste linear escolhe a função que minimiza o RSS sobre as observações que recebe. No conjunto modificado, a soma a minimizar é

$$\underbrace{\sum_{\ell \neq i} (Y_{\ell} - g(\mathbf{X}_{\ell}))^2}_{\text{as } n-1 \text{ de sempre}} + \underbrace{(\tilde{Y}_i - g(\mathbf{X}_i))^2}_{\text{a parcela nova}}.$$

Dois observações fecham o argumento. A função $\hat{g}_{-i}$ minimiza a primeira parcela — é

a definição dela. E ela *zera* a segunda, porque $\tilde{Y}_i$ foi escolhido como sendo exatamente $\hat{g}_{-i}(\mathbf{X}_i)$.

Como nenhuma função pode fazer melhor do que atingir o mínimo da primeira parcela e zero na segunda, $\hat{g}_{-i}$ minimiza o conjunto modificado. E, sendo a solução única (posto cheio), ela é *a* solução.

O truque, em uma frase: trocamos a observação problemática por uma que o ajuste sem ela já "concorda", e com isso ela para de puxar o ajuste para lado nenhum.

(b) Chame de $\hat{g}^{\text{mod}}$ o ajuste no conjunto modificado; por (a), $\hat{g}^{\text{mod}} = \hat{g}_{-i}$.

Como o ajuste é linear nas respostas e os pesos $h_{i\ell}$ dependem só de $\mathbf{X}$ — que não mudou —, os mesmos pesos valem nos dois conjuntos. Avaliando em $\mathbf{X}_i$:

$$\hat{g}^{\text{mod}}(\mathbf{X}_i) = \sum_{\ell \neq i} h_{i\ell} Y_\ell + h_{ii} \tilde{Y}_i.$$

Some e subtraia $h_{ii} Y_i$ para fazer aparecer o ajuste completo:

$$\begin{aligned} &= \underbrace{\sum_{\ell} h_{i\ell} Y_\ell - h_{ii} Y_i + h_{ii} \tilde{Y}_i}_{= \hat{g}(\mathbf{X}_i)} = \hat{g}(\mathbf{X}_i) + h_{ii} (\tilde{Y}_i - Y_i), \end{aligned}$$

que é o pedido, já que o lado esquerdo é $\hat{g}_{-i}(\mathbf{X}_i)$.

(c) Como $\tilde{Y}_i = \hat{g}_{-i}(\mathbf{X}_i)$, o item (b) diz

$$\tilde{Y}_i = \hat{g}(\mathbf{X}_i) + h_{ii} \tilde{Y}_i - h_{ii} Y_i \implies \tilde{Y}_i (1 - h_{ii}) = \hat{g}(\mathbf{X}_i) - h_{ii} Y_i.$$

Subtraia $Y_i(1 - h_{ii})$ dos dois lados, que é o passo que faz o resíduo aparecer:

$$(\tilde{Y}_i - Y_i)(1 - h_{ii}) = \hat{g}(\mathbf{X}_i) - h_{ii} Y_i - Y_i + h_{ii} Y_i = \hat{g}(\mathbf{X}_i) - Y_i.$$

Trocando o sinal dos dois lados e lembrando que $Y_i - \hat{g}_{-i}(\mathbf{X}_i) = Y_i - \tilde{Y}_i$:

$$Y_i - \hat{g}_{-i}(\mathbf{X}_i) = \frac{Y_i - \hat{g}(\mathbf{X}_i)}{1 - h_{ii}}.$$

Elevando ao quadrado e tomando a média em i , sai a fórmula.

O ganho é esse: os n resíduos de validação saem todos de $\hat{g}$, o ajuste único feito com todos os dados. O LOOCV de graça.

(d) Para uma matriz de projeção vale $0 \leq h_{ii} \leq 1$, logo $1 - h_{ii} \in [0, 1]$ e o fator $1/(1 - h_{ii})$ é sempre ≥ 1 .

Isso torna exata uma afirmação que a Aula 03 fazia em geral: o resíduo de validação é sempre **maior ou igual** ao de treino, nunca menor. Aqui não é uma tendência nem um argumento de plausibilidade — é uma igualdade, observação por observação, com o fator de inflação explícito.

O h_{ii} mede a **alavancagem**: o quanto a observação i influencia sua própria predição. Onde ele é grande, $\hat{g}$ foi puxada na direção de Y_i , o resíduo de treino ficou artificialmente pequeno, e o fator infla bastante para corrigir. São exatamente os pontos cujo resíduo de treino mais engana.

No limite $h_{ii} \rightarrow 1$ o fator explode. Isso descreve uma observação que determina sozinha a predição no seu próprio ponto: tirá-la do ajuste muda tudo ali. O LOOCV registra isso com um resíduo enorme — e está certo, porque não existe informação independente para prever naquele lugar.

Exercício 7 — a mesma validação cruzada, escrita de dois jeitos. Quem estuda validação cruzada pela Aula 03 e pelo [ISLP] encontra duas fórmulas diferentes para a mesma coisa, e é natural desconfiar de que uma delas esteja errada. Não está: elas são a mesma conta, escrita com outra unidade.

A Aula 03 define

$$\hat{R}_{k\text{-CV}} = \frac{1}{n} \sum_{j=1}^k \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2,$$

e o [ISLP] define $CV_{(k)} = \frac{1}{k} \sum_{j=1}^k \text{EQM}_j$, com $\text{EQM}_j = \frac{1}{|L_j|} \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2$.

(a) Reescreva a fórmula da aula de modo a fazer os EQM_j aparecerem, mostrando que

$$\hat{R}_{k\text{-CV}} = \sum_{j=1}^k \frac{|L_j|}{n} \text{EQM}_j.$$

- (b) Olhando para os pesos que você obteve, diga em que condição as duas definições coincidem — e se coincidem exatamente ou apenas aproximadamente. Em seguida, nomeie a unidade que cada fórmula pondera igualmente.
- (c) Com $n = 50$ e $k = 7$, o `KFold` produz dobras de tamanhos 8, 8, 7, 7, 7, 7, 6. Confirme que somam 50 e explique por que, neste caso, os dois números diferem.
- (d) Suponha que a dobra de 6 observações tenha $\text{EQM} = 10$ e todas as outras tenham $\text{EQM} = 1$. Calcule os dois estimadores, diga qual deles dá mais peso à dobra atípica, e qual você reportaria. Justifique a escolha.

Solução

(a) A chave é reconhecer a soma interna. Pela definição de EQM_j , basta multiplicar dos dois lados por $|L_j|$:

$$\sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2 = |L_j| \text{EQM}_j.$$

Substituindo na fórmula da aula,

$$\hat{R}_{k\text{-CV}} = \frac{1}{n} \sum_{j=1}^k |L_j| \text{EQM}_j = \sum_{j=1}^k \frac{|L_j|}{n} \text{EQM}_j.$$

São os *mesmos* EQM_j do [ISLP], numa média ponderada. E os pesos somam 1, porque as dobras particionam as n observações: $\sum_j |L_j| = n$.

(b) Se k divide n , todas as dobras têm o mesmo tamanho $|L_j| = n/k$, e cada peso vale $(n/k)/n = 1/k$. A média ponderada vira média simples — que é exatamente a definição do [ISLP].

E coincidem **exatamente**, não aproximadamente: é a mesma soma dos mesmos números com os mesmos pesos.

Quanto à unidade, a diferença é essa: a fórmula da aula pondera igualmente cada **observação**, e a do [ISLP] pondera igualmente cada **dobra**.

(c) $8 + 8 + 7 + 7 + 7 + 7 + 6 = 50$.

Diferem porque os tamanhos não são todos iguais. Os pesos da fórmula da aula valem $8/50$, $8/50$, $7/50$ (quatro vezes) e $6/50$, enquanto a do [ISLP] usa $1/7$ para todas as sete. O efeito concreto é sobre as observações individuais: uma que caiu na dobra de 6 recebe, na conta do [ISLP], peso maior do que uma que caiu na dobra de 8 — porque ela divide a responsabilidade da sua dobra com menos gente.

(d) Pela fórmula da aula, a dobra atípica entra com peso $6/50$ e as outras 44 observações com $44/50$:

$$\hat{R}_{k-CV} = \frac{6}{50} \times 10 + \frac{44}{50} \times 1 = \frac{60 + 44}{50} = \frac{104}{50} = \mathbf{2,08}.$$

Pela do [ISLP], a dobra atípica é uma das sete, e só:

$$CV_{(7)} = \frac{1}{7}(10 + 6 \times 1) = \frac{16}{7} \approx \mathbf{2,286}.$$

A do [ISLP] dá mais peso à dobra atípica — e é fácil ver por quê: ela é a *menor* dobra e ainda assim vale $1/7 \approx 0,143$ do total, contra $6/50 = 0,12$ na outra conta. Justamente por ter menos observações, cada uma delas pesa mais.

Qual reportar? Para *estimar o risco*, a fórmula da aula é a mais defensável: a unidade amostral é a observação, não a dobra, e não há razão para uma observação valer mais por acaso de agrupamento. Na prática, porém, o `scikit-learn` segue o [ISLP] — `cross_val_score(...).mean()` é média não ponderada — então o essencial é *saber qual das duas o seu código está calculando* antes de comparar com o de outra pessoa.

E a recomendação da aula encerra a discussão pela raiz: com n pequeno, escolha um k que divida n . Aí as duas coincidem e a pergunta não se coloca.

Exercício 8 — de que tamanho é o viés da validação cruzada. A validação cruzada estima o risco de um procedimento — mas não exatamente o risco que interessa. Há um descompasso embutido, e a boa notícia é que ele tem sinal conhecido.

- (a) Cada g_{-j} é ajustado com quantas observações? Usando isso, argumente que $\mathbb{E}[\hat{R}_{k-CV}] = R_{n-n/k}$, onde R_m denota o risco esperado do procedimento treinado com m observações. A conta é mais curta do que parece: tome a esperança dentro da soma dupla e pergunte-se, para uma parcela qualquer, o que a observação i representa para o ajuste g_{-j} que a está prevendo.
- (b) O alvo que interessa é R_n , o risco do procedimento treinado com a amostra inteira. Supondo que R_m decresça com m — mais dados não pioram —, conclua que a validação cruzada é **pessimista**.
- (c) Ordene $k = 2$, $k = 10$ e $k = n$ quanto ao tamanho desse viés, justificando pelo número de observações de treino em cada caso.
- (d) Se o LOOCV tem o menor viés, por que $k = 5$ e $k = 10$ são os valores usuais? Responda pensando em *para que* a validação cruzada costuma ser usada.

Solução

(a) O ajuste g_{-j} usa todas as observações menos as da dobra L_j , isto é, $n - |L_j|$ pontos. Com dobras de tamanho n/k , são $n - n/k$. Tome a esperança na definição:

$$\mathbb{E}[\hat{R}_{k-CV}] = \frac{1}{n} \sum_{j=1}^k \sum_{i \in L_j} \mathbb{E}[(Y_i - g_{-j}(\mathbf{X}_i))^2].$$

Agora olhe uma parcela isolada. A observação i pertence a L_j , e L_j foi justamente a dobra retirada para treinar g_{-j} — então i **não** participou daquele ajuste. Para g_{-j} , ela é uma observação nova e independente.

Mas "erro esperado de um ajuste numa observação nova" é exatamente a definição de risco.

Como g_{-j} foi treinado com $n - n/k$ pontos, essa esperança vale $R_{n-n/k}$ — e vale o mesmo para toda parcela, por simetria, já que as observações são i.i.d.

São n parcelas no total (cada observação aparece em exatamente uma dobra), o fator $1/n$ cancela, e sobra $\mathbb{E}[\hat{R}_{k-CV}] = R_{n-n/k}$.

(b) Como $n - n/k < n$ e R_m é decrescente em m , temos $R_{n-n/k} \geq R_n$. Logo

$$\mathbb{E}[\hat{R}_{k-CV}] = R_{n-n/k} \geq R_n.$$

A validação cruzada superestima, em média, o risco do procedimento treinado com tudo. A origem do viés cabe numa frase: **a CV mede o desempenho de um modelo treinado com menos dados do que aquele que você vai de fato usar.**

E o sinal conhecido é uma vantagem, não um defeito. Se a CV diz que o modelo é bom, ele é pelo menos aquilo — o erro está do lado seguro.

(c) O viés é tanto maior quanto menos observações sobram para treinar:

	observações de treino	viés
$k = 2$	$n/2$	o maior
$k = 10$	$0,9n$	pequeno
$k = n$ (LOOCV)	$n - 1$	o menor

Com $k = 2$, metade dos dados é descartada em cada rodada, e o que se estima é o risco de um procedimento com metade da amostra — que pode ser bem pior. Com o LOOCV, cada ajuste usa $n - 1$ pontos, praticamente a amostra inteira, e o alvo estimado é praticamente o certo.

(d) Porque o viés atrapalha menos do que parece para o uso mais comum, e o LOOCV custa caro.

Se o objetivo for **reportar** o risco, o viés importa de verdade: o número sai sistematicamente alto, e aí um k grande ajuda.

Só que o uso mais frequente é **escolher** um hiperparâmetro — descobrir onde a curva $\theta \mapsto \hat{R}(\theta)$ tem mínimo. Para isso o que importa é a *forma* da curva, não o nível dela. Um viés que desloca todos os valores para cima de maneira parecida preserva a posição do mínimo, e a escolha não muda.

Some a isso o custo: o LOOCV exige n ajustes e, fora do caso linear, não tem atalho — justamente o que o exercício do atalho mostra é que a economia só existe quando o ajuste é linear. Com $k = 10$ o viés já é pequeno e o custo é dez ajustes, não mil.

Uma ressalva, para fechar: o argumento clássico diz também que k grande aumenta a *variância* da estimativa, porque as dobras ficam muito parecidas entre si. É o que o deck da Aula 03 ensina, e é o que se costuma repetir — ainda que a medição desse efeito seja menos consensual do que o argumento sugere.

Aula 04 — Métodos Não Paramétricos (KNN)

Exercício 9 — quanto custa cada nó de um spline. Um *spline* é uma função polinomial por partes, colada suavemente nos **nós**. A Aula 04 apresenta a base truncada que os constrói, e este exercício pergunta por que ela funciona — e quanto custa cada nó.

Um *spline* de grau g com nós $t_1 < \dots < t_J$ é combinação linear de

$$1, x, x^2, \dots, x^g, (x - t_1)_+^g, \dots, (x - t_J)_+^g, \quad (u)_+ = \max(u, 0).$$

Sobre as letras: aqui g é o **grau** e J o **número de nós**. As notas usam k e p para essas duas quantidades; trocamos as letras de propósito, para não colidir com o k do KNN nem com o p de covariáveis. É o tipo de colisão que a Aula 04 tem e que convém não carregar para uma prova.

- (a) Quantas funções há na base? Escreva I em função de g e J , e confira no caso cúbico ($g = 3$) com 4 nós.
- (b) Mostre que $(x - t_j)_+^g$ e suas $g - 1$ primeiras derivadas se anulam em $x = t_j$. Em seguida, tire a conclusão que interessa: por que acrescentar essa função à base *não altera* o ajuste à esquerda de t_j , e por que a emenda no nó sai suave sem que se precise impor restrição nenhuma.
- (c) Use (b) para justificar a frase "cada nó compra exatamente um grau de liberdade". Depois compare com a alternativa ingênua: ajustar um polinômio de grau g **independente** em cada um dos $J + 1$ pedaços. Quantos parâmetros seriam? Onde foi parar a diferença, e o que ela custa?
- (d) O ajuste é por mínimos quadrados sobre essa base. Isso faz do *spline* um **ajuste linear** no sentido da Aula 02 — explique por quê. E então responda: se ele é linear, o que exatamente o torna um método *não paramétrico*?

Solução

- (a) São $g + 1$ monômios $(1, x, \dots, x^g)$ mais J funções truncadas, uma por nó:

$$I = (g + 1) + J.$$

No caso cúbico com 4 nós, $I = (3 + 1) + 4 = 8$ funções na base — oito coeficientes a estimar.

- (b) Separe os dois lados do nó.

À esquerda, $x < t_j$ dá $(x - t_j)_+ = 0$: a função é identicamente nula num intervalo inteiro, e uma função identicamente nula tem todas as derivadas nulas ali.

À direita, $x > t_j$ dá $(x - t_j)_+^g = (x - t_j)^g$, cuja m -ésima derivada é

$$\frac{g!}{(g - m)!} (x - t_j)^{g - m}.$$

Para $m \leq g - 1$ o expoente $g - m$ é positivo, e essa expressão tende a 0 quando $x \downarrow t_j$. Os limites laterais coincidem, e valem zero, para a função e suas primeiras $g - 1$ derivadas. A g -ésima é a primeira a saltar: passa de 0 para $g!$.

Daí as duas conclusões. Como a função é nula à esquerda, somá-la ao modelo **não muda nada antes do nó** — o coeficiente dela é livre para ajustar o que vem depois sem estragar o que veio antes. E como ela e suas $g - 1$ derivadas se anulam no nó, a emenda é de classe C^{g-1} automaticamente: a suavidade não precisa ser imposta, ela está embutida na escolha da base.

- (c) Cada nó acrescenta *uma* função à base, logo *um* coeficiente livre, logo um grau de liberdade. E, por (b), esse grau de liberdade é **localizado**: só atua à direita de t_j . Você compra flexibilidade onde quer, e paga por uma unidade de cada vez.

A alternativa ingênua seriam $J + 1$ pedaços com $g + 1$ coeficientes cada:

$$(J + 1)(g + 1) \text{ parâmetros.}$$

No caso cúbico com 4 nós, $5 \times 4 = 20$ — contra os 8 da base truncada.

A diferença são as restrições de continuidade. A base truncada já embute que a função e suas $g - 1$ primeiras derivadas são contínuas em cada nó: g restrições por nó, gJ no total.

E a conta fecha:

$$(J + 1)(g + 1) - gJ = g + 1 + J = I.$$

Os 12 parâmetros que sumiram no caso cúbico são exatamente as 3×4 restrições.

O que a alternativa custa: com mais liberdade, ela ajusta *melhor* o treino — e produz saltos nos nós, variância alta e extrapolação ruim. Paga-se flexibilidade com instabilidade, que é a Aula 01 aparecendo de novo com outra roupa.

(d) Fixadas as funções da base, o modelo é $g(x) = \sum_{m=1}^I \beta_m f_m(x)$: **linear nos parâmetros** β_m , ainda que profundamente não linear em x . Basta montar a matriz de delineamento com $\mathbb{X}_{im} = f_m(x_i)$ e os β_m saem pelas equações normais, como na Aula 02. Vale inclusive a matriz de projecção $\mathbf{H}$ — e, com ela, o atalho do LOOCV.

O que torna o método não paramétrico não é a forma do ajuste, então. É o fato de I — o número de funções da base, isto é, o número de nós — **crescer com n** . Com poucos dados usam-se poucos nós e a curva é rígida; com muitos dados, mais nós, e a classe de funções representáveis se aproxima de qualquer função suave.

Essa é a distinção que a Aula 04 faz logo no começo: um método paramétrico fixa a complexidade *antes* de ver os dados; um não paramétrico deixa que ela cresça com eles. Não é "ter ou não ter parâmetros" — é *quando* o número deles fica decidido.

Exercício 10 — duas doenças, dois remédios. As Aulas 02 e 04 apresentam ferramentas que, à primeira vista, andam em sentidos opostos. A regularização *restringe* o modelo; os métodos não paramétricos o *soltam*. Parece contradição, e não é: são remédios para doenças diferentes.

Este exercício pede que você organize as duas numa única imagem — a da Aula 01.

- (a) Escreva a decomposição do erro de um estimador $\hat{r}$ em relação a r nos dois termos da Aula 01, e diga qual dos dois cada família de métodos ataca.
- (b) Descreva, em uma frase cada, a situação que motiva cada família: o que está errado com o modelo *antes* de aplicarmos Ridge, e o que está errado *antes* de aplicarmos um spline?
- (c) O KNN com $k = 1$ e o MQO com p grande erram por motivos que, na decomposição, caem no mesmo lugar. Explique. Em seguida diga qual é o remédio de cada um e por que os dois remédios se parecem.
- (d) As duas ideias podem ser combinadas? Dê um exemplo concreto, visto no curso, de método que seja ao mesmo tempo não paramétrico e regularizado, e diga qual botão controla cada coisa nele.

Solução

(a) Para um ponto $\mathbf{x}$ fixo,

$$\mathbb{E}_{\mathcal{D}}[(\hat{r}(\mathbf{x}) - r(\mathbf{x}))^2] = \underbrace{(\mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x})] - r(\mathbf{x}))^2}_{\text{viés}^2} + \underbrace{\text{Var}_{\mathcal{D}}(\hat{r}(\mathbf{x}))}_{\text{variância}}.$$

A **regularização ataca a variância**: ela restringe o espaço de soluções, encolhendo os coeficientes, e aceita pagar viés por isso.

Os **métodos não paramétricos atacam o viés**: eles ampliam a classe de funções representáveis para que r caiba nela, e aceitam pagar variância.

(b) Antes do Ridge, o problema é um modelo **flexível demais para a amostra que se tem**: colunas demais ou colineares, o ajuste persegue o ruído e os coeficientes ficam instáveis. Excesso de variância.

Antes do spline, o problema é um modelo **rígido demais para a verdade**: a reta não acompanha uma r curva, e o erro persiste por mais dados que se colete. Excesso de viés. A diferença entre "para a amostra" e "para a verdade" é o coração da distinção: uma é falta de dados, a outra é falta de classe.

(c) Os dois erram por **variância**.

O KNN com $k = 1$ faz cada predição depender de uma única observação, e todo o ruído daquele ponto entra na resposta. O ajuste passa exatamente pelos dados de treino, com resíduo nulo e nenhuma estabilidade — troque a amostra e a função muda inteira.

O MQO com p grande tem parâmetros demais para os dados disponíveis, e cada coeficiente é estimado com pouca informação. No limite $p > n$ a solução nem é única.

O remédio do KNN é **aumentar** k , fazendo cada predição ser a média de mais observações. O do MQO é **regularizar**, encolhendo os coeficientes em direção a zero. Os dois se parecem porque fazem a mesma coisa no fundo: reduzem a *complexidade efetiva* do ajuste, trocando variância por viés. Em ambos há um botão contínuo — k de um lado, λ do outro — e em ambos ele se escolhe por validação cruzada, nunca no olho.

Um cuidado que costuma confundir: os botões correm em sentidos opostos. k grande e λ grande dão modelos mais simples, mas k grande significa vizinhança larga e λ grande significa coeficientes pequenos. O teste seguro, quando a memória falha, é perguntar de que lado está o modelo constante.

(d) Podem, e o exemplo do curso são as *smoothing splines* da Aula 04.

Elas põem um nó em **cada observação** — portanto são não paramétricas ao extremo, com $I = n$ — e controlam a flexibilidade resultante **penalizando a curvatura**:

$$\sum_{i=1}^n (y_i - g(x_i))^2 + \gamma \int (g''(x))^2 dx.$$

Os dois papéis estão separados e visíveis: a base cresce com n (o lado não paramétrico) e o γ regula quanta daquela liberdade é de fato usada (o lado regularizado). E neste método quem manda é o γ — os nós deixaram de ser o botão, porque são todos. É uma solução elegante para um problema chato, que é ter de escolher onde pôr os nós.

Aula 05 — Árvores de Regressão e *Ensembles*

Exercício 11 — podar é outro problema, não o mesmo de crescer. Construir uma árvore tem duas etapas, e elas usam objetivos diferentes de propósito. O crescimento escolhe cortes que mais reduzem o RSS; a poda escolhe uma subárvore $T \subseteq T_0$ minimizando

$$C_\alpha(T) = \sum_{m=1}^{|T|} \sum_{i: x_i \in R_m} (y_i - \hat{c}_m)^2 + \alpha |T|,$$

onde $|T|$ é o número de folhas e $\hat{c}_m$ a média de y na folha m . Se a forma lembra a regularização da Aula 02, não é coincidência.

- (a) O que se obtém nos dois extremos, $\alpha = 0$ e $\alpha \rightarrow \infty$? Diga em cada caso quantas folhas tem a subárvore vencedora.
- (b) Considere uma folha com RSS igual a S_m , que pode ser dividida em duas com RSS S_a e S_b . Escreva a condição sobre $S_m - (S_a + S_b)$ para que a divisão valha a pena segundo C_α , e interprete: em que unidade o α está cobrando?

- (c) Uma árvore tem RSS total 120 com 6 folhas; podando-a para 4 folhas, o RSS sobe para 140. Para quais valores de α a podada é preferível?
- (d) Por que a poda usa um critério diferente do crescimento, em vez de simplesmente parar de crescer quando o ganho fica pequeno? Dê um exemplo de estrutura nos dados que um critério de parada perderia e a poda recupera.

Solução

(a) Com $\alpha = 0$ a penalidade some e $C_0(T)$ é só o RSS. Como o RSS nunca aumenta ao acrescentar cortes, a minimizadora é a árvore inteira T_0 — no limite, uma observação por folha e RSS zero.

Com $\alpha \rightarrow \infty$ o termo $\alpha |T|$ domina, e minimizá-lo exige $|T|$ mínimo: a vencedora é a **raiz sozinha**, uma única folha, cuja predição é a média de y no conjunto todo.

Entre os dois extremos, α percorre uma sequência finita de subárvores aninhadas — e é essa sequência que a validação cruzada percorre para escolher o α .

(b) Dividir a folha troca 1 folha por 2: o número de folhas sobe em 1 e o custo de complexidade sobe em α . Em compensação o RSS cai de S_m para $S_a + S_b$. A divisão reduz C_α se, e só se,

$$(S_a + S_b) + \alpha(|T| + 1) < S_m + \alpha |T| \iff S_m - (S_a + S_b) > \alpha.$$

Em palavras: **a divisão precisa reduzir o RSS em mais de α** .

E a interpretação sai direto daí: o α é literalmente o *preço de uma folha*, cobrado na mesma unidade do RSS. Ganhos menores que esse preço não pagam a complexidade que introduzem. Se o RSS está em reais ao quadrado, o α também está — o que, de passagem, explica por que ele não é comparável entre problemas de escalas diferentes.

(c) A árvore grande custa $120 + 6\alpha$; a podada, $140 + 4\alpha$. A podada vence quando

$$140 + 4\alpha < 120 + 6\alpha \iff 20 < 2\alpha \iff \boxed{\alpha > 10}.$$

Para $\alpha < 10$ mantêm-se as seis folhas; em $\alpha = 10$ as duas empatam.

O 10 é exatamente o ganho médio de RSS por folha removida, $20/2$. O ponto de indiferença é sempre o ganho por folha — o que dá uma forma rápida de estimar de cabeça qual α separa duas subárvores.

(d) Porque o critério de parada é **míope**: ele avalia um corte de cada vez e não enxerga o que viria depois. Um corte pode reduzir pouco o RSS sozinho e ainda assim ser indispensável, por *viabilizar* os cortes seguintes. Quem para ali nunca chega a eles.

O exemplo clássico é a **interação**. Tome $y = \text{sin}(x_1 x_2)$, com x_1 e x_2 simétricos em torno de zero. Um corte em x_1 isolado quase não reduz o RSS: de cada lado dele, y continua metade positivo e metade negativo, e a média local segue perto de zero. O mesmo vale para x_2 . Só a *combinação* dos dois cortes separa os quadrantes — e um critério de parada com limiar razoável interromperia o crescimento logo no primeiro, devolvendo a raiz sozinha.

A poda escapa disso porque **cresce primeiro e corta depois**: a árvore grande chega a descobrir a interação, e a poda então avalia subárvores inteiras, não cortes isolados. É por isso que os dois objetivos são diferentes de propósito — e é por isso que não se deve confundir o α da poda com um limite de profundidade, que é justamente um critério de parada disfarçado.

Exercício 12 — as duas condições, e o que a floresta faz com elas. A Aula 05 justifica a agregação com uma proposição de enunciado curto: se $g_1, \dots, g_B$ são não-viesados para $r(\mathbf{x})$, têm a mesma variância $v(\mathbf{x})$ e são **não-correlacionados**, então $\bar{g} = \frac{1}{B} \sum_b g_b$ tem variância $v(\mathbf{x})/B$.

Proposições com hipóteses só ficam úteis quando se sabe o que acontece ao violá-las — e, no caso do *bagging*, uma delas é violada o tempo todo.

- (a) Identifique as duas condições e explique, para cada uma, o que acontece com a conclusão se ela falhar.
- (b) O *bagging* usa árvores **profundas e não podadas**. Qual das duas condições essa escolha atende? E por que podar as árvores seria contraproducente aqui?
- (c) Na prática as árvores do *bagging* são correlacionadas. Explique a razão — o que elas têm em comum que as faz parecidas — e por que aumentar B não resolve esse problema específico.
- (d) A floresta aleatória sorteia $m < p$ covariáveis candidatas em cada nó. Explique como isso ataca a condição comprometida, qual é o preço pago na outra, e por que o negócio costuma compensar mesmo assim.

Solução

(a) As duas condições são:

(i) **não-viesados**. Se os g_b tiverem viés, a média o herda integralmente: $\mathbb{E}[\bar{g}] = \mathbb{E}[g_b] \neq r(\mathbf{x})$. Promediar reduz variância, mas **não corrige viés** — a média de mil estimadores enviesados é igualmente enviesada. A conclusão sobre o risco deixa de valer, porque sobra um termo de viés² que B nenhum elimina.

(ii) **não-correlacionados**. Se houver correlação $\rho > 0$ entre pares, a variância da média não é v/B , e sim

$$\text{Var}(\bar{g}) = \rho v + \frac{1 - \rho}{B} v \xrightarrow{B \rightarrow \infty} \rho v.$$

A redução **estaciona num piso** ρv , em vez de ir a zero.

(b) Atende a condição (i), a de não-viesamento.

Árvores profundas são muito flexíveis: acompanham r de perto e têm viés baixo, ao custo de variância alta. E variância alta é justamente o defeito que a agregação sabe consertar — de graça, pela própria proposição.

Podar seria contraproducente porque a poda *introduz viés de propósito* para reduzir variância. Só que a variância já vai ser tratada pela média dos B ajustes. Podar seria, então, pagar viés por um benefício que se teria sem pagar nada.

A regra que fica: deixe cada árvore ser instável, e deixe a média estabilizar.

(c) As árvores do *bagging* são treinadas em amostras bootstrap do **mesmo** conjunto de dados, e todas enxergam **todas** as p covariáveis em todos os nós.

Se houver uma covariável fortemente preditiva, ela tende a ser escolhida no primeiro corte por quase todas as árvores. E árvores que começam igual continuam parecidas: elas erram juntas, o que é precisamente o que $\rho > 0$ significa.

Aumentar B não resolve porque, na fórmula de (a), o termo ρv **não depende de B** . Acrescentar árvores só encolhe o segundo termo; o piso permanece onde está. Passado certo ponto, cada árvore nova custa tempo de computação e não compra quase nada.

(d) A floresta ataca diretamente o ρ . Ao sortear $m < p$ candidatas por nó, ela impede que a covariável dominante seja usada sempre: em cerca de $1 - m/p$ dos nós ela sequer está disponível, e a árvore é obrigada a olhar para outra coisa. As árvores passam a divergir estruturalmente, ρ cai, e com ele o piso ρv .

O preço é pago na qualidade individual. Uma árvore proibida de usar a melhor covariável em parte dos nós é uma árvore **pior**, com variância individual v maior. O sorteio degrada cada membro para melhorar o conjunto — o que é contraintuitivo, e é o ponto que costuma ser mal explicado.

Compensa porque, com B grande, o que sobra em $\rho v + \frac{1-\rho}{B}v$ é ρv , e a queda em ρ costuma ser proporcionalmente maior que a subida em v . Há um limite, claro: com m pequeno demais as árvores ficam ruins demais e o produto ρv volta a subir. É por isso que m é um hiperparâmetro, e $m \approx p/3$ em regressão é um ponto de partida razoável — não uma verdade.

Aula 06 — Pré-processamento e *Pipelines*

Exercício 13 — para quem a régua importa. Um colega recebeu um banco em que a coluna **renda** está em reais e a coluna **altura** em metros, e pergunta se precisa padronizar antes de ajustar. A resposta honesta é "depende do método" — e o critério que decide cabe numa pergunta: **o método soma coisas vindas de colunas diferentes?**

Se soma, as unidades precisam ser comparáveis, e trocar uma delas estraga a comparação. Se não soma, a unidade é irrelevante.

- (a) Para cada método abaixo, diga se multiplicar uma única coluna por 1000 **muda** ou **não muda** a predição, justificando em uma linha onde está — ou onde não está — a soma sobre colunas.
- (i) Mínimos quadrados ordinários.
 - (ii) Regressão Ridge com $\lambda > 0$ fixo.
 - (iii) Árvore de regressão.
 - (iv) Floresta aleatória.
 - (v) KNN com k fixo.
 - (vi) *Spline* de base truncada, ajustado por mínimos quadrados.
- (b) Entre os que mudam, qual você espera que seja o mais afetado, e por quê? Compare o *modo* como a escala entra em cada um.
- (c) Um colega observa que, ao reescalar uma coluna, o risco do Lasso *melhorou*, e conclui que não padronizar foi uma boa ideia. Explique o erro do raciocínio.

Solução

(a)

	muda?	onde está (ou não) a soma sobre colunas
(i)	não	O MQO é equivariante: o coeficiente da coluna se divide por 1000 e o produto $\beta_j x_j$ fica igual. Nada na função-objetivo compara coeficientes entre si.
(ii)	sim	A penalidade $\lambda \sum_j \beta_j^2$ soma coeficientes de colunas diferentes; mudar a unidade de uma delas muda quanto ela pesa nessa soma.
(iii)	não	A árvore só pergunta " $x_j \leq t$ ". O corte t é multiplicado junto, e a pergunta separa exatamente as mesmas observações.
(iv)	não	É uma média de árvores, e cada uma é indiferente; a indiferença atravessa a agregação.
(v)	sim	A distância euclidiana $\sum_j (x_{ij} - x_{\ell j})^2$ é uma soma sobre colunas.
(vi)	não	É um MQO sobre uma base fixa de funções de uma coluna; vale o mesmo argumento de (i).

(b) O KNN, e a diferença é de ordem, não de grau.

Nos métodos penalizados a escala entra *uma vez*, de forma linear, na comparação entre coeficientes. Na distância euclidiana ela entra **ao quadrado**: multiplicar a coluna por 1000 multiplica as diferenças naquela coordenada por 1000, e a contribuição delas para a distância por 10^6 .

O efeito é que a coluna reescalada passa a decidir sozinha quem é vizinho de quem. As demais não são apenas menos importantes — elas somem da conta, e o método deixa de usar a informação que carregavam.

(c) O erro é confundir um resultado com um argumento.

A melhora aconteceu porque a coluna reescalada era, naquele problema, a de maior efeito verdadeiro. Deixá-la 1000 vezes maior tornou o coeficiente dela 1000 vezes menor, e um coeficiente minúsculo quase não pesa em $\sum_j |\beta_j|$ — a coluna ficou praticamente isenta da penalidade. Isentar de penalidade justamente a coluna que mais importa calhou de ajudar. Calhou: é sorte, não método. Aplique a mesma reescala a uma coluna *irrelevante* e o efeito se inverte — ela ganharia liberdade para receber um coeficiente grande sem pagar por isso, e o ajuste pioraria.

O ponto de fundo é que, nos dois casos, quem decidiu quanto regularizar cada coluna não foi o analista: foi a **unidade de medida** em que o dado chegou. E é por isso que o argumento do colega não se salva nem quando o resultado o favorece — um procedimento cujo desempenho depende de a coluna ter sido anotada em metros ou em milímetros está fora de controle, e ter dado certo desta vez não muda isso.