

Lista de Revisão — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aulas 01 a 06 — Fundamentos, Regressão, Validação Cruzada, KNN, Árvores e Pipelines

Não há ordem obrigatória para a resolução, mas os exercícios de uma mesma aula se apoiam uns nos outros, ou em exercícios de listas anteriores.

Salvo indicação em contrário, $(\mathbf{X}, Y)$ é um vetor aleatório com distribuição P , $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ é a função de regressão, $\mathcal{D} = \{(\mathbf{X}_i, Y_i)\}_{i=1}^n$ é a amostra de treino (i.i.d.), p é o número de covariáveis e a perda é a quadrática.

Aula 01 — Introdução

Exercício 1 — O melhor preditor. No início do curso, vimos uma afirmação forte: de todas as funções que você poderia usar para prever Y a partir de $\mathbf{X}$, a melhor é a função de regressão $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$. Não a melhor entre as lineares, nem a melhor entre as que o seu método consegue produzir — a melhor, ponto.

Uma afirmação dessas pede demonstração, e ela é mais curta do que parece. Todo o trabalho está num truque que você vai reencontrar várias vezes no curso: somar e subtrair a quantidade certa dentro de um quadrado.

- (a) Seja $g : \mathbb{R}^p \rightarrow \mathbb{R}$ uma função qualquer com $\mathbb{E}[g(\mathbf{X})^2] < \infty$. Some e subtraia $r(\mathbf{X})$ dentro do quadrado e mostre que

$$\mathbb{E}[(Y - g(\mathbf{X}))^2] = \mathbb{E}[(Y - r(\mathbf{X}))^2] + \mathbb{E}[(r(\mathbf{X}) - g(\mathbf{X}))^2].$$

O trabalho está em mostrar que o termo cruzado desaparece; condicione em $\mathbf{X}$ e pergunte-se o que $\mathbb{E}[Y - r(\mathbf{X}) \mid \mathbf{X}]$ vale.

- (b) Olhe para a identidade que você acabou de provar e responda: por que ela mostra que r é o minimizador? Em seguida, mostre que o valor mínimo é $R(r) = \mathbb{E}[\text{Var}(Y \mid \mathbf{X})]$.
- (c) Esse mínimo tem nome: **erro irreduzível**. O nome sugere que não há como baixá-lo, e é verdade — mas a razão não é que os métodos atuais sejam ruins. Explique de onde vem essa impossibilidade, e diga o que teria de mudar *no problema* para o número diminuir.
- (d) Na Lista Teórica 01, mostramos que o melhor preditor *constante* tem risco $\text{Var}(Y)$. Use a identidade de (a) para escrever a diferença $\text{Var}(Y) - R(r)$ como uma esperança, e interprete: que pergunta prática essa quantidade responde?

Solução

- (a) Escreva a diferença em duas partes,

$$Y - g(\mathbf{X}) = \underbrace{(Y - r(\mathbf{X}))}_{\text{o que ninguém prevê}} + \underbrace{(r(\mathbf{X}) - g(\mathbf{X}))}_{\text{o quanto } g \text{ erra o alvo}},$$

e eleve ao quadrado:

$$(Y - g(\mathbf{X}))^2 = (Y - r(\mathbf{X}))^2 + 2(Y - r(\mathbf{X}))(r(\mathbf{X}) - g(\mathbf{X})) + (r(\mathbf{X}) - g(\mathbf{X}))^2.$$

Tomando esperança, o que precisa ser mostrado é que o termo do meio some.

Condicione em $\mathbf{X}$. Feito isso, $r(\mathbf{X}) - g(\mathbf{X})$ vira uma constante — as duas são funções de $\mathbf{X}$, e $\mathbf{X}$ está fixo — e portanto sai de dentro da esperança condicional:

$$\mathbb{E}[(Y - r(\mathbf{X}))(r(\mathbf{X}) - g(\mathbf{X}))] = \mathbb{E}\left[(r(\mathbf{X}) - g(\mathbf{X})) \underbrace{\mathbb{E}[Y - r(\mathbf{X}) \mid \mathbf{X}]}_{=0}\right].$$

E a esperança que sobrou é zero, porque $\mathbb{E}[Y \mid \mathbf{X}] = r(\mathbf{X})$ é exatamente a definição de r . Sobram os dois quadrados.

(b) A identidade separa o risco de g em duas parcelas, e só a segunda depende de g :

$$R(g) = \underbrace{\mathbb{E}[(Y - r(\mathbf{X}))^2]}_{\text{fixo, não depende de } g} + \underbrace{\mathbb{E}[(r(\mathbf{X}) - g(\mathbf{X}))^2]}_{\geq 0}.$$

Como a segunda é uma esperança de algo não negativo, ela nunca ajuda: o melhor que g pode fazer é anulá-la, e isso acontece exatamente quando $g(\mathbf{X}) = r(\mathbf{X})$ com probabilidade 1. Logo r minimiza, e o mínimo é a primeira parcela.

Para identificá-la, olhe para o que está dentro do quadrado: $Y - r(\mathbf{X}) = Y - \mathbb{E}[Y \mid \mathbf{X}]$ é o desvio de Y em relação à sua própria média condicional. A lei da esperança total dá

$$R(r) = \mathbb{E}[(Y - \mathbb{E}[Y \mid \mathbf{X}])^2] = \mathbb{E}[\mathbb{E}[(Y - \mathbb{E}[Y \mid \mathbf{X}])^2 \mid \mathbf{X}]] = \mathbb{E}[\text{Var}(Y \mid \mathbf{X})].$$

(c) A expressão $\mathbb{E}[\text{Var}(Y \mid \mathbf{X})]$ não menciona g nenhuma. Ela é uma propriedade da **distribuição conjunta de $(\mathbf{X}, Y)$** — do problema, não do método.

O que ela mede é isto: fixe um valor $\mathbf{x}$ das covariáveis; entre todos os indivíduos que têm exatamente esse $\mathbf{x}$, quanto Y ainda varia? Se dois pacientes com idade, peso e exames idênticos ainda assim têm desfechos diferentes, nenhum algoritmo pode distinguir um do outro — ele recebeu a mesma entrada nos dois casos. Mesmo conhecendo r exatamente, com $n = \infty$ e zero erro de estimação, esse termo permanece.

E é isso que diz o que fazer para baixá-lo: não trocar de modelo, e sim **trocar de $\mathbf{X}$** . Medir uma covariável nova, que explique parte do que hoje é indistinguível. Isso muda o problema, e só mudar o problema resolve.

(d) Aplique a identidade de (a) com $g \equiv \mathbb{E}[Y]$, que é o melhor preditor constante:

$$\underbrace{R(\mathbb{E}[Y])}_{= \text{Var}(Y)} = R(r) + \mathbb{E}[(r(\mathbf{X}) - \mathbb{E}[Y])^2].$$

A esperança que sobrou é a variância de $r(\mathbf{X})$, porque $\mathbb{E}[r(\mathbf{X})] = \mathbb{E}[Y]$ pela lei da esperança total. Logo

$$\text{Var}(Y) - R(r) = \text{Var}(r(\mathbf{X})).$$

A pergunta que isso responde é: **vale a pena usar as covariáveis?** O lado esquerdo é quanto se ganha ao trocar o preditor constante pelo melhor preditor possível. O lado direito diz que esse ganho é exatamente o quanto $r(\mathbf{X})$ varia, isto é, o quanto a resposta esperada muda de um perfil de covariáveis para outro.

Nos dois extremos: se $\text{Var}(r(\mathbf{X})) = 0$, a função de regressão é constante, as covariáveis não carregam informação nenhuma sobre Y , e prever pela média é o melhor que existe — não há modelo a construir. Quanto maior essa variância, maior o prêmio por acertar r .

Exercício 2. A palavra "risco" apareceu durante o nosso curso com dois sentidos, e a diferença entre eles não é preciosismo: ela decide qual pergunta o seu número está respondendo.

Quando g é tratada como uma função *fixa*, a esperança em $\mathbb{E}[(Y - g(\mathbf{X}))^2]$ percorre só a

observação nova $(\mathbf{X}, Y)$. Chamamos isso de **risco condicional**. Quando $g = \hat{g}$ é tratada como aleatória — e ela é, porque foi construída a partir de $\mathcal{D}$ —, a esperança percorre também as amostras de treino possíveis, e temos o **risco esperado**.

- (a) Cada um dos dois oferece uma garantia diferente. Descreva as duas, e diga qual interessa a quem já ajustou um modelo e vai colocá-lo em produção, e qual interessa a quem ainda está escolhendo entre diversos métodos.
- (b) Você separou um conjunto de teste de m observações que não participou de nenhum treinamento, e calculou $\hat{R}(\hat{g}) = \frac{1}{m} \sum_{k=1}^m W_k$, com $W_k = (Y_k - \hat{g}(\mathbf{X}_k))^2$. Qual dos dois riscos esse número estima? Para responder, pergunte-se o que está fixo e o que varia no momento em que você faz a conta.
- (c) Um conjunto de teste permite algo que a validação cruzada não permite: uma barra de erro honesta. Explique por que os W_k são i.i.d. e escreva o intervalo de confiança aproximado de 95% que o Teorema Central do Limite fornece.

Solução

(a) O **risco condicional** é uma garantia sobre *aquela função específica*: se eu usar este $\hat{g}$, já ajustado, em observações novas, meu erro quadrático médio esperado é tanto.

O **risco esperado** é uma garantia sobre o *procedimento*: se eu sortear uma amostra de treino, rodar este método e usar o que sair, meu erro esperado é tanto. A esperança percorre também os treinos possíveis.

Quem vai pôr o modelo em produção quer o **condicional**. O modelo dele é um só, já existe, não vai ser reajustado — saber como se comportam os modelos que aquele método *costuma* produzir não paga as contas.

Quem está comparando métodos quer o **esperado**. A pergunta ali é "qual deles tende a produzir bons modelos", e uma rodada de sorte com um método ruim não deveria decidir a escolha.

(b) Estima o **risco condicional**.

No momento da conta, $\hat{g}$ já foi ajustado e não muda: é uma função fixa. O que varia de uma parcela para outra é apenas o par $(\mathbf{X}_k, Y_k)$ sorteado para o teste. A aleatoriedade do treino — que outra amostra teria dado outro $\hat{g}$ — não entra na conta em momento nenhum, porque o treino aconteceu antes e não é repetido.

Dito de outro modo: para estimar o risco *esperado* você teria de repetir o processo inteiro, sorteando vários treinos, e não é o que um único conjunto de teste faz.

(c) Condicionalmente a $\hat{g}$ — que é a situação, por (b) — cada $W_k = (Y_k - \hat{g}(\mathbf{X}_k))^2$ é função de um único par $(\mathbf{X}_k, Y_k)$. Esses pares são i.i.d. entre si e independentes do treino, e a mesma função $\hat{g}$ é aplicada a todos. Logo os W_k são i.i.d., com média $R(\hat{g})$.

Como $\hat{R}$ é média de i.i.d., o Teorema Central do Limite se aplica e dá

$$\hat{R}(\hat{g}) \pm 2\sqrt{\hat{\sigma}^2/m}, \quad \hat{\sigma}^2 = \frac{1}{m} \sum_{k=1}^m (W_k - \bar{W})^2.$$

Há uma hipótese fazendo todo o trabalho aqui: o teste não participou de nada. Se ele tivesse sido usado para escolher qualquer coisa, os W_k deixariam de ser independentes do $\hat{g}$ e o intervalo perderia o sentido.

Aula 02 — Regressão Linear e Regularização

Exercício 3 — Regressão no caso ortonormal. As notas da aula de Regressão Linear apresentam duas fórmulas prontas para o caso ortonormal, $\mathbb{X}^\top \mathbb{X} = \mathbb{I}$, e não as derivam. São elas que explicam a frase "o Ridge encolhe e o Lasso zera", e o exercício é preencher essa lacuna.

Use as definições da aula, **sem** fator $\frac{1}{2}$ no RSS:

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \sum_j \beta_j^2 \right\}, \quad \hat{\beta}^{\text{lasso}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \sum_j |\beta_j| \right\}.$$

- (a) Comece pelo passo que torna tudo possível. Supondo $\mathbb{X}^\top \mathbb{X} = \mathbb{I}$, mostre que o estimador de mínimos quadrados é $\hat{\beta} = \mathbb{X}^\top \mathbf{y}$ e que

$$\|\mathbf{y} - \mathbb{X}\beta\|^2 = \|\mathbf{y}\|^2 - \|\hat{\beta}\|^2 + \sum_{j=1}^p (\beta_j - \hat{\beta}_j)^2.$$

Explique por que essa identidade faz o problema **se separar** em p problemas de uma variável — e por que é justamente isso que falha quando as colunas não são ortonormais.

- (b) Com a separação em mãos, derive $\hat{\beta}_j^{\text{ridge}} = \hat{\beta}_j / (1 + \lambda)$.
- (c) Agora o Lasso. A dificuldade nova é que $|\beta_j|$ não é derivável em zero, então não dá para igualar a derivada a zero e pronto: trate separadamente as regiões $\beta_j > 0$, $\beta_j < 0$ e o ponto $\beta_j = 0$. Derive $\hat{\beta}_j^{\text{lasso}} = \text{sign}(\hat{\beta}_j) (\left| \hat{\beta}_j \right| - \lambda/2)_+$ e diga qual é a condição exata que leva um coeficiente a zero.
- (d) O limiar deu $\lambda/2$, e não λ . De onde veio esse 2? Diga o que mudaria nas duas fórmulas se a aula tivesse definido o RSS com um $\frac{1}{2}$ na frente, e que lição prática isso deixa.

Solução

(a) Com $\mathbb{X}^\top \mathbb{X} = \mathbb{I}$, as equações normais dão diretamente $\hat{\beta} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{y} = \mathbb{X}^\top \mathbf{y}$. Agora expanda o RSS, usando essa igualdade e a ortonormalidade:

$$\|\mathbf{y} - \mathbb{X}\beta\|^2 = \mathbf{y}^\top \mathbf{y} - 2\beta^\top \underbrace{\mathbb{X}^\top \mathbf{y}}_{=\hat{\beta}} + \beta^\top \underbrace{\mathbb{X}^\top \mathbb{X}}_{=\mathbb{I}} \beta = \|\mathbf{y}\|^2 - 2\beta^\top \hat{\beta} + \|\beta\|^2.$$

Os dois últimos termos pedem um completar quadrados:

$$-2\beta^\top \hat{\beta} + \|\beta\|^2 = \|\beta - \hat{\beta}\|^2 - \|\hat{\beta}\|^2,$$

o que dá a identidade do enunciado.

O que ela tem de especial: o único termo que depende de β é $\sum_j (\beta_j - \hat{\beta}_j)^2$, e nessa soma a j -ésima parcela envolve *apenas* β_j . Como as penalidades $\sum_j \beta_j^2$ e $\sum_j |\beta_j|$ também são somas coordenada a coordenada, o problema inteiro vira p problemas escalares que não conversam entre si — e problema escalar a gente resolve derivando.

Quando as colunas *não* são ortonormais, $\mathbb{X}^\top \mathbb{X}$ tem termos fora da diagonal, aparecem produtos $\beta_j \beta_\ell$ com $j \neq \ell$, e a separação morre. É exatamente por isso que o Lasso não tem solução fechada no caso geral: a ortonormalidade é uma hipótese muito forte, não uma simplificação inocente.

(b) O problema escalar é minimizar $h(\beta) = (\beta - \hat{\beta}_j)^2 + \lambda\beta^2$, que é derivável em toda a reta:

$$h'(\beta) = 2(\beta - \hat{\beta}_j) + 2\lambda\beta = 0 \implies \beta(1 + \lambda) = \hat{\beta}_j \implies \beta = \frac{\hat{\beta}_j}{1 + \lambda}.$$

Como $h'' = 2(1 + \lambda) > 0$, é mínimo.

Leia o resultado: o Ridge **multiplica** por um fator $1/(1 + \lambda) < 1$. Isso encolhe proporcionalmente — quem era grande perde mais em valor absoluto — e nunca zera, porque o fator só alcança zero no limite $\lambda \rightarrow \infty$.

(c) Agora $h(\beta) = (\beta - \hat{\beta}_j)^2 + \lambda |\beta|$. Analise por regiões.

Onde $\beta > 0$, temos $|\beta| = \beta$ e $h'(\beta) = 2(\beta - \hat{\beta}_j) + \lambda$, que zera em $\beta = \hat{\beta}_j - \lambda/2$. Só que essa raiz precisa cair na região em que a conta vale, isto é, precisa ser positiva — o que exige $\hat{\beta}_j > \lambda/2$.

Onde $\beta < 0$, temos $|\beta| = -\beta$ e $h'(\beta) = 2(\beta - \hat{\beta}_j) - \lambda$, que zera em $\beta = \hat{\beta}_j + \lambda/2$, admissível se $\hat{\beta}_j < -\lambda/2$.

E se $|\hat{\beta}_j| \leq \lambda/2$? Aí nenhuma das duas raízes cai na sua própria região: a candidata positiva sai negativa e vice-versa. Como h é convexa e contínua, o mínimo existe, e só pode estar no único ponto que sobrou — $\beta = 0$, justamente onde a função não é derivável. (Em linguagem de subgradiente: 0 é mínimo quando $0 \in -2\hat{\beta}_j + \lambda[-1, 1]$, que é exatamente a condição $|\hat{\beta}_j| \leq \lambda/2$.)

Juntando os três casos,

$$\hat{\beta}_j^{\text{lasso}} = \text{sinal}(\hat{\beta}_j)(|\hat{\beta}_j| - \lambda/2)_+,$$

e a condição exata para zerar é $|\hat{\beta}_j| \leq \lambda/2$.

Compare com (b) e a diferença salta: o Lasso **subtrai** uma constante em vez de multiplicar por um fator. Todo mundo encolhe pela mesma quantidade, $\lambda/2$, e quem era menor que isso em módulo não sobrevive ao deslocamento. É o *soft thresholding*, e é a razão algébrica de o Lasso fazer seleção de variáveis.

(d) O 2 vem da derivada do quadrado. Derivando $(\beta - \hat{\beta}_j)^2$ aparece um fator 2; derivando $\lambda|\beta|$ aparece só $\pm\lambda$. Ao isolar β dividimos tudo por 2, e o λ vira $\lambda/2$.

Com um $\frac{1}{2}$ na frente do RSS, e só dele, o fator 2 some da derivada do quadrado, e a da penalidade não muda. Refazendo as contas, o Lasso fica com $(\beta - \hat{\beta}_j) \pm \lambda = 0$, e o limiar vira λ ; o Ridge fica com $(\beta - \hat{\beta}_j) + 2\lambda\beta = 0$, e a fórmula vira $\hat{\beta}_j/(1 + 2\lambda)$.

As duas mudanças são, na verdade, uma só. Multiplicar o objetivo inteiro por 2 não altera o minimizador, e transforma o problema novo no da aula com 2λ no lugar de λ : basta fazer essa troca nas duas fórmulas. Repare que pôr o $\frac{1}{2}$ também na penalidade não mudaria nada — seria multiplicar o objetivo todo por uma constante.

A lição prática é que **o limiar depende da convenção**, não da matemática. Antes de comparar um λ do seu caderno com um λ de um artigo ou de uma biblioteca, confira qual objetivo cada um está minimizando. O Lasso do `scikit-learn` é um bom exemplo: ele minimiza $\frac{1}{2n} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \alpha \|\boldsymbol{\beta}\|_1$, e o seu α corresponde a $\lambda = 2n\alpha$ na convenção da aula — o n vem da média, e o 2 é exatamente o deste item.

Exercício 4 — O que o MQO estima quando a linearidade é falsa. Circula por aí a ideia de que a regressão linear "só vale se o modelo estiver correto". Vimos durante o curso que isso é impreciso: o MQO converge para uma função bem definida mesmo quando r não é linear.

Essa função é o **melhor preditor linear**,

$$\boldsymbol{\beta}^* = \arg \min_{\boldsymbol{\beta}} \mathbb{E}[(Y - \boldsymbol{\beta}^\top \mathbf{X})^2],$$

que existe sempre que $\Sigma = \mathbb{E}[\mathbf{X}\mathbf{X}^\top]$ é bem definida e invertível — *sem* supor nada sobre a forma de r .

- (a) Derive $\beta^* = \Sigma^{-1}\alpha$, onde $\alpha = \mathbb{E}[Y\mathbf{X}]$. É o mesmo cálculo das equações normais, com esperanças no lugar de somas.
- (b) O estimador de mínimos quadrados pode ser escrito como $\hat{\beta} = \hat{\Sigma}^{-1}\hat{\alpha}$, com $\hat{\Sigma} = \frac{1}{n} \sum_i \mathbf{X}_i \mathbf{X}_i^\top$ e $\hat{\alpha} = \frac{1}{n} \sum_i Y_i \mathbf{X}_i$. Olhe para essas duas expressões e diga o que elas são, estatisticamente. Em seguida, explique por que $\hat{\beta} \rightarrow \beta^*$ em probabilidade sem que se precise supor linearidade em lugar nenhum.
- (c) Todo teorema garante uma coisa e deixa de garantir outra. Enuncie as duas, com cuidado. Em particular: o resultado diz que o risco de $\hat{\beta}$ é pequeno?
- (d) Um colega ajusta uma regressão linear a dados em que r é visivelmente curva e conclui: "o coeficiente deu 2,3, logo aumentar x_1 em uma unidade aumenta Y em 2,3". Separe o que é leitura legítima de β^* do que não é.

Solução

- (a) Expanda o objetivo, tratando as esperanças como constantes:

$$Q(\beta) = \mathbb{E}[(Y - \beta^\top \mathbf{X})^2] = \mathbb{E}[Y^2] - 2\beta^\top \underbrace{\mathbb{E}[Y\mathbf{X}]}_{\alpha} + \beta^\top \underbrace{\mathbb{E}[\mathbf{X}\mathbf{X}^\top]}_{\Sigma} \beta.$$

O gradiente é $\nabla Q = -2\alpha + 2\Sigma\beta$, que se anula quando $\Sigma\beta = \alpha$, ou seja, $\beta^* = \Sigma^{-1}\alpha$. A Hessiana é 2Σ , definida positiva por hipótese: é mínimo, e é único.

A conta é a mesma das equações normais da aula, com $\mathbb{E}[\mathbf{X}\mathbf{X}^\top]$ no lugar de $\frac{1}{n}\mathbb{X}^\top\mathbb{X}$ e $\mathbb{E}[Y\mathbf{X}]$ no lugar de $\frac{1}{n}\mathbb{X}^\top\mathbf{y}$. É o mesmo problema, escrito na população em vez de na amostra.

- (b) Tanto $\hat{\Sigma}$ quanto $\hat{\alpha}$ são **médias amostrais** de variáveis i.i.d.: a primeira das matrizes $\mathbf{X}_i \mathbf{X}_i^\top$, a segunda dos vetores $Y_i \mathbf{X}_i$. Essa é a observação que resolve o item.

Pela lei dos grandes números, médias amostrais convergem para as esperanças correspondentes: $\hat{\Sigma} \rightarrow \Sigma$ e $\hat{\alpha} \rightarrow \alpha$ em probabilidade. Como inverter matriz e multiplicar são operações contínuas onde Σ é invertível, o teorema de Mann–Wald (continuous mapping) transporta a convergência:

$$\hat{\beta} = \hat{\Sigma}^{-1}\hat{\alpha} \rightarrow \Sigma^{-1}\alpha = \beta^*.$$

Em nenhum passo foi preciso supor $r(\mathbf{x}) = \beta^{\top}\mathbf{x}$. A definição de β^* é um problema de minimização que faz sentido para qualquer distribuição P ; o que a linearidade de r acrescentaria seria a coincidência $\beta^{*\top}\mathbf{x} = r(\mathbf{x})$ — uma coincidência agradável, mas dispensável para a convergência.

- (c) **Garante:** com n grande, o MQO acerta a melhor aproximação linear disponível. Ele não fica vagando nem depende de sorte da amostra; converge para um alvo bem definido, e esse alvo é o melhor que a classe das funções lineares tem a oferecer.

Não garante: que esse alvo seja bom. Se r for muito curva, o melhor preditor linear pode ter risco alto, e o teorema apenas assegura que chegaremos perto dele — perto de uma aproximação ruim continua sendo ruim.

Na linguagem da Aula 01: o teorema controla a **variância**, porque o erro de estimação some com n , e não diz absolutamente nada sobre o **viés de aproximação** $\mathbb{E}[(r(\mathbf{X}) - \beta^{*\top}\mathbf{X})^2]$, que é o preço fixo de ter escolhido uma classe rígida. "Convergir para o alvo certo" e "o alvo certo ser bom" são afirmações independentes, e só a primeira foi demonstrada.

- (d) O erro é ler β^* como efeito causal — ou mesmo como descrição local de r .

O que se pode dizer é que 2,3 é a inclinação da reta que *melhor aproxima* r no sentido de erro quadrático médio, ponderada pela distribuição de $\mathbf{X}$. É um resumo global, e nada além disso.

Duas consequências mostram por que a frase do colega não se sustenta. Primeira: com r curva, a inclinação verdadeira $\partial r / \partial x_1$ muda de ponto para ponto, e 2,3 é uma espécie de média dela — podendo não coincidir com a inclinação em ponto nenhum. Segunda, e mais desconfortável: se ele coletar a mesma medida noutra população, com outra faixa de x_1 , o β^* muda, porque a ponderação mudou — ainda que r seja exatamente a mesma função do mundo. Um número que depende de onde você coletou não descreve um mecanismo.

Exercício 5 — A Regressão Ridge como moda a posteriori. Já mencionamos que o Ridge tem uma leitura bayesiana: ele é a moda a posteriori sob uma priori gaussiana. A afirmação é mais do que curiosidade — ela dá um significado concreto ao λ , que até aqui era só um hiperparâmetro.

Considere o modelo

$$\mathbf{y} \mid \boldsymbol{\beta} \sim N(\mathbb{X}\boldsymbol{\beta}, \sigma^2 \mathbb{I}), \quad \boldsymbol{\beta} \sim N(\mathbf{0}, \sigma_\beta^2 \mathbb{I}),$$

com σ^2 e σ_β^2 conhecidos.

- (a) Escreva a densidade a posteriori de $\boldsymbol{\beta}$ a menos de constante multiplicativa e mostre que maximizá-la equivale a minimizar

$$\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \frac{1}{2\sigma_\beta^2} \|\boldsymbol{\beta}\|^2.$$

O caminho é o de sempre: passar ao logaritmo transforma produto em soma, e trocar o sinal transforma maximizar em minimizar.

- (b) Compare o que você obteve com a definição do Ridge da aula e identifique λ em função de σ^2 e σ_β^2 . Cuidado com o fator que precisa ser eliminado antes da comparação.
- (c) Agora a parte interessante: o que a priori está *afirmando* quando $\sigma_\beta^2 \rightarrow \infty$, e quando $\sigma_\beta^2 \rightarrow 0$? Ligue cada resposta ao comportamento do Ridge em $\lambda \rightarrow 0$ e $\lambda \rightarrow \infty$.

Solução

- (a) Pelo teorema de Bayes, a posteriori é proporcional ao produto da verossimilhança pela priori:

$$\pi(\boldsymbol{\beta} \mid \mathbf{y}) \propto f(\mathbf{y} \mid \boldsymbol{\beta}) \pi(\boldsymbol{\beta}) \propto \exp \left\{ -\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 \right\} \cdot \exp \left\{ -\frac{1}{2\sigma_\beta^2} \|\boldsymbol{\beta}\|^2 \right\}.$$

As constantes de normalização das duas gaussianas não dependem de $\boldsymbol{\beta}$ e por isso podem ser absorvidas no $\propto$.

Maximizar uma função positiva é o mesmo que maximizar seu logaritmo, e o logaritmo de um produto de exponenciais é a soma dos expoentes:

$$\log \pi(\boldsymbol{\beta} \mid \mathbf{y}) = \text{const} - \frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 - \frac{1}{2\sigma_\beta^2} \|\boldsymbol{\beta}\|^2.$$

Maximizar isso é minimizar o simétrico dos dois termos que dependem de $\boldsymbol{\beta}$, que é exatamente o objetivo do enunciado.

- (b) O objetivo de (a) tem um $1/(2\sigma^2)$ na frente do primeiro termo, e a definição do Ridge não tem fator nenhum ali. Multiplique tudo por $2\sigma^2 > 0$ — o que não altera o

minimizador, por ser constante positiva:

$$\|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \frac{\sigma^2}{\sigma_{\beta}^2} \|\boldsymbol{\beta}\|^2.$$

Agora a comparação é imediata, e

$$\lambda = \frac{\sigma^2}{\sigma_{\beta}^2}$$

(c) Quando $\sigma_{\beta}^2 \rightarrow \infty$, a priori fica **difusa**: ela espalha massa por toda parte e não expressa preferência alguma por coeficientes pequenos. Em outras palavras, ela não afirma nada. Correspondentemente $\lambda \rightarrow 0$ e o Ridge degenera no MQO: os dados decidem sozinhos, com viés baixo e variância alta.

Quando $\sigma_{\beta}^2 \rightarrow 0$, a priori fica **concentrada em zero**: ela afirma, antes de ver dado nenhum, que os coeficientes são praticamente nulos. Correspondentemente $\lambda \rightarrow \infty$ e $\hat{\boldsymbol{\beta}} \rightarrow \mathbf{0}$: viés máximo, variância mínima.

Entre os dois extremos, a fórmula $\lambda = \sigma^2/\sigma_{\beta}^2$ diz uma coisa bem razoável: regulariza-se mais quando os *dados* são ruidosos (σ^2 grande) ou quando a *crença prévia* é firme (σ_{β}^2 pequeno). O λ é a razão entre duas incertezas, e escolhê-lo por validação cruzada é, nessa leitura, deixar os dados escolherem a priori que melhor prediz.

Aula 03 — Seleção de Modelos e Validação Cruzada

Exercício 6 — A fórmula de regressão linear para LOOCV. O LOOCV (*Leave-One-Out Cross Validation*) parece caro: n ajustes, um para cada observação deixada de fora. Já comentamos que, para ajustes lineares, um único ajuste basta — mas não demonstramos.

Vamos demonstrar no caso da regressão linear por mínimos quadrados. A matriz de delineamento $\mathbb{X}$ tem linha i igual a $\mathbf{X}_i^\top$, e o ajuste com *todos* os dados é $\hat{\mathbf{g}}(\mathbf{x}) = \mathbf{x}^\top \hat{\boldsymbol{\beta}}$, com $\hat{\boldsymbol{\beta}} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{y}$. Chame de $\hat{g}_{-i}$ o ajuste feito sem a i -ésima observação. A fórmula a demonstrar é

$$\hat{R}_{\text{LOO}} = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{g}(\mathbf{X}_i)}{1 - h_{ii}} \right)^2,$$

em que h_{ii} é o i -ésimo elemento da diagonal da matriz $\mathbf{H} = \mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top$.

Suponha que $\mathbb{X}$ tenha posto cheio, e que continue tendo quando se tira qualquer uma de suas linhas. Assim todos os ajustes são únicos, e $h_{ii} \neq 1$: dividir por $1 - h_{ii}$ nunca é problema.

A demonstração vem em etapas. O item (a) mostra o que são os números $h_{i\ell}$; os itens (b) e (c) usam um truque para escrever $\hat{g}_{-i}(\mathbf{X}_i)$ em termos de $\hat{g}$; o (d) faz a conta; e o (e) interpreta o resultado.

- (a) *De onde vêm os pesos.* Mostre que o vetor de valores ajustados, $\hat{\mathbf{y}} = (\hat{g}(\mathbf{X}_1), \dots, \hat{g}(\mathbf{X}_n))^\top$, é igual a $\mathbf{H}\mathbf{y}$, e conclua, olhando a coordenada i , que

$$\hat{g}(\mathbf{X}_i) = \sum_{\ell=1}^n h_{i\ell} Y_{\ell},$$

em que $h_{i\ell}$ é a entrada (i, ℓ) de $\mathbf{H}$. Dica: como a linha i de $\mathbb{X}$ é $\mathbf{X}_i^\top$, vale $\hat{\mathbf{y}} = \mathbb{X}\hat{\boldsymbol{\beta}}$.

Em palavras: a predição no ponto $\mathbf{X}_i$ é uma combinação de todas as respostas, inclusive da própria Y_i , que entra com peso h_{ii} . De que esses pesos dependem? E de que eles *não* dependem?

- (b) *O truque.* Imagine o conjunto de dados em que a resposta Y_i foi trocada por $\tilde{Y}_i = \hat{g}_{-i}(\mathbf{X}_i)$ — o valor que o ajuste sem a observação i prevê ali —, com as covariáveis e as demais respostas intactas. Mostre que o ajuste de mínimos quadrados nesse conjunto modificado é exatamente $\hat{g}_{-i}$.

Antes do caso geral, veja o truque funcionar no modelo só com intercepto, em que o ajuste é a média: troque Y_i pela média das outras $n - 1$ respostas e confira que a média das n passa a ser justamente a média das outras. Para o caso geral, um caminho: escreva o RSS do conjunto modificado como a soma das $n - 1$ parcelas de sempre com a parcela da observação i ; veja o que $\hat{g}_{-i}$ faz com cada uma das duas partes; e conclua que nenhuma função linear consegue um RSS menor, o que basta, porque o ajuste é único.

- (c) *A mesma matriz, duas vezes.* O conjunto modificado tem as mesmas covariáveis que o original, e portanto a mesma matriz $\mathbf{H}$. Aplique (a) a ele e use (b) para mostrar que

$$\hat{g}_{-i}(\mathbf{X}_i) = \sum_{\ell \neq i} h_{i\ell} Y_\ell + h_{ii} \tilde{Y}_i.$$

Depois some e subtraia $h_{ii}Y_i$ para chegar a

$$\hat{g}_{-i}(\mathbf{X}_i) = \hat{g}(\mathbf{X}_i) + h_{ii}(\tilde{Y}_i - Y_i).$$

- (d) *A conta.* Na igualdade de (c), $\tilde{Y}_i$ aparece dos dois lados, porque o lado esquerdo é o próprio $\tilde{Y}_i$. Subtraia Y_i dos dois lados, junte os termos com $\tilde{Y}_i - Y_i$ e isole o resíduo de validação $Y_i - \hat{g}_{-i}(\mathbf{X}_i)$. Conclua a fórmula do enunciado.
- (e) *Lendo o resultado.* A matriz $\mathbf{H}$ tem duas propriedades. É simétrica, porque $\mathbb{X}^\top \mathbb{X}$ é simétrica e sua inversa também. E vale $\mathbf{H}\mathbf{H} = \mathbf{H}$, o que se confere multiplicando:

$$\mathbf{H}\mathbf{H} = \mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1} \underbrace{\mathbb{X}^\top \mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1}}_{=\mathbf{I}} \mathbb{X}^\top = \mathbf{H}.$$

Em palavras: $\mathbf{H}$ projeta $\mathbf{y}$ no espaço gerado pelas colunas de $\mathbb{X}$, e projetar de novo o que já foi projetado não muda nada. Usando as duas propriedades, a entrada (i, i) de $\mathbf{H}\mathbf{H} = \mathbf{H}$ dá

$$h_{ii} = \sum_{\ell=1}^n h_{i\ell}^2 = h_{ii}^2 + \sum_{\ell \neq i} h_{i\ell}^2.$$

Conclua que $0 \leq h_{ii} \leq 1$ e que, portanto, o resíduo de validação nunca é menor, em módulo, que o de treino. O que isso confirma sobre o erro de treino como estimativa do risco? E o que significa uma observação com h_{ii} próximo de 1?

Solução

- (a) O vetor $\hat{\mathbf{y}}$ empilha as predições de $\hat{g}$ nos próprios pontos de treino. Como a linha i de $\mathbb{X}$ é $\mathbf{X}_i^\top$, a coordenada i de $\mathbb{X}\hat{\boldsymbol{\beta}}$ é $\mathbf{X}_i^\top \hat{\boldsymbol{\beta}} = \hat{g}(\mathbf{X}_i)$, e por isso $\hat{\mathbf{y}} = \mathbb{X}\hat{\boldsymbol{\beta}}$. Basta substituir $\hat{\boldsymbol{\beta}}$:

$$\hat{\mathbf{y}} = \mathbb{X}\hat{\boldsymbol{\beta}} = \underbrace{\mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top}_{=\mathbf{H}} \mathbf{y} = \mathbf{H}\mathbf{y}.$$

A coordenada i de $\mathbf{H}\mathbf{y}$ é a linha i de $\mathbf{H}$ multiplicada por $\mathbf{y}$, ou seja, $\sum_{\ell} h_{i\ell} Y_\ell$. Igualando as coordenadas i dos dois lados, sai a igualdade pedida.

Os pesos $h_{i\ell}$ são entradas de $\mathbf{H}$, que é construída só com $\mathbb{X}$. Eles dependem das **covariáveis** e **não dependem das respostas**: troque o vetor $\mathbf{y}$ mantendo as covariáveis, e a predição em $\mathbf{X}_i$ continua sendo a mesma combinação, agora das respostas novas. É essa propriedade que o item (c) usa. (No modelo só com intercepto, $\mathbb{X}$ é uma coluna de uns, todas as

entradas de $\mathbf{H}$ valem $1/n$, e a combinação é a média.)

(b) Primeiro o caso da média. Seja $\bar{Y}_{-i}$ a média das outras $n - 1$ respostas. Trocando Y_i por $\bar{Y}_{-i}$, a soma das n respostas vira $(n - 1)\bar{Y}_{-i} + \bar{Y}_{-i} = n\bar{Y}_{-i}$, e a nova média é $\bar{Y}_{-i}$. A observação trocada foi posta exatamente onde o ajuste sem ela já estava, e por isso não puxa o ajuste para lado nenhum.

O caso geral é o mesmo argumento, escrito com o RSS. Para uma função linear g qualquer, o RSS do conjunto modificado é

$$\underbrace{\sum_{\ell \neq i} (Y_\ell - g(\mathbf{X}_\ell))^2}_{\text{as } n-1 \text{ parcelas de sempre}} + \underbrace{(\tilde{Y}_i - g(\mathbf{X}_i))^2}_{\text{a parcela da observação } i}.$$

Veja o que $\hat{g}_{-i}$ faz com cada parte. A primeira ela minimiza: é a definição de $\hat{g}_{-i}$, o ajuste de mínimos quadrados sem a observação i . A segunda ela zera, porque $\tilde{Y}_i$ foi escolhido como $\hat{g}_{-i}(\mathbf{X}_i)$.

Nenhuma função linear consegue menos que o mínimo na primeira parte, nem menos que zero na segunda. Logo $\hat{g}_{-i}$ atinge o menor RSS possível no conjunto modificado e, como o ajuste de mínimos quadrados é único, é ele.

(c) O conjunto modificado difere do original só na resposta i . As covariáveis são as mesmas, então a matriz $\mathbf{H}$ é a mesma, e (a) diz que o ajuste nele prevê em $\mathbf{X}_i$ a mesma combinação de antes, com $\tilde{Y}_i$ no lugar de Y_i :

$$\sum_{\ell \neq i} h_{i\ell} Y_\ell + h_{ii} \tilde{Y}_i.$$

Por (b), esse ajuste é $\hat{g}_{-i}$; logo a soma acima é $\hat{g}_{-i}(\mathbf{X}_i)$, que é a primeira igualdade.

Para a segunda, somar e subtrair $h_{ii} Y_i$ completa a soma sobre todos os ℓ :

$$\hat{g}_{-i}(\mathbf{X}_i) = \underbrace{\sum_{\ell} h_{i\ell} Y_\ell}_{=\hat{g}(\mathbf{X}_i)} + h_{ii} \tilde{Y}_i - h_{ii} Y_i = \hat{g}(\mathbf{X}_i) + h_{ii} (\tilde{Y}_i - Y_i).$$

(d) Como o lado esquerdo de (c) é $\tilde{Y}_i$, a igualdade diz

$$\tilde{Y}_i = \hat{g}(\mathbf{X}_i) + h_{ii} (\tilde{Y}_i - Y_i).$$

Subtraindo Y_i dos dois lados, a diferença $\tilde{Y}_i - Y_i$ aparece nos dois:

$$\tilde{Y}_i - Y_i = (\hat{g}(\mathbf{X}_i) - Y_i) + h_{ii} (\tilde{Y}_i - Y_i) \implies (1 - h_{ii})(\tilde{Y}_i - Y_i) = \hat{g}(\mathbf{X}_i) - Y_i.$$

Dividindo por $1 - h_{ii}$ e trocando o sinal dos dois lados,

$$Y_i - \hat{g}_{-i}(\mathbf{X}_i) = \frac{Y_i - \hat{g}(\mathbf{X}_i)}{1 - h_{ii}}.$$

Elevando ao quadrado e tirando a média em i , sai a fórmula.

O ganho está no lado direito: ele só usa $\hat{g}$, o ajuste feito uma vez, com todos os dados. Os n ajustes do LOOCV viraram um.

(e) Na igualdade do enunciado, a primeira passagem usa a simetria: $(\mathbf{H}\mathbf{H})_{ii} = \sum_{\ell} h_{i\ell} h_{\ell i} = \sum_{\ell} h_{i\ell}^2$. Dela saem as duas desigualdades. Como soma de quadrados, $h_{ii} \geq 0$. E como a soma dos quadrados com $\ell \neq i$ também é ≥ 0 , temos $h_{ii} \geq h_{ii}^2$, isto é, $h_{ii}(1 - h_{ii}) \geq 0$ — o que, junto com $h_{ii} \geq 0$, dá $h_{ii} \leq 1$.

O extremo $h_{ii} = 1$ é o que a hipótese do enunciado exclui. Ele acontece exatamente quando $\mathbb{X}$ perde posto sem a linha i — por exemplo, se uma coluna é uma indicadora que só a observação i tem. Aí as outras observações não dizem nada sobre a predição em $\mathbf{X}_i$, e $\hat{g}_{-i}$ nem é único.

Com $0 \leq h_{ii} < 1$, o fator $1/(1 - h_{ii})$ é pelo menos 1, e (d) dá

$$|Y_i - \hat{g}_{-i}(\mathbf{X}_i)| \geq |Y_i - \hat{g}(\mathbf{X}_i)| \quad \text{para toda observação } i.$$

Tirando a média dos quadrados, $\hat{R}_{\text{LOO}}$ nunca fica abaixo do erro quadrático médio de treino. Isso confirma, de um jeito bem concreto, que o erro de treino é **otimista**: na regressão linear ele fica abaixo da estimativa por LOOCV em toda amostra — não só em média —, observação por observação, e com o tamanho da correção escrito.

O h_{ii} mede a **alavancagem**: quanto a própria Y_i pesa na predição feita em $\mathbf{X}_i$. Perto de 1, essa predição é quase só Y_i — o ajuste passa colado no ponto, e o resíduo de treino sai pequeno e engana. O fator $1/(1 - h_{ii})$ fica grande justamente para desfazer o engano: sem a observação i , as outras quase não informam o que acontece em $\mathbf{X}_i$, e o resíduo de validação registra isso.

Exercício 7 — Duas fórmulas da validação cruzada. Quem estuda validação cruzada pelas notas de aula e pelo livro encontra duas fórmulas diferentes para a mesma quantia, e é natural desconfiar de que uma delas esteja errada. Não está: elas só diferem na unidade que cada uma pondera igualmente.

As notas de aula definem

$$\hat{R}_{k\text{-CV}} = \frac{1}{n} \sum_{j=1}^k \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2,$$

e o livro define $\text{CV}_{(k)} = \frac{1}{k} \sum_{j=1}^k \text{EQM}_j$, com $\text{EQM}_j = \frac{1}{|L_j|} \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2$.

(a) Reescreva a fórmula da aula de modo a fazer os EQM_j aparecerem, mostrando que

$$\hat{R}_{k\text{-CV}} = \sum_{j=1}^k \frac{|L_j|}{n} \text{EQM}_j.$$

- (b) Olhando para os pesos que você obteve, diga em que condição as duas definições coincidem — e se coincidem exatamente ou apenas aproximadamente. Em seguida, nomeie a unidade que cada fórmula pondera igualmente.
- (c) Com $n = 50$ e $k = 7$, as dobras não podem ter todas o mesmo tamanho; suponha que tenham tamanhos 8, 8, 7, 7, 7, 7, 6. Confirme que somam 50 e explique por que, neste caso, os dois números diferem.
- (d) Suponha que a dobra de 6 observações tenha $\text{EQM} = 10$ e todas as outras tenham $\text{EQM} = 1$. Calcule os dois estimadores, diga qual deles dá mais peso à dobra atípica, e qual você reportaria. Justifique a escolha.

Solução

(a) A chave é reconhecer a soma interna. Pela definição de EQM_j , basta multiplicar dos

dois lados por $|L_j|$:

$$\sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2 = |L_j| \text{EQM}_j.$$

Substituindo na fórmula da aula,

$$\hat{R}_{k\text{-CV}} = \frac{1}{n} \sum_{j=1}^k |L_j| \text{EQM}_j = \sum_{j=1}^k \frac{|L_j|}{n} \text{EQM}_j.$$

São os *mesmos* EQM_j do livro, numa média ponderada. E os pesos somam 1, porque as dobras particionam as n observações: $\sum_j |L_j| = n$.

(b) Se k divide n , todas as dobras têm o mesmo tamanho $|L_j| = n/k$, e cada peso vale $(n/k)/n = 1/k$. A média ponderada vira média simples — que é exatamente a definição do livro.

E coincidem **exatamente**, não aproximadamente: é a mesma soma dos mesmos números com os mesmos pesos.

Quanto à unidade, a diferença é essa: a fórmula da aula pondera igualmente cada **observação**, e a do livro pondera igualmente cada **dobra**.

(c) $8 + 8 + 7 + 7 + 7 + 7 + 6 = 50$.

Diferem porque os tamanhos não são todos iguais. Os pesos da fórmula da aula valem $8/50$, $8/50$, $7/50$ (quatro vezes) e $6/50$, enquanto a do livro usa $1/7$ para todas as sete.

O efeito concreto é sobre as observações individuais: uma que caiu na dobra de 6 recebe, na conta do livro, peso maior do que uma que caiu na dobra de 8 — porque ela divide a responsabilidade da sua dobra com menos gente.

(d) Pela fórmula da aula, a dobra atípica entra com peso $6/50$ e as outras 44 observações com $44/50$:

$$\hat{R}_{k\text{-CV}} = \frac{6}{50} \times 10 + \frac{44}{50} \times 1 = \frac{60 + 44}{50} = \frac{104}{50} = \mathbf{2,08}.$$

Pela do livro, a dobra atípica é uma das sete, e só:

$$\text{CV}_{(7)} = \frac{1}{7}(10 + 6 \times 1) = \frac{16}{7} \approx \mathbf{2,286}.$$

A do livro dá mais peso à dobra atípica — e é fácil ver por quê: ela é a *menor* dobra e ainda assim vale $1/7 \approx 0,143$ do total, contra $6/50 = 0,12$ na outra conta. Justamente por ter menos observações, cada uma delas pesa mais.

Qual reportar? Para *estimar o risco*, a fórmula da aula é a mais defensável: a unidade amostral é a observação, não a dobra, e não há razão para uma observação valer mais por acaso de agrupamento. Na prática, porém, o `scikit-learn` segue o livro — `cross_val_score(...).mean()` é média não ponderada — então o essencial é *saber qual das duas o seu código está calculando* antes de comparar com o de outra pessoa.

E a recomendação da aula encerra a discussão pela raiz: com n pequeno, escolha um k que divida n . Aí as duas coincidem e a pergunta não se coloca.

Aula 04 — Métodos Não Paramétricos (KNN)

Exercício 8 — duas doenças, dois remédios. Durante o curso, apresentamos ferramentas que, à primeira vista, andam em sentidos opostos. A regularização *restringe* o modelo: o Ridge,

por exemplo, soma ao RSS do MQO uma penalidade sobre o tamanho dos coeficientes,

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}.$$

Os métodos não paramétricos o *soltam*: o KNN, por exemplo, não supõe forma nenhuma para r e prevê pela média das respostas dos k vizinhos mais próximos de $\mathbf{x}$, cujos índices formam o conjunto $\mathcal{N}_{\mathbf{x}}$,

$$\hat{r}(\mathbf{x}) = \frac{1}{k} \sum_{i \in \mathcal{N}_{\mathbf{x}}} Y_i.$$

Parece contradição, e não é: são ferramentas para serem usadas em dois contextos diferentes.

Para ver quais, a referência é a decomposição do erro de previsão num ponto fixo $\mathbf{x}_0$. Para um estimador $\hat{r}$ construído com a amostra $\mathcal{D}$,

$$\mathbb{E}_{\mathcal{D}}[(Y_0 - \hat{r}(\mathbf{x}_0))^2] = \underbrace{(\mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0)] - r(\mathbf{x}_0))^2}_{\text{viés}^2} + \underbrace{\text{Var}_{\mathcal{D}}(\hat{r}(\mathbf{x}_0))}_{\text{variância}} + \underbrace{\sigma^2(\mathbf{x}_0)}_{\text{irredutível}},$$

em que Y_0 é uma resposta nova em $\mathbf{x}_0$, $\sigma^2(\mathbf{x}_0) = \text{Var}(Y \mid \mathbf{X} = \mathbf{x}_0)$, e $\mathbb{E}_{\mathcal{D}}$ e $\text{Var}_{\mathcal{D}}$ percorrem as amostras de treino possíveis. O último termo não depende do método; a disputa é entre os dois primeiros.

- (a) Explique, em palavras, o que o viés e a variância medem. Depois diga qual dos dois termos a regularização ataca e qual os métodos não paramétricos atacam, e o que cada família aceita pagar no outro.
- (b) Descreva, em uma frase cada, a situação que motiva cada família: o que está errado com o modelo *antes* de aplicarmos Ridge, e o que está errado *antes* de aplicarmos um spline?
- (c) O KNN com $k = 1$ e o MQO com p grande erram por motivos que, na decomposição, caem no mesmo lugar. Explique. Em seguida diga qual é o remédio de cada um e por que os dois remédios se parecem.

Dica para o KNN: trate as covariáveis da amostra como fixas — assim os vizinhos de $\mathbf{x}_0$ também ficam fixos — e suponha que Y tenha variância constante σ^2 em torno de r . Nesse caso a decomposição fica

$$\mathbb{E}[(Y_0 - \hat{r}(\mathbf{x}_0))^2] = \left(\frac{1}{k} \sum_{i \in \mathcal{N}_{\mathbf{x}_0}} r(\mathbf{X}_i) - r(\mathbf{x}_0) \right)^2 + \frac{\sigma^2}{k} + \sigma^2.$$

O que acontece com cada termo quando k cresce?

- (d) As duas ideias podem ser combinadas? Dê um exemplo concreto, visto no curso, de método que seja ao mesmo tempo não paramétrico e regularizado, e diga qual botão controla cada coisa nele.

Solução

(a) O **viés** compara a média de $\hat{r}(\mathbf{x}_0)$ sobre todas as amostras de treino possíveis com o alvo $r(\mathbf{x}_0)$. É o erro sistemático, o que sobra depois que o acaso da amostra se cancela na média — e, quando o modelo não consegue representar r , ele não diminui com mais dados. A **variância** mede a instabilidade: o quanto $\hat{r}(\mathbf{x}_0)$ mudaria se a amostra de treino fosse outra, do mesmo tamanho.

A **regularização ataca a variância**: ela restringe o espaço de soluções, encolhendo os

coeficientes, e aceita pagar viés por isso.

Os **métodos não paramétricos atacam o viés**: eles ampliam a classe de funções representáveis para que r caiba nela, e aceitam pagar variância.

O termo irreduzível fica fora da disputa: nenhuma das duas famílias mexe nele.

(b) Antes do Ridge, o problema é um modelo **flexível demais para a amostra que se tem**: colunas demais ou colineares, o ajuste persegue o ruído e os coeficientes ficam instáveis. Excesso de variância.

Antes do spline, o problema é um modelo **rígido demais para a verdade**: a reta não acompanha uma r curva, e o erro persiste por mais dados que se colete. Excesso de viés. A diferença entre "para a amostra" e "para a verdade" é o coração da distinção: uma é falta de dados, a outra é falta de classe.

(c) Os dois erram por **variância**.

O KNN com $k = 1$ faz cada predição depender de uma única observação, e todo o ruído daquele ponto entra na resposta. A fórmula da dica mostra o tamanho disso: com $k = 1$ o termo de variância vale σ^2 , tanto quanto o próprio ruído, enquanto o viés costuma ser pequeno, porque o vizinho mais próximo está perto de $\mathbf{x}_0$. O ajuste passa exatamente pelos dados de treino, com resíduo nulo e nenhuma estabilidade — troque a amostra e a função muda inteira.

O MQO com p grande tem parâmetros demais para os dados disponíveis, e cada coeficiente é estimado com pouca informação. No limite $p > n$ a solução nem é única.

O remédio do KNN é **aumentar k** . Pela dica, a variância cai como σ^2/k , e o preço aparece no primeiro termo: vizinhos mais distantes entram na média, e $\frac{1}{k} \sum r(\mathbf{X}_i)$ se afasta de $r(\mathbf{x}_0)$. O do MQO é **regularizar**, encolhendo os coeficientes em direção a zero. No caso ortonormal a troca é igualmente explícita: o Ridge multiplica cada coeficiente por $1/(1 + \lambda)$, o que divide a variância por $(1 + \lambda)^2$ e cria um viés de $-\lambda\beta_j/(1 + \lambda)$.

Os dois se parecem porque fazem a mesma coisa no fundo: reduzem a *complexidade efetiva* do ajuste, trocando variância por viés. Em ambos há um botão contínuo — k de um lado, λ do outro — e em ambos ele se escolhe por validação cruzada, nunca no olho.

Um cuidado que costuma confundir: os botões correm em sentidos opostos. k *grande* e λ *grande* dão modelos mais simples, mas k grande significa vizinhança larga e λ grande significa coeficientes pequenos. O teste seguro, quando a memória falha, é perguntar de que lado está o modelo constante.

(d) Podem, e o exemplo do curso são as *smoothing splines* da Aula 04.

Elas põem um nó em **cada observação** — portanto são não paramétricas ao extremo, com $I = n$ — e controlam a flexibilidade resultante **penalizando a curvatura**:

$$\sum_{i=1}^n (y_i - g(x_i))^2 + \gamma \int (g''(x))^2 dx.$$

Os dois papéis estão separados e visíveis: a base cresce com n (o lado não paramétrico) e o γ regula quanta daquela liberdade é de fato usada (o lado regularizado). E neste método quem manda é o γ — os nós deixaram de ser o botão, porque são todos. É uma solução elegante para um problema chato, que é ter de escolher onde pôr os nós.

Aula 05 — Árvores de Regressão e *Ensembles*

Exercício 9 — O problema da poda. Construir uma árvore tem duas etapas, e elas usam objetivos diferentes de propósito. O crescimento escolhe cortes que mais reduzem o RSS; a poda

escolhe uma subárvore $T \subseteq T_0$ minimizando

$$C_\alpha(T) = \sum_{k=1}^{|T|} \sum_{i: \mathbf{X}_i \in R_k} (Y_i - \hat{y}_{R_k})^2 + \alpha |T|,$$

onde $|T|$ é o número de folhas e $\hat{y}_{R_k}$ é a média das respostas na folha R_k . Se a forma lembra a regularização, não é coincidência.

- (a) O que se obtém nos dois extremos, $\alpha = 0$ e $\alpha \rightarrow \infty$? Diga em cada caso quantas folhas tem a subárvore vencedora.
- (b) Considere uma folha com RSS igual a S , que pode ser dividida em duas com RSS S_a e S_b . Escreva a condição sobre $S - (S_a + S_b)$ para que a divisão valha a pena segundo C_α , e interprete: em que unidade o α está cobrando?
- (c) Uma árvore tem RSS total 120 com 6 folhas; podando-a para 4 folhas, o RSS sobe para 140. Para quais valores de α a podada é preferível?
- (d) Por que a poda usa um critério diferente do crescimento, em vez de simplesmente parar de crescer quando o ganho fica pequeno? Dê um exemplo de estrutura nos dados que um critério de parada perderia e a poda recupera.

Solução

(a) Com $\alpha = 0$ a penalidade some e $C_0(T)$ é só o RSS. Como o RSS nunca aumenta ao acrescentar cortes, a minimizadora é a árvore inteira T_0 — no limite, uma observação por folha e RSS zero.

Com $\alpha \rightarrow \infty$ o termo $\alpha |T|$ domina, e minimizá-lo exige $|T|$ mínimo: a vencedora é a **raiz sozinha**, uma única folha, cuja predição é a média de todas as respostas.

Entre os dois extremos, α percorre uma sequência finita de subárvores aninhadas — e é essa sequência que a validação cruzada percorre para escolher o α .

(b) Dividir a folha troca 1 folha por 2: o número de folhas sobe em 1 e o custo de complexidade sobe em α . Em compensação o RSS cai de S para $S_a + S_b$. A divisão reduz C_α se, e só se,

$$(S_a + S_b) + \alpha(|T| + 1) < S + \alpha |T| \iff S - (S_a + S_b) > \alpha.$$

Em palavras: **a divisão precisa reduzir o RSS em mais de α** .

E a interpretação sai direto daí: o α é literalmente o *preço de uma folha*, cobrado na mesma unidade do RSS. Ganhos menores que esse preço não pagam a complexidade que introduzem. Se o RSS está em reais ao quadrado, o α também está — o que, de passagem, explica por que ele não é comparável entre problemas de escalas diferentes.

(c) A árvore grande custa $120 + 6\alpha$; a podada, $140 + 4\alpha$. A podada vence quando

$$140 + 4\alpha < 120 + 6\alpha \iff 20 < 2\alpha \iff \boxed{\alpha > 10}.$$

Para $\alpha < 10$ mantêm-se as seis folhas; em $\alpha = 10$ as duas empatam.

O 10 é exatamente o ganho médio de RSS por folha removida, $20/2$. O ponto de indiferença é sempre o ganho por folha — o que dá uma forma rápida de estimar de cabeça qual α separa duas subárvores.

(d) Porque o critério de parada é **míope**: ele avalia um corte de cada vez e não enxerga o que viria depois. Um corte pode reduzir pouco o RSS sozinho e ainda assim ser indispensável, por *viabilizar* os cortes seguintes. Quem para ali nunca chega a eles.

O exemplo clássico é a **interação**. Tome $y = \sin(x_1 x_2)$, com x_1 e x_2 simétricos em torno de zero. Um corte em x_1 isolado quase não reduz o RSS: de cada lado dele, y continua metade positivo e metade negativo, e a média local segue perto de zero. O mesmo vale para x_2 . Só a *combinação* dos dois cortes separa os quadrantes — e um critério de parada com limiar razoável interromperia o crescimento logo no primeiro, devolvendo a raiz sozinha. A poda escapa disso porque **cresce primeiro e corta depois**: a árvore grande chega a descobrir a interação, e a poda então avalia subárvores inteiras, não cortes isolados. É por isso que os dois objetivos são diferentes de propósito — e é por isso que não se deve confundir o α da poda com um limite de profundidade, que é justamente um critério de parada disfarçado.

Exercício 10. Justificamos o *bagging* com uma proposição de enunciado curto: se $g_1, \dots, g_B$ são não-viesados para $r(\mathbf{x})$, têm a mesma variância $v(\mathbf{x})$ e são **não-correlacionados**, então a média $\bar{g} = \frac{1}{B} \sum_b g_b$ tem risco $\text{Var}(Y | \mathbf{x}) + v(\mathbf{x})/B$, que nunca passa do risco $\text{Var}(Y | \mathbf{x}) + v(\mathbf{x})$ de cada g_b .

Proposições com hipóteses só ficam úteis quando se sabe o que acontece ao violá-las — e, no caso do *bagging*, uma delas é violada o tempo todo.

- (a) Identifique as duas condições e explique, para cada uma, o que acontece com a conclusão se ela falhar.
- (b) O *bagging* usa árvores **profundas e não podadas**. Qual das duas condições essa escolha atende? E por que podar as árvores seria contraproducente aqui?
- (c) Na prática as árvores do *bagging* são correlacionadas. Explique a razão — o que elas têm em comum que as faz parecidas — e por que aumentar B não resolve esse problema específico.
- (d) A floresta aleatória sorteia $m < p$ covariáveis candidatas em cada nó. Explique como isso ataca a condição comprometida, qual é o preço pago na outra, e por que essa troca costuma compensar.

Solução

(a) As duas condições são:

(i) **não-viesados**. Se os g_b tiverem viés, a média o herda integralmente: $\mathbb{E}[\bar{g}] = \mathbb{E}[g_b] \neq r(\mathbf{x})$. Promediar reduz variância, mas **não corrige viés** — a média de mil estimadores enviesados é igualmente enviesada. A conclusão sobre o risco deixa de valer, porque sobra um termo de viés² que B nenhum elimina.

(ii) **não-correlacionados**. Se houver correlação $\rho > 0$ entre pares, a variância da média não é v/B , e sim

$$\text{Var}(\bar{g}) = \rho v + \frac{1 - \rho}{B} v \xrightarrow{B \rightarrow \infty} \rho v.$$

A redução **estaciona num piso** ρv , em vez de ir a zero.

(b) Atende a condição (i), a de não-viesamento.

Árvores profundas são muito flexíveis: acompanham r de perto e têm viés baixo, ao custo de variância alta. E variância alta é justamente o defeito que a agregação sabe consertar — de graça, pela própria proposição.

Podar seria contraproducente porque a poda *introduz viés de propósito* para reduzir variância. Só que a variância já vai ser tratada pela média dos B ajustes. Podar seria, então, pagar viés por um benefício que se teria sem pagar nada.

A regra que fica: deixe cada árvore ser instável, e deixe a média estabilizar.

(c) As árvores do *bagging* são treinadas em amostras bootstrap do **mesmo** conjunto de dados, e todas enxergam **todas** as p covariáveis em todos os nós.

Se houver uma covariável fortemente preditiva, ela tende a ser escolhida no primeiro corte por quase todas as árvores. E árvores que começam igual continuam parecidas: elas erram juntas, o que é precisamente o que $\rho > 0$ significa.

Aumentar B não resolve porque, na fórmula de (a), o termo ρv **não depende de B** . Acrescentar árvores só encolhe o segundo termo; o piso permanece onde está. Passado certo ponto, cada árvore nova custa tempo de computação e não compra quase nada.

(d) A floresta ataca diretamente o ρ . Ao sortear $m < p$ candidatas por nó, ela impede que a covariável dominante seja usada sempre: em cerca de $1 - m/p$ dos nós ela sequer está disponível, e a árvore é obrigada a olhar para outra coisa. As árvores passam a divergir estruturalmente, ρ cai, e com ele o piso ρv .

O preço é pago na qualidade individual. Uma árvore proibida de usar a melhor covariável em parte dos nós é uma árvore **pior**, com variância individual v maior. O sorteio degrada cada membro para melhorar o conjunto — o que é contraintuitivo, e é o ponto que costuma ser mal explicado.

Compensa porque, com B grande, o que sobra em $\rho v + \frac{1-\rho}{B}v$ é ρv , e a queda em ρ costuma ser proporcionalmente maior que a subida em v . Há um limite, claro: com m pequeno demais as árvores ficam ruins demais e o produto ρv volta a subir. É por isso que m é um hiperparâmetro, e $m \approx p/3$ em regressão é um ponto de partida razoável — não uma verdade.

Aula 06 — Pré-processamento e *Pipelines*

Exercício 11. Um colega recebeu um banco de dados em que a coluna **renda** está em reais e a coluna **altura** em metros, e pergunta se precisa padronizar antes de ajustar. A resposta honesta é "depende do método" — e o critério que decide cabe numa pergunta: **o método soma coisas vindas de colunas diferentes?**

Se soma, as unidades precisam ser comparáveis, e trocar uma delas estraga a comparação. Se não soma, a unidade é irrelevante.

- (a) Para cada método abaixo, diga se multiplicar uma única coluna por 1000 **muda** ou **não muda** a predição, justificando em uma linha onde está — ou onde não está — a soma sobre colunas.
 - (i) Mínimos quadrados ordinários.
 - (ii) Regressão Ridge com $\lambda > 0$ fixo.
 - (iii) Árvore de regressão.
 - (iv) Floresta aleatória.
 - (v) KNN com k fixo.
- (b) Entre os que mudam, qual você espera que seja o mais afetado, e por quê? Compare o *modo* como a escala entra em cada um.
- (c) Outro colega ajustou o Lasso a dados padronizados, com λ escolhido por validação cruzada. Em seguida multiplicou por 1000 a coluna de maior efeito sobre Y , reajustou com o *mesmo* λ , e o erro quadrático médio no conjunto de teste *diminuiu*. Ele conclui que é melhor não padronizar. Explique por que a reescala pode ter ajudado e por que a conclusão não se sustenta.

Solução

(a) Só dois mudam, o Ridge e o KNN: os dois que somam coisas vindas de colunas diferentes.

- (i) **Não muda.** O MQO é equivariante: o coeficiente da coluna se divide por 1000 e o produto $\beta_j x_j$ fica igual. Nada na função-objetivo compara coeficientes entre si.
- (ii) **Muda.** A penalidade $\lambda \sum_j \beta_j^2$ soma coeficientes de colunas diferentes; mudar a unidade de uma delas muda quanto ela pesa nessa soma.
- (iii) **Não muda.** A árvore só pergunta " $x_j \leq t$ ". O corte t é multiplicado junto, e a pergunta separa exatamente as mesmas observações.
- (iv) **Não muda.** É uma média de árvores, e cada uma é indiferente; a indiferença atravessa a agregação.
- (v) **Muda.** A distância euclidiana $\sum_j (x_{ij} - x_{lj})^2$ é uma soma sobre colunas.

(b) O KNN. A diferença não está no tamanho do fator — nos dois métodos ele chega a 10^6 —, e sim no que a escala controla em cada um.

No Ridge, a escala mexe só no *quanto* um coeficiente é penalizado. O coeficiente que produz o mesmo ajuste fica 1000 vezes menor, e o termo dele na penalidade $\lambda \sum_j \beta_j^2$, 10^6 vezes menor: a coluna fica praticamente livre do encolhimento. Mas o ajuste continua usando todas as colunas, e o pior que pode acontecer é aquele coeficiente deixar de ser encolhido — uma mudança limitada, que desaparece quando $\lambda \rightarrow 0$, porque aí o Ridge vira o MQO, que não muda.

No KNN, a escala mexe em *quem* entra na média. As diferenças na coluna reescalada são multiplicadas por 1000, e a contribuição delas para $\sum_j (x_{ij} - x_{lj})^2$, por 10^6 . A coluna passa a decidir sozinha quem é vizinho de quem, e as demais não ficam apenas menos importantes — somem da conta, e o método deixa de usar a informação que carregavam.

(c) Primeiro, por que a reescala pode ter ajudado. Multiplicar a coluna por 1000 faz o coeficiente que produz o mesmo ajuste ficar 1000 vezes menor, e um coeficiente minúsculo quase não pesa em $\lambda \sum_j |\beta_j|$: a coluna ficou praticamente isenta da penalidade. Como era a de maior efeito, o Lasso deixou de encolher justamente o coeficiente que mais importa. E encolher um coeficiente grande é quase só viés. No caso ortonormal, o Lasso subtrai $\lambda/2$ de todo coeficiente que sobrevive, um deslocamento que não reduz variância nenhuma. Tirar esse viés pode baixar o erro de teste — pode, não precisa: nem nesse caso favorável a melhora é garantida.

A conclusão, porém, não se sustenta, porque o resultado dependeu de *qual* coluna foi reescalada. Aplique a mesma reescala a uma coluna *irrelevante* e o efeito tende a se inverter: ela ganha liberdade para receber um coeficiente grande sem pagar por isso, e o ajuste passa a acompanhar ruído.

O ponto de fundo é que, nos dois casos, quem decidiu quanto regularizar cada coluna não foi o analista: foi a **unidade de medida** em que o dado chegou. E é por isso que o argumento do colega não se salva nem quando o resultado o favorece — um procedimento cujo desempenho depende de a coluna ter sido anotada em metros ou em milímetros está fora de controle, e ter dado certo desta vez não muda isso.