

Lista de Revisão

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aulas 01 a 06 — Fundamentos, Regressão, Validação Cruzada, KNN, Árvores e Pipelines

Não há ordem obrigatória para a resolução, mas os exercícios de uma mesma aula se apoiam uns nos outros, ou em exercícios de listas anteriores.

Salvo indicação em contrário, $(\mathbf{X}, Y)$ é um vetor aleatório com distribuição P , $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ é a função de regressão, $\mathcal{D} = \{(\mathbf{X}_i, Y_i)\}_{i=1}^n$ é a amostra de treino (i.i.d.), p é o número de covariáveis e a perda é a quadrática.

Aula 01 — Introdução

Exercício 1 — O melhor preditor. No início do curso, vimos uma afirmação forte: de todas as funções que você poderia usar para prever Y a partir de $\mathbf{X}$, a melhor é a função de regressão $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$. Não a melhor entre as lineares, nem a melhor entre as que o seu método consegue produzir — a melhor, ponto.

Uma afirmação dessas pede demonstração, e ela é mais curta do que parece. Todo o trabalho está num truque que você vai reencontrar várias vezes no curso: somar e subtrair a quantidade certa dentro de um quadrado.

- (a) Seja $g : \mathbb{R}^p \rightarrow \mathbb{R}$ uma função qualquer com $\mathbb{E}[g(\mathbf{X})^2] < \infty$. Some e subtraia $r(\mathbf{X})$ dentro do quadrado e mostre que

$$\mathbb{E}[(Y - g(\mathbf{X}))^2] = \mathbb{E}[(Y - r(\mathbf{X}))^2] + \mathbb{E}[(r(\mathbf{X}) - g(\mathbf{X}))^2].$$

O trabalho está em mostrar que o termo cruzado desaparece; condicione em $\mathbf{X}$ e pergunte-se o que $\mathbb{E}[Y - r(\mathbf{X}) \mid \mathbf{X}]$ vale.

- (b) Olhe para a identidade que você acabou de provar e responda: por que ela mostra que r é o minimizador? Em seguida, mostre que o valor mínimo é $R(r) = \mathbb{E}[\text{Var}(Y \mid \mathbf{X})]$.
- (c) Esse mínimo tem nome: **erro irreduzível**. O nome sugere que não há como baixá-lo, e é verdade — mas a razão não é que os métodos atuais sejam ruins. Explique de onde vem essa impossibilidade, e diga o que teria de mudar *no problema* para o número diminuir.
- (d) Na Lista Teórica 01, mostramos que o melhor preditor *constante* tem risco $\text{Var}(Y)$. Use a identidade de (a) para escrever a diferença $\text{Var}(Y) - R(r)$ como uma esperança, e interprete: que pergunta prática essa quantidade responde?

Exercício 2. A palavra "risco" apareceu durante o nosso curso com dois sentidos, e a diferença entre eles não é preciosismo: ela decide qual pergunta o seu número está respondendo.

Quando g é tratada como uma função *fixa*, a esperança em $\mathbb{E}[(Y - g(\mathbf{X}))^2]$ percorre só a observação nova $(\mathbf{X}, Y)$. Chamamos isso de **risco condicional**. Quando $g = \hat{g}$ é tratada como aleatória — e ela é, porque foi construída a partir de $\mathcal{D}$ —, a esperança percorre também as amostras de treino possíveis, e temos o **risco esperado**.

- (a) Cada um dos dois oferece uma garantia diferente. Descreva as duas, e diga qual interessa a quem já ajustou um modelo e vai colocá-lo em produção, e qual interessa a quem ainda está escolhendo entre diversos métodos.

- (b) Você separou um conjunto de teste de m observações que não participou de nenhum treinamento, e calculou $\widehat{R}(\widehat{g}) = \frac{1}{m} \sum_{k=1}^m W_k$, com $W_k = (Y_k - \widehat{g}(\mathbf{X}_k))^2$. Qual dos dois riscos esse número estima? Para responder, pergunte-se o que está fixo e o que varia no momento em que você faz a conta.
- (c) Um conjunto de teste permite algo que a validação cruzada não permite: uma barra de erro honesta. Explique por que os W_k são i.i.d. e escreva o intervalo de confiança aproximado de 95% que o Teorema Central do Limite fornece.

Aula 02 — Regressão Linear e Regularização

Exercício 3 — Regressão no caso ortonormal. As notas da aula de Regressão Linear apresentam duas fórmulas prontas para o caso ortonormal, $\mathbb{X}^\top \mathbb{X} = \mathbb{I}$, e não as derivam. São elas que explicam a frase "o Ridge encolhe e o Lasso zera", e o exercício é preencher essa lacuna.

Use as definições da aula, **sem** fator $\frac{1}{2}$ no RSS:

$$\widehat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \sum_j \beta_j^2 \right\}, \quad \widehat{\beta}^{\text{lasso}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \sum_j |\beta_j| \right\}.$$

- (a) Comece pelo passo que torna tudo possível. Supondo $\mathbb{X}^\top \mathbb{X} = \mathbb{I}$, mostre que o estimador de mínimos quadrados é $\widehat{\beta} = \mathbb{X}^\top \mathbf{y}$ e que

$$\|\mathbf{y} - \mathbb{X}\beta\|^2 = \|\mathbf{y}\|^2 - \|\widehat{\beta}\|^2 + \sum_{j=1}^p (\beta_j - \widehat{\beta}_j)^2.$$

Explique por que essa identidade faz o problema **se separar** em p problemas de uma variável — e por que é justamente isso que falha quando as colunas não são ortonormais.

- (b) Com a separação em mãos, derive $\widehat{\beta}_j^{\text{ridge}} = \widehat{\beta}_j / (1 + \lambda)$.
- (c) Agora o Lasso. A dificuldade nova é que $|\beta_j|$ não é derivável em zero, então não dá para igualar a derivada a zero e pronto: trate separadamente as regiões $\beta_j > 0$, $\beta_j < 0$ e o ponto $\beta_j = 0$. Derive $\widehat{\beta}_j^{\text{lasso}} = \text{sign}(\widehat{\beta}_j) (|\widehat{\beta}_j| - \lambda/2)_+$ e diga qual é a condição exata que leva um coeficiente a zero.
- (d) O limiar deu $\lambda/2$, e não λ . De onde veio esse 2? Diga o que mudaria nas duas fórmulas se a aula tivesse definido o RSS com um $\frac{1}{2}$ na frente, e que lição prática isso deixa.

Exercício 4 — O que o MQO estima quando a linearidade é falsa. Circula por aí a ideia de que a regressão linear "só vale se o modelo estiver correto". Vimos durante o curso que isso é impreciso: o MQO converge para uma função bem definida mesmo quando r não é linear.

Essa função é o **melhor preditor linear**,

$$\beta^* = \arg \min_{\beta} \mathbb{E}[(Y - \beta^\top \mathbf{X})^2],$$

que existe sempre que $\Sigma = \mathbb{E}[\mathbf{X}\mathbf{X}^\top]$ é bem definida e invertível — *sem* supor nada sobre a forma de r .

- (a) Derive $\beta^* = \Sigma^{-1} \alpha$, onde $\alpha = \mathbb{E}[Y\mathbf{X}]$. É o mesmo cálculo das equações normais, com esperanças no lugar de somas.

- (b) O estimador de mínimos quadrados pode ser escrito como $\hat{\beta} = \hat{\Sigma}^{-1}\hat{\alpha}$, com $\hat{\Sigma} = \frac{1}{n} \sum_i \mathbf{X}_i \mathbf{X}_i^\top$ e $\hat{\alpha} = \frac{1}{n} \sum_i Y_i \mathbf{X}_i$. Olhe para essas duas expressões e diga o que elas são, estatisticamente. Em seguida, explique por que $\hat{\beta} \rightarrow \beta^*$ em probabilidade sem que se precise supor linearidade em lugar nenhum.
- (c) Todo teorema garante uma coisa e deixa de garantir outra. Enuncie as duas, com cuidado. Em particular: o resultado diz que o risco de $\hat{\beta}$ é pequeno?
- (d) Um colega ajusta uma regressão linear a dados em que r é visivelmente curva e conclui: "o coeficiente deu 2,3, logo aumentar x_1 em uma unidade aumenta Y em 2,3". Separe o que é leitura legítima de β^* do que não é.

Exercício 5 — A Regressão Ridge como moda a posteriori. Já mencionamos que o Ridge tem uma leitura bayesiana: ele é a moda a posteriori sob uma priori gaussiana. A afirmação é mais do que curiosidade — ela dá um significado concreto ao λ , que até aqui era só um hiperparâmetro.

Considere o modelo

$$\mathbf{y} | \beta \sim N(\mathbb{X}\beta, \sigma^2 \mathbb{I}), \quad \beta \sim N(\mathbf{0}, \sigma_\beta^2 \mathbb{I}),$$

com σ^2 e σ_β^2 conhecidos.

- (a) Escreva a densidade a posteriori de β a menos de constante multiplicativa e mostre que maximizá-la equivale a minimizar

$$\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\beta\|^2 + \frac{1}{2\sigma_\beta^2} \|\beta\|^2.$$

O caminho é o de sempre: passar ao logaritmo transforma produto em soma, e trocar o sinal transforma maximizar em minimizar.

- (b) Compare o que você obteve com a definição do Ridge da aula e identifique λ em função de σ^2 e σ_β^2 . Cuidado com o fator que precisa ser eliminado antes da comparação.
- (c) Agora a parte interessante: o que a priori está afirmando quando $\sigma_\beta^2 \rightarrow \infty$, e quando $\sigma_\beta^2 \rightarrow 0$? Ligue cada resposta ao comportamento do Ridge em $\lambda \rightarrow 0$ e $\lambda \rightarrow \infty$.

Aula 03 — Seleção de Modelos e Validação Cruzada

Exercício 6 — A fórmula de regressão linear para LOOCV. O LOOCV (*Leave-One-Out Cross Validation*) parece caro: n ajustes, um para cada observação deixada de fora. Já comentamos que, para ajustes lineares, um único ajuste basta — mas não demonstramos.

Vamos demonstrar no caso da regressão linear por mínimos quadrados. A matriz de design $\mathbb{X}$ tem linha i igual a $\mathbf{X}_i^\top$, e o ajuste com todos os dados é $\hat{g}(\mathbf{x}) = \mathbf{x}^\top \hat{\beta}$, com $\hat{\beta} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{y}$. Chame de $\hat{g}_{-i}$ o ajuste feito sem a i -ésima observação. A fórmula a demonstrar é

$$\hat{R}_{\text{LOO}} = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{g}(\mathbf{X}_i)}{1 - h_{ii}} \right)^2,$$

em que h_{ii} é o i -ésimo elemento da diagonal da matriz $\mathbf{H} = \mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top$.

Suponha que $\mathbb{X}$ tenha posto cheio, e que continue tendo quando se tira qualquer uma de suas linhas. Assim todos os ajustes são únicos, e $h_{ii} \neq 1$: dividir por $1 - h_{ii}$ nunca é problema.

A demonstração vem em etapas. O item (a) mostra o que são os números h_{ii} ; os itens (b) e (c) usam um truque para escrever $\hat{g}_{-i}(\mathbf{X}_i)$ em termos de $\hat{g}$; o (d) faz a conta; e o (e) interpreta o resultado.

- (a) *De onde vêm os pesos.* Mostre que o vetor de valores ajustados, $\hat{\mathbf{y}} = (\hat{g}(\mathbf{X}_1), \dots, \hat{g}(\mathbf{X}_n))^\top$, é igual a $\mathbf{H}\mathbf{y}$, e conclua, olhando a coordenada i , que

$$\hat{g}(\mathbf{X}_i) = \sum_{\ell=1}^n h_{i\ell} Y_\ell,$$

em que $h_{i\ell}$ é a entrada (i, ℓ) de $\mathbf{H}$. Dica: como a linha i de $\mathbb{X}$ é $\mathbf{X}_i^\top$, vale $\hat{\mathbf{y}} = \mathbb{X}\hat{\boldsymbol{\beta}}$.

Em palavras: a predição no ponto $\mathbf{X}_i$ é uma combinação de todas as respostas, inclusive da própria Y_i , que entra com peso h_{ii} . De que esses pesos dependem? E de que eles *não* dependem?

- (b) *O truque.* Imagine o conjunto de dados em que a resposta Y_i foi trocada por $\tilde{Y}_i = \hat{g}_{-i}(\mathbf{X}_i)$ — o valor que o ajuste sem a observação i prevê ali —, com as covariáveis e as demais respostas intactas. Mostre que o ajuste de mínimos quadrados nesse conjunto modificado é exatamente $\hat{g}_{-i}$.

Antes do caso geral, veja o truque funcionar no modelo só com intercepto, em que o ajuste é a média: troque Y_i pela média das outras $n - 1$ respostas e confira que a média das n passa a ser justamente a média das outras. Para o caso geral, um caminho: escreva o RSS do conjunto modificado como a soma das $n - 1$ parcelas de sempre com a parcela da observação i ; veja o que $\hat{g}_{-i}$ faz com cada uma das duas partes; e conclua que nenhuma função linear consegue um RSS menor, o que basta, porque o ajuste é único.

- (c) *A mesma matriz, duas vezes.* O conjunto modificado tem as mesmas covariáveis que o original, e portanto a mesma matriz $\mathbf{H}$. Aplique (a) a ele e use (b) para mostrar que

$$\hat{g}_{-i}(\mathbf{X}_i) = \sum_{\ell \neq i} h_{i\ell} Y_\ell + h_{ii} \tilde{Y}_i.$$

Depois some e subtraia $h_{ii}Y_i$ para chegar a

$$\hat{g}_{-i}(\mathbf{X}_i) = \hat{g}(\mathbf{X}_i) + h_{ii}(\tilde{Y}_i - Y_i).$$

- (d) *A conta.* Na igualdade de (c), $\tilde{Y}_i$ aparece dos dois lados, porque o lado esquerdo é o próprio $\tilde{Y}_i$. Subtraia Y_i dos dois lados, junte os termos com $\tilde{Y}_i - Y_i$ e isole o resíduo de validação $Y_i - \hat{g}_{-i}(\mathbf{X}_i)$. Conclua a fórmula do enunciado.
- (e) *Lendo o resultado.* A matriz $\mathbf{H}$ tem duas propriedades. É simétrica, porque $\mathbb{X}^\top \mathbb{X}$ é simétrica e sua inversa também. E vale $\mathbf{H}\mathbf{H} = \mathbf{H}$, o que se confere multiplicando:

$$\mathbf{H}\mathbf{H} = \mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1} \underbrace{\mathbb{X}^\top \mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1}}_{=\mathbf{I}} \mathbb{X}^\top = \mathbf{H}.$$

Em palavras: $\mathbf{H}$ projeta $\mathbf{y}$ no espaço gerado pelas colunas de $\mathbb{X}$, e projetar de novo o que já foi projetado não muda nada. Usando as duas propriedades, a entrada (i, i) de $\mathbf{H}\mathbf{H} = \mathbf{H}$ dá

$$h_{ii} = \sum_{\ell=1}^n h_{i\ell}^2 = h_{ii}^2 + \sum_{\ell \neq i} h_{i\ell}^2.$$

Conclua que $0 \leq h_{ii} \leq 1$ e que, portanto, o resíduo de validação nunca é menor, em módulo, que o de treino. O que isso confirma sobre o erro de treino como estimativa do risco? E o que significa uma observação com h_{ii} próximo de 1?

Exercício 7 — Duas fórmulas da validação cruzada. Quem estuda validação cruzada pelas notas de aula e pelo ISLP encontra duas fórmulas diferentes para a mesma quantia, e é natural desconfiar de que uma delas esteja errada. Não está: elas só diferem na unidade que cada uma pondera igualmente.

As notas de aula definem

$$\hat{R}_{k\text{-CV}} = \frac{1}{n} \sum_{j=1}^k \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2,$$

e o ISLP define $\text{CV}_{(k)} = \frac{1}{k} \sum_{j=1}^k \text{EQM}_j$, com $\text{EQM}_j = \frac{1}{|L_j|} \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2$.

(a) Reescreva a fórmula da aula de modo a fazer os EQM_j aparecerem, mostrando que

$$\hat{R}_{k\text{-CV}} = \sum_{j=1}^k \frac{|L_j|}{n} \text{EQM}_j.$$

(b) Olhando para os pesos que você obteve, diga em que condição as duas definições coincidem — e se coincidem exatamente ou apenas aproximadamente. Em seguida, nomeie a unidade que cada fórmula pondera igualmente.

(c) Com $n = 50$ e $k = 7$, as dobras não podem ter todas o mesmo tamanho; suponha que tenham tamanhos 8, 8, 7, 7, 7, 7, 6. Confirme que somam 50 e explique por que, neste caso, os dois números diferem.

(d) Suponha que a dobra de 6 observações tenha $\text{EQM} = 10$ e todas as outras tenham $\text{EQM} = 1$. Calcule os dois estimadores, diga qual deles dá mais peso à dobra atípica, e qual você reportaria. Justifique a escolha.

Aula 04 — Métodos Não Paramétricos (KNN)

Exercício 8 — duas doenças, dois remédios. Durante o curso, apresentamos ferramentas que, à primeira vista, andam em sentidos opostos. A regularização *restringe* o modelo: o Ridge, por exemplo, soma ao RSS do MQO uma penalidade sobre o tamanho dos coeficientes,

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}.$$

Os métodos não paramétricos o *soltam*: o KNN, por exemplo, não supõe forma nenhuma para r e prevê pela média das respostas dos k vizinhos mais próximos de $\mathbf{x}$, cujos índices formam o conjunto $\mathcal{N}_{\mathbf{x}}$,

$$\hat{r}(\mathbf{x}) = \frac{1}{k} \sum_{i \in \mathcal{N}_{\mathbf{x}}} Y_i.$$

Parece contradição, e não é: são ferramentas para serem usadas em dois contextos diferentes.

Para ver quais, a referência é a decomposição do erro de previsão num ponto fixo $\mathbf{x}_0$. Para um estimador $\hat{r}$ construído com a amostra $\mathcal{D}$,

$$\mathbb{E}_{\mathcal{D}}[(Y_0 - \hat{r}(\mathbf{x}_0))^2] = \underbrace{(\mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0)] - r(\mathbf{x}_0))^2}_{\text{viés}^2} + \underbrace{\text{Var}_{\mathcal{D}}(\hat{r}(\mathbf{x}_0))}_{\text{variância}} + \underbrace{\sigma^2(\mathbf{x}_0)}_{\text{irreduzível}},$$

em que Y_0 é uma resposta nova em $\mathbf{x}_0$, $\sigma^2(\mathbf{x}_0) = \text{Var}(Y \mid \mathbf{X} = \mathbf{x}_0)$, e $\mathbb{E}_{\mathcal{D}}$ e $\text{Var}_{\mathcal{D}}$ percorrem as amostras de treino possíveis. O último termo não depende do método; a disputa é entre os dois primeiros.

- (a) Explique, em palavras, o que o viés e a variância medem. Depois diga qual dos dois termos a regularização ataca e qual os métodos não paramétricos atacam, e o que cada família aceita pagar no outro.
- (b) Descreva, em uma frase cada, a situação que motiva cada família: o que está errado com o modelo *antes* de aplicarmos Ridge, e o que está errado *antes* de aplicarmos um spline?
- (c) O KNN com $k = 1$ e o MQO com p grande erram por motivos que, na decomposição, caem no mesmo lugar. Explique. Em seguida diga qual é o remédio de cada um e por que os dois remédios se parecem.

Dica para o KNN: trate as covariáveis da amostra como fixas — assim os vizinhos de $\mathbf{x}_0$ também ficam fixos — e suponha que Y tenha variância constante σ^2 em torno de r . Nesse caso a decomposição fica

$$\mathbb{E}[(Y_0 - \hat{r}(\mathbf{x}_0))^2] = \left(\frac{1}{k} \sum_{i \in \mathcal{N}_{\mathbf{x}_0}} r(\mathbf{X}_i) - r(\mathbf{x}_0) \right)^2 + \frac{\sigma^2}{k} + \sigma^2.$$

O que acontece com cada termo quando k cresce?

- (d) As duas ideias podem ser combinadas? Dê um exemplo concreto, visto no curso, de método que seja ao mesmo tempo não paramétrico e regularizado, e diga qual botão controla cada coisa nele.

Aula 05 — Árvores de Regressão e *Ensembles*

Exercício 9 — O problema da poda. Construir uma árvore tem duas etapas, e elas usam objetivos diferentes de propósito. O crescimento escolhe cortes que mais reduzem o RSS; a poda escolhe uma subárvore $T \subseteq T_0$ minimizando

$$C_\alpha(T) = \sum_{k=1}^{|T|} \sum_{i: \mathbf{X}_i \in R_k} (Y_i - \hat{y}_{R_k})^2 + \alpha |T|,$$

onde $|T|$ é o número de folhas e $\hat{y}_{R_k}$ é a média das respostas na folha R_k . Se a forma lembra a regularização, não é coincidência.

- (a) O que se obtém nos dois extremos, $\alpha = 0$ e $\alpha \rightarrow \infty$? Diga em cada caso quantas folhas tem a subárvore vencedora.
- (b) Considere uma folha com RSS igual a S , que pode ser dividida em duas com RSS S_a e S_b . Escreva a condição sobre $S - (S_a + S_b)$ para que a divisão valha a pena segundo C_α , e interprete: em que unidade o α está cobrando?
- (c) Uma árvore tem RSS total 120 com 6 folhas; podando-a para 4 folhas, o RSS sobe para 140. Para quais valores de α a podada é preferível?
- (d) Por que a poda usa um critério diferente do crescimento, em vez de simplesmente parar de crescer quando o ganho fica pequeno? Dê um exemplo de estrutura nos dados que um critério de parada perderia e a poda recupera.

Exercício 10. Justificamos o *bagging* com uma proposição de enunciado curto: se $g_1, \dots, g_B$ são não-viesados para $r(\mathbf{x})$, têm a mesma variância $v(\mathbf{x})$ e são **não-correlacionados**, então a

média $\bar{g} = \frac{1}{B} \sum_b g_b$ tem risco $\text{Var}(Y \mid \mathbf{x}) + v(\mathbf{x})/B$, que nunca passa do risco $\text{Var}(Y \mid \mathbf{x}) + v(\mathbf{x})$ de cada g_b .

Proposições com hipóteses só ficam úteis quando se sabe o que acontece ao violá-las — e, no caso do *bagging*, uma delas é violada o tempo todo.

- (a) Identifique as duas condições e explique, para cada uma, o que acontece com a conclusão se ela falhar.
- (b) O *bagging* usa árvores **profundas e não podadas**. Qual das duas condições essa escolha atende? E por que podar as árvores seria contraproducente aqui?
- (c) Na prática as árvores do *bagging* são correlacionadas. Explique a razão — o que elas têm em comum que as faz parecidas — e por que aumentar B não resolve esse problema específico.
- (d) A floresta aleatória sorteia $m < p$ covariáveis candidatas em cada nó. Explique como isso ataca a condição comprometida, qual é o preço pago na outra, e por que essa troca costuma compensar.

Aula 06 — Pré-processamento e *Pipelines*

Exercício 11. Um colega recebeu um banco de dados em que a coluna **renda** está em reais e a coluna **altura** em metros, e pergunta se precisa padronizar antes de ajustar. A resposta honesta é "depende do método" — e o critério que decide cabe numa pergunta: **o método soma coisas vindas de colunas diferentes?**

Se soma, as unidades precisam ser comparáveis, e trocar uma delas estraga a comparação. Se não soma, a unidade é irrelevante.

- (a) Para cada método abaixo, diga se multiplicar uma única coluna por 1000 **muda** ou **não muda** a predição, justificando em uma linha onde está — ou onde não está — a soma sobre colunas.
 - (i) Mínimos quadrados ordinários.
 - (ii) Regressão Ridge com $\lambda > 0$ fixo.
 - (iii) Árvore de regressão.
 - (iv) Floresta aleatória.
 - (v) KNN com k fixo.
- (b) Entre os que mudam, qual você espera que seja o mais afetado, e por quê? Compare o *modo* como a escala entra em cada um.
- (c) Outro colega ajustou o Lasso a dados padronizados, com λ escolhido por validação cruzada. Em seguida multiplicou por 1000 a coluna de maior efeito sobre Y , reajustou com o *mesmo* λ , e o erro quadrático médio no conjunto de teste *diminuiu*. Ele conclui que é melhor não padronizar. Explique por que a reescala pode ter ajudado e por que a conclusão não se sustenta.