

Lista de Revisão

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aulas 01 a 06 — Fundamentos, Regressão, Validação Cruzada, KNN, Árvores e Pipelines

Treze exercícios para revisar o Bloco I antes da avaliação. Eles não repetem os das listas de cada aula — a maior parte pede que você *demonstre* resultados que as notas usaram sem demonstrar, ou que ligue duas aulas vistas separadamente.

Não há ordem obrigatória, mas os exercícios de uma mesma aula se apoiam uns nos outros, e vários apontam para exercícios das listas anteriores — quando isso acontece, o enunciado avisa.

Salvo indicação em contrário, $(\mathbf{X}, Y)$ é um par aleatório com distribuição P , $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ é a função de regressão, $\mathcal{D} = \{(\mathbf{X}_i, Y_i)\}_{i=1}^n$ é a amostra de treino (i.i.d.), p é o número de covariáveis e a perda é a quadrática.

Aula 01 — Introdução

Exercício 1 — o melhor preditor de todos, e o que sobra depois dele. A Aula 01 abriu com uma afirmação forte: de todas as funções que você poderia usar para prever Y a partir de $\mathbf{X}$, a melhor é a função de regressão $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$. Não a melhor entre as lineares, nem a melhor entre as que o seu método consegue produzir — a melhor, ponto.

Uma afirmação dessas pede demonstração, e ela é mais curta do que parece. Todo o trabalho está num truque que você vai reencontrar várias vezes no curso: somar e subtrair a quantidade certa dentro de um quadrado.

- (a) Seja $g : \mathbb{R}^p \rightarrow \mathbb{R}$ uma função qualquer com $\mathbb{E}[g(\mathbf{X})^2] < \infty$. Some e subtraia $r(\mathbf{X})$ dentro do quadrado e mostre que

$$\mathbb{E}[(Y - g(\mathbf{X}))^2] = \mathbb{E}[(Y - r(\mathbf{X}))^2] + \mathbb{E}[(r(\mathbf{X}) - g(\mathbf{X}))^2].$$

O trabalho está em mostrar que o termo cruzado desaparece; condicione em $\mathbf{X}$ e pergunte-se o que $\mathbb{E}[Y - r(\mathbf{X}) \mid \mathbf{X}]$ vale.

- (b) Olhe para a identidade que você acabou de provar e responda: por que ela mostra que r é o minimizador? Em seguida, mostre que o valor mínimo é $R(r) = \mathbb{E}[\text{Var}(Y \mid \mathbf{X})]$.
- (c) Esse mínimo tem nome: **erro irreduzível**. O nome sugere que não há como baixá-lo, e é verdade — mas a razão não é que os métodos atuais sejam ruins. Explique de onde vem essa impossibilidade, e diga o que teria de mudar *no problema* para o número diminuir.
- (d) Na Lista Teórica 01 você mostrou que o melhor preditor *constante* tem risco $\text{Var}(Y)$. Use a identidade de (a) para escrever a diferença $\text{Var}(Y) - R(r)$ como uma esperança, e interprete: que pergunta prática essa quantidade responde?

Exercício 2 — dois riscos com o mesmo nome, e uma barra de erro. A palavra "risco" aparece na Aula 01 com dois sentidos, e a diferença entre eles não é preciosismo: ela decide qual pergunta o seu número está respondendo.

Quando g é tratada como uma função *fixa*, a esperança em $\mathbb{E}[(Y - g(\mathbf{X}))^2]$ percorre só a observação nova $(\mathbf{X}, Y)$. Chamamos isso de **risco condicional**. Quando $g = \hat{g}$ é tratada como aleatória — e ela é, porque foi construída a partir de $\mathcal{D}$ —, a esperança percorre também as amostras de treino possíveis, e temos o **risco esperado**.

- (a) Cada um dos dois oferece uma garantia diferente. Descreva as duas, e diga qual interessa a quem já ajustou um modelo e vai colocá-lo em produção, e qual interessa a quem ainda está escolhendo entre dois métodos.
- (b) Você separou um conjunto de teste de m observações que não participou de nada, e calculou $\hat{R}(\hat{g}) = \frac{1}{m} \sum_{k=1}^m W_k$, com $W_k = (Y_k - \hat{g}(\mathbf{X}_k))^2$. Qual dos dois riscos esse número estima? Para responder, pergunte-se o que está fixo e o que varia no momento em que você faz a conta.
- (c) Um conjunto de teste permite algo que a validação cruzada não permite: uma barra de erro honesta. Explique por que os W_k são i.i.d. e escreva o intervalo de confiança aproximado de 95% que o Teorema Central do Limite fornece.
- (d) Num teste com $m = 400$ você obteve $\hat{R} = 2,50$ e $\hat{\sigma}^2 = 16,0$. Calcule o intervalo. Um colega, no mesmo conjunto, obteve 2,20 com outro método e anuncia que o dele é melhor. Ele pode? Justifique.

Aula 02 — Regressão Linear e Regularização

Exercício 3 — de onde saem as fórmulas do caso ortonormal. As notas da Aula 02 apresentam duas fórmulas prontas para o caso ortonormal, $\mathbb{X}^\top \mathbb{X} = \mathbb{I}$, e não as derivam. São elas que explicam a frase "o Ridge encolhe e o Lasso zera", e o exercício é preencher essa lacuna.

Use as definições da aula, **sem** fator $\frac{1}{2}$ no RSS:

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \sum_j \beta_j^2 \right\}, \quad \hat{\beta}^{\text{lasso}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \sum_j |\beta_j| \right\}.$$

- (a) Comece pelo passo que torna tudo possível. Supondo $\mathbb{X}^\top \mathbb{X} = \mathbb{I}$, mostre que o estimador de mínimos quadrados é $\hat{\beta} = \mathbb{X}^\top \mathbf{y}$ e que

$$\|\mathbf{y} - \mathbb{X}\beta\|^2 = \|\mathbf{y}\|^2 - \|\hat{\beta}\|^2 + \sum_{j=1}^p (\beta_j - \hat{\beta}_j)^2.$$

Explique por que essa identidade faz o problema **se separar** em p problemas de uma variável — e por que é justamente isso que falha quando as colunas não são ortonormais.

- (b) Com a separação em mãos, derive $\hat{\beta}_j^{\text{ridge}} = \hat{\beta}_j / (1 + \lambda)$.
- (c) Agora o Lasso. A dificuldade nova é que $|\beta_j|$ não é derivável em zero, então não dá para igualar a derivada a zero e pronto: trate separadamente as regiões $\beta_j > 0$, $\beta_j < 0$ e o ponto $\beta_j = 0$. Derive $\hat{\beta}_j^{\text{lasso}} = \text{sign}(\hat{\beta}_j) (|\hat{\beta}_j| - \lambda/2)_+$ e diga qual é a condição exata que leva um coeficiente a zero.
- (d) O limiar deu $\lambda/2$, e não λ . De onde veio esse 2? Diga o que mudaria nas duas fórmulas se a aula tivesse definido o RSS com um $\frac{1}{2}$ na frente, e que lição prática isso deixa.

Exercício 4 — o que o MQO estima quando a linearidade é falsa. Circula por aí a ideia de que a regressão linear "só vale se o modelo estiver correto". A Aula 02 mostra que isso é impreciso: o MQO converge para alguma coisa bem definida mesmo quando r não é linear coisa nenhuma.

Essa coisa é o **melhor preditor linear**,

$$\beta^* = \arg \min_{\beta} \mathbb{E}[(Y - \beta^\top \mathbf{X})^2],$$

que existe sempre que $\Sigma = \mathbb{E}[\mathbf{X}\mathbf{X}^\top]$ é bem definida e invertível — *sem* supor nada sobre a forma de r .

- (a) Derive $\beta^* = \Sigma^{-1}\alpha$, onde $\alpha = \mathbb{E}[Y\mathbf{X}]$. É o mesmo cálculo das equações normais, com esperanças no lugar de somas.
- (b) O estimador de mínimos quadrados pode ser escrito como $\hat{\beta} = \hat{\Sigma}^{-1}\hat{\alpha}$, com $\hat{\Sigma} = \frac{1}{n} \sum_i \mathbf{X}_i \mathbf{X}_i^\top$ e $\hat{\alpha} = \frac{1}{n} \sum_i Y_i \mathbf{X}_i$. Olhe para essas duas expressões e diga o que elas são, estatisticamente. Em seguida, explique por que $\hat{\beta} \rightarrow \beta^*$ em probabilidade sem que se precise supor linearidade em lugar nenhum.
- (c) Todo teorema garante uma coisa e deixa de garantir outra. Enuncie as duas, com cuidado. Em particular: o resultado diz que o risco de $\hat{\beta}$ é pequeno?
- (d) Um colega ajusta uma regressão linear a dados em que r é visivelmente curva e conclui: "o coeficiente deu 2,3, logo aumentar x_1 em uma unidade aumenta Y em 2,3". Separe o que é leitura legítima de β^* do que não é.

Exercício 5 — a Ridge como moda a posteriori. A Aula 02 menciona que o Ridge tem uma leitura bayesiana: ele é a moda a posteriori sob uma priori gaussiana. A afirmação é mais do que curiosidade — ela dá um significado concreto ao λ , que até aqui era só um botão a girar. Suponha o modelo

$$\mathbf{y} | \beta \sim N(\mathbb{X}\beta, \sigma^2 \mathbb{I}), \quad \beta \sim N(\mathbf{0}, \sigma_\beta^2 \mathbb{I}),$$

com σ^2 e σ_β^2 conhecidos.

- (a) Escreva a densidade a posteriori de β a menos de constante multiplicativa e mostre que maximizá-la equivale a minimizar

$$\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbb{X}\beta\|^2 + \frac{1}{2\sigma_\beta^2} \|\beta\|^2.$$

O caminho é o de sempre: passar ao logaritmo transforma produto em soma, e maximizar em minimizar.

- (b) Compare o que você obteve com a definição do Ridge da aula e identifique λ em função de σ^2 e σ_β^2 . Cuidado com o fator que precisa ser eliminado antes da comparação.
- (c) Agora a parte interessante: o que a priori está *afirmando* quando $\sigma_\beta^2 \rightarrow \infty$, e quando $\sigma_\beta^2 \rightarrow 0$? Ligue cada resposta ao comportamento do Ridge em $\lambda \rightarrow 0$ e $\lambda \rightarrow \infty$.
- (d) Neste modelo a moda e a média a posteriori coincidem. Para o Lasso a priori correspondente é a de Laplace, e essa coincidência **falha**. Explique por que isso importa na prática — em particular, por que a média a posteriori do Lasso não produz coeficientes exatamente nulos.

Aula 03 — Seleção de Modelos e Validação Cruzada

Exercício 6 — o atalho do LOOCV, demonstrado. O LOOCV parece caro: n ajustes, um para cada observação deixada de fora. A Aula 03 enuncia que, para ajustes lineares, um único ajuste basta — e não demonstra. É uma das fórmulas mais bonitas da área, e o exercício é prová-la.

Para um ajuste com matriz de projeção $\mathbf{H} = \mathbb{X}(\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top$, vale

$$\hat{R}_{\text{LOO}} = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{g}(\mathbf{X}_i)}{1 - h_{ii}} \right)^2,$$

com $\hat{g}$ ajustado em *todos* os dados.

Escreva $\hat{g}(\mathbf{X}_i) = \sum_{\ell} h_{i\ell} Y_{\ell}$ — é isso que "ajuste linear" quer dizer: a predição é combinação linear das respostas, com pesos que dependem só de $\mathbb{X}$. Denote por $\hat{g}_{-i}$ o ajuste feito sem a i -ésima observação.

- (a) *O truque.* Imagine o conjunto de dados em que a resposta Y_i foi trocada por $\tilde{Y}_i = \hat{g}_{-i}(\mathbf{X}_i)$ — isto é, pelo valor que o ajuste sem ela teria previsto ali — mantendo as demais. Argumente que o ajuste linear nesse conjunto modificado devolve exatamente a mesma função $\hat{g}_{-i}$.

A ideia é que $\hat{g}_{-i}$ já minimiza o RSS nas outras $n - 1$ observações, e a parcela nova contribui com zero.

- (b) Use (a) e a linearidade do ajuste para mostrar que

$$\hat{g}_{-i}(\mathbf{X}_i) = \hat{g}(\mathbf{X}_i) + h_{ii}(\tilde{Y}_i - Y_i).$$

- (c) O item (b) é uma equação em que $\tilde{Y}_i$ aparece dos dois lados. Resolva-a para o resíduo de validação $Y_i - \hat{g}_{-i}(\mathbf{X}_i)$ e conclua a fórmula do enunciado.
- (d) Agora leia o que você provou. Por que o fator $1/(1 - h_{ii})$ é sempre ≥ 1 , e que afirmação da Aula 03 isso torna exata? O que significa uma observação com h_{ii} próximo de 1?

Exercício 7 — a mesma validação cruzada, escrita de dois jeitos. Quem estuda validação cruzada pela Aula 03 e pelo [ISLP] encontra duas fórmulas diferentes para a mesma coisa, e é natural desconfiar de que uma delas esteja errada. Não está: elas são a mesma conta, escrita com outra unidade.

A Aula 03 define

$$\hat{R}_{k\text{-CV}} = \frac{1}{n} \sum_{j=1}^k \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2,$$

e o [ISLP] define $\text{CV}_{(k)} = \frac{1}{k} \sum_{j=1}^k \text{EQM}_j$, com $\text{EQM}_j = \frac{1}{|L_j|} \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2$.

- (a) Reescreva a fórmula da aula de modo a fazer os EQM_j aparecerem, mostrando que

$$\hat{R}_{k\text{-CV}} = \sum_{j=1}^k \frac{|L_j|}{n} \text{EQM}_j.$$

- (b) Olhando para os pesos que você obteve, diga em que condição as duas definições coincidem — e se coincidem exatamente ou apenas aproximadamente. Em seguida, nomeie a unidade que cada fórmula pondera igualmente.
- (c) Com $n = 50$ e $k = 7$, o `KFold` produz dobras de tamanhos 8, 8, 7, 7, 7, 7, 6. Confirme que somam 50 e explique por que, neste caso, os dois números diferem.
- (d) Suponha que a dobra de 6 observações tenha $\text{EQM} = 10$ e todas as outras tenham $\text{EQM} = 1$. Calcule os dois estimadores, diga qual deles dá mais peso à dobra atípica, e qual você reportaria. Justifique a escolha.

Exercício 8 — de que tamanho é o viés da validação cruzada. A validação cruzada estima o risco de um procedimento — mas não exatamente o risco que interessa. Há um descompasso embutido, e a boa notícia é que ele tem sinal conhecido.

- (a) Cada g_{-j} é ajustado com quantas observações? Usando isso, argumente que $\mathbb{E}[\hat{R}_{k-CV}] = R_{n-n/k}$, onde R_m denota o risco esperado do procedimento treinado com m observações. A conta é mais curta do que parece: tome a esperança dentro da soma dupla e pergunte-se, para uma parcela qualquer, o que a observação i representa para o ajuste g_{-j} que a está prevendo.
- (b) O alvo que interessa é R_n , o risco do procedimento treinado com a amostra inteira. Supondo que R_m decresça com m — mais dados não pioram —, conclua que a validação cruzada é **pessimista**.
- (c) Ordene $k = 2$, $k = 10$ e $k = n$ quanto ao tamanho desse viés, justificando pelo número de observações de treino em cada caso.
- (d) Se o LOOCV tem o menor viés, por que $k = 5$ e $k = 10$ são os valores usuais? Responda pensando em *para que* a validação cruzada costuma ser usada.

Aula 04 — Métodos Não Paramétricos (KNN)

Exercício 9 — quanto custa cada nó de um spline. Um *spline* é uma função polinomial por partes, colada suavemente nos **nós**. A Aula 04 apresenta a base truncada que os constrói, e este exercício pergunta por que ela funciona — e quanto custa cada nó.

Um *spline* de grau g com nós $t_1 < \dots < t_J$ é combinação linear de

$$1, x, x^2, \dots, x^g, (x - t_1)_+^g, \dots, (x - t_J)_+^g, \quad (u)_+ = \max(u, 0).$$

Sobre as letras: aqui g é o **grau** e J o **número de nós**. As notas usam k e p para essas duas quantidades; trocamos as letras de propósito, para não colidir com o k do KNN nem com o p de covariáveis. É o tipo de colisão que a Aula 04 tem e que convém não carregar para uma prova.

- (a) Quantas funções há na base? Escreva I em função de g e J , e confira no caso cúbico ($g = 3$) com 4 nós.
- (b) Mostre que $(x - t_j)_+^g$ e suas $g - 1$ primeiras derivadas se anulam em $x = t_j$. Em seguida, tire a conclusão que interessa: por que acrescentar essa função à base *não altera* o ajuste à esquerda de t_j , e por que a emenda no nó sai suave sem que se precise impor restrição nenhuma.
- (c) Use (b) para justificar a frase "cada nó compra exatamente um grau de liberdade". Depois compare com a alternativa ingênua: ajustar um polinômio de grau g **independente** em cada um dos $J + 1$ pedaços. Quantos parâmetros seriam? Onde foi parar a diferença, e o que ela custa?
- (d) O ajuste é por mínimos quadrados sobre essa base. Isso faz do *spline* um **ajuste linear** no sentido da Aula 02 — explique por quê. E então responda: se ele é linear, o que exatamente o torna um método *não paramétrico*?

Exercício 10 — duas doenças, dois remédios. As Aulas 02 e 04 apresentam ferramentas que, à primeira vista, andam em sentidos opostos. A regularização *restringe* o modelo; os métodos não paramétricos o *soltam*. Parece contradição, e não é: são remédios para doenças diferentes.

Este exercício pede que você organize as duas numa única imagem — a da Aula 01.

- (a) Escreva a decomposição do erro de um estimador $\hat{r}$ em relação a r nos dois termos da Aula 01, e diga qual dos dois cada família de métodos ataca.
- (b) Descreva, em uma frase cada, a situação que motiva cada família: o que está errado com o modelo *antes* de aplicarmos Ridge, e o que está errado *antes* de aplicarmos um spline?
- (c) O KNN com $k = 1$ e o MQO com p grande erram por motivos que, na decomposição, caem no mesmo lugar. Explique. Em seguida diga qual é o remédio de cada um e por que os dois remédios se parecem.
- (d) As duas ideias podem ser combinadas? Dê um exemplo concreto, visto no curso, de método que seja ao mesmo tempo não paramétrico e regularizado, e diga qual botão controla cada coisa nele.

Aula 05 — Árvores de Regressão e *Ensembles*

Exercício 11 — podar é outro problema, não o mesmo de crescer. Construir uma árvore tem duas etapas, e elas usam objetivos diferentes de propósito. O crescimento escolhe cortes que mais reduzem o RSS; a poda escolhe uma subárvore $T \subseteq T_0$ minimizando

$$C_\alpha(T) = \sum_{m=1}^{|T|} \sum_{i: \mathbf{x}_i \in R_m} (y_i - \hat{c}_m)^2 + \alpha |T|,$$

onde $|T|$ é o número de folhas e $\hat{c}_m$ a média de y na folha m . Se a forma lembra a regularização da Aula 02, não é coincidência.

- (a) O que se obtém nos dois extremos, $\alpha = 0$ e $\alpha \rightarrow \infty$? Diga em cada caso quantas folhas tem a subárvore vencedora.
- (b) Considere uma folha com RSS igual a S_m , que pode ser dividida em duas com RSS S_a e S_b . Escreva a condição sobre $S_m - (S_a + S_b)$ para que a divisão valha a pena segundo C_α , e interprete: em que unidade o α está cobrando?
- (c) Uma árvore tem RSS total 120 com 6 folhas; podando-a para 4 folhas, o RSS sobe para 140. Para quais valores de α a podada é preferível?
- (d) Por que a poda usa um critério diferente do crescimento, em vez de simplesmente parar de crescer quando o ganho fica pequeno? Dê um exemplo de estrutura nos dados que um critério de parada perderia e a poda recupera.

Exercício 12 — as duas condições, e o que a floresta faz com elas. A Aula 05 justifica a agregação com uma proposição de enunciado curto: se $g_1, \dots, g_B$ são não-viesados para $r(\mathbf{x})$, têm a mesma variância $v(\mathbf{x})$ e são **não-correlacionados**, então $\bar{g} = \frac{1}{B} \sum_b g_b$ tem variância $v(\mathbf{x})/B$.

Proposições com hipóteses só ficam úteis quando se sabe o que acontece ao violá-las — e, no caso do *bagging*, uma delas é violada o tempo todo.

- (a) Identifique as duas condições e explique, para cada uma, o que acontece com a conclusão se ela falhar.
- (b) O *bagging* usa árvores **profundas e não podadas**. Qual das duas condições essa escolha atende? E por que podar as árvores seria contraproducente aqui?

- (c) Na prática as árvores do *bagging* são correlacionadas. Explique a razão — o que elas têm em comum que as faz parecidas — e por que aumentar B não resolve esse problema específico.
- (d) A floresta aleatória sorteia $m < p$ covariáveis candidatas em cada nó. Explique como isso ataca a condição comprometida, qual é o preço pago na outra, e por que o negócio costuma compensar mesmo assim.

Aula 06 — Pré-processamento e *Pipelines*

Exercício 13 — para quem a régua importa. Um colega recebeu um banco em que a coluna **renda** está em reais e a coluna **altura** em metros, e pergunta se precisa padronizar antes de ajustar. A resposta honesta é "depende do método" — e o critério que decide cabe numa pergunta: **o método soma coisas vindas de colunas diferentes?**

Se soma, as unidades precisam ser comparáveis, e trocar uma delas estraga a comparação. Se não soma, a unidade é irrelevante.

- (a) Para cada método abaixo, diga se multiplicar uma única coluna por 1000 **muda** ou **não muda** a predição, justificando em uma linha onde está — ou onde não está — a soma sobre colunas.
 - (i) Mínimos quadrados ordinários.
 - (ii) Regressão Ridge com $\lambda > 0$ fixo.
 - (iii) Árvore de regressão.
 - (iv) Floresta aleatória.
 - (v) KNN com k fixo.
 - (vi) *Spline* de base truncada, ajustado por mínimos quadrados.
- (b) Entre os que mudam, qual você espera que seja o mais afetado, e por quê? Compare o *modo* como a escala entra em cada um.
- (c) Um colega observa que, ao reescalar uma coluna, o risco do Lasso *melhorou*, e conclui que não padronizar foi uma boa ideia. Explique o erro do raciocínio.