Lista de Revisão — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aulas 07 a 10 — Classificadores Gaussianos, Métricas, SVM, KNN e Árvores de Classificação

---

Salvo indicação em contrário, $(\boldsymbol{X}, Y)$ é um vetor aleatório com $\boldsymbol{X} \in \mathbb{R}^p$ e Y num conjunto finito $\mathcal{C}$ de classes; no caso binário, $\mathcal{C} = \{0, 1\}$, a classe $Y = 1$ é a positiva e $\eta(\boldsymbol{x}) = \mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x})$. A perda é a 0–1, com risco $R(g) = \mathbb{P}(Y \neq g(\boldsymbol{X}))$, e a amostra de treino $\mathcal{D} = \{(\boldsymbol{X}_i, Y_i)\}_{i=1}^n$ é i.i.d. Nos exercícios sobre SVM, as classes são codificadas por $y \in \{-1, +1\}$.

Aula 07 — Classificação e Classificadores Gaussianos

Exercício 1. Renata é atuária numa seguradora e quer classificar os segurados de um ramo em dois perfis, $Y = 1$ (risco alto) e $Y = 0$ (risco baixo), a partir de uma única covariável: o tempo X, em anos, entre a contratação da apólice e o primeiro sinistro. Ela hesita entre a análise discriminante linear (LDA) e a regressão logística, dois métodos que chegam a uma fronteira linear por caminhos diferentes. Ao longo do exercício, $\sigma(u) = e^u/(1 + e^u)$ é a função logística, log é o logaritmo natural e $\pi_c = \mathbb{P}(Y = c)$.

(a) Comece pelo caso geral, com p covariáveis: suponha que $\boldsymbol{X} \in \mathbb{R}^p$ e que, como no LDA, $\boldsymbol{X} \mid Y = c \sim N(\boldsymbol{\mu}_c, \boldsymbol{\Sigma})$ para $c \in \{0, 1\}$, com $\boldsymbol{\Sigma}$ simétrica e positiva definida. Mostre que $\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x}) = \sigma(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x})$ e escreva β_0 e $\boldsymbol{\beta}$ em função de π_0, π_1, $\boldsymbol{\mu}_0$, $\boldsymbol{\mu}_1$ e $\boldsymbol{\Sigma}$. Conclua que, sob as hipóteses do LDA, o modelo da regressão logística vale exatamente. (Escreva $\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x})$ pelo Teorema de Bayes, com f_c a densidade de $\boldsymbol{X}$ dado $Y = c$, divida o numerador e o denominador por $\pi_1 f_1(\boldsymbol{x})$ e ponha o resultado na forma $\sigma(u(\boldsymbol{x}))$. Depois, substitua as densidades normais em $u(\boldsymbol{x})$, expanda as duas formas quadráticas e observe o que se cancela porque a covariância é a mesma nas duas classes.)

(b) Os tempos de Renata não se parecem com uma normal: são positivos e muito assimétricos. Suponha agora que $X \mid Y = c$ tenha distribuição exponencial de taxa λ_c, com densidade $\lambda_c e^{-\lambda_c x}$ para $x > 0$, com $\lambda_0 = 1$, $\lambda_1 = 3$ e $\pi_0 = \pi_1 = 1/2$: em média, o primeiro sinistro do perfil de risco alto chega três vezes mais cedo. Mostre que $\mathbb{P}(Y = 1 \mid X = x) = \sigma(\log 3 - 2x)$ para $x > 0$. O modelo da regressão logística vale nesta população, isto é, existem constantes β_0 e β_1 com $\mathbb{P}(Y = 1 \mid X = x) = \sigma(\beta_0 + \beta_1 x)$ para todo $x > 0$? As hipóteses do LDA, de que X é normal em cada classe e tem a mesma variância nas duas, valem?

Solução

(a) Pelo Teorema de Bayes, com f_c a densidade de $\boldsymbol{X}$ dado $Y = c$,

$$\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x}) = \frac{\pi_1 f_1(\boldsymbol{x})}{\pi_0 f_0(\boldsymbol{x}) + \pi_1 f_1(\boldsymbol{x})} = \frac{1}{1 + e^{-u(\boldsymbol{x})}} = \sigma(u(\boldsymbol{x})),$$

com

$$u(\boldsymbol{x}) = \log \frac{\pi_1 f_1(\boldsymbol{x})}{\pi_0 f_0(\boldsymbol{x})},$$

em que a segunda igualdade sai de dividir numerador e denominador por $\pi_1 f_1(\boldsymbol{x}) > 0$. Basta, portanto, mostrar que o *log-odds* $u(\boldsymbol{x})$ é afim em $\boldsymbol{x}$. As duas densidades normais têm a mesma constante de normalização, $(2\pi)^{-p/2}(\det \boldsymbol{\Sigma})^{-1/2}$, porque a covariância é

comum, e ela se cancela no quociente:

$$u(\boldsymbol{x}) = \log\frac{\pi_1}{\pi_0} - \tfrac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_1)^\top\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_1) + \tfrac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_0)^\top\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_0).$$

Como $\boldsymbol{\Sigma}^{-1}$ é simétrica, $(\boldsymbol{x}-\boldsymbol{\mu})^\top\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}) = \boldsymbol{x}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{x} - 2\boldsymbol{\mu}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{x} + \boldsymbol{\mu}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$. O termo quadrático $\boldsymbol{x}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{x}$ aparece nas duas formas e se cancela, e sobra

$$u(\boldsymbol{x}) = \beta_0 + \boldsymbol{\beta}^\top\boldsymbol{x}, \qquad \boldsymbol{\beta} = \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1-\boldsymbol{\mu}_0), \qquad \beta_0 = \log\frac{\pi_1}{\pi_0} - \tfrac{1}{2}(\boldsymbol{\mu}_1^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_0).$$

Logo $\mathbb{P}(Y=1 \mid \boldsymbol{X}=\boldsymbol{x}) = \sigma(\beta_0 + \boldsymbol{\beta}^\top\boldsymbol{x})$, que é exatamente o modelo da regressão logística. A covariância comum foi usada duas vezes, para cancelar as constantes de normalização e para cancelar o termo quadrático, e só o segundo uso é indispensável para que o *log-odds* seja afim. Com covariâncias $\boldsymbol{\Sigma}_0 \neq \boldsymbol{\Sigma}_1$, as constantes deixariam em $u(\boldsymbol{x})$ a parcela $\frac{1}{2}\log(\det\boldsymbol{\Sigma}_0/\det\boldsymbol{\Sigma}_1)$, que não depende de $\boldsymbol{x}$ e iria para β_0; já o termo $-\frac{1}{2}\,\boldsymbol{x}^\top(\boldsymbol{\Sigma}_1^{-1} - \boldsymbol{\Sigma}_0^{-1})\boldsymbol{x}$ não seria identicamente nulo, e o *log-odds* seria quadrático em $\boldsymbol{x}$, como no QDA.

(b) Pela mesma fórmula de Bayes, para $x > 0$,

$$u(x) = \log\frac{\pi_1\lambda_1 e^{-\lambda_1 x}}{\pi_0\lambda_0 e^{-\lambda_0 x}} = \log\frac{\pi_1}{\pi_0} + \log\frac{\lambda_1}{\lambda_0} - (\lambda_1-\lambda_0)\,x = 0 + \log 3 - 2x,$$

e portanto $\mathbb{P}(Y=1 \mid X=x) = \sigma(\log 3 - 2x)$. O modelo logístico vale exatamente, com $\beta_0 = \log 3 \approx 1{,}0986$ e $\beta_1 = -2$. As hipóteses do LDA falham duas vezes: $X \mid Y=c$ não é normal (vive em $(0,\infty)$ e é assimétrica), e as variâncias das duas classes, 1 e 1/9, são diferentes. O item (a) mostra que as hipóteses do LDA bastam para o modelo logístico, e este item mostra que não são necessárias: a logística supõe apenas que o *log-odds* seja afim, e isso acontece aqui sem nada de normal.

Exercício 2. Lucas é analista de crédito e quer prever a inadimplência, $Y=1$, a partir da renda mensal X_1 do cliente, em milhares de reais. Na população de clientes, $X_1 \mid Y=1 \sim N(3,1)$ e $X_1 \mid Y=0 \sim N(5,1)$. Ao juntar duas bases, Lucas fica, sem perceber, com a renda duas vezes: em X_1, em milhares de reais, e em $X_2 = 1000\,X_1$, em reais. Ele ajusta um Bayes ingênuo gaussiano às duas colunas. Para separar o erro do modelo do erro de estimação, suponha que a amostra é tão grande que o ingênuo usa as distribuições verdadeiras de X_1 e de X_2 em cada classe. Seja

$$L(x_1) = \log\frac{f_1(x_1)}{f_0(x_1)}$$

a razão de log-verossimilhanças da renda, em que f_c é a densidade de X_1 dado $Y=c$ e log é o logaritmo natural, e sejam $\pi_c = \mathbb{P}(Y=c)$ e $\sigma(u) = e^u/(1+e^u)$.

(a) Mostre que $L(x_1) = 8 - 2x_1$. Mostre que, num cliente com renda x_1, o *log-odds* verdadeiro é $\log(\pi_1/\pi_0) + L(x_1)$ e o calculado pelo ingênuo é $\log(\pi_1/\pi_0) + 2L(x_1)$.

(b) Suponha $\pi_0 = \pi_1 = 1/2$ e seja $\eta = \mathbb{P}(Y=1 \mid X_1 = x_1)$. Mostre que a probabilidade calculada pelo ingênuo é $\widehat{P} = \eta^2/(\eta^2 + (1-\eta)^2)$. Conclua que ela ordena os clientes como η, que classifica cada um como o classificador de Bayes, e que $\left|\widehat{P} - 1/2\right| > |\eta - 1/2|$ sempre que $\eta \notin \{0, 1/2, 1\}$. Calcule $\widehat{P}$ para $\eta = 0{,}6$ e para $\eta = 0{,}8$.

(c) Na carteira de Lucas, porém, só 20% dos clientes são inadimplentes: $\pi_1 = 0{,}2$. Determine as rendas que o classificador de Bayes classifica como inadimplentes e as que o ingênuo

classifica assim, e mostre que as duas decisões diferem num intervalo de rendas. Calcule a probabilidade de um cliente cair nesse intervalo e diga qual das duas decisões erra mais nele. *Dados:* $\log 2 \approx 0{,}6931$, $\Phi(-1{,}3466) \approx 0{,}0891$, $\Phi(-1{,}6931) \approx 0{,}0452$, $\Phi(0{,}6534) \approx 0{,}7433$ e $\Phi(0{,}3069) \approx 0{,}6205$, em que Φ é a função de distribuição da normal padrão.

(d) Se a renda aparecesse em m colunas, todas proporcionais a X_1, o que aconteceria com o *log-odds* do ingênuo? E com a sua decisão quando $m \to \infty$? Resuma o que o exercício mostra sobre o Bayes ingênuo com covariáveis redundantes: o que ele preserva e o que ele estraga.

Solução

(a) Com as densidades $N(3,1)$ e $N(5,1)$, as constantes de normalização se cancelam no quociente, e

$$L(x_1) = -\tfrac{1}{2}(x_1-3)^2 + \tfrac{1}{2}(x_1-5)^2 = \tfrac{1}{2}\left[(x_1-5)^2 - (x_1-3)^2\right] = \tfrac{1}{2}\,(-2)(2x_1-8) = 8 - 2x_1,$$

em que se usou $a^2 - b^2 = (a-b)(a+b)$ com $a = x_1 - 5$ e $b = x_1 - 3$.
O par (X_1, X_2) carrega a mesma informação que X_1, porque $X_2 = 1000\,X_1$ é uma função de X_1, e X_1 é função do par. Saber que $(X_1, X_2) = (x_1, 1000\,x_1)$ é, portanto, o mesmo que saber que $X_1 = x_1$, e o *log-odds* verdadeiro é o da renda sozinha:

$$\log \frac{\mathbb{P}(Y=1 \mid X_1 = x_1)}{\mathbb{P}(Y=0 \mid X_1 = x_1)} = \log \frac{\pi_1 f_1(x_1)}{\pi_0 f_0(x_1)} = \log \frac{\pi_1}{\pi_0} + L(x_1).$$

O ingênuo, por sua vez, trata as duas colunas como independentes dentro de cada classe e usa o produto das densidades marginais. A densidade de $X_2 = 1000\,X_1$ dado $Y = c$ é $h_c(x_2) = \frac{1}{1000} f_c(x_2/1000)$, pela fórmula da mudança de variável, e o fator $1/1000$ se cancela no quociente: $h_1(1000\,x_1)/h_0(1000\,x_1) = f_1(x_1)/f_0(x_1)$. O *log-odds* do ingênuo é então

$$\log \frac{\pi_1 f_1(x_1)\, h_1(1000\,x_1)}{\pi_0 f_0(x_1)\, h_0(1000\,x_1)} = \log \frac{\pi_1}{\pi_0} + 2L(x_1).$$

A mudança de unidade não altera a razão de verossimilhanças, e a segunda coluna repete a evidência da primeira; o ingênuo a soma de novo, como se fosse uma testemunha independente.

(b) Com prioris iguais, $\log(\pi_1/\pi_0) = 0$, o *log-odds* verdadeiro é $u = L(x_1)$ e o do ingênuo é $2u$. Como $\eta = \sigma(u)$, vale $e^u = \eta/(1-\eta)$, e

$$\widehat{P} = \sigma(2u) = \frac{e^{2u}}{1+e^{2u}} = \frac{\eta^2/(1-\eta)^2}{1+\eta^2/(1-\eta)^2} = \frac{\eta^2}{\eta^2 + (1-\eta)^2}.$$

A função $u \mapsto \sigma(2u)$ é estritamente crescente, e $u \mapsto \sigma(u)$ também; logo $\widehat{P}$ é uma função estritamente crescente de η, e os dois ordenam os clientes da mesma maneira. Em particular, $\widehat{P} > 1/2 \iff 2u > 0 \iff u > 0 \iff \eta > 1/2$, e o ingênuo classifica cada cliente como o classificador de Bayes.
Para $1/2 < \eta < 1$, dividindo por $\eta > 0$,

$$\widehat{P} > \eta \iff \eta > \eta^2 + (1-\eta)^2 \iff 2\eta^2 - 3\eta + 1 < 0 \iff (2\eta - 1)(\eta - 1) < 0,$$

o que vale, porque o primeiro fator é positivo e o segundo é negativo. Para $0 < \eta < 1/2$, a simetria $\widehat{P}(1-\eta) = 1 - \widehat{P}(\eta)$ dá $\widehat{P} < \eta$. Nos dois casos $\widehat{P}$ fica mais longe de $1/2$ que η. Com $\eta = 0{,}6$, $\widehat{P} = 0{,}36/0{,}52 \approx 0{,}692$; com $\eta = 0{,}8$, $\widehat{P} = 0{,}64/0{,}68 \approx 0{,}941$. O ingênuo acerta a ordem e a decisão, mas exagera a certeza.

(c) Com $\pi_1 = 0{,}2$, $\log(\pi_1/\pi_0) = \log(1/4) = -2\log 2$. O classificador de Bayes declara inadimplente quando o *log-odds* verdadeiro é positivo:

$$-2\log 2 + 8 - 2x_1 > 0 \iff x_1 < 4 - \log 2 \approx 3{,}3069.$$

O ingênuo declara quando o seu *log-odds* é positivo:

$$-2\log 2 + 2(8 - 2x_1) > 0 \iff x_1 < 4 - \tfrac{1}{2}\log 2 \approx 3{,}6534.$$

As decisões diferem no intervalo $I = [3{,}3069;\ 3{,}6534)$, de rendas entre cerca de R\$ 3 307 e R\$ 3 653: ali o ingênuo declara inadimplente quem o classificador de Bayes declara adimplente. Com prioris iguais isso não acontecia, porque multiplicar o *log-odds* por 2 não muda o seu sinal; com prioris diferentes, o termo $\log(\pi_1/\pi_0)$ não é dobrado, e o ponto em que a soma troca de sinal se desloca.
Pela lei da probabilidade total, com os dados do enunciado,

$$\mathbb{P}(X_1 \in I \mid Y = 0) = \Phi(3{,}6534 - 5) - \Phi(3{,}3069 - 5) \approx 0{,}0891 - 0{,}0452 = 0{,}0439,$$
$$\mathbb{P}(X_1 \in I \mid Y = 1) = \Phi(3{,}6534 - 3) - \Phi(3{,}3069 - 3) \approx 0{,}7433 - 0{,}6205 = 0{,}1228,$$

e $\mathbb{P}(X_1 \in I) \approx 0{,}8 \cdot 0{,}0439 + 0{,}2 \cdot 0{,}1228 \approx 0{,}035 + 0{,}025 = 0{,}060$: a decisão muda para cerca de 6% dos clientes. Em I, o ingênuo erra nos adimplentes, com probabilidade $\mathbb{P}(Y = 0,\ X_1 \in I) \approx 0{,}035$, e o classificador de Bayes erra nos inadimplentes, com probabilidade $\mathbb{P}(Y = 1,\ X_1 \in I) \approx 0{,}025$. O ingênuo erra mais, e a sua probabilidade de erro fica cerca de 0,011 acima da de Bayes, como tinha de ser, porque nenhum classificador erra menos que o de Bayes.

(d) Com m colunas proporcionais a X_1, o argumento do item (a) se repete para cada uma, e o *log-odds* do ingênuo passa a $\log(\pi_1/\pi_0) + m\,L(x_1)$. Quando $m \to \infty$, o segundo termo domina sempre que $L(x_1) \neq 0$: o *log-odds* vai a $+\infty$ se $L(x_1) > 0$ e a $-\infty$ se $L(x_1) < 0$, e a probabilidade calculada vai a 1 ou a 0. A decisão passa a ser $x_1 < 4$, a de prioris iguais, como se a priori tivesse sumido.
O Bayes ingênuo com covariáveis redundantes preserva a ordenação das observações, porque o seu *log-odds* continua sendo uma função crescente do verdadeiro. Estraga as probabilidades, que saem empurradas para 0 e 1, e, quando as classes têm tamanhos diferentes, estraga também algumas decisões, porque a evidência é contada mais de uma vez e a priori, uma vez só. Covariáveis apenas correlacionadas produzem uma versão mais branda do mesmo efeito; com colunas repetidas ou quase repetidas, convém retirá-las antes do ajuste ou usar um modelo que leve a correlação em conta.

Aula 08 — Métricas para Classificação

Exercício 3. Diego é analista antifraude num banco e tem dois sistemas que já foram avaliados, A e B. Tome a fraude como a classe positiva, $Y = 1$. As taxas de falsos positivos e de verdadeiros positivos são $(\mathrm{FPR}, \mathrm{TPR}) = (0{,}02;\ 0{,}50)$ para A e $(0{,}08;\ 0{,}80)$ para B. O banco aceita mandar para revisão manual no máximo 5% das transações legítimas, e nenhum dos dois sistemas aproveita esse limite: A fica abaixo dele e B o ultrapassa. Diego então propõe sortear: para cada transação, uma moeda com probabilidade λ de dar cara, lançada independentemente de tudo o mais, escolhe se a decisão será a de A (cara) ou a de B (coroa). Seja g_λ esse classificador.

(a) Mostre que $\mathrm{FPR}(g_\lambda) = \lambda\,\mathrm{FPR}(A) + (1-\lambda)\,\mathrm{FPR}(B)$ e que o mesmo vale para a TPR, isto é, que o ponto de g_λ no plano (FPR, TPR) está no segmento que liga os pontos de A e de

B. Determine λ para que a taxa de falsos positivos seja exatamente 0,05 e calcule a taxa de verdadeiros positivos obtida. Que classificadores sorteados dão os pontos da diagonal?

(b) Um terceiro sistema, C, tem $(\mathrm{FPR}, \mathrm{TPR}) = (0{,}70;\ 0{,}40)$. Mostre que o classificador que inverte todas as decisões de C tem o ponto $(0{,}30;\ 0{,}60)$ e, em geral, que inverter as decisões leva $(\mathrm{FPR}, \mathrm{TPR})$ a $(1-\mathrm{FPR}, 1-\mathrm{TPR})$. Se um escore tem curva ROC abaixo da diagonal, com área $\mathrm{AUC} < 1/2$, qual é a curva e qual é a área do escore com o sinal trocado?

(c) Com custos ℓ_0 por falso negativo e ℓ_1 por falso positivo, o custo esperado de um classificador g é $R_\ell(g) = \ell_1 \mathbb{P}(g(\boldsymbol{X}) = 1, Y = 0) + \ell_0 \mathbb{P}(g(\boldsymbol{X}) = 0, Y = 1)$. Mostre que $R_\ell(g_\lambda) = \lambda R_\ell(A) + (1-\lambda) R_\ell(B)$ e conclua que, sem a restrição do banco, sortear nunca custa menos que o melhor dos dois sistemas. Para que serve, então, o sorteio?

Solução

(a) Seja Z a moeda, com $\mathbb{P}(Z = 1) = \lambda$, independente de $(\boldsymbol{X}, Y)$. Pela lei da probabilidade total, condicionando em Z,

$$\begin{aligned}\mathbb{P}\big(g_\lambda(\boldsymbol{X}) = 1 \mid Y = 0\big) = \lambda\, &\mathbb{P}\big(g_A(\boldsymbol{X}) = 1 \mid Y = 0,\, Z = 1\big) \\ &+ (1-\lambda)\, \mathbb{P}\big(g_B(\boldsymbol{X}) = 1 \mid Y = 0,\, Z = 0\big),\end{aligned}$$

em que se usou $\mathbb{P}(Z = 1 \mid Y = 0) = \mathbb{P}(Z = 1) = \lambda$, pela independência. Também pela independência, condicionar em Z não altera a distribuição de $\boldsymbol{X}$ dado Y, e as duas probabilidades condicionais são as taxas de falsos positivos de A e de B. Assim, $\mathrm{FPR}(g_\lambda) = \lambda\,\mathrm{FPR}(A) + (1-\lambda)\,\mathrm{FPR}(B)$, e a mesma conta, condicionando em $Y = 1$, dá a TPR. O ponto de g_λ é a combinação convexa dos pontos de A e de B com pesos λ e $1-\lambda$, e percorre o segmento entre eles quando λ vai de 0 a 1.
Para a taxa de falsos positivos valer 0,05,

$$0{,}02\,\lambda + 0{,}08\,(1-\lambda) = 0{,}05 \iff 0{,}06\,\lambda = 0{,}03 \iff \lambda = \tfrac{1}{2},$$

e a taxa de verdadeiros positivos é $\frac{1}{2}\cdot 0{,}50 + \frac{1}{2}\cdot 0{,}80 = 0{,}65$: Diego usa o limite do banco inteiro e detecta 65% das fraudes, contra 50% de A. A diagonal vem do sorteio entre os dois classificadores triviais, $g \equiv 0$, no ponto $(0,0)$, e $g \equiv 1$, no ponto $(1,1)$: sortear $g = 1$ com probabilidade q dá o ponto (q, q).

(b) Se $g' = 1 - g$, então $g'(\boldsymbol{X}) = 1$ exatamente quando $g(\boldsymbol{X}) = 0$, e

$$\mathrm{TPR}(g') = \mathbb{P}(g(\boldsymbol{X}) = 0 \mid Y = 1) = 1 - \mathrm{TPR}(g), \qquad \mathrm{FPR}(g') = 1 - \mathrm{FPR}(g).$$

Para C, o ponto invertido é $(1-0{,}70;\ 1-0{,}40) = (0{,}30;\ 0{,}60)$, acima da diagonal: um sistema que erra sistematicamente carrega informação, desde que se faça o contrário do que ele diz. A aplicação $(a, b) \mapsto (1-a, 1-b)$ é a simetria em relação ao ponto $(\frac{1}{2}, \frac{1}{2})$. Trocar o sinal do escore troca "escore acima do corte" por "escore abaixo do corte", o que inverte as decisões em cada corte; a curva do escore com o sinal trocado é, portanto, a simétrica da original em relação a $(\frac{1}{2}, \frac{1}{2})$. Essa simetria leva a região do quadrado unitário abaixo de uma curva na região acima da curva simétrica e preserva áreas. A área sob a curva nova é, então, a área acima da curva antiga, $1 - \mathrm{AUC} > 1/2$.

(c) Condicionando de novo na moeda, e usando a independência,

$$\mathbb{P}\big(g_\lambda(\boldsymbol{X}) = 1, Y = 0\big) = \lambda\, \mathbb{P}\big(g_A(\boldsymbol{X}) = 1, Y = 0\big) + (1-\lambda)\, \mathbb{P}\big(g_B(\boldsymbol{X}) = 1, Y = 0\big),$$

e o mesmo para $\mathbb{P}(g_\lambda(\boldsymbol{X}) = 0, Y = 1)$. Multiplicando a primeira igualdade por ℓ_1, a segunda por ℓ_0 e somando, $R_\ell(g_\lambda) = \lambda R_\ell(A) + (1-\lambda) R_\ell(B)$. Uma média ponderada de dois números nunca é menor que o menor deles, e o sorteio nunca custa menos que o melhor dos dois sistemas: sem restrição, basta escolher um deles. O sorteio serve para atingir um ponto que nenhum dos dois atinge, como a taxa de falsos positivos de exatamente 0,05 permitida pelo banco: respeitando esse limite, $g_{1/2}$ detecta 65% das fraudes, e A, só 50%.

Exercício 4. Cecília é médica e coordena o rastreamento de uma doença que atinge 1% da população: $\mathbb{P}(Y = 1) = 0{,}01$, com $Y = 1$ para doente. O exame disponível tem resultado $X \in \{0, 1\}$ e, seguindo o resultado (isto é, declarando doente quem tem $X = 1$), detecta 90% dos doentes e dá alarme falso para 10% dos saudáveis: $\mathbb{P}(X = 1 \mid Y = 1) = 0{,}9$ e $\mathbb{P}(X = 1 \mid Y = 0) = 0{,}1$. Seja $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$.

(a) Calcule $\eta(1)$ e $\eta(0)$.

(b) Determine o classificador de Bayes, o que minimiza a probabilidade de erro. Compare a probabilidade de erro dele com a do classificador que segue o exame. Um colega conclui que o exame não serve para nada. O que há de errado nessa conclusão?

(c) Sejam ℓ_0 o custo de deixar passar um doente e ℓ_1 o de um alarme falso, e $r = \ell_0/\ell_1$. Lembre que o classificador que declara doente quando $\eta(x) > \ell_1/(\ell_0 + \ell_1)$ minimiza o custo esperado. Mostre que esse classificador segue o exame, isto é, declara doente exatamente quem tem $X = 1$, se e somente se $11 < r \leq 891$, e diga o que ele faz fora dessa faixa. Para $\ell_0 = 20$ e $\ell_1 = 1$, calcule o custo esperado de declarar todos saudáveis, de seguir o exame e de declarar todos doentes, numa população de 10 000 pessoas.

Solução

(a) Pelo Teorema de Bayes,

$$\eta(1) = \frac{0{,}9 \cdot 0{,}01}{0{,}9 \cdot 0{,}01 + 0{,}1 \cdot 0{,}99} = \frac{0{,}009}{0{,}108} = \frac{1}{12} \approx 0{,}083,$$

$$\eta(0) = \frac{0{,}1 \cdot 0{,}01}{0{,}1 \cdot 0{,}01 + 0{,}9 \cdot 0{,}99} = \frac{0{,}001}{0{,}892} = \frac{1}{892} \approx 0{,}0011.$$

Um resultado positivo multiplica a probabilidade de doença por cerca de 8, de 1% para 8,3%, e um negativo a divide por cerca de 9; ainda assim, mesmo com o exame positivo, a doença continua improvável, porque ela é rara: entre os positivos, os 9 doentes em cada mil pessoas são superados pelos 99 saudáveis com alarme falso.

(b) O classificador de Bayes declara doente quando $\eta(x) > 1/2$. Como $\eta(0)$ e $\eta(1)$ estão abaixo de $1/2$, ele é $g \equiv 0$: declara todos saudáveis, qualquer que seja o resultado do exame. A probabilidade de erro dele é $\mathbb{P}(Y = 1) = 0{,}01$. Seguir o exame erra nos doentes com $X = 0$ e nos saudáveis com $X = 1$:

$$\mathbb{P}(X \neq Y) = 0{,}01 \cdot 0{,}1 + 0{,}99 \cdot 0{,}1 = 0{,}001 + 0{,}099 = 0{,}1,$$

dez vezes mais. A conclusão do colega confunde a probabilidade de erro com a utilidade. O classificador de Bayes minimiza a probabilidade de erro, que dá o mesmo peso a um doente não detectado e a um alarme falso; com uma doença rara, a maneira mais barata de errar pouco é nunca acusar ninguém, ao preço de não detectar doente nenhum. O exame detecta 90% dos doentes: o que falta saber é quanto vale cada um deles comparado a um alarme falso.

(c) O corte é $\ell_1/(\ell_0 + \ell_1) = 1/(1 + r)$, e o classificador compara $\eta(x)$ com ele em cada valor de x separadamente. Ele segue o exame, isto é, declara doente em $x = 1$ e saudável em $x = 0$, quando

$$\eta(1) > \frac{1}{1+r} \iff 1 + r > 12 \iff r > 11 \qquad \text{e} \qquad \eta(0) \leq \frac{1}{1+r} \iff r \leq 891.$$

Com $r \leq 11$, ele declara todos saudáveis; com $r > 891$, declara todos doentes, porque, quando um doente não detectado custa mais que 891 alarmes falsos, até a chance de $1/892$ que resta depois de um exame negativo justifica declarar doente. Nos extremos da faixa

há empate: com $r = 11$, declarar doente ou saudável custa o mesmo em $x = 1$, e, com $r = 891$, em $x = 0$. Nos dois empates o classificador declara saudável, porque só declara doente quando $\eta(x)$ passa do corte; por isso a faixa exclui $r = 11$ e inclui $r = 891$. Em termos de custo, seguir o exame é uma decisão ótima para $11 \le r \le 891$, e a única para $11 < r < 891$: vale a pena exatamente quando deixar passar um doente custa entre 11 e 891 alarmes falsos.
Com $\ell_0 = 20$ e $\ell_1 = 1$, $r = 20$ está na faixa, e seguir o exame é o ótimo. Numa população de 10 000 pessoas há, em média, $P = 100$ doentes e $N = 9\,900$ saudáveis, e as contagens esperadas saem das taxas: $\mathrm{FN} = (1 - \mathrm{TPR})\,P$ e $\mathrm{FP} = \mathrm{FPR} \cdot N$. Declarar todos saudáveis dá $\mathrm{FN} = 100$ e custo $20 \cdot 100 = 2\,000$. Seguir o exame dá $\mathrm{FN} = 0{,}1 \cdot 100 = 10$ e $\mathrm{FP} = 0{,}1 \cdot 9\,900 = 990$, com custo $20 \cdot 10 + 990 = 1\,190$. Declarar todos doentes dá $\mathrm{FP} = 9\,900$ e custo 9 900. O exame economiza 810 unidades de custo a cada dez mil pessoas em relação ao classificador de Bayes, embora erre dez vezes mais que ele.

Aula 09 — Máquinas de Vetores de Suporte

Exercício 5. Tiago trabalha no controle de qualidade de uma fábrica e classifica peças em boas ($y = +1$) e defeituosas ($y = -1$) a partir de p medidas. As suas n observações de treino $(\boldsymbol{x}_i, y_i)$ são linearmente separáveis, e cada classe tem pelo menos duas observações. O classificador de margem máxima é dado pela solução do problema

$$\max_{\beta_0,\,\boldsymbol{\beta},\,M} \; M \quad \text{sujeito a} \quad \sum_{j=1}^{p} \beta_j^2 = 1 \quad \text{e} \quad y_i\,(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) \ge M, \quad i = 1, \dots, n.$$

Defina $f(\boldsymbol{x}) = \beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}$. Os vetores de suporte são as observações com $y_i f(\boldsymbol{x}_i) = M$, e $\mathcal{S}$ é o conjunto dos seus índices. Admita que, para observações separáveis com as duas classes presentes, o problema tem solução, e seja $M^* > 0$ o valor ótimo. Durante as aulas afirmamos, sem demonstrar, que essa solução depende apenas dos vetores de suporte. Este exercício pretende elucidar esse resultado.

(a) Mostre que a solução é única. (Se houvesse duas soluções com vetores $\boldsymbol{\beta}$ diferentes, compare-as com o ponto médio entre elas. Se tivessem o mesmo $\boldsymbol{\beta}$, olhe, como funções de β_0, o menor valor de $y_i f(\boldsymbol{x}_i)$ em cada classe.)

(b) Seja $i_0 \notin \mathcal{S}$. Mostre que o classificador de margem máxima das $n - 1$ observações sem a observação i_0 é o mesmo das n observações. (Se o valor ótimo sem i_0 fosse maior que M^*, combine a solução nova com a antiga, com peso pequeno na nova.) Mostre também que deslocar $\boldsymbol{x}_{i_0}$ para qualquer ponto $\boldsymbol{x}'$ com $y_{i_0} f(\boldsymbol{x}') > M^*$, em que f é a função da solução, não muda o classificador.

(c) A estimativa do risco por validação cruzada com uma observação deixada de fora (LOOCV) é a proporção das observações i que o classificador ajustado sem i classifica errado. Mostre que, para o classificador de margem máxima, ela é no máximo $|\mathcal{S}|\,/n$.

Solução

(a) Sejam $(\beta_0, \boldsymbol{\beta}, M^*)$ e $(\beta_0', \boldsymbol{\beta}', M^*)$ duas soluções, e $(\bar{b}, \bar{\boldsymbol{w}})$ o ponto médio de $(\beta_0, \boldsymbol{\beta})$ e $(\beta_0', \boldsymbol{\beta}')$. Para cada i,

$$y_i(\bar{b} + \bar{\boldsymbol{w}}^\top \boldsymbol{x}_i) = \tfrac{1}{2}\left[y_i(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) + y_i(\beta_0' + \boldsymbol{\beta}'^\top \boldsymbol{x}_i)\right] \;\ge\; M^*.$$

Suponha $\boldsymbol{\beta} \neq \boldsymbol{\beta}'$. Como $\|\boldsymbol{\beta}\| = \|\boldsymbol{\beta}'\| = 1$, a desigualdade de Cauchy–Schwarz dá $\boldsymbol{\beta}^\top \boldsymbol{\beta}' < 1$, com desigualdade estrita porque a igualdade exigiria $\boldsymbol{\beta}' = \boldsymbol{\beta}$, e $\|\bar{\boldsymbol{w}}\|^2 = \frac{1}{4}(2 + 2\,\boldsymbol{\beta}^\top \boldsymbol{\beta}') < 1$. Também $\bar{\boldsymbol{w}} \neq \mathbf{0}$: do contrário, $y_i \bar{b} \geq M^* > 0$ para todo i, o que exigiria $\bar{b} > 0$ nas observações da classe $+1$ e $\bar{b} < 0$ nas da classe -1. Dividindo $(\bar{b}, \bar{\boldsymbol{w}})$ por $\|\bar{\boldsymbol{w}}\| \in (0, 1)$, obtém-se um vetor de norma 1 com $y_i(\cdot) \geq M^* / \|\bar{\boldsymbol{w}}\| > M^*$ para todo i, o que contradiz a otimalidade de M^*. Logo $\boldsymbol{\beta} = \boldsymbol{\beta}'$.

Com $\boldsymbol{\beta}$ fixado, sejam $m_+(b) = \min_{i:\, y_i = +1}(b + \boldsymbol{\beta}^\top \boldsymbol{x}_i)$ e $m_-(b) = \min_{i:\, y_i = -1}(-b - \boldsymbol{\beta}^\top \boldsymbol{x}_i)$, de modo que a margem do hiperplano $(b, \boldsymbol{\beta})$ é $\min\{m_+(b), m_-(b)\}$. A função m_+ é estritamente crescente, e m_-, estritamente decrescente. Suponha $\beta_0 < \beta_0'$. Então $m_-(\beta_0) > m_-(\beta_0') \geq M^*$, e, como o mínimo em β_0 vale M^*, é $m_+(\beta_0) = M^*$; do mesmo modo, $m_+(\beta_0') > m_+(\beta_0) = M^*$ e $m_-(\beta_0') = M^*$. No ponto médio $b = (\beta_0 + \beta_0')/2$, $m_+(b) > m_+(\beta_0) = M^*$ e $m_-(b) > m_-(\beta_0') = M^*$: o hiperplano $(b, \boldsymbol{\beta})$ teria margem maior que M^*, um absurdo. Logo $\beta_0 = \beta_0'$, e a solução é única.

(b) Seja $(\beta_0^*, \boldsymbol{\beta}^*, M^*)$ a solução com as n observações e f^* a função correspondente; como $i_0 \notin \mathcal{S}$, vale $\delta = y_{i_0} f^*(\boldsymbol{x}_{i_0}) - M^* > 0$. Sem i_0, as observações continuam separáveis e com as duas classes, porque cada classe tinha pelo menos duas; o problema tem solução, com valor ótimo M'. O ponto $(\beta_0^*, \boldsymbol{\beta}^*, M^*)$ satisfaz todas as restrições sem i_0, e portanto $M' \geq M^*$.

Suponha $M' > M^*$, atingido por $(\beta_0', \boldsymbol{\beta}')$, com função f'. Para $t \in (0, 1]$, seja $(b_t, \boldsymbol{w}_t) = (1 - t)(\beta_0^*, \boldsymbol{\beta}^*) + t(\beta_0', \boldsymbol{\beta}')$. Para $i \neq i_0$,

$$y_i(b_t + \boldsymbol{w}_t^\top \boldsymbol{x}_i) = (1 - t)\, y_i f^*(\boldsymbol{x}_i) + t\, y_i f'(\boldsymbol{x}_i) \;\geq\; (1 - t)M^* + tM' \;>\; M^*,$$

e, para i_0, com $c = |y_{i_0} f'(\boldsymbol{x}_{i_0}) - y_{i_0} f^*(\boldsymbol{x}_{i_0})|$,

$$y_{i_0}(b_t + \boldsymbol{w}_t^\top \boldsymbol{x}_{i_0}) \;\geq\; M^* + \delta - t\,c \;>\; M^* \qquad \text{para } 0 < t < \delta/c$$

(para todo t, se $c = 0$). Pela desigualdade triangular, $\|\boldsymbol{w}_t\| \leq (1 - t)\,\|\boldsymbol{\beta}^*\| + t\,\|\boldsymbol{\beta}'\| = 1$, e $\boldsymbol{w}_t \neq \mathbf{0}$ pelo mesmo argumento do item (a). Fixe um tal t e divida $(b_t, \boldsymbol{w}_t)$ por $\|\boldsymbol{w}_t\| \leq 1$: os números $y_i(\cdot)$, todos maiores que $M^* > 0$, não diminuem, e o resultado é um hiperplano de norma 1 com $y_i f(\boldsymbol{x}_i) > M^*$ para *todas* as n observações. Isso contradiz a otimalidade de M^*. Logo $M' = M^*$, e $(\beta_0^*, \boldsymbol{\beta}^*, M^*)$, que é viável sem i_0 e atinge esse valor, é uma solução sem i_0; pelo item (a), aplicado às $n - 1$ observações, é a única.

Para o deslocamento, considere as $n - 1$ observações sem i_0 mais a observação $(\boldsymbol{x}', y_{i_0})$. Todo ponto viável desse problema é viável sem i_0, e por isso o valor ótimo é no máximo M^*. A solução $(\beta_0^*, \boldsymbol{\beta}^*, M^*)$ satisfaz as restrições sem i_0 e a nova, $y_{i_0} f^*(\boldsymbol{x}') > M^*$: é viável e atinge M^*, logo é ótima e, pelo item (a), a única. A solução não vê as observações que estão do lado certo e fora da faixa: elas podem sair ou mudar de lugar, desde que continuem fora dela.

(c) Para cada i, as observações sem i são separáveis e têm as duas classes, e o classificador de margem máxima delas, g_{-i}, está bem definido. Se $i \notin \mathcal{S}$, pelo item (b) g_{-i} é o classificador g das n observações, que classifica $\boldsymbol{x}_i$ corretamente, porque $y_i f^*(\boldsymbol{x}_i) > M^* > 0$. Assim, $g_{-i}(\boldsymbol{x}_i) \neq y_i$ só pode acontecer para $i \in \mathcal{S}$, e

$$\frac{1}{n}\sum_{i=1}^{n} \mathbf{1}\{g_{-i}(\boldsymbol{x}_i) \neq y_i\} = \frac{1}{n}\sum_{i \in \mathcal{S}} \mathbf{1}\{g_{-i}(\boldsymbol{x}_i) \neq y_i\} \;\leq\; \frac{|\mathcal{S}|}{n}.$$

A cota sai de um único ajuste, o das n observações: das n retiradas que a validação cruzada faria, só as dos vetores de suporte podem alterar o classificador e, com isso, produzir um erro.

Exercício 6. Júlia estuda matemática aplicada e lê nas notas que o *kernel* radial $k(\boldsymbol{x}, \boldsymbol{x}') = \exp(-\gamma \|\boldsymbol{x} - \boldsymbol{x}'\|^2)$, com $\gamma > 0$, é um *kernel* em $\mathbb{R}^p$; e decide tentar demonstrar o resultado. Lembre que $k : \mathbb{R}^p \times \mathbb{R}^p \to \mathbb{R}$ é um *kernel* se existem um espaço de Hilbert $\mathcal{H}$ e uma função $\varphi : \mathbb{R}^p \to \mathcal{H}$ com $k(\boldsymbol{x}, \boldsymbol{x}') = \langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle_{\mathcal{H}}$ para todos $\boldsymbol{x}, \boldsymbol{x}'$, e que, pelo teorema visto em aula, isso acontece se e somente se k é simétrica e, para todo $n \geq 1$ e quaisquer $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n \in \mathbb{R}^p$, a matriz $[k(\boldsymbol{x}_i, \boldsymbol{x}_j)]_{i,j=1}^n$ é positiva semidefinida. Use à vontade que o produto interno $\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$ e as funções constantes iguais a $c \geq 0$ são *kernels*, e que a soma de dois *kernels* e o produto de um *kernel* por uma constante $c \geq 0$ também são.

(a) Mostre que, se k_1 e k_2 são *kernels*, o produto $k(\boldsymbol{x}, \boldsymbol{x}') = k_1(\boldsymbol{x}, \boldsymbol{x}')\, k_2(\boldsymbol{x}, \boldsymbol{x}')$ também é. (Escreva uma das duas matrizes pela decomposição espectral.)

(b) Mostre que, se k é um *kernel* e $h : \mathbb{R}^p \to \mathbb{R}$ é uma função qualquer, então $h(\boldsymbol{x})\, h(\boldsymbol{x}')\, k(\boldsymbol{x}, \boldsymbol{x}')$ é um *kernel*. Mostre também que $e^{k(\boldsymbol{x}, \boldsymbol{x}')}$ é um *kernel*, usando a série da exponencial e o fato de que um limite de matrizes positivas semidefinidas é positivo semidefinido.

(c) Conclua que o *kernel* radial é um *kernel* em $\mathbb{R}^p$, para todo p e todo $\gamma > 0$. (Escreva $\|\boldsymbol{x} - \boldsymbol{x}'\|^2$ em termos de $\|\boldsymbol{x}\|^2$, $\|\boldsymbol{x}'\|^2$ e $\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$.)

Solução

(a) Sejam $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n \in \mathbb{R}^p$, $A = [k_1(\boldsymbol{x}_i, \boldsymbol{x}_j)]$ e $B = [k_2(\boldsymbol{x}_i, \boldsymbol{x}_j)]$, simétricas e positivas semidefinidas pelo teorema. A matriz de k nesses pontos é o produto entrada a entrada, $(A \circ B)_{ij} = A_{ij} B_{ij}$, que é simétrica. Pelo teorema espectral, $B = \sum_{m=1}^n \lambda_m \boldsymbol{v}_m \boldsymbol{v}_m^\top$, com autovalores $\lambda_m \geq 0$, porque B é positiva semidefinida, e autovetores ortonormais $\boldsymbol{v}_m \in \mathbb{R}^n$; em coordenadas, $B_{ij} = \sum_m \lambda_m v_{mi} v_{mj}$. Para $\boldsymbol{a} \in \mathbb{R}^n$,

$$\begin{aligned} \boldsymbol{a}^\top (A \circ B)\, \boldsymbol{a} &= \sum_{i,j} a_i a_j A_{ij} \sum_m \lambda_m v_{mi} v_{mj} = \sum_m \lambda_m \sum_{i,j} (a_i v_{mi})\, A_{ij}\, (a_j v_{mj}) \\ &= \sum_m \lambda_m\, \boldsymbol{u}_m^\top A\, \boldsymbol{u}_m \;\geq\; 0, \end{aligned}$$

em que $\boldsymbol{u}_m = (a_1 v_{m1}, \ldots, a_n v_{mn})$, e cada parcela é não negativa porque $\lambda_m \geq 0$ e A é positiva semidefinida. Como isso vale para todo n e quaisquer pontos, o teorema dá que $k_1 k_2$ é um *kernel*.

(b) A função $h(\boldsymbol{x}) h(\boldsymbol{x}') k(\boldsymbol{x}, \boldsymbol{x}')$ é simétrica, e a sua matriz nos pontos $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n$ é DKD, com $K = [k(\boldsymbol{x}_i, \boldsymbol{x}_j)]$ e $D = \operatorname{diag}(h(\boldsymbol{x}_1), \ldots, h(\boldsymbol{x}_n))$. Para $\boldsymbol{a} \in \mathbb{R}^n$, $\boldsymbol{a}^\top DKD\, \boldsymbol{a} = (D\boldsymbol{a})^\top K (D\boldsymbol{a}) \geq 0$. (Pela definição, é o mesmo que tomar a função $h\varphi$ no lugar de φ.) Para a exponencial, $e^{k(\boldsymbol{x}, \boldsymbol{x}')} = \sum_{m \geq 0} k(\boldsymbol{x}, \boldsymbol{x}')^m / m!$. A potência k^0 é a constante 1, que é um *kernel*, e, se k^m é um *kernel*, $k^{m+1} = k^m \cdot k$ também é, pelo item (a); por indução, todas as potências são *kernels*. As somas parciais $S_M = \sum_{m=0}^M k^m / m!$ são, então, *kernels*, como somas de *kernels* multiplicados por constantes positivas. Fixados os pontos e $\boldsymbol{a} \in \mathbb{R}^n$, cada número $\boldsymbol{a}^\top [S_M(\boldsymbol{x}_i, \boldsymbol{x}_j)]\, \boldsymbol{a}$ é não negativo, e, quando $M \to \infty$, converge para $\boldsymbol{a}^\top [e^{k(\boldsymbol{x}_i, \boldsymbol{x}_j)}]\, \boldsymbol{a}$, porque é uma soma finita de termos que convergem. Um limite de números não negativos é não negativo. A matriz de e^k é, portanto, positiva semidefinida, e e^k, que é simétrica, é um *kernel*.

(c) Como $\|\boldsymbol{x} - \boldsymbol{x}'\|^2 = \|\boldsymbol{x}\|^2 - 2\langle \boldsymbol{x}, \boldsymbol{x}' \rangle + \|\boldsymbol{x}'\|^2$,

$$e^{-\gamma \|\boldsymbol{x} - \boldsymbol{x}'\|^2} = e^{-\gamma \|\boldsymbol{x}\|^2}\, e^{-\gamma \|\boldsymbol{x}'\|^2}\, e^{2\gamma \langle \boldsymbol{x}, \boldsymbol{x}' \rangle}.$$

O produto interno é um *kernel*, e $2\gamma \langle \boldsymbol{x}, \boldsymbol{x}' \rangle$ também, porque $2\gamma > 0$. Pelo item (b), $e^{2\gamma \langle \boldsymbol{x}, \boldsymbol{x}' \rangle}$ é um *kernel*, e, ainda pelo item (b), com $h(\boldsymbol{x}) = e^{-\gamma \|\boldsymbol{x}\|^2}$, o produto acima é um *kernel*. O argumento vale para todo p e todo $\gamma > 0$, e não precisa exibir φ; com $p = 1$, expandir $e^{2\gamma x x'}$ em série reproduz a função φ do exemplo das notas.

Aula 10 — KNN e Árvores de Classificação

Exercício 7. Otávio é agrônomo e usa o KNN para classificar os talhões de uma fazenda em atacados por uma praga ($Y = 1$) ou não ($Y = 0$), a partir de medidas de solo e de clima. Num talhão novo, com covariáveis $\boldsymbol{x}$, a probabilidade de praga é $\eta(\boldsymbol{x}) = \mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x}) = 0{,}6$. O KNN estima essa probabilidade pela proporção de praga entre os k talhões de treino mais próximos de $\boldsymbol{x}$, cujos índices formam o conjunto $\mathcal{N}_{\boldsymbol{x}}^{(k)}$,

$$\widehat{P} = \frac{1}{k} \sum_{i \in \mathcal{N}_{\boldsymbol{x}}^{(k)}} Y_i,$$

e declara praga quando $\widehat{P} > 1/2$. Tome k ímpar, para que não haja empate. Para isolar o papel de k, suponha que os rótulos dos vizinhos sejam independentes entre si e do rótulo Y do talhão novo, e que cada um seja igual a 1 com probabilidade 0,6, como se todos os vizinhos estivessem no próprio $\boldsymbol{x}$.

(a) Mostre que $\mathbb{E}[\widehat{P}] = 0{,}6$ e $\mathrm{Var}(\widehat{P}) = 0{,}24/k$.

(b) Seja $q_k = \mathbb{P}(\widehat{P} > 1/2)$. Mostre que a probabilidade de o KNN errar o talhão novo é $0{,}6 - 0{,}2\, q_k$. Calcule q_5 e, usando $q_1 = 0{,}600$, $q_{15} \approx 0{,}787$ e $q_{51} \approx 0{,}926$, a probabilidade de erro para $k = 1, 5, 15$ e 51. Use a desigualdade de Chebyshev para mostrar que $q_k \to 1$ e que a probabilidade de erro tende a 0,4. Que classificador erra com probabilidade 0,4 nesse talhão?

(c) Mostre que, com $k = 1$ e uma probabilidade η qualquer no lugar de 0,6, a probabilidade de erro é $2\eta(1-\eta)$, e que $\min(\eta, 1-\eta) \le 2\eta(1-\eta) \le 2\min(\eta, 1-\eta)$. Interprete. O que acontece no outro extremo, com $k = n$?

Solução

(a) O conjunto $\mathcal{N}_{\boldsymbol{x}}^{(k)}$ tem k elementos, e cada Y_i, com $i \in \mathcal{N}_{\boldsymbol{x}}^{(k)}$, é uma Bernoulli(0,6), com média 0,6 e variância $0{,}6 \cdot 0{,}4 = 0{,}24$. A esperança sai da linearidade, e a variância, da independência dos rótulos, que permite somar as variâncias:

$$\mathbb{E}[\widehat{P}] = \frac{1}{k} \sum_{i \in \mathcal{N}_{\boldsymbol{x}}^{(k)}} \mathbb{E}[Y_i] = \frac{k \cdot 0{,}6}{k} = 0{,}6, \qquad \mathrm{Var}(\widehat{P}) = \frac{1}{k^2} \sum_{i \in \mathcal{N}_{\boldsymbol{x}}^{(k)}} \mathrm{Var}(Y_i) = \frac{k \cdot 0{,}24}{k^2} = \frac{0{,}24}{k}.$$

Nesta idealização, a proporção de vizinhos é um estimador não viesado de $\eta(\boldsymbol{x})$, e a sua variância cai como $1/k$.

(b) O KNN erra se declara praga num talhão sem praga ou deixa de declarar num talhão com praga. Como a decisão depende só dos rótulos dos vizinhos, que são independentes de Y,

$$\mathbb{P}(\widehat{g}(\boldsymbol{x}) \neq Y) = q_k\, \mathbb{P}(Y = 0) + (1 - q_k)\, \mathbb{P}(Y = 1) = 0{,}4\, q_k + 0{,}6\,(1 - q_k) = 0{,}6 - 0{,}2\, q_k.$$

Com $k = 5$, o KNN declara praga quando pelo menos 3 dos 5 vizinhos têm praga, e o número deles é uma binomial(5; 0,6):

$$q_5 = \binom{5}{3}(0{,}6)^3(0{,}4)^2 + \binom{5}{4}(0{,}6)^4(0{,}4) + (0{,}6)^5 = 0{,}3456 + 0{,}2592 + 0{,}0778 \approx 0{,}683.$$

As probabilidades de erro são 0,480, 0,463, 0,443 e 0,415 para $k = 1$, 5, 15 e 51. Como k é ímpar, $\widehat{P} \neq 1/2$, e o KNN deixa de declarar praga exatamente quando $\widehat{P} < 1/2$. Esse

evento está contido em $\{\left|\widehat{P} - 0{,}6\right| \geq 0{,}1\}$, e, pela desigualdade de Chebyshev,

$$1 - q_k = \mathbb{P}(\widehat{P} < 1/2) \leq \mathbb{P}(\left|\widehat{P} - 0{,}6\right| \geq 0{,}1) \leq \frac{\mathrm{Var}(\widehat{P})}{0{,}1^2} = \frac{24}{k} \longrightarrow 0.$$

Logo $q_k \to 1$ e a probabilidade de erro tende a $0{,}6 - 0{,}2 = 0{,}4$. É a probabilidade de erro do classificador de Bayes nesse talhão: como $\eta(\boldsymbol{x}) > 1/2$, ele declara praga, e erra com probabilidade $1 - \eta(\boldsymbol{x}) = 0{,}4$, que nenhum classificador pode melhorar.

(c) Com $k = 1$, o KNN repete o rótulo do vizinho mais próximo, que é 1 com probabilidade η e independente de Y. Ele erra se os dois rótulos diferem:

$$\mathbb{P}(\widehat{g}(\boldsymbol{x}) \neq Y) = \eta(1-\eta) + (1-\eta)\eta = 2\eta(1-\eta).$$

Sejam $m = \min(\eta, 1-\eta)$ e $1 - m = \max(\eta, 1-\eta)$, com $1/2 \leq 1 - m \leq 1$. Então $2\eta(1-\eta) = 2m(1-m)$, e multiplicar as desigualdades $1/2 \leq 1 - m \leq 1$ por $2m \geq 0$ dá $m \leq 2m(1-m) \leq 2m$. Como m é a probabilidade de erro do classificador de Bayes em $\boldsymbol{x}$, o 1-NN, nesta idealização, erra pelo menos tanto quanto ele e no máximo o dobro; com $\eta = 0{,}6$, são 0,48 contra 0,40. No outro extremo, com $k = n$, todos os pontos de treino votam, $\widehat{P}$ é a proporção de talhões com praga no treino inteiro, e o KNN atribui a mesma classe, a majoritária, a qualquer talhão: é o classificador constante, com o maior viés possível.

Exercício 8. Rafael é analista numa operadora de planos de saúde e cresceu uma árvore de classificação, com o índice de Gini, para prever quais beneficiários serão internados no próximo ano ($Y = 1$). Agora vai podá-la. Para uma região R com n_R observações de treino, sejam $n_{R,c}$ o número delas na classe c e $\widehat{p}_{R,c} = n_{R,c}/n_R$; o índice de Gini de R é $G(R) = \sum_c \widehat{p}_{R,c}(1 - \widehat{p}_{R,c})$. A folha R prediz a classe majoritária, e $E(R) = 1 - \max_c \widehat{p}_{R,c}$ é o seu erro de classificação, de modo que $n_R E(R) = n_R - \max_c n_{R,c}$ é o número de erros de treino na folha. Na poda por custo-complexidade com o erro de classificação, escolhe-se, entre as subárvores T da árvore crescida, a que minimiza

$$C_\alpha(T) = \sum_{m=1}^{|T|} n_m E(R_m) + \alpha\,|T|\,,$$

em que $R_1, \ldots, R_{|T|}$ são as folhas de T, $n_m = n_{R_m}$ e $|T|$ é o número de folhas; o valor de $\alpha > 0$ é escolhido por validação cruzada.

(a) Seja R uma região dividida em regiões disjuntas $R_1, \ldots, R_L$. Mostre que $\sum_l n_{R_l} E(R_l) \leq n_R E(R)$, com qualquer número de classes, e que vale a igualdade quando uma mesma classe c^* é majoritária em todas as R_l; nesse caso, c^* é majoritária também em R.

(b) Mostre que, para todo $\alpha > 0$, nenhuma subárvore que minimize C_α tem um nó interno cujas folhas descendentes predizem todas a mesma classe.

(c) Na árvore de Rafael, um nó R com 400 beneficiários, dos quais 100 foram internados, foi dividido em dois filhos de 200, que são folhas da árvore crescida: R_1, com 20 internados, e R_2, com 80. Calcule a redução do índice de Gini ponderado, $G(R) - [n_1 G(R_1) + n_2 G(R_2)]/n_R$, e a redução do erro de classificação ponderado. Por que o crescimento fez essa divisão, e o que a poda fará com ela?

Solução

(a) As regiões R_l particionam R, e por isso $n_{R,c} = \sum_l n_{R_l,c}$ para cada classe c. O máximo de uma soma não passa da soma dos máximos:

$$\max_c n_{R,c} = \max_c \sum_l n_{R_l,c} \;\le\; \sum_l \max_c n_{R_l,c}.$$

Logo

$$\sum_l n_{R_l} E(R_l) = \sum_l \Big(n_{R_l} - \max_c n_{R_l,c}\Big) = n_R - \sum_l \max_c n_{R_l,c} \;\le\; n_R - \max_c n_{R,c} = n_R E(R).$$

Se c^* é majoritária em todas as R_l, então $\sum_l \max_c n_{R_l,c} = \sum_l n_{R_l,c^*} = n_{R,c^*} \le \max_c n_{R,c}$; com a desigualdade anterior, os três números são iguais. A igualdade vale, e $n_{R,c^*} = \max_c n_{R,c}$: c^* é majoritária em R. Dividir uma região nunca aumenta o número de erros de treino, e só o diminui quando alguma das partes muda a classe predita.

(b) Suponha que T minimize C_α e tenha um nó interno t cujas $L \ge 2$ folhas descendentes predizem todas a classe c^*. Seja T' a subárvore obtida trocando o ramo que sai de t por uma única folha, a região de t. Pelo item (a), essa folha tem c^* como classe majoritária e o mesmo número de erros de treino que as L folhas juntas; as outras folhas não mudam. As duas subárvores cometem, então, os mesmos erros, e $|T'| = |T| - (L-1)$, de modo que

$$C_\alpha(T') = C_\alpha(T) - \alpha(L-1) < C_\alpha(T),$$

porque $\alpha > 0$ e $L \ge 2$. Isso contradiz a escolha de T. Qualquer que seja $\alpha > 0$, a poda pelo erro de classificação remove todos os ramos que não mudam nenhuma decisão.

(c) As proporções de internados são 0,25 no nó e 0,1 e 0,4 nos filhos. Com duas classes, as duas parcelas de G são iguais, e $G = 2\widehat{p}(1-\widehat{p})$, com $\widehat{p}$ a proporção de internados:

$$G(R) = 2 \cdot 0{,}25 \cdot 0{,}75 = 0{,}375, \qquad \tfrac{1}{2}\,G(R_1) + \tfrac{1}{2}\,G(R_2) = \tfrac{1}{2} \cdot 0{,}18 + \tfrac{1}{2} \cdot 0{,}48 = 0{,}33,$$

uma redução de 0,045. A classe majoritária é "não internado" no nó (300 contra 100) e nos dois filhos (180 contra 20 e 120 contra 80). Os erros são 100 no nó e $20 + 80 = 100$ nos filhos: a redução do erro é zero, como o item (a) previa. O Gini é estritamente côncavo e registra o ganho de pureza de separar um grupo de risco baixo (10% de internações) de um de risco alto (40%); por isso o crescimento fez a divisão. Como os filhos são folhas da árvore crescida, numa subárvore que mantenha a divisão eles são as únicas folhas descendentes de R, e os dois predizem a mesma classe. Pelo item (b), a poda pelo erro remove a divisão, qualquer que seja $\alpha > 0$.

Exercício 9. Ana é bióloga e usa uma árvore de classificação para distinguir mudas de duas espécies, a espécie 1 e a espécie 0, a partir de características medidas no viveiro. Num nó com 12 mudas, 6 de cada espécie, a árvore compara duas divisões:

A pela altura, separa dois grupos de 6 mudas, um com 2 da espécie 1 e 4 da espécie 0 e outro com 4 da espécie 1 e 2 da espécie 0;

B por uma mancha rara na folha, isola uma única muda, da espécie 0, das outras 11, que têm 6 da espécie 1 e 5 da espécie 0.

Numa região com proporção p de mudas da espécie 1, o índice de Gini é $G(p) = 2p(1-p)$, a entropia é $D(p) = -p\log_2 p - (1-p)\log_2(1-p)$, com $0\log_2 0 = 0$, e o erro de classificação é $E(p) = \min(p, 1-p)$. Uma divisão em regiões com n_1 e n_2 mudas e proporções p_1 e p_2 tem

impureza ponderada $[n_1 I(p_1) + n_2 I(p_2)]/(n_1 + n_2)$, para cada medida I, e a árvore escolhe a divisão de menor impureza ponderada.

(a) Calcule a impureza ponderada das divisões A e B pelas três medidas e diga qual divisão cada medida escolhe. *Dados:* $\log_2 3 \approx 1{,}5850$, $\log_2 5 \approx 2{,}3219$ e $\log_2 11 \approx 3{,}4594$.

(b) Seja I uma medida de impureza qualquer para duas classes, com $I(p) = I(1-p)$, $I(0) = 0$ e $I(6/11) > 0$. Mostre que A tem impureza ponderada menor que B se e somente se $I(1/3)/I(6/11) < 11/12$. Calcule essa razão para as três medidas e explique que propriedade da curva da entropia a leva a escolher B.

Solução

(a) Na divisão A, as proporções da espécie 1 são 1/3 e 2/3, cada uma num filho com metade das mudas. Na divisão B, são 0, numa muda, e 6/11, nas outras 11. Pelo Gini,

$$\text{A: } \tfrac{1}{2}\cdot 2\cdot\tfrac{1}{3}\cdot\tfrac{2}{3} + \tfrac{1}{2}\cdot 2\cdot\tfrac{2}{3}\cdot\tfrac{1}{3} = \tfrac{4}{9} \approx 0{,}444, \qquad \text{B: } \tfrac{1}{12}\cdot 0 + \tfrac{11}{12}\cdot 2\cdot\tfrac{6}{11}\cdot\tfrac{5}{11} = \tfrac{5}{11} \approx 0{,}455.$$

Pela entropia, como $D(1/3) = D(2/3) = \frac{1}{3}\log_2 3 + \frac{2}{3}\log_2\frac{3}{2} = \log_2 3 - \frac{2}{3}$,

$$\text{A: } \log_2 3 - \tfrac{2}{3} \approx 0{,}918,$$

$$\text{B: } \tfrac{11}{12} D\big(\tfrac{6}{11}\big) = \tfrac{1}{12}\Big(6\log_2\tfrac{11}{6} + 5\log_2\tfrac{11}{5}\Big) = \tfrac{1}{12}\big(11\log_2 11 - 6\log_2 6 - 5\log_2 5\big) \approx 0{,}911,$$

com $\log_2 6 = 1 + \log_2 3$. Pelo erro de classificação, A erra 2 mudas em cada filho, $4/12 = 1/3$, e B erra as 5 mudas da espécie 0 no filho grande, $5/12 \approx 0{,}417$. O Gini e o erro escolhem A; a entropia escolhe B. O nó tem $G = 0{,}5$ e $D = 1$, e as reduções correspondentes são 0,056 (A) e 0,045 (B) no Gini, e 0,082 (A) e 0,089 (B) na entropia.

(b) Pela simetria, a impureza ponderada de A é $\frac{1}{2}I(1/3) + \frac{1}{2}I(2/3) = I(1/3)$, e a de B é $\frac{1}{12}I(0) + \frac{11}{12}I(6/11) = \frac{11}{12}I(6/11)$. Como $I(6/11) > 0$,

$$I\big(\tfrac{1}{3}\big) < \tfrac{11}{12}\, I\big(\tfrac{6}{11}\big) \iff \frac{I(1/3)}{I(6/11)} < \frac{11}{12} \approx 0{,}917.$$

As razões são $(4/9)/(60/121) = 121/135 \approx 0{,}896$ para o Gini, $0{,}918/0{,}994 \approx 0{,}924$ para a entropia e $(1/3)/(5/11) = 11/15 \approx 0{,}733$ para o erro: só a entropia passa de 11/12.
A comparação tem uma leitura simples. A divisão A leva os dois filhos da proporção 1/2 à proporção 1/3; a divisão B torna pura 1/12 das mudas e deixa as outras numa região quase tão misturada quanto o nó, porque $6/11 \approx 0{,}545$ está perto de 1/2. Com $I(6/11) \approx I(1/2)$, a pergunta é, em essência, se $I(1/3)$ fica abaixo de 11/12 do máximo: $G(1/3)/G(1/2) = 8/9 \approx 0{,}889$, mas $D(1/3)/D(1/2) \approx 0{,}918$. A entropia é mais achatada perto do máximo: trata uma região com um terço de uma espécie como quase tão impura quanto uma equilibrada, e por isso dá pouco valor à purificação parcial de A e, em comparação, mais valor à purificação completa de um pedaço pequeno, que é o que B faz.