Lista de Revisão — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aulas 07 a 10 — Classificadores Gaussianos, Métricas, SVM, KNN e Árvores de Classificação

---

Salvo indicação em contrário, $(\boldsymbol{X}, Y)$ é um vetor aleatório com $\boldsymbol{X} \in \mathbb{R}^p$ e Y num conjunto finito $\mathcal{C}$ de classes; no caso binário, $\mathcal{C} = \{0, 1\}$, a classe $Y = 1$ é a positiva e $\eta(\boldsymbol{x}) = \mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x})$. A perda é a 0–1, com risco $R(g) = \mathbb{P}(Y \neq g(\boldsymbol{X}))$, e a amostra de treino $\mathcal{D} = \{(\boldsymbol{X}_i, Y_i)\}_{i=1}^n$ é i.i.d. Nos exercícios sobre SVM, as classes são codificadas por $y \in \{-1, +1\}$.

Aula 07 — Classificação e Classificadores Gaussianos

Exercício 1. Renata é atuária numa seguradora e quer classificar os segurados de um ramo em dois perfis, $Y = 1$ (risco alto) e $Y = 0$ (risco baixo), a partir de uma única covariável: o tempo X, em anos, entre a contratação da apólice e o primeiro sinistro. Ela hesita entre a análise discriminante linear (LDA) e a regressão logística, dois métodos que chegam a uma fronteira linear por caminhos diferentes. Ao longo do exercício, $\sigma(u) = e^u/(1 + e^u)$ é a função logística, log é o logaritmo natural e $\pi_c = \mathbb{P}(Y = c)$.

(a) Suponha que $\boldsymbol{X} \in \mathbb{R}^p$ e que, como no LDA, $\boldsymbol{X} \mid Y = c \sim N(\boldsymbol{\mu}_c, \boldsymbol{\Sigma})$ para $c \in \{0, 1\}$, com $\boldsymbol{\Sigma}$ simétrica e positiva definida. Mostre que $\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x}) = \sigma(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x})$ e escreva β_0 e $\boldsymbol{\beta}$ em função de π_0, π_1, $\boldsymbol{\mu}_0$, $\boldsymbol{\mu}_1$ e $\boldsymbol{\Sigma}$. Conclua que, sob as hipóteses do LDA, o modelo da regressão logística vale exatamente. (*Dica:* Escreva $\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x})$ pelo Teorema de Bayes, com f_c a densidade de $\boldsymbol{X}$ dado $Y = c$, divida o numerador e o denominador por $\pi_1 f_1(\boldsymbol{x})$ e ponha o resultado na forma $\sigma(u(\boldsymbol{x}))$. Depois, substitua as densidades normais em $u(\boldsymbol{x})$, expanda as duas formas quadráticas e observe o que se cancela porque a covariância é a mesma nas duas classes.)

(b) Os tempos de Renata não se parecem com uma normal: são positivos e muito assimétricos. Suponha agora que $X \mid Y = c$ tenha distribuição exponencial de taxa λ_c, com densidade $\lambda_c e^{-\lambda_c x}$ para $x > 0$, com $\lambda_0 = 1$, $\lambda_1 = 3$ e $\pi_0 = \pi_1 = 1/2$: em média, o primeiro sinistro do perfil de risco alto chega três vezes mais cedo. Mostre que $\mathbb{P}(Y = 1 \mid X = x) = \sigma(\log 3 - 2x)$ para $x > 0$. O modelo da regressão logística vale nesta população, isto é, existem constantes β_0 e β_1 com $\mathbb{P}(Y = 1 \mid X = x) = \sigma(\beta_0 + \beta_1 x)$ para todo $x > 0$? As hipóteses do LDA, de que X é normal em cada classe e tem a mesma variância nas duas, valem?

Solução

(a) Pelo Teorema de Bayes, com f_c a densidade de $\boldsymbol{X}$ dado $Y = c$,

$$\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x}) = \frac{\pi_1 f_1(\boldsymbol{x})}{\pi_0 f_0(\boldsymbol{x}) + \pi_1 f_1(\boldsymbol{x})} = \frac{1}{1 + e^{-u(\boldsymbol{x})}} = \sigma(u(\boldsymbol{x})),$$

com

$$u(\boldsymbol{x}) = \log \frac{\pi_1 f_1(\boldsymbol{x})}{\pi_0 f_0(\boldsymbol{x})},$$

em que a segunda igualdade sai de dividir numerador e denominador por $\pi_1 f_1(\boldsymbol{x}) > 0$. Basta, portanto, mostrar que o *log-odds* $u(\boldsymbol{x})$ é afim em $\boldsymbol{x}$. As duas densidades normais têm a mesma constante de normalização, $(2\pi)^{-p/2}(\det \boldsymbol{\Sigma})^{-1/2}$, porque a covariância é

comum, e ela se cancela no quociente:

$$u(\boldsymbol{x}) = \log\frac{\pi_1}{\pi_0} - \tfrac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_1)^\top\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_1) + \tfrac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_0)^\top\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_0).$$

Como $\boldsymbol{\Sigma}^{-1}$ é simétrica, $(\boldsymbol{x}-\boldsymbol{\mu})^\top\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}) = \boldsymbol{x}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{x} - 2\boldsymbol{\mu}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{x} + \boldsymbol{\mu}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$. O termo quadrático $\boldsymbol{x}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{x}$ aparece nas duas formas e se cancela, e sobra

$$u(\boldsymbol{x}) = \beta_0 + \boldsymbol{\beta}^\top\boldsymbol{x}, \qquad \boldsymbol{\beta} = \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1-\boldsymbol{\mu}_0), \qquad \beta_0 = \log\frac{\pi_1}{\pi_0} - \tfrac{1}{2}(\boldsymbol{\mu}_1^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_0).$$

Logo $\mathbb{P}(Y=1 \mid \boldsymbol{X}=\boldsymbol{x}) = \sigma(\beta_0 + \boldsymbol{\beta}^\top\boldsymbol{x})$, que é exatamente o modelo da regressão logística. A covariância comum foi usada uma única vez, no cancelamento do termo quadrático; com covariâncias diferentes, esse termo e os determinantes sobreviveriam, e o *log-odds* seria quadrático, como no QDA.

(b) Pela mesma fórmula de Bayes, para $x > 0$,

$$u(x) = \log\frac{\pi_1\lambda_1 e^{-\lambda_1 x}}{\pi_0\lambda_0 e^{-\lambda_0 x}} = \log\frac{\pi_1}{\pi_0} + \log\frac{\lambda_1}{\lambda_0} - (\lambda_1-\lambda_0)\,x = 0 + \log 3 - 2x,$$

e portanto $\mathbb{P}(Y=1 \mid X=x) = \sigma(\log 3 - 2x)$. O modelo logístico vale exatamente, com $\beta_0 = \log 3 \approx 1{,}0986$ e $\beta_1 = -2$. As hipóteses do LDA falham duas vezes: $X \mid Y=c$ não é normal (vive em $(0,\infty)$ e é assimétrica), e as variâncias das duas classes, 1 e 1/9, são diferentes. O item (a) mostra que as hipóteses do LDA bastam para o modelo logístico, e este item mostra que não são necessárias: a logística supõe apenas que o *log-odds* seja afim, e isso acontece aqui sem nada de normal.

Exercício 2. Lucas é analista de crédito e quer prever a inadimplência, $Y=1$, a partir da renda mensal X_1 do cliente, em milhares de reais. Na população de clientes, $X_1 \mid Y=1 \sim N(3,1)$ e $X_1 \mid Y=0 \sim N(5,1)$. Ao juntar duas bases, Lucas fica, sem perceber, com a renda duas vezes: em X_1, em milhares de reais, e em $X_2 = 1000\,X_1$, em reais. Ele ajusta um Bayes ingênuo gaussiano às duas colunas. Para separar o erro do modelo do erro de estimação, suponha que a amostra é tão grande que o ingênuo usa as distribuições verdadeiras de X_1 e de X_2 em cada classe. Seja

$$L(x_1) = \log\frac{f_1(x_1)}{f_0(x_1)}$$

a razão de log-verossimilhanças da renda, em que f_c é a densidade de X_1 dado $Y=c$ e log é o logaritmo natural, e sejam $\pi_c = \mathbb{P}(Y=c)$ e $\sigma(u) = e^u/(1+e^u)$.

(a) Mostre que $L(x_1) = 8 - 2x_1$. Mostre que, num cliente com renda x_1, o *log-odds* verdadeiro é $\log(\pi_1/\pi_0) + L(x_1)$ e o calculado pelo ingênuo é $\log(\pi_1/\pi_0) + 2L(x_1)$.

(b) Suponha $\pi_0 = \pi_1 = 1/2$ e seja $\eta = \mathbb{P}(Y=1 \mid X_1 = x_1)$. Mostre que a probabilidade calculada pelo ingênuo é $\widehat{P} = \eta^2/(\eta^2 + (1-\eta)^2)$. Conclua que ela ordena os clientes como η, que classifica cada um como o classificador de Bayes, e que $\left|\widehat{P} - 1/2\right| > |\eta - 1/2|$ sempre que $\eta \notin \{0, 1/2, 1\}$. Calcule $\widehat{P}$ para $\eta = 0{,}6$ e para $\eta = 0{,}8$.

(c) Na carteira de Lucas, porém, só 20% dos clientes são inadimplentes: $\pi_1 = 0{,}2$. Determine as rendas que o classificador de Bayes classifica como inadimplentes e as que o ingênuo classifica assim, e mostre que as duas decisões diferem num intervalo de rendas. Calcule a probabilidade de um cliente cair nesse intervalo e diga qual das duas decisões erra mais nele. *Dados:* $\log 2 \approx 0{,}6931$, $\Phi(-1{,}3466) \approx 0{,}0891$, $\Phi(-1{,}6931) \approx 0{,}0452$, $\Phi(0{,}6534) \approx 0{,}7433$ e $\Phi(0{,}3069) \approx 0{,}6205$, em que Φ é a função de distribuição da normal padrão.

(d) Se a renda aparecesse em m colunas, todas proporcionais a X_1, o que aconteceria com o *log-odds* do ingênuo? E com a sua decisão quando $m \to \infty$? Resuma o que o exercício mostra sobre o Bayes ingênuo com covariáveis redundantes: o que ele preserva e o que ele estraga.

Solução

(a) Com as densidades $N(3,1)$ e $N(5,1)$, as constantes de normalização se cancelam no quociente, e

$$L(x_1) = -\tfrac{1}{2}(x_1-3)^2 + \tfrac{1}{2}(x_1-5)^2 = \tfrac{1}{2}\left[(x_1-5)^2 - (x_1-3)^2\right] = \tfrac{1}{2}\,(-2)(2x_1-8) = 8-2x_1,$$

em que se usou $a^2-b^2=(a-b)(a+b)$ com $a=x_1-5$ e $b=x_1-3$.
O par (X_1, X_2) carrega a mesma informação que X_1, porque $X_2 = 1000\,X_1$ é uma função de X_1, e X_1 é função do par. Saber que $(X_1,X_2)=(x_1,1000\,x_1)$ é, portanto, o mesmo que saber que $X_1=x_1$, e o *log-odds* verdadeiro é o da renda sozinha:

$$\log\frac{\mathbb{P}(Y=1\mid X_1=x_1)}{\mathbb{P}(Y=0\mid X_1=x_1)} = \log\frac{\pi_1 f_1(x_1)}{\pi_0 f_0(x_1)} = \log\frac{\pi_1}{\pi_0} + L(x_1).$$

O ingênuo, por sua vez, trata as duas colunas como independentes dentro de cada classe e usa o produto das densidades marginais. A densidade de $X_2 = 1000\,X_1$ dado $Y=c$ é $h_c(x_2) = \frac{1}{1000} f_c(x_2/1000)$, pela fórmula da mudança de variável, e o fator $1/1000$ se cancela no quociente: $h_1(1000\,x_1)/h_0(1000\,x_1) = f_1(x_1)/f_0(x_1)$. O *log-odds* do ingênuo é então

$$\log\frac{\pi_1 f_1(x_1)\,h_1(1000\,x_1)}{\pi_0 f_0(x_1)\,h_0(1000\,x_1)} = \log\frac{\pi_1}{\pi_0} + 2L(x_1).$$

A mudança de unidade não altera a razão de verossimilhanças, e a segunda coluna repete a evidência da primeira; o ingênuo a soma de novo, como se fosse uma testemunha independente.

(b) Com prioris iguais, $\log(\pi_1/\pi_0)=0$, o *log-odds* verdadeiro é $u=L(x_1)$ e o do ingênuo é $2u$. Como $\eta=\sigma(u)$, vale $e^u = \eta/(1-\eta)$, e

$$\widehat{P} = \sigma(2u) = \frac{e^{2u}}{1+e^{2u}} = \frac{\eta^2/(1-\eta)^2}{1+\eta^2/(1-\eta)^2} = \frac{\eta^2}{\eta^2+(1-\eta)^2}.$$

A função $u \mapsto \sigma(2u)$ é estritamente crescente, e $u\mapsto\sigma(u)$ também; logo $\widehat{P}$ é uma função estritamente crescente de η, e os dois ordenam os clientes da mesma maneira. Em particular, $\widehat{P}>1/2 \iff 2u>0 \iff u>0 \iff \eta>1/2$, e o ingênuo classifica cada cliente como o classificador de Bayes.
Para $1/2<\eta<1$, dividindo por $\eta>0$,

$$\widehat{P}>\eta \iff \eta > \eta^2+(1-\eta)^2 \iff 2\eta^2-3\eta+1<0 \iff (2\eta-1)(\eta-1)<0,$$

o que vale, porque o primeiro fator é positivo e o segundo é negativo. Para $0<\eta<1/2$, a simetria $\widehat{P}(1-\eta)=1-\widehat{P}(\eta)$ dá $\widehat{P}<\eta$. Nos dois casos $\widehat{P}$ fica mais longe de $1/2$ que η. Com $\eta=0{,}6$, $\widehat{P}=0{,}36/0{,}52\approx 0{,}692$; com $\eta=0{,}8$, $\widehat{P}=0{,}64/0{,}68\approx 0{,}941$. O ingênuo acerta a ordem e a decisão, mas exagera a certeza.

(c) Com $\pi_1=0{,}2$, $\log(\pi_1/\pi_0)=\log(1/4)=-2\log 2$. O classificador de Bayes declara inadimplente quando o *log-odds* verdadeiro é positivo:

$$-2\log 2 + 8 - 2x_1 > 0 \iff x_1 < 4-\log 2 \approx 3{,}3069.$$

O ingênuo declara quando o seu *log-odds* é positivo:

$$-2\log 2 + 2(8 - 2x_1) > 0 \iff x_1 < 4 - \tfrac{1}{2}\log 2 \approx 3{,}6534.$$

As decisões diferem no intervalo $I = [3{,}3069;\ 3{,}6534)$, de rendas entre cerca de R\$ 3 307 e R\$ 3 653: ali o ingênuo declara inadimplente quem o classificador de Bayes declara adimplente. Com prioris iguais isso não acontecia, porque multiplicar o *log-odds* por 2 não muda o seu sinal; com prioris diferentes, o termo $\log(\pi_1/\pi_0)$ não é dobrado, e o ponto em que a soma troca de sinal se desloca.
Pela lei da probabilidade total, com os dados do enunciado,

$$\mathbb{P}(X_1 \in I \mid Y = 0) = \Phi(3{,}6534 - 5) - \Phi(3{,}3069 - 5) \approx 0{,}0891 - 0{,}0452 = 0{,}0439,$$
$$\mathbb{P}(X_1 \in I \mid Y = 1) = \Phi(3{,}6534 - 3) - \Phi(3{,}3069 - 3) \approx 0{,}7433 - 0{,}6205 = 0{,}1228,$$

e $\mathbb{P}(X_1 \in I) \approx 0{,}8 \cdot 0{,}0439 + 0{,}2 \cdot 0{,}1228 \approx 0{,}035 + 0{,}025 = 0{,}060$: a decisão muda para cerca de 6% dos clientes. Em I, o ingênuo erra nos adimplentes, com probabilidade $\mathbb{P}(Y = 0,\ X_1 \in I) \approx 0{,}035$, e o classificador de Bayes erra nos inadimplentes, com probabilidade $\mathbb{P}(Y = 1,\ X_1 \in I) \approx 0{,}025$. O ingênuo erra mais, e a sua probabilidade de erro fica cerca de 0,011 acima da de Bayes, como tinha de ser, porque nenhum classificador erra menos que o de Bayes.

(d) Com m colunas proporcionais a X_1, o argumento do item (a) se repete para cada uma, e o *log-odds* do ingênuo passa a $\log(\pi_1/\pi_0) + m\,L(x_1)$. Quando $m \to \infty$, o segundo termo domina sempre que $L(x_1) \neq 0$: o *log-odds* vai a $+\infty$ se $L(x_1) > 0$ e a $-\infty$ se $L(x_1) < 0$, e a probabilidade calculada vai a 1 ou a 0. A decisão passa a ser $x_1 < 4$, a de prioris iguais, como se a priori tivesse sumido.
O Bayes ingênuo com covariáveis redundantes preserva a ordenação das observações, porque o seu *log-odds* continua sendo uma função crescente do verdadeiro. Estraga as probabilidades, que saem empurradas para 0 e 1, e, quando as classes têm tamanhos diferentes, estraga também algumas decisões, porque a evidência é contada mais de uma vez e a priori, uma vez só. Covariáveis apenas correlacionadas produzem uma versão mais branda do mesmo efeito; com colunas repetidas ou quase repetidas, convém retirá-las antes do ajuste ou usar um modelo que leve a correlação em conta.

Exercício 3. Beatriz trabalha com marketing e ajusta uma regressão logística para prever se um cliente responde a uma campanha ($y_i = 1$) ou não ($y_i = 0$), a partir de p covariáveis. Sejam $\tilde{\boldsymbol{x}}_i = (1, \boldsymbol{x}_i) \in \mathbb{R}^{p+1}$ o vetor de covariáveis da observação i com um 1 na frente, $\tilde{\mathbb{X}}$ a matriz $n \times (p+1)$ cujas linhas são os $\tilde{\boldsymbol{x}}_i^\top$, $\boldsymbol{\beta} = (\beta_0, \beta_1, \ldots, \beta_p)$ e

$$\pi_i(\boldsymbol{\beta}) = \sigma(\tilde{\boldsymbol{x}}_i^\top \boldsymbol{\beta}), \qquad \sigma(u) = \frac{e^u}{1 + e^u}, \qquad \ell(\boldsymbol{\beta}) = \sum_{i=1}^{n} \Big[y_i \log \pi_i(\boldsymbol{\beta}) + (1 - y_i) \log\big(1 - \pi_i(\boldsymbol{\beta})\big) \Big],$$

a log-verossimilhança da amostra. O otimizador do pacote que ela usa avisa, numa das bases, que não convergiu e devolve coeficientes enormes, e ela quer entender por quê.

(a) Mostre que $\ell(\boldsymbol{\beta}) = \sum_i \big[y_i\, \tilde{\boldsymbol{x}}_i^\top \boldsymbol{\beta} - \log\big(1 + e^{\tilde{\boldsymbol{x}}_i^\top \boldsymbol{\beta}}\big) \big]$, que o gradiente é $\nabla \ell(\boldsymbol{\beta}) = \sum_i (y_i - \pi_i) \tilde{\boldsymbol{x}}_i$ e que a hessiana é $-\tilde{\mathbb{X}}^\top W \tilde{\mathbb{X}}$, com $W = \operatorname{diag}\big(\pi_i(1 - \pi_i)\big)$. Conclua que ℓ é côncava, que todo ponto crítico de ℓ é um máximo global e que, se $\tilde{\mathbb{X}}$ tem posto $p + 1$, há no máximo um maximizador.

(b) Mostre que, num maximizador $\widehat{\boldsymbol{\beta}}$, a soma das probabilidades ajustadas é igual ao número de clientes que responderam: $\sum_i \pi_i(\widehat{\boldsymbol{\beta}}) = \sum_i y_i$. Que leitura isso tem?

(c) Não há fórmula fechada para o maximizador, e o otimizador usa o método de Newton–Raphson. Supondo $\tilde{\mathbb{X}}$ de posto $p+1$, escreva o passo de Newton que leva $\boldsymbol{\beta}$ a $\boldsymbol{\beta}^{\text{novo}}$ e mostre que $\boldsymbol{\beta}^{\text{novo}}$ minimiza a soma de quadrados ponderada $\sum_i w_i (z_i - \tilde{\boldsymbol{x}}_i^\top \boldsymbol{b})^2$ em $\boldsymbol{b}$, com $w_i = \pi_i(1-\pi_i)$ e $z_i = \tilde{\boldsymbol{x}}_i^\top \boldsymbol{\beta} + (y_i - \pi_i)/w_i$, todos calculados no $\boldsymbol{\beta}$ atual. Por que o método se chama mínimos quadrados reponderados iterativamente (IRLS)?

(d) Na base problemática existe $\boldsymbol{b}^* \in \mathbb{R}^{p+1}$ com $\tilde{\boldsymbol{x}}_i^\top \boldsymbol{b}^* > 0$ para todo i com $y_i = 1$ e $\tilde{\boldsymbol{x}}_i^\top \boldsymbol{b}^* < 0$ para todo i com $y_i = 0$: um hiperplano separa os que responderam dos que não responderam. Mostre que $\ell(\boldsymbol{\beta}) < 0$ para todo $\boldsymbol{\beta}$ e que $\ell(t\,\boldsymbol{b}^*) \to 0$ quando $t \to \infty$, e conclua que a verossimilhança não tem maximizador. Mostre em seguida que, se as duas classes estão presentes, a função penalizada $Q(\boldsymbol{\beta}) = \ell(\boldsymbol{\beta}) - \lambda \sum_{j=1}^{p} \beta_j^2$, com $\lambda > 0$ e o intercepto sem penalidade, tem um único maximizador.

Solução

(a) Escreva $u_i = \tilde{\boldsymbol{x}}_i^\top \boldsymbol{\beta}$. Como $\pi_i = e^{u_i}/(1+e^{u_i})$ e $1-\pi_i = 1/(1+e^{u_i})$, valem $\log \pi_i = u_i - \log(1+e^{u_i})$ e $\log(1-\pi_i) = -\log(1+e^{u_i})$, e a parcela i de ℓ é

$$y_i\big[u_i - \log(1+e^{u_i})\big] - (1-y_i)\log(1+e^{u_i}) = y_i u_i - \log(1+e^{u_i}),$$

que é a expressão pedida. A derivada de $u \mapsto \log(1+e^u)$ é $\sigma(u)$, e a de σ é $\sigma(1-\sigma)$. Pela regra da cadeia, com $\partial u_i/\partial \boldsymbol{\beta} = \tilde{\boldsymbol{x}}_i$,

$$\nabla \ell(\boldsymbol{\beta}) = \sum_{i=1}^{n} (y_i - \pi_i)\tilde{\boldsymbol{x}}_i, \qquad \nabla^2 \ell(\boldsymbol{\beta}) = -\sum_{i=1}^{n} \pi_i(1-\pi_i)\,\tilde{\boldsymbol{x}}_i \tilde{\boldsymbol{x}}_i^\top = -\tilde{\mathbb{X}}^\top W \tilde{\mathbb{X}}.$$

Para todo $\boldsymbol{v} \in \mathbb{R}^{p+1}$,

$$\boldsymbol{v}^\top (\tilde{\mathbb{X}}^\top W \tilde{\mathbb{X}}) \boldsymbol{v} = \sum_{i=1}^{n} \pi_i(1-\pi_i)(\tilde{\boldsymbol{x}}_i^\top \boldsymbol{v})^2 \;\geq\; 0,$$

e a hessiana é negativa semidefinida em todo ponto: ℓ é côncava. Para uma função côncava e diferenciável, $\ell(\boldsymbol{b}) \leq \ell(\boldsymbol{\beta}) + \nabla \ell(\boldsymbol{\beta})^\top (\boldsymbol{b} - \boldsymbol{\beta})$ para todos $\boldsymbol{b}, \boldsymbol{\beta}$; num ponto crítico o gradiente se anula, e $\ell(\boldsymbol{b}) \leq \ell(\boldsymbol{\beta})$ para todo $\boldsymbol{b}$: o ponto crítico é um máximo global. Se $\tilde{\mathbb{X}}$ tem posto $p+1$, então $\tilde{\mathbb{X}}\boldsymbol{v} \neq \mathbf{0}$ para $\boldsymbol{v} \neq \mathbf{0}$, alguma parcela $(\tilde{\boldsymbol{x}}_i^\top \boldsymbol{v})^2$ é positiva, e, como $0 < \pi_i < 1$, a soma acima é positiva: a hessiana é negativa definida e ℓ é estritamente côncava. Se houvesse dois maximizadores distintos, ℓ seria, no ponto médio entre eles, estritamente maior que o valor máximo, o que é absurdo. Há, portanto, no máximo um.

(b) Num maximizador o gradiente se anula, e a primeira coordenada de $\nabla \ell$, a que corresponde ao intercepto, é $\sum_i (y_i - \pi_i) \cdot 1$. Logo $\sum_i \pi_i(\widehat{\boldsymbol{\beta}}) = \sum_i y_i$, e, dividindo por n, a média das probabilidades ajustadas é a proporção de clientes que responderam. A logística com intercepto acerta, no treino, a taxa global de respostas: o que ela pode errar é como essa taxa se distribui entre os clientes.

(c) O método de Newton para maximizar ℓ substitui ℓ, perto do $\boldsymbol{\beta}$ atual, pela sua aproximação de Taylor de segunda ordem e toma o maximizador dela: $\boldsymbol{\beta}^{\text{novo}} = \boldsymbol{\beta} - [\nabla^2 \ell(\boldsymbol{\beta})]^{-1} \nabla \ell(\boldsymbol{\beta})$. Com o item (a), e escrevendo $\boldsymbol{y}$ e $\boldsymbol{\pi}$ para os vetores de y_i e π_i,

$$\boldsymbol{\beta}^{\text{novo}} = \boldsymbol{\beta} + (\tilde{\mathbb{X}}^\top W \tilde{\mathbb{X}})^{-1} \tilde{\mathbb{X}}^\top (\boldsymbol{y} - \boldsymbol{\pi}).$$

A matriz $\tilde{\mathbb{X}}^\top W \tilde{\mathbb{X}}$ é invertível porque, pelo item (a), é positiva definida. Como $W\boldsymbol{z} = W\tilde{\mathbb{X}}\boldsymbol{\beta} + (\boldsymbol{y} - \boldsymbol{\pi})$, vale $\tilde{\mathbb{X}}^\top W \boldsymbol{z} = \tilde{\mathbb{X}}^\top W \tilde{\mathbb{X}}\,\boldsymbol{\beta} + \tilde{\mathbb{X}}^\top (\boldsymbol{y} - \boldsymbol{\pi})$, e portanto

$$\boldsymbol{\beta}^{\text{novo}} = (\tilde{\mathbb{X}}^\top W \tilde{\mathbb{X}})^{-1} \tilde{\mathbb{X}}^\top W \boldsymbol{z}.$$

Por outro lado, a soma $S(\boldsymbol{b}) = \sum_i w_i(z_i - \tilde{\boldsymbol{x}}_i^\top \boldsymbol{b})^2$ é uma função quadrática estritamente convexa de $\boldsymbol{b}$, cujo gradiente, $-2\tilde{\mathbb{X}}^\top W(\boldsymbol{z} - \tilde{\mathbb{X}}\boldsymbol{b})$, se anula exatamente quando $\tilde{\mathbb{X}}^\top W\tilde{\mathbb{X}}\,\boldsymbol{b} = \tilde{\mathbb{X}}^\top W\boldsymbol{z}$: são as equações normais dos mínimos quadrados ponderados, e a solução delas é $\boldsymbol{\beta}^{\text{novo}}$. Cada passo de Newton é, assim, uma regressão de mínimos quadrados ponderados de uma resposta de trabalho $\boldsymbol{z}$ sobre $\tilde{\mathbb{X}}$. Os pesos w_i e a resposta z_i dependem do $\boldsymbol{\beta}$ atual e são recalculados a cada passo: daí o nome. Os pesos são maiores nas observações com π_i perto de $1/2$, aquelas sobre as quais o modelo ainda está mais incerto.

(d) Cada fator da verossimilhança, π_i se $y_i = 1$ ou $1 - \pi_i$ se $y_i = 0$, está em $(0, 1)$, porque σ toma valores em $(0, 1)$. A verossimilhança é um produto de números em $(0, 1)$ e é menor que 1, e $\ell(\boldsymbol{\beta}) < 0$ para todo $\boldsymbol{\beta}$. Ao longo da semirreta $t\,\boldsymbol{b}^*$, com $t > 0$, cada observação com $y_i = 1$ contribui com $\log \sigma(t\,\tilde{\boldsymbol{x}}_i^\top \boldsymbol{b}^*)$, e $t\,\tilde{\boldsymbol{x}}_i^\top \boldsymbol{b}^* \to +\infty$; cada uma com $y_i = 0$ contribui com $\log\left(1 - \sigma(t\,\tilde{\boldsymbol{x}}_i^\top \boldsymbol{b}^*)\right)$, e $t\,\tilde{\boldsymbol{x}}_i^\top \boldsymbol{b}^* \to -\infty$. Nos dois casos a parcela tende a $\log 1 = 0$, e $\ell(t\,\boldsymbol{b}^*) \to 0$. Assim, $\sup_{\boldsymbol{\beta}} \ell(\boldsymbol{\beta}) = 0$ e esse valor não é atingido em ponto nenhum: não há maximizador. É o que o otimizador de Beatriz encontrou: cada passo aumenta ℓ afastando $\boldsymbol{\beta}$ na direção de $\boldsymbol{b}^*$, e as iterações param pelo limite, com coeficientes tão grandes quanto o número de passos permitir.

Agora a função penalizada. Ela é contínua. Considere uma sequência $\boldsymbol{\beta}^{(m)}$ com $\left\|\boldsymbol{\beta}^{(m)}\right\| \to \infty$, e escreva $\boldsymbol{\beta} = (\beta_0, \boldsymbol{\beta}_{1:p})$. Passando a uma subsequência, há dois casos. Se $\left\|\boldsymbol{\beta}_{1:p}^{(m)}\right\| \to \infty$, então, como $\ell \le 0$, $Q(\boldsymbol{\beta}^{(m)}) \le -\lambda\left\|\boldsymbol{\beta}_{1:p}^{(m)}\right\|^2 \to -\infty$. Se $\left\|\boldsymbol{\beta}_{1:p}^{(m)}\right\|$ fica limitada, então $\left|\beta_0^{(m)}\right| \to \infty$. Tome uma observação i com $y_i = 0$ e uma j com $y_j = 1$, que existem porque as duas classes estão presentes; como as parcelas de ℓ são negativas, $Q \le \ell \le \log(1-\pi_i) + \log \pi_j$. Se $\beta_0^{(m)} \to +\infty$, então $\tilde{\boldsymbol{x}}_i^\top \boldsymbol{\beta}^{(m)} \to +\infty$ e $\log(1 - \pi_i) \to -\infty$; se $\beta_0^{(m)} \to -\infty$, é $\log \pi_j$ que vai a $-\infty$. Em qualquer caso $Q(\boldsymbol{\beta}^{(m)}) \to -\infty$. Logo o conjunto $\{\boldsymbol{\beta} : Q(\boldsymbol{\beta}) \ge Q(\mathbf{0})\}$ é limitado, e é fechado porque Q é contínua; numa região compacta, a função contínua Q atinge o máximo, que é o máximo global, porque fora dela $Q < Q(\mathbf{0})$. A hessiana de Q é $-\tilde{\mathbb{X}}^\top W\tilde{\mathbb{X}} - 2\lambda D$, com $D = \operatorname{diag}(0, 1, \ldots, 1)$. Para $\boldsymbol{v} = (v_0, \boldsymbol{v}_{1:p}) \neq \mathbf{0}$, se $\boldsymbol{v}_{1:p} \neq \mathbf{0}$ o termo $2\lambda\left\|\boldsymbol{v}_{1:p}\right\|^2$ é positivo; se $\boldsymbol{v}_{1:p} = \mathbf{0}$, então $v_0 \neq 0$ e $\boldsymbol{v}^\top\tilde{\mathbb{X}}^\top W\tilde{\mathbb{X}}\boldsymbol{v} = v_0^2 \sum_i \pi_i(1 - \pi_i) > 0$. A hessiana é negativa definida, Q é estritamente côncava, e o maximizador é único, pelo argumento do item (a). Com separação perfeita, a verossimilhança empurra os coeficientes para o infinito, e a penalidade os traz de volta: é por isso que a penalização resolve o problema.

Aula 08 — Métricas para Classificação

Exercício 4 — A curva ROC não vê a escala. Carla é epidemiologista e avalia um modelo que estima, para cada paciente, a probabilidade de uma doença ($Y = 1$). Numa amostra de teste com 4 doentes e 6 saudáveis, independente dos dados usados para ajustar o modelo, ela anota o escore s_i do seu modelo e o escore r_i do modelo de um colega:

paciente	1	2	3	4	5	6	7	8	9	10
y_i	1	1	1	1	0	0	0	0	0	0
s_i	0,90	0,70	0,45	0,25	0,60	0,35	0,15	0,12	0,08	0,05
r_i	0,988	0,845	0,401	0,100	0,692	0,225	0,030	0,018	0,008	0,003

Ela percebe que, em todos os pacientes, $r_i = h(s_i)$, com $h(s) = s^2/(s^2 + (1 - s)^2)$. Cada modelo declara positivo quem tem escore maior ou igual a um corte p_0, e a curva ROC de um escore

é o conjunto dos pontos (taxa de falsos positivos, taxa de verdadeiros positivos) que os cortes produzem nesta amostra, ligados por segmentos.

(a) Liste os pontos da curva ROC do escore s, desenhe a curva e calcule a área sob ela, a AUC. Em que ponto da curva fica o corte $p_0 = 0{,}5$?

(b) Mostre que h é estritamente crescente em $(0, 1)$ e que, para *toda* função h estritamente crescente, o escore $h(s)$ tem a mesma curva ROC que s nesta amostra. Conclua que os dois modelos têm a mesma AUC.

(c) No hospital, deixar passar um doente custa quatro vezes mais que um alarme falso: $\ell_0 = 4$ e $\ell_1 = 1$. O corte que minimiza o custo esperado, quando o escore é a probabilidade verdadeira $\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x})$, é $\ell_1/(\ell_0 + \ell_1)$. Aplique esse corte aos escores s e aos escores r, identifique os pacientes declarados positivos em cada caso e calcule o custo total $\ell_1\,\mathrm{FP} + \ell_0\,\mathrm{FN}$ de cada decisão na amostra. Compare com o custo dos outros cortes possíveis para s.

(d) O que a curva ROC e a AUC dizem sobre os dois modelos, e o que elas não dizem? O que é preciso saber sobre os escores para usar o corte $\ell_1/(\ell_0 + \ell_1)$?

Solução

(a) Os escores são distintos. Em ordem decrescente, as classes aparecem na sequência $1, 1, 0, 1, 0, 1, 0, 0, 0, 0$ (pacientes 1, 2, 5, 3, 6, 4, 7, 8, 9, 10). Baixar o corte de um escore ao seguinte acrescenta um paciente aos declarados positivos: se ele é doente, a taxa de verdadeiros positivos sobe $1/P = 1/4$; se é saudável, a de falsos positivos sobe $1/N = 1/6$. Começando sem ninguém declarado positivo, os pontos são

$$(0,0),\ (0,\tfrac{1}{4}),\ (0,\tfrac{1}{2}),\ (\tfrac{1}{6},\tfrac{1}{2}),\ (\tfrac{1}{6},\tfrac{3}{4}),\ (\tfrac{1}{3},\tfrac{3}{4}),\ (\tfrac{1}{3},1),\ (\tfrac{1}{2},1),\ (\tfrac{2}{3},1),\ (\tfrac{5}{6},1),\ (1,1),$$

e a curva é uma escada: sobe nos doentes e anda para a direita nos saudáveis. A área sob ela é a soma das áreas dos retângulos sob os trechos horizontais, cada um de largura $1/6$:

$$\mathrm{AUC} = \tfrac{1}{6}\Big(\tfrac{1}{2} + \tfrac{3}{4} + 1 + 1 + 1 + 1\Big) = \tfrac{1}{6} \cdot \tfrac{21}{4} = \tfrac{7}{8} = 0{,}875.$$

O corte 0,5 declara positivos os pacientes 1, 2 e 5: dois doentes e uma saudável, o ponto $(\frac{1}{6}, \frac{1}{2})$.

(b) Em $(0, 1)$, $h(s) = 1/\big(1 + ((1-s)/s)^2\big)$. A função $s \mapsto (1-s)/s = 1/s - 1$ é estritamente decrescente e positiva, o seu quadrado também é estritamente decrescente, e $u \mapsto 1/(1+u)$ é estritamente decrescente em $u > 0$; a composta é estritamente crescente.

Seja agora h uma função estritamente crescente qualquer. Para todo corte p_0 do escore s, o conjunto dos declarados positivos é $\{i : s_i \geq p_0\}$, e, como h é estritamente crescente, $s_i \geq p_0 \iff h(s_i) \geq h(p_0)$. Esse conjunto é, portanto, exatamente o que o corte $h(p_0)$ produz para o escore $h(s)$. Reciprocamente, cada corte q do escore $h(s)$ declara positivos os pacientes com $h(s_i) \geq q$, que formam o conjunto $\{i : s_i \geq s_{(q)}\}$, com $s_{(q)}$ o menor s_i tal que $h(s_i) \geq q$, ou nenhum paciente, se não há tal s_i. Os dois escores produzem, assim, a mesma família de conjuntos de declarados positivos, e cada conjunto determina as duas taxas. As curvas ROC têm os mesmos pontos e, ligadas por segmentos, são a mesma curva, com a mesma área: os dois modelos têm AUC 0,875.

(c) O corte é $\ell_1/(\ell_0 + \ell_1) = 1/5 = 0{,}2$. Nos escores s, ficam acima dele os pacientes 1, 2, 3, 4, 5 e 6: os quatro doentes e duas saudáveis, com $\mathrm{FN} = 0$, $\mathrm{FP} = 2$ e custo $1 \cdot 2 + 4 \cdot 0 = 2$. Nos escores r, ficam acima de 0,2 os pacientes 1, 2, 3, 5 e 6, e o paciente 4, doente, com $r_4 = 0{,}100$, fica de fora: $\mathrm{FN} = 1$, $\mathrm{FP} = 2$ e custo $1 \cdot 2 + 4 \cdot 1 = 6$. Os outros cortes de s custam, do mais alto ao mais baixo, 16 (ninguém positivo), 12, 8, 9, 5, 6, 2, 3, 4, 5 e 6

(todos positivos): o corte 0,2 aplicado a s escolhe, nesta amostra, o ponto mais barato da curva, $(\frac{1}{3}, 1)$, e aplicado a r escolhe o ponto $(\frac{1}{3}, \frac{3}{4})$, que custa três vezes mais.

A razão está na escala. Como $\log \frac{h(s)}{1-h(s)} = 2 \log \frac{s}{1-s}$, o escore r dobra o *log-odds* de s, e $r > 0{,}2$ equivale a $s > 1/3$: o mesmo número 0,2, aplicado a escalas diferentes, seleciona pontos diferentes da mesma curva. Em 10 pacientes, o custo observado é uma estimativa ruidosa do custo esperado; o que o exercício mostra é o mecanismo, não o tamanho da diferença.

(d) A curva ROC e a AUC dizem que trocas entre as duas taxas cada escore permite, corte a corte, e isso só depende da ordem em que ele põe os pacientes; nisso os dois modelos são idênticos. Não dizem nada sobre a escala dos escores, porque qualquer transformação estritamente crescente as deixa iguais: uma curva ROC não distingue uma probabilidade bem estimada de outra que exagere a certeza. O corte $\ell_1/(\ell_0 + \ell_1)$, por sua vez, é ótimo para a probabilidade verdadeira $\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x})$; aplicado a um escore, ele só tem esse sentido se o escore estimar bem essa probabilidade. Se Carla tem razões para confiar nas suas probabilidades, o modelo do colega, que dobra o *log-odds*, exagera a certeza, como faz o Bayes ingênuo com covariáveis redundantes, e o corte 0,2 aplicado a r deixa passar doentes. Para escolher o corte, é preciso saber se os escores estão na escala de probabilidades; para escolher entre modelos com a mesma ROC, a curva não basta.

Exercício 5 — Sortear entre dois classificadores. Diego é analista antifraude num banco e tem dois sistemas que já foram avaliados, A e B. Tome a fraude como a classe positiva, $Y = 1$. As taxas de falsos positivos e de verdadeiros positivos são $(\mathrm{FPR}, \mathrm{TPR}) = (0{,}02;\ 0{,}50)$ para A e $(0{,}08;\ 0{,}80)$ para B. O banco aceita mandar para revisão manual no máximo 5% das transações legítimas, e nenhum dos dois sistemas aproveita esse limite: A fica abaixo dele e B o ultrapassa. Diego então propõe sortear: para cada transação, uma moeda com probabilidade λ de dar cara, lançada independentemente de tudo o mais, escolhe se a decisão será a de A (cara) ou a de B (coroa). Seja g_λ esse classificador.

(a) Mostre que $\mathrm{FPR}(g_\lambda) = \lambda\,\mathrm{FPR}(A) + (1-\lambda)\,\mathrm{FPR}(B)$ e que o mesmo vale para a TPR, isto é, que o ponto de g_λ no plano (FPR, TPR) está no segmento que liga os pontos de A e de B. Determine λ para que a taxa de falsos positivos seja exatamente 0,05 e calcule a taxa de verdadeiros positivos obtida. Que classificadores sorteados dão os pontos da diagonal?

(b) Um terceiro sistema, C, tem $(\mathrm{FPR}, \mathrm{TPR}) = (0{,}70;\ 0{,}40)$. Mostre que o classificador que inverte todas as decisões de C tem o ponto $(0{,}30;\ 0{,}60)$ e, em geral, que inverter as decisões leva $(\mathrm{FPR}, \mathrm{TPR})$ a $(1-\mathrm{FPR}, 1-\mathrm{TPR})$. Se um escore tem curva ROC abaixo da diagonal, com área $\mathrm{AUC} < 1/2$, qual é a curva e qual é a área do escore com o sinal trocado?

(c) Com custos ℓ_0 por falso negativo e ℓ_1 por falso positivo, o custo esperado de um classificador g é $R_\ell(g) = \ell_1 \mathbb{P}(g(\boldsymbol{X}) = 1, Y = 0) + \ell_0 \mathbb{P}(g(\boldsymbol{X}) = 0, Y = 1)$. Mostre que $R_\ell(g_\lambda) = \lambda R_\ell(A) + (1-\lambda) R_\ell(B)$ e conclua que, sem a restrição do banco, sortear nunca custa menos que o melhor dos dois sistemas. Para que serve, então, o sorteio?

(d) Mostre que o conjunto dos pontos (FPR, TPR) de todos os classificadores, sorteados ou não, é convexo e contém a diagonal. Use isso para explicar por que a curva ROC estimada de um escore é desenhada ligando os pontos de cortes consecutivos por segmentos de reta.

Solução

(a) Seja Z a moeda, com $\mathbb{P}(Z = 1) = \lambda$, independente de $(\boldsymbol{X}, Y)$. Pela lei da probabilidade

total, condicionando em Z,

$$\begin{aligned}\mathbb{P}(g_\lambda(\boldsymbol{X}) = 1 \mid Y = 0) = \lambda\,\mathbb{P}(g_A(\boldsymbol{X}) = 1 \mid Y = 0,\, Z = 1) \\ + (1-\lambda)\,\mathbb{P}(g_B(\boldsymbol{X}) = 1 \mid Y = 0,\, Z = 0),\end{aligned}$$

em que se usou $\mathbb{P}(Z = 1 \mid Y = 0) = \mathbb{P}(Z = 1) = \lambda$, pela independência. Também pela independência, condicionar em Z não altera a distribuição de $\boldsymbol{X}$ dado Y, e as duas probabilidades condicionais são as taxas de falsos positivos de A e de B. Assim, $\mathrm{FPR}(g_\lambda) = \lambda\,\mathrm{FPR}(A) + (1-\lambda)\,\mathrm{FPR}(B)$, e a mesma conta, condicionando em $Y = 1$, dá a TPR. O ponto de g_λ é a combinação convexa dos pontos de A e de B com pesos λ e $1-\lambda$, e percorre o segmento entre eles quando λ vai de 0 a 1.
Para a taxa de falsos positivos valer 0,05,

$$0{,}02\,\lambda + 0{,}08\,(1-\lambda) = 0{,}05 \iff 0{,}06\,\lambda = 0{,}03 \iff \lambda = \tfrac{1}{2},$$

e a taxa de verdadeiros positivos é $\frac{1}{2}\cdot 0{,}50 + \frac{1}{2}\cdot 0{,}80 = 0{,}65$: Diego usa o limite do banco inteiro e detecta 65% das fraudes, contra 50% de A. A diagonal vem do sorteio entre os dois classificadores triviais, $g \equiv 0$, no ponto $(0,0)$, e $g \equiv 1$, no ponto $(1,1)$: sortear $g = 1$ com probabilidade q dá o ponto (q,q).

(b) Se $g' = 1 - g$, então $g'(\boldsymbol{X}) = 1$ exatamente quando $g(\boldsymbol{X}) = 0$, e

$$\mathrm{TPR}(g') = \mathbb{P}(g(\boldsymbol{X}) = 0 \mid Y = 1) = 1 - \mathrm{TPR}(g), \qquad \mathrm{FPR}(g') = 1 - \mathrm{FPR}(g).$$

Para C, o ponto invertido é $(1-0{,}70;\ 1-0{,}40) = (0{,}30;\ 0{,}60)$, acima da diagonal: um sistema que erra sistematicamente carrega informação, desde que se faça o contrário do que ele diz. A aplicação $(a,b) \mapsto (1-a, 1-b)$ é a simetria em relação ao ponto $(\frac{1}{2},\frac{1}{2})$. Trocar o sinal do escore troca "escore acima do corte" por "escore abaixo do corte", o que inverte as decisões em cada corte; a curva do escore com o sinal trocado é, portanto, a simétrica da original em relação a $(\frac{1}{2},\frac{1}{2})$. Essa simetria leva a região do quadrado unitário abaixo de uma curva na região acima da curva simétrica e preserva áreas. A área sob a curva nova é, então, a área acima da curva antiga, $1 - \mathrm{AUC} > 1/2$.

(c) Condicionando de novo na moeda, e usando a independência,

$$\mathbb{P}(g_\lambda(\boldsymbol{X}) = 1,\, Y = 0) = \lambda\,\mathbb{P}(g_A(\boldsymbol{X}) = 1,\, Y = 0) + (1-\lambda)\,\mathbb{P}(g_B(\boldsymbol{X}) = 1,\, Y = 0),$$

e o mesmo para $\mathbb{P}(g_\lambda(\boldsymbol{X}) = 0,\, Y = 1)$. Multiplicando a primeira igualdade por ℓ_1, a segunda por ℓ_0 e somando, $R_\ell(g_\lambda) = \lambda R_\ell(A) + (1-\lambda) R_\ell(B)$. Uma média ponderada de dois números nunca é menor que o menor deles, e o sorteio nunca custa menos que o melhor dos dois sistemas: sem restrição, basta escolher um deles. O sorteio serve para atingir um ponto que nenhum dos dois atinge, como a taxa de falsos positivos de exatamente 0,05 permitida pelo banco: respeitando esse limite, $g_{1/2}$ detecta 65% das fraudes, e A, só 50%.

(d) Dados dois pontos atingíveis, de classificadores g e g', sorteados ou não, o argumento do item (a) vale sem alteração para o sorteio entre g e g', e todos os pontos do segmento entre eles são atingíveis: o conjunto é convexo. Ele contém $(0,0)$ e $(1,1)$, dos classificadores triviais, e portanto o segmento entre eles, que é a diagonal. Para um escore, cada corte dá um ponto da curva; entre os pontos de dois cortes consecutivos, o sorteio entre os dois classificadores de corte atinge cada ponto do segmento que os liga. A poligonal descreve, portanto, desempenhos de fato disponíveis, e não apenas um traço para guiar o olho.

Exercício 6 — Um bom exame que o classificador de Bayes ignora. Helena é médica e coordena o rastreamento de uma doença que atinge 1% da população: $\mathbb{P}(Y = 1) = 0{,}01$, com

$Y = 1$ para doente. O exame disponível tem resultado $X \in \{0, 1\}$ e, seguindo o resultado (isto é, declarando doente quem tem $X = 1$), detecta 90% dos doentes e dá alarme falso para 10% dos saudáveis: $\mathbb{P}(X = 1 \mid Y = 1) = 0{,}9$ e $\mathbb{P}(X = 1 \mid Y = 0) = 0{,}1$. Seja $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$.

(a) Calcule $\eta(1)$ e $\eta(0)$.

(b) Determine o classificador de Bayes, o que minimiza a probabilidade de erro. Compare a probabilidade de erro dele com a do classificador que segue o exame. Um colega conclui que o exame não serve para nada. O que há de errado nessa conclusão?

(c) Sejam ℓ_0 o custo de deixar passar um doente e ℓ_1 o de um alarme falso, e $r = \ell_0/\ell_1$. Lembre que o classificador de menor custo esperado declara doente quando $\eta(x) > \ell_1/(\ell_0 + \ell_1)$. Mostre que seguir o exame é a decisão de menor custo esperado se e somente se $11 < r \leq 891$, e diga qual é a decisão ótima fora dessa faixa. Para $\ell_0 = 20$ e $\ell_1 = 1$, calcule o custo esperado de declarar todos saudáveis, de seguir o exame e de declarar todos doentes, numa população de 10 000 pessoas.

(d) Os cortes aplicados a $\eta(X)$ produzem só três classificadores. Encontre os seus pontos (FPR, TPR), desenhe a curva ROC que os liga por segmentos e calcule a AUC. Como uma AUC alta e um classificador de Bayes que ignora o exame podem conviver?

Solução

(a) Pelo Teorema de Bayes,

$$\eta(1) = \frac{0{,}9 \cdot 0{,}01}{0{,}9 \cdot 0{,}01 + 0{,}1 \cdot 0{,}99} = \frac{0{,}009}{0{,}108} = \frac{1}{12} \approx 0{,}083,$$

$$\eta(0) = \frac{0{,}1 \cdot 0{,}01}{0{,}1 \cdot 0{,}01 + 0{,}9 \cdot 0{,}99} = \frac{0{,}001}{0{,}892} = \frac{1}{892} \approx 0{,}0011.$$

Um resultado positivo multiplica a probabilidade de doença por cerca de 8, de 1% para 8,3%, e um negativo a divide por cerca de 9; ainda assim, mesmo com o exame positivo, a doença continua improvável, porque ela é rara: entre os positivos, os 9 doentes em cada mil pessoas são superados pelos 99 saudáveis com alarme falso.

(b) O classificador de Bayes declara doente quando $\eta(x) > 1/2$. Como $\eta(0)$ e $\eta(1)$ estão abaixo de $1/2$, ele é $g \equiv 0$: declara todos saudáveis, qualquer que seja o resultado do exame. A probabilidade de erro dele é $\mathbb{P}(Y = 1) = 0{,}01$. Seguir o exame erra nos doentes com $X = 0$ e nos saudáveis com $X = 1$:

$$\mathbb{P}(X \neq Y) = 0{,}01 \cdot 0{,}1 + 0{,}99 \cdot 0{,}1 = 0{,}001 + 0{,}099 = 0{,}1,$$

dez vezes mais. A conclusão do colega confunde a probabilidade de erro com a utilidade. O classificador de Bayes minimiza a probabilidade de erro, que dá o mesmo peso a um doente não detectado e a um alarme falso; com uma doença rara, a maneira mais barata de errar pouco é nunca acusar ninguém, ao preço de não detectar doente nenhum. O exame detecta 90% dos doentes: o que falta saber é quanto vale cada um deles comparado a um alarme falso.

(c) O corte é $\ell_1/(\ell_0 + \ell_1) = 1/(1 + r)$, e a decisão ótima é tomada em cada valor de x separadamente. Seguir o exame significa declarar doente em $x = 1$ e saudável em $x = 0$, o que é ótimo quando

$$\eta(1) > \frac{1}{1+r} \iff 1 + r > 12 \iff r > 11 \qquad \text{e} \qquad \eta(0) \leq \frac{1}{1+r} \iff r \leq 891.$$

Com $r < 11$, a decisão ótima é declarar todos saudáveis; com $r = 11$, as duas decisões em $x = 1$ custam o mesmo; com $r > 891$, é declarar todos doentes, porque, quando um doente

não detectado custa mais que 891 alarmes falsos, até a chance de 1/892 que resta depois de um exame negativo justifica declarar doente. Seguir o exame é ótimo exatamente quando deixar passar um doente custa entre 11 e 891 alarmes falsos.
Com $\ell_0 = 20$ e $\ell_1 = 1$, $r = 20$ está na faixa, e seguir o exame é o ótimo. Numa população de 10 000 pessoas há, em média, $P = 100$ doentes e $N = 9\,900$ saudáveis, e as contagens esperadas saem das taxas: $\mathrm{FN} = (1 - \mathrm{TPR})\,P$ e $\mathrm{FP} = \mathrm{FPR} \cdot N$. Declarar todos saudáveis dá FN $= 100$ e custo $20 \cdot 100 = 2\,000$. Seguir o exame dá FN $= 0{,}1 \cdot 100 = 10$ e FP $= 0{,}1 \cdot 9\,900 = 990$, com custo $20 \cdot 10 + 990 = 1\,190$. Declarar todos doentes dá FP $= 9\,900$ e custo 9 900. O exame economiza 810 unidades de custo a cada dez mil pessoas em relação ao classificador de Bayes, embora erre dez vezes mais que ele.

(d) O escore $\eta(X)$ assume só os valores 1/892 e 1/12, e, como no item (c), o classificador de corte p_0 declara doente quem tem $\eta(X) > p_0$. Um corte $p_0 \geq 1/12$ não declara ninguém doente, o ponto $(0, 0)$; um corte $1/892 \leq p_0 < 1/12$ declara doentes os que têm $X = 1$, o ponto $(0{,}1;\ 0{,}9)$; um corte $p_0 < 1/892$ declara todos doentes, o ponto $(1, 1)$. A curva liga $(0, 0)$ a $(0{,}1;\ 0{,}9)$ e este a $(1, 1)$, e a área sob ela é a de um triângulo e um trapézio:

$$\mathrm{AUC} = \tfrac{1}{2} \cdot 0{,}1 \cdot 0{,}9 + \tfrac{1}{2}\,(0{,}9 + 1) \cdot 0{,}9 = 0{,}045 + 0{,}855 = 0{,}9.$$

As duas coisas convivem porque medem coisas diferentes. A AUC avalia o exame ao longo de todos os cortes, e o exame separa bem doentes de saudáveis. O classificador de Bayes usa um único corte, 1/2, que é o corte certo quando os dois erros custam o mesmo; com uma doença rara, esse corte fica acima de qualquer probabilidade que o exame produza. O exame é bom; o que decide se vale a pena usá-lo é a razão de custos, pelo item (c).

Aula 09 — Máquinas de Vetores de Suporte

Exercício 7 — Só os vetores de suporte importam. Tiago trabalha no controle de qualidade de uma fábrica e classifica peças em boas ($y = +1$) e defeituosas ($y = -1$) a partir de p medidas. As suas n observações de treino $(\boldsymbol{x}_i, y_i)$ são linearmente separáveis, e cada classe tem pelo menos duas observações. O classificador de margem máxima é dado pela solução do problema

$$\max_{\beta_0,\,\boldsymbol{\beta},\,M} M \quad \text{sujeito a} \quad \sum_{j=1}^{p} \beta_j^2 = 1 \quad \text{e} \quad y_i\,(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) \geq M, \quad i = 1, \ldots, n.$$

Escreva $f(\boldsymbol{x}) = \beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}$. Os vetores de suporte são as observações com $y_i f(\boldsymbol{x}_i) = M$, e $\mathcal{S}$ é o conjunto dos seus índices. Admita que, para observações separáveis com as duas classes presentes, o problema tem solução, e seja $M^* > 0$ o valor ótimo. As notas afirmam, sem demonstrar, que essa solução depende apenas dos vetores de suporte; Tiago quer a demonstração e quer saber o que ela lhe dá.

(a) Mostre que a solução é única. (Se houvesse duas soluções com vetores $\boldsymbol{\beta}$ diferentes, compare-as com o ponto médio entre elas. Se tivessem o mesmo $\boldsymbol{\beta}$, olhe, como funções de β_0, o menor valor de $y_i f(\boldsymbol{x}_i)$ em cada classe.)

(b) Seja $i_0 \notin \mathcal{S}$. Mostre que o classificador de margem máxima das $n - 1$ observações sem a observação i_0 é o mesmo das n observações. (Se o valor ótimo sem i_0 fosse maior que M^*, combine a solução nova com a antiga, com peso pequeno na nova.) Mostre também que deslocar $\boldsymbol{x}_{i_0}$ para qualquer ponto $\boldsymbol{x}'$ com $y_{i_0} f(\boldsymbol{x}') > M^*$, em que f é a função da solução, não muda o classificador.

(c) A estimativa do risco por validação cruzada com uma observação deixada de fora (LOOCV) é a proporção das observações i que o classificador ajustado sem i classifica errado. Mostre que, para o classificador de margem máxima, ela é no máximo $|\mathcal{S}|/n$.

(d) Tiago ajusta o classificador a 60 peças e encontra 3 vetores de suporte. O que ele pode afirmar sobre a estimativa LOOCV sem fazer mais nenhum ajuste? Ele refaz os 60 ajustes e não encontra erro nenhum. Isso contradiz o item (c)? O que a cota não garante?

Solução

(a) Sejam $(\beta_0, \boldsymbol{\beta}, M^*)$ e $(\beta_0', \boldsymbol{\beta}', M^*)$ duas soluções, e $(\bar{b}, \bar{\boldsymbol{w}})$ o ponto médio de $(\beta_0, \boldsymbol{\beta})$ e $(\beta_0', \boldsymbol{\beta}')$. Para cada i,

$$y_i(\bar{b} + \bar{\boldsymbol{w}}^\top \boldsymbol{x}_i) = \tfrac{1}{2}\left[y_i(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) + y_i(\beta_0' + \boldsymbol{\beta}'^\top \boldsymbol{x}_i)\right] \;\geq\; M^*.$$

Suponha $\boldsymbol{\beta} \neq \boldsymbol{\beta}'$. Como $\|\boldsymbol{\beta}\| = \|\boldsymbol{\beta}'\| = 1$, a desigualdade de Cauchy–Schwarz dá $\boldsymbol{\beta}^\top \boldsymbol{\beta}' < 1$, com desigualdade estrita porque a igualdade exigiria $\boldsymbol{\beta}' = \boldsymbol{\beta}$, e $\|\bar{\boldsymbol{w}}\|^2 = \frac{1}{4}(2 + 2\,\boldsymbol{\beta}^\top \boldsymbol{\beta}') < 1$. Também $\bar{\boldsymbol{w}} \neq \mathbf{0}$: do contrário, $y_i \bar{b} \geq M^* > 0$ para todo i, o que exigiria $\bar{b} > 0$ nas observações da classe $+1$ e $\bar{b} < 0$ nas da classe -1. Dividindo $(\bar{b}, \bar{\boldsymbol{w}})$ por $\|\bar{\boldsymbol{w}}\| \in (0, 1)$, obtém-se um vetor de norma 1 com $y_i(\cdot) \geq M^*/\|\bar{\boldsymbol{w}}\| > M^*$ para todo i, o que contradiz a otimalidade de M^*. Logo $\boldsymbol{\beta} = \boldsymbol{\beta}'$.
Com $\boldsymbol{\beta}$ fixado, sejam $m_+(b) = \min_{i:\, y_i = +1}(b + \boldsymbol{\beta}^\top \boldsymbol{x}_i)$ e $m_-(b) = \min_{i:\, y_i = -1}(-b - \boldsymbol{\beta}^\top \boldsymbol{x}_i)$, de modo que a margem do hiperplano $(b, \boldsymbol{\beta})$ é $\min\{m_+(b), m_-(b)\}$. A função m_+ é estritamente crescente, e m_-, estritamente decrescente. Suponha $\beta_0 < \beta_0'$. Então $m_-(\beta_0) > m_-(\beta_0') \geq M^*$, e, como o mínimo em β_0 vale M^*, é $m_+(\beta_0) = M^*$; do mesmo modo, $m_+(\beta_0') > m_+(\beta_0) = M^*$ e $m_-(\beta_0') = M^*$. No ponto médio $b = (\beta_0 + \beta_0')/2$, $m_+(b) > m_+(\beta_0) = M^*$ e $m_-(b) > m_-(\beta_0') = M^*$: o hiperplano $(b, \boldsymbol{\beta})$ teria margem maior que M^*, um absurdo. Logo $\beta_0 = \beta_0'$, e a solução é única.
(b) Seja $(\beta_0^*, \boldsymbol{\beta}^*, M^*)$ a solução com as n observações e f^* a função correspondente; como $i_0 \notin \mathcal{S}$, vale $\delta = y_{i_0} f^*(\boldsymbol{x}_{i_0}) - M^* > 0$. Sem i_0, as observações continuam separáveis e com as duas classes, porque cada classe tinha pelo menos duas; o problema tem solução, com valor ótimo M'. O ponto $(\beta_0^*, \boldsymbol{\beta}^*, M^*)$ satisfaz todas as restrições sem i_0, e portanto $M' \geq M^*$.
Suponha $M' > M^*$, atingido por $(\beta_0', \boldsymbol{\beta}')$, com função f'. Para $t \in (0, 1]$, seja $(b_t, \boldsymbol{w}_t) = (1 - t)(\beta_0^*, \boldsymbol{\beta}^*) + t(\beta_0', \boldsymbol{\beta}')$. Para $i \neq i_0$,

$$y_i(b_t + \boldsymbol{w}_t^\top \boldsymbol{x}_i) = (1 - t)\, y_i f^*(\boldsymbol{x}_i) + t\, y_i f'(\boldsymbol{x}_i) \;\geq\; (1 - t)M^* + tM' \;>\; M^*,$$

e, para i_0, com $c = |y_{i_0} f'(\boldsymbol{x}_{i_0}) - y_{i_0} f^*(\boldsymbol{x}_{i_0})|$,

$$y_{i_0}(b_t + \boldsymbol{w}_t^\top \boldsymbol{x}_{i_0}) \;\geq\; M^* + \delta - t\,c \;>\; M^* \qquad \text{para } 0 < t < \delta/c$$

(para todo t, se $c = 0$). Pela desigualdade triangular, $\|\boldsymbol{w}_t\| \leq (1 - t)\,\|\boldsymbol{\beta}^*\| + t\,\|\boldsymbol{\beta}'\| = 1$, e $\boldsymbol{w}_t \neq \mathbf{0}$ pelo mesmo argumento do item (a). Fixe um tal t e divida $(b_t, \boldsymbol{w}_t)$ por $\|\boldsymbol{w}_t\| \leq 1$: os números $y_i(\cdot)$, todos maiores que $M^* > 0$, não diminuem, e o resultado é um hiperplano de norma 1 com $y_i f(\boldsymbol{x}_i) > M^*$ para *todas* as n observações. Isso contradiz a otimalidade de M^*. Logo $M' = M^*$, e $(\beta_0^*, \boldsymbol{\beta}^*, M^*)$, que é viável sem i_0 e atinge esse valor, é uma solução sem i_0; pelo item (a), aplicado às $n - 1$ observações, é a única.
Para o deslocamento, considere as $n - 1$ observações sem i_0 mais a observação $(\boldsymbol{x}', y_{i_0})$. Todo ponto viável desse problema é viável sem i_0, e por isso o valor ótimo é no máximo M^*. A solução $(\beta_0^*, \boldsymbol{\beta}^*, M^*)$ satisfaz as restrições sem i_0 e a nova, $y_{i_0} f^*(\boldsymbol{x}') > M^*$: é viável e atinge M^*, logo é ótima e, pelo item (a), a única. A solução não vê as observações que estão do lado certo e fora da faixa: elas podem sair ou mudar de lugar, desde que continuem fora dela.

(c) Para cada i, as observações sem i são separáveis e têm as duas classes, e o classificador de margem máxima delas, g_{-i}, está bem definido. Se $i \notin \mathcal{S}$, pelo item (b) g_{-i} é o classificador g das n observações, que classifica $\boldsymbol{x}_i$ corretamente, porque $y_i f^*(\boldsymbol{x}_i) > M^* > 0$. Assim, $g_{-i}(\boldsymbol{x}_i) \neq y_i$ só pode acontecer para $i \in \mathcal{S}$, e

$$\frac{1}{n}\sum_{i=1}^{n} \mathbf{1}\{g_{-i}(\boldsymbol{x}_i) \neq y_i\} = \frac{1}{n}\sum_{i\in\mathcal{S}} \mathbf{1}\{g_{-i}(\boldsymbol{x}_i) \neq y_i\} \;\leq\; \frac{|\mathcal{S}|}{n}.$$

(d) Com um único ajuste, Tiago sabe que a estimativa LOOCV é no máximo $3/60 = 0{,}05$: das 60 retiradas, 57 deixam o classificador intacto e não erram, e só as 3 de vetores de suporte podem errar. Os 60 ajustes, que mostram erro zero, não contradizem nada: a cota é uma desigualdade, e os vetores de suporte deixados de fora podem continuar do lado certo do hiperplano recalculado. Neste conjunto de dados, nenhum deles muda de lado. A cota limita uma estimativa do risco, não o risco. Ela não diz que peças futuras serão classificadas sem erro: o treino ser separável não significa que a população seja, e uma peça nova perto da fronteira pode deslocar muito o hiperplano, que é a sensibilidade a observações novas apontada nas notas. O que ela mostra é que a estimativa LOOCV deste classificador custa um ajuste em vez de n, desde que se aceite uma cota no lugar do número.

Exercício 8 — O *kernel* radial em qualquer dimensão. Júlia estuda matemática aplicada e lê nas notas que o *kernel* radial $k(\boldsymbol{x}, \boldsymbol{x}') = \exp(-\gamma\,\|\boldsymbol{x} - \boldsymbol{x}'\|^2)$, com $\gamma > 0$, é um *kernel* em $\mathbb{R}^p$; o exemplo das notas, porém, só exibe a função φ para $p = 1$. Ela decide provar o caso geral. Lembre que $k : \mathbb{R}^p \times \mathbb{R}^p \to \mathbb{R}$ é um *kernel* se existem um espaço de Hilbert $\mathcal{H}$ e uma função $\varphi : \mathbb{R}^p \to \mathcal{H}$ com $k(\boldsymbol{x}, \boldsymbol{x}') = \langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle_{\mathcal{H}}$ para todos $\boldsymbol{x}, \boldsymbol{x}'$, e que, pelo teorema visto em aula, isso acontece se e somente se k é simétrica e, para todo $n \geq 1$ e quaisquer $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n \in \mathbb{R}^p$, a matriz $\big[k(\boldsymbol{x}_i, \boldsymbol{x}_j)\big]_{i,j=1}^{n}$ é positiva semidefinida. Use à vontade que o produto interno $\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$ e as funções constantes iguais a $c \geq 0$ são *kernels*, e que a soma de dois *kernels* e o produto de um *kernel* por uma constante $c \geq 0$ também são.

(a) Mostre que, se k_1 e k_2 são *kernels*, o produto $k(\boldsymbol{x}, \boldsymbol{x}') = k_1(\boldsymbol{x}, \boldsymbol{x}')\, k_2(\boldsymbol{x}, \boldsymbol{x}')$ também é. (Escreva uma das duas matrizes pela decomposição espectral.)

(b) Mostre que, se k é um *kernel* e $h : \mathbb{R}^p \to \mathbb{R}$ é uma função qualquer, então $h(\boldsymbol{x})\, h(\boldsymbol{x}')\, k(\boldsymbol{x}, \boldsymbol{x}')$ é um *kernel*. Mostre também que $e^{k(\boldsymbol{x}, \boldsymbol{x}')}$ é um *kernel*, usando a série da exponencial e o fato de que um limite de matrizes positivas semidefinidas é positivo semidefinido.

(c) Conclua que o *kernel* radial é um *kernel* em $\mathbb{R}^p$, para todo p e todo $\gamma > 0$. (Escreva $\|\boldsymbol{x} - \boldsymbol{x}'\|^2$ em termos de $\|\boldsymbol{x}\|^2$, $\|\boldsymbol{x}'\|^2$ e $\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$.)

(d) Mostre que, para todo *kernel*, $\|\varphi(\boldsymbol{x}) - \varphi(\boldsymbol{x}')\|_{\mathcal{H}}^2 = k(\boldsymbol{x}, \boldsymbol{x}) - 2\,k(\boldsymbol{x}, \boldsymbol{x}') + k(\boldsymbol{x}', \boldsymbol{x}')$, e calcule essa distância para o *kernel* radial. Conclua que φ leva $\mathbb{R}^p$ na esfera unitária de $\mathcal{H}$ e que pontos distintos ficam, em $\mathcal{H}$, a distância menor que $\sqrt{2}$. Para dois pontos à distância 1 em $\mathbb{R}^p$, calcule a distância em $\mathcal{H}$ com $\gamma = 0{,}5$ e com $\gamma = 50$, e interprete o resultado em termos da flexibilidade da SVM.

Solução

(a) Sejam $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n \in \mathbb{R}^p$, $A = \big[k_1(\boldsymbol{x}_i, \boldsymbol{x}_j)\big]$ e $B = \big[k_2(\boldsymbol{x}_i, \boldsymbol{x}_j)\big]$, simétricas e positivas semidefinidas pelo teorema. A matriz de k nesses pontos é o produto entrada a entrada, $(A \circ B)_{ij} = A_{ij} B_{ij}$, que é simétrica. Pelo teorema espectral, $B = \sum_{m=1}^{n} \lambda_m \boldsymbol{v}_m \boldsymbol{v}_m^{\top}$, com autovalores $\lambda_m \geq 0$, porque B é positiva semidefinida, e autovetores ortonormais $\boldsymbol{v}_m \in \mathbb{R}^n$;

em coordenadas, $B_{ij} = \sum_m \lambda_m v_{mi} v_{mj}$. Para $\boldsymbol{a} \in \mathbb{R}^n$,

$$\begin{aligned}\boldsymbol{a}^\top (A \circ B)\, \boldsymbol{a} &= \sum_{i,j} a_i a_j A_{ij} \sum_m \lambda_m v_{mi} v_{mj} = \sum_m \lambda_m \sum_{i,j} (a_i v_{mi})\, A_{ij}\, (a_j v_{mj}) \\ &= \sum_m \lambda_m\, \boldsymbol{u}_m^\top A\, \boldsymbol{u}_m \;\geq\; 0,\end{aligned}$$

em que $\boldsymbol{u}_m = (a_1 v_{m1}, \ldots, a_n v_{mn})$, e cada parcela é não negativa porque $\lambda_m \geq 0$ e A é positiva semidefinida. Como isso vale para todo n e quaisquer pontos, o teorema dá que $k_1 k_2$ é um *kernel*.

(b) A função $h(\boldsymbol{x}) h(\boldsymbol{x}') k(\boldsymbol{x}, \boldsymbol{x}')$ é simétrica, e a sua matriz nos pontos $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n$ é DKD, com $K = [k(\boldsymbol{x}_i, \boldsymbol{x}_j)]$ e $D = \operatorname{diag}\big(h(\boldsymbol{x}_1), \ldots, h(\boldsymbol{x}_n)\big)$. Para $\boldsymbol{a} \in \mathbb{R}^n$, $\boldsymbol{a}^\top DKD\, \boldsymbol{a} = (D\boldsymbol{a})^\top K (D\boldsymbol{a}) \geq 0$. (Pela definição, é o mesmo que tomar a função $h\varphi$ no lugar de φ.)
Para a exponencial, $e^{k(\boldsymbol{x}, \boldsymbol{x}')} = \sum_{m \geq 0} k(\boldsymbol{x}, \boldsymbol{x}')^m / m!$. A potência k^0 é a constante 1, que é um *kernel*, e, se k^m é um *kernel*, $k^{m+1} = k^m \cdot k$ também é, pelo item (a); por indução, todas as potências são *kernels*. As somas parciais $S_M = \sum_{m=0}^{M} k^m / m!$ são, então, *kernels*, como somas de *kernels* multiplicados por constantes positivas. Fixados os pontos e $\boldsymbol{a} \in \mathbb{R}^n$, cada número $\boldsymbol{a}^\top [S_M(\boldsymbol{x}_i, \boldsymbol{x}_j)]\, \boldsymbol{a}$ é não negativo, e, quando $M \to \infty$, converge para $\boldsymbol{a}^\top [e^{k(\boldsymbol{x}_i, \boldsymbol{x}_j)}]\, \boldsymbol{a}$, porque é uma soma finita de termos que convergem. Um limite de números não negativos é não negativo. A matriz de e^k é, portanto, positiva semidefinida, e e^k, que é simétrica, é um *kernel*.

(c) Como $\|\boldsymbol{x} - \boldsymbol{x}'\|^2 = \|\boldsymbol{x}\|^2 - 2\,\langle \boldsymbol{x}, \boldsymbol{x}' \rangle + \|\boldsymbol{x}'\|^2$,

$$e^{-\gamma \|\boldsymbol{x} - \boldsymbol{x}'\|^2} = e^{-\gamma \|\boldsymbol{x}\|^2}\, e^{-\gamma \|\boldsymbol{x}'\|^2}\, e^{2\gamma \langle \boldsymbol{x}, \boldsymbol{x}' \rangle}.$$

O produto interno é um *kernel*, e $2\gamma\, \langle \boldsymbol{x}, \boldsymbol{x}' \rangle$ também, porque $2\gamma > 0$. Pelo item (b), $e^{2\gamma \langle \boldsymbol{x}, \boldsymbol{x}' \rangle}$ é um *kernel*, e, ainda pelo item (b), com $h(\boldsymbol{x}) = e^{-\gamma \|\boldsymbol{x}\|^2}$, o produto acima é um *kernel*. O argumento vale para todo p e todo $\gamma > 0$, e não precisa exibir φ; com $p = 1$, expandir $e^{2\gamma x x'}$ em série reproduz a função φ do exemplo das notas.

(d) Pela bilinearidade e pela simetria do produto interno de $\mathcal{H}$,

$$\begin{aligned}\big\|\varphi(\boldsymbol{x}) - \varphi(\boldsymbol{x}')\big\|^2 &= \langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}) \rangle - 2\,\langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle + \langle \varphi(\boldsymbol{x}'), \varphi(\boldsymbol{x}') \rangle \\ &= k(\boldsymbol{x}, \boldsymbol{x}) - 2\, k(\boldsymbol{x}, \boldsymbol{x}') + k(\boldsymbol{x}', \boldsymbol{x}').\end{aligned}$$

No *kernel* radial, $k(\boldsymbol{x}, \boldsymbol{x}) = e^0 = 1$, de modo que $\|\varphi(\boldsymbol{x})\| = 1$ para todo $\boldsymbol{x}$, e

$$\big\|\varphi(\boldsymbol{x}) - \varphi(\boldsymbol{x}')\big\|^2 = 2\big(1 - e^{-\gamma \|\boldsymbol{x} - \boldsymbol{x}'\|^2}\big).$$

Essa quantidade é nula se e somente se $\boldsymbol{x} = \boldsymbol{x}'$, cresce com $\|\boldsymbol{x} - \boldsymbol{x}'\|$ e é sempre menor que 2: os pontos vão para a esfera unitária de $\mathcal{H}$, a distâncias menores que $\sqrt{2}$, isto é, com produto interno $k(\boldsymbol{x}, \boldsymbol{x}') > 0$ e ângulo menor que 90°. Para $\|\boldsymbol{x} - \boldsymbol{x}'\| = 1$, a distância em $\mathcal{H}$ é $\sqrt{2(1 - e^{-0{,}5})} \approx 0{,}887$ com $\gamma = 0{,}5$ e $\sqrt{2(1 - e^{-50})} \approx 1{,}4142$ com $\gamma = 50$, que é $\sqrt{2}$ até a quarta casa.
Com $\gamma = 50$, dois pontos à distância 1 já são praticamente ortogonais em $\mathcal{H}$: cada observação de treino fica, em $\mathcal{H}$, tão longe das outras quanto o *kernel* permite, e na função de decisão $f(\boldsymbol{x}) = \beta_0 + \sum_{i \in \mathcal{S}} \alpha_i k(\boldsymbol{x}, \boldsymbol{x}_i)$ cada parcela só pesa muito perto do seu $\boldsymbol{x}_i$. A fronteira pode, assim, contornar observações isoladas, e o ajuste fica flexível, com risco de superajuste. Com γ pequeno, pontos próximos em $\mathbb{R}^p$ continuam próximos em $\mathcal{H}$, cada parcela pesa numa região grande, e a fronteira é suave.

Exercício 9 — O ou exclusivo. Mariana estuda engenharia e quer que um classificador linear

preveja quando uma lâmpada acende. A lâmpada tem duas chaves, $x_1, x_2 \in \{0,1\}$, e acende ($y = +1$) quando exatamente uma delas está ligada; com as duas desligadas ou as duas ligadas, fica apagada ($y = -1$). As quatro observações são $(0,0)$ e $(1,1)$, na classe -1, e $(1,0)$ e $(0,1)$, na classe $+1$. Lembre que observações $(\boldsymbol{z}_i, y_i)$ de $\mathbb{R}^q$ são linearmente separáveis se existe $(\beta_0, \boldsymbol{\beta})$, com $\boldsymbol{\beta} \neq \mathbf{0}$, tal que $y_i(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{z}_i) > 0$ para todo i, e que, nesse caso, o classificador de margem máxima é dado pela solução de

$$\max_{\beta_0,\, \boldsymbol{\beta},\, M} \; M \quad \text{sujeito a} \quad \|\boldsymbol{\beta}\| = 1 \quad \text{e} \quad y_i\,(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{z}_i) \geq M \;\; \text{para todo } i.$$

(a) Suponha que algum ponto $\boldsymbol{z} \in \mathbb{R}^q$ seja combinação convexa de observações da classe $+1$ e também combinação convexa de observações da classe -1. Mostre que as observações não são linearmente separáveis. Por que isso vale, em particular, quando uma observação de uma classe está no interior de um triângulo formado por observações da outra?

(b) Mostre que as quatro observações de Mariana não são linearmente separáveis.

(c) Mariana segue a primeira ideia das notas para obter fronteiras não lineares: acrescenta os quadrados e trabalha com as covariáveis (x_1, x_2, x_1^2, x_2^2). Mostre que as observações continuam não separáveis nesse espaço ampliado.

(d) Ela troca os quadrados pelo produto e usa as três covariáveis $\boldsymbol{z} = (x_1,\, x_2,\, x_1x_2)$. Mostre que $f(\boldsymbol{z}) = 2z_1 + 2z_2 - 4z_3 - 1$ satisfaz $y_i f(\boldsymbol{z}_i) = 1$ nas quatro observações. Mostre que o classificador de margem máxima nesse espaço é o hiperplano $f(\boldsymbol{z}) = 0$, com $M = 1/\sqrt{24} \approx 0{,}204$, e que as quatro observações são vetores de suporte. (Para a cota superior, multiplique as restrições das observações $(0,0)$, $(1,1)$, $(1,0)$ e $(0,1)$ pelos pesos 8, 4, 6 e 6, some e use a desigualdade de Cauchy–Schwarz.) Que fronteira esse hiperplano define no plano (x_1, x_2)?

Solução

(a) Escreva $\boldsymbol{z} = \sum_j \lambda_j \boldsymbol{z}_j^+ = \sum_k \mu_k \boldsymbol{z}_k^-$, com $\boldsymbol{z}_j^+$ observações da classe $+1$, $\boldsymbol{z}_k^-$ observações da classe -1, pesos $\lambda_j, \mu_k \geq 0$ e $\sum_j \lambda_j = \sum_k \mu_k = 1$. Suponha, por absurdo, que $f(\boldsymbol{z}) = \beta_0 + \boldsymbol{\beta}^\top \boldsymbol{z}$ separe as classes: $f(\boldsymbol{z}_j^+) > 0$ para todo j e $f(\boldsymbol{z}_k^-) < 0$ para todo k. Como os pesos somam 1,

$$f\Big(\sum_j \lambda_j \boldsymbol{z}_j^+\Big) = \sum_j \lambda_j \beta_0 + \sum_j \lambda_j \boldsymbol{\beta}^\top \boldsymbol{z}_j^+ = \sum_j \lambda_j f(\boldsymbol{z}_j^+),$$

e uma combinação convexa de números positivos é positiva: $f(\boldsymbol{z}) > 0$. Pela mesma conta com os μ_k, $f(\boldsymbol{z}) < 0$, o que é absurdo. Em termos geométricos, cada lado de um hiperplano é convexo, e um ponto que é combinação convexa das duas classes teria de estar dos dois lados ao mesmo tempo. Se uma observação $\boldsymbol{z}^+$ está no interior de um triângulo de observações da classe -1, ela é combinação convexa dos três vértices, e também, trivialmente, de si mesma, com peso 1: a hipótese vale com $\boldsymbol{z} = \boldsymbol{z}^+$.

(b) O centro do quadrado é combinação convexa das duas classes:

$$(\tfrac{1}{2}, \tfrac{1}{2}) = \tfrac{1}{2}(1,0) + \tfrac{1}{2}(0,1) = \tfrac{1}{2}(0,0) + \tfrac{1}{2}(1,1).$$

Pelo item (a), nenhuma reta separa as observações.

(c) Em $\{0,1\}$, $x_j^2 = x_j$. Cada observação ampliada é, então, $T(\boldsymbol{x}) = (x_1, x_2, x_1, x_2)$, em que $T : \mathbb{R}^2 \to \mathbb{R}^4$ é linear. Uma aplicação linear preserva combinações convexas, e, aplicando T à identidade do item (b),

$$T(\tfrac{1}{2}, \tfrac{1}{2}) = \tfrac{1}{2}T(1,0) + \tfrac{1}{2}T(0,1) = \tfrac{1}{2}T(0,0) + \tfrac{1}{2}T(1,1),$$

um ponto de $\mathbb{R}^4$ que é combinação convexa das duas classes ampliadas. Pelo item (a), que vale em qualquer dimensão, as observações ampliadas não são separáveis. Dito de outro modo, um hiperplano de $\mathbb{R}^4$ calculado nas observações ampliadas vale $\beta_0 + (\beta_1+\beta_3)x_1 + (\beta_2+\beta_4)x_2$: é uma função afim de (x_1, x_2), que o item (b) já mostrou incapaz de separar as classes. Os quadrados não acrescentam nada a variáveis binárias.

(d) As observações ampliadas são $(0,0,0)$ e $(1,1,1)$, na classe -1, e $(1,0,0)$ e $(0,1,0)$, na classe $+1$, e

$$f(0,0,0) = -1, \qquad f(1,1,1) = 2+2-4-1 = -1, \qquad f(1,0,0) = f(0,1,0) = 2-1 = 1 :$$

$y_i f(\boldsymbol{z}_i) = 1$ nas quatro. Dividindo os coeficientes por $\|(2,2,-4)\| = \sqrt{24}$, obtém-se $\boldsymbol{\beta} = (2,2,-4)/\sqrt{24}$, de norma 1, e $\beta_0 = -1/\sqrt{24}$, com $y_i(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{z}_i) = 1/\sqrt{24}$ para todo i: o valor $M = 1/\sqrt{24}$ é atingido.

Para a cota, seja $(\beta_0, \boldsymbol{\beta}, M)$ qualquer ponto que satisfaça as restrições. Multiplicando a restrição de cada observação pelo seu peso $\alpha_i > 0$ e somando,

$$\beta_0 \sum_i \alpha_i y_i + \boldsymbol{\beta}^\top \Big(\sum_i \alpha_i y_i \boldsymbol{z}_i \Big) \;\geq\; M \sum_i \alpha_i .$$

Com os pesos 8, 4, 6 e 6, $\sum_i \alpha_i y_i = -8-4+6+6 = 0$, e β_0 desaparece; $\sum_i \alpha_i y_i \boldsymbol{z}_i = -4(1,1,1) + 6(1,0,0) + 6(0,1,0) = (2,2,-4)$; e $\sum_i \alpha_i = 24$. Pela desigualdade de Cauchy–Schwarz e por $\|\boldsymbol{\beta}\| = 1$,

$$24\,M \;\leq\; \boldsymbol{\beta}^\top (2,2,-4) \;\leq\; \|(2,2,-4)\| = \sqrt{24}, \qquad \text{isto é,} \qquad M \leq \frac{1}{\sqrt{24}}.$$

O ponto encontrado acima é, portanto, ótimo. É também a única solução: a igualdade em Cauchy–Schwarz exige $\boldsymbol{\beta} = (2,2,-4)/\sqrt{24}$, e, como todos os pesos são positivos, a igualdade na soma exige que as quatro restrições valham com igualdade, o que determina $\beta_0 = -1/\sqrt{24}$. As quatro observações estão sobre a margem: todas são vetores de suporte. Os pesos não são arbitrários: com o sinal de cada classe, -8, -4, 6 e 6 são, a menos de um fator comum, os coeficientes α_i da representação de f por produtos internos que as notas admitem sem demonstração, e é isso que faz o β_0 sumir da soma.

No plano original, $f = 2x_1 + 2x_2 - 4x_1x_2 - 1 = -4\big(x_1 - \tfrac{1}{2}\big)\big(x_2 - \tfrac{1}{2}\big)$. A fronteira $f = 0$ é o par de retas $x_1 = \tfrac{1}{2}$ e $x_2 = \tfrac{1}{2}$, e o classificador acende a lâmpada quando $(x_1 - \tfrac{1}{2})(x_2 - \tfrac{1}{2}) < 0$, isto é, quando exatamente uma das chaves está acima de $\tfrac{1}{2}$. O que o ou exclusivo pede é a interação x_1x_2, e não os quadrados. O *kernel* polinomial de grau 2, $\big(1 + \langle \boldsymbol{x}, \boldsymbol{x}' \rangle\big)^2$, contém o monômio x_1x_2 entre as coordenadas da sua função φ, e uma SVM com ele também separa estas observações, embora com coeficientes diferentes, porque as coordenadas de φ vêm multiplicadas por constantes.

Aula 10 — KNN e Árvores de Classificação

Exercício 10 — O voto dos vizinhos. Otávio é agrônomo e usa o KNN para classificar os talhões de uma fazenda em atacados por uma praga ($Y = 1$) ou não ($Y = 0$), a partir de medidas de solo e de clima. Num talhão novo, com covariáveis $\boldsymbol{x}$, a probabilidade de praga é $\eta(\boldsymbol{x}) = \mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x}) = 0{,}6$. O KNN estima essa probabilidade pela proporção de vizinhos com praga, $\widehat{P} = \frac{1}{k}\sum_{j=1}^{k} Y_{(j)}$, em que $Y_{(1)}, \ldots, Y_{(k)}$ são os rótulos dos k vizinhos de $\boldsymbol{x}$ no treino, e declara praga quando $\widehat{P} > 1/2$. Tome k ímpar, para que não haja empate. Para isolar o papel de k, suponha que os rótulos dos vizinhos sejam independentes entre si e do rótulo Y do talhão

novo, e que, nos itens (a) e (b), cada um seja igual a 1 com probabilidade 0,6, como se todos os vizinhos estivessem no próprio $\boldsymbol{x}$.

(a) Mostre que $\mathbb{E}[\widehat{P}] = 0{,}6$ e $\mathrm{Var}(\widehat{P}) = 0{,}24/k$.

(b) Seja $q_k = \mathbb{P}(\widehat{P} > 1/2)$. Mostre que a probabilidade de o KNN errar o talhão novo é $0{,}6 - 0{,}2\,q_k$. Calcule q_5 e, usando $q_1 = 0{,}600$, $q_{15} \approx 0{,}787$ e $q_{51} \approx 0{,}926$, a probabilidade de erro para $k = 1, 5, 15$ e 51. Use a desigualdade de Chebyshev para mostrar que $q_k \to 1$ e que a probabilidade de erro tende a 0,4. Que classificador erra com probabilidade 0,4 nesse talhão?

(c) Na fazenda real, só os 9 talhões de treino mais próximos de $\boldsymbol{x}$ têm $\eta = 0{,}6$; do décimo vizinho em diante, eles vêm de uma região em que a probabilidade de praga é 0,2. Mantida a independência, a tabela dá q_k e a probabilidade de erro no talhão novo:

k	1	5	9	15	25	51
q_k	0,6000	0,6826	0,7334	0,3037	0,0381	0,0001
erro	0,4800	0,4635	0,4533	0,5393	0,5924	0,6000

Calcule $\mathbb{E}[\widehat{P}]$ para $k > 9$ e use a desigualdade de Chebyshev para explicar por que a probabilidade de erro se aproxima de 0,6 quando k cresce. Que k Otávio deveria escolher para este talhão? O que os itens (b) e (c), juntos, dizem sobre o papel de k?

(d) Mostre que, com $k = 1$ e uma probabilidade η qualquer no lugar de 0,6, a probabilidade de erro é $2\eta(1-\eta)$, e que $\min(\eta, 1-\eta) \le 2\eta(1-\eta) \le 2\min(\eta, 1-\eta)$. Interprete. O que acontece no outro extremo, com $k = n$?

Solução

(a) Pela linearidade da esperança, $\mathbb{E}[\widehat{P}] = \frac{1}{k}\sum_j \mathbb{E}[Y_{(j)}] = \frac{1}{k}\cdot k \cdot 0{,}6 = 0{,}6$. Cada $Y_{(j)}$ é uma Bernoulli(0,6), com variância $0{,}6 \cdot 0{,}4 = 0{,}24$, e, como os rótulos são independentes, as variâncias se somam: $\mathrm{Var}(\widehat{P}) = \frac{1}{k^2}\sum_j \mathrm{Var}(Y_{(j)}) = \frac{0{,}24}{k}$. Nesta idealização, a proporção de vizinhos é um estimador não viesado de $\eta(\boldsymbol{x})$, e a sua variância cai como $1/k$.

(b) O KNN erra se declara praga num talhão sem praga ou deixa de declarar num talhão com praga. Como a decisão depende só dos rótulos dos vizinhos, que são independentes de Y,

$$\mathbb{P}(\hat{g}(\boldsymbol{x}) \neq Y) = q_k\,\mathbb{P}(Y=0) + (1-q_k)\,\mathbb{P}(Y=1) = 0{,}4\,q_k + 0{,}6\,(1-q_k) = 0{,}6 - 0{,}2\,q_k.$$

Com $k = 5$, o KNN declara praga quando pelo menos 3 dos 5 vizinhos têm praga, e o número deles é uma binomial(5; 0,6):

$$q_5 = \binom{5}{3}(0{,}6)^3(0{,}4)^2 + \binom{5}{4}(0{,}6)^4(0{,}4) + (0{,}6)^5 = 0{,}3456 + 0{,}2592 + 0{,}0778 \approx 0{,}683.$$

As probabilidades de erro são 0,480, 0,463, 0,443 e 0,415 para $k = 1$, 5, 15 e 51. Como k é ímpar, $\widehat{P} \neq 1/2$, e o KNN deixa de declarar praga exatamente quando $\widehat{P} < 1/2$. Esse evento está contido em $\{\left|\widehat{P} - 0{,}6\right| \ge 0{,}1\}$, e, pela desigualdade de Chebyshev,

$$1 - q_k = \mathbb{P}(\widehat{P} < 1/2) \le \mathbb{P}(\left|\widehat{P} - 0{,}6\right| \ge 0{,}1) \le \frac{\mathrm{Var}(\widehat{P})}{0{,}1^2} = \frac{24}{k} \longrightarrow 0.$$

Logo $q_k \to 1$ e a probabilidade de erro tende a $0{,}6 - 0{,}2 = 0{,}4$. É a probabilidade de erro do classificador de Bayes nesse talhão: como $\eta(\boldsymbol{x}) > 1/2$, ele declara praga, e erra com probabilidade $1 - \eta(\boldsymbol{x}) = 0{,}4$, que nenhum classificador pode melhorar.

(c) Para $k > 9$, os 9 primeiros vizinhos têm esperança 0,6 e os outros $k-9$, esperança 0,2, e

$$\mathbb{E}[\widehat{P}] = \frac{9 \cdot 0{,}6 + (k-9) \cdot 0{,}2}{k} = 0{,}2 + \frac{3{,}6}{k},$$

que vale 0,44 para $k = 15$, 0,344 para $k = 25$ e cerca de 0,271 para $k = 51$. Para $k > 12$, a esperança fica abaixo de $1/2$ e se aproxima de 0,2. A variância, pela independência, é no máximo $0{,}24/k$, porque cada parcela tem variância 0,24 ou 0,16. Como $\widehat{P} > 1/2$ exige um desvio de pelo menos $d_k = 1/2 - \mathbb{E}[\widehat{P}]$ em relação à esperança, Chebyshev dá

$$q_k = \mathbb{P}(\widehat{P} > 1/2) \leq \frac{\mathrm{Var}(\widehat{P})}{d_k^2} \leq \frac{0{,}24}{k\, d_k^2} \;\longrightarrow\; 0,$$

porque $d_k \to 0{,}3$. A probabilidade de erro $0{,}6 - 0{,}2\, q_k$ tende então a 0,6: com muitos vizinhos, o KNN declara o talhão sem praga, contra o que diz $\eta(\boldsymbol{x}) = 0{,}6$. Entre os valores da tabela, o melhor é $k = 9$, com probabilidade de erro 0,453.

Os dois itens mostram as duas metades do balanço. No item (b), os vizinhos têm todos a probabilidade certa, e aumentar k só reduz o ruído do voto: é a variância que cai. No item (c), os vizinhos mais distantes trazem a probabilidade de outra região, e aumentar k demais desloca o voto para a resposta errada: é o viés que cresce. O melhor k depende de quão depressa η muda em torno de $\boldsymbol{x}$, o que não se conhece; por isso k é escolhido por validação cruzada.

(d) Com $k = 1$, o KNN repete o rótulo do vizinho mais próximo, que é 1 com probabilidade η e independente de Y. Ele erra se os dois rótulos diferem:

$$\mathbb{P}(\widehat{g}(\boldsymbol{x}) \neq Y) = \eta(1-\eta) + (1-\eta)\eta = 2\eta(1-\eta).$$

Sejam $m = \min(\eta, 1-\eta)$ e $1 - m = \max(\eta, 1-\eta)$, com $1/2 \leq 1 - m \leq 1$. Então $2\eta(1-\eta) = 2m(1-m)$, e multiplicar as desigualdades $1/2 \leq 1 - m \leq 1$ por $2m \geq 0$ dá $m \leq 2m(1-m) \leq 2m$. Como m é a probabilidade de erro do classificador de Bayes em $\boldsymbol{x}$, o 1-NN, nesta idealização, erra pelo menos tanto quanto ele e no máximo o dobro; com $\eta = 0{,}6$, são 0,48 contra 0,40. No outro extremo, com $k = n$, todos os pontos de treino votam, $\widehat{P}$ é a proporção de talhões com praga no treino inteiro, e o KNN atribui a mesma classe, a majoritária, a qualquer talhão: é o classificador constante, com o maior viés possível.

Exercício 11 — Crescer com Gini, podar com o erro. Rafael é analista numa operadora de planos de saúde e cresceu uma árvore de classificação, com o índice de Gini, para prever quais beneficiários serão internados no próximo ano ($Y = 1$). Agora vai podá-la. Para uma região R com n_R observações de treino, sejam $n_{R,c}$ o número delas na classe c e $\widehat{p}_{R,c} = n_{R,c}/n_R$. A folha R prediz a classe majoritária, e $E(R) = 1 - \max_c \widehat{p}_{R,c}$ é o seu erro de classificação, de modo que $n_R E(R) = n_R - \max_c n_{R,c}$ é o número de erros de treino na folha. Na poda por custo-complexidade com o erro de classificação, escolhe-se, entre as subárvores T da árvore crescida, a que minimiza

$$C_\alpha(T) = \sum_{m=1}^{|T|} n_m E(R_m) + \alpha\, |T|\,,$$

em que $R_1, \ldots, R_{|T|}$ são as folhas de T, $n_m = n_{R_m}$ e $|T|$ é o número de folhas; o valor de $\alpha > 0$ é escolhido por validação cruzada.

(a) Seja R uma região dividida em regiões disjuntas $R_1, \ldots, R_L$. Mostre que $\sum_l n_{R_l} E(R_l) \leq n_R E(R)$, com qualquer número de classes, e que vale a igualdade quando uma mesma classe c^* é majoritária em todas as R_l; nesse caso, c^* é majoritária também em R.

(b) Mostre que, para todo $\alpha > 0$, nenhuma subárvore que minimize C_α tem um nó interno cujas folhas descendentes predigam todas a mesma classe.

(c) Na árvore de Rafael, um nó com 400 beneficiários, dos quais 100 foram internados, foi dividido em dois filhos de 200, com 20 e com 80 internados. Calcule a redução do índice de Gini ponderado, $G(R) - [n_1 G(R_1) + n_2 G(R_2)]/n_R$, e a redução do erro de classificação ponderado. Por que o crescimento fez essa divisão, e o que a poda fará com ela?

(d) A operadora estima que deixar de prever uma internação custa quatro vezes mais que prever uma que não acontece: $\ell_0 = 4$ e $\ell_1 = 1$. Cada folha passa a prever internação quando a sua proporção de internados passa de $\ell_1/(\ell_0 + \ell_1)$, e o custo da folha é $\ell_1\,\mathrm{FP} + \ell_0\,\mathrm{FN}$ nas suas observações de treino. Calcule o custo do nó do item (c) antes e depois da divisão. Se a poda usar esse custo no lugar do número de erros, para que valores de α a divisão sobrevive? O que isso diz sobre podar pelo erro de classificação?

Solução

(a) As regiões R_l particionam R, e por isso $n_{R,c} = \sum_l n_{R_l,c}$ para cada classe c. O máximo de uma soma não passa da soma dos máximos:

$$\max_c n_{R,c} = \max_c \sum_l n_{R_l,c} \;\le\; \sum_l \max_c n_{R_l,c}.$$

Logo

$$\sum_l n_{R_l} E(R_l) = \sum_l \Big(n_{R_l} - \max_c n_{R_l,c}\Big) = n_R - \sum_l \max_c n_{R_l,c} \;\le\; n_R - \max_c n_{R,c} = n_R E(R).$$

Se c^* é majoritária em todas as R_l, então $\sum_l \max_c n_{R_l,c} = \sum_l n_{R_l,c^*} = n_{R,c^*} \le \max_c n_{R,c}$; com a desigualdade anterior, os três números são iguais. A igualdade vale, e $n_{R,c^*} = \max_c n_{R,c}$: c^* é majoritária em R. Dividir uma região nunca aumenta o número de erros de treino, e só o diminui quando alguma das partes muda a classe predita.

(b) Suponha que T minimize C_α e tenha um nó interno t cujas $L \ge 2$ folhas descendentes predizem todas a classe c^*. Seja T' a subárvore obtida trocando o ramo que sai de t por uma única folha, a região de t. Pelo item (a), essa folha tem c^* como classe majoritária e o mesmo número de erros de treino que as L folhas juntas; as outras folhas não mudam. As duas subárvores cometem, então, os mesmos erros, e $|T'| = |T| - (L-1)$, de modo que

$$C_\alpha(T') = C_\alpha(T) - \alpha(L-1) < C_\alpha(T),$$

porque $\alpha > 0$ e $L \ge 2$. Isso contradiz a escolha de T. Qualquer que seja $\alpha > 0$, a poda pelo erro de classificação remove todos os ramos que não mudam nenhuma decisão.

(c) As proporções de internados são 0,25 no nó e 0,1 e 0,4 nos filhos, e, com duas classes, $G = 2\widehat{p}(1-\widehat{p})$:

$$G(R) = 2 \cdot 0{,}25 \cdot 0{,}75 = 0{,}375, \qquad \tfrac{1}{2}\,G(R_1) + \tfrac{1}{2}\,G(R_2) = \tfrac{1}{2} \cdot 0{,}18 + \tfrac{1}{2} \cdot 0{,}48 = 0{,}33,$$

uma redução de 0,045. A classe majoritária é "não internado" no nó (300 contra 100) e nos dois filhos (180 contra 20 e 120 contra 80). Os erros são 100 no nó e $20 + 80 = 100$ nos filhos: a redução do erro é zero, como o item (a) previa. O Gini é estritamente côncavo e registra o ganho de pureza de separar um grupo de risco baixo (10% de internações) de um de risco alto (40%); por isso o crescimento fez a divisão. Os dois filhos, porém, predizem a mesma classe, e, pelo item (b), a poda pelo erro remove a divisão qualquer que seja $\alpha > 0$.

(d) O corte é $\ell_1/(\ell_0 + \ell_1) = 1/5$. Antes da divisão, a proporção 0,25 passa do corte, e o nó prevê internação para os 400: os 300 não internados são falsos positivos, com custo

$1 \cdot 300 = 300$. Depois, o filho com proporção 0,1 prevê não internação e erra nos 20 internados, com custo $4 \cdot 20 = 80$, e o filho com 0,4 prevê internação e erra nos 120 não internados, com custo $1 \cdot 120 = 120$: são 200 no total. Com o custo no lugar dos erros, manter a divisão contribui com $200 + 2\alpha$ para o critério e removê-la, com $300 + \alpha$, e a divisão sobrevive para $\alpha < 100$.
O número de erros conta um falso negativo e um falso positivo como iguais, e por isso corresponde ao corte 1/2. Com custos assimétricos, a divisão que o erro de classificação manda remover é justamente a que muda a decisão no corte relevante. A poda deve usar o mesmo critério que vai guiar as decisões: o erro de classificação quando os dois erros custam o mesmo, o custo quando não custam. O argumento do item (b) continua valendo com o custo: a poda remove os ramos cujas folhas tomam todas a mesma decisão no corte de custo.

Exercício 12 — Quando Gini e entropia discordam. Ana é bióloga e usa uma árvore de classificação para distinguir mudas de duas espécies, a espécie 1 e a espécie 0, a partir de características medidas no viveiro. Num nó com 12 mudas, 6 de cada espécie, a árvore compara duas divisões:

A pela altura, separa dois grupos de 6 mudas, um com 2 da espécie 1 e 4 da espécie 0 e outro com 4 da espécie 1 e 2 da espécie 0;

B por uma mancha rara na folha, isola uma única muda, da espécie 0, das outras 11, que têm 6 da espécie 1 e 5 da espécie 0.

Numa região com proporção p de mudas da espécie 1, o índice de Gini é $G(p) = 2p(1-p)$, a entropia é $D(p) = -p\log_2 p - (1-p)\log_2(1-p)$, com $0\log_2 0 = 0$, e o erro de classificação é $E(p) = \min(p, 1-p)$. Uma divisão em regiões com n_1 e n_2 mudas e proporções p_1 e p_2 tem impureza ponderada $[n_1 I(p_1) + n_2 I(p_2)]/(n_1 + n_2)$, para cada medida I, e a árvore escolhe a divisão de menor impureza ponderada.

(a) Calcule a impureza ponderada das divisões A e B pelas três medidas e diga qual divisão cada medida escolhe. *Dados:* $\log_2 3 \approx 1{,}5850$, $\log_2 5 \approx 2{,}3219$ e $\log_2 11 \approx 3{,}4594$.

(b) Seja ϕ uma medida de impureza qualquer para duas classes, com $\phi(p) = \phi(1-p)$, $\phi(0) = 0$ e $\phi(6/11) > 0$. Mostre que A tem impureza ponderada menor que B se e somente se $\phi(1/3)/\phi(6/11) < 11/12$. Calcule essa razão para as três medidas e explique que propriedade da curva da entropia a leva a escolher B.

(c) No exemplo dos slides, o `DecisionTreeClassifier` é ajustado com `min_samples_leaf=5`, que só admite divisões com pelo menos 5 observações em cada filho. O que acontece com a divisão B, e as medidas continuam discordando? Qual das duas divisões você preferiria, e por quê? As notas dizem que o Gini e a entropia quase sempre escolhem as mesmas divisões; o que este exemplo diz sobre esse "quase"?

Solução

(a) Na divisão A, as proporções da espécie 1 são 1/3 e 2/3, cada uma num filho com metade das mudas. Na divisão B, são 0, numa muda, e 6/11, nas outras 11. Pelo Gini,

$$\text{A: } \tfrac{1}{2}\cdot 2\cdot\tfrac{1}{3}\cdot\tfrac{2}{3} + \tfrac{1}{2}\cdot 2\cdot\tfrac{2}{3}\cdot\tfrac{1}{3} = \tfrac{4}{9} \approx 0{,}444, \qquad \text{B: } \tfrac{1}{12}\cdot 0 + \tfrac{11}{12}\cdot 2\cdot\tfrac{6}{11}\cdot\tfrac{5}{11} = \tfrac{5}{11} \approx 0{,}455.$$

Pela entropia, como $D(1/3) = D(2/3) = \frac{1}{3}\log_2 3 + \frac{2}{3}\log_2 \frac{3}{2} = \log_2 3 - \frac{2}{3}$,

A: $\log_2 3 - \frac{2}{3} \approx 0{,}918$,

B: $\frac{11}{12} D(\frac{6}{11}) = \frac{1}{12}\Big(6\log_2 \frac{11}{6} + 5\log_2 \frac{11}{5}\Big) = \frac{1}{12}(11\log_2 11 - 6\log_2 6 - 5\log_2 5) \approx 0{,}911$,

com $\log_2 6 = 1 + \log_2 3$. Pelo erro de classificação, A erra 2 mudas em cada filho, $4/12 = 1/3$, e B erra as 5 mudas da espécie 0 no filho grande, $5/12 \approx 0{,}417$. O Gini e o erro escolhem A; a entropia escolhe B. O nó tem $G = 0{,}5$ e $D = 1$, e as reduções correspondentes são 0,056 (A) e 0,045 (B) no Gini, e 0,082 (A) e 0,089 (B) na entropia.

(b) Pela simetria, a impureza ponderada de A é $\frac{1}{2}\phi(1/3) + \frac{1}{2}\phi(2/3) = \phi(1/3)$, e a de B é $\frac{1}{12}\phi(0) + \frac{11}{12}\phi(6/11) = \frac{11}{12}\phi(6/11)$. Como $\phi(6/11) > 0$,

$$\phi(\tfrac{1}{3}) < \tfrac{11}{12}\,\phi(\tfrac{6}{11}) \iff \frac{\phi(1/3)}{\phi(6/11)} < \frac{11}{12} \approx 0{,}917.$$

As razões são $(4/9)/(60/121) = 121/135 \approx 0{,}896$ para o Gini, $0{,}918/0{,}994 \approx 0{,}924$ para a entropia e $(1/3)/(5/11) = 11/15 \approx 0{,}733$ para o erro: só a entropia passa de 11/12.

A comparação tem uma leitura simples. A divisão A leva os dois filhos da proporção 1/2 à proporção 1/3; a divisão B torna pura 1/12 das mudas e deixa as outras numa região quase tão misturada quanto o nó, porque $6/11 \approx 0{,}545$ está perto de 1/2. Com $\phi(6/11) \approx \phi(1/2)$, a pergunta é, em essência, se $\phi(1/3)$ fica abaixo de 11/12 do máximo: $G(1/3)/G(1/2) = 8/9 \approx 0{,}889$, mas $D(1/3)/D(1/2) \approx 0{,}918$. A entropia é mais achatada perto do máximo: trata uma região com um terço de uma espécie como quase tão impura quanto uma equilibrada, e por isso dá pouco valor à purificação parcial de A e, em comparação, mais valor à purificação completa de um pedaço pequeno, que é o que B faz.

(c) Com `min_samples_leaf=5`, a divisão B deixa um filho com uma única muda e não é admitida; entre as duas, só A resta, e as medidas deixam de discordar. A é a divisão preferível: separa grupos de 6 mudas com maiorias claras, enquanto B se apoia numa mancha que aparece numa muda só, purifica uma observação e deixa as outras tão misturadas quanto antes, o que dificilmente se repetirá em mudas novas.

O exemplo mostra que o "quase" é literal: as duas medidas podem, de fato, escolher divisões diferentes. É uma questão de frequência. Numa enumeração de todos os pares de divisões possíveis em nós de 10 a 40 observações, de todas as composições de classes, as duas medidas discordam em cerca de 2% dos pares, e a proporção quase não muda quando se exige que todos os filhos tenham pelo menos 5 observações. Aqui a restrição desfaz a discordância porque a divisão B isola uma única muda; em geral, o tamanho mínimo de folha não basta para isso. O que torna a escolha entre o Gini e a entropia pouco importante na prática é a raridade da discordância, e não uma restrição como a do slide.