Lista de Revisão

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aulas 07 a 10 — Classificadores Gaussianos, Métricas, SVM, KNN e Árvores de Classificação

---

Não há ordem obrigatória para a resolução. Cada exercício se resolve com o seu enunciado e as notas de aula, e vários deles juntam ideias de aulas diferentes, como o corte ótimo sob custos assimétricos, a curva ROC e a validação cruzada.

Salvo indicação em contrário, $(\boldsymbol{X}, Y)$ é um vetor aleatório com $\boldsymbol{X} \in \mathbb{R}^p$ e Y num conjunto finito $\mathcal{C}$ de classes; no caso binário, $\mathcal{C} = \{0, 1\}$, a classe $Y = 1$ é a positiva e $\eta(\boldsymbol{x}) = \mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x})$. A perda é a 0–1, com risco $R(g) = \mathbb{P}\big(Y \neq g(\boldsymbol{X})\big)$, e a amostra de treino $\mathcal{D} = \{(\boldsymbol{X}_i, Y_i)\}_{i=1}^{n}$ é i.i.d. Nos exercícios sobre máquinas de vetores de suporte, as classes são codificadas por $y \in \{-1, +1\}$.

Aula 07 — Classificação e Classificadores Gaussianos

Exercício 1 — A logística sem gaussianas. Renata é atuária numa seguradora e quer classificar os segurados de um ramo em dois perfis, $Y = 1$ (risco alto) e $Y = 0$ (risco baixo), a partir de uma única covariável: o tempo X, em anos, entre a contratação da apólice e o primeiro sinistro. Ela hesita entre a análise discriminante linear (LDA) e a regressão logística, dois métodos que chegam a uma fronteira linear por caminhos diferentes. Ao longo do exercício, $\sigma(u) = e^u/(1 + e^u)$ é a função logística, log é o logaritmo natural e $\pi_c = \mathbb{P}(Y = c)$.

(a) Suponha que $\boldsymbol{X} \in \mathbb{R}^p$ e que, como no LDA, $\boldsymbol{X} \mid Y = c \sim N(\boldsymbol{\mu}_c, \boldsymbol{\Sigma})$ para $c \in \{0, 1\}$, com $\boldsymbol{\Sigma}$ simétrica e positiva definida. Mostre que $\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x}) = \sigma(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x})$ e escreva β_0 e $\boldsymbol{\beta}$ em função de π_0, π_1, $\boldsymbol{\mu}_0$, $\boldsymbol{\mu}_1$ e $\boldsymbol{\Sigma}$. Conclua que, sob as hipóteses do LDA, o modelo da regressão logística vale exatamente.

(b) Os tempos de Renata não se parecem com uma normal: são positivos e muito assimétricos. Suponha agora que $X \mid Y = c$ tenha distribuição exponencial de taxa λ_c, com densidade $\lambda_c e^{-\lambda_c x}$ para $x > 0$, com $\lambda_0 = 1$, $\lambda_1 = 3$ e $\pi_0 = \pi_1 = 1/2$: em média, o primeiro sinistro do perfil de risco alto chega três vezes mais cedo. Mostre que $\mathbb{P}(Y = 1 \mid X = x) = \sigma(\log 3 - 2x)$ para $x > 0$. O modelo logístico continua valendo? E as hipóteses do LDA?

(c) Com uma amostra muito grande dessa população, as estimativas de máxima verossimilhança do LDA se aproximam dos valores populacionais: as médias de $\mathbb{E}[X \mid Y = c] = 1/\lambda_c$, a variância comum de $v = \pi_0 \operatorname{Var}(X \mid Y = 0) + \pi_1 \operatorname{Var}(X \mid Y = 1)$, com $\operatorname{Var}(X \mid Y = c) = 1/\lambda_c^2$, e as prioris de $1/2$. Admita também que, quando o modelo logístico vale, os coeficientes estimados pela logística se aproximam dos verdadeiros. Calcule os coeficientes (β_0, β_1) de que cada método se aproxima, o corte de cada um no nível $1/2$ (o tempo abaixo do qual ele classifica o segurado como de risco alto) e a probabilidade de erro de cada corte.

(d) Renata quer acompanhar de perto os segurados cuja probabilidade de risco alto passe de $p_0 = 0{,}1$. Determine, para cada método, os tempos x marcados para acompanhamento e compare a diferença entre os dois cortes com a que você encontrou no nível $1/2$. O que isso diz sobre a frase "sob as hipóteses do LDA, os dois métodos têm a mesma forma e diferem só na estimação"?

Exercício 2 — O preço do ingênuo. Lucas é analista de crédito e quer prever a inadimplência, $Y = 1$, a partir da renda mensal X_1 do cliente, em milhares de reais. Na população de clientes,

$X_1 \mid Y=1 \sim N(3,1)$ e $X_1 \mid Y=0 \sim N(5,1)$. Ao juntar duas bases, Lucas fica, sem perceber, com a renda duas vezes: em X_1, em milhares de reais, e em $X_2 = 1000\,X_1$, em reais. Ele ajusta um Bayes ingênuo gaussiano às duas colunas. Para separar o erro do modelo do erro de estimação, suponha que a amostra é tão grande que o ingênuo usa as distribuições verdadeiras de X_1 e de X_2 em cada classe. Seja

$$L(x_1) = \log \frac{f_1(x_1)}{f_0(x_1)}$$

a razão de log-verossimilhanças da renda, em que f_c é a densidade de X_1 dado $Y=c$ e log é o logaritmo natural, e sejam $\pi_c = \mathbb{P}(Y=c)$ e $\sigma(u) = e^u/(1+e^u)$.

(a) Mostre que $L(x_1) = 8 - 2x_1$. Mostre que, num cliente com renda x_1, o *log-odds* verdadeiro é $\log(\pi_1/\pi_0) + L(x_1)$ e o calculado pelo ingênuo é $\log(\pi_1/\pi_0) + 2L(x_1)$.

(b) Suponha $\pi_0 = \pi_1 = 1/2$ e seja $\eta = \mathbb{P}(Y=1 \mid X_1 = x_1)$. Mostre que a probabilidade calculada pelo ingênuo é $\widehat{P} = \eta^2/(\eta^2 + (1-\eta)^2)$. Conclua que ela ordena os clientes como η, que classifica cada um como o classificador de Bayes, e que $\left|\widehat{P} - 1/2\right| > |\eta - 1/2|$ sempre que $\eta \notin \{0, 1/2, 1\}$. Calcule $\widehat{P}$ para $\eta = 0{,}6$ e para $\eta = 0{,}8$.

(c) Na carteira de Lucas, porém, só 20% dos clientes são inadimplentes: $\pi_1 = 0{,}2$. Determine as rendas que o classificador de Bayes classifica como inadimplentes e as que o ingênuo classifica assim, e mostre que as duas decisões diferem num intervalo de rendas. Calcule a probabilidade de um cliente cair nesse intervalo e diga qual das duas decisões erra mais nele. *Dados:* $\log 2 \approx 0{,}6931$, $\Phi(-1{,}3466) \approx 0{,}0891$, $\Phi(-1{,}6931) \approx 0{,}0452$, $\Phi(0{,}6534) \approx 0{,}7433$ e $\Phi(0{,}3069) \approx 0{,}6205$, em que Φ é a função de distribuição da normal padrão.

(d) Se a renda aparecesse em m colunas, todas proporcionais a X_1, o que aconteceria com o *log-odds* do ingênuo? E com a sua decisão quando $m \to \infty$? Resuma o que o exercício mostra sobre o Bayes ingênuo com covariáveis redundantes: o que ele preserva e o que ele estraga.

Exercício 3 — A verossimilhança da logística. Beatriz trabalha com marketing e ajusta uma regressão logística para prever se um cliente responde a uma campanha ($y_i = 1$) ou não ($y_i = 0$), a partir de p covariáveis. Sejam $\tilde{\boldsymbol{x}}_i = (1, \boldsymbol{x}_i) \in \mathbb{R}^{p+1}$ o vetor de covariáveis da observação i com um 1 na frente, $\tilde{\mathbb{X}}$ a matriz $n \times (p+1)$ cujas linhas são os $\tilde{\boldsymbol{x}}_i^\top$, $\boldsymbol{\beta} = (\beta_0, \beta_1, \ldots, \beta_p)$ e

$$\pi_i(\boldsymbol{\beta}) = \sigma(\tilde{\boldsymbol{x}}_i^\top \boldsymbol{\beta}), \qquad \sigma(u) = \frac{e^u}{1+e^u}, \qquad \ell(\boldsymbol{\beta}) = \sum_{i=1}^{n} \Big[y_i \log \pi_i(\boldsymbol{\beta}) + (1-y_i) \log\big(1 - \pi_i(\boldsymbol{\beta})\big) \Big],$$

a log-verossimilhança da amostra. O otimizador do pacote que ela usa avisa, numa das bases, que não convergiu e devolve coeficientes enormes, e ela quer entender por quê.

(a) Mostre que $\ell(\boldsymbol{\beta}) = \sum_i \big[y_i\, \tilde{\boldsymbol{x}}_i^\top \boldsymbol{\beta} - \log\big(1 + e^{\tilde{\boldsymbol{x}}_i^\top \boldsymbol{\beta}}\big) \big]$, que o gradiente é $\nabla \ell(\boldsymbol{\beta}) = \sum_i (y_i - \pi_i) \tilde{\boldsymbol{x}}_i$ e que a hessiana é $-\tilde{\mathbb{X}}^\top W \tilde{\mathbb{X}}$, com $W = \operatorname{diag}\big(\pi_i(1-\pi_i)\big)$. Conclua que ℓ é côncava, que todo ponto crítico de ℓ é um máximo global e que, se $\tilde{\mathbb{X}}$ tem posto $p+1$, há no máximo um maximizador.

(b) Mostre que, num maximizador $\widehat{\boldsymbol{\beta}}$, a soma das probabilidades ajustadas é igual ao número de clientes que responderam: $\sum_i \pi_i(\widehat{\boldsymbol{\beta}}) = \sum_i y_i$. Que leitura isso tem?

(c) Não há fórmula fechada para o maximizador, e o otimizador usa o método de Newton–Raphson. Supondo $\tilde{\mathbb{X}}$ de posto $p+1$, escreva o passo de Newton que leva $\boldsymbol{\beta}$ a $\boldsymbol{\beta}^{\text{novo}}$ e mostre que $\boldsymbol{\beta}^{\text{novo}}$ minimiza a soma de quadrados ponderada $\sum_i w_i (z_i - \tilde{\boldsymbol{x}}_i^\top \boldsymbol{b})^2$ em $\boldsymbol{b}$, com $w_i = \pi_i(1-\pi_i)$ e $z_i = \tilde{\boldsymbol{x}}_i^\top \boldsymbol{\beta} + (y_i - \pi_i)/w_i$, todos calculados no $\boldsymbol{\beta}$ atual. Por que o método se chama mínimos quadrados reponderados iterativamente (IRLS)?

(d) Na base problemática existe $\boldsymbol{b}^* \in \mathbb{R}^{p+1}$ com $\tilde{\boldsymbol{x}}_i^\top \boldsymbol{b}^* > 0$ para todo i com $y_i = 1$ e $\tilde{\boldsymbol{x}}_i^\top \boldsymbol{b}^* < 0$ para todo i com $y_i = 0$: um hiperplano separa os que responderam dos que não responderam. Mostre que $\ell(\boldsymbol{\beta}) < 0$ para todo $\boldsymbol{\beta}$ e que $\ell(t\,\boldsymbol{b}^*) \to 0$ quando $t \to \infty$, e conclua que a verossimilhança não tem maximizador. Mostre em seguida que, se as duas classes estão presentes, a função penalizada $Q(\boldsymbol{\beta}) = \ell(\boldsymbol{\beta}) - \lambda \sum_{j=1}^{p} \beta_j^2$, com $\lambda > 0$ e o intercepto sem penalidade, tem um único maximizador.

Aula 08 — Métricas para Classificação

Exercício 4 — A curva ROC não vê a escala. Carla é epidemiologista e avalia um modelo que estima, para cada paciente, a probabilidade de uma doença ($Y = 1$). Numa amostra de teste com 4 doentes e 6 saudáveis, independente dos dados usados para ajustar o modelo, ela anota o escore s_i do seu modelo e o escore r_i do modelo de um colega:

paciente	1	2	3	4	5	6	7	8	9	10
y_i	1	1	1	1	0	0	0	0	0	0
s_i	0,90	0,70	0,45	0,25	0,60	0,35	0,15	0,12	0,08	0,05
r_i	0,988	0,845	0,401	0,100	0,692	0,225	0,030	0,018	0,008	0,003

Ela percebe que, em todos os pacientes, $r_i = h(s_i)$, com $h(s) = s^2/(s^2 + (1-s)^2)$. Cada modelo declara positivo quem tem escore maior ou igual a um corte p_0, e a curva ROC de um escore é o conjunto dos pontos (taxa de falsos positivos, taxa de verdadeiros positivos) que os cortes produzem nesta amostra, ligados por segmentos.

(a) Liste os pontos da curva ROC do escore s, desenhe a curva e calcule a área sob ela, a AUC. Em que ponto da curva fica o corte $p_0 = 0{,}5$?

(b) Mostre que h é estritamente crescente em $(0, 1)$ e que, para *toda* função h estritamente crescente, o escore $h(s)$ tem a mesma curva ROC que s nesta amostra. Conclua que os dois modelos têm a mesma AUC.

(c) No hospital, deixar passar um doente custa quatro vezes mais que um alarme falso: $\ell_0 = 4$ e $\ell_1 = 1$. O corte que minimiza o custo esperado, quando o escore é a probabilidade verdadeira $\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x})$, é $\ell_1/(\ell_0 + \ell_1)$. Aplique esse corte aos escores s e aos escores r, identifique os pacientes declarados positivos em cada caso e calcule o custo total $\ell_1\,\mathrm{FP} + \ell_0\,\mathrm{FN}$ de cada decisão na amostra. Compare com o custo dos outros cortes possíveis para s.

(d) O que a curva ROC e a AUC dizem sobre os dois modelos, e o que elas não dizem? O que é preciso saber sobre os escores para usar o corte $\ell_1/(\ell_0 + \ell_1)$?

Exercício 5 — Sortear entre dois classificadores. Diego é analista antifraude num banco e tem dois sistemas que já foram avaliados, A e B. Tome a fraude como a classe positiva, $Y = 1$. As taxas de falsos positivos e de verdadeiros positivos são $(\mathrm{FPR}, \mathrm{TPR}) = (0{,}02;\ 0{,}50)$ para A e $(0{,}08;\ 0{,}80)$ para B. O banco aceita mandar para revisão manual no máximo 5% das transações legítimas, e nenhum dos dois sistemas aproveita esse limite: A fica abaixo dele e B o ultrapassa. Diego então propõe sortear: para cada transação, uma moeda com probabilidade λ de dar cara, lançada independentemente de tudo o mais, escolhe se a decisão será a de A (cara) ou a de B (coroa). Seja g_λ esse classificador.

(a) Mostre que $\mathrm{FPR}(g_\lambda) = \lambda\,\mathrm{FPR}(A) + (1-\lambda)\,\mathrm{FPR}(B)$ e que o mesmo vale para a TPR, isto é, que o ponto de g_λ no plano (FPR, TPR) está no segmento que liga os pontos de A e de B. Determine λ para que a taxa de falsos positivos seja exatamente 0,05 e calcule a taxa de verdadeiros positivos obtida. Que classificadores sorteados dão os pontos da diagonal?

(b) Um terceiro sistema, C, tem $(\mathrm{FPR}, \mathrm{TPR}) = (0{,}70;\ 0{,}40)$. Mostre que o classificador que inverte todas as decisões de C tem o ponto $(0{,}30;\ 0{,}60)$ e, em geral, que inverter as decisões leva $(\mathrm{FPR}, \mathrm{TPR})$ a $(1-\mathrm{FPR}, 1-\mathrm{TPR})$. Se um escore tem curva ROC abaixo da diagonal, com área AUC $< 1/2$, qual é a curva e qual é a área do escore com o sinal trocado?

(c) Com custos ℓ_0 por falso negativo e ℓ_1 por falso positivo, o custo esperado de um classificador g é $R_\ell(g) = \ell_1 \mathbb{P}(g(\boldsymbol{X}) = 1, Y = 0) + \ell_0 \mathbb{P}(g(\boldsymbol{X}) = 0, Y = 1)$. Mostre que $R_\ell(g_\lambda) = \lambda R_\ell(A) + (1-\lambda) R_\ell(B)$ e conclua que, sem a restrição do banco, sortear nunca custa menos que o melhor dos dois sistemas. Para que serve, então, o sorteio?

(d) Mostre que o conjunto dos pontos (FPR, TPR) de todos os classificadores, sorteados ou não, é convexo e contém a diagonal. Use isso para explicar por que a curva ROC estimada de um escore é desenhada ligando os pontos de cortes consecutivos por segmentos de reta.

Exercício 6 — Um bom exame que o classificador de Bayes ignora. Helena é médica e coordena o rastreamento de uma doença que atinge 1% da população: $\mathbb{P}(Y = 1) = 0{,}01$, com $Y = 1$ para doente. O exame disponível tem resultado $X \in \{0, 1\}$ e, seguindo o resultado (isto é, declarando doente quem tem $X = 1$), detecta 90% dos doentes e dá alarme falso para 10% dos saudáveis: $\mathbb{P}(X = 1 \mid Y = 1) = 0{,}9$ e $\mathbb{P}(X = 1 \mid Y = 0) = 0{,}1$. Seja $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$.

(a) Calcule $\eta(1)$ e $\eta(0)$.

(b) Determine o classificador de Bayes, o que minimiza a probabilidade de erro. Compare a probabilidade de erro dele com a do classificador que segue o exame. Um colega conclui que o exame não serve para nada. O que há de errado nessa conclusão?

(c) Sejam ℓ_0 o custo de deixar passar um doente e ℓ_1 o de um alarme falso, e $r = \ell_0/\ell_1$. Lembre que o classificador de menor custo esperado declara doente quando $\eta(x) > \ell_1/(\ell_0 + \ell_1)$. Mostre que seguir o exame é a decisão de menor custo esperado se e somente se $11 < r \leq 891$, e diga qual é a decisão ótima fora dessa faixa. Para $\ell_0 = 20$ e $\ell_1 = 1$, calcule o custo esperado de declarar todos saudáveis, de seguir o exame e de declarar todos doentes, numa população de 10 000 pessoas.

(d) Os cortes aplicados a $\eta(X)$ produzem só três classificadores. Encontre os seus pontos (FPR, TPR), desenhe a curva ROC que os liga por segmentos e calcule a AUC. Como uma AUC alta e um classificador de Bayes que ignora o exame podem conviver?

Aula 09 — Máquinas de Vetores de Suporte

Exercício 7 — Só os vetores de suporte importam. Tiago trabalha no controle de qualidade de uma fábrica e classifica peças em boas ($y = +1$) e defeituosas ($y = -1$) a partir de p medidas. As suas n observações de treino $(\boldsymbol{x}_i, y_i)$ são linearmente separáveis, e cada classe tem pelo menos duas observações. O classificador de margem máxima é dado pela solução do problema

$$\max_{\beta_0,\,\boldsymbol{\beta},\,M} M \quad \text{sujeito a} \quad \sum_{j=1}^{p} \beta_j^2 = 1 \quad \text{e} \quad y_i\,(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) \geq M, \quad i = 1, \ldots, n.$$

Escreva $f(\boldsymbol{x}) = \beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}$. Os vetores de suporte são as observações com $y_i f(\boldsymbol{x}_i) = M$, e $\mathcal{S}$ é o conjunto dos seus índices. Admita que, para observações separáveis com as duas classes presentes, o problema tem solução, e seja $M^* > 0$ o valor ótimo. As notas afirmam, sem demonstrar, que essa solução depende apenas dos vetores de suporte; Tiago quer a demonstração e quer saber o que ela lhe dá.

(a) Mostre que a solução é única. (Se houvesse duas soluções com vetores $\boldsymbol{\beta}$ diferentes, compare-as com o ponto médio entre elas. Se tivessem o mesmo $\boldsymbol{\beta}$, olhe, como funções de β_0, o menor valor de $y_i f(\boldsymbol{x}_i)$ em cada classe.)

(b) Seja $i_0 \notin \mathcal{S}$. Mostre que o classificador de margem máxima das $n-1$ observações sem a observação i_0 é o mesmo das n observações. (Se o valor ótimo sem i_0 fosse maior que M^*, combine a solução nova com a antiga, com peso pequeno na nova.) Mostre também que deslocar $\boldsymbol{x}_{i_0}$ para qualquer ponto $\boldsymbol{x}'$ com $y_{i_0} f(\boldsymbol{x}') > M^*$, em que f é a função da solução, não muda o classificador.

(c) A estimativa do risco por validação cruzada com uma observação deixada de fora (LOOCV) é a proporção das observações i que o classificador ajustado sem i classifica errado. Mostre que, para o classificador de margem máxima, ela é no máximo $|\mathcal{S}|/n$.

(d) Tiago ajusta o classificador a 60 peças e encontra 3 vetores de suporte. O que ele pode afirmar sobre a estimativa LOOCV sem fazer mais nenhum ajuste? Ele refaz os 60 ajustes e não encontra erro nenhum. Isso contradiz o item (c)? O que a cota não garante?

Exercício 8 — O *kernel* radial em qualquer dimensão. Júlia estuda matemática aplicada e lê nas notas que o *kernel* radial $k(\boldsymbol{x}, \boldsymbol{x}') = \exp(-\gamma \|\boldsymbol{x} - \boldsymbol{x}'\|^2)$, com $\gamma > 0$, é um *kernel* em $\mathbb{R}^p$; o exemplo das notas, porém, só exibe a função φ para $p = 1$. Ela decide provar o caso geral. Lembre que $k : \mathbb{R}^p \times \mathbb{R}^p \to \mathbb{R}$ é um *kernel* se existem um espaço de Hilbert $\mathcal{H}$ e uma função $\varphi : \mathbb{R}^p \to \mathcal{H}$ com $k(\boldsymbol{x}, \boldsymbol{x}') = \langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle_{\mathcal{H}}$ para todos $\boldsymbol{x}, \boldsymbol{x}'$, e que, pelo teorema visto em aula, isso acontece se e somente se k é simétrica e, para todo $n \geq 1$ e quaisquer $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n \in \mathbb{R}^p$, a matriz $\left[k(\boldsymbol{x}_i, \boldsymbol{x}_j)\right]_{i,j=1}^n$ é positiva semidefinida. Use à vontade que o produto interno $\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$ e as funções constantes iguais a $c \geq 0$ são *kernels*, e que a soma de dois *kernels* e o produto de um *kernel* por uma constante $c \geq 0$ também são.

(a) Mostre que, se k_1 e k_2 são *kernels*, o produto $k(\boldsymbol{x}, \boldsymbol{x}') = k_1(\boldsymbol{x}, \boldsymbol{x}')\, k_2(\boldsymbol{x}, \boldsymbol{x}')$ também é. (Escreva uma das duas matrizes pela decomposição espectral.)

(b) Mostre que, se k é um *kernel* e $h : \mathbb{R}^p \to \mathbb{R}$ é uma função qualquer, então $h(\boldsymbol{x})\, h(\boldsymbol{x}')\, k(\boldsymbol{x}, \boldsymbol{x}')$ é um *kernel*. Mostre também que $e^{k(\boldsymbol{x}, \boldsymbol{x}')}$ é um *kernel*, usando a série da exponencial e o fato de que um limite de matrizes positivas semidefinidas é positivo semidefinido.

(c) Conclua que o *kernel* radial é um *kernel* em $\mathbb{R}^p$, para todo p e todo $\gamma > 0$. (Escreva $\|\boldsymbol{x} - \boldsymbol{x}'\|^2$ em termos de $\|\boldsymbol{x}\|^2$, $\|\boldsymbol{x}'\|^2$ e $\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$.)

(d) Mostre que, para todo *kernel*, $\|\varphi(\boldsymbol{x}) - \varphi(\boldsymbol{x}')\|_{\mathcal{H}}^2 = k(\boldsymbol{x}, \boldsymbol{x}) - 2\, k(\boldsymbol{x}, \boldsymbol{x}') + k(\boldsymbol{x}', \boldsymbol{x}')$, e calcule essa distância para o *kernel* radial. Conclua que φ leva $\mathbb{R}^p$ na esfera unitária de $\mathcal{H}$ e que pontos distintos ficam, em $\mathcal{H}$, a distância menor que $\sqrt{2}$. Para dois pontos à distância 1 em $\mathbb{R}^p$, calcule a distância em $\mathcal{H}$ com $\gamma = 0{,}5$ e com $\gamma = 50$, e interprete o resultado em termos da flexibilidade da SVM.

Exercício 9 — O ou exclusivo. Mariana estuda engenharia e quer que um classificador linear preveja quando uma lâmpada acende. A lâmpada tem duas chaves, $x_1, x_2 \in \{0, 1\}$, e acende ($y = +1$) quando exatamente uma delas está ligada; com as duas desligadas ou as duas ligadas,

fica apagada ($y = -1$). As quatro observações são $(0,0)$ e $(1,1)$, na classe -1, e $(1,0)$ e $(0,1)$, na classe $+1$. Lembre que observações $(\boldsymbol{z}_i, y_i)$ de $\mathbb{R}^q$ são linearmente separáveis se existe $(\beta_0, \boldsymbol{\beta})$, com $\boldsymbol{\beta} \neq \mathbf{0}$, tal que $y_i(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{z}_i) > 0$ para todo i, e que, nesse caso, o classificador de margem máxima é dado pela solução de

$$\max_{\beta_0,\, \boldsymbol{\beta},\, M} \; M \quad \text{sujeito a} \quad \|\boldsymbol{\beta}\| = 1 \quad \text{e} \quad y_i\,(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{z}_i) \geq M \;\; \text{para todo } i.$$

(a) Suponha que algum ponto $\boldsymbol{z} \in \mathbb{R}^q$ seja combinação convexa de observações da classe $+1$ e também combinação convexa de observações da classe -1. Mostre que as observações não são linearmente separáveis. Por que isso vale, em particular, quando uma observação de uma classe está no interior de um triângulo formado por observações da outra?

(b) Mostre que as quatro observações de Mariana não são linearmente separáveis.

(c) Mariana segue a primeira ideia das notas para obter fronteiras não lineares: acrescenta os quadrados e trabalha com as covariáveis (x_1, x_2, x_1^2, x_2^2). Mostre que as observações continuam não separáveis nesse espaço ampliado.

(d) Ela troca os quadrados pelo produto e usa as três covariáveis $\boldsymbol{z} = (x_1,\, x_2,\, x_1x_2)$. Mostre que $f(\boldsymbol{z}) = 2z_1 + 2z_2 - 4z_3 - 1$ satisfaz $y_i f(\boldsymbol{z}_i) = 1$ nas quatro observações. Mostre que o classificador de margem máxima nesse espaço é o hiperplano $f(\boldsymbol{z}) = 0$, com $M = 1/\sqrt{24} \approx 0{,}204$, e que as quatro observações são vetores de suporte. (Para a cota superior, multiplique as restrições das observações $(0,0)$, $(1,1)$, $(1,0)$ e $(0,1)$ pelos pesos 8, 4, 6 e 6, some e use a desigualdade de Cauchy–Schwarz.) Que fronteira esse hiperplano define no plano (x_1, x_2)?

Aula 10 — KNN e Árvores de Classificação

Exercício 10 — O voto dos vizinhos. Otávio é agrônomo e usa o KNN para classificar os talhões de uma fazenda em atacados por uma praga ($Y = 1$) ou não ($Y = 0$), a partir de medidas de solo e de clima. Num talhão novo, com covariáveis $\boldsymbol{x}$, a probabilidade de praga é $\eta(\boldsymbol{x}) = \mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x}) = 0{,}6$. O KNN estima essa probabilidade pela proporção de vizinhos com praga, $\widehat{P} = \frac{1}{k}\sum_{j=1}^{k} Y_{(j)}$, em que $Y_{(1)}, \ldots, Y_{(k)}$ são os rótulos dos k vizinhos de $\boldsymbol{x}$ no treino, e declara praga quando $\widehat{P} > 1/2$. Tome k ímpar, para que não haja empate. Para isolar o papel de k, suponha que os rótulos dos vizinhos sejam independentes entre si e do rótulo Y do talhão novo, e que, nos itens (a) e (b), cada um seja igual a 1 com probabilidade 0,6, como se todos os vizinhos estivessem no próprio $\boldsymbol{x}$.

(a) Mostre que $\mathbb{E}[\widehat{P}] = 0{,}6$ e $\mathrm{Var}(\widehat{P}) = 0{,}24/k$.

(b) Seja $q_k = \mathbb{P}(\widehat{P} > 1/2)$. Mostre que a probabilidade de o KNN errar o talhão novo é $0{,}6 - 0{,}2\,q_k$. Calcule q_5 e, usando $q_1 = 0{,}600$, $q_{15} \approx 0{,}787$ e $q_{51} \approx 0{,}926$, a probabilidade de erro para $k = 1, 5, 15$ e 51. Use a desigualdade de Chebyshev para mostrar que $q_k \to 1$ e que a probabilidade de erro tende a 0,4. Que classificador erra com probabilidade 0,4 nesse talhão?

(c) Na fazenda real, só os 9 talhões de treino mais próximos de $\boldsymbol{x}$ têm $\eta = 0{,}6$; do décimo vizinho em diante, eles vêm de uma região em que a probabilidade de praga é 0,2. Mantida a independência, a tabela dá q_k e a probabilidade de erro no talhão novo:

k	1	5	9	15	25	51
q_k	0,6000	0,6826	0,7334	0,3037	0,0381	0,0001
erro	0,4800	0,4635	0,4533	0,5393	0,5924	0,6000

Calcule $\mathbb{E}[\widehat{P}]$ para $k > 9$ e use a desigualdade de Chebyshev para explicar por que a probabilidade de erro se aproxima de 0,6 quando k cresce. Que k Otávio deveria escolher para este talhão? O que os itens (b) e (c), juntos, dizem sobre o papel de k?

(d) Mostre que, com $k = 1$ e uma probabilidade η qualquer no lugar de 0,6, a probabilidade de erro é $2\eta(1-\eta)$, e que $\min(\eta, 1-\eta) \le 2\eta(1-\eta) \le 2\min(\eta, 1-\eta)$. Interprete. O que acontece no outro extremo, com $k = n$?

Exercício 11 — Crescer com Gini, podar com o erro. Rafael é analista numa operadora de planos de saúde e cresceu uma árvore de classificação, com o índice de Gini, para prever quais beneficiários serão internados no próximo ano ($Y = 1$). Agora vai podá-la. Para uma região R com n_R observações de treino, sejam $n_{R,c}$ o número delas na classe c e $\widehat{p}_{R,c} = n_{R,c}/n_R$. A folha R prediz a classe majoritária, e $E(R) = 1 - \max_c \widehat{p}_{R,c}$ é o seu erro de classificação, de modo que $n_R E(R) = n_R - \max_c n_{R,c}$ é o número de erros de treino na folha. Na poda por custo-complexidade com o erro de classificação, escolhe-se, entre as subárvores T da árvore crescida, a que minimiza

$$C_\alpha(T) = \sum_{m=1}^{|T|} n_m E(R_m) + \alpha\,|T|\,,$$

em que $R_1, \ldots, R_{|T|}$ são as folhas de T, $n_m = n_{R_m}$ e $|T|$ é o número de folhas; o valor de $\alpha > 0$ é escolhido por validação cruzada.

(a) Seja R uma região dividida em regiões disjuntas $R_1, \ldots, R_L$. Mostre que $\sum_l n_{R_l} E(R_l) \le n_R E(R)$, com qualquer número de classes, e que vale a igualdade quando uma mesma classe c^* é majoritária em todas as R_l; nesse caso, c^* é majoritária também em R.

(b) Mostre que, para todo $\alpha > 0$, nenhuma subárvore que minimize C_α tem um nó interno cujas folhas descendentes predigam todas a mesma classe.

(c) Na árvore de Rafael, um nó com 400 beneficiários, dos quais 100 foram internados, foi dividido em dois filhos de 200, com 20 e com 80 internados. Calcule a redução do índice de Gini ponderado, $G(R) - [n_1 G(R_1) + n_2 G(R_2)]/n_R$, e a redução do erro de classificação ponderado. Por que o crescimento fez essa divisão, e o que a poda fará com ela?

(d) A operadora estima que deixar de prever uma internação custa quatro vezes mais que prever uma que não acontece: $\ell_0 = 4$ e $\ell_1 = 1$. Cada folha passa a prever internação quando a sua proporção de internados passa de $\ell_1/(\ell_0 + \ell_1)$, e o custo da folha é $\ell_1\,\mathrm{FP} + \ell_0\,\mathrm{FN}$ nas suas observações de treino. Calcule o custo do nó do item (c) antes e depois da divisão. Se a poda usar esse custo no lugar do número de erros, para que valores de α a divisão sobrevive? O que isso diz sobre podar pelo erro de classificação?

Exercício 12 — Quando Gini e entropia discordam. Ana é bióloga e usa uma árvore de classificação para distinguir mudas de duas espécies, a espécie 1 e a espécie 0, a partir de características medidas no viveiro. Num nó com 12 mudas, 6 de cada espécie, a árvore compara duas divisões:

A pela altura, separa dois grupos de 6 mudas, um com 2 da espécie 1 e 4 da espécie 0 e outro com 4 da espécie 1 e 2 da espécie 0;

B por uma mancha rara na folha, isola uma única muda, da espécie 0, das outras 11, que têm 6 da espécie 1 e 5 da espécie 0.

Numa região com proporção p de mudas da espécie 1, o índice de Gini é $G(p) = 2p(1-p)$, a entropia é $D(p) = -p\log_2 p - (1-p)\log_2(1-p)$, com $0\log_2 0 = 0$, e o erro de classificação é $E(p) = \min(p, 1-p)$. Uma divisão em regiões com n_1 e n_2 mudas e proporções p_1 e p_2 tem impureza ponderada $[n_1 I(p_1) + n_2 I(p_2)]/(n_1 + n_2)$, para cada medida I, e a árvore escolhe a divisão de menor impureza ponderada.

(a) Calcule a impureza ponderada das divisões A e B pelas três medidas e diga qual divisão cada medida escolhe. *Dados:* $\log_2 3 \approx 1{,}5850$, $\log_2 5 \approx 2{,}3219$ e $\log_2 11 \approx 3{,}4594$.

(b) Seja ϕ uma medida de impureza qualquer para duas classes, com $\phi(p) = \phi(1-p)$, $\phi(0) = 0$ e $\phi(6/11) > 0$. Mostre que A tem impureza ponderada menor que B se e somente se $\phi(1/3)/\phi(6/11) < 11/12$. Calcule essa razão para as três medidas e explique que propriedade da curva da entropia a leva a escolher B.

(c) No exemplo dos slides, o `DecisionTreeClassifier` é ajustado com `min_samples_leaf=5`, que só admite divisões com pelo menos 5 observações em cada filho. O que acontece com a divisão B, e as medidas continuam discordando? Qual das duas divisões você preferiria, e por quê? As notas dizem que o Gini e a entropia quase sempre escolhem as mesmas divisões; o que este exemplo diz sobre esse "quase"?