Lista de Revisão

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aulas 07 a 10 — Classificadores Gaussianos, Métricas, SVM, KNN e Árvores de Classificação

---

Salvo indicação em contrário, $(\boldsymbol{X}, Y)$ é um vetor aleatório com $\boldsymbol{X} \in \mathbb{R}^p$ e Y num conjunto finito $\mathcal{C}$ de classes; no caso binário, $\mathcal{C} = \{0, 1\}$, a classe $Y = 1$ é a positiva e $\eta(\boldsymbol{x}) = \mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x})$. A perda é a 0–1, com risco $R(g) = \mathbb{P}\big(Y \neq g(\boldsymbol{X})\big)$, e a amostra de treino $\mathcal{D} = \{(\boldsymbol{X}_i, Y_i)\}_{i=1}^{n}$ é i.i.d. Nos exercícios sobre SVM, as classes são codificadas por $y \in \{-1, +1\}$.

Aula 07 — Classificação e Classificadores Gaussianos

Exercício 1. Renata é atuária numa seguradora e quer classificar os segurados de um ramo em dois perfis, $Y = 1$ (risco alto) e $Y = 0$ (risco baixo), a partir de uma única covariável: o tempo X, em anos, entre a contratação da apólice e o primeiro sinistro. Ela hesita entre a análise discriminante linear (LDA) e a regressão logística, dois métodos que chegam a uma fronteira linear por caminhos diferentes. Ao longo do exercício, $\sigma(u) = e^u/(1 + e^u)$ é a função logística, log é o logaritmo natural e $\pi_c = \mathbb{P}(Y = c)$.

(a) Comece pelo caso geral, com p covariáveis: suponha que $\boldsymbol{X} \in \mathbb{R}^p$ e que, como no LDA, $\boldsymbol{X} \mid Y = c \sim N(\boldsymbol{\mu}_c, \boldsymbol{\Sigma})$ para $c \in \{0, 1\}$, com $\boldsymbol{\Sigma}$ simétrica e positiva definida. Mostre que $\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x}) = \sigma(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x})$ e escreva β_0 e $\boldsymbol{\beta}$ em função de π_0, π_1, $\boldsymbol{\mu}_0$, $\boldsymbol{\mu}_1$ e $\boldsymbol{\Sigma}$. Conclua que, sob as hipóteses do LDA, o modelo da regressão logística vale exatamente. (Escreva $\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x})$ pelo Teorema de Bayes, com f_c a densidade de $\boldsymbol{X}$ dado $Y = c$, divida o numerador e o denominador por $\pi_1 f_1(\boldsymbol{x})$ e ponha o resultado na forma $\sigma(u(\boldsymbol{x}))$. Depois, substitua as densidades normais em $u(\boldsymbol{x})$, expanda as duas formas quadráticas e observe o que se cancela porque a covariância é a mesma nas duas classes.)

(b) Os tempos de Renata não se parecem com uma normal: são positivos e muito assimétricos. Suponha agora que $X \mid Y = c$ tenha distribuição exponencial de taxa λ_c, com densidade $\lambda_c e^{-\lambda_c x}$ para $x > 0$, com $\lambda_0 = 1$, $\lambda_1 = 3$ e $\pi_0 = \pi_1 = 1/2$: em média, o primeiro sinistro do perfil de risco alto chega três vezes mais cedo. Mostre que $\mathbb{P}(Y = 1 \mid X = x) = \sigma(\log 3 - 2x)$ para $x > 0$. O modelo da regressão logística vale nesta população, isto é, existem constantes β_0 e β_1 com $\mathbb{P}(Y = 1 \mid X = x) = \sigma(\beta_0 + \beta_1 x)$ para todo $x > 0$? As hipóteses do LDA, de que X é normal em cada classe e tem a mesma variância nas duas, valem?

Exercício 2. Lucas é analista de crédito e quer prever a inadimplência, $Y = 1$, a partir da renda mensal X_1 do cliente, em milhares de reais. Na população de clientes, $X_1 \mid Y = 1 \sim N(3, 1)$ e $X_1 \mid Y = 0 \sim N(5, 1)$. Ao juntar duas bases, Lucas fica, sem perceber, com a renda duas vezes: em X_1, em milhares de reais, e em $X_2 = 1000\, X_1$, em reais. Ele ajusta um Bayes ingênuo gaussiano às duas colunas. Para separar o erro do modelo do erro de estimação, suponha que a amostra é tão grande que o ingênuo usa as distribuições verdadeiras de X_1 e de X_2 em cada classe. Seja

$$L(x_1) = \log \frac{f_1(x_1)}{f_0(x_1)}$$

a razão de log-verossimilhanças da renda, em que f_c é a densidade de X_1 dado $Y = c$ e log é o logaritmo natural, e sejam $\pi_c = \mathbb{P}(Y = c)$ e $\sigma(u) = e^u/(1 + e^u)$.

(a) Mostre que $L(x_1) = 8 - 2x_1$. Mostre que, num cliente com renda x_1, o *log-odds* verdadeiro é $\log(\pi_1/\pi_0) + L(x_1)$ e o calculado pelo ingênuo é $\log(\pi_1/\pi_0) + 2L(x_1)$.

(b) Suponha $\pi_0 = \pi_1 = 1/2$ e seja $\eta = \mathbb{P}(Y = 1 \mid X_1 = x_1)$. Mostre que a probabilidade calculada pelo ingênuo é $\widehat{P} = \eta^2/(\eta^2 + (1-\eta)^2)$. Conclua que ela ordena os clientes como η, que classifica cada um como o classificador de Bayes, e que $\left|\widehat{P} - 1/2\right| > |\eta - 1/2|$ sempre que $\eta \notin \{0, 1/2, 1\}$. Calcule $\widehat{P}$ para $\eta = 0{,}6$ e para $\eta = 0{,}8$.

(c) Na carteira de Lucas, porém, só 20% dos clientes são inadimplentes: $\pi_1 = 0{,}2$. Determine as rendas que o classificador de Bayes classifica como inadimplentes e as que o ingênuo classifica assim, e mostre que as duas decisões diferem num intervalo de rendas. Calcule a probabilidade de um cliente cair nesse intervalo e diga qual das duas decisões erra mais nele. *Dados:* $\log 2 \approx 0{,}6931$, $\Phi(-1{,}3466) \approx 0{,}0891$, $\Phi(-1{,}6931) \approx 0{,}0452$, $\Phi(0{,}6534) \approx 0{,}7433$ e $\Phi(0{,}3069) \approx 0{,}6205$, em que Φ é a função de distribuição da normal padrão.

(d) Se a renda aparecesse em m colunas, todas proporcionais a X_1, o que aconteceria com o *log-odds* do ingênuo? E com a sua decisão quando $m \to \infty$? Resuma o que o exercício mostra sobre o Bayes ingênuo com covariáveis redundantes: o que ele preserva e o que ele estraga.

Aula 08 — Métricas para Classificação

Exercício 3. Diego é analista antifraude num banco e tem dois sistemas que já foram avaliados, A e B. Tome a fraude como a classe positiva, $Y = 1$. As taxas de falsos positivos e de verdadeiros positivos são $(\mathrm{FPR}, \mathrm{TPR}) = (0{,}02;\ 0{,}50)$ para A e $(0{,}08;\ 0{,}80)$ para B. O banco aceita mandar para revisão manual no máximo 5% das transações legítimas, e nenhum dos dois sistemas aproveita esse limite: A fica abaixo dele e B o ultrapassa. Diego então propõe sortear: para cada transação, uma moeda com probabilidade λ de dar cara, lançada independentemente de tudo o mais, escolhe se a decisão será a de A (cara) ou a de B (coroa). Seja g_λ esse classificador.

(a) Mostre que $\mathrm{FPR}(g_\lambda) = \lambda\,\mathrm{FPR}(A) + (1-\lambda)\,\mathrm{FPR}(B)$ e que o mesmo vale para a TPR, isto é, que o ponto de g_λ no plano (FPR, TPR) está no segmento que liga os pontos de A e de B. Determine λ para que a taxa de falsos positivos seja exatamente 0,05 e calcule a taxa de verdadeiros positivos obtida. Que classificadores sorteados dão os pontos da diagonal?

(b) Um terceiro sistema, C, tem $(\mathrm{FPR}, \mathrm{TPR}) = (0{,}70;\ 0{,}40)$. Mostre que o classificador que inverte todas as decisões de C tem o ponto $(0{,}30;\ 0{,}60)$ e, em geral, que inverter as decisões leva $(\mathrm{FPR}, \mathrm{TPR})$ a $(1-\mathrm{FPR}, 1-\mathrm{TPR})$. Se um escore tem curva ROC abaixo da diagonal, com área $\mathrm{AUC} < 1/2$, qual é a curva e qual é a área do escore com o sinal trocado?

(c) Com custos ℓ_0 por falso negativo e ℓ_1 por falso positivo, o custo esperado de um classificador g é $R_\ell(g) = \ell_1 \mathbb{P}(g(\boldsymbol{X}) = 1, Y = 0) + \ell_0 \mathbb{P}(g(\boldsymbol{X}) = 0, Y = 1)$. Mostre que $R_\ell(g_\lambda) = \lambda R_\ell(A) + (1-\lambda) R_\ell(B)$ e conclua que, sem a restrição do banco, sortear nunca custa menos que o melhor dos dois sistemas. Para que serve, então, o sorteio?

Exercício 4. Cecília é médica e coordena o rastreamento de uma doença que atinge 1% da população: $\mathbb{P}(Y = 1) = 0{,}01$, com $Y = 1$ para doente. O exame disponível tem resultado $X \in \{0, 1\}$ e, seguindo o resultado (isto é, declarando doente quem tem $X = 1$), detecta 90% dos doentes e dá alarme falso para 10% dos saudáveis: $\mathbb{P}(X = 1 \mid Y = 1) = 0{,}9$ e $\mathbb{P}(X = 1 \mid Y = 0) = 0{,}1$. Seja $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$.

(a) Calcule $\eta(1)$ e $\eta(0)$.

(b) Determine o classificador de Bayes, o que minimiza a probabilidade de erro. Compare a probabilidade de erro dele com a do classificador que segue o exame. Um colega conclui que o exame não serve para nada. O que há de errado nessa conclusão?

(c) Sejam ℓ_0 o custo de deixar passar um doente e ℓ_1 o de um alarme falso, e $r = \ell_0/\ell_1$. Lembre que o classificador que declara doente quando $\eta(x) > \ell_1/(\ell_0+\ell_1)$ minimiza o custo esperado. Mostre que esse classificador segue o exame, isto é, declara doente exatamente quem tem $X = 1$, se e somente se $11 < r \leq 891$, e diga o que ele faz fora dessa faixa. Para $\ell_0 = 20$ e $\ell_1 = 1$, calcule o custo esperado de declarar todos saudáveis, de seguir o exame e de declarar todos doentes, numa população de 10 000 pessoas.

Aula 09 — Máquinas de Vetores de Suporte

Exercício 5. Tiago trabalha no controle de qualidade de uma fábrica e classifica peças em boas ($y = +1$) e defeituosas ($y = -1$) a partir de p medidas. As suas n observações de treino $(\boldsymbol{x}_i, y_i)$ são linearmente separáveis, e cada classe tem pelo menos duas observações. O classificador de margem máxima é dado pela solução do problema

$$\max_{\beta_0,\,\boldsymbol{\beta},\,M} \; M \quad \text{sujeito a} \quad \sum_{j=1}^{p} \beta_j^2 = 1 \quad \text{e} \quad y_i\,(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) \geq M, \quad i = 1, \ldots, n.$$

Defina $f(\boldsymbol{x}) = \beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}$. Os vetores de suporte são as observações com $y_i f(\boldsymbol{x}_i) = M$, e $\mathcal{S}$ é o conjunto dos seus índices. Admita que, para observações separáveis com as duas classes presentes, o problema tem solução, e seja $M^* > 0$ o valor ótimo. Durante as aulas afirmamos, sem demonstrar, que essa solução depende apenas dos vetores de suporte. Este exercício pretende elucidar esse resultado.

(a) Mostre que a solução é única. (Se houvesse duas soluções com vetores $\boldsymbol{\beta}$ diferentes, compare-as com o ponto médio entre elas. Se tivessem o mesmo $\boldsymbol{\beta}$, olhe, como funções de β_0, o menor valor de $y_i f(\boldsymbol{x}_i)$ em cada classe.)

(b) Seja $i_0 \notin \mathcal{S}$. Mostre que o classificador de margem máxima das $n-1$ observações sem a observação i_0 é o mesmo das n observações. (Se o valor ótimo sem i_0 fosse maior que M^*, combine a solução nova com a antiga, com peso pequeno na nova.) Mostre também que deslocar $\boldsymbol{x}_{i_0}$ para qualquer ponto $\boldsymbol{x}'$ com $y_{i_0} f(\boldsymbol{x}') > M^*$, em que f é a função da solução, não muda o classificador.

(c) A estimativa do risco por validação cruzada com uma observação deixada de fora (LOOCV) é a proporção das observações i que o classificador ajustado sem i classifica errado. Mostre que, para o classificador de margem máxima, ela é no máximo $|\mathcal{S}|\,/n$.

Exercício 6. Júlia estuda matemática aplicada e lê nas notas que o *kernel* radial $k(\boldsymbol{x}, \boldsymbol{x}') = e^{-\gamma\|\boldsymbol{x}-\boldsymbol{x}'\|^2}$, com $\gamma > 0$, é um *kernel* em $\mathbb{R}^p$; e decide tentar demonstrar o resultado. Lembre que $k : \mathbb{R}^p \times \mathbb{R}^p \to \mathbb{R}$ é um *kernel* se existem um espaço de Hilbert $\mathcal{H}$ e uma função $\varphi : \mathbb{R}^p \to \mathcal{H}$ com $k(\boldsymbol{x}, \boldsymbol{x}') = \langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle_{\mathcal{H}}$ para todos $\boldsymbol{x}, \boldsymbol{x}'$, e que, pelo teorema visto em aula, isso acontece se e somente se k é simétrica e, para todo $n \geq 1$ e quaisquer $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n \in \mathbb{R}^p$, a matriz $\big[k(\boldsymbol{x}_i, \boldsymbol{x}_j)\big]_{i,j=1}^{n}$ é positiva semidefinida. Use à vontade que o produto interno $\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$ e as funções constantes iguais a $c \geq 0$ são *kernels*, e que a soma de dois *kernels* e o produto de um *kernel* por uma constante $c \geq 0$ também são.

(a) Mostre que, se k_1 e k_2 são *kernels*, o produto $k(\boldsymbol{x}, \boldsymbol{x}') = k_1(\boldsymbol{x}, \boldsymbol{x}')\, k_2(\boldsymbol{x}, \boldsymbol{x}')$ também é. (Escreva uma das duas matrizes pela decomposição espectral.)

(b) Mostre que, se k é um *kernel* e $h : \mathbb{R}^p \to \mathbb{R}$ é uma função qualquer, então $h(\boldsymbol{x})\, h(\boldsymbol{x}')\, k(\boldsymbol{x}, \boldsymbol{x}')$ é um *kernel*. Mostre também que $e^{k(\boldsymbol{x},\boldsymbol{x}')}$ é um *kernel*, usando a série da exponencial e o fato de que um limite de matrizes positivas semidefinidas é positivo semidefinido.

(c) Conclua que o *kernel* radial é um *kernel* em $\mathbb{R}^p$, para todo p e todo $\gamma > 0$. (Escreva $\|\boldsymbol{x} - \boldsymbol{x}'\|^2$ em termos de $\|\boldsymbol{x}\|^2$, $\|\boldsymbol{x}'\|^2$ e $\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$.)

Aula 10 — KNN e Árvores de Classificação

Exercício 7. Otávio é agrônomo e usa o KNN para classificar os talhões de uma fazenda em atacados por uma praga ($Y = 1$) ou não ($Y = 0$), a partir de medidas de solo e de clima. Num talhão novo, com covariáveis $\boldsymbol{x}$, a probabilidade de praga é $\eta(\boldsymbol{x}) = \mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x}) = 0{,}6$. O KNN estima essa probabilidade pela proporção de praga entre os k talhões de treino mais próximos de $\boldsymbol{x}$, cujos índices formam o conjunto $\mathcal{N}_{\boldsymbol{x}}^{(k)}$,

$$\widehat{P} = \frac{1}{k} \sum_{i \in \mathcal{N}_{\boldsymbol{x}}^{(k)}} Y_i,$$

e declara praga quando $\widehat{P} > 1/2$. Tome k ímpar, para que não haja empate. Para isolar o papel de k, suponha que os rótulos dos vizinhos sejam independentes entre si e do rótulo Y do talhão novo, e que cada um seja igual a 1 com probabilidade 0,6, como se todos os vizinhos estivessem no próprio $\boldsymbol{x}$.

(a) Mostre que $\mathbb{E}[\widehat{P}] = 0{,}6$ e $\mathrm{Var}(\widehat{P}) = 0{,}24/k$.

(b) Seja $q_k = \mathbb{P}(\widehat{P} > 1/2)$. Mostre que a probabilidade de o KNN errar o talhão novo é $0{,}6 - 0{,}2\, q_k$. Calcule q_5 e, usando $q_1 = 0{,}600$, $q_{15} \approx 0{,}787$ e $q_{51} \approx 0{,}926$, a probabilidade de erro para $k = 1, 5, 15$ e 51. Use a desigualdade de Chebyshev para mostrar que $q_k \to 1$ e que a probabilidade de erro tende a 0,4. Que classificador erra com probabilidade 0,4 nesse talhão?

(c) Mostre que, com $k = 1$ e uma probabilidade η qualquer no lugar de 0,6, a probabilidade de erro é $2\eta(1 - \eta)$, e que $\min(\eta, 1 - \eta) \le 2\eta(1 - \eta) \le 2 \min(\eta, 1 - \eta)$. Interprete. O que acontece no outro extremo, com $k = n$?

Exercício 8. Rafael é analista numa operadora de planos de saúde e cresceu uma árvore de classificação, com o índice de Gini, para prever quais beneficiários serão internados no próximo ano ($Y = 1$). Agora vai podá-la. Para uma região R com n_R observações de treino, sejam $n_{R,c}$ o número delas na classe c e $\widehat{p}_{R,c} = n_{R,c}/n_R$; o índice de Gini de R é $G(R) = \sum_c \widehat{p}_{R,c}(1 - \widehat{p}_{R,c})$. A folha R prediz a classe majoritária, e $E(R) = 1 - \max_c \widehat{p}_{R,c}$ é o seu erro de classificação, de modo que $n_R E(R) = n_R - \max_c n_{R,c}$ é o número de erros de treino na folha. Na poda por custo-complexidade com o erro de classificação, escolhe-se, entre as subárvores T da árvore crescida, a que minimiza

$$C_\alpha(T) = \sum_{m=1}^{|T|} n_m E(R_m) + \alpha\, |T|\,,$$

em que $R_1, \ldots, R_{|T|}$ são as folhas de T, $n_m = n_{R_m}$ e $|T|$ é o número de folhas; o valor de $\alpha > 0$ é escolhido por validação cruzada.

(a) Seja R uma região dividida em regiões disjuntas $R_1, \ldots, R_L$. Mostre que $\sum_l n_{R_l} E(R_l) \le n_R E(R)$, com qualquer número de classes, e que vale a igualdade quando uma mesma classe c^* é majoritária em todas as R_l; nesse caso, c^* é majoritária também em R.

(b) Mostre que, para todo $\alpha > 0$, nenhuma subárvore que minimize C_α tem um nó interno cujas folhas descendentes predizem todas a mesma classe.

(c) Na árvore de Rafael, um nó R com 400 beneficiários, dos quais 100 foram internados, foi dividido em dois filhos de 200, que são folhas da árvore crescida: R_1, com 20 internados, e R_2, com 80. Calcule a redução do índice de Gini ponderado, $G(R) - [n_1 G(R_1) + n_2 G(R_2)]/n_R$, e a redução do erro de classificação ponderado. Por que o crescimento fez essa divisão, e o que a poda fará com ela?

Exercício 9. Ana é bióloga e usa uma árvore de classificação para distinguir mudas de duas espécies, a espécie 1 e a espécie 0, a partir de características medidas no viveiro. Num nó com 12 mudas, 6 de cada espécie, a árvore compara duas divisões:

A pela altura, separa dois grupos de 6 mudas, um com 2 da espécie 1 e 4 da espécie 0 e outro com 4 da espécie 1 e 2 da espécie 0;

B por uma mancha rara na folha, isola uma única muda, da espécie 0, das outras 11, que têm 6 da espécie 1 e 5 da espécie 0.

Numa região com proporção p de mudas da espécie 1, o índice de Gini é $G(p) = 2p(1-p)$, a entropia é $D(p) = -p\log_2 p - (1-p)\log_2(1-p)$, com $0\log_2 0 = 0$, e o erro de classificação é $E(p) = \min(p, 1-p)$. Uma divisão em regiões com n_1 e n_2 mudas e proporções p_1 e p_2 tem impureza ponderada $[n_1 I(p_1) + n_2 I(p_2)]/(n_1 + n_2)$, para cada medida I, e a árvore escolhe a divisão de menor impureza ponderada.

(a) Calcule a impureza ponderada das divisões A e B pelas três medidas e diga qual divisão cada medida escolhe. *Dados:* $\log_2 3 \approx 1{,}5850$, $\log_2 5 \approx 2{,}3219$ e $\log_2 11 \approx 3{,}4594$.

(b) Seja I uma medida de impureza qualquer para duas classes, com $I(p) = I(1-p)$, $I(0) = 0$ e $I(6/11) > 0$. Mostre que A tem impureza ponderada menor que B se e somente se $I(1/3)/I(6/11) < 11/12$. Calcule essa razão para as três medidas e explique que propriedade da curva da entropia a leva a escolher B.