

Trabalho Prático 01 — Roteiro de Correção

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Atenção

Documento do professor. Os números das caixas de solução foram medidos no notebook de resolução, com as sementes do enunciado e o `scikit-learn` 1.9; outra versão, ou outra escolha razoável do aluno, desloca a terceira casa decimal e às vezes a segunda. O que se corrige é o *raciocínio* — a leitura do número, não o número.

O que é este trabalho

Ao longo do curso você viu cada método isolado, quase sempre em dados simulados, em que a resposta certa é conhecida. Neste trabalho a situação se inverte: dois conjuntos de dados reais, públicos, de áreas diferentes, e nenhuma resposta conhecida de antemão. O que se pede é o que se faz numa análise de verdade — entender os dados antes de modelar, montar um protocolo de avaliação honesto, comparar métodos com as ferramentas certas e, no fim, *chegar às suas próprias conclusões*.

O trabalho tem duas partes, uma de **regressão** e uma de **classificação**, e cada tarefa corresponde a uma ou mais aulas do curso. A maior parte do código de que você precisa já apareceu nas aulas práticas; o que é novo aqui é juntar as peças e decidir, em cada passo, *por que* fazer assim.

Ideia central: o que vale nota

Um número sem justificativa não será considerado. Quando uma tarefa pergunta “por quê?”, “o que isso significa?” ou “compare”, a resposta é um texto curto, em português, numa célula de *markdown* logo abaixo do código — e é esse texto que recebe a maior parte da nota. Um resultado errado com uma leitura honesta (“esperava X , obtive Y , e desconfio de Z ”) vale mais do que um resultado certo sem explicação nenhuma.

1 Regras de entrega

1. Um **único notebook** TP01_<nome>.ipynb, com as duas partes. Use o `Trabalho pratico 01 - modelo.ipynb` como ponto de partida: ele já carrega os dados e tem uma seção por tarefa.
2. O notebook deve **rodar do início ao fim sem erro** com *Kernel* $\rightarrow$ *Restart & Run All*, com os dois `.csv` na mesma pasta dele, sem baixar nada da internet. Em um computador comum, a execução completa deve levar no máximo uns 20 minutos: se passar disso, reduza grades ou o número de árvores e diga que reduziu.
3. **Bibliotecas**: `numpy`, `pandas`, `matplotlib`, `scipy` e `scikit-learn`, esta na versão 1.6 ou mais nova (o `GroupKFold` de `R2` usa o parâmetro `shuffle`, que só existe a partir dela). Nada de outras bibliotecas de aprendizado de máquina.
4. **Reprodutibilidade**: use as sementes do enunciado onde ele as fixa, e fixe você mesmo (`random_state` ou `np.random.default_rng`) toda outra aleatoriedade.

5. **O conjunto de teste de cada parte deve ser usado uma única vez**, nas tarefas R8 e C7. Toda escolha anterior — de modelo, de hiperparâmetro, de corte — é feita por validação cruzada *dentro do treino*. Usar o teste antes disso para escolher qualquer coisa invalida a tarefa correspondente.
6. **Gráficos** com eixos rotulados e unidades. **Tabelas** com poucas casas decimais — três ou quatro algarismos significativos bastam.
7. O trabalho é **individual**. Pode (e deve) reaproveitar código das aulas práticas e das listas; o que se exige é que cada resposta escrita seja sua.

Distribuição dos pontos. Parte I, 4,5 pontos; Parte II, 4,5 pontos; **qualidade do notebook**, 1,0 ponto — roda do começo ao fim, está organizado por tarefa, explica *antes* de cada bloco de código o que ele vai fazer, tem gráficos legíveis, etc.

Critério de correção (sugestão)

Qualidade (1,0). 0,3 roda sem erro do começo ao fim (se para num erro pontual e o resto é coerente, 0,15); 0,3 organização por tarefa e texto antes do código; 0,2 gráficos e tabelas legíveis; 0,2 teste tocado só em R8 e C7. Quem escolheu modelo, hiperparâmetro ou corte olhando o teste perde esses 0,2 e a nota da tarefa em que fez a escolha.

2 Os dados

Os dois conjuntos são do *UCI Machine Learning Repository* (<https://archive.ics.uci.edu>), um dos repositórios públicos de dados mais usados em aprendizado de máquina; os dois também estão no Kaggle. Ambos são distribuídos sob a licença CC BY 4.0. Os arquivos que você recebe são os originais, convertidos de planilha para **.csv sem limpeza nenhuma**: só os nomes das colunas do concreto foram traduzidos, e a resposta do crédito foi renomeada para **default**. Tudo o que houver de estranho nos dados está lá de propósito — ou melhor, está lá porque dados reais são assim.

2.1 Parte I — **concreto.csv**: resistência do concreto à compressão

Fonte. I.-C. Yeh (1998), “Modeling of strength of high-performance concrete using artificial neural networks”, *Cement and Concrete Research* 28(12), 1797–1808. Repositório UCI, *Concrete Compressive Strength*, DOI [10.24432/C5PK67](https://doi.org/10.24432/C5PK67).

O problema. O concreto é o material mais usado na engenharia civil, e a sua resistência à compressão é a propriedade que define para que ele serve. Ela depende da *receita* — as quantidades de cimento, água, aditivos e agregados em um metro cúbico de mistura, o que os engenheiros chamam de **traço** — e da **idade**: o concreto continua ganhando resistência por meses depois de moldado. Medir a resistência exige moldar corpos de prova, esperar e rompê-los numa prensa, o que é caro e lento — a norma usual é esperar 28 dias. Um bom preditor permitiria estimar a resistência de um traço *novo* antes de ensaiá-lo.

As variáveis. São $n = 1030$ ensaios de laboratório, sem valores faltantes:

coluna	significado	unidade
cimento	cimento Portland	kg/m ³ de mistura
escoria	escória de alto-forno (subproduto siderúrgico)	kg/m ³
cinza_volante	cinza volante (subproduto de termelétricas)	kg/m ³
agua	água	kg/m ³
superplastificante	aditivo que dá fluidez com menos água	kg/m ³
agregado_graudo	brita	kg/m ³
agregado_miudo	areia	kg/m ³
idade	idade do corpo de prova no ensaio	dias (1 a 365)
resistencia	resposta: resistência à compressão	MPa

Um fato da engenharia que pode vir a ser útil: a **lei de Abrams** (1918) diz que, para os mesmos materiais, a resistência cai com a **razão água/cimento** — é a regra mais antiga e mais citada da dosagem de concreto.

2.2 Parte II — `credito.csv`: inadimplência no cartão de crédito

Fonte. I.-C. Yeh e C.-H. Lien (2009), “The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients”, *Expert Systems with Applications* 36(2), 2473–2480. Repositório UCI, *Default of Credit Card Clients*, DOI [10.24432/C55S3H](https://doi.org/10.24432/C55S3H).

O problema. São $n = 30\,000$ clientes de um banco de Taiwan, acompanhados de abril a setembro de 2005. Para cada um, sabe-se o limite de crédito, alguns dados cadastrais e o histórico dos últimos seis meses — se pagou em dia ou com atraso, quanto veio na fatura e quanto pagou. A resposta é se o cliente **ficou inadimplente no mês seguinte** (outubro de 2005). Os valores estão em dólares de Taiwan (NT\$).

coluna	significado
ID	número do cliente
LIMIT_BAL	limite de crédito concedido (NT\$), individual mais o da família
SEX	1 = masculino; 2 = feminino
EDUCATION	1 = pós-graduação; 2 = universidade; 3 = ensino médio; 4 = outros
MARRIAGE	1 = casado(a); 2 = solteiro(a); 3 = outros
AGE	idade (anos)
PAY_0, PAY_2, ..., PAY_6	situação do pagamento em setembro (PAY_0), agosto (PAY_2), ..., abril (PAY_6): -1 = pagou em dia; 1 = um mês de atraso; 2 = dois meses; ...; 9 = nove meses ou mais. (Não existe PAY_1: o nome é assim no original.)
BILL_AMT1, ..., BILL_AMT6	valor da fatura (NT\$) em setembro, agosto, ..., abril
PAY_AMT1, ..., PAY_AMT6	valor pago (NT\$) em setembro, agosto, ..., abril
default	resposta: 1 se ficou inadimplente em outubro, 0 se não

A descrição acima é a da documentação oficial. Você vai encontrar nos dados códigos que ela não descreve; tratá-los é parte da Tarefa C1.

3 Parte I — Regressão: a resistência do concreto (4,5 pontos)

R1. Conhecendo os dados

(0,6 ponto)

Antes de ajustar um modelo, vamos olhar para os dados.

- (a) Quantas observações e covariáveis há? O problema é de regressão ou de classificação?
- (b) Faça o histograma da resistência e os diagramas de dispersão da resistência contra a idade e contra a razão água/cimento. Qual das relações é mais visivelmente não linear? Em que idades os ensaios foram feitos?
- (c) Procure **linhas duplicadas**, contando as que repetem uma linha anterior (é o que o `duplicated()` do `pandas` conta): quantas repetem uma linha anterior por inteiro, e quantas repetem só as oito covariáveis (estas incluem aquelas)? Uma resistência medida em laboratório, igual a outra até a oitava casa decimal, é um segundo ensaio ou outra coisa? Decida o que fazer com as linhas inteiramente repetidas, **justifique**, e siga com essa decisão no resto da Parte I.
- (d) Um grupo de linhas com as mesmas oito covariáveis é um conjunto de **réplicas** — o mesmo experimento repetido —, desde que cada linha seja um ensaio de verdade. Com esses grupos dá para estimar o erro irreduzível $\sigma^2 = \text{Var}(Y \mid \mathbf{X} = \mathbf{x})$ sem modelo nenhum, pela variância combinada dentro dos grupos,

$$\hat{\sigma}^2 = \frac{\sum_g \sum_{i \in g} (Y_i - \bar{Y}_g)^2}{\sum_g (n_g - 1)},$$

em que g percorre os grupos, n_g é o tamanho do grupo e $\bar{Y}_g$ a sua média. Calcule $\hat{\sigma}^2$ com todos os grupos de linhas com as mesmas oito covariáveis, *antes* e *depois* da decisão do item (c), com os graus de liberdade $\sum_g (n_g - 1)$ de cada caso, e um intervalo de 95% para σ^2 supondo normalidade e variância constante. O que essa estimativa diz sobre o menor erro quadrático médio que *qualquer* preditor poderia atingir?

- (e) O mesmo **traço** (as sete quantidades de ingredientes) foi ensaiado em várias idades. Crie uma coluna que identifique o traço,

```
1 componentes = ["cimento", "escoria", "cinza_volante", "agua",
2               "superplastificante", "agregado_graudo", "agregado_miudo"]
3 concreto["traco"] = concreto.groupby(componentes).ngroup()
```

e conte: quantos traços distintos há, e quantas linhas por traço? Por que isso significa que as linhas da tabela *não* são observações independentes umas das outras?

Solução

- (a) $n = 1030$, $p = 8$, todas quantitativas e sem faltantes. A resposta é quantitativa — faz sentido uma “resistência média” —, então é regressão.
- (b) A idade é a relação mais não linear: sobe depressa nas primeiras semanas e quase estabiliza depois de 90 dias, o que sugere $\log(\text{idade})$. A razão água/cimento tem relação decrescente e razoavelmente monótona (Abrams). Os ensaios foram feitos em só 14 idades, de 1 a 365 dias; 28 dias tem 425 das 1030 linhas.
- (c) 25 linhas são idênticas a uma anterior, e 34 repetem as oito covariáveis. Uma medida contínua repetida até a oitava casa não é réplica: é registro duplicado. O esperado é remover as 25, ficando com $n = 1005$. (Manter e justificar — “não sei se são erros” — é aceitável, desde que a consequência para o item (d) seja discutida.)
- (d) Com as duplicatas: 19 grupos, 34 graus de liberdade, $\hat{\sigma}^2 = 25,1$, IC (16,4; 43,1). Sem elas: 9 grupos, 9 graus de liberdade, $\hat{\sigma}^2 = 64,6$, IC (30,6; 215,5). Os zeros das duplicatas puxavam a estimativa para baixo e davam uma falsa precisão; o que sobra é praticamente inútil — um intervalo que vai de 31 a 215. A leitura correta: o piso do risco existe ($\mathbb{E}[\text{Var}(Y \mid \mathbf{X})]$), mas estes dados quase não o identificam; e, com variância

não constante, as poucas réplicas nem representariam todas as regiões do espaço. (Na Tarefa R8 os melhores modelos ficam com EQM de validação em torno de 35, compatível com o intervalo.)

(e) 428 traços para 1005 linhas; 246 traços aparecem uma vez e 77 aparecem cinco vezes. Linhas do mesmo traço compartilham a receita — e o que quer que tenha acontecido no preparo daquela mistura —, então não são independentes: o traço é a unidade, a linha é uma medida repetida dela.

Critério de correção (sugestão)

0,1 por item, e 0,2 no (d). No (c), a nota vem da justificativa: remover sem dizer por quê vale metade; contar todas as linhas envolvidas (36 e 53, em vez de 25 e 34), dizendo que contou assim, também vale. No (d), exigir os dois cálculos e a leitura de que 9 graus de liberdade não sustentam conclusão; o intervalo pode ser qualquer um corretamente justificado.

R2. Protocolo de avaliação

(0,4 ponto)

A pergunta que queremos responder é: *qual a resistência de um traço que ainda não foi ensaiado?*

(a) Separe o conjunto de teste **por traço**, exatamente assim:

```
1 import sklearn.model_selection as skm
2 X = concreto[componentes + ["idade"]]
3 y = concreto["resistencia"]
4 separa = skm.GroupShuffleSplit(n_splits=1, test_size=0.25, random_state=2026)
5 i_tr, i_te = next(separa.split(X, y, groups=concreto["traco"]))
```

O `X` tem só as oito covariáveis originais: a coluna `traco` identifica o grupo, não é covariável. Quantas linhas e quantos traços ficaram em cada lado? Confira que nenhum traço aparece nos dois.

(b) Por que separar por traço, e não por linha com `train_test_split`? Que tipo de vazamento — grave ou leve — a separação por linha produziria, e para qual pergunta ela seria, ao contrário, a separação certa?

(c) Toda escolha de hiperparâmetro da Parte I será feita por validação cruzada de 5 dobras **em grupo**, dentro do treino, passando `groups=` os traços do treino:

```
1 dobras = skm.GroupKFold(n_splits=5, shuffle=True, random_state=0)
```

Reporte sempre o risco estimado como **média ± erro-padrão** das cinco dobras. O que esse erro-padrão mede, e o que ele *não* mede?

Solução

(a) 321 traços e 756 linhas no treino, 107 traços e 249 linhas no teste (a proporção de 25% é de traços, não de linhas); nenhum traço em comum.

(b) Com a separação por linha, o mesmo traço, ensaiado em outra idade, ficaria no treino e no teste — “a mesma unidade dos dois lados”, um vazamento **grave**, que nenhum *pipeline* conserta. O teste mediria o acerto em traços já conhecidos. A separação por linha seria a certa para outra pergunta: prever a resistência de um traço já ensaiado, numa idade que ainda não foi.

(c) O erro-padrão mede a variabilidade entre as cinco dobras — quanto a estimativa

dependeria de quais traços caíram em cada uma. Não mede a variabilidade da amostra inteira (outro conjunto de 428 traços), e é otimista mesmo como medida da primeira coisa, porque as dobras compartilham treino e as cinco estimativas não são independentes.

Critério de correção (sugestão)

0,1 no (a); 0,2 no (b) — 0,1 por nomear o vazamento, 0,1 por identificar a pergunta para a qual a separação por linha serviria; 0,1 no (c). No (c), aceitar a resposta sem a ressalva da dependência entre dobras, desde que diga o que o EP mede.

R3. Modelos lineares e regularização

(0,9 ponto)

- Estime o risco do **preditor constante** (a média do treino, `DummyRegressor`) e do **MQO** nas oito covariáveis originais. Some as sete colunas de ingredientes linha a linha: o que você observa? Calcule o número de condição de $\mathbb{X}^\top \mathbb{X}$ (com a coluna de uns) nas escalas original e padronizada. Com isso em mente, faz sentido ler o coeficiente da água como “o efeito de aumentar a água em 1 kg/m³ mantendo as outras covariáveis fixas”?
- Troque a idade por $\log(\text{idade})$ e acrescente a razão água/cimento — duas covariáveis construídas, nove ao todo — e reestime o risco do MQO. Por que o modelo continua sendo uma regressão *linear*? De onde veio o ganho, em termos de viés e variância?
- Sobre as covariáveis de (b), faça a expansão polinomial de grau 2 (`PolynomialFeatures`) e ajuste MQO, Ridge e Lasso, com a padronização *dentro* do *pipeline*. Escolha o λ do Ridge e o do Lasso por validação cruzada numa grade logarítmica e mostre a curva do risco estimado contra λ , com barras de um erro-padrão. Aplique também a **regra de um erro-padrão**. Quantos coeficientes o Lasso zera em cada escolha? Faça o gráfico do caminho de regularização do Lasso.
- Por que foi preciso padronizar antes do Ridge e do Lasso, e não antes do MQO? O λ escolhido para o Ridge e o escolhido para o Lasso podem ser comparados diretamente no `scikit-learn`?

Solução

- Constante: $250,5 \pm 21,7$. MQO original: $105,4 \pm 5,6$. Os sete ingredientes somam quase o mesmo valor em toda linha (média 2339, desvio 63,8 kg/m³) — é a massa de um metro cúbico de concreto. Com o intercepto, as colunas ficam quase linearmente dependentes: número de condição $1,0 \times 10^{10}$ na escala original, 72 padronizado (a padronização resolve a parte numérica, não a colinearidade de fundo). “Aumentar a água mantendo o resto fixo” descreve uma mistura que muda de volume — que não existe; aumentar a água é, na prática, diminuir outra coisa. O coeficiente é uma comparação entre misturas que diferem em tudo, e não um efeito causal.
- $51,5 \pm 3,4$: o risco cai à metade. O modelo continua linear *nos parâmetros*; as covariáveis é que são funções dos dados. O ganho é de **viés**: a classe de funções passou a conter formas (crescimento logarítmico, efeito da razão) que a reta nas covariáveis originais não alcançava, com só um parâmetro a mais.
- Com 54 covariáveis: MQO $53,7 \pm 7,9$; Ridge $43,8 \pm 4,3$ no mínimo ($\alpha \approx 4$) e $46,7 \pm 3,5$ pela regra 1-EP ($\alpha \approx 63$); Lasso $44,7 \pm 5,3$ no mínimo ($\alpha \approx 0,012$, 37 de 54 coeficientes não nulos) e $49,6 \pm 3,6$ pela regra 1-EP ($\alpha \approx 0,18$, 23 não nulos). A expansão sozinha piora o MQO por variância; a penalização recupera. Leituras esperadas: a regra 1-EP troca pouco risco por um modelo bem mais simples; o λ que melhor prediz não é o que

melhor seleciona.

(d) A penalização soma β_j^2 ou $|\beta_j|$, que dependem da unidade da covariável; o MQO é equivariante (a predição não muda). E não: o **Ridge** minimiza $\|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \alpha \|\boldsymbol{\beta}\|^2$ e o **Lasso**, $\frac{1}{2n} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \alpha \|\boldsymbol{\beta}\|_1$ — há um fator $2n$ entre as escalas de α .

Critério de correção (sugestão)

(a) 0,25 — 0,05 pelos riscos, 0,1 pela soma e pelo número de condição, 0,1 pela leitura do coeficiente. (b) 0,15. (c) 0,35 — 0,1 pela validação sem vazamento (padronização no *pipeline*, dobras em grupo), 0,1 pelas curvas, 0,1 pela regra 1-EP e contagem de zeros, 0,05 pelo caminho. (d) 0,15. Grades que param na borda (o λ escolhido é o menor ou o maior da grade) sem comentário perdem 0,05. No erro-padrão da regra 1-EP, o desvio das cinco dobras pode ter divisor 5 (o `std_test_score` do `GridSearchCV`) ou 4 (o da solução): no Lasso, a regra escolhe $\alpha \approx 0,14$ num caso e 0,18 no outro, e os dois valem.

R4. Validação cruzada, LOOCV e *bootstrap*

(0,6 ponto)

Use o MQO com as covariáveis de R3(b).

- Implemente à mão a validação cruzada em grupo, dobra a dobra, com as dobras de R2(c). As dobras têm o mesmo tamanho? Calcule o risco pela média *simples* dos cinco EQM e pela média *ponderada* pelo tamanho das dobras (a fórmula das notas de aula), e compare com o `cross_val_score`.
- Calcule o LOOCV de duas formas: com n ajustes, e pelo atalho da *leverage* h_{ii} , com um único ajuste. Confira que coincidem. O LOOCV fica acima ou abaixo da validação em grupo? Por quê, e qual dos dois responde à pergunta de R2?
- Estime o erro-padrão de cada coeficiente de três formas: pela fórmula clássica, a raiz da diagonal de $\hat{\sigma}^2(\mathbb{X}^\top \mathbb{X})^{-1}$, com $\hat{\sigma}^2 = \text{RSS}/(n - p - 1)$; por *bootstrap* das **linhas**; e por *bootstrap* dos **traços** — sorteando traços inteiros, com reposição, e levando todas as linhas de cada traço sorteado. Use $B = 2000$ e o gerador `np.random.default_rng(2026)`. Compare as três colunas. Qual reamostragem imita o jeito como os dados foram coletados?

Solução

- Não: 160, 150, 153, 147 e 146 linhas, porque os traços têm tamanhos diferentes. Média simples 51,526 (igual ao `cross_val_score`, que faz a média não ponderada); ponderada 51,429. A diferença é pequena, e existe porque as duas fórmulas só coincidem quando as dobras têm o mesmo tamanho.
- Atalho e explícito coincidem até a sexta casa decimal: 49,360332. O LOOCV fica *abaixo* da validação em grupo (51,53): ao deixar uma linha de fora, as outras idades do mesmo traço continuam no treino, e o modelo “já conhece” aquela receita. O LOOCV responde a “prever um ensaio novo de um traço conhecido”; a pergunta de R2 é a da validação em grupo. Para o MQO, com 10 parâmetros, a diferença é pequena — o modelo quase não consegue decorar traços.
- Para $\log(\text{idade})$: 0,218, 0,220 e 0,304; para a razão água/cimento: 2,10, 2,31 e 3,45. O *bootstrap* das linhas reproduz aproximadamente a fórmula clássica (e é um pouco maior, porque não supõe variância constante); o dos traços dá erros-padrão de 1,4 a 1,6 vez os do *bootstrap* das linhas, e de 1,4 a 2,1 vezes os da fórmula clássica, conforme o coeficiente. Os dados foram coletados por traço — cada receita, ensaiada em várias idades —, e a reamostragem que imita isso é a dos traços. As outras duas tratam as linhas como independentes e subestimam a incerteza.

Critério de correção (sugestão)

(a) 0,2; (b) 0,2 — 0,1 pela igualdade, 0,1 pela comparação com a validação em grupo; (c) 0,2 — 0,1 pelos três cálculos, 0,1 pela leitura. Implementar o *bootstrap* dos traços errado (sorteando linhas dentro de traços, por exemplo) vale metade do (c) se a leitura estiver certa.

R5. Métodos não paramétricos: KNN**(0,5 ponto)**

- (a) Ajuste o KNN com as covariáveis padronizadas, escolhendo k de 1 a 30 por validação cruzada, e mostre a curva do risco estimado contra k . Qual k foi escolhido? Ajuste também o KNN *sem* padronizar, com o mesmo k , e explique a diferença (pense em quanto cada covariável pesa na distância, com e sem padronização).

Solução

(a) A validação escolhe $k = 1$ ($57,3 \pm 4,1$), e a curva cresce com k (a menos de uma oscilação desprezível em $k = 14$) — com poucos traços parecidos entre si, o vizinho mais próximo é o único que ajuda. (O mesmo acontece com as covariáveis construídas: $55,4$.) Sem padronizar, com o mesmo $k = 1$, o risco sobe para $74,1 \pm 3,2$. Sem padronização, cada covariável pesa na distância em proporção à sua variância: o cimento responde por 29% dela, e a água e o superplastificante, que variam poucas dezenas de kg, por 1% e 0,1% — a água, que a lei de Abrams põe no centro, quase some da distância. Padronizadas, as oito pesam o mesmo. (Com $k = 5$ a diferença é bem menor, 88,0 contra 85,4, como mostra a tabela de R7.)

Critério de correção (sugestão)

0,25 pela curva e pela escolha de k ; 0,25 pela explicação do que a padronização muda na distância.

R6. Árvores, *bagging* e florestas**(0,5 ponto)**

- (a) Ajuste uma árvore de regressão cheia e calcule o seu erro de treino e o seu risco estimado. Depois, faça a poda por custo-complexidade, escolhendo o `ccp_alpha` por validação cruzada. Desenhe a árvore com profundidade 3 (`plot_tree`) e interprete os três primeiros cortes.
- (b) Ajuste o *bagging* e florestas aleatórias com m (`max_features`) de 1 a 8. Mostre o risco estimado contra m . Qual é o padrão de `max_features` no `RandomForestRegressor`, e o que isso quer dizer? Use o piso ρv da variância para explicar a forma da curva.
- (c) Mostre o risco estimado da floresta escolhida contra o número de árvores B , de 1 a algumas centenas. Por que B não é escolhido por validação cruzada como m ?

Solução

(a) A árvore cheia tem 740 folhas e erro de treino 0,05 — não é zero porque as réplicas, com as mesmas covariáveis e respostas diferentes, não podem ser separadas —, e risco estimado $56,4 \pm 2,8$. A poda escolhe um α pequeno (320 folhas) e quase não ajuda: $55,9 \pm 2,5$. O primeiro corte é na idade, em 21 dias, e os dois seguintes são no cimento: em 386 kg/m^3 entre os corpos de prova de até 21 dias e em $357,5 \text{ kg/m}^3$ entre os mais velhos. A idade vem primeiro porque é o corte que mais separa as resistências — um concreto jovem ainda

não chegou à resistência que terá —, e nos dois ramos mais cimento dá mais resistência.

(b) De 47,3 ($m = 1$) o risco cai até 35,5 ($m = 5$) e fica praticamente plano até o *bagging* ($m = 8$: 36,3); todas as diferenças de $m = 3$ em diante estão dentro de um erro-padrão (cerca de 4,3). O padrão do `RandomForestRegressor` é `max_features=1.0`, isto é, todas as covariáveis: é *bagging*, e não floresta. Com $m = 1$ as árvores ficam descorrelacionadas mas fracas demais (o v e o viés sobem mais do que o ρ cai); com $p = 8$ covariáveis, das quais poucas dominam, há pouco a descorrelacionar.

(c) De 87,9 com uma árvore o risco desce a 38,6 com 10, 35,9 com 50 e estaciona em 35,2–35,5 de 100 a 400. Aumentar B só reduz o termo $(1 - \rho)v/B$, e não há superajuste em B : basta um B grande o bastante.

Critério de correção (sugestão)

(a) 0,2 — 0,1 pelos números e pela poda, 0,1 pela interpretação da árvore; (b) 0,2 — inclui dizer que o padrão é *bagging*; (c) 0,1.

R7. Sensibilidade à escala

(0,5 ponto)

(a) Suponha que os mesmos dados chegassem com a idade em **horas**, e não em dias: crie uma cópia das covariáveis de treino com a coluna **idade** multiplicada por 24, sem mexer em mais nada. Estime o risco dos seis modelos abaixo, todos nas oito covariáveis originais, *duas vezes*: com a idade em dias e com a idade em horas. Use a validação cruzada em grupo de R2(c) e mantenha fixos os hiperparâmetros — nada é reescolhido na segunda estimativa.

- o MQO;
- o Lasso com `alpha=1`, com as covariáveis padronizadas dentro do *pipeline*;
- o KNN com $k = 5$, sem padronizar;
- o mesmo KNN, com as covariáveis padronizadas dentro do *pipeline*;
- a árvore podada de R6(a), com o `ccp_alpha` escolhido lá;
- a floresta de R6(b), com o m escolhido lá.

Monte uma tabela com uma linha por modelo e uma coluna para cada unidade. Quais riscos mudaram com a troca de unidade, e quais ficaram iguais? Explique, modelo a modelo, por que a unidade da idade afeta ou não o resultado.

Solução

(a) Só o KNN sem padronizar muda: de 88,0 para 63,4. MQO (105,4), Lasso com `alpha=1` (119,3), KNN padronizado (85,4), árvore e floresta ficam praticamente idênticos (o KNN padronizado oscila na terceira casa decimal, de 85,352 para 85,351). O MQO é equivariante à escala; o Lasso e o KNN padronizados absorvem a mudança no `StandardScaler`; árvore e floresta comparam valores dentro de cada coluna. O KNN cru é o único que enxerga a unidade — e aqui melhora por acaso, porque em horas a idade (a covariável mais informativa) passa a dominar a distância. Quem decidiu foi a unidade de medida, não o analista.

Critério de correção (sugestão)

0,25 pela tabela dos doze riscos; 0,25 pela explicação, modelo a modelo, de quem muda e por quê. Não é preciso usar nenhuma classificação dos métodos: basta dizer, de cada um, por que a unidade não o afeta (ou afeta).

R8. Escolha final e teste

(0,5 ponto)

- (a) Monte uma tabela com o risco estimado ($\pm$ erro-padrão) de pelo menos um modelo de cada família: constante, linear regularizado, KNN, árvore e floresta. Escolha **um** modelo final e justifique — a regra de um erro-padrão pode entrar no argumento.
- (b) Reajuste o modelo escolhido em *todo* o treino e meça, **uma vez**, o EQM no teste, com um intervalo de 95% para o risco. O EQM de teste ficou acima ou abaixo da estimativa da validação cruzada?
- (c) Só agora, calcule o EQM de teste dos outros finalistas — para leitura, sem trocar a escolha. Os intervalos se sobrepõem? Algum modelo foi muito pior no teste do que a validação previa? Investigue os maiores erros dele: as covariáveis dessas observações estão dentro do intervalo visto no treino?
- (d) Em um parágrafo, tente explicar para alguém que não fez este curso: o que o modelo consegue prever, com que erro típico (em MPa), e em que situação você não confiaria nele.

Solução

(a) Na validação: floresta ($m = 5$) $35,5 \pm 4,5$, *bagging* $36,3 \pm 4,5$, Ridge grau 2 43,8, Lasso 44,7, MQO com covariáveis construídas 51,5, KNN e árvore 55–57, constante 250. Floresta e *bagging* empatam dentro de um erro-padrão, e nenhum modelo mais simples fica a menos de um erro-padrão do mínimo (a Ridge de grau 2, com 43,8, passa do limite $35,5 + 4,5 = 40,0$): a regra de um erro-padrão não troca a escolha. A resolução fica com a floresta, o menor risco estimado; o *bagging*, bem justificado, também é aceitável.

(b) Floresta no teste: EQM 45,8, IC (31,9; 59,7). O EQM ficou *acima* da estimativa da validação cruzada (35,5), mas o intervalo contém o 35,5: o teste não desmente a validação, e a diferença cabe na variabilidade de sortear 107 traços. Quem quiser ir além acha a causa na variância da resistência, 310,6 no teste contra 248,2 no treino: uma razão de 1,25, quase a mesma com que a floresta piora (1,29). O teste é mais difícil, e não há sinal de superajuste.

(c) No teste, com a meia largura do intervalo de 95% depois do $\pm$: *bagging* $50,0 \pm 14,8$, Lasso 1-EP $50,0 \pm 11,8$, MQO construído $56,4 \pm 12,3$, KNN $65,4 \pm 15,6$, árvore $92,7 \pm 25,0$: os intervalos dos bons modelos se sobrepõem, e o teste não os distingue. Quem foi muito pior do que a validação previa é a árvore podada: 55,9 na validação e 92,7 no teste, uma razão de 1,66, contra 1,01 a 1,38 dos outros finalistas. Os seis maiores erros dela, que somam 24% do EQM, são de dois traços do teste com a mesma receita-base (água 228, os mesmos agregados, cimento e escória somando 380 kg/m^3), ensaiados de 180 a 365 dias — e as covariáveis estão todas *dentro* do intervalo do treino: não é extrapolação. A árvore põe os nove ensaios desses dois traços numa folha com só três linhas do treino, de outros traços, todas de 28 dias e com cinza volante, de média 23,5 MPa, quando eles resistem de 48 a 56 MPa. Os dois traços do treino com a mesma receita-base ficaram do outro lado de um corte na escória ($\leq 97,5$), em folhas que preveem de 41 a 52 MPa. É a instabilidade da árvore: um único corte, numa região com poucos traços, decide a vizinhança. A única extrapolação do teste é um traço (5 linhas) com agregado miúdo (992,6) acima do máximo do treino (945), e a floresta não sofre com ele: sem essas 5 linhas, o EQM dela é 46,5, praticamente o mesmo.

(d) Algo como: “o modelo prevê a resistência de um concreto com uma receita que ainda não foi ensaiada, e erra tipicamente uns 7 MPa, para mais ou para menos (a raiz do EQM de teste); não confiaria nele para receitas fora da faixa das que foram ensaiadas — por exemplo, com mais areia do que qualquer mistura dos dados —, nem para idades fora de 1 a 365 dias.”

Critério de correção (sugestão)

(a) 0,15; (b) 0,15 — o EQM com o intervalo, e a comparação com a validação lida à luz do intervalo, não só “ficou acima”; comparar as variâncias não é exigido, mas vale como justificativa; (c) 0,1 — exigir que o aluno identifique o modelo que mais piorou da validação para o teste e *investigue* os maiores erros dele; concluir, com os números, que as covariáveis estão dentro do intervalo do treino e que o problema é outro vale a nota cheia; (d) 0,1 — erro em MPa, não em MPa².

4 Parte II — Classificação: inadimplência no cartão de crédito (4,5 pontos)

C1. Conhecendo os dados

(0,4 ponto)

- (a) Qual a proporção de inadimplentes? Qual a acurácia do classificador que diz “ninguém fica inadimplente”? O que isso antecipa sobre a acurácia como métrica neste problema?
- (b) Tabele os valores de **SEX**, **EDUCATION**, **MARRIAGE** e **PAY_0**. Que códigos aparecem sem estar na documentação? Decida o que fazer com eles e justifique. Quais dessas colunas são nominais, e o que isso exige antes de usá-las num modelo que soma covariáveis? E o **ID**?
- (c) Os **PAY_*** misturam atrasos (1 a 9 meses, uma escala ordinal) com códigos (−2, −1, 0) que não são “quantidades de atraso”. Que problema isso cria para um modelo linear que usa **PAY_0** como número? Proponha uma alternativa.
- (d) Calcule a matriz de correlação das seis colunas **BILL_AMT**. Para qual dos classificadores generativos isso é uma má notícia, e por quê?
- (e) **SEX**, **AGE** e **MARRIAGE** são covariáveis disponíveis. Em uma linha: vê algum problema em usá-las para decidir quem recebe crédito? (Não é preciso retirá-las do modelo; é preciso pensar nisso.)

Solução

- (a) 22,12%; a acurácia de “ninguém” é 77,9%. Qualquer modelo tem de ser comparado com esse piso, e mesmo um bom modelo vai ganhar poucos pontos de acurácia (C4).
- (b) **EDUCATION** tem 0, 5 e 6 (345 clientes) e **MARRIAGE** tem 0 (54), não documentados; **PAY_0** tem −2 e 0, também não documentados. Juntar os códigos desconhecidos em “outros” é a escolha mais simples e defensável; tratá-los como faltantes também. **SEX** e **MARRIAGE** são nominais; **EDUCATION** tem ordem nos códigos 1 a 3, mas o “outros” a quebra, e tratá-la também como nominal é o mais simples (tratá-la como ordinal, dizendo o que se fez com o “outros”, também vale). As nominais precisam de *dummies* (**OneHotEncoder** num **ColumnTransformer**); usá-las como número impõe uma ordem e distâncias que não existem. O **ID** é identificador e sai: para um cliente novo ele não quer dizer nada. (A inadimplência varia entre os decis do **ID** mais do que o acaso explicaria — qui-quadrado 51,7 com 9 graus de liberdade —, mas sem tendência. O **ID** é a posição no arquivo, e o que ele captura é o jeito como o arquivo foi montado, não uma propriedade do cliente.)
- (c) Como número, **PAY_0** supõe que a diferença entre −2 e −1 é a mesma entre 1 e 2 meses de atraso, e que o efeito no *log-odds* é linear na escala. Alternativa: *dummies* por código (medido em C3: a AUC da logística vai de 0,719 para 0,765), ou uma indicadora “em atraso” mais o número de meses.
- (d) Correlações de 0,80 a 0,95. É má notícia para o **Bayes ingênuo**: ele trata seis colunas

que dizem quase a mesma coisa como seis testemunhas independentes, e as probabilidades saem extremas (medido em C4).

(e) Sim: decisão de crédito com base em sexo ou estado civil pode ser discriminatória, e é restrita por lei em muitos países — e retirar a coluna não basta se outras covariáveis a reproduzirem. Qualquer resposta que reconheça a questão vale a nota.

Critério de correção (sugestão)

0,1 em (a), (b) e (c); 0,05 em (d) e (e).

C2. Protocolo e custos

(0,4 ponto)

- (a) Separe o teste de forma estratificada, exatamente assim, e use estas dobras em toda validação cruzada da Parte II (os nomes com c evitam sobrescrever as variáveis da Parte I):

```
1 Xc_tr, Xc_te, yc_tr, yc_te = skm.train_test_split(
2     Xc, yc, test_size=0.25, stratify=yc, random_state=2026)
3 dobras_c = skm.StratifiedKFold(5, shuffle=True, random_state=0)
```

Por que estratificar aqui, se na Parte I a separação foi por grupo? Há alguma unidade repetida nestes dados?

- (b) O banco vai usar o modelo para decidir **quem contatar** com uma proposta de renegociação antes do vencimento. Contatar um cliente que pagaria de qualquer jeito custa $c_{FP} = 1$ (tempo da equipe, desconto concedido sem necessidade); deixar de contatar um cliente que vai ficar inadimplente custa $c_{FN} = 5$. Deduza o corte ótimo para a probabilidade verdadeira $\mathbb{P}(Y = 1 \mid \mathbf{x})$.
- (c) Calcule, no treino, o custo médio por cliente das duas regras triviais, “não contatar ninguém” e “contatar todos”. Qual delas é a referência a bater?

Solução

(a) A estratificação mantém a prevalência de 22,12% nos dois lados e nas dobras, o que estabiliza as métricas com classe desbalanceada. Aqui a unidade é o cliente e cada um aparece uma vez (35 linhas são idênticas em tudo menos no ID, provavelmente clientes sem movimento; não é o caso de agrupar).

(b) Prever 1 custa $c_{FP}(1 - \eta)$ em esperança; prever 0 custa $c_{FN}\eta$. Prever 1 quando $c_{FP}(1 - \eta) < c_{FN}\eta$, isto é, $\eta > c_{FP}/(c_{FP} + c_{FN}) = 1/6 \approx 0,167$.

(c) Ninguém: $5 \times 0,2212 = 1,106$ por cliente. Todos: $1 \times 0,7788 = 0,779$. A referência é “contatar todos” — e um modelo só vale a pena se ficar abaixo de 0,779.

Critério de correção (sugestão)

(a) 0,1; (b) 0,2 — a dedução, não só o número; (c) 0,1.

C3. Regressão logística e modelos generativos

(0,8 ponto)

Em toda esta parte, o pré-processamento (padronização das numéricas, *dummies* das nominais) mora dentro do *pipeline*.

- (a) Ajuste a regressão logística com `PAY_*` como número, escolhendo o `C` por validação cruzada com `scoring="neg_log_loss"`. Reporte a razão de chances e^{β_j} de `PAY_0`, de `LIMIT_BAL` e de `BILL_AMT1` e `BILL_AMT2`, e interprete as duas primeiras — atenção à escala em que os coeficientes estão. O que acontece com os sinais de `BILL_AMT1` e `BILL_AMT2`, e por que eles não devem ser lidos isoladamente?
- (b) Ajuste a mesma logística com os `PAY_*` em *dummies* e compare as duas pela AUC, fora da dobra (`cross_val_predict`).
- (c) Ajuste o Bayes ingênuo gaussiano, o LDA e o QDA. O QDA com o `reg_param` padrão ajusta? Leia a mensagem de erro, explique a causa, e escolha um `reg_param` por validação cruzada. Quantos parâmetros de covariância o LDA e o QDA estimam no seu p (depois das *dummies*)?
- (d) Faça o histograma de `LIMIT_BAL` e de `BILL_AMT1` em cada classe. Quais suposições dos modelos generativos são claramente falsas aqui? Isso os impede de classificar bem? (Guarde a pergunta; C4 responde.)

Solução

- (a) $C \approx 0,32$. Com as numéricas padronizadas, e^{β_j} é o fator na chance por **um desvio-padrão** a mais: `PAY_0`, 1,85 por DP ($\approx 1,12$ “unidades” de código) — quem atrasa mais tem uma chance quase duas vezes maior; `LIMIT_BAL`, 0,92 por DP ($\approx$ NT\$130 mil) — limite maior, chance um pouco menor, com o resto fixo. `BILL_AMT1` tem razão 0,64 e `BILL_AMT2`, 1,25: sinais opostos em duas colunas com correlação 0,95. É o efeito da colinearidade — o modelo contrasta as duas faturas, e “aumentar uma mantendo a outra fixa” é uma situação quase inexistente nos dados. Lê-se o par, não cada um.
- (b) AUC fora da dobra: 0,719 com `PAY_*` numérico e 0,765 com *dummies* ($C = 0,1$). A forma funcional estava errada, e a correção é de *covariáveis*, não de método.
- (c) Bayes ingênuo: AUC 0,726. LDA: 0,713. O QDA sem regularização levanta `LinAlgError`: “The covariance matrix of class 0 is not full rank”. As *dummies* de uma mesma variável somam (quase) uma constante e, dentro de uma classe, algumas colunas ficam constantes ou colineares; a covariância da classe é singular. Escolhido pelo *log-loss*, o mesmo critério do `C` da logística, numa grade até 0,99, o `reg_param` é 0,8: um mínimo no interior da grade (*log-loss* 0,604), com AUC 0,714. Pela AUC a escolha seria 0,3 (0,733); qualquer um dos dois critérios vale, desde que o aluno diga qual usou. Com $p = 28$ depois das *dummies*: $p(p+1)/2 = 406$ parâmetros de covariância no LDA e 812 no QDA.
- (d) As duas são muito assimétricas, positivas, com massa em zero (faturas nulas) e caudas longas; a normalidade dentro de cada classe é falsa, e a independência do Bayes ingênuo também (C1). Mesmo assim os três ordenam razoavelmente (AUC 0,71–0,73): classificar bem exige menos do que estimar bem as densidades. O preço aparece nas probabilidades, em C4.

Critério de correção (sugestão)

- (a) 0,25 — 0,1 pela interpretação por desvio-padrão (interpretar como “por unidade” com dados padronizados perde esses 0,1), 0,15 pela leitura do par de faturas; (b) 0,15; (c) 0,25 — 0,1 pela causa da recusa do QDA, 0,1 pelo `reg_param` escolhido por validação, 0,05 pela conta; (d) 0,15.

C4. Métricas, custos e calibração

(1,0 ponto)

Toda esta tarefa usa probabilidades **fora da dobra** no treino, e o teste continua guardado:

```

1 p = skm.cross_val_predict(modelo, Xc_tr, yc_tr, cv=dobras_c,
2                             method="predict_proba")[:, 1]

```

- (a) Para a logística com `PAY_*` em *dummies*, no corte 0,5: a matriz de confusão, a acurácia, a sensibilidade, a especificidade, a precisão, o VPN e o F_1 . Compare a acurácia com a de C1(a). Qual erro o modelo comete mais?
- (b) Sobreponha as curvas ROC e as curvas precisão–recall da logística de (a), do Bayes ingênuo e do LDA, com a AUC e a precisão média de cada um.
- (c) Compare a **calibração**: o score de Brier e a curva de calibração da logística e do Bayes ingênuo. Que fração das probabilidades do Bayes ingênuo passa de 0,99? Calibre-o com `CalibratedClassifierCV (method="isotonic")` e compare de novo. O que mudou na AUC, e o que mudou no Brier? Por quê?
- (d) Para cada modelo até aqui, calcule o custo médio por cliente no corte 1/6 de C2(b) e o menor custo possível varrendo o corte de 0,02 a 0,95. Em quais modelos o melhor corte fica perto de 1/6, e em quais fica longe? Relacione com o item (c).
- (e) Reajuste a logística com `class_weight="balanced"`. O que acontece com o Brier e com o custo no corte 1/6? Mostre que, se a reponderação multiplica a chance estimada por n_0/n_1 , o corte que corresponde a 1/6 no modelo reponderado é $[\frac{1}{5} \cdot \frac{n_0}{n_1}] / [1 + \frac{1}{5} \cdot \frac{n_0}{n_1}]$, calcule-o e confira com o melhor corte que você encontrou.

Solução

- (a) VN 16725, FP 798, FN 3248, VP 1729: acurácia 0,820 (contra 0,779 do trivial — quatro pontos), sensibilidade 0,347, especificidade 0,955, precisão 0,684, VPN 0,837, F_1 0,461. O erro dominante é o falso negativo: dois em cada três inadimplentes passam sem ser apontados no corte 0,5 — justamente o erro que custa 5.
- (b) AUC: logística 0,765, Bayes ingênuo 0,726, LDA 0,713; precisão média 0,536, 0,479 e 0,495 (referência: a prevalência, 0,221). A ROC da logística domina as outras em quase toda a extensão.
- (c) Brier: logística 0,137, Bayes ingênuo 0,335 — quase duas vezes e meia pior, com AUC comparável. 14,5% das probabilidades do ingênuo passam de 0,99 (e 11% ficam abaixo de 0,01); a curva de calibração dele é quase horizontal. Calibrado: Brier 0,145, AUC 0,729 — a AUC quase não se mexe, porque a calibração isotônica é monótona e preserva a ordem; o Brier cai porque os números passam a significar frequências. Classificar (ordenar) bem $\neq$ estimar bem probabilidades, e a causa é a correlação das faturas (C1d).
- (d) No corte 1/6 e no melhor corte: logística com *dummies* 0,580 e 0,579 (corte 0,16); Bayes ingênuo calibrado 0,618 e 0,617 (0,17); logística com `PAY_*` numérico 0,691 e 0,635 (0,23); LDA 0,690 e 0,638 (0,21); QDA 0,690 e 0,647 (0,31); Bayes ingênuo 0,701 e 0,622 (0,77). O corte teórico só é o ótimo quando as probabilidades são honestas: os modelos calibrados têm melhor corte em 1/6; os descalibrados, longe. E a logística com `PAY_*` numérico mostra que especificação errada também descalibra.
- (e) Brier 0,186 (piora) e custo em 1/6 de 0,755 — quase o de “contatar todos”. Com $n_0/n_1 = 3,52$, a chance 1/5 vira 0,704 e o corte equivalente é 0,413; o melhor corte medido é 0,40, com custo 0,579 — praticamente o da logística sem peso no corte 1/6, 0,580. Reponderar é mover o corte por outro caminho, e ao preço de estragar as probabilidades.

Critério de correção (sugestão)

(a) 0,15; (b) 0,15; (c) 0,3 — 0,1 pelas medidas, 0,1 pela calibração do ingênuo, 0,1 pela explicação de por que a AUC não muda; (d) 0,25 — a relação entre calibração e corte é o centro da tarefa; (e) 0,15 — 0,1 pela conta do corte equivalente. Custos calculados no teste, em vez de fora da dobra, zeram o (d).

C5. SVM**(0,5 ponto)**

O custo de treinar o SVC cresce entre n^2 e n^3 . Faça esta tarefa numa subamostra estratificada de 5000 clientes do treino:

```
1 i_sub = skm.train_test_split(np.arange(len(yc_tr)), train_size=5000,
2                             stratify=yc_tr, random_state=2026)[0]
```

- (a) Ajuste a SVM com *kernel* RBF, escolhendo **C** e **gamma** numa grade bidimensional por validação cruzada (`scoring="roc_auc"`), e a SVM linear. Mostre a tabela da grade. O ótimo ficou no interior dela?
- (b) Compare com a logística ajustada na *mesma* subamostra. Como a SVM não estima probabilidades, de onde vem a AUC dela?
- (c) Conte os vetores de suporte para alguns valores de **C**. No `scikit-learn`, o que se espera que aconteça com eles quando **C** cresce? Aconteceu? Explique o que viu pensando na sobreposição das classes.
- (d) Seria razoável usar o corte 1/6 de **C** nas “probabilidades” de `SVC(probability=True)`? Por quê?

Solução

- (a) Com **C** em $\{0,1; 1; 10; 100\}$ e **gamma** em $\{10^{-4}, \dots, 10^{-2}\}$, o ótimo é interior, perto de **C**= 10, **gamma**= 3×10^{-4} , $AUC \approx 0,748$; o linear fica em $\approx 0,74$. Uma grade que ponha o ótimo na borda precisa ser estendida.
- (b) A logística na mesma subamostra: $AUC \approx 0,753$ — a SVM não ganha. A AUC só precisa de um *score* que ordene, e a `decision_function` (a distância com sinal à fronteira) serve.
- (c) No `scikit-learn` **C** é o peso da penalidade: **C** maior tolera menos violações, a margem estreita, e espera-se *menos* vetores de suporte. Aqui eles ficam entre 2235 e 2336 de 5000 para qualquer **C**, e chegam a subir de **C**= 0,1 para **C**= 10. As classes se sobrepõem muito (o erro de Bayes aqui não é pequeno): todo ponto mal classificado é vetor de suporte, e os pontos dentro da margem também; com tanta sobreposição, quase metade da amostra está sempre nessa situação.
- (d) Não sem verificar: as “probabilidades” do SVC vêm de um ajuste de Platt *a posteriori*, feito por validação cruzada interna, e não do método. Se estiverem calibradas o corte vale; é preciso conferir (Brier, curva de calibração) antes de usá-lo.

Critério de correção (sugestão)

(a) 0,15; (b) 0,1; (c) 0,15 — a nota é da explicação, e não de o número de vetores ter caído; (d) 0,1.

C6. KNN, árvores e florestas**(0,6 ponto)**

- (a) Ajuste o KNN (padronizado, dentro do *pipeline*), escolhendo k ímpar por validação cruzada pela AUC. Por que o k escolhido é tão maior do que o da Parte I?

- (b) Ajuste árvores de classificação com Gini e com entropia, de profundidade 3: os cortes coincidem? Depois, faça a poda de uma árvore cheia por custo-complexidade, escolhendo o `ccp_alpha` por validação cruzada com `scoring="neg_log_loss"`. Desenhe a árvore de Gini de profundidade 3 e interprete o primeiro corte.
- (c) Ajuste florestas com $m = \sqrt{p}$ (o padrão do `RandomForestClassifier`), $m \approx p/3$ e $m = p$ (*bagging*), com `min_samples_leaf=5`, e uma com $m = \sqrt{p}$ e folhas cheias, isto é, com o `min_samples_leaf` padrão. Compare AUC e Brier. Opcional: o `AdaBoostClassifier` e o custo dele no corte 1/6.

Solução

- (a) A AUC sobe de 0,613 ($k = 1$) a 0,745 ($k = 101$) e fica plana (0,747–0,748) de $k = 151$ a 401; a busca escolhe $k = 301$, mas qualquer k nesse platô é equivalente. A escolha é grande porque o sinal é fraco e ruidoso (as classes se sobrepõem, n é grande), e estimar uma proporção local exige muitos vizinhos; na Parte I o sinal era forte e n , pequeno.
- (b) Os cortes das duas árvores de profundidade 3 coincidem quase todos (`PAY_0` ≤ 1,5, `PAY_2` ≤ 1,5, `PAY_AMT3` ≤ 664,5, ...), como era de esperar: as duas medidas de impureza são muito parecidas. A poda por *log-loss* deixa 14 folhas (AUC 0,751, contra 0,611 da cheia). O primeiro corte separa quem está com dois ou mais meses de atraso em setembro — o grupo de maior risco.
- (c) Com 200 árvores: $m = \sqrt{p}$, AUC 0,773 e Brier 0,1356; $m \approx p/3$, 0,772; *bagging*, 0,767; folhas cheias, 0,760 e Brier 0,1387 — folhas de uma observação dão probabilidades mais extremas. O AdaBoost ordena bem (AUC 0,771), mas as probabilidades dele ficam entre 0,22 e 0,67: no corte 1/6 ele contata todo mundo, com custo 0,779 — o mesmo da regra trivial (o corte por custo pode não cortar nada).

Critério de correção (sugestão)

- (a) 0,15; (b) 0,2; (c) 0,25. O AdaBoost é opcional e não soma pontos, mas uma boa leitura dele pode compensar até 0,1 perdido nesta tarefa.

C7. Escolha final e teste

(0,8 ponto)

- (a) Monte uma tabela, com probabilidades fora da dobra no treino, de todos os modelos: AUC, precisão média, Brier, custo no corte 1/6, melhor corte e custo nele. Escolha o modelo final *e* o corte, e justifique. Qual das colunas responde à pergunta do banco?
- (b) Reajuste o modelo escolhido em todo o treino e aplique-o **uma vez** ao teste, no corte escolhido: a matriz de confusão, o custo médio por cliente, a sensibilidade e a fração de clientes contatados. Compare com as regras triviais.
- (c) Faça um *bootstrap* **pareado** no teste ($B = 1000$, `np.random.default_rng(2026)`): em cada réplica, sorteie clientes com reposição e calcule, nos *mesmos* clientes, a diferença de AUC e a diferença de custo entre o seu modelo e a logística com `PAY_*` em *dummies*. Dê os intervalos de 95% (percentis). O seu modelo é melhor que a logística? Por que o *bootstrap* precisa ser pareado?
- (d) Em um parágrafo, para a gerente de risco: quantos clientes contatar, quantos inadimplentes isso pega, e o que se ganha em relação a contatar todos.

Solução

(a) Pelo custo no corte 1/6: floresta $m = \sqrt{p}$ 0,565, floresta $p/3$ 0,571, *bagging* 0,579, logística com *dummies* 0,580, árvore podada 0,586, KNN 0,598 — todos bem abaixo de 0,779. A coluna que responde ao banco é o custo; a AUC ordena modelos sem saber dos custos, e o Brier diz se o corte teórico é confiável. A floresta $m = \sqrt{p}$ tem o menor custo, e o melhor corte dela (0,16) coincide com o teórico — o que autoriza usar 1/6. A logística com *dummies*, a 0,015 de distância e muito mais interpretável, é uma escolha igualmente defensável.

(b) Floresta no teste, corte 1/6: VN 3632, FP 2209, FN 386, VP 1273. Custo médio 0,552 por cliente, contra 0,779 de contatar todos (29% menos); contata 46,4% dos clientes e pega 76,7% dos inadimplentes. AUC 0,787, Brier 0,134.

(c) AUC: floresta 0,787, logística 0,784, diferença com IC (−0,006; 0,012). Custo: floresta 0,552, logística 0,538, diferença com IC (−0,008; 0,035). Os dois intervalos contêm zero: o teste *não distingue* os dois modelos, e no custo a logística até ficou à frente nesta amostra. O *bootstrap* é pareado porque os dois modelos são avaliados nos mesmos clientes: os erros são correlacionados (clientes difíceis são difíceis para os dois), e a diferença tem variância muito menor do que a soma das variâncias. Reamostrar cada modelo separadamente jogaria fora essa correlação e produziria intervalos largos demais.

(d) “Contatando os clientes com probabilidade estimada de inadimplência acima de 1 em 6 (cerca de 17%) — uns 46% da carteira —, pegamos três de cada quatro que vão ficar inadimplentes, e o custo total cai cerca de 30% em relação a contatar todos. Um modelo mais simples, a regressão logística, faz praticamente o mesmo.”

Critério de correção (sugestão)

(a) 0,25 — a escolha do corte e a justificativa pelo custo; (b) 0,2; (c) 0,25 — 0,1 pelo cálculo pareado, 0,15 pela conclusão e pela explicação do pareamento; (d) 0,1. Não há modelo “certo”: a nota é da coerência entre a tabela, a escolha e a conclusão.

Para fechar

Se você chegou até aqui, percorreu o curso inteiro — risco, viés e variância, regularização, validação cruzada, métodos não paramétricos, árvores e florestas, *pipelines*, os classificadores generativos e discriminativos, as métricas, a SVM — em dados que ninguém inventou. Repare no que decidiu os resultados mais importantes: quase nunca foi a escolha do método. Foi olhar os dados antes (as duplicatas, o traço, os códigos do PAY), avaliar do jeito que responde à pergunta (por grupo, com o custo certo) e desconfiar dos números que pareciam bons demais. É isso que se leva deste curso.