

Trabalho Prático 01

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Instruções.

- O trabalho é **individual** e vale **10,0 pontos**; o valor de cada tarefa está indicado ao lado dela.
- Prazo de entrega: **a definir pelo professor**.
- Entrega: **um único notebook Jupyter** (.ipynb), com o código e as respostas escritas, nas regras da Seção 1.
- **Justifique todas as respostas**.

O que é este trabalho

Ao longo do curso você viu cada método isolado, quase sempre em dados simulados, em que a resposta certa é conhecida. Neste trabalho a situação se inverte: dois conjuntos de dados reais, públicos, de áreas diferentes, e nenhuma resposta conhecida de antemão. O que se pede é o que se faz numa análise de verdade — entender os dados antes de modelar, montar um protocolo de avaliação honesto, comparar métodos com as ferramentas certas e, no fim, *chegar às suas próprias conclusões*.

O trabalho tem duas partes, uma de **regressão** e uma de **classificação**, e cada tarefa corresponde a uma ou mais aulas do curso. A maior parte do código de que você precisa já apareceu nas aulas práticas; o que é novo aqui é juntar as peças e decidir, em cada passo, *por que* fazer assim.

Ideia central: o que vale nota

Um número sem justificativa não será considerado. Quando uma tarefa pergunta “por quê?”, “o que isso significa?” ou “compare”, a resposta é um texto curto, em português, numa célula de *markdown* logo abaixo do código — e é esse texto que recebe a maior parte da nota. Um resultado errado com uma leitura honesta (“esperava X , obtive Y , e desconfio de Z ”) vale mais do que um resultado certo sem explicação nenhuma.

1 Regras de entrega

1. **Um único notebook** TP01_<nome>.ipynb, com as duas partes. Use o **Trabalho pratico 01 - modelo.ipynb** como ponto de partida: ele já carrega os dados e tem uma seção por tarefa.
2. O notebook deve **rodar do início ao fim sem erro** com *Kernel* $\rightarrow$ *Restart & Run All*, com os dois **.csv** na mesma pasta dele, sem baixar nada da internet. Em um computador comum, a execução completa deve levar no máximo uns 20 minutos: se passar disso, reduza grades ou o número de árvores e diga que reduziu.
3. **Bibliotecas**: **numpy**, **pandas**, **matplotlib**, **scipy** e **scikit-learn**, esta na versão 1.6 ou mais nova (o **GroupKFold** de **R2** usa o parâmetro **shuffle**, que só existe a partir dela). Nada de outras bibliotecas de aprendizado de máquina.
4. **Reprodutibilidade**: use as sementes do enunciado onde ele as fixa, e fixe você mesmo (**random_state** ou **np.random.default_rng**) toda outra aleatoriedade.

5. **O conjunto de teste de cada parte deve ser usado uma única vez**, nas tarefas R8 e C7. Toda escolha anterior — de modelo, de hiperparâmetro, de corte — é feita por validação cruzada *dentro do treino*. Usar o teste antes disso para escolher qualquer coisa invalida a tarefa correspondente.
6. **Gráficos** com eixos rotulados e unidades. **Tabelas** com poucas casas decimais — três ou quatro algarismos significativos bastam.
7. O trabalho é **individual**. Pode (e deve) reaproveitar código das aulas práticas e das listas; o que se exige é que cada resposta escrita seja sua.

Distribuição dos pontos. Parte I, 4,5 pontos; Parte II, 4,5 pontos; **qualidade do notebook**, 1,0 ponto — roda do começo ao fim, está organizado por tarefa, explica *antes* de cada bloco de código o que ele vai fazer, tem gráficos legíveis, etc.

2 Os dados

Os dois conjuntos são do *UCI Machine Learning Repository* (<https://archive.ics.uci.edu>), um dos repositórios públicos de dados mais usados em aprendizado de máquina; os dois também estão no Kaggle. Ambos são distribuídos sob a licença CC BY 4.0. Os arquivos que você recebe são os originais, convertidos de planilha para **.csv sem limpeza nenhuma**: só os nomes das colunas do concreto foram traduzidos, e a resposta do crédito foi renomeada para **default**. Tudo o que houver de estranho nos dados está lá de propósito — ou melhor, está lá porque dados reais são assim.

2.1 Parte I — **concreto.csv**: resistência do concreto à compressão

Fonte. I.-C. Yeh (1998), “Modeling of strength of high-performance concrete using artificial neural networks”, *Cement and Concrete Research* 28(12), 1797–1808. Repositório UCI, *Concrete Compressive Strength*, DOI [10.24432/C5PK67](https://doi.org/10.24432/C5PK67).

O problema. O concreto é o material mais usado na engenharia civil, e a sua resistência à compressão é a propriedade que define para que ele serve. Ela depende da *receita* — as quantidades de cimento, água, aditivos e agregados em um metro cúbico de mistura, o que os engenheiros chamam de **traço** — e da **idade**: o concreto continua ganhando resistência por meses depois de moldado. Medir a resistência exige moldar corpos de prova, esperar e rompê-los numa prensa, o que é caro e lento — a norma usual é esperar 28 dias. Um bom preditor permitiria estimar a resistência de um traço *novo* antes de ensaiá-lo.

As variáveis. São $n = 1030$ ensaios de laboratório, sem valores faltantes:

coluna	significado	unidade
cimento	cimento Portland	kg/m ³ de mistura
escoria	escória de alto-forno (subproduto siderúrgico)	kg/m ³
cinza_volante	cinza volante (subproduto de termelétricas)	kg/m ³
agua	água	kg/m ³
superplastificante	aditivo que dá fluidez com menos água	kg/m ³
agregado_graudo	brita	kg/m ³
agregado_miudo	areia	kg/m ³
idade	idade do corpo de prova no ensaio	dias (1 a 365)
resistencia	resposta: resistência à compressão	MPa

Um fato da engenharia que pode vir a ser útil: a **lei de Abrams** (1918) diz que, para os mesmos materiais, a resistência cai com a **razão água/cimento** — é a regra mais antiga e mais citada da dosagem de concreto.

2.2 Parte II — `credito.csv`: inadimplência no cartão de crédito

Fonte. I.-C. Yeh e C.-H. Lien (2009), “The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients”, *Expert Systems with Applications* 36(2), 2473–2480. Repositório UCI, *Default of Credit Card Clients*, DOI [10.24432/C55S3H](https://doi.org/10.24432/C55S3H).

O problema. São $n = 30\,000$ clientes de um banco de Taiwan, acompanhados de abril a setembro de 2005. Para cada um, sabe-se o limite de crédito, alguns dados cadastrais e o histórico dos últimos seis meses — se pagou em dia ou com atraso, quanto veio na fatura e quanto pagou. A resposta é se o cliente **ficou inadimplente no mês seguinte** (outubro de 2005). Os valores estão em dólares de Taiwan (NT\$).

coluna	significado
ID	número do cliente
LIMIT_BAL	limite de crédito concedido (NT\$), individual mais o da família
SEX	1 = masculino; 2 = feminino
EDUCATION	1 = pós-graduação; 2 = universidade; 3 = ensino médio; 4 = outros
MARRIAGE	1 = casado(a); 2 = solteiro(a); 3 = outros
AGE	idade (anos)
PAY_0, PAY_2, ..., PAY_6	situação do pagamento em setembro (PAY_0), agosto (PAY_2), ..., abril (PAY_6): -1 = pagou em dia; 1 = um mês de atraso; 2 = dois meses; ...; 9 = nove meses ou mais. (Não existe PAY_1: o nome é assim no original.)
BILL_AMT1, ..., BILL_AMT6	valor da fatura (NT\$) em setembro, agosto, ..., abril
PAY_AMT1, ..., PAY_AMT6	valor pago (NT\$) em setembro, agosto, ..., abril
default	resposta: 1 se ficou inadimplente em outubro, 0 se não

A descrição acima é a da documentação oficial. Você vai encontrar nos dados códigos que ela não descreve; tratá-los é parte da Tarefa C1.

3 Parte I — Regressão: a resistência do concreto (4,5 pontos)

R1. Conhecendo os dados

(0,6 ponto)

Antes de ajustar um modelo, vamos olhar para os dados.

- Quantas observações e covariáveis há? O problema é de regressão ou de classificação?
- Faça o histograma da resistência e os diagramas de dispersão da resistência contra a idade e contra a razão água/cimento. Qual das relações é mais visivelmente não linear? Em que idades os ensaios foram feitos?
- Procure **linhas duplicadas**, contando as que repetem uma linha anterior (é o que o `duplicated()` do `pandas` conta): quantas repetem uma linha anterior por inteiro, e quantas repetem só as oito covariáveis (estas incluem aquelas)? Uma resistência medida em laboratório, igual a outra até a oitava casa decimal, é um segundo ensaio ou outra coisa? Decida o que fazer com as linhas inteiramente repetidas, **justifique**, e siga com essa decisão no resto da Parte I.

- (d) Um grupo de linhas com as mesmas oito covariáveis é um conjunto de **réplicas** — o mesmo experimento repetido —, desde que cada linha seja um ensaio de verdade. Com esses grupos dá para estimar o erro irreduzível $\sigma^2 = \text{Var}(Y | \mathbf{X} = \mathbf{x})$ sem modelo nenhum, pela variância combinada dentro dos grupos,

$$\hat{\sigma}^2 = \frac{\sum_g \sum_{i \in g} (Y_i - \bar{Y}_g)^2}{\sum_g (n_g - 1)},$$

em que g percorre os grupos, n_g é o tamanho do grupo e $\bar{Y}_g$ a sua média. Calcule $\hat{\sigma}^2$ com todos os grupos de linhas com as mesmas oito covariáveis, *antes* e *depois* da decisão do item (c), com os graus de liberdade $\sum_g (n_g - 1)$ de cada caso, e um intervalo de 95% para σ^2 supondo normalidade e variância constante. O que essa estimativa diz sobre o menor erro quadrático médio que *qualquer* preditor poderia atingir?

- (e) O mesmo **traço** (as sete quantidades de ingredientes) foi ensaiado em várias idades. Crie uma coluna que identifique o traço,

```
1 componentes = ["cimento", "escoria", "cinza_volante", "agua",
2               "superplastificante", "agregado_graudo", "agregado_miudo"]
3 concreto["traco"] = concreto.groupby(componentes).ngroup()
```

e conte: quantos traços distintos há, e quantas linhas por traço? Por que isso significa que as linhas da tabela *não* são observações independentes umas das outras?

R2. Protocolo de avaliação

(0,4 ponto)

A pergunta que queremos responder é: *qual a resistência de um traço que ainda não foi ensaiado?*

- (a) Separe o conjunto de teste **por traço**, exatamente assim:

```
1 import sklearn.model_selection as skm
2 X = concreto[componentes + ["idade"]]
3 y = concreto["resistencia"]
4 separa = skm.GroupShuffleSplit(n_splits=1, test_size=0.25, random_state=2026)
5 i_tr, i_te = next(separa.split(X, y, groups=concreto["traco"]))
```

O X tem só as oito covariáveis originais: a coluna **traco** identifica o grupo, não é covariável. Quantas linhas e quantos traços ficaram em cada lado? Confira que nenhum traço aparece nos dois.

- (b) Por que separar por traço, e não por linha com **train_test_split**? Que tipo de vazamento — grave ou leve — a separação por linha produziria, e para qual pergunta ela seria, ao contrário, a separação certa?
- (c) Toda escolha de hiperparâmetro da Parte I será feita por validação cruzada de 5 dobras **em grupo**, dentro do treino, passando **groups=** os traços do treino:

```
1 dobras = skm.GroupKFold(n_splits=5, shuffle=True, random_state=0)
```

Reporte sempre o risco estimado como **média** $\pm$ **erro-padrão** das cinco dobras. O que esse erro-padrão mede, e o que ele *não* mede?

R3. Modelos lineares e regularização

(0,9 ponto)

- (a) Estime o risco do **preditor constante** (a média do treino, `DummyRegressor`) e do **MQO** nas oito covariáveis originais. Some as sete colunas de ingredientes linha a linha: o que você observa? Calcule o número de condição de $\mathbb{X}^\top \mathbb{X}$ (com a coluna de uns) nas escalas original e padronizada. Com isso em mente, faz sentido ler o coeficiente da água como “o efeito de aumentar a água em 1 kg/m³ mantendo as outras covariáveis fixas”?
- (b) Troque a idade por $\log(\text{idade})$ e acrescente a razão água/cimento — duas covariáveis construídas, nove ao todo — e reestime o risco do MQO. Por que o modelo continua sendo uma regressão *linear*? De onde veio o ganho, em termos de viés e variância?
- (c) Sobre as covariáveis de (b), faça a expansão polinomial de grau 2 (`PolynomialFeatures`) e ajuste MQO, Ridge e Lasso, com a padronização *dentro* do *pipeline*. Escolha o λ do Ridge e o do Lasso por validação cruzada numa grade logarítmica e mostre a curva do risco estimado contra λ , com barras de um erro-padrão. Aplique também a **regra de um erro-padrão**. Quantos coeficientes o Lasso zera em cada escolha? Faça o gráfico do caminho de regularização do Lasso.
- (d) Por que foi preciso padronizar antes do Ridge e do Lasso, e não antes do MQO? O λ escolhido para o Ridge e o escolhido para o Lasso podem ser comparados diretamente no `scikit-learn`?

R4. Validação cruzada, LOOCV e *bootstrap*

(0,6 ponto)

Use o MQO com as covariáveis de R3(b).

- (a) Implemente à mão a validação cruzada em grupo, dobra a dobra, com as dobras de R2(c). As dobras têm o mesmo tamanho? Calcule o risco pela média *simples* dos cinco EQM e pela média *ponderada* pelo tamanho das dobras (a fórmula das notas de aula), e compare com o `cross_val_score`.
- (b) Calcule o LOOCV de duas formas: com n ajustes, e pelo atalho da *leverage* h_{ii} , com um único ajuste. Confira que coincidem. O LOOCV fica acima ou abaixo da validação em grupo? Por quê, e qual dos dois responde à pergunta de R2?
- (c) Estime o erro-padrão de cada coeficiente de três formas: pela fórmula clássica, a raiz da diagonal de $\hat{\sigma}^2(\mathbb{X}^\top \mathbb{X})^{-1}$, com $\hat{\sigma}^2 = \text{RSS}/(n - p - 1)$; por *bootstrap* das **linhas**; e por *bootstrap* dos **traços** — sorteando traços inteiros, com reposição, e levando todas as linhas de cada traço sorteado. Use $B = 2000$ e o gerador `np.random.default_rng(2026)`. Compare as três colunas. Qual reamostragem imita o jeito como os dados foram coletados?

R5. Métodos não paramétricos: KNN

(0,5 ponto)

- (a) Ajuste o KNN com as covariáveis padronizadas, escolhendo k de 1 a 30 por validação cruzada, e mostre a curva do risco estimado contra k . Qual k foi escolhido? Ajuste também o KNN *sem* padronizar, com o mesmo k , e explique a diferença (pense em quanto cada covariável pesa na distância, com e sem padronização).

R6. Árvores, *bagging* e florestas

(0,5 ponto)

- (a) Ajuste uma árvore de regressão cheia e calcule o seu erro de treino e o seu risco estimado. Depois, faça a poda por custo-complexidade, escolhendo o `ccp_alpha` por validação cruzada. Desenhe a árvore com profundidade 3 (`plot_tree`) e interprete os três primeiros cortes.

- (b) Ajuste o *bagging* e florestas aleatórias com m (`max_features`) de 1 a 8. Mostre o risco estimado contra m . Qual é o padrão de `max_features` no `RandomForestRegressor`, e o que isso quer dizer? Use o piso ρv da variância para explicar a forma da curva.
- (c) Mostre o risco estimado da floresta escolhida contra o número de árvores B , de 1 a algumas centenas. Por que B não é escolhido por validação cruzada como m ?

R7. Sensibilidade à escala

(0,5 ponto)

- (a) Suponha que os mesmos dados chegassem com a idade em **horas**, e não em dias: crie uma cópia das covariáveis de treino com a coluna **idade** multiplicada por 24, sem mexer em mais nada. Estime o risco dos seis modelos abaixo, todos nas oito covariáveis originais, *duas vezes*: com a idade em dias e com a idade em horas. Use a validação cruzada em grupo de R2(c) e mantenha fixos os hiperparâmetros — nada é reescolhido na segunda estimativa.
 - o MQO;
 - o Lasso com `alpha=1`, com as covariáveis padronizadas dentro do *pipeline*;
 - o KNN com $k = 5$, sem padronizar;
 - o mesmo KNN, com as covariáveis padronizadas dentro do *pipeline*;
 - a árvore podada de R6(a), com o `ccp_alpha` escolhido lá;
 - a floresta de R6(b), com o m escolhido lá.

Monte uma tabela com uma linha por modelo e uma coluna para cada unidade. Quais riscos mudaram com a troca de unidade, e quais ficaram iguais? Explique, modelo a modelo, por que a unidade da idade afeta ou não o resultado.

R8. Escolha final e teste

(0,5 ponto)

- (a) Monte uma tabela com o risco estimado ($\pm$ erro-padrão) de pelo menos um modelo de cada família: constante, linear regularizado, KNN, árvore e floresta. Escolha **um** modelo final e justifique — a regra de um erro-padrão pode entrar no argumento.
- (b) Reajuste o modelo escolhido em *todo* o treino e meça, **uma vez**, o EQM no teste, com um intervalo de 95% para o risco. O EQM de teste ficou acima ou abaixo da estimativa da validação cruzada?
- (c) Só agora, calcule o EQM de teste dos outros finalistas — para leitura, sem trocar a escolha. Os intervalos se sobrepõem? Algum modelo foi muito pior no teste do que a validação previa? Investigue os maiores erros dele: as covariáveis dessas observações estão dentro do intervalo visto no treino?
- (d) Em um parágrafo, tente explicar para alguém que não fez este curso: o que o modelo consegue prever, com que erro típico (em MPa), e em que situação você não confiaria nele.

4 Parte II — Classificação: inadimplência no cartão de crédito (4,5 pontos)

C1. Conhecendo os dados

(0,4 ponto)

- (a) Qual a proporção de inadimplentes? Qual a acurácia do classificador que diz “ninguém fica inadimplente”? O que isso antecipa sobre a acurácia como métrica neste problema?

- (b) Tabele os valores de `SEX`, `EDUCATION`, `MARRIAGE` e `PAY_0`. Que códigos aparecem sem estar na documentação? Decida o que fazer com eles e justifique. Quais dessas colunas são nominais, e o que isso exige antes de usá-las num modelo que soma covariáveis? E o `ID`?
- (c) Os `PAY_*` misturam atrasos (1 a 9 meses, uma escala ordinal) com códigos ($-2, -1, 0$) que não são “quantidades de atraso”. Que problema isso cria para um modelo linear que usa `PAY_0` como número? Proponha uma alternativa.
- (d) Calcule a matriz de correlação das seis colunas `BILL_AMT`. Para qual dos classificadores generativos isso é uma má notícia, e por quê?
- (e) `SEX`, `AGE` e `MARRIAGE` são covariáveis disponíveis. Em uma linha: vê algum problema em usá-las para decidir quem recebe crédito? (Não é preciso retirá-las do modelo; é preciso pensar nisso.)

C2. Protocolo e custos

(0,4 ponto)

- (a) Separe o teste de forma estratificada, exatamente assim, e use estas dobras em toda validação cruzada da Parte II (os nomes com `c` evitam sobrescrever as variáveis da Parte I):

```
1 Xc_tr, Xc_te, yc_tr, yc_te = skm.train_test_split(
2     Xc, yc, test_size=0.25, stratify=yc, random_state=2026)
3 dobras_c = skm.StratifiedKFold(5, shuffle=True, random_state=0)
```

Por que estratificar aqui, se na Parte I a separação foi por grupo? Há alguma unidade repetida nestes dados?

- (b) O banco vai usar o modelo para decidir **quem contatar** com uma proposta de renegociação antes do vencimento. Contatar um cliente que pagaria de qualquer jeito custa $c_{FP} = 1$ (tempo da equipe, desconto concedido sem necessidade); deixar de contatar um cliente que vai ficar inadimplente custa $c_{FN} = 5$. Deduza o corte ótimo para a probabilidade verdadeira $\mathbb{P}(Y = 1 \mid \mathbf{x})$.
- (c) Calcule, no treino, o custo médio por cliente das duas regras triviais, “não contatar ninguém” e “contatar todos”. Qual delas é a referência a bater?

C3. Regressão logística e modelos generativos

(0,8 ponto)

Em toda esta parte, o pré-processamento (padronização das numéricas, *dummies* das nominais) mora dentro do *pipeline*.

- (a) Ajuste a regressão logística com `PAY_*` como número, escolhendo o `C` por validação cruzada com `scoring="neg_log_loss"`. Reporte a razão de chances e^{β_j} de `PAY_0`, de `LIMIT_BAL` e de `BILL_AMT1` e `BILL_AMT2`, e interprete as duas primeiras — atenção à escala em que os coeficientes estão. O que acontece com os sinais de `BILL_AMT1` e `BILL_AMT2`, e por que eles não devem ser lidos isoladamente?
- (b) Ajuste a mesma logística com os `PAY_*` em *dummies* e compare as duas pela AUC, fora da dobra (`cross_val_predict`).
- (c) Ajuste o Bayes ingênuo gaussiano, o LDA e o QDA. O QDA com o `reg_param` padrão ajusta? Leia a mensagem de erro, explique a causa, e escolha um `reg_param` por validação cruzada. Quantos parâmetros de covariância o LDA e o QDA estimam no seu p (depois das *dummies*)?

- (d) Faça o histograma de `LIMIT_BAL` e de `BILL_AMT1` em cada classe. Quais suposições dos modelos generativos são claramente falsas aqui? Isso os impede de classificar bem? (Guarde a pergunta; C4 responde.)

C4. Métricas, custos e calibração

(1,0 ponto)

Toda esta tarefa usa probabilidades **fora da dobra** no treino, e o teste continua guardado:

```
1 p = skm.cross_val_predict(modelo, Xc_tr, yc_tr, cv=dobras_c,
2                             method="predict_proba")[:, 1]
```

- (a) Para a logística com `PAY_*` em *dummies*, no corte 0,5: a matriz de confusão, a acurácia, a sensibilidade, a especificidade, a precisão, o VPN e o F_1 . Compare a acurácia com a de C1(a). Qual erro o modelo comete mais?
- (b) Sobreponha as curvas ROC e as curvas precisão–*recall* da logística de (a), do Bayes ingênuo e do LDA, com a AUC e a precisão média de cada um.
- (c) Compare a **calibração**: o score de Brier e a curva de calibração da logística e do Bayes ingênuo. Que fração das probabilidades do Bayes ingênuo passa de 0,99? Calibre-o com `CalibratedClassifierCV` (`method="isotonic"`) e compare de novo. O que mudou na AUC, e o que mudou no Brier? Por quê?
- (d) Para cada modelo até aqui, calcule o custo médio por cliente no corte 1/6 de C2(b) e o menor custo possível varrendo o corte de 0,02 a 0,95. Em quais modelos o melhor corte fica perto de 1/6, e em quais fica longe? Relacione com o item (c).
- (e) Reajuste a logística com `class_weight="balanced"`. O que acontece com o Brier e com o custo no corte 1/6? Mostre que, se a reponderação multiplica a chance estimada por n_0/n_1 , o corte que corresponde a 1/6 no modelo reponderado é $[\frac{1}{5} \cdot \frac{n_0}{n_1}] / [1 + \frac{1}{5} \cdot \frac{n_0}{n_1}]$, calcule-o e confira com o melhor corte que você encontrou.

C5. SVM

(0,5 ponto)

O custo de treinar o SVC cresce entre n^2 e n^3 . Faça esta tarefa numa subamostra estratificada de 5000 clientes do treino:

```
1 i_sub = skm.train_test_split(np.arange(len(yc_tr)), train_size=5000,
2                               stratify=yc_tr, random_state=2026)[0]
```

- (a) Ajuste a SVM com *kernel* RBF, escolhendo `C` e `gamma` numa grade bidimensional por validação cruzada (`scoring="roc_auc"`), e a SVM linear. Mostre a tabela da grade. O ótimo ficou no interior dela?
- (b) Compare com a logística ajustada na *mesma* subamostra. Como a SVM não estima probabilidades, de onde vem a AUC dela?
- (c) Conte os vetores de suporte para alguns valores de `C`. No `scikit-learn`, o que se espera que aconteça com eles quando `C` cresce? Aconteceu? Explique o que viu pensando na sobreposição das classes.
- (d) Seria razoável usar o corte 1/6 de C2 nas “probabilidades” de `SVC(probability=True)`? Por quê?

C6. KNN, árvores e florestas**(0,6 ponto)**

- (a) Ajuste o KNN (padronizado, dentro do *pipeline*), escolhendo k ímpar por validação cruzada pela AUC. Por que o k escolhido é tão maior do que o da Parte I?
- (b) Ajuste árvores de classificação com Gini e com entropia, de profundidade 3: os cortes coincidem? Depois, faça a poda de uma árvore cheia por custo-complexidade, escolhendo o `ccp_alpha` por validação cruzada com `scoring="neg_log_loss"`. Desenhe a árvore de Gini de profundidade 3 e interprete o primeiro corte.
- (c) Ajuste florestas com $m = \sqrt{p}$ (o padrão do `RandomForestClassifier`), $m \approx p/3$ e $m = p$ (*bagging*), com `min_samples_leaf=5`, e uma com $m = \sqrt{p}$ e folhas cheias, isto é, com o `min_samples_leaf` padrão. Compare AUC e Brier. Opcional: o `AdaBoostClassifier` e o custo dele no corte 1/6.

C7. Escolha final e teste**(0,8 ponto)**

- (a) Monte uma tabela, com probabilidades fora da dobra no treino, de todos os modelos: AUC, precisão média, Brier, custo no corte 1/6, melhor corte e custo nele. Escolha o modelo final *e* o corte, e justifique. Qual das colunas responde à pergunta do banco?
- (b) Reajuste o modelo escolhido em todo o treino e aplique-o **uma vez** ao teste, no corte escolhido: a matriz de confusão, o custo médio por cliente, a sensibilidade e a fração de clientes contatados. Compare com as regras triviais.
- (c) Faça um *bootstrap* **pareado** no teste ($B = 1000$, `np.random.default_rng(2026)`): em cada réplica, sorteie clientes com reposição e calcule, nos *mesmos* clientes, a diferença de AUC e a diferença de custo entre o seu modelo e a logística com `PAY_*` em *dummies*. Dê os intervalos de 95% (percentis). O seu modelo é melhor que a logística? Por que o *bootstrap* precisa ser pareado?
- (d) Em um parágrafo, para a gerente de risco: quantos clientes contatar, quantos inadimplentes isso pega, e o que se ganha em relação a contatar todos.

Para fechar

Se você chegou até aqui, percorreu o curso inteiro — risco, viés e variância, regularização, validação cruzada, métodos não paramétricos, árvores e florestas, *pipelines*, os classificadores generativos e discriminativos, as métricas, a SVM — em dados que ninguém inventou. Repare no que decidiu os resultados mais importantes: quase nunca foi a escolha do método. Foi olhar os dados antes (as duplicatas, o traço, os códigos do `PAY`), avaliar do jeito que responde à pergunta (por grupo, com o custo certo) e desconfiar dos números que pareciam bons demais. É isso que se leva deste curso.