

# Aprendizagem de Máquina I – Lista 05

Referente aos slides “08 Classificacao e classificadores gaussianos”  
e “09 Metricas para classificacao”

Prof. Hugo Carvalho

## Fontes para os exercícios

- [ITSL] Gareth James, Daniela Witten, Trevor Hastie, Rob Tibshirani & Jonathan Taylor - *An Introduction to Statistical Learning, with Applications in Python* [baixe aqui]
- [AME] Rafael Izbicki & Tiago Mendonça dos Santos - *Aprendizado de Máquina: Uma Abordagem Estatística* [baixe aqui]

## Questões do livro

- [ITSL] Capítulo 4
  - Questões conceituais: 7, 8

## Questões avulsas

**Questão 1:** Prove o resultado a seguir para um problema de classificação multiclasse, ou seja, quando  $\mathcal{C}$  tem mais de dois elementos (lembre-se que fizemos, em aula, a prova para o caso de classificação binária):

**Teorema 1.** A função  $g : \mathbb{R}^p \rightarrow \mathcal{C}$  que minimiza o risco  $R(g) = \mathbb{E}[\mathbb{I}(Y \neq g(\mathbf{X}))] = \mathbb{P}(Y \neq g(\mathbf{X}))$  é o classificador de Bayes, dado por  $g(\mathbf{x}) = \operatorname{argmax}_{d \in \mathcal{C}} \mathbb{P}(Y = d | \mathbf{X} = \mathbf{x})$ .

**Questão 2:** Agora vamos provar um resultado análogo no caso de classificação binária ( $\mathcal{C} = \{0, 1\}$ ), mas assumindo que cada erro tem um peso diferente. Formalmente, encontre o classificador  $g : \mathbb{R}^p \rightarrow \mathcal{C}$  que minimiza a função risco abaixo:

$$\begin{aligned} R(g) &= \mathbb{E}[\ell_1 \mathbb{I}(Y \neq g(\mathbf{X}) \text{ e } Y = 0) + \ell_0 \mathbb{I}(Y \neq g(\mathbf{X}) \text{ e } Y = 1)] \\ &= \ell_1 \mathbb{P}(Y \neq g(\mathbf{X}) \text{ e } Y = 0) + \ell_0 \mathbb{P}(Y \neq g(\mathbf{X}) \text{ e } Y = 1). \end{aligned}$$

**Questão 3:** Vimos em aula métricas para avaliar o resultado de uma classificação no caso binário. Estude generalizações dessas métricas para o caso multiclasse. Para isso você precisará estudar duas formas de generalizar classificadores binários para o caso multiclasse, chamadas de *one-versus-one* (OvO) e *one-versus-all* (OvA). Alguns classificadores são naturalmente generalizáveis para o caso multiclasse (por exemplo, classificadores Naive Bayes), mas isso não é o caso para outros classificadores que veremos ao longo do curso, por isso essas generalizações são importantes.

**Questão 4:** Desde a primeira parte curso, referente a modelos regressão, implementamos o seguinte procedimento na validação cruzada: utilizamos validação cruzada no conjunto de treinamento para encontrar o “melhor” modelo dentro de cada classe (por exemplo, o “melhor”  $\lambda_R$  para Ridge, o “melhor”  $\lambda_L$  para o Lasso, o “melhor”  $k$  para o KNN, etc.), retreinamos esses “melhores” modelos de cada classe no conjunto de treinamento todo e escolhemos pelo “melhorzão” comparando o desempenho deles no conjunto de teste. No caso de regressão não conseguimos provar rigorosamente que isso é bom, devido à natureza contínua (e potencialmente ilimitada) da função risco  $R$ . Porém, no caso discreto, como o risco é uma variável aleatória limitada, conseguimos provar coisas interessantes. Para isso, precisaremos de um resultado preliminar:

**Teorema 2** (Desigualdade de Hoeffding). *Para  $W_1, \dots, W_n$  variáveis aleatórias independentes onde cada  $W_i$  tem suporte em  $(a_i, b_i)$ , para todo  $\varepsilon > 0$  vale que:*

$$\mathbb{P}(|\bar{W}_n - \mathbb{E}[\bar{W}_n]| > \varepsilon) \leq 2e^{-2n^2\varepsilon^2 / \sum_{i=1}^n (b_i - a_i)^2},$$

onde  $\bar{W}_n = \frac{1}{n} \sum_{i=1}^n W_i$ .

O resultado que queremos provar pode ser formalmente enunciado como:

**Teorema 3.** *Seja  $\mathbb{G} = \{g_1, \dots, g_N\}$  uma classe de classificadores estimados com base em um conjunto de treinamento e seja  $\hat{R}(g)$  o erro estimado de  $g$  com base no conjunto de teste (de tamanho  $s$ ):*

$$\hat{R}(g) = \frac{1}{s} \sum_{i=1}^s \mathbb{I}(Y_i \neq g(\mathbf{X}_i)) \approx R(g).$$

*Seja  $g^*$  o modelo que minimiza o risco real  $R(g)$ , dentre  $g \in \mathbb{G}$ , e seja  $\hat{g}$  o modelo que minimiza o risco estimado  $\hat{R}(g)$ , dentre  $g \in \mathbb{G}$ . Então, com probabilidade de no máximo  $\varepsilon$ , vale que:*

$$|R(\hat{g}) - R(g^*)| > 2\sqrt{\frac{1}{2s} \log \frac{2N}{\varepsilon}}.$$

Para provar esse resultado siga o roteiro abaixo.

- a) Use a desigualdade de Hoeffding para limitar superiormente a quantidade  $\mathbb{P}(|\hat{R}(g) - R(g)| > \delta)$ , fixado um  $\delta > 0$  e um  $g \in \mathbb{G}$ .
- b) Argumente que

$$\mathbb{P}\left(\max_{g \in \mathbb{G}} |\hat{R}(g) - R(g)| > \delta\right) = \mathbb{P}\left(\bigcup_{g \in \mathbb{G}} \left\{|\hat{R}(g) - R(g)| > \delta\right\}\right),$$

e use que  $\mathbb{P}(\cup A_i) \leq \sum \mathbb{P}(A_i)$  juntamente com o resultado obtido no item a) para limitar superiormente o lado esquerdo da expressão acima.

- c) Escolha um  $\delta$  adequado para concluir o resultado desejado. Tome cuidado pois o resultado desejado envolve  $R(g^*)$  e o que provamos acima não tem essa quantidade. Você terá que fazer uma malandragem para conseguir fazer aparecer o  $R(g^*)$ .
- d) Interprete o resultado obtido, relacionando-o com a interpretação proposta no início da presente questão.
- e) À luz do resultado provado e de sua interpretação, argumente porque a estratégia de “treinar todo mundo no conjunto de treino e compará-los no conjunto de teste para encontrar o ‘melhor’ modelo” é, provavelmente, pior do que a estratégia proposta no início da questão.
- f) Justifique porque essa prova não vale para um problema de regressão.
- g) Prove a desigualdade de Hoeffding.