

Aprendizagem de Máquina I – Avaliação Presencial 01

Prof. Hugo Carvalho

07/10/2025

Questão 1: Considere um conjunto de dados artificial de n observações, onde cada observação consiste de um vetor de p atributos independentes e identicamente distribuídos, seguindo uma distribuição de probabilidade qualquer. Sejam $\mathbf{X}^{(i)}$ e $\mathbf{X}^{(j)}$ dois vetores independentes de observações gerados de acordo com esse processo, ou seja, ambos de tamanho p , consistindo de entradas independentes e identicamente distribuídas da mesma distribuição.

- a) Mostre que a quantidade abaixo, chamada de *coeficiente de variação* satisfaz:


$$\text{cv} \left(\left\| \mathbf{X}^{(i)} - \mathbf{X}^{(j)} \right\|^2 \right) = \frac{\sqrt{\mathbb{V} \left(\left\| \mathbf{X}^{(i)} - \mathbf{X}^{(j)} \right\|^2 \right)}}{\mathbb{E} \left[\left\| \mathbf{X}^{(i)} - \mathbf{X}^{(j)} \right\|^2 \right]} \propto \frac{1}{\sqrt{p}}.$$

Fórmula útil: Para variáveis aleatórias quaisquer $X_1, \dots, X_n$ temos que $\mathbb{V}(\sum_i X_i) = \sum_i \mathbb{V}(X_i) + 2 \sum_{i < j} \text{Cov}(X_i, X_j)$.

Dica: A quantidade $\left\| \mathbf{X}^{(i)} - \mathbf{X}^{(j)} \right\|^2$ pode ser escrita como $\sum_{k=1}^p \left(X_k^{(i)} - X_k^{(j)} \right)^2 = \sum_{k=1}^p Z_k^2$, onde cada Z_k é a diferença de duas variáveis aleatórias independentes e identicamente distribuídas. Lembre-se que o valor esperado é um operador linear, e mesmo a variância não sendo, sob hipótese de independência, as coisas ficam significativamente mais simples. Repare que a questão não pede a constante de proporcionalidade, portanto sua resposta pode (e deve) depender de valores não calculados. Seguindo essas dicas direitinho, a conta sai em uma linha.

- b) Relacione o resultado acima com o que acontece com o KNN quando temos p grande e n pequeno.

Questão 2:



- a) O painel da esquerda na figura acima representa um particionamento binário recursivo do espaço dos atributos X_1 e X_2 . Esboce a árvore de regressão correspondente a esse particionamento. Os números dentro de cada retângulo correspondem à média da variável resposta dentro de cada região e devem estar nos nós terminais adequados de sua árvore.
- b) O painel da direita na figura acima representa uma árvore de regressão. Esboce o particionamento binário recursivo do espaço das covariáveis X_1 e X_2 correspondente à essa árvore. Os números nos nós terminais correspondem às previsões da variável resposta em cada nó terminal, e tais valores devem estar no seu esboço, dentro das regiões adequadas.

– VEJA A QUESTÃO 3 NO VERSO –

Questão 3: Lembremos do balanço entre o viés e a variância, que pode ser formulado como:

$$\mathbb{E}_{\mathbf{X}, Y, \mathcal{D}}[(\hat{f}(\mathbf{X}; \mathcal{D}) - Y)^2] = \int (\mathbb{E}_{\mathcal{D}}[\hat{f}(\mathbf{x}; \mathcal{D})] - \hat{f}_{\text{opt}}(\mathbf{x}))^2 p(\mathbf{x}) d\mathbf{x} + \quad (1)$$

$$\int \mathbb{E}_{\mathcal{D}}[(\hat{f}(\mathbf{x}; \mathcal{D}) - \mathbb{E}_{\mathcal{D}}[\hat{f}(\mathbf{x}; \mathcal{D})])^2] p(\mathbf{x}) d\mathbf{x} + \quad (2)$$

$$\iint (\hat{f}_{\text{opt}}(\mathbf{x}) - y)^2 p(\mathbf{x}, y) d\mathbf{x} dy. \quad (3)$$

A relação entre os atributos $\mathbf{X}$ e a resposta Y é modelado através da relação $Y = f(\mathbf{X}) + \varepsilon$, onde ε é independente de $\mathbf{X}$ e tem média zero e os dados $(\mathbf{X}, Y)$ seguem uma distribuição de probabilidade conjunta $p(\mathbf{x}, y)$. Na equação acima, $\hat{f}(\mathbf{x}; \mathcal{D})$ é uma estimativa de f obtida a partir de um determinado conjunto de observações $\mathcal{D}$, e $\hat{f}_{\text{opt}}(\mathbf{x}) = \mathbb{E}_Y[Y|\mathbf{X} = \mathbf{x}]$ é a estimativa ótima de f , no sentido de minimizar o erro quadrático médio.

- a) Argumente porque os termos (1) e (2) da equação acima são chamados de “viés” e “variância”, respectivamente. Diga também quem é o termo (3).
- b) Forneça um esboço das curvas típicas de viés, variância, erro no conjunto de treinamento, erro no conjunto de testes e erro irreduzível, todas em um mesmo gráfico, ao variar de métodos de aprendizado menos flexíveis para mais flexíveis. O eixo horizontal deve representar o nível de flexibilidade do método e o eixo vertical deve representar os valores de cada curva. Rotule adequadamente cada curva. Justifique o formato de cada uma das cinco curvas que você construiu.

$$\textcircled{1} \textcircled{a} \quad \|\vec{x}^{(i)} - \vec{x}^{(j)}\|^2 = \sum_{k=1}^p \underbrace{(x_k^{(i)} - x_k^{(j)})^2}_{z_k^2} = \sum_{k=1}^p z_k^2.$$

$$\Rightarrow \mathbb{E}[\|\vec{x}^{(i)} - \vec{x}^{(j)}\|^2] = \mathbb{E}\left[\sum_{k=1}^p z_k^2\right] = \sum_{k=1}^p \mathbb{E}[z_k^2] = p \mathbb{E}[z_1^2], \text{ pois os}$$

V.A.s $z_1, \dots, z_p$ têm a mesma distribuição, uma vez que todos os $x_k^{(i)}$, $i=1, \dots, n$ e $k=1, \dots, p$, o têm.

$$\bullet V(\|\vec{x}^{(i)} - \vec{x}^{(j)}\|^2) = V\left(\sum_{k=1}^p z_k^2\right) = \sum_{k=1}^p V(z_k^2) + 2 \sum_{k < l} \text{Cov}(z_k^2, z_l^2)$$


$= p V(z_1^2)$, com a mesma justificativa dada acima.

0, pois as observações $\vec{x}^{(i)}$, $i=1, \dots, n$, são independentes.

$$\Rightarrow CV(\|\vec{x}^{(i)} - \vec{x}^{(j)}\|^2) = \frac{\sqrt{p V(z_1^2)}}{p \mathbb{E}[z_1^2]} = \frac{1}{\sqrt{p}} \frac{\sqrt{V(z_1^2)}}{\mathbb{E}[z_1^2]} \propto \frac{1}{\sqrt{p}}.$$

① (b) À medida que p aumenta, o coeficiente de variação do quadrado da distância das observações diminui, indicando que as observações tendem a se tornar "igualmente espaçadas". Para "compensar" esse fato e ter dados que cubram "bem" todo o espaço de possibilidades, é necessário ter um grande número de observações. Como o KNN se baseia em distâncias, com p grande e n pequeno esperamos uma má performance, justamente pelo espaço não ser adequadamente preenchido com observações.

② (a)



$\begin{cases} \text{Esq.} = \text{SIM} \\ \text{Dir.} = \text{NÃO} \end{cases}$

(2)(b)

x_2	2	2,49	
		-1,06	0,121
	1	-1,80	0,63
		0	1
		x_1	


$$\begin{cases} \text{Esq.} = \text{SEM} \\ \text{Dir.} = \text{HFO} \end{cases}$$

(3)(a) O termo (1) é a média, sobre todos os observáveis $\vec{x}$, da diferença $\left(\mathbb{E}_{\mathcal{D}} [\hat{f}(\vec{x}; \mathcal{D})] - \hat{f}_{\text{opt}}(\vec{x}) \right)^2$, e tal quantidade mede o quanto a estimativa $\hat{f}$ se desvia, em média, do "melhor possível" $\hat{f}_{\text{opt}}$. Isso é bem parecido com a definição de Viés de um estimador $\hat{\theta}$ em inferência estatística $(\mathbb{E}[\hat{\theta}] - \theta)$, sendo θ o valor estimado). Assim, o nome "viés" é justificado.

O termo (2) é a média, em todos os $\vec{x}$, da quantidade $\mathbb{E}_{\mathcal{D}} \left[\left(\hat{f}(\vec{x}; \mathcal{D}) - \mathbb{E}_{\mathcal{D}} [\hat{f}(\vec{x}; \mathcal{D})] \right)^2 \right]$.

Tal termo mede o quanto $\hat{f}$ se desvia de sua média $\mathbb{E}_{\mathcal{D}}[\hat{f}]$, ao variar o conjunto de dados $\mathcal{D}$, e parece bastante a definição da variância, justificando esse nome.

Finalmente, o termo (3) nos depõe de $\hat{f}$, mas só de $\left(\hat{f}_{\text{opt}}(\vec{x}) - y \right)^2$, sendo referente a "quanto a melhor estimativa erra", ou seja, a parcela irreduzível de erro.



- (i) Métodos mais flexíveis são mais capazes de capturar a função f "verdadeira", tendo, portanto, menor viés.
- (ii) Métodos mais flexíveis têm um treinamento mais complexo, podendo ser mais sensíveis a variações no conjunto de dados, tendo, portanto, maior variância.
- (iii) ~~flex~~ Métodos mais flexíveis são mais capazes de aprender o ruído ϵ inerente aos dados observados, tendo, portanto, menor erro no conjunto de treinamento.

Pelo motivo acima, métodos mais flexíveis não generalizam bem fora do conjunto de treinamento, justificando o erro alto no conjunto de teste.

Similares mente, métodos pouco flexíveis não aprendem complexidades nos dados, de modo que apresentam alto erro tanto no treino quanto no teste.

- (v) O erro irreduzível depende apenas do processo gerador de dados, de modo que ele é constante

Se variar o método de aprendizado. A curva

(iii) pode estar abaixo da (iv) (over fitting), mas

a (iv) deve estar sempre acima de (v).